



全日制硕士学位论文

基于因素分析的因果森林算法研究 Research on Causal Forest Algorithm based on Factor Analysis

作者姓名：_____林凯乐_____

导师姓名：_____曾繁慧 教授_____

学科专业：_____数学_____

研究方向：_____智能科学的数学理论及应用_____

完成日期：_____2024 年 6 月 20 日_____

辽宁工程技术大学

Liaoning Technical University

中图分类号 O29

学校代码 10147

UDC 510

密 级 公 开

辽宁工程技术大学
全日制硕士学位论文

基于因素分析的因果森林算法研究
Research on Causal Forest Algorithm based on
Factor Analysis

作者姓名 林凯乐 学 号 472121459

导师姓名 曾繁慧（教授） 副导师姓名

申请学位 理学硕士 培养单位 理学院

学科专业 数学 研究方向 智能科学的数学理论及应用

二〇二四年六月

摘要

在当今信息化飞速发展的时代，各行各业正朝着智能化方向前进，大数据规模不断增长，因此，如何从海量数据中自动挖掘出有价值的信息变得至关重要。分析数据是数据挖掘的主要任务，也是信息技术领域的重要研究方向之一。汪培庄提出因素空间这一由我国自主创新的原创理论，启动了因素思维的新篇章。在因素空间理论中，因素是因果分析的要素，因素之间存在着关联和因果两种关系。因素分析法作为因素空间理论的核心算法之一，可以快速地从数据集中提取出条件因素对结果因素的推理规则，用于决策支持。然而，在实际应用中，该方法也存在过拟合、对噪声敏感等问题，限制了其决策效用的发挥。为提高单一分类器的分类性能以及泛化能力，集成学习是目前用于处理分类问题以及优化模型的广泛学习策略。

本文的主要工作如下：

第一，为解决分类问题，基于因素空间理论的决定度，利用因素分析法，将条件因素对结果因素的推理规则的原理和步骤进行分析，提出了基于树结构的因果树算法。使用 UCI 数据库中的 Lymphography 数据集说明因果树算法存在的过拟合问题。

第二，为解决因果树算法过拟合的问题以及提高单一因果树的准确率，利用自助抽样法得到多个大小相同的不同的数据集，从而建立多个不同的因果树模型，提出因果树聚合算法，给出算法原理和步骤。对 UCI 数据库中的 8 个分类数据集进行实验分析，将因果树算法、ID3 算法和 Bagging 算法作为对比算法，实验结果表明因果树聚合的性能优于因果树算法。

第三，为解决条件因素性状取值过多或数据较为复杂对因果树聚合算法产生的影响，基于因素空间理论的决定度，定义因素重要度，提出因果森林算法。通过设置重要度阈值 α ，将因素重要度小于 α 的条件因素删除，同时随机选择因素子空间进行因果树的构建。通过对 UCI 数据库和 Data Fountain 数据平台中的数据集进行实验，与因果树算法、因果树聚合算法、随机森林算法进行对比分析，实验结果表明因果森林算法在大多数数据集上取得了较好的性能。本文的研究拓展了因素空间理论的研究及应用。

本论文有图 21 幅，表 15 个，参考文献 74 篇。

关键词：因素空间；因果树算法；因果树聚合算法；因素重要度；因果森林算法

Abstract

In the era of rapid development of information technology, various industries are moving towards intelligence, and the scale of big data is constantly growing. Therefore, it is crucial to automatically mine valuable information from massive data. Analyzing data is the main task of data mining and an important research direction in the field of information technology. Wang Peizhuang proposed the original theory of factor space, which was independently innovated by China, and launched a new chapter of factor thinking. In factor space theory, factors are the elements of causal analysis, and there are two types of relationships between factors: correlation and causality. As one of the core algorithms of factor space theory, factor analysis method can quickly extract inference rules between conditional factors and result factors from datasets, construct causal trees, and use them for decision support. However, in practical applications, this method also has issues such as over-fitting and sensitivity to noise, which limit its decision-making effectiveness. To improve the classification performance and generalization ability of a single classifier, ensemble learning is currently a widely used learning strategy for handling classification problems and optimizing models.

The main work of this paper is as follows:

Firstly, to solve the classification problem, based on the degree of determination of factor space theory, using factor analysis method, analyze the principle and steps of the inference rules between conditional factors and result factors, and propose a causal tree algorithm based on tree structure. Use the Lymphography dataset from the UCI database to illustrate the over-fitting problem of the causal tree algorithm.

Secondly, in order to solve the problem of over-fitting in the causal tree algorithm and improve the accuracy of a single causal tree, using self sampling method to obtain multiple datasets of the same size, establish multiple different causal tree models, propose a causal tree ensemble algorithm, and provide the algorithm principle and steps. Experimental analysis was conducted on 8 datasets in the UCI classification dataset, using causal tree algorithm, ID3 algorithm, and Bagging algorithm as comparison algorithms. The experimental results showed that the performance of causal tree ensemble was better than that of causal tree algorithm.

Thirdly, in order to address the impact of too many conditional factor state values or complex data on the causal tree ensemble algorithm, based on the degree of determination of factor space theory, the factor importance is defined, and the causal forest algorithm is proposed. By setting an importance threshold α , conditional factors with an importance less than α are

removed, and randomly select factor subspaces to construct a causal tree. By conducting experiments on datasets from UCI database and Data Fountain data platform, and comparing them with causal tree algorithm, causal tree ensemble algorithm, and random forest algorithm, the experimental results show that causal forest algorithm has achieved good performance on most datasets. This study expands the research and application of factor space theory.

There are 21 figures, 15 tables, and 74 references in this paper.

Keywords: factor space; causal tree algorithm; causal tree ensemble algorithm; factor importance; causal forest algorithm

目 录

1 绪论.....	1
1.1 研究背景.....	1
1.2 研究现状.....	1
1.3 存在问题及研究意义.....	4
1.4 结构安排.....	5
2 理论基础.....	7
2.1 因素空间理论.....	7
2.2 集成学习算法.....	10
2.3 评价指标.....	13
3 因果树算法研究	16
3.1 决定度.....	16
3.2 因果树算法.....	17
3.3 实验分析.....	22
3.4 小结.....	24
4 因果树聚合算法研究	25
4.1 因果树聚合算法.....	25
4.2 实验分析.....	30
4.3 小结.....	34
5 因果森林算法研究	35
5.1 因素重要度.....	35
5.2 因果森林算法.....	37
5.3 实验分析.....	41
5.4 小结.....	45
6 结论与展望.....	46
参考文献.....	47

图清单

图序号	图名称	页码
图 1.1	技术路线	6
Figure 1.1	Technical route	6
图 2.1	集成学习一般结构	10
Figure 2.1	General structure of ensemble learning	10
图 2.2	Bagging 算法学习过程	11
Figure 2.2	Learning process of bagging algorithm	11
图 2.3	Boosting 算法学习过程	12
Figure 2.3	Learning process of boosting algorithm	12
图 2.4	随机森林算法学习过程	13
Figure 2.4	Learning process of random forest algorithm	13
图 3.1	某商品购买问题的因果树	17
Figure 3.1	A causal tree of product purchase problem	17
图 3.2	因果树算法流程图	19
Figure 3.2	Causal tree algorithm flowchart	19
图 3.3	选择“知名度”作为根节点	20
Figure 3.3	Selection of “fame” as root node	20
图 3.4	图 3.3 的进一步分析	21
Figure 3.4	Further analysis of figure 3.3	21
图 3.5	表 3.2 的因果树	21
Figure 3.5	Causal tree of table 3.2	21
图 3.6	每折测试集准确率	22
Figure 3.6	Accuracy of each fold test set	22
图 4.1	因果树聚合算法流程图	27
Figure 4.1	Causal tree ensemble algorithm flowchart	27
图 4.2	表 4.1 的因果树	28
Figure 4.2	Causal tree of table 4.1	28
图 4.3	表 4.2 的因果树	29
Figure 4.3	Causal tree of table 4.2	29
图 4.4	算法的准确率	32
Figure 4.4	Accuracy of algorithms	32
图 4.5	算法的精确率	33
Figure 4.5	Precision of algorithms	33
图 4.6	算法的召回率	33
Figure 4.6	Recall of algorithms	33
图 4.7	算法的 F1 值	34
Figure 4.7	F1 value of algorithms	34
图 5.1	因果森林算法流程图	41

Figure 5.1	Flow chart of causal forest algorithm	41
图 5.2	α 大小与单个树准确率的关系	43
Figure 5.2	Relationship between accuracy of a single tree and α threshold	43
图 5.3	基学习器个数与分类准确率的关系	43
Figure 5.3	Relationship between the number of base learners and classification accuracy	43

表清单

表序号	表名称	页码
表 2.1	二分类结果的混淆矩阵	14
Table 2.1	Confusion matrix for dichotomous results	14
表 3.1	因果分析表	16
Table 3.1	Causal analysis table	16
表 3.2	某商品销量分析表	20
Table 3.2	Sales analysis table for a certain product	20
表 3.3	Lymphography 数据集情况	22
Table 3.3	Lymphography dataset situation	22
表 4.1	评价因果分析表	28
Table 4.1	Evaluation causal analysis table	28
表 4.2	新的评价因果分析表	29
Table 4.2	New evaluation causal analysis table	29
表 4.3	评价因果分析表测试集	29
Table 4.3	Evaluation causal analysis table test set	29
表 4.4	实验数据说明	30
Table 4.4	Explanation of experimental data	30
表 4.5	实验结果对比	31
Table 4.5	Comparison of experimental results	31
续表 4.5	实验结果对比	32
Continue table 4.5	Comparison of experimental results	32
表 5.1	评价分析表	36
Table 5.1	Evaluation analysis table	36
表 5.2	因果森林算法	40
Table 5.2	Causal forest algorithm	40
表 5.3	实验数据说明	42
Table 5.3	Explanation of experimental data	42
表 5.4	用户流失的因果分析表	42
Table 5.4	Causal analysis of user churn	42
表 5.5	各算法比较	44
Table 5.5	Comparison of various algorithms	44
表 5.6	实验结果对比	45
Table 5.6	Comparison of experimental results	45

变量注释表

D	论域
f	因素
$X(f)$ 或 $I(f)$	性状空间
(D,F)	因素空间
$F = \{f_1, f_2, \cdots, f_n\}$	条件因素集
$(D, F = \{f_1, f_2, \cdots, f_n\}; g)$	因果分析表
K	基学习器个数
$d(f_j)$	决定度
$M(f_j)$	因素重要度
α	因素重要度阈值

1 绪论

1.1 研究背景

随着信息网络技术的快速发展，各个领域获得的信息和数据显著增加，特别是近几十年，人们获得的数据量呈现出爆炸式增长的趋势，大数据不仅成为当前技术发展的主流趋势，也成为推动人工智能发展的核心技术之一。大数据和人工智能技术的出现极大地丰富了人们的生活，为日常生活带来了许多便利。但是，为了充分利用这些先进工具，必须有效处理和利用现有的数据资源。在美国底特律举行的第十届国际人工智能大会上，提出了知识发现数据库的概念，人们开始探索如何从数据库中挖掘出有价值的信息和知识。因此，知识发现和数据挖掘成为了当前研究的热门话题。数据挖掘要从数据库中提取出隐含的、未被发现的以及具有潜在应用价值的信息和知识，是一项具有挑战性的任务。有效的数据挖掘不仅需要高效的技术和算法，还需要对数据进行深入理解和精确处理。通过这些方法，可以从数据中发现知识，预测未来趋势，从而做出更加明智的决策。

1982年，在信息科学领域的理论研究中，几个不同国家的学者都在探讨建立以认知为描述对象的知识表达。德国学者 Wille^[1]提出了形式概念分析，通过形式背景对数据进行分析 and 规则提取。波兰学者 Pawlak^[2]提出了粗糙集理论，用于刻画数据的不完整性和不确定性，可以对数据进行分析 and 推理，从中挖掘出隐藏的知识，揭示潜在规律。这些理论共同引领着关系数据库知识挖掘的前沿领域。同年，汪培庄^[3]首次提出了因素空间这一由我国自主创新的原创理论，开启了因素思维的新篇章，建立了知识表示的数学理论，为概念的生成、对象的区别判断和推理等的数学描述提供了理论框架，为大数据的分析和处理奠定了一定的数学基础。

因素空间理论精准捕捉了事物描述的本质：智能问题。利用因素空间的方式描述大数据和智能科学，不仅在理论层面上使问题的描述更为透彻和精确，在方法上也使得算法更加简洁高效。从目标角度来看，因素空间将视野放得更长远，能够引领大数据时代的思维方式。因素代表了人脑对事物观察的不同视角，因素空间是智能革命的数学符号，构成了信息科学、智能科学和数据科学的共同数学基础。通过在因素空间框架下应用数据挖掘理论，不仅可以深化理论的内在理解，还能显著提升实际应用的效率和效果。因素空间理论下的因素分析法作为该理论的一个重要分支，已广泛应用于实践，显示出其在实际应用中的广泛适用性和深远影响。

1.2 研究现状

（1）因素空间理论

因素空间理论从形成事物的本质出发，用因素分析问题和解决问题，其发展经历了两

个阶段。

① 1982 年-2012 年，因素空间理论的基础研究阶段。

上世纪六十年代，汪培庄在讲授概率论的课程中提出了因素空间的原始思想：随机性是由因素的缺失引起的^[4]。其提出用因素空间处理概率论中柯尔莫戈洛夫所提出的基本空间，把概率论的基本空间看成是因素空间，可以更好地促成随机性向确定性的转化。1982 年，汪培庄^[3]正式公开发表了因素空间的论文，给出了因素空间的定义，为概念、判断、推理等的数学描述提供了理论框架，并在 1994 年与李洪兴^[5]合写了《知识表示的数学理论》一书，进一步扩展了因素空间这一领域。在该书中将因素空间视为探索知识表示的一项关键的理论基础，并提出了概念的反馈和外延等相关表达方式。为了解释概率论中随机性的问题，汪培庄^[6]建立了基于因素空间的模糊落影理论。李洪兴^[7-11]先后在因素空间的知识表示的数学框架、变权理论、综合决策和模糊决策理论方面作出了很多贡献。刘增良^[12-13]把因素空间和人工神经网络结合起来，提出了因素神经网络并应用到军事科学领域。袁学海^[14-15]主要解决了因素空间理论与拓扑学、范畴学等之间的数学关系问题，拓展了因素空间在代数结构方面的理论及应用。于福生^[16-17]将因素空间理论应用于专家系统，提出了多种模糊专家系统的设计方案。

② 2013 年至今，因素空间理论从模糊数学转向智能科学的探索与发展阶段。

2013 年，汪培庄提出了一种新的数据库，即因素库^[18]。这种数据库将表中的关系提升到背景关系。此外，汪培庄还详述了因素库在属性划分中的独特处理方法，为大数据处理带来了新的视角，并显著提升了计算效率。2014 年，汪培庄^[19]等利用因素空间和因素库思想提出因素分析法，该方法在离散情况下定义了决定度，用于表达条件因素对结果因素的单向线性因果关系，是因素库理论的关键算法之一。刘海涛^[20]等利用“知识+推理机”的思想提出了因素分析法的推理模型，有效克服了因训练集样本不完备而导致的对象无法识别问题，提高了因素分析法的准确率。为了更好地利用样本数据，包研科^[21]等提出差转计算算法，提高多因素分类算法的准确性。汪华东^[22]等提出改进的因素分析法，在进行因素叠加划分时按逐列推进的方式选择因素，提高算法的准确率，使算法快速收敛。曲卫华^[23]等提出多标准因果分析法，使因果分析的应用可从单向归纳学习拓展到多向归纳学习。陈万景^[24]等针对因素分析表中的因素实时变化的问题，提出了基于决定度的动态因素约简算法，为处理动态数据库中的因素约简提供了新的方法和思路。孙慧^[25]等为减少利用多目标因果分析法进行规则提取的计算复杂度，提出多目标因果分析降维算法。刘晓同^[26]等提出逆向因果分析算法，并将其应用于银行卡信用违约预测，不仅提高了违约预测的准确性，也生成了更完整的推理规则。目前，因素分析法已经广泛地应用到高血压诊断^[27-28]、煤矿安全^[29-30]、银行^[26]、物联网^[31]等领域。

2018 年，汪培庄^[32]提出了背景基的概念，将原始数据信息转化为背景分布的母体，能

够自动生成概念和推理规则，同时提出了内点判别法构造背景基。曲国华^[33]等探讨了随机性和模糊性中的背景分布与模糊背景关系。吕金辉^[34]等将汪培庄提出的钝角删除法发展为一种精确算法。蒲凌杰^[35]等提出一种新的背景基提取算法，在几乎不损失信息的前提下，显著减少了背景基点的数量。

2024 年，汪培庄^[36]等出版了《因素空间理论—统一智能理论的数学基础》一书，提出了因素显隐思想。人工智能中的一切困难都在于问题求解的关键因素没有显露出来，隐藏的关键因素一旦显露出来，问题就迎刃而解了。寻找隐藏的关键因素，使之显现出来的过程叫做因素显隐。书中介绍了因素显隐的理论，将现有人工智能数学算法归结到回归和优化两大方面，突出了支持向量机与因素空间对支持向量机的改进。

其他有关因素空间的研究还有：崔铁军^[37]等提出空间故障树理论，将空间故障树理论与因素空间理论、云模型、模糊数学及系统稳定性等相结合，为系统演化过程分析的普适框架。崔铁军^[38]等还提出系统故障熵的概念，基于因素空间理论中线性熵的线性均匀度特性，推导了多因素相被划分为两状态时的线性熵模型，可以应用于各领域故障及数据分析。

（2）集成学习

集成学习^[39]是机器学习领域的一个核心研究主题。该方法通过结合多个现有的机器学习模型，可以构建一个整体性能优于任何单一模型的集成模型。集成学习的概念最早是 Hansen^[40]等在 1990 年提出的，当时的研究主要关注如何将多个简单模型（通常是弱学习器）组合起来，以产生一个性能更优越的强学习器。该方法基于一个简单的假设：多个模型通过合作能够取得比单一模型更好的决策效果。

1996 年，Breiman^[41]提出了 Bagging 集成学习方法，是最早提出的集成学习方法之一，主要用于减少模型预测的方差，特别是对于容易过拟合的模型。Zhang^[42]等提出基于树的机器学习算法并结合 Bagging 策略，对滑坡敏感性建模，提高模型的分类性能。Misiuk^[43]等将残差空间协方差作为 Bagging 过程，利用地图误差的空间自相关性和空间采样强度信息解决非独立数据对环境制图影响。Azhagiri^[44]等将 Bagging 和按重要性排序的特征子集结合提出了一种入侵检测系统，可以用最少的特征数预测攻击。Wang^[45]等针对多类别不平衡数据的情况，提出了不平衡 Bagging 框架，该框架可以与轻量级结合，具有较高的分类精度和较低的计算复杂度。Zhang^[46]等开发了一种滑坡易发性建模，采用基学习器为减少错误剪枝的决策树和功能树模型的 Bagging 算法，增强了滑坡易发性预测的整体性能和鲁棒性提高预测精度。目前的 Bagging 算法改进方向主要有：优化采样策略^[47]，例如采用加权采样、分层抽样等；集成不同的模型^[48-49]，例如结合 SVM、神经网络等构建更强大的集成模型；集成策略优化^[50]，除了简单的投票策略，还可以根据基学习器的性能进行加权投票或引入自适应集成策略。

随机森林^[51]是基于 Bagging 的一种算法，通过在决策树的训练过程中引入特征的随机

选择增加模型的多样性。目前的随机森林算法改进方向有：对生成的决策树结构进行优化。传统随机森林使用 CART 决策树生成树，通过控制树的深度避免过拟合和欠拟合，Wang^[52]在 C5.0 算法的基础上提出了一种增强型随机森林算法，可以有效选择分类特征，最大限度地减少信息冗余。Zhang^[53]为提高模型的泛化能力，在随机森林中引入剪枝方法避免过拟合，同时利用合成少数类过采样方法，提出了改进的随机森林的财务管理模型。通过特征选择与组合优化改进。Ma^[54]等先通过相关性分析以光谱数据的分形特征、光谱特征参数和光谱主成分作为特征向量，再基于随机森林算法进行二分类建模，提出了一种融合分形理论的枣树缺水检测方法。结合深度学习方法改进。Wang^[55]等在节点移动和网络拓扑动态更新的条件下提出了一种基于随机森林训练的评估传感器节点信任状态的预测模型，同时融合深度强化学习建立了水声传感器网络动态评估信任模型。对不平衡数据的改进。李强^[56]等将 SMOTE 过采样和随机森林结合应用到商业性养老保险购买行为预测过程中，能够提高模型的性能。汪力纯^[57]等为了更好地处理高维不平衡数据，提出基于混合采样和特征选择的改进随机森林算法。Zhou^[58]等从数据集的构建、自助抽样、决策树生成和多节点投票四个方面对随机森林进行改进，提出一种新的基于随机森林的变压器故障诊断方法。

Boosting^[59-61]是另一种可以提高弱学习器准确率的集成技术，目标是减少偏差。AdaBoost^[62]是由 Yoav Freund 和 Robert Schapire 在 1995 年提出的，是一种流行的 Boosting 方法，通过调整错误分类数据点的权重，使后续的模型更加关注这些点。Nirmal^[63]等提出 CNN 与 AdaBoost 的混合方法来处理维数灾难、数据不平衡等问题，对合法用户和欺诈用户进行分类。宋玉涵^[64]等基于 AdaBoost 模型提出一种具有隐私保护功能的异常交易检测方案。Gradient Boosting^[65]是另一种 Boosting 方法，直接优化一个可微分的损失函数来提升模型的性能，能够灵活地适应各种不同的数据科学问题。XGBoost^[66-68]、LightGBM^[69-70]和 CatBoost^[71-72]是基于 Gradient Boosting 的方法，在算法效率、扩展性以及处理大规模数据集方面进行优化和改进。

Stacking^[73-74]通过训练一个元模型组合多个不同的模型进行预测。这个元模型可以利用每个基模型的输出作为输入来提高预测的准确性。Stacking 的关键在于选择合适的基模型和元学习器，以及如何组合这些模型的输出。

1.3 存在问题及研究意义

为解决智能决策问题，汪培庄提出了因素分析法，通过简化处理大数据中决策问题的复杂性，以一种快速而直观的方式从数据表中提取出条件因素对结果因素的推理规则。这一方法不仅是对人类日常思维过程的摹写，而且也为数据科学的智能化进程揭开了崭新的篇章，是一种有用的归纳方法，具有很高的概括性，是归纳、学习、分类、评价、预测、控制等高级思维活动的统一方法，以它为基础可以向任何领域精细化。然而，在实际应用

中，因素分析法也面临着诸多挑战。因素分析法用决定度衡量条件因素对结果因素的影响程度，当数据集中某些因素的性状取值的样本数量非常少或性状取值较多时，决定度会对噪声数据敏感，容易过拟合，影响模型的性能，限制了其决策效用的发挥。这促使研究者们继续探索更为高效的解决方案，以克服这些限制，进一步推进人工智能的发展。

为进一步提高单一分类器的分类性能以及泛化能力，集成学习是目前用于处理分类问题以及优化模型的广泛学习策略。通过构建多个不同的模型进行决策，可以提高预测的准确性和模型的鲁棒性，减小单一模型的过拟合问题，增强模型在未见数据上的泛化能力。随机森林算法在构建每个分类器时，通过随机选取部分特征进行规则提取，可以减小模型的复杂性。但是，受因素重要度不平衡的影响，随机森林算法可能随机抽取到弱因素子集，从而生成弱分类器，进而导致模型的收敛速度降低、性能下降。因此，本文将因素分析法与集成学习结合，有助于解决复杂的数据分析问题，提高智能决策，对解决因素分析法在分类任务中的局限性具有重要的理论意义和实际应用价值，为人工智能领域带来更广阔的应用前景。

1.4 结构安排

第1章是绪论，主要介绍了本文的研究背景、研究现状、存在问题 and 研究意义。

第2章是基础理论，首先对因素、因素之间的关系与运算、因素空间、背景关系等基础理论进行了概述，然后对几种集成学习算法的思想和学习过程进行阐述，并介绍了几种常用的分类算法评价指标。

第3章是对因果树算法进行研究。首先基于因素空间决定度的定义，根据因素分析法的原理和步骤提出因果树算法，并给出一个算例展示因果树的构建过程。然后通过对 UCI 中的数据集中的数据集进行分析，说明因果树算法存在的过拟合问题，预测效果不佳。

第4章是因果树聚合算法的研究。为解决因果树算法存在的过拟合问题以及提高单一因果树的准确性，通过自助采样法随机生成多个大小相同的不同数据集，得到多个不同的因果树模型，采用聚合的方法对其进行综合考量，在一定程度上提高分类的准确性和泛化能力，并在 UCI 数据集中实验对比聚合前后因果树的分类性能。

第5章是因果森林算法的研究。首先定义了因素重要度的度量方法衡量条件因素对因果分析表分类能力所产生的影响；其次，聚合多个因果树，引入重要度阈值策略，同时加入随机因素选择过程，进而得到因果森林算法；最后在数据集上进行实验分析，并与因果树算法、因果树聚合算法和传统的随机森林算法进行对比分析。

第6章为结论和展望。根据本文的数据实验得出相关结论，并对下一步在该领域中的研究工作进行展望。

本文技术路线见图 1.1。




图 1.1 技术路线

Figure 1.1 Technical route

2 理论基础

本章梳理了因素空间理论的一些基本概念、集成学习算法和常用的分类算法评价指标。

2.1 因素空间理论

本节介绍因素空间理论下因素与因素空间、因素的关系与运算的基础知识。

2.1.1 因素与因素空间

因素是构成事物本质的成分，是决定事物走向的原因或条件，是认识主体观察事物的视角，是信息科学区别于物质科学的起点。因素是广义的基因，基因是生物的质根，每个基因串出一列生物性状。因素是事物的质根，每个因素串出事物的一系列属性或性状。例如颜色这个因素可以串出黑、白、红、绿等性状。从数学方面来看，因素是一种特殊的映射，可以把对象映射到其相上。因素空间相关基础知识如下：

定义 2.1^[32] (因素) 因素 f 是一个映射

$$f: D \rightarrow I(f)$$

其中 D 为论域，是所要讨论的一类事物的集合，叫做 f 的定义域。

定义 2.2^[32] (性状空间) 因素 f 作用在某个特定的对象上得到的特定的性状或相记为 a_i ，称

$$I = I(f) = \{a_1, a_2, \dots, a_k\}$$

为因素 f 的性状空间或相域，其中每个性状或相都不相同。有时 $I(f)$ 也记作 $X(f)$ 。

按照性状空间的不同，可以将因素分为数值型因素、符号型因素、开关型因素和程度型因素四种类型。

(1) 数值型因素又称为可测因素，是一类通过测量得到的普通变量，具有具体的数值表示，并且可以有单位。例如，温度、某人的身高、某商品的价格。

(2) 符号型因素的性状空间由一组离散的符号组成，每个符号代表着某个特定的性状。例如“颜色”这个因素的性状空间可以是“红”、“黑”、“白”、“绿”等。

(3) 开关型因素是性状的取值只有两种情况的因素。例如，“性别”这一因素的性状取值只能是“男”和“女”这两种，某人是否“拥有驾照”这一因素的性状取值也只能是“有”和“没有”两种。

(4) 程度型因素是一类抽象且不能直接测量的因素，但其性状可以通过程度的大小进行度量，性状空间通常用区间 $[0,1]$ 表示。例如，“满意度”这个因素的性状空间可以用 $[0,1]$ 表示，0 表示完全不满意，1 表示完全满意。

定义 2.3^[32] 若 $I(\mathbf{0}) = \{\emptyset\}$ ，则称符号 $\mathbf{0}$ 为零因素。即零因素仅有一个性状，且该性状为空性状。

定义 2.4^[32] 对于因素 f 和 g , 如果存在集合 Y 满足 $Y \neq \Phi$ 且 $Y \neq \{\theta\}$, 使得

$$I(f) = I(g) \times Y$$

则称因素 g 为因素 f 的真子因素, 记作 $f > g$ 。如果 $f > g$ 或 $f = g$ 则称因素 g 为因素 f 的子因素, 记作 $f \geq g$ 。

定义 2.5^[32] 如果以因素 f 和因素 g 为映射, 满足

$$D(f) = D(g), I(f) = I(g)$$

且对任意的 $d \in D(f)$ 有 $f(d) = g(d)$, 则称因素 f 和因素 g 相等。

定义 2.6^[32] 如果 $f(d) \times g(d) = (f \vee g)(d)$, 则称因素 f 与因素 g 独立。如果 $f \wedge g = \mathbf{0}$, 称因素 f 与因素 g 泛独立。

定义 2.7^[32] 对于因素 f, g 和 h , 如果 h 是 f 与 g 的最大公共子因素, 即 $f \geq h, g \geq h$, 且对于任意因素 e , 必有

$$(f \geq e, g \geq e) \Rightarrow h \geq e$$

则称因素 h 为 f 与 g 的合取因素, 记作 $h = f \wedge g$ 。

定义 2.8^[32] 对于因素 f, g 和 h , 如果 f 与 g 均是 h 的子因素, 且 h 是这样的最小因素, 即 $h \geq f, h \geq g$, 且对于任意因素 e , 必有

$$(e \geq f, e \geq g) \Rightarrow e \geq h$$

则称因素 h 为 f 与 g 的析取因素, 记作 $h = f \vee g$ 。

定义 2.9^[32] 如果因素 h 满足 $(f \wedge g) \vee h = f$ 和 $h \wedge g = \mathbf{0}$, 则称因素 h 为因素 f 和因素 g 的差, 记为 $h = f - g$ 。

定义 2.10^[32] 当论域和研究的问题确定时, 只考虑与该问题有关的因素, 称为因素集, 记作 F 。对 F 中的任一因素 f , 记 $f^c = F - f$, 称 f^c 为 f 在因素集 F 中的余因素。

定义 2.11^[32] 给定一个因素集 F , 称 (D, F) 为一个因素空间, 如果对任意 $f_i, f_j, \dots, f_n \in F$, 两两的析取为零因素 $f_i \vee f_j = \mathbf{0} (1 \leq i \neq j \leq n)$, 则有

$$I(f_1 \wedge f_2 \wedge \dots \wedge f_n) = I(f_1) \times I(f_2) \times \dots \times I(f_n)$$

称 (D, F) 是一个简单因素空间。如果因素集 $F = 2^{\{f_1, f_2, \dots, f_n\}}$, 亦即 F 是由 $f_1, f_2, \dots, f_n$ 这几个因素合成而得。 $f_1, f_2, \dots, f_n$ 叫做元因素。

记

$$I_{\max} = I(f_1) \times I(f_2) \times \dots \times I(f_n)$$

为最大的性状空间, 对于离散型的性状空间而言, 任意向量 $\mathbf{a} = (x_1, x_2, \dots, x_n) \in I$ 称为一个性状颗粒。

2.1.2 因素的关系和运算

定义 2.12^[33] (背景关系) 给定 D 上的定性因素空间 $(D, F = (f_1, f_2, \dots, f_n))$, 设 I 是定

性的性状空间, 对任意相 $\mathbf{a} = (a_1, a_2, \dots, a_n) \in I$, 记其在 D 上的原相为

$$[a] = F^{-1}(a) = \{d \in D \mid F(d) = a\}$$

$[a]$ 可能是空集, 若 $[a] \neq \emptyset$, 则称 $\mathbf{a}$ 是一个实性状颗粒, 否则称 $\mathbf{a}$ 是一个虚性状。

全体实性状的集合记为

$$R = F(D) = \{\mathbf{a} = (a_1, a_2, \dots, a_n) \in I \mid \exists d \in D; f_1(d) = a_1, f_2(d) = a_2, \dots, f_n(d) = a_n\}$$

称 R 为因素 $f_1, f_2, \dots, f_n$ 之间的背景关系, 也称为因素 F 的背景集。

若因素 $f_1, f_2, \dots, f_n$ 互不相关, 则 $R = I(f_1) \times I(f_2) \times \dots \times I(f_n)$ 。 $I = I(f_1) \times I(f_2) \times \dots \times I(f_n)$ 是 n 个因素的联合相域, 其所包含的相比单个因素的相多。例如, 如果每个因素有三个相, 10 个因素就有 3^{10} 个相, 其中有很多相是没有意义的。称在 D 中没有对象去取的相为实际不存在的虚性状, 背景关系 R 就是排除虚性状后实际出现的性状集, 是实际存在的笛卡尔乘积空间。

定义 2.13^[33] 如果背景关系

$$R = [f \vee g](D) = f(D) \times g(D)$$

则称因素 f 与 g 独立。

定义 2.14^[33] (背景分布) 在论域大小为 m 的样本中, 若相 $a_{(1)(2)\dots(n)}$ 出现了 k 次, 则称 $p_{(1)(2)\dots(n)}^* = k/m$ 为相 $a_{(1)(2)\dots(n)}$ 出现的频率, 称 $\{p_{(1)(2)\dots(n)}^*\}$ 为背景分布。

给定因素 $f: D \rightarrow I(f) = \{a_1, a_2, \dots, a_n\}$ 。 $[a_i] = \{d \in D \mid f(d) = a_i\} (i=1, 2, \dots, n)$ 为相 a_i 的反馈外延。由因素 f 确定一个划分关系 $\sim: d \sim d'$ 当且仅当 $f(d) = f(d')$ 。这是一个等价关系 (即满足反身性、对称性和传递性的二元关系), 等价关系决定了对定义域 D 的分类。

定义 2.15^[32] 记

$$H(D, f) = \{[a_i] \mid i=1, 2, \dots, n\}$$

称为因素 f 对论域 D 的划分。

把每个类 $c_i = [a_i]$ 看作是一个元素而形成集合 $D/f = \{c_i \mid i=1, 2, \dots, n\}$, 称为 D 关于 f 的商集。

如果 $H(D, f)$ 中的任意一个类都被 $H(D, g)$ 中的一个类所包含, 则称 f 的划分比 g 细, 或称 f 的划分能力比 g 强, 记作 $H(D, f) \prec H(D, g)$ 或 $f \geq g$ 。

命题 2.1^[32] 记 F_D 为在 D 上有定义的所有因素所构成的集合, 按强弱关系 $\geq$ 构成一个偏序集 $(F_D, \geq)$ 。

事物是量与质的统一, 属性是质的表, 因素是质的根。若把质根想象成一种有形的团粒, 零因素是空团粒, 质根越粗, 因素的分辨能力越强。多个因素的合取使质根的团粒变粗。要提高因素的划分能力, 单靠一个因素不够, 就需要把多个简单的质根并成一个复杂的质根。

定义 2.16^[36] (因素的质根运算) 如果因素 h 的质根是 f 和 g 的质根之并, 那么 h 称为

因素 f 与 g 的合成, 记作 $h = f \cup g$; 如果 h 的质根是 f 和 g 的质根之交, 那么 h 称为因素 f 与 g 的分解, 记作 $h = f \cap g$ 。

例 2.1 美食家评价菜肴, 论域 D =接受评判的所有菜肴所成之集。判别的元因素有: f_1 =色, $I(f_1)=\{\text{美, 中, 丑}\}$; f_2 =香, $I(f_2)=\{\text{香, 臭}\}$; f_3 =味, $I(f_3)=\{\text{鲜, 常, 差}\}$ 。由合成产生的复杂因素有: $f_4=f_2 \cup f_3$ =香味; $f_5=f_1 \cup f_3$ =色味; $f_6=f_1 \cup f_2$ =色香; $f_7=f_1 \cup f_2 \cup f_3$ =色香味。这些复杂因素又可分解成简单因素, 如 $f_4 \cap f_5$ =味, $f_4 \cap f_6$ =香, $f_5 \cap f_6$ =色; $f_1 \cap f_2 = f_2 \cap f_3 = f_1 \cap f_3 = \mathbf{0}$ (零因素)。

合成(分解)运算使注意的分辨率提高(降低), 对论域的划分能力加强(减弱)。

命题 2.2^[36] $f \cup g = \text{Sup}(f, g)$, $f \cap g = \text{Inf}(f, g)$, 这里 Sup 和 Inf 分别是因素按序关系 $\geq$ 定义的上、下确界。

定义 2.17^[36] (因素的逻辑运算) 给定因素 f, g 和 h 。如果因素 h 对论域的划分关系 $\sim_{\text{且}}$ 被定义为:

$$d \sim_{\text{且}} d' \text{ 当且仅当 } f(d) = f(d') \text{ 且 } g(d) = g(d')$$

那么称因素 h 是 f 和 g 的合取, 记作 $h = f \wedge g$; 如果因素 h 对论域的划分关系 $\sim_{\text{或}}$ 被定义为:

$$d \sim_{\text{或}} d' \text{ 当且仅当 } f(d) = f(d') \text{ 或 } g(d) = g(d')$$

那么称因素 h 是 f 和 g 的析取, 记作 $h = f \vee g$ 。

合取运算使注意的分辨率提高, 对论域的划分能力加强; 析取运算使注意的分辨率降低, 对论域的划分能力减弱。

命题 2.3^[36] (两种运算的逆向对合性):

$$f \wedge g = f \cup g, f \vee g = f \cap g$$

2.2 集成学习算法

传统的机器学习算法, 如决策树算法、支持向量机、朴素贝叶斯和神经网络等, 目的都是寻找一个最优的分类器, 对训练数据进行分类。集成学习则采用了一种区别于传统方法的策略, 通过构建多个基分类器, 将所有结果综合起来, 共同完成一个分类任务, 从而达到比任何一个单一分类器性能更优秀的目的。集成学习一般结构如图 2.1 所示。




图 2.1 集成学习一般结构

Figure 2.1 General structure of ensemble learning

在集成学习中，基分类器的选取策略主要有两种：一种是同质的，即所有的基分类器都属于同一类型，例如都是决策树或者都是神经网络；另一种是异质的，即所有的基分类器都属于不同的类型。例如，一个分类问题可能同时采用支持向量机、逻辑回归和朴素贝叶斯进行分类，将这些分类器的结果通过某种方法结合起来，以确定最终的分类结果。

2.2.1 Bagging 算法

Bagging 算法又称袋装算法，通过组合多个模型提高整体预测性能，特别适用于高方差的学习算法，如决策树。Bagging 可以降低模型的方差，减少预测结果的波动性，使得最终的模型更加稳定和可靠。其核心思想是利用自助抽样法 **Bootstrap**，从原始数据集中生成多个不同的训练子集，然后独立地在每个子集上训练一个基学习器。重抽样后的数据可以得到相较于原观测数据少的噪声点。每个基学习器都可能会有不同的表现和预测误差。最终，这些基学习器的预测结果通过投票（分类问题）或平均（回归问题）的方式合并，以产生最终的预测结果。




图 2.2 Bagging 算法学习过程

Figure 2.2 Learning process of bagging algorithm

Bagging 算法学习过程如图 2.2 所示。具体步骤如下：

- (1) 对原始训练数据集进行 k 次 Bootstrap 抽样，得到 k 个新的子训练集，这 k 个新的子训练集大小与原始数据集相同。
- (2) 在每个新的子训练集上都使用同一个基学习器进行训练。由于训练数据的不同，所以训练出的基学习器效果也不同。
- (3) 将所有基学习器的预测结果进行整合。对于分类问题采用多数投票法，对于回归问题采用平均法。

2.2.2 Boosting 算法

与 Bagging 不同, Boosting 的各个基学习器是依次训练的, 并且每一个后续的学习器都在尝试纠正前一个学习器的错误。Boosting 的关键在于每个新的学习器都会关注前一个学习器未能正确分类的样本, 通过不断调整训练样本的权重, 使得后续的学习器能够更专注于错分样本, 从而逐步提高整体模型的性能。

Boosting 算法学习过程如图 2.3 所示。具体步骤如下:

- (1) 初始化训练数据集的权值分布, 对训练集中的每一个样本分配相同的权重。
- (2) 训练第一个弱分类器 C_1 , 并计算错误率, 即错误分类的样本权值之和与所有的样本权值之和之比。
- (3) 根据错误率调整训练数据集中每个样本的权值。被错误分类的样本权值增加, 被正确分类的样本权值减少, 使得下一个分类器更关注之前分类错误的样本。使用调整后的权值分布训练下一个弱分类器 C_2 , 并计算错误率。
- (4) 重复第 3 步, 直到训练完所有的弱分类器或错误率足够小。
- (5) 计算学习器权重, 每个学习器的贡献是由其错误率决定的, 错误率低的学习器有更高的权重。
- (6) 将所有弱分类器按照其权重组合成一个强分类器。




图 2.3 Boosting 算法学习过程

Figure 2.3 Learning process of boosting algorithm

2.2.3 随机森林算法

随机森林算法是 Bagging 算法的一个扩展算法。随机森林使用 CART 决策树作为基学习器, CART 决策树使用基尼指数作为节点分裂准则, 每个节点处都是二分的 (即每个节点分为两个子节点)。同时, 在每次分裂时不考虑所有的特征, 而是随机选取一个包含 l

个特征的子集（ l 远小于特征总数 n ）。

随机森林算法学习过程如图 2.4 所示。具体步骤如下：

（1）对于 m 个样本的数据集，在构建每个树时都进行随机有放回的抽样，重复此过程 m 次，得到包含 m 个样本的新样本数据集。

（2）在每个节点分裂时，首先从这 n 个特征中随机选择 l 个特征（其中 l 远小于 n ），然后基于这 l 个特征，采用某种度量标准（如信息增益）选择最佳的分裂特征。

（3）根据上述随机选择的样本和特征，构建决策树。每个节点都按照第 2 步的方法进行分裂，直至无法再分裂。在构建过程中没有剪枝操作。

（4）重复上述过程，建立多个决策树，每个树都基于第 1 步的随机样本集和第 2 步的随机特征集独立构建。所有这些决策树的集合构成了随机森林。




图 2.4 随机森林算法学习过程

Figure 2.4 Learning process of random forest algorithm

2.3 评价指标

在二分类中，评价指标是衡量模型分类性能的标准，用于评估区分两个类别（正类和负类）的能力。准确率、精确率、召回率、F1 分数、ROC 曲线和 AUC 值等是常见的评价指标，不同的指标具有不同的评价结果。每个指标都有其特定的适用场景和局限性，选择哪个评价指标取决于具体的应用场景和对模型性能的要求。

混淆矩阵是评估二分类模型性能的一个重要工具，具体结构见表 2.1。通过混淆矩阵，可以计算出准确率、精确率、召回率和 F1 分数评价指标。在处理多分类问题时，对于每

一个类别，可以通过将该类别视为正类，而将所有其他类别合并视为负类。

表 2.1 二分类结果的混淆矩阵

Table 2.1 Confusion matrix for dichotomous results

真实情况	预测结果	
	正类	负类
正类	TP（真正类）	FN（假反类）
负类	FP（假正类）	TN（真反类）

真正类（True positives, TP）：模型正确地将正类样本预测为正类。

假负类（False negatives, FN）：模型错误地将正类样本预测为负类。

假正类（False positives, FP）：模型错误地将负类样本预测为正类。

真负类（True negatives, TN）：模型正确地将负类样本预测为负类。

（1）准确率

准确率是模型正确预测的样本（无论正例还是负例）与总样本数的比例，计算公式为：

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}}$$

（2）精确率和召回率

精确率又为查准率，衡量预测结果为正类的样本中实际为正类的比例，计算公式为：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

召回率又为查全率，衡量实际为正类的样本中被正确预测为正类的比例，计算公式为：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

精确率和召回率是一对相互矛盾的指标，精确率越高时，往往召回率越低，反之亦然。如果预测正类的准确性比避免将负类错分为正类更重要，应优先考虑精确率。如果捕捉尽可能多的正类样本比准确性更重要，则应优先考虑召回率。当需要在精确率和召回率之间找到一个平衡时，F1 分数是一个有用的指标。

（3）F1 分数

F1 分数是精确率和召回率的调和平均数，是同时考虑精确率和召回率的综合性能指标，计算公式为：

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

（4）ROC 曲线和 AUC 值

ROC（Receiver operating characteristic）曲线是用于可视化二分类模型在不同阈值下的真正类率（召回率）和假正类率之间的权衡关系的图形。相关指标计算公式如下：

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}, \quad \text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

其中 FPR (False positive rate, 假正类率) 衡量的是在所有真实为负类的样本中, 被错误预测为正类的样本的比例; TPR (True positive rate, 真正类率) 衡量的是在所有真实为正类的样本中, 被正确预测为正类的样本的比例。

在 ROC 曲线中, FPR 通常设定为横轴, TPR 设定为纵轴。ROC 曲线描绘了模型在识别正类时随着误判负类率增加的变化情况。理想情况下, ROC 曲线越接近左上角, 表明模型越能在保持低假正类率的同时实现高真正类率, 即模型性能越好。

AUC (Area under the curve) 值是 ROC 曲线下的面积, 用来量化 ROC 曲线所覆盖的区域大小。AUC 值的取值范围在 0~1 之间, 其中 0.5 表示模型的性能等同于随机预测, 而 1 表示模型完美地区分了正类和负类样本。一般来说, 值越接近 1 表示模型性能越好。

3 因果树算法研究

因素分析法是因素空间理论的核心算法之一，主要用于规则提取，能够体现人脑在认知过程中的归纳和推理，主要用于处理离散型数据的分类和归纳问题。本章基于决定度，利用因素分析法，对因果树算法进行研究。3.1节介绍了决定度的定义；3.2节介绍算法的原理和步骤，并给出一个算例说明因果树算法的构建过程；3.3节是选取UCI数据库中的数据集进行实验分析；3.4节是本章小结。

3.1 决定度

因素之间相互影响、相互制约、互为因果。在因素分析中，某个被关注的因素 g 称为结果因素，对结果因素有影响的那些因素 $\{f_1, f_2, \dots, f_n\}$ 称为条件因素。给定因素空间 $(D, f_1, f_2, \dots, f_n, g)$ ，称 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$ 为因果分析表，其样式见表 3.1。

表 3.1 因果分析表

Table 3.1 Causal analysis table					
D	$F \rightarrow g$				
	f_1	f_2	$\dots$	f_n	g
d_1					
d_2					
$\vdots$					
d_m					

在表 3.1 中，第 i 行第 j 列的元素表示的是第 i 个对象在第 j 个因素下的性状。有限个对象构成论域 $D = \{d_1, d_2, \dots, d_m\}$ ，条件因素为 $F = \{f_1, f_2, \dots, f_n\}$ ，条件因素性状空间为 $I(f_j) = \{a_{j1}, a_{j2}, \dots, a_{jk}\} (j=1, 2, \dots, n)$ ，结果因素用 g 表示，结果因素的性状空间为 $I(g) = \{g_1, g_2, \dots, g_s\}$ 。一个因果分析表是由有限个对象在因果空间中所形成的一个背景样本。

因素分析要以最少的因素来决定所有可能的结果，每次节点划分的标准根据决定度最大的条件因素依次进行划分。

定义 3.1^[32]（决定度）给定一个条件因素 f_j 和该因素所取的一个性状 a_{ji} ，记 $[a_{ji}] = \{d_i | f_j(d_i) = a_{ji}\}$ ，如果 $[a_{ji}]$ 中的所有对象所对应的结果因素取值都相同（即存在结果因素 g 的一个性状或等级 g_l ，使 $[g_l] = \{d_i | g(d_i) = g_l\} \supseteq [a_{ji}]$ ，则称 $[a_{ji}]$ 是因素 f_j 的一个决定类。因素 f_j 的所有决定类的并集称为该因素对结果因素 g 的决定域。因素 f_j 的决定域所占行数 c 与表的行数（即全体对象个数） m 之比称为该因素对结果因素 g 的决定度，记作 $d(f_j) = c / m$ 。

假设有 m 个对象，划分条件为因素 f_j 的不同值 $a_{j1}, a_{j2}, \dots, a_{jk}$ ，在每个值对应的类 $[a_{ji}]$ 中，如果 f_j 是一个好的分裂因素，那么其决定度 $d(f_j)$ 应该较高。这意味着 f_j 对结果因素 g 有较

强的区分能力。

定理 3.1 在相同的条件下, 条件因素 f_j 的决定度 $d(f_j)$ 越高, 则对结果因素 g 的区分能力越强。

证明 条件因素 f_j 的决定类 $[a_{jt}]$ 中的所有对象在结果因素 g 上取值相同, 说明这个条件因素在这个分裂中可以完全区分这些对象的结果。决定域 c 越大, 表示区分的对象越多。因此, 决定度中的决定域 c 越大, 表示因素 f_j 具有更强的区分能力。

因素分析的最终目的就是要从一个因果分析表中提取出有效的推理规则。推理的逻辑本质在于集合的包含: 若 A 则 B , 当且仅当 $A \subseteq B$ 。一个因素的决定类被一个结果类所包含, 从决定类到结果类形成一个推理规则。

定义 3.2^[32] 若条件因素 f_j 的某个类 $[a_{jt}]$ 是一个决定类, 类中所有对象都有唯一确定的结果 g_l , 则称“若 f_j 处于 a_{jt} , 则结果 g 是 g_l ”这句话是由该因素所确定的一个推理规则, 记作 $f_j = a_{jt} \rightarrow g = g_l$ 。

3.2 因果树算法

因果树算法是基于树的结构进行规则提取, 这也是人类在分析问题的一种很自然的处理机制。在构建过程中, 每一步因素的选择都基于前一个因素选择的结果, 形成一种递进的分析方式。某商品购买问题分析过程的因果树见图 3.1。




图 3.1 某商品购买问题的因果树

Figure 3.1 A causal tree of product purchase problem

在图 3.1, 首先选择一个重要因素进行分析, 如“还贷=?”, 这个问题的答案有“好”、“中”、“可”或“差”, 不同的选择会对应不同的分支进行下一步分析。例如, “还贷=可”后, 下一步就要对“职业=?”进行分析, 此时的分析会特别关注已经被判定为还贷为可的群体, 对该群体进行细分。如果“职业=商”, 下一步的分析就是对还贷可和职业商的群体进行细分。随着不断的分析, 每一层的选择都是在上一层分析结果的限定范围之内。这种逐步分析的方法可以将一个复杂的决策问题分解成一系列更简单、更具体的子问

题。通过这种方式，决策者可以更系统地处理信息，减少误判的可能性，提高决策的可靠性和准确性。每一步的判断不仅是对单一因素的分析，而是一个综合考虑前面所有因素的复合判断过程，最终形成一个全面的决策结果。

（1）算法原理

因果树算法的原理是通过分析条件因素对结果因素的决定度建立模型。该算法的核心思想是在一个因果分析表中，每个条件因素对结果因素的决定程度（即决定度）是不同的，通过量化这种决定程度，算法能够识别出最具决定性的因素，并选择具有最大决定度的条件因素作为节点对论域进行划分。在划分过程中，每当有决定类出现，就会产生推理规则。

因果树算法通过计算决定度，选择具有最大决定度的条件因素作为当前节点的划分标准。然后，根据这一标准将数据集划分为几个不同的子集，每个子集包含的样本数据在该条件因素上的性状取值都是相同的。在每个子集中，继续对剩余的条件因素计算决定度，不断地选择因素进行划分，直到所有节点的样本数据都属于同一类或条件因素集为空。从上到下形成了一个因果树，从而得到推理规则。

（2）算法步骤

因果树算法具体步骤如下：

输入 因果分析表 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$ ，条件因素集 $F = \{f_1, f_2, \dots, f_n\}$ ，结果因素 g 。

输出 以 `node` 为根节点的一个因果树 Tr 。

步骤 1 创建一个新的节点 `node`；

步骤 2 检查因果分析表中的样本所对应的结果因素类别 g_i 是否都相同。如果都相同，则将节点 `node` 标记为 g_i 类别的叶节点；

步骤 3 检查条件因素集中的取值情况。如果条件因素集为空或因果分析表中的对象在因素集 F 上的取值相同，则将节点 `node` 标记为叶节点，并将其类别标记为因果分析表中对象数最多的类别；

步骤 4 计算条件因素集 F 每个因素的决定度，选择具有最大决定度的条件因素；

步骤 5 遍历所选条件因素的每个取值作为节点 `node` 生成的一个分支，每个分支所包含的样本为在该条件因素下取值为 a_i 的样本；

步骤 6 检查每个分支的结果因素情况，如果结果因素性状唯一，则将分支节点标记为叶节点，并将其类别标记为该分支中对象的类别；如果结果因素性状不唯一，进入步骤 7；

步骤 7 该分支中去掉该条件因素后的样本作为输入，重复步骤 2-6。

因果树算法过程见图 3.2。




图 3.2 因果树算法流程图

Figure 3.2 Causal tree algorithm flowchart

例 3.1 某商品的销量情况见表 3.2，利用因果树算法得到该商品销量情况的推理规则。

计算各条件因素的决策度。以因素“价格”为例，将论域 D 分为 3 类：低 {2,3,4,5,6,8}，中 {1,9}，高 {7,10,11}。其中，“低”类所对应的结果因素销量有高 {2,3,4,5} 有低 {6,8}，不是决定类。“中”类所对应的结果因素销量有高 {9} 有低 {1}，不是决定类。“高”类所对应的结果因素销量都是低，是一个决定类。因此，因素“价格”的决策度是 3/11。以此类

推，因素“知名度”的决定度是 3/11，因素“口味”的决定度是 1/11，因素“促销方式”的决定度是 1/11。“价格”和“知名度”的决定度最高，随机选取一个因素作为树的根节点，这里选择“知名度”，得到三个分支，见图 3.3。

表 3.2 某商品销量分析表
Table3.2 Sales analysis table for a certain product

D	$F \rightarrow g$				
	价格	知名度	口味	促销方式	销量
1	中	中	燕麦	无	低
2	低	中	水果	普通	高
3	低	中	原味	普通	高
4	低	中	水果	让利	高
5	低	中	原味	让利	高
6	低	低	原味	普通	低
7	高	低	原味	普通	低
8	低	低	水果	普通	低
9	中	高	水果	让利	高
10	高	高	原味	让利	低
11	高	高	水果	让利	低
d	3/11	3/11	1/11	1/11	




图 3.3 选择“知名度”作为根节点

Figure 3.3 Selection of “fame” as root node

进一步对三个分支进行分析。对于“知名度=低”的分支，对应的结果因素“销量”都为低，因此将该分支的类别标记为“低”。对于“知名度=中”的分支，对应的结果因素“销量”性状取值不唯一，计算分支中各条件因素的决定度，为(1, 1, 1)。各条件因素的决定度都相等，选取因素“价格”进行下一步的分析。对于“知名度=高”的分支，对应的结果因素“销量”性状取值不唯一，计算分支中各条件因素的决定度，为(1/3, 1/3, 0)。各条件因素的决定度都相等，选取因素“价格”进行下一步的分析。见图 3.4。

在图 3.4 中，“知名度=中且价格=中”、“知名度=中且价格=低”、“知名度=高且

价格=高”和“知名度=高且价格=中”这四个分支中的对象所对应的结果因素“销量”的性状取值都相同，将分支类别标记为其所对应的结果因素类别，分析完毕。




图 3.4 图 3.3 的进一步分析

Figure 3.4 Further analysis of figure 3.3

最后得到的因果树见图 3.5 且得到如下推理规则：

知名度_低→销量_低；

知名度_中且价格_中→销量_低；

知名度_中且价格_低→销量_高；

知名度_高且价格_中→销量_高；

知名度_高且价格_高→销量_低。




图 3.5 表 3.2 的因果树

Figure 3.5 Causal tree of table 3.2

(3) 复杂度分析

假设数据集的大小为 m ，条件因素个数为 n ，条件因素性状个数平均为 p ，使用决定度时要对每个因素的每个性状值所对应的结果进行检查，算法时间复杂度大约为 $O(mnp)$ 。

经典决策树算法如 ID3 或 C4.5，对于每个因素都要计算信息增益或信息增益率，时间复杂度为 $O(m^2n)$ 。因此因果树算法的复杂度要相对较低。

3.3 实验分析

选取 UCI 数据库中的 Lymphography 数据集对因果树算法的性能进行分析。该数据集是用来诊断淋巴结病变状况，其中，条件因素有 18 个且均为离散型因素；结果因素有 1 个，有正常发现、转移、恶性淋巴和纤维化四种性状。该数据集中一共有 148 个对象，具体情况见表 3.3。

表 3.3 Lymphography 数据集情况
Table 3.3 Lymphography dataset situation

D	f_1	f_2	$\cdots$	f_6	$\cdots$	f_{17}	f_{18}	g
1	4	2	$\cdots$	1	$\cdots$	2	2	3
2	3	2	$\cdots$	2	$\cdots$	2	2	2
3	3	2	$\cdots$	2	$\cdots$	2	7	3
4	3	1	$\cdots$	2	$\cdots$	2	6	3
5	3	1	$\cdots$	1	$\cdots$	2	1	2
6	2	1	$\cdots$	1	$\cdots$	2	4	2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
148	2	2	$\cdots$	2	$\cdots$	2	6	2

在该数据集上对因果树算法采用十折交叉验证，将数据集分成十个部分，轮流使用其中九个部分训练模型，并用剩下的一部分验证模型。交叉验证结果见图 3.6。




图 3.6 每折测试集准确率

Figure 3.6 Accuracy of each fold test set

由图 3.6 可知,测试集准确率范围从 46.67%到 86.67%,这表明算法在不同折上的性能波动较大;通过计算,平均测试集准确率为 67.66%,训练集准确率均为 100%,测试集准确率的平均值较低,表明存在性能下降,出现过拟合的迹象。过拟合意味着模型在训练集上学到了过多的细节和噪声,导致无法有效地泛化到未见过的数据。

选择测试集准确率为 86.67%的训练集进行具体分析,在训练集上得到 78 条推理规则,推理规则部分如下:

$$\begin{aligned}
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=1 \text{ 且 } f_1=1 \rightarrow g=1, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=1 \text{ 且 } f_1=2 \rightarrow g=2, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=2 \text{ 且 } f_{15}=1 \text{ 且 } f_1=2 \rightarrow g=2, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=2 \text{ 且 } f_{15}=1 \text{ 且 } f_1=3 \rightarrow g=2, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=2 \text{ 且 } f_{15}=1 \text{ 且 } f_1=4 \rightarrow g=2, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=2 \text{ 且 } f_{15}=2 \text{ 且 } f_1=2 \rightarrow g=3, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=2 \text{ 且 } f_{15}=2 \text{ 且 } f_1=3 \rightarrow g=3, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=3 \text{ 且 } f_{14}=3 \text{ 且 } f_{10}=1 \rightarrow g=2, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=3 \text{ 且 } f_{14}=3 \text{ 且 } f_{10}=2 \text{ 且 } f_1=2 \rightarrow g=3, \\
 &f_{18}=1 \text{ 且 } f_2=1 \text{ 且 } f_6=1 \text{ 且 } f_{13}=3 \text{ 且 } f_{14}=3 \text{ 且 } f_{10}=2 \text{ 且 } f_1=4 \rightarrow g=3。
 \end{aligned}$$

选择测试集准确率为 46.67%的训练集进行具体分析,在训练集上得到 88 条推理规则,推理规则部分如下:

$$\begin{aligned}
 &f_{14}=2 \text{ 且 } f_{13}=1 \rightarrow g=1, \\
 &f_{14}=2 \text{ 且 } f_{13}=2 \rightarrow g=2, \\
 &f_{14}=2 \text{ 且 } f_{13}=3 \text{ 且 } f_1=2 \rightarrow g=2, \\
 &f_{14}=2 \text{ 且 } f_{13}=3 \text{ 且 } f_1=3 \text{ 且 } f_2=1 \rightarrow g=2, \\
 &f_{14}=2 \text{ 且 } f_{13}=3 \text{ 且 } f_1=3 \text{ 且 } f_2=2 \rightarrow g=2, \\
 &f_{14}=3 \text{ 且 } f_8=1 \text{ 且 } f_1=2 \text{ 且 } f_2=2 \text{ 且 } f_3=1 \rightarrow g=2, \\
 &f_{14}=3 \text{ 且 } f_8=1 \text{ 且 } f_1=2 \text{ 且 } f_2=2 \text{ 且 } f_3=2 \rightarrow g=2, \\
 &f_{14}=4 \text{ 且 } f_{15}=3 \text{ 且 } f_{12}=4 \text{ 且 } f_{18}=6 \text{ 且 } f_1=2 \rightarrow g=2, \\
 &f_{14}=4 \text{ 且 } f_{15}=3 \text{ 且 } f_{12}=4 \text{ 且 } f_{18}=6 \text{ 且 } f_1=3 \rightarrow g=3, \\
 &f_{14}=8 \text{ 且 } f_{13}=2 \text{ 且 } f_{18}=1 \text{ 且 } f_{15}=1 \text{ 且 } f_1=2 \rightarrow g=2, \\
 &f_{14}=8 \text{ 且 } f_{13}=2 \text{ 且 } f_{18}=1 \text{ 且 } f_{15}=1 \text{ 且 } f_1=3 \rightarrow g=2, \\
 &f_{14}=8 \text{ 且 } f_{13}=2 \text{ 且 } f_{18}=1 \text{ 且 } f_{15}=1 \text{ 且 } f_1=4 \rightarrow g=2, \\
 &f_{14}=8 \text{ 且 } f_{13}=2 \text{ 且 } f_{18}=1 \text{ 且 } f_{15}=2 \text{ 且 } f_1=2 \rightarrow g=3, \\
 &f_{14}=8 \text{ 且 } f_{13}=2 \text{ 且 } f_{18}=1 \text{ 且 } f_{15}=2 \text{ 且 } f_1=3 \rightarrow g=3。
 \end{aligned}$$

比较 2 组推理规则集得到:前者测试集准确率为 86.67%,后者测试集准确率仅为

46.67%，这表明因果树算法在不同测试集上的泛化能力差异很大。后者在测试集上表现不佳是因为所生成的规则尝试拟合训练集中的每一个细节，包括噪声，这意味着这些规则对于新的数据样本不具有普遍适用性。

基于上述分析可以得出结论，因果树算法在该数据集上表现出过拟合的迹象，特别是训练集准确率持续为 100%。如果训练集包含噪声或异常值，算法会学习到这些不代表整体数据分布的特性，特别是在规则过于具体时，过拟合的风险增加。

3.4 小结

本章首先基于因素空间的决定度，给出了因果树算法的原理和步骤，并通过一个算例具体展示了因果树的构建过程；其次，通过对 UCI 数据库中的 Lymphography 数据集的分析，讨论因果树算法在实际应用中的表现和存在的问题。分析结果表明：在某些情况下因果树算法面临着过拟合和准确率不高的问题。过拟合问题导致算法对训练集过度敏感，难以泛化到新的数据集上，而准确率不高则限制了其在实际应用中的性能。

4 因果树聚合算法研究

在处理决策问题时，因果树算法从数据表中快捷简明地生成因果树，得到推理规则，极大地缩减了决策复杂性，但是该算法容易发生过拟合，使得算法过度适应训练数据中的噪声或异常，导致因果树算法的泛化能力不足，进而影响预测效果。因此，本章提出因果树聚合算法，通过综合多个因果树模型的预测结果，提高整体分类性能。4.1 节主要介绍了算法的原理和步骤；4.2 节对 UCI 数据库中的 8 个分类数据集进行实验分析；4.3 节是本章小结。

4.1 因果树聚合算法

(1) 基本概念

给定训练样本构成的因果分析表 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$ ，论域 $D = \{d_1, d_2, \dots, d_n\}$ ，条件因素为 $F = \{f_1, f_2, \dots, f_n\}$ ，条件因素的性状空间为 $I(f_j) = \{a_{j1}, a_{j2}, \dots, a_{jk}\} (j=1, 2, \dots, n)$ ，结果因素 g 的性状空间为 $I(g) = \{g_1, g_2, \dots, g_l\}$ 。从一个因果分析表中可以提取出如下形式的规则：

$$(f_1 = a_{1t}) \wedge (f_2 = a_{2t}) \wedge \dots \wedge (f_n = a_{nt}) \rightarrow g = g_l$$

简记为 $R_{bi} : (a_{1t} \wedge a_{2t} \wedge \dots \wedge a_{nt}) \rightarrow g_l$ 。其中 a_{jt} 是条件因素 f_j 的一个性状取值， g_l 是结果因素的一个性状取值。

定义 4.1 给定一个因果分析表 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$ ，通过自助采样获得 K 个子因果分析表，记作 $(D_K, F = \{f_1, f_2, \dots, f_n\}; g)$ ，称

$$\begin{cases} R_{b1} : (a_{1t} \wedge a_{2t} \wedge \dots \wedge a_{nt}) \rightarrow g_l \\ R_{b2} : (a'_{1t} \wedge a'_{2t} \wedge \dots \wedge a'_{nt}) \rightarrow g'_l \\ \dots \\ R_{bK} : (a''_{1t} \wedge a''_{2t} \wedge \dots \wedge a''_{nt}) \rightarrow g''_l \end{cases}$$

为每个表获得的推理规则。

因果树聚合指的是在一个因果分析表中通过自助采样的方法获得 K 个子因果分析表， K 个表提取出 K 组推理规则，对于待测样本 d ，每组规则都可以得到一个结果，将这些结果综合在一起形成一个统一的决策模型。

定义 4.2 设 K 为因果分析表的个数，记第 k 个因果分析表提取的推理规则对预测对象 d 的预测结果为 $T_k(d)$ ，由 K 个因果分析表产生的 K 个预测结果为 $\{T_1(d), T_2(d), \dots, T_K(d)\}$ ，则因果树聚合后的预测结果为 $T(d) = \text{mode}\{T_1(d), T_2(d), \dots, T_K(d)\}$ ，mode 表示一组数据中出现次数最高的类别。

(2) 算法原理

首先，从原始因果分析表中随机有放回地抽取 m 次，得到原始因果分析表的一个子表，

重复 K 次形成 K 个子因果分析表。每个子表都是原始数据的随机抽样,使得每个因果树模型在略有不同的数据集上进行训练。其次,对于每一个因果分析表,都训练一个独立的因果树模型,从而生成决策规则。最后,在对新数据进行预测时,将所有因果树模型的预测结果进行结合。对于分类问题,采用采用投票的方法得到最终的预测结果,即对于每个样本,统计每个类别在所有因果树模型中的出现频率,选择出现频率最高的类别作为最终的预测结果。

由于每个因果树都是在略有不同的训练数据集上训练的,且是独立的,彼此之间存在差异,这种差异有助于减少单个因果树的过拟合现象,提高整体模型的泛化能力。同时,通过随机抽样,可以减少训练数据中的噪声对模型的影响,从而提高了模型的稳健性和可靠性。

假设有一个预测目标 Y 和待测样本 d , $T_k(d)$ 的预测准确率为 p , 即

$$P(T_k(d)=Y)=p$$

对于因果树聚合算法来说,假设每个模型的预测是独立的,那么聚合模型预测准确的概率可以通过多数投票法计算。如果有 K 个因果树模型,其中超过一半(即 $[K/2]$ 个)模型正确预测结果,则聚合模型的预测结果是正确的。聚合模型预测正确的概率 $P(T(d)=Y)$ 可以表示为

$$P(T(d)=Y)=\sum_{k=[K/2]}^K \binom{K}{k} p^k (1-p)^{K-k}$$

这个概率随着 K 的增加而提高,尤其当 $p>0.5$ 时,聚合模型的预测准确率显著提高。

如果有 3 个因果树模型(即 $K=3$),每个模型的预测准确率为 0.6,则聚合模型预测正确的概率为

$$P(T(d)=Y)=\binom{3}{2} p^2 (1-p)^1 + \binom{3}{3} p^3 (1-p)^0 = 3 \times 0.6^2 \times 0.4 + 1 \times 0.6^3 = 0.648$$

这表明,通过聚合方法,聚合模型的准确率为 0.648,显著高于单个模型的准确率 0.6。

(3) 算法步骤

因果树聚合算法具体步骤如下:

输入 因果分析表 (D, F, g) , 基分类器个数 K , 待预测样本 d 。

输出 待预测样本 d 的分类结果。

步骤 1 从原始因果分析表中通过自助采样的方法(允许重复)从论域 D 中抽取与原论域大小相同的元素构成新论域 D' ;

步骤 2 根据新的因果分析表 (D', F, g) 利用因果树算法进行训练;

步骤 3 重复步骤 1 和步骤 2 K 次,得到 K 个因果树,把所有生成的因果树组合成一个模型 $\{t_i, i=1, 2, \dots, K\}$;

步骤 4 将待预测样本 d 输入模型，得到对应的分类结果 $\{T_1(d), T_2(d), \dots, T_K(d)\}$ ；

步骤 5 使用简单多数投票方式取预测分类结果的众数作为最终的分类结果。

其中，步骤 1-3 为算法的训练过程，步骤 4-5 为算法的预测过程。

因果树聚合算法的学习过程见图 4.1。




图 4.1 因果树聚合算法流程图

Figure 4.1 Causal tree ensemble algorithm flowchart

例 4.1 表 4.1 是一个关于评价的因果分析表，使用因果树算法进行训练，得到一个因果树，见图 4.2。

表 4.1 评价因果分析表
Table 4.1 Evaluation causal analysis table

D	$F \rightarrow g$				
	年龄	职业	还贷	收入	评价
1	老	教师	可	中	差
2	中	教师	好	中	好
3	青	学生	中	低	好
4	中	雇主	可	中	好
5	老	雇主	中	低	差
6	老	雇主	中	高	好
7	青	学生	差	低	差
8	中	教师	好	高	好

由图 4.2 的因果树得到的 7 条推理规则如下：

还贷_好 $\rightarrow$ 评价_好；

还贷_差 $\rightarrow$ 评价_差；

还贷_中 且 年龄_青 $\rightarrow$ 评价_好；

还贷_可 且 年龄_中 $\rightarrow$ 评价_好；

还贷_可 且 年龄_老 $\rightarrow$ 评价_差；

还贷_中 且 年龄_老 且 收入高 $\rightarrow$ 评价_好；

还贷_中 且 年龄_老 且 收入中 $\rightarrow$ 评价_差。




图 4.2 表 4.1 的因果树

Figure 4.2 Causal tree of table 4.1

对表 4.1 使用自助采样法得到一个新的因果分析表，见表 4.2。

表 4.2 新的评价因果分析表
Table 4.2 New evaluation causal analysis table

D	$F \rightarrow g$				
	年龄	职业	还贷	收入	评价
1	中	教师	好	中	好
2	老	雇主	中	高	好
3	中	雇主	可	中	好
4	青	学生	中	低	好
5	老	教师	可	中	差
6	青	学生	中	低	好
7	青	学生	差	低	差
8	中	教师	好	中	好

表 4.2 的因果树见图 4.3。




图 4.3 表 4.2 的因果树
Figure 4.3 Causal tree of table 4.2

使用这两个因果树分别对表 4.3 中的数据进行预测。表 4.1 的因果树对对象 11 预测错误，表 4.2 的因果树对全部对象预测正确。

表 4.3 评价因果分析表测试集
Table 4.3 Evaluation causal analysis table test set

D	$F \rightarrow g$				
	年龄	职业	还贷	收入	评价
9	中	学生	可	中	好
10	青	学生	中	低	好
11	老	雇主	中	低	好
12	老	教师	中	高	好
13	老	雇主	好	中	好
14	老	雇主	可	低	差

4.2 实验分析

为验证因果树聚合算法对提升因果树算法分类准确性的有效性,使用 UCI 数据库中的 8 个不同的分类数据集进行了实验分析,并将因果树算法、ID3 算法和 Bagging 算法作为对比算法。

(1) 数据说明

算法实证分析中所用的数据集来源于 UCI 共享数据库,共选择了 8 个分类数据集,各数据集的具体结构见表 4.4。

表 4.4 实验数据说明
Table 4.4 Explanation of experimental data

序号	名称	对象个数	条件因素个数	结果类别
1	Lymphography	148	18	4
2	Heart	267	13	2
3	Breast cancer	286	9	2
4	Dermatology	366	34	6
5	Vote	435	16	2
6	Cancer	683	9	2
7	Credit	1000	24	2
8	KpkrA7	3196	34	2

各数据集的具体信息如下:

Lymphography 数据集是用来诊断淋巴结病变的状况,结果因素有 4 种:正常发现、转移、恶性淋巴和纤维化;

Heart 数据集是根据心脏单质子发射计算机断层扫描图像判断患者情况,结果因素分为正常和异常两类;

Breast cancer 是根据病人肿瘤大小、受侵淋巴结数、恶性肿瘤程度等因素判断乳腺癌是否复发,结果因素有 2 种:复发和不复发;

Dermatology 数据集是根据临床特征和组织病理学等特征确定红血球鳞状疾病的类型,结果因素有 6 种:牛皮癣、脂性皮炎、扁平苔藓、玫瑰糠疹、克隆性皮炎和毛发红糠疹;

Vote 数据集是美国众议院议员对 CQA 确定的 16 张关键选票的投票,根据选票预测党派为民主党或共和党;

Cancer 数据集是根据癌细胞核半径、纹理度、周长形状等细胞核形态对乳腺癌患者进行诊断,结果因素有 2 种:良性和恶性;

Credit 数据集是根据一组属性描述对人进行分类,结果因素有 2 种:良好或不良信用风险;

KpkrA7 数据集由格拉斯哥的图灵学院提供，每个实例都是国际象棋残局的棋盘再现，结果因素描述了白棋方是否能够获胜。

(2) 实验结果与分析

在 8 个数据集上分别对 4 个算法采用十折交叉验证的方式，其中，因果树聚合算法和 Bagging 算法的基分类器个数取 10，分类性能取 10 次实验结果的平均值。为评价不同分类结果的好坏，采用准确率(Accuracy)、精确率(Precision)、召回率(Recall)、F1 值和运行时间(Time)这五个性能指标评估算法。各算法实验结果对比见表 4.5。

表 4.5 实验结果对比

Table 4.5 Comparison of experimental results

数据集	指标	因果树 算法	因果树聚合 算法	ID3 算法	Bagging 算法
Lymphography	准确率	0.7786	0.8036	0.7272	0.7416
	精确率	0.7759	0.8129	0.5715	0.5794
	召回率	0.7549	0.7592	0.7031	0.7129
	F1	0.7726	0.7810	0.7275	0.7374
	T/s	0.3646	2.8036	0.1592	1.1360
Heart	准确率	0.7745	0.8246	0.7924	0.8092
	精确率	0.8165	0.8462	0.8036	0.8445
	召回率	0.8535	0.8679	0.8276	0.8294
	F1	0.8346	0.8569	0.8154	0.8369
	T/s	0.3143	2.2874	0.1267	1.1065
Breast cancer	准确率	0.6329	0.6678	0.6469	0.6608
	精确率	0.8060	0.8507	0.7662	0.8458
	召回率	0.7105	0.7246	0.7404	0.7203
	F1	0.7552	0.7826	0.7531	0.7780
	T/s	0.3036	2.1595	0.1276	0.8489
Dermatology	准确率	0.8275	0.8332	0.8249	0.8714
	精确率	0.8730	0.8950	0.8179	0.8697
	召回率	0.8076	0.7907	0.7973	0.8465
	F1	0.8303	0.8293	0.8045	0.8561
	T/s	1.7131	12.3937	0.3311	2.5336
Vote	准确率	0.8308	0.9462	0.9231	0.9308
	精确率	0.9718	0.9877	0.9750	0.9873
	召回率	0.8625	0.9302	0.9070	0.9070
	F1	0.9139	0.9581	0.9398	0.9454
	T/s	0.4597	3.6975	0.1443	1.2768
Cancer	准确率	0.8609	0.8653	0.9531	0.9678
	精确率	0.9907	0.9907	0.9722	0.9791
	召回率	0.8243	0.8291	0.9544	0.9701
	F1	0.8999	0.9027	0.9632	0.9746
	T/s	0.4179	3.1458	0.0616	0.4382
Credit	准确率	0.6550	0.6630	0.6400	0.6610
	精确率	0.8686	0.8871	0.8400	0.8857
	召回率	0.7062	0.7065	0.7033	0.7053
	F1	0.7790	0.7866	0.7656	0.7853
	T/s	3.9693	28.7169	0.2600	1.6709

续表 4.5 实验结果对比

Continue table 4.5 Comparison of experimental results

数据集	指标	因果树 算法	因果树聚合 算法	ID3 算法	Bagging 算法
KpkrA7	准确率	0.9609	0.9775	0.9671	0.9778
	精确率	0.9996	0.9996	0.9848	0.9933
	召回率	0.9561	0.9744	0.9765	0.9806
	F1	0.9774	0.9868	0.9806	0.9869
	T/s	0.6361	7.4219	1.3161	10.7494

为便于直观地比较各算法的分类性能，将准确率、精确率、召回率和 F1 值分别绘制各算法在各数据集下的柱状图，如图 4.4-图 4.7 所示。




图 4.4 算法的准确率

Figure 4.4 Accuracy of algorithms

由图 4.4 可知，因果树算法和 ID3 算法的准确率在各数据集上的表现一般；因果树聚合算法的准确率普遍较高，在大多数数据集上表现都非常好，特别是在 Lymphography、Heart 和 Vote 数据集上表现出色。在 Dermatology 和 Cancer 数据集中，Bagging 算法具有较好的性能。在 Credit 和 KpkrA7 数据集中，因果树聚合算法和 Bagging 算法的准确率相差不多。

从图 4.4-图 4.7 中可以看出，在这 8 个数据集上，因果树聚合算法在各数据集上的学习性能相较于因果树算法都有一定的提升，这表明对因果树算法的改进增强了其处理噪声数据的能力。在大多数数据集上，因果树聚合算法的准确率、精确率、召回率、F1 值均明显显著优于其他分类算法。然而，在某些数据集上，各分类算法之间的性能差异并不显著，例如 KpkrA7 数据集。在 Dermatology 和 Cancer 数据集上，尽管因果树聚合算法表现出了

较高的精确率，但其综合表现略逊于 Bagging 算法。




图 4.5 算法的精确率

Figure 4.5 Precision of algorithms




图 4.6 算法的召回率

Figure 4.6 Recall of algorithms




图 4.7 算法的 F1 值

Figure 4.7 F1 value of algorithms

4.3 小结

本章进一步对因果树算法进行分析，并针对其可能出现的过拟合问题以及提高准确率提出了因果树聚合算法，从而克服单一因果树可能面临的数据特异性和过拟合倾向。通过 UCI 数据库中 8 个分类数据集的数据实验结果表明，因果树聚合算法在大多数数据集上的学习性能都较因果树算法有一定的提升，这说明对因果树算法的改进提高了算法应对噪声数据的能力。

5 因果森林算法研究

因果树聚合算法在一定程度上可以提高因果树算法的分类准确性，但当条件因素性状取值个数过多或数据较为复杂时，算法的预测效果不佳。因此，本章提出因果森林算法，通过定义因素重要度，设置重要度阈值 α 对条件因素集中分类性能较差的因素删除。同时，在因果树构建时增加因素的随机选择过程。5.1 节介绍了算法的一些基本概念；5.2 节是算法的原理和步骤；5.3 节是实验分析；5.4 节是本章小结。

5.1 因素重要度

因果分析表的每一行均是一个对象在因素空间中的坐标。有限个对象构成论域 $D = \{d_1, d_2, \dots, d_m\}$ ，条件因素为 $F = \{f_1, f_2, \dots, f_n\}$ ，条件因素性状空间为

$$I(f_j) = \{a_{j1}, a_{j2}, \dots, a_{jk}\} (j=1, 2, \dots, n)$$

结果因素 g 的性状空间为

$$I(g) = \{g_1, g_2, \dots, g_s\}$$

为了衡量条件因素对因果分析表的分类效果所产生的影响，下面给出因素重要度的定义。

定义 5.1 （因素重要度）给定一个因果分析表 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$ ，对 $\forall f_j \in F$ 和其余因素 $f_j^c = F - \{f_j\}$ ，称条件因素集 F 合成划分的决定度与余因素 f_j^c 合成划分的决定度之差为论域 D 上因素 f_j 的重要度，记作

$$M(f_j) = d(F) - d(f_j^c) \quad (5.1)$$

式 (5.1) 中， $d(F)$ 表示条件因素集 $F = \{f_1, f_2, \dots, f_n\}$ 合成划分的决定度， f_j^c 表示在条件因素集 F 中去掉因素 f_j 后的余因素， $d(f_j^c)$ 表示条件因素集 F 去掉因素 f_j 后的余因素的合成划分的决定度， $M(f_j)$ 表示因素 f_j 的重要度。

一般情况下，若论域 D 中的每个对象在各个条件因素下的性状都不相同，即因果分析表考虑的是样本的背景分布，条件因素集 F 能够完全区分论域中的对象，则 $d(F)$ 取值为 1。

显然，因素重要度可以用来度量该因素对因果分析表的分类能力所产生的影响。

命题 5.1 条件因素 f_j 的重要度越大，该因素在分类中的影响力越大。

证明 由决定度的定义可知

$$d(F) = \frac{\text{条件因素集 } F \text{ 的决定类的对象个数}}{m}$$

$$d(f_j^c) = \frac{f_j^c \text{ 的决定类的对象个数}}{m}$$

则条件因素 f_j 的重要度为

$$M(f_j) = d(F) - d(f_j^\circ) = \frac{\text{条件因素集 } F \text{ 的决定类的对象个数} - f_j^\circ \text{ 的决定类的对象个数}}{m}$$

如果条件因素 f_j 对结果因素 g 的影响显著, 则去掉 f_j 后的余因素集合 $f_j^\circ = F - \{f_j\}$ 的决定类的对象个数会显著减少, 导致其决定度减小, 从而 $M(f_j)$ 较大。如果条件因素 f_j 对结果因素 g 的影响不显著, 则去掉 f_j 后的余因素集合 $f_j^\circ = F - \{f_j\}$ 的决定类的对象个数变化不大, 导致其决定度变化不大, 从而 $M(f_j)$ 较小。

定义 5.2 给定一个因果分析表 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$, 对 $\forall f_i \in F$, 如果

$$d(F) \neq d(f_i^\circ)$$

则称 f_i 是论域 D 上的优势因素, 否则, 称 f_i 是论域 D 上的劣势因素。

例 5.1 给定一个评价分析表见表 5.1, 其中包含了 10 个对象, 4 个条件因素和 1 个两类的结果因素。论域为 $D = \{d_1, d_2, d_3, d_4, d_5, d_6, d_7, d_8, d_9, d_{10}\}$, 条件因素集为 $F = \{f_1, f_2, f_3, f_4\}$, 条件因素的性状空间为 $I(f_1) = \{a_{11}, a_{12}, a_{13}\} = \{1, 2, 3\}$, $I(f_2) = \{a_{21}, a_{22}, a_{23}, a_{24}\} = \{0, 1, 2, 3\}$, $I(f_3) = \{a_{31}, a_{32}, a_{33}\} = \{1, 2\}$, $I(f_4) = \{a_{41}, a_{42}\} = \{1, 2\}$, 结果因素为 g , 结果因素的性状空间为 $I(g) = \{g_1, g_2\} = \{1, 2\}$ 。计算各条件因素的重要度。

表 5.1 评价分析表
Table 5.1 Evaluation analysis table

D	$F \rightarrow g$				
	f_1	f_2	f_3	f_4	g
d_1	1	0	2	1	1
d_2	2	1	1	2	1
d_3	3	2	3	1	2
d_4	2	3	1	2	2
d_5	1	1	2	1	1
d_6	3	1	3	2	2
d_7	2	3	1	1	1
d_8	1	0	2	2	1
d_9	2	2	3	1	2
d_{10}	3	1	1	2	2

计算各条件因素对结果因素的决定度, $d(f_1) = 6/10$, $d(f_2) = 4/10$, $d(f_3) = 6/10$, $d(f_4) = 0$ 。

以条件因素 f_1 为例给出因素重要度的计算过程。每个对象在条件因素集 F 中的取值都不相同, 因此 $d(F) = 1$ 。去掉因素 f_1 后, 其余因素 f_2 、 f_3 、 f_4 的合成划分将论域 D 划分为 8 类:

$(0,2,1): \{d_1\}$ 对应 $g = \{1\}$,
 $(1,1,2): \{d_2, d_{10}\}$ 对应 $g = \{1, 2\}$,
 $(2,3,1): \{d_3, d_9\}$ 对应 $g = \{2\}$,
 $(3,1,2): \{d_4\}$ 对应 $g = \{2\}$,
 $(1,2,1): \{d_5\}$ 对应 $g = \{1\}$,
 $(1,3,2): \{d_6\}$ 对应 $g = \{2\}$,
 $(3,1,1): \{d_7\}$ 对应 $g = \{1\}$,
 $(0,2,2): \{d_8\}$ 对应 $g = \{1\}$ 。

类 $(0,2,1)$ 、 $(3,1,2)$ 、 $(1,2,1)$ 、 $(1,3,2)$ 、 $(3,1,1)$ 和 $(0,2,2)$ 中都只包含一个对象，都是合成因素 f_2 、 f_3 、 f_4 的决定类，类 $(1,1,2)$ 和 $(2,3,1)$ 都包含两个对象，其中，类 $(1,1,2)$ 中的两个对象对应的结果因素不都相同（有 1 有 2），不是决定类，类 $(2,3,1)$ 中的两个对象对应的结果因素都相同（都为 2），是决定类，因此

$$d(f_2, f_3, f_4) = (1 + 2 + 1 + 1 + 1 + 1 + 1) / 10 = 8 / 10$$

所以，因素 f_1 的重要度为

$$M(f_1) = d(F) - d(F - \{f_1\}) = d(F) - d(f_2, f_3, f_4) = 1 - 8 / 10 = 2 / 10$$

同理因素 f_2 的重要度：

$$M(f_2) = d(F) - d(F - \{f_2\}) = d(F) - d(f_1, f_3, f_4) = 1 - 8 / 10 = 2 / 10$$

因素 f_3 的重要度：

$$M(f_3) = d(F) - d(F - \{f_3\}) = d(F) - d(f_1, f_2, f_4) = 1 - 10 / 10 = 0$$

因素 f_4 的重要度：

$$M(f_4) = d(F) - d(F - \{f_4\}) = d(F) - d(f_1, f_2, f_3) = 1 - 10 / 10 = 0$$

因素 f_3 和 f_4 的重要度为 0，这说明去掉因素 f_3 或 f_4 后，对因果分析表区分对象的分类能力不变。

5.2 因果森林算法

（1）算法原理

算法的本质是通过自助采样和因素的随机选择的方法构建多个因果树形成因果森林。算法的关键是计算条件因素重要度，筛选出重要因素，并通过随机选择增加模型的多样性，新的测试数据的分类结果由森林中的每个因果树的投票结果所得。

具体算法原理：

对原始数据集采用自助采样的抽样方式，生成新的训练样本集合，确保每个生成的训练集都是原始数据集的一个随机子集，增加模型的多样性；对于每个新生成的训练集，计算各个条件因素的重要度，设置重要度阈值 α ，删除那些重要度小于 α 的条件因素，以此

减少因素维度，优化因果树的构建基础；在因果树构建时随机选择 l 个因素作为节点的候选因素；选择具有最大决定度的因素作为划分节点形成一个因果树；每个因果树对测试集上的样本进行预测；所有因果树的预测结果通过投票机制汇总，最终投票数最多的类别标签为测试样本的类别标签。

对于一个单一的因果树分类器 T_k ，其对待测样本 d 进行错误分类的概率为 ε 。现在因果森林中有 K 个因果树，假设每个因果树的错误率都相同且独立，那么因果森林分类器的错误率为

$$P(\text{因果森林错误率}) = \sum_{k=\lfloor K/2 \rfloor}^K \binom{K}{k} \varepsilon^k (1-\varepsilon)^{K-k} \quad (5.2)$$

式 (5.2) 表示因果森林分类器在超过一半的树模型都错误分类时的概率。通过增加因果树的个数 K ，可以显著降低因果森林分类器的错误率。

如果将每个树的分类结果都视为一个随机变量，即每个树的分类结果 $T_k \in \{0,1\}$ ，且这个随机变量的期望值等于分类器的错误率，即 $E(T_k) = \varepsilon$ 。其中， T_k 表示第 k 个树对一个待测样本的分类结果。如果分类正确，则 $T_k = 0$ ；如果分类错误，则 $T_k = 1$ 。那么，因果森林分类器的分类结果 T 为

$$T = \begin{cases} 1, & \text{如果 } \sum_{k=1}^K T_k > K/2 \\ 0, & \text{如果 } \sum_{k=1}^K T_k \leq K/2 \end{cases}$$

对于一个因果树，其错误率为 ε ，方差为

$$\text{Var}(T_k) = E(T_k^2) - (E(T_k))^2 = \varepsilon - \varepsilon^2 = \varepsilon(1-\varepsilon)$$

则因果森林分类器的方差为

$$\text{Var}(T) = \text{Var}\left(\frac{1}{K} \sum_{k=1}^K T_k\right) = \frac{1}{K^2} \sum_{k=1}^K \text{Var}(T_k) = \frac{1}{K^2} \cdot K \cdot \varepsilon(1-\varepsilon) = \frac{\varepsilon(1-\varepsilon)}{K}$$

因果森林的方差随着 K 的增加而减少，这说明更多的树可以显著降低分类误差的方差。

通过上面的分析，因果森林算法可以将单个因果树的方差降低到 $1/K$ 倍，从而显著提高分类准确性。

(2) 阈值的设定

在利用因果森林算法进行数据分类时，条件因素的选择对模型的性能有着决定性影响。这里，条件因素的选择是根据其对模型的重要度来决定。重要度的计算旨在评估每个因素对模型预测能力的贡献度。然而，决定哪些因素应该保留哪些应该删除，关键在于设定一个合理的重要度阈值。阈值的设定过程中，既要避免模型过度简化，又要防止模型过于复杂。因此，合理设定阈值对于模型的性能很重要。

① α 值太高：导致几乎所有的条件因素都被视为不重要因素而被删除，导致模型过度简化，丢失了重要的信息，从而降低模型的性能。

② α 值太低：导致一些实际上对于模型的预测贡献不大的条件因素被视为重要因素而被保留，导致模型过于复杂，存在过拟合的风险，从而降低模型的泛化能力。

(3) 算法步骤

设论域 $D = \{d_1, d_2, \dots, d_m\}$ ，条件因素集 $F = \{f_1, f_2, \dots, f_n\}$ ，条件因素性状空间为 $I(f_j) = \{a_{j1}, a_{j2}, \dots, a_{jk}\} (j=1, 2, \dots, n)$ ；结果因素为 g ，结果因素的性状空间为 $I(g) = \{g_1, g_2, \dots, g_s\}$ 。因果森林算法步骤如下：

步骤 1 通过自助采样法的采样策略，从原始因果分析表中产生 K 个不同的因果分析表；

步骤 2 对于每个生成的因果分析表，计算各个条件因素的因素重要度，设置因素重要度阈值 α ，删除重要度低于阈值 α 的条件因素，以减少因素维度；

步骤 3 在划分节点时，从剩余的条件因素中随机选择一个子集，计算这些子集中每个因素的決定度，选择具有最大決定度的条件因素作为当前节点的划分标准；

步骤 4 根据选定的条件因素进行划分，重复上述过程，直到所有节点的样本数据都属于同一类或条件因素集为空；

步骤 5 重复上述步骤，构建 K 个因果树；

步骤 6 对于待测样本，通过投票的方式将前面生成的 K 个因果树的结果综合起来，出现次数最多的结果即为待测样本的预测结果。

算法具体步骤如下：

算法 5.1 因果森林算法

输入 因果分析表 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$ ，条件因素集 $F = \{f_1, f_2, \dots, f_n\}$ ，结果因素 g ，因果树的个数 K ，待测样本 d 。

输出 待测样本 d 的类别标签。

步骤 1 对于任意的 $1 \leq k \leq K$ ，从原始因果分析表中通过自助采样的抽样方式，获得 K 个大小为 m 的新的因果分析表 $T_1, T_2, \dots, T_K$ ；

步骤 2 对每个新的因果分析表 T_k ，调用算法 5.2 构建一个因果树 Tr_k 。

步骤 3 对待测样本 d ，分别使用这 K 个因果树对 d 进行预测，得到 K 个预测结果 $T_1(d), T_2(d), \dots, T_K(d)$ ，通过投票的方式得到测试样本 d 的类别标签；

步骤 4 算法结束，返回测试样本 d 的最终预测结果。

算法 5.2 单个因果树 Tr_k 算法

输入 因果分析表 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$ ，条件因素集 $F = \{f_1, f_2, \dots, f_n\}$ ，结果因素 g ，因素重要度阈值 α 。

输出 因果树 Tr_k 。

步骤 1 创建一个新的节点，该节点包括论域中的全部对象；

步骤 2 如果节点满足停止分裂条件（所有样本属于同一类或条件因素集为空），将该节点标记为叶子节点，并将节点中最大的类作为该结点的类别标签；

步骤 3 计算 F 中每个条件因素的因素重要度，设置因素重要度阈值 α ，将重要度小于阈值 α 的条件因素删除，从剩余的条件因素中随机选择部分因素，得到当前因果分析表 $(D, F'; g)$ ；

步骤 4 计算剩余因素中的每个因素的決定度，选择具有最大決定度的条件因素作为当前节点的划分标准，根据选定的条件因素进行论域划分，形成新的子节点；递归地对子节点重复以上步骤，直到所有节点的样本数据都属于同一类或条件因素集为空；

步骤 5 算法结束，返回构建好的因果树 Tr_i 。

因果森林算法过程见表 5.2。

表 5.2 因果森林算法
Table 5.2 Causal forest algorithm

因果森林算法

输入：因果分析表 $(D, F = \{f_1, f_2, \dots, f_n\}; g)$ ，条件因素集 $F = \{f_1, f_2, \dots, f_n\}$ ，结果因素 g ，因果树的个数 K ，因素重要度阈值 α ，待测样本 d 。

过程：

1. **for** $k = 1, 2, \dots, K$
2. 从原始因果分析表中通过自助采样的抽样方式，获得大小为 m 的新的因果分析表；
3. 计算 F 中每个条件因素的因素重要度，设置因素重要度阈值 α ，将重要度小于阈值 α 的条件因素删除，从剩余的条件因素中随机选择部分因素，得到当前因果分析表，利用因果树算法生成因果树；
4. 对待测样本 d ，使用因果树对 d 进行预测，得到预测结果；
5. **end for**
6. 将所有预测结果进行综合。

输出： d 的类别标签。

因果森林算法流程图见图 5.1。




图 5.1 因果森林算法流程图
Figure 5.1 Flow chart of causal forest algorithm

5.3 实验分析

为验证因果森林算法的有效性，使用 UCI 数据库和 Data Fountain 数据平台中的 5 个不同分类数据集进行了实验分析。

(1) 数据说明

除了 4.2 节中用到的 Vote 和 Cancer 数据集，其余各数据集的具体信息如下：

Npha 数据集是全国健康老龄化民意调查，用来预测受访者在一年内看到的医生数量，结果因素有 2 种：0-3 名医生记为 1，4 名或更多医生记为 2；

Car 数据集源自一个简单的分层决策模型，用于汽车评估。结果因素分为四种：不接受、被接受、好和非常好；

Churn 数据集是某电信客户流失数据集，用来判断客户是否流失，结果因素有 2 种：流失和不流失。

各数据集的具体结构见表 5.3。

表 5.3 实验数据说明
Table 5.3 Explanation of experimental data

序号	名称	对象个数	条件因素个数	结果类别
1	Vote	435	16	2
2	Cancer	683	9	2
3	Npha	714	14	2
4	Car	1728	6	4
5	Churn	6859	16	2

(2) 实验结果与分析

Churn 数据集的具体信息见表 5.4，以该数据集为例说明 α 阈值和基学习器个数的确定。

表 5.4 用户流失的因果分析表
Table 5.4 Causal analysis of user churn

D	f_1	f_2	f_3	f_4	f_5	$\cdots$	g
1	1	1	1	2	1	$\cdots$	1
2	2	2	1	2	2	$\cdots$	2
3	1	2	2	2	1	$\cdots$	1
4	1	2	1	1	1	$\cdots$	2
5	1	2	1	2	1	$\cdots$	2
6	2	2	1	1	3	$\cdots$	2
7	2	2	2	2	1	$\cdots$	2
8	2	2	1	1	3	$\cdots$	2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
6859	2	1	1	2	1	$\cdots$	1

① α 阈值确定

α 阈值的大小与单个树的准确率之间的关系如图 5.2 所示。




图 5.2 α 大小与单个树准确率的关系

Figure 5.2 Relationship between accuracy of a single tree and α threshold

由图 5.2 可知, 在此数据集中, 当 α 为 0.2 时, 单个因果树的准确率最高, 因此, 对该数据集选取因素重要度的阈值为 0.2。

② 基学习器个数的确定

在 α 大小固定的情况下, 因果树个数 K 分别取 5、10、15、...、100 等数值, 通过十折交叉验证进行实验, 根据平均分类准确率确定最优的参数。结果见图 5.3。




图 5.3 基学习器个数与分类准确率的关系

Figure 5.3 Relationship between the number of base learners and classification accuracy

由图 5.3 可知, 当 $K=40$ 时, 算法的平均准确率最高, 即建立 40 个因果树是最优的。

③ 算法对比

应用因果树算法、因果树聚合算法、随机森林算法和因果森林算法分别对样本数据建

立了分类模型。对各算法的准确率、精准率、召回率和 F1 值进行比较, 结果见表 5.5。

表 5.5 各算法比较

Table 5.5 Comparison of various algorithms

算法	准确率/%	精准率/%	召回率/%	F1 值
因果树算法	36.49	34.59	48.81	0.40
因果树聚合算法	73.62	73.44	71.76	0.73
随机森林算法	69.44	64.58	72.65	0.68
因果森林算法	76.83	74.91	80.39	0.78

通过对比表 5.5 中各算法的结果显示, 在对客户流失数据集应用因果树算法时, 训练集上的准确率接近 100%, 而测试集的准确率只有 34.69%; 同时, 还出现了样本无法识别的问题, 测试集中有 525 个样本无法识别。因果森林算法的准确率为 76.83%, 并且测试集中所有样本均可识别, 解决了因果树算法的过拟合准确率不高的问题。并且, 因果森林算法的准确率也高于因果树聚合算法。

对其余四个数据集进行实验分析。对于 Vote 数据集, 因素重要度阈值 α 为 0.01; 对于 Cancer 数据集, 因素重要度阈值 α 为 0.002; 对于 Npha 数据集, 因素重要度阈值 α 为 0.2; 对于 Car 数据集, 因素重要度阈值 α 为 0.05。实验结果见表 5.6。

表 5.6 实验结果对比

Table 5.6 Comparison of experimental results

数据集	指标	因果树 算法	因果树聚合 算法	因果森林 算法	随机森林 算法
Vote	Acc	0.8308	0.9462	0.9478	0.9308
	Pre	0.9718	0.9877	0.9886	0.9873
	Rec	0.8625	0.9302	0.9364	0.9070
	F1	0.9139	0.9581	0.9618	0.9454
Cancer	Acc	0.8609	0.8653	0.9056	0.9519
	Pre	0.9907	0.9907	0.9822	0.9969
	Rec	0.8243	0.8219	0.9795	0.9895
	F1	0.8999	0.9027	0.9423	0.9932
Npha	Acc	0.5352	0.6637	0.7746	0.6761
	Pre	0.8140	0.6978	0.8000	0.7581
	Rec	0.7292	0.8823	0.9455	0.8545
	F1	0.7693	0.7793	0.8667	0.8034
Car	Acc	0.8895	0.8757	0.9427	0.9028
	Pre	0.9604	0.8682	0.9672	0.9505
	Rec	0.8895	0.8436	0.9427	0.9028
	F1	0.9189	0.8557	0.9529	0.9232

通过表 5.6 可知, 在 Vote 和 Car 数据集中, 因果森林算法显示了最佳的准确率、精确率、召回率和 F1 值, 在该数据集上的综合性能最优; 对于 Cancer 数据集, 随机森林算法在准确率、精确率、召回率和 F1 值上均表现最优; 在 Npha 数据集中, 因果森林算法各方面的性能都优于因果树聚合算法和随机森林算法, 因果树算法有最高的精确率。从整体

来看，因果森林算法在准确率、精准率、召回率和 F1 值都优于因果树算法、随机森林算法和因果树聚合算法。

5.4 小结

为了解决当条件因素性状取值个数过多或复杂数据集因果树聚合算法的准确率不高的问题，本章提出了因果森林算法。即在原有因果树聚合算法的基础上增加了因素约简和因素随机选择的步骤，设置阈值将因素重要度低的条件因素删除，从而提高算法的分类性能。通过对数据集使用不同算法进行对比分析得到：因果森林算法在准确率、精确率、召回率以及 F1 值四个指标上性能均优于因果树算法、因果树聚合算法和随机森林算法，证明了算法的有效性。

6 结论与展望

此部分首先对本文涉及到的创新点、提出的算法进行评价，然后对未来工作进行进一步展望。

(1) 基于因素空间理论的决定度，利用因素分析法提取推理规则的原理，提出基于树结构的因果树算法，得到推理规则，并通过一个算例具体展示因果树的构建过程。对 UCI 数据库中的 Lymphography 数据集用因果树算法进行分析发现，因果树算法在某些情况下存在着过拟合和准确率不高的问题。

(2) 针对因果树算法可能出现的过拟合问题和提高单一因果树的准确率，利用自助抽样法，提出因果树聚合算法。通过对 UCI 数据库中的 8 个数据集进行实验分析，结果表明：因果树聚合算法在各数据集上的学习性能都较因果树算法有一定的提升，这说明对因果树算法的改进提高了算法应对噪声数据的能力。在各数据集上因果树聚合算法的准确率、精确率、召回率、F1 值都明显优于其他大多数分类算法，但是在个别数据集上各分类算法性能相差不大，如 KpkrA7 数据集。

(3) 针对条件因素过多或数据较为复杂对分类造成的影响，提出因果森林算法。首先，给出因素重要度的概念；其次，设置阈值对条件因素集进行约简，随机选择因素得到因果森林算法。通过在数据集中分别应用因果树算法、因果树聚合算法、随机森林算法和因果森林算法进行对比分析，在大多数数据集中因果森林算法的准确率、精准率、召回率和 F1 值都优于其他算法。

在实际应用中，需要进行处理的数据往往很庞大，虽然因果森林算法在一定程度上提高了分类的准确率，但庞大的数据集不可避免的会增加运算时间，所以如何降低算法的复杂度是今后所要解决的问题。后续的研究可以继续从数据集的因素约简中入手，减小算法的训练时间。此外，本文所提出的算法都是通过并行的方法实现的，未来的研究可以探索串行的聚合方法。这种方法可以进一步挖掘学习器间的互补性，潜在地提高模型的准确性和泛化能力。同时，研究如何有效地组合并行和串行学习方法，也可能为解决更复杂的数据分析问题提供新的思路 and 工具。

参考文献

- [1] Wille R. Restructuring lattice theory: an approach based on hierarchies of concepts[M]. Ordered Sets. Springer Netherlands, 1982: 445-470.
- [2] Pawlak Z. Rough sets[J]. International Journal of Parallel Programming, 1982, 11(05): 341-356.
- [3] 汪培庄, Sugeno M. 因素场与模糊集的背景结构[J]. 模糊数学, 1982(02): 45-54.
- [4] 汪培庄. 随机微分方程·统计物理学进展[M]. 北京: 科学出版社, 1981.
- [5] 汪培庄, 李洪兴. 知识表示的数学理论[M]. 天津: 天津科学技术出版社, 1994.
- [6] Wang P Z, Zhang X H, Liu H C, et al. Mathematical theory of truth-valued flow inference[J]. Fuzzy Sets and Systems, 1995, 72(02): 221-238.
- [7] 李洪兴. 因素空间理论与知识表示的数学框架(I)-因素空间的公理化定义与描述架[J]. 北京师范大学学报(自然科学版), 1996, 32(04): 470-475.
- [8] 李洪兴. 因素空间理论与知识表示的数学框架(VIII)-变权综合原理[J]. 模糊系统与数学, 1995, 9(03): 1-9.
- [9] 李洪兴. 因素空间理论与知识表示的数学框架-概念的反馈外延与因素的重合性[J]. 系统工程学报, 1996, 11(04): 12-21.
- [10] 李洪兴. 因素空间理论与知识表示的数学框架(XII)-描述架中概念的结构(1)[J]. 模糊系统与数学, 1997, 11(02): 3-11.
- [11] 李洪兴. 因素空间理论与知识表示的数学框架(VI)- ASM_m -func 的生成与综合决策的一般模型[J]. 系统工程学报, 1999, 14(01): 3-10.
- [12] 刘增良. 因素神经网络理论[M]. 北京: 北京师范大学出版社, 1990.
- [13] 刘增良, 刘有才. 模糊逻辑与神经网络[M]. 北京: 北京航空航天大学出版社, 1996.
- [14] 袁学海, 汪培庄. 因素空间中的一些数学结构[J]. 模糊系统与数学, 1993, 7(01): 44-54.
- [15] 袁学海, 汪培庄. 因素空间和范畴[J]. 模糊系统与数学, 1995, 9(02): 25-33.
- [16] 于福生. 基于因素空间的模糊诊断理论和模糊诊断专家系统开发工具[D]. 北京师范大学, 1998.
- [17] 于福生. 反向推理型诊断问题专家系统通用构建模型[J]. 系统工程理论与实践, 1998, 18(05): 72-77.
- [18] 汪培庄. 因素空间与因素库[J]. 辽宁工程技术大学学报(自然科学版), 2013, 32(10): 1297-1304.
- [19] 汪培庄, 郭嗣琮, 包研科, 等. 因素空间中的因素分析法[J]. 辽宁工程技术大学学报: 自然科学版, 2014, 33(07): 865-870.
- [20] 刘海涛, 郭嗣琮. 因素分析法的推理模型[J]. 辽宁工程技术大学学报(自然科学版), 2015, 34(01): 124-128.
- [21] 包研科, 茹慧英, 金圣军. 因素空间中知识挖掘的一种新算法[J]. 辽宁工程技术大学学报(自然科学版), 2014, 33(08): 1141-1144.
- [22] 汪华东, 汪培庄, 郭嗣琮. 因素空间中改进的因素分析法[J]. 辽宁工程技术大学学报自然科学版, 2015, 34(04): 539-544.

- [23] 曲卫华,刘海涛,郭嗣琮.因素空间中的多标准因果分析方法[J].模糊系统与数学,2017,31(06):74-81.
- [24] 陈万景,曾繁慧.基于因素空间决定度的动态因素约简算法[J].辽宁工程技术大学学报(自然科学版),2018,37(02):430-433.
- [25] 孙慧,曾繁慧,蒲凌杰.因素空间理论下多目标因果分析的降维算法[J].辽宁工程技术大学学报(自然科学版),2021,40(05):466-472.
- [26] 刘晓同,曾繁慧,刘晓娟.因素空间理论下银行信用卡违约预测[J].辽宁工程技术大学学报(自然科学版),2021,40(06):567-574.
- [27] 张艳妮,曾繁慧,包研科,等.辽宁省阜新农村地区人群高血压危险因素分析[J].中华高血压杂志,2017,25(10):937-941.
- [28] 曾繁慧,张晶,汪北方,等.基于决定度的高盐饮食人群高血压病因素分析[J].模糊系统与数学,2018,32(03):176-184.
- [29] 杨巨文,何峰,崔铁军,等.基于因素分析法的煤矿灾害安全性分析[J].中国安全生产科学技术,2015,11(04):84-89.
- [30] 刘海涛,郝传波,傅贵.因素空间下的煤与瓦斯突出预测方法[J].黑龙江科技大学学报,2017,27(04):354-358.
- [31] 郭君,汪培庄,黄崇福.因素空间与因素熵在物联网中的应用[J].模糊系统与数学,2017,31(06):59-65.
- [32] 汪培庄.因素空间理论—机制主义人工智能理论的数学基础[J].智能系统学报,2018,13(01):37-54.
- [33] 曲国华,曾繁慧.因素空间中的背景分布与模糊背景关系[J].模糊系统与数学,2017,31(06):66-73.
- [34] 吕金辉,刘海涛,郭芳芳,等.因素空间背景基的信息压缩算法[J].模糊系统与数学,2017(06):82-86.
- [35] 蒲凌杰,曾繁慧,汪培庄.因素空间理论下基点分类算法研究[J].智能系统学报,2020,15(03):528-536.
- [36] 汪培庄,曾繁慧.因素空间理论—统一智能理论的数学基础[M].北京:科学出版社,2024.
- [37] 崔铁军,汪培庄.空间故障树与因素空间融合的智能可靠性分析方法[J].智能系统学报,2019,14(05):853-864.
- [38] 崔铁军,李莎莎.线性熵的系统故障熵模型及其时变研究[J].智能系统学报,2021,16(06):1136-1142.
- [39] 罗常伟,王双双,尹峻松,等.集成学习研究现状及展望[J].指挥与控制学报,2023,9(01):1-8.
- [40] Hansen L,Salamon P.Neural network ensembles[J].IEEE Transaction on Pattern Recognition and Machine Intelligence,1990,12(10):993-1001.
- [41] Breiman L.Bagging predictors[J].Machine Learning,1996,24(02):123-140.
- [42] Zhang T Y,Quevedo R P,Wang H Y,et al.Improved tree-based machine learning algorithms combining with bagging strategy for landslide susceptibility modeling[J].Arabian Journal of Geosciences,2022,15(2):21-44.
- [43] Misiuk B,Brown C J.Improved environmental mapping and validation using bagging models with spatially clustered data[J].Ecological Informatics,2023,77.

- [44] Azhagiri M,Rajesh A,Karthik S,et al.An intrusion detection system using ranked feature bagging[J]. International Journal of Information Technology,2023,16(2):1213-1219.
- [45] Wang J Y,Jiang X Z,Liu H L,et al.An adaptive bagging algorithm based on lightweight transformer for multi-class imbalance recognition[J].Multimedia Systems,2024,30(2):99-108.
- [46] Zhang Q ,Ning Z X,Ding X H, et al.Hybrid integration of bagging and decision tree algorithms for landslide susceptibility mapping[J].Water,2024,16(5):435-448.
- [47] 郭耀木,刘鹏,孙源乐,等.基于不平衡社交媒体文本的抑郁症检测方法[J].计算机技术与发展,2024,34(04):153-161.
- [48] Nithya R,Kokilavani T,Beena T,et al.Balancing cerebrovascular disease data with integrated ensemble learning and SVM-SMOTE[J].Network Modeling Analysis in Health Informatics and Bioinformatics, 2024,13(1).
- [49] 祁炜雯,张俊,吴洋,等.基于改进 BP-Bagging 算法的光伏电站故障诊断方法[J].浙江电力,2024,43(03): 65-74.
- [50] 于涛,丁海旭,黄卫民,等.面向复杂异质数据的集成学习研究综述[J].控制工程,2023,30(08):1425-1435.
- [51] Breiman L.Random forests[J].Machine Learning,2001,45(01):5-32.
- [52] Wang T Y.Improved random forest classification model combined with C5.0 algorithm for vegetation feature analysis in non-agricultural environments[J].Scientific Reports,2024,14(1):10367-10367.
- [53] Zhang J H.Impact of an improved random forest-based financial management model on the effectiveness of corporate sustainability decisions[J].Systems and Soft Computing,2024,6200102.
- [54] Ma X T,Zhang F ,Luo H P, et al.Water shortage detection of jujube trees based on spectral technology and random forest classifier integrated with fractal theory[J].Industrial Crops & Products,2024,216118729.
- [55] Wang B B,Yue X F,Liu Y L,et al.A Dynamic Trust Model for Underwater Sensor Networks Fusing Deep Reinforcement Learning and Random Forest Algorithm[J].Applied Sciences,2024,14(8):3374.
- [56] 李强,陈衍姣.基于随机森林的商业性养老保险购买行为预测[J].科技和产业,2022,22(08):271-275.
- [57] 汪力纯,刘水生.基于混合采样和特征选择的改进随机森林算法研究[J].南京邮电大学学报(自然科学版),2022,42(01):81-89.
- [58] Zhou L W,Xu D,Yuan Y N,et al.Research on transformer fault intelligent diagnosis technology based on improved random forest algorithm[J].Journal of Physics:Conference Series,2024,2728(1).
- [59] Freund Y,Schapire R E.Experiments with a new boosting algorithm[J].In:Proceedings of International Conference on Machine Learning,1996,96:148-156.
- [60] Luxmi K M,Tiwari N K,Ranjan S.Estimation and comparison of gabion weir oxygen mass transfer by ensemble learnings of bagging,boosting,and stacking algorithms[J].ISH Journal of Hydraulic Engineering, 2023,29(01):196-211.

- [61] 李春鹏,韩萌,孟凡兴,等.复杂数据流在线集成分类算法综述[J].计算机应用研究,2024,41(03):641-651.
- [62] Freund Y,Schipare R.A decision-theoretic generalization of on-line learning and an application to boosting[J].Computational Learning Theory:Second European Conference,1995:23-37.
- [63] Nirmal S,Patil P,Kumar R R J.CNN-AdaBoost based hybrid model for electricity theft detection in smart grid[J].e-Prime-Advances in Electrical Engineering,Electronics and Energy,2024,7100452.
- [64] 宋玉涵,祝跃飞,魏福山.一种基于 AdaBoost 模型的区块链异常交易检测方案[J].信息安全,2024,24(01):24-35.
- [65] Friedman H J.Greedy function approximation:a gradient boosting machine[J].The Annals of Statistics,2001,29(05):1189-1232.
- [66] Ayyoub F,Mohamed M,Mehdi M,et al.Harnessing LSTM and XGBoost algorithms for storm prediction[J].Scientific Reports,2024,14(1):11381-11381
- [67] Veronica Z,Andrea M,Chiara C,et al.Classification of tumor types using XGBoost machine learning model:a vector space transformation of genomic alterations[J].Journal of Translational Medicine,2023,21(01):836-836.
- [68] Preethi R.Assaul type detection in WSN based on modified DBSCAN with osprey optimization using hybrid classifier LSTM with XGBOOST for military sector[J].Optical Memory and Neural Networks,2024,33(1): 53-71.
- [69] Wang M,Zhang J G,Han L,et al.Identification of mine water source based on TPE-LightGBM[J].Scientific Reports,2024,14(1):12539-12539.
- [70] Zhu J Y,An J L,Feng Y Z,et al.Atmospheric ozone concentration prediction in nanjing based on LightGBM[J].Huan jing ke xue,2023,44(07):3685-3694.
- [71] Ren X K,Yu H W,Chen X F,et al.Application of the CatBoost model for stirred reactor state monitoring based on vibration signals[J].School of Mechanical Engineering,Tianjin University[J].2024,140(1): 647-663.
- [72] Chang W F,Wang X,Yang J,et al.An improved CatBoost-Based classification model for ecological suitability of blueberries[J].Sensors,2023,23(04):1811-1811.
- [73] Bian X,Fan Z Y,Liu J X,et al.Regional 3D geological modeling along metro lines based on stacking ensemble model[J].Underground Space,2024,18:65-82.
- [74] Pal M,Agrawal A,Nirala K C.Enhancing formability in Micro-Incremental sheet forming by a novel stacking method of ultra-thin sheets[J].Manufacturing Letters,2024,40:159-163.

学位论文数据集

关键词*	密 级*	中图分类号*	UDC	论文资助
因素空间；因果树算法；因果树聚合算法；因素重要度；因果森林算法	公开	O29	510	辽宁省教育厅高等学校基本科研项目重点攻关项目（LJKZZ20220047）
学位授予单位名称*	学位授予单位代码*	学位类别*		学位级别*
辽宁工程技术大学	10147	学术		硕士研究生
论文题名*		并列题名*		论文语种*
基于因素分析的因果森林算法研究		Research on Causal Forest Algorithm based on Factor Analysis		中文
作者姓名*	林凯乐	学 号*		472121459
培养单位名称*	培养单位代码*	培养单位地址		邮 编
辽宁工程技术大学	10147	辽宁省阜新市		123000
学科专业*	研究方向*	学 制*		学位授予年*
数学	智能科学的数学理论及应用	3 年		2024
论文提交日期*		2024 年 6 月 20 日		
导师姓名*	曾繁慧	职 称*		教授
评阅人		答辩委员会主席*	答辩委员会成员	
		屠良平	胡行华，于冬梅，赵世杰， 刘海涛，徒君	
电子版论文提交格式 文本（√） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） 推荐格式： application/msword; application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*		50		
注：共 33 项，其中带*为必填数据，共 22 项。				