

文章编号: 2095-6991(2026)04-0054-11

基于异构联邦因果森林模型的 惠农补贴欺诈跨区域归因分析研究

林怡胜

(安徽绿海商务职业学院 工商管理学院, 安徽 合肥 230601)

摘要:针对传统归因分析方法在处理跨区域惠农补贴数据时面临的数据异构性、计算效率低下以及隐私保护难题,提出一种融合联邦学习与因果森林算法的异构联邦因果森林模型。研究以 2018—2023 年全国 31 个省市的惠农补贴数据为对象,与传统因果森林、联邦随机森林以及异构联邦逻辑回归等模型进行了对比分析。研究结果表明,本文模型在分类与回归任务中均展现出卓越的性能,其准确率高达 0.87, AUC-ROC 值达到 0.91, 均方根误差仅为 0.82, 且跨区域泛化能力较强。该模型不仅精准识别公示透明度、干部任期等关键共性因素,还揭示了各区域特有的影响因素,并通过因果效应可视化直观呈现了各因素与惠农补贴欺诈风险之间的关系。

关键词:异构联邦因果森林模型; 惠农补贴欺诈; 跨区域归因分析; 联邦学习; 因果推断

中图分类号: TP181

文献标志码: A

DOI: 10.13804/j.cnki.2095-6991.2026.04.012

Cross-Regional Attribution Analysis of Agricultural Subsidy Fraud Based on Heterogeneous Federated Causal Forest Model

LIN Yi-sheng

(School of Business Administration, Anhui Lvhai Vocational College of Business, Hefei 230601, China)

Abstract: Aiming at the data heterogeneity, computational inefficiency, and privacy protection challenges faced by traditional attribution analysis methods when dealing with cross-region rural subsidy data, a Heterogeneous Federated Causal Forest Model (HFCF) integrating federated learning and causal forest algorithms is proposed. The study takes the data of agricultural subsidies in 31 provinces and cities across China from 2018 to 2023 as the research object, and compares it with the traditional Causal Forest (CF), Federated Random Forest (FRF), and Heterogeneous Federated Logistic Regression (HFLR). HFLR models were comparatively analyzed. The results show that the HFCF model exhibits excellent performance in both classification and regression tasks, with an accuracy as high as 0.87, an AUC-ROC value of 0.91, a root-mean-square error of only 0.82, and a strong cross-region generalization ability. The model not only accurately identifies key common factors such as transparency of public announcements and cadre tenure, but also reveals region-specific influencing factors, and visualizes the relationship between each factor and the risk of rural subsidy fraud through the visualization of causal effects.

Key words: heterogeneous federated causal forest model; fraud of agricultural subsidies; cross regional attribution analysis; federated learning; causal inference

收稿日期: 2025-08-25

基金项目: 安徽省高等学校科学研究项目(2022AH052914); 安徽省教育厅省级质量工程一流核心课程项目(2023hxkc173)

作者简介: 林怡胜(1984-), 男, 安徽岳西人, 讲师, 硕士, 研究方向为大数据与会计、财务管理教育. E-mail: ahlys2025@163.com.

0 引言

我国的惠农补贴政策在农业发展与农民生活改善中发挥了重要作用,但在执行过程中,骗取惠农补贴等违规申领问题长期较为突出^[1].部分地区常见做法包括虚报种植面积、伪造危房改造项目以及重复申报补贴.这些行为不仅浪费了财政资金,还破坏了政策的公平性,降低农户对惠农扶持政策的信任感^[2].传统集中式归因分析模型在多区域惠农补贴融合分析场景下存在多重局限.首先,不同地区在数据收集方式、统计口径和格式上存在显著差异,例如部分区域以农户为统计单元,而其他区域则以村集体为单位,导致数据结构和维度不一致,从而增加了跨区域整合与比较的难度^[3].其次,补贴数据通常规模庞大且维度较高,传统方法在处理此类数据时计算效率低,难以满足快速分析的需求^[4].更为关键的是,补贴数据涉及农户收入与身份等敏感信息,而传统方法缺乏有效的隐私保护机制,易引发数据泄露风险^[5].

近年来,惠农补贴欺诈问题在学术界与政策制定领域受到越来越多的关注.现有研究集中在3个方向.其一,基于规则与审计的检测方法.在此类方法中,研究人员通常依托政策规则与人工稽核筛查异常申领行为,高度依赖人工审核,面对海量补贴数据时效率极低^[6].其二,因果推断方法.以因果树与因果森林为代表的模型在解释欺诈行为成因方面具有一定优势,但模型推断效果高度依赖协变量完备性,跨区域异构数据集下泛化稳健性^[7].其三,随着跨区域补贴数据的不断增加,学者们开始尝试引入迁移学习以及联邦学习,以解决隐私保护与数据异构带来的挑战.Kairouz P等^[8]系统总结了联邦学习在数据安全与隐私保护中的应用.

不过,这些方法仍然存在明显不足.因果森林(causal forest, CF)在应对不同地区的分布差异时适应性有限;联邦随机森林(federated random forest, FRF)在因果效应估计上缺乏解释力;而异构联邦逻辑回归(heterogeneous federated logistic regression, HFLR)在非线性的任务中的表现不够理想^[9].因此,亟需一种既能在异构数据环境中

保证隐私保护,又能实现稳定建模并提供因果解释的新方法.针对上述问题,提出了一种异构联邦因果森林模型(heterogeneous federated causal forest model, HFCF).该模型依托联邦学习分布式架构,各区域本地训练、仅交互模型参数,全程不上传原始农户敏感数据以实现隐私保护.同时结合因果森林,更好地识别各类因素与补贴欺诈之间的因果关系.这样既能在跨区域数据中建立统一的归因模型,又能挖掘每个地区的特有因素.相比现有方法, HFCF在异构数据融合、因果效应估计以及跨区域泛化能力方面都有更突出的优势.

1 异构联邦因果森林模型构建

1.1 问题定义与数据模型

1.1.1 异构数据场景建模

在跨区域惠农补贴欺诈的归因分析中,数据异构性是一个至关重要的挑战.设存在 M 个区域节点,每个节点拥有独立收集和管理的惠农补贴数据,记为

$$D_m = \{(\mathbf{X}_i^m, T_i^m, Y_i^m)\}_{i=1}^{N_m}. \quad (1)$$

式中, $\mathbf{X}_i^m$ 是一个包含多种特征的向量,这些特征涵盖了补贴类型、申报流程细节、相关干部履历等多方面信息.不同地区的补贴类型可能存在差异,例如某些地区针对特色农产品种植提供专项补贴,而其它地区则侧重于农业基础设施建设补贴,从而导致特征呈现出较强的多样性^[10].

申报流程在不同区域中存在差异,部分地区主要采用线上申报方式,部分地区采用线下纸质申报模式.申报流程的复杂程度和透明度也不尽相同,这些差异均体现在 $\mathbf{X}_i^m$ 中.干部个体履历特征同样存在显著区域异质性,不同地区的干部在工作经验、教育背景、任职年限等方面存在差异,上述个体特征均会作用于惠农补贴申报、全流程审批环节,存在潜在因果关联^[11].

T_i^m 作为干预变量,清晰标识该样本是否涉及欺诈行为.其中,数值1代表发生欺诈行为,数值0代表未发生欺诈行为. Y_i^m 作为结果变量,它既可以表示因欺诈行为所导致的损失金额,也可依据特定评估标准来确定风险等级,以此衡量欺诈行为的严重程度及其潜在影响.

数据的异构性在实际应用中表现得尤为复杂.从分布差异的角度来看,不同区域的特征分布 $P(\mathbf{X}^m)$ 往往存在显著差异.以补贴类型特征为例,在以粮食种植为主导的区域,粮食补贴相关的数据分布相对集中,而在特色农业发展较为成熟的区域,特色农产品补贴相关的数据分布则更为显著,即

$$P(\mathbf{X}^m) \neq P(\mathbf{X}^n). \quad (2)$$

1.1.2 因果效应目标函数

因果效应的准确估计是本研究的核心目标之一.定义个体因果效应为

$$\tau_i = Y_i(1) - Y_i(0), \quad (3)$$

式中, $Y_i(1)$ 表示在干预发生(即 $T_i=1$, 发生惠农补贴欺诈)的情况下, 样本 i 的潜在结果; $Y_i(0)$ 则表示在干预未发生(即 $T_i=0$, 未发生惠农补贴欺诈)的情况下, 样本 i 的潜在结果. 个体因果效应 τ_i 直观反映了欺诈行为对每个样本的具体影响程度.

模型的主要目标是估计条件平均因果效应(GATE), 其定义为

$$\text{GATE}(\mathbf{X}) = E[\tau_i | \mathbf{X}_i = \mathbf{X}]. \quad (4)$$

这表明在给定特征向量 $\mathbf{X}$ 的前提下, 计算所有样本个体因果效应的期望值. 通过估计 GATE, 可以了解在特定特征组合下, 欺诈行为对惠农补贴结果的平均影响, 为后续的归因分析和风险评估提供关键依据^[12]. 在异构联邦学习的框架下, 各区域节点基于本地数据计算得到各自的 $\text{GATE}(\mathbf{X})$. 鉴于不同区域的数据存在异构性, 各区域的 $\text{GATE}(\mathbf{X})$ 也会存在明显差异. 借助高效的联邦学习机制, 将区域层面的 $\text{GATE}(\mathbf{X})$ 进行聚合, 进而构建出能够映射全局特征的归因模型. 该全局归因模型能够综合考虑各区域的特性与共性, 全面且精准地识别发生惠农补贴欺诈的核心因素, 为制定跨区域的统一监管策略提供了参考.

1.2 模型架构设计

1.2.1 分层联邦因果森林框架

异构联邦因果森林模型的架构采用分层形式, 创新性地应对跨区域惠农补贴数据的复杂性与异构性. 异构联邦因果森林模型采用 3 层结构: 本地因果树层、异构数据融合层和全局归因层. 每

一层都具有独特且关键的作用, 承担着不完全相同的功能任务^[13]. 3 层之间依次相连, 层层传递信息, 最终形成一个完整的跨区域归因模型.

第一层是本地因果树层. 每个区域利用本地数据训练因果树. 训练时采用“诚实”分裂策略, 一部分样本用于建立树的结构, 另一部分样本用于估计叶子节点的因果效应. 这样可以保证每个区域在本地得到较准确的因果效应估计. 该过程不需要交换原始数据, 只在区域内部完成.

本地因果树层构成模型的基础, 各区域借助本地惠农补贴数据训练因果树, 训练时采用“诚实”分裂策略, 该策略重点在于对训练集进行划分^[14]. 具体而言, 将一半样本用于构建因果树结构, 利用算法与准则确定节点分裂方式, 以最大化不同子节点间的处理效应差异, 从而精准划分特征空间; 另一半样本则用于叶子节点因果效应的估计, 其估计公式为

$$\hat{\tau}_m(l) = \bar{Y}_m^{T=1}(l) - \bar{Y}_m^{T=0}(l). \quad (5)$$

式中, $\bar{Y}_m^{T=1}(l)$ 表示区域 m 中因果树叶子节点 l , 处于干预组(即发生惠农补贴欺诈的样本组)的平均结果; $\bar{Y}_m^{T=0}(l)$ 则表示区域 m 中因果树叶子节点 l , 处于对照组(即未发生惠农补贴欺诈的样本组)的平均结果. 借助这种计算方法, 能够获得每个叶子节点上相对准确的因果效应估计值, 从而有效控制模型的复杂度, 避免过拟合现象, 进而增强模型在本地数据上的泛化能力.

第二层是异构数据融合层. 不同区域的数据分布和特征差异很大. 若直接对各区域本地因果树结果合并, 会受区域分布异构性干扰, 引入聚合偏差. 为此, 本模型引入对抗性域自适应方法(如 DANN), 使特征提取器学习到跨区域更稳定的表示. 各区域本地因果特征输出经对抗域自适应融合机制校正, 有效缩小跨域分布偏移.

第三层是全局归因层. 各客户端区域将校正后的模型参数与局部因果效应估计结果上传至中心服务器. 服务器对信息进行加权聚合, 得到全局因果森林. 该全局聚合模型可同时兼顾区域个性化特征与跨区域共性因果规律, 解决异构数据下全局建模失真问题. 最终, 全局归因模型可以在新的跨区域数据上进行推断, 并生成因果效应可视

化、特征重要性排序和风险热力图。

三层关系为“先局部学习,再统一融合,最后全局建模”。本地因果树层保证每个区域因果效应估计的准确性,异构数据融合层保证不同区域的信息能在共同的表示空间中对齐,减少区域差异。全局归因层在此基础上完成整合,形成可推广到各区域的模型。三层协同作用,使 HFCF 既能处理异构数据,又能保护隐私,还能给出跨区域的稳定归因结果。

1.2.2 异构数据融合机制

在异构联邦因果森林模型中,DANN 的损失函数旨在降低数据分布差异对模型效果的负面影响。常用的 DANN 损失函数可基于 Wasserstein GAN 损失进行设计。在 Wasserstein GAN 框架下,判别器(域分类器)力图最大化真实样本与生成样本之间的 Wasserstein 距离,而生成器(特征提取器)则致力于最小化这一距离。

对于 DANN 在本模型中的应用,其损失函数完整形式可以表示为

$$L_{adv} = E_{x \sim P_r} [D(x)] - E_{x \sim P_s} [D(x)] \quad (6)$$

式中, L_{adv} 为域分类对抗损失, E 表示期望, P_r 和 P_s 分别代表不同区域的数据分布(例如, P_r 可以是东部地区的数据分布, P_s 可以是西部地区的数据分布), $D(x)$ 是域分类器对样本 x 的输出(域分类器试图判断样本 x 来自哪个区域)。特征提取器通过优化损失函数,提取使域分类器难以辨识数据来源区域的特征,从而有效降低数据分布差异的影响。

1.3 模型训练与推断流程

异构联邦因果森林模型的训练与推断流程建立在严密的逻辑和有序的结构之上,通过充分利用区域数据,实现惠农补贴欺诈的跨区域归因分析。在本地训练阶段,各区域将数据划分为 8:2 的训练集和验证集,因果树采用“诚实”分裂策略生成,并经过验证集的调整与评估,最终输出相关分析结果^[15]。随后,将分裂特征重要性、因果树结构信息及 GATE 估计等核心参数加密上传至服务器。服务器依据各区域数据量与验证损失进行加权聚合,从而完成整个模型参数的更新。进入归因阶段,待分析数据被输入至全局森林模型,生成

因果效应的推断结果,特征重要性排序及区域风险热力图在归因报告中得以具体呈现,为监管部门提供了关注重点以及策略依据,同时也验证了模型的分析精度与推断前提的可靠性。模型训练与推断流程如图 1 所示。




图1 模型训练与推断流程

2 数据处理与实验设计

2.1 数据来源与预处理

2.1.1 多源异构数据集

本研究使用的数据来自 2018 年至 2023 年全国 31 个省市的惠农补贴信息,主要来源包括各省市农业农村厅和财政厅的公开数据,国家统计局和地方统计局的相关年度数据,以及部分由第三方调查机构开展的专项调查数据。为了保证数据全面性,研究团队还收集了部分地方政府网站和公开公报上的补贴信息。

数据采集采用全面统计为主、抽样调查为辅的组合方案。全面统计数据包括各省市在财政支农项目中记录的补贴发放明细,覆盖对象较全。抽样调查数据则主要用于校验、修正官方统计数据中存在的记录缺失与指标口径冲突问题。在数据完整性方面,大多数省市提供了较完整的补贴记录,但个别省市的部分年份存在缺失。对缺失数据,当缺失比例较低时,采用同类补贴在邻近地区或相邻年份的均值进行填补;当缺失比例较高时,利用多重特征插补方式生成补充样本,以减少数据不均衡和缺失带来的偏差。通过上述方法,保证了不同区域和不同年份的数据在整体上可用。

研究汇总形成了一个包含 31 个省市、时间跨度为 6 年的多源异构数据集,从多个维度对补贴

欺诈现象进行了深入剖析。基础信息涵盖补贴类型、金额及受益农户数量等;流程数据记录了申报审核步骤及公示渠道;主体特征则聚焦于村干部任期、学历、廉政记录,以及农户的教育水平和收入状况等;区域环境涉及当地 GDP、人口密度和交通便利性等因素。数据经过脱敏处理后,按省份划为 31 个联邦节点,不同地区欺诈类型各有侧重。其中,东部地区经济发达且产业多元,“产业补贴”欺诈偏多;中西部地区以农业为主,“粮食直补”和“危房改造”类欺诈尤为突出,如粮食直补虚

报面积产量、危房改造虚构项目等。这为后续分析提供了丰富且有针对性的数据依据。

图 2 呈现了 2018—2023 年各区域惠农补贴欺诈发生率的变化情况。从图中数据可以看出,东部、中部和西部地区的欺诈发生率整体呈下降趋势。其中,东部地区从 2018 年的 3.5% 降至 2023 年的 2.2%,中部地区从 4.0% 降至 2.8%,西部地区从 4.5% 降至 3.2%。这表明在研究期间,各区域在惠农补贴监管方面取得了一定成效,但不同区域仍存在差异。




图 2 2018—2023 年东部、中部和西部数据对比

2.1.2 特征工程与标签构建

本研究在特征选择时遵循 3 个标准:一是政策相关性,即特征要能反映补贴政策执行的关键环节,如补贴复杂度、公示透明度;二是数据可获得性,即指标可依托公开统计、实地调研数据稳定采集,如干部违规记录、农户教育水平;三是解释性,即特征与欺诈行为之间要有清楚的逻辑联系,例如贫困率可能影响农户对补贴的依赖程度,从而会影响欺诈风险。

本文在主体特征构建中重点选取基层干部的任期、学历、廉政记录,以及农户的教育水平与收入状况。主要基于 3 点:一是这些变量可直观体现监管干部履职约束、执行能力,以及农户虚假申领补贴的内在动机,且与腐败违规高度相关;二是数据来源稳定、统计可得性强,便于在跨区域联邦学习框架下开展可比建模;三是政策解释性明确,如任期较长且廉政记录较差可能扩大寻租空间,干部学历偏低可能影响政策理解与执行,而教育水平较低、收入中低的农户对补贴依赖更强,更易卷入或被动参与欺诈。

3 个标准是在系统梳理相关研究与政策文件的基础上,结合惠农补贴欺诈监管的实际应用需求归纳得出。其出发点在于,一方面保证所选特征紧扣惠农补贴政策执行链条,避免出现统计上显著但在政策层面难以解释的变量;另一方面,充分考虑跨区域联邦学习场景下的数据可得性与实际应用的可操作性,确保模型结果能够被监管部门理解并切实加以利用。所选特征与腐败、违规行为密切相关,能够刻画基层权力掌握与约束程度及农户的认知能力和经济压力,同时具有较好的数据可得性和政策解释性。

在方法上,首先通过文献回顾和政策文件分析,初步列出可能的特征集合。然后利用专家访谈筛选掉与补贴欺诈关系较弱或难以获得的数据项。最后在建模前,对各特征进行单变量相关性检验和特征重要性预评估,去掉冗余和噪声特征。这样得到政策、主体、环境 3 个维度的最终特征集。

标签分为二分类和回归两类。在二分类任务中,标记是否发生欺诈;在回归任务中,以损失程度为标签。对缺失值使用均值或邻近值填补;对不

平衡数据使用 SMOTE 方法生成新样本,使得数据分布更平衡。

2.2 实验设置与对比方法

2.2.1 评价指标

为了全面且准确地评估模型在惠农补贴欺诈归因分析中的性能,本研究采用了一系列具有针对性的评价指标,主要涉及分类性能、因果效应估计及归因解释等核心内容。评价指标的选取覆盖了对模型性能评估的多维度需求,可有效避免评估过程中的偏颇和不准确性。

分类性能评估包含 ACC、Precision、Recall 以及 AUC-ROC 曲线下面积等指标。ACC 用于描述模型正确预测样本数在总样本数中占的比例,其具体计算公式为

$$R_{\text{ACC}} = \frac{N_{\text{TP}} + N_{\text{TN}}}{N_{\text{TP}} + N_{\text{TN}} + N_{\text{FP}} + N_{\text{FN}}}, \quad (7)$$

式中,TP 为真正例,表示模型对欺诈样本的正确预测数;TN 为真反例,表示模型对非欺诈样本的正确预测数;FP 为假正例,代表模型错误地预测为欺诈的样本数;FN 为假反例,表示模型错误地预测为非欺诈的样本数。该指标用于评估模型的预测性能。

精确率则关注模型预测为欺诈的样本中,实际真正发生欺诈的样本比例,其计算公式为

$$R_{\text{precision}} = \frac{N_{\text{TP}}}{N_{\text{TP}} + N_{\text{FP}}}. \quad (8)$$

召回率衡量的是实际发生欺诈的样本中,被模型正确预测出来的比例,计算公式为

$$R_{\text{recall}} = \frac{N_{\text{TP}}}{N_{\text{TP}} + N_{\text{FN}}}. \quad (9)$$

AUC-ROC 曲线下面积可对分类模型的性能进行综合评估,且能够说明模型在不同阈值时的分类质量。当 AUC-ROC 接近 1 时,分类性能越好;值为 0.5 时,模型的预测等同随机猜测。

因果效应估计方面,模型准确性评估采用均方根误差与平均绝对误差。均方根误差可衡量预测因果效应和真实因果效应之间的平均误差,计算公式为

$$E_{\text{RMS}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{\tau}_i - \tau_i)^2}. \quad (10)$$

式中, $\hat{\tau}_i$ 表示模型预测的个体因果效应, τ_i 表示真实的个体因果效应, n 为样本数量。

MAE 则直接衡量模型预测的因果效应与真实因果效应之间的平均绝对误差,计算公式为

$$E_{\text{MAE}} = \frac{1}{n} \sum_{i=1}^n |\hat{\tau}_i - \tau_i|. \quad (11)$$

RMSE 和 MAE 的值越小,说明模型对因果效应的估计越准确,能够更精确地量化各因素与惠农补贴欺诈之间的因果关系。

2.2.2 对比模型选择

为验证异构联邦因果森林模型(HFCF)在惠农补贴欺诈跨区域归因分析中的性能,本研究选取了传统因果森林(CF)、联邦随机森林(FRF)、异构联邦逻辑回归(HFLR)、联邦梯度提升树(federated gradient boosting decision tree, FGBDT)和联邦支持向量机(federated support vector machine, FSVM)等多模型进行对比实验。CF 在高维数据处理上有优势,但难以整合异构数据,泛化能力和准确性易受影响;FRF 在隐私保护和数据整合方面有优势,但在因果效应评估和归因分析的深度及准确性方面不足;HFLR 擅长处理异构数据和区域差异,但在非线性关系复杂的任务中性能有限。FGBDT 通过迭代拟合残差提升性能,与 HFCF 的因果树构建和联邦学习架构不同,可从不同角度评估因果推断和跨区域数据处理能力。FSVM 扩展了 SVM 的功能,适应联邦学习框架,适合处理小样本和非线性分类问题,与 HFCF 对比可验证其在不同数据规模和特征复杂性下的优势。

2.2.3 实验平台与参数

本研究基于 Python 3.9 编程,采用 Scikit-learn 1.2 进行数据预处理和传统模型构建,TensorFlow Federated 0.30 实现联邦学习。硬件配置为 Intel i7-12700K 处理器、32GB RAM 内存和 NVIDIA RTX 3090 显卡,加速深度学习模型训练。模型训练参数设置如下:因果树深度为 5,避免过拟合并提升效率与解释性;森林树为 100,增强数据多样性、模型准确性与鲁棒性;联邦通信轮次为 50,平衡速度与时长;学习率为 0.01,保障收敛稳定性。为了保证实验结果的可靠性和稳定性,本

研究在每次模型训练时随机划分训练集和验证集,并对整个实验过程进行了 5 次独立重复.在每次重复实验中,保持数据划分随机但分布一致.最终结果取 5 次实验的平均值,同时计算标准差,以反映模型的稳定性和结果的波动情况.通过这种重复实验方式,可以避免单次实验因随机性带来的偏差,确保模型在不同划分下都有稳定表现.

图 3 展示了不同模型的训练时间对比.训练时间是评估模型计算效率的重要指标之一.从图中数据可知,HFCF 模型训练时间为 60 min,CF 模型为 40 min,FRF 模型为 50 min,HFLR 模型为 35 min.HFCF 的训练时间相对较长,但综合




图 3 不同模型训练时间对比

表 1 不同模型性能对比

模型	ACC	Precision	Recall	AUC-ROC	RMSE	MAE
HFCF	0.87	0.84	0.82	0.91	0.82	0.65
CF	0.80	0.78	0.70	0.82	1.02	0.81
FRF	0.82	0.79	0.73	0.84	1.02	0.80
HFLR	0.78	0.75	0.68	0.79	1.1	0.85

图 4 呈现了不同模型在各区域的精确率对比情况.




图 4 不同模型在各区域的精确率对比

精确率反映了模型预测为欺诈的样本中,实际真正发生欺诈的样本比例.通过该图可知,在东

考虑其在分类、回归任务以及跨区域泛化能力等方面的优越表现,在实际应用中,可根据资源配置和具体任务需求,权衡并选择最合适的模型.

3 结果与分析

3.1 模型性能对比

3.1.1 分类与回归效果

对惠农补贴欺诈的分类与回归任务评估实验结果如表 1 所列,HFCF 整体性能更优.具体在分类能力上,HFCF 的准确率(ACC)比 CF 提高了 7.2%,降低了误判率;AUC-ROC 指标提高了 8.9%,更好区分欺诈与非欺诈样本.与 FRF 和 HFLR 的对比中,HFCF 在 ACC 与 AUC-ROC 指标上表现领先,复杂数据与异构性处理能力更强.中西部数据稀疏区域中,HFCF 的召回率提高了 12.5%,对欺诈行为的识别更有效,避免了漏检现象.在回归任务下,HFCF 的 RMSE 达到 0.82,与 FRF 对比误差降低 19.6%,可以更精准地估计欺诈损失,为风险防控和损失评估提供支持,说明惠农补贴欺诈分析中 HFCF 优势显著.

部地区,HFCF 模型精确率达 0.86,高于 CF、FRF 和 HFLR 模型,这表明 HFCF 在东部地区对欺诈样本的精准识别能力更强;中部地区 HFCF 精确率为 0.83,同样领先于其他模型;西部地区 HFCF 精确率为 0.80,在该区域也具有相对优势.整体来看,HFCF 在各区域的精确率表现突出,有助于更准确地识别实际发生欺诈的样本.

图 5 展示了不同模型在除了中西部数据稀疏区域外其他区域的召回率对比.召回率衡量的是实际发生欺诈的样本中,被模型正确预测出来的比例.从图中数据可以看出,在东北部地区,HFCF 的召回率为 0.85,高于 CF 的 0.73、FRF 的 0.

76 和 HFLR 的 0.70;南部沿海地区,HFCF 召回率为 0.84,同样优于其他模型.这说明 HFCF 在不同区域都能较好地识别实际发生的欺诈样本,有效避免漏检现象,为惠农补贴欺诈监管提供更全面的保障.




图 5 不同模型在各区域的召回率对比

3.1.2 跨区域泛化能力

为深入评估模型的区域表现,进一步分析跨区域泛化能力,表 2 列出了不同模型的 AUC-ROC 指标.根据东部高资源、中部中等资源和西部低资源的区域特性结果,HFCF 模型在各区域的性能都保持了较强的泛化性,尤其是在西部低资源的区域优势进一步强化.通过区域表现的直观对比,更清晰地体现了 HFCF 性能特征的显著性.

表 2 不同模型在各区域的 AUC-ROC 表现

区域	HFCF	CF	FRF
东部	0.93	0.85	0.88
中部	0.9	0.83	0.86
西部	0.89	0.78	0.81

从表 2 可看出,在西部区域,HFCF 的 AUC-ROC 为 0.89,高于 CF 的 0.78 和 FRF 的 0.81,实验结果体现了 HFCF 异构数据处理机制的显著性和有效性.其分层联邦架构和异构数据融合机制,使得 HFCF 能够有效整合各区域数据信息,克服数据分布和特征空间差异带来的挑战,实现不同资源条件区域预测分析的准确执行.在东部高资源区域,HFCF 的 AUC-ROC 达到 0.93,尽管其他模型在该区域也较好,但 HFCF 依然保持领先地位,这表明其不仅在数据稀疏区域表现出

色,还能充分挖掘数据丰富的区域的数据价值,精准识别惠农补贴欺诈行为.在中部中等资源区域,HFCF 的 AUC-ROC 为 0.90,性能稳定且较高,优于其他对比模型.

3.2 归因结果分析

3.2.1 关键因果因素识别

特征重要性分析结果明确了影响惠农补贴欺诈行为的核心因果要素,如表 3 所列,“公示透明度”重要性最高,重要性得分为 0.32,与欺诈风险存在强相关性.当透明度降低时,欺诈风险随之上升,公示不充分可能使违规行为在暗箱中进行.“干部任期”得分达到 0.25,基层干部任期较长,虽可积累基层治理与政策执行经验,但长期固定的任职环境易形成固化利益圈层,提升权力寻租、为亲友违规申报补贴的舞弊风险.“补贴类型复杂度”得分为 0.21,补贴类型越复杂,所需专业知识越多,从而增加了被不当利用的操作空间.例如虚报面积、篡改产量等行为,研究结果为理解此类惠农补贴欺诈机制提供了依据和线索.

表 3 特征重要性分析结果

关键因果因素	重要性得分
公示透明度	0.32
干部任期	0.25
补贴类型复杂度	0.21

图 6 呈现了关键因果因素与不同补贴类型欺诈风险的相关性.从图中数据可知,在粮食直补方面,公示透明度与欺诈风险呈较强负相关(相关性系数为-0.75),即公示透明度越高,欺诈风险越低;干部任期和补贴类型复杂度与欺诈风险呈正相关,系数分别为 0.68 和 0.70.产业补贴和危房改造补贴也呈现出类似规律,但相关性程度略有差异.




图 6 特征重要性分析结果

图 7 展示了关键因果因素在不同数据量区域的重要性变化。在数据丰富区,公示透明度重要性得分最高,为 0.35。随着数据量减少,其得分在数据中等区降为 0.32,在数据稀疏区降为 0.28;干部任期和补贴类型复杂度也呈现类似趋势。这表明数据量会对因素重要性评估产生影响,在数据稀疏区域,关键因果因素对欺诈风险的影响可能相对减弱。了解这一变化规律,有助于在不同数据量情况下更准确地识别导致惠农补贴欺诈的关键因素。




图 7 关键因果因素在不同数据量区域的重要性变化

3.2.2 区域特有因素差异

在识别跨区域共性关键因素后,进一步探究各区域的特有因素差异,实验结果如图 8 所示。研究表明,惠农补贴欺诈行为在不同区域受到部分特有因素的显著影响,这些因素与特定环境、政策及社会经济状况密切相关。




图 8 不同区域特有的惠农补贴欺诈影响因素分析

从图 8 可看出,东部地区中“企业参与补贴审核”这一因素特征重要性为 0.18,对补贴欺诈风险存在显著负向影响。东部地区经济较为发达,具有更为完善的市场机制,为企业监督作用的发挥、补贴审核透明度和公正性的提升

奠定了基础,进而有效降低欺诈风险。企业具备专业化审核能力与成熟内控体系,审查补贴申请时可以发现潜在的欺诈行为。在惠农补贴审核时,一些企业利用大数据对补贴申请数据进行全面分析,能够精准识别各类虚假申报行为,筑牢补贴资金安全防线。中西部地区存在“贫困发生率”(重要性 0.15)与“交通便利性”(重要性 -0.12)两个与惠农补贴欺诈风险显著相关的因素。贫困发生率较高的地区对补贴依赖更强,部分农户、基层工作人员虚假申领补贴的动机更强。交通不便导致现场核查困难、信息传递滞后,监管成本上升,欺诈更易发生。以部分山区为例,监管人员年度实地核查次数有限,个别基层干部虚报种植面积以骗取直补的机会增加。

表 4 列出了区域特有因素与区域经济指标的关联情况。在东部地区,企业参与补贴审核与 GDP、人均收入和第二产业占比均呈正相关,表明随着经济发展和产业结构优化,企业参与补贴审核对降低欺诈风险的作用更显著。中西部地区,贫困发生率与各项经济指标呈负相关,交通便利性与经济指标呈正相关,这说明经济发展水平和交通条件与惠农补贴欺诈风险密切相关。

这些区域特有因素,为制定差异化的监管策略提供了重要依据。东部地区可强化企业参与补贴审核的机制建设,充分发挥企业专业优势与监督作用。而中西部地区可通过面向贫困群体开展惠农政策普法与诚信宣传,强化农户法律约束意识,同时加强交通基础设施建设,从而提高监管效果。

3.2.3 因果效应可视化

通过因果效应可视化方法,可以直观呈现各因素与惠农补贴欺诈风险之间的因果关系。以中部某省份为例,对“干部学历”与欺诈风险之间的条件平均因果效应进行估计并加以可视化。

表 5 的结果显示,在大专以下学历干部任职的区域,欺诈风险比大专及以上学历干部任职区域高出约 15% - 20%。进一步分析表明,干部学历与任期之间存在显著的交互效应。学历较低的干部在短期内任职时,其对欺诈风险的影响并不显著,因为此时仍处于适应和学习阶段。然而,随着任期延长,这类干部逐渐熟悉地方性资源网络,

表 4 区域特有因素差异

区域	特有因素	GDP 相关性	人均收入相关性	第二产业占比相关性
东部	企业参与补贴审核	0.65	0.70	0.68
中西部	贫困发生率	-0.70	-0.75	-0.60
中西部	交通便利性	0.72	0.78	0.75

并与特定利益群体形成更紧密的联系,在知识更新不足和管理漏洞的叠加作用下,欺诈风险显著上升.当任期超过 7 年时,学历较低干部所对应的欺诈风险水平比基准值高出约 20%.相对而言,本科及以上学历干部即便任期较长,仍能凭借较强的政策理解能力和专业知识维持风险稳定.

表 5 干部学历对欺诈风险的条件平均因果效应

干部学历	干部任期(年)	欺诈风险变化(与基准对比)	备注
大专以下	1-3	+15%	新任职干部,学历影响初显
大专以下	4-6	+18%	任期延长,学历影响增强
大专以下	7 年及以上	+20%	长期任职,学历影响显著
本科及以上	1-3	基准水平	学历较高,管理能力较强
本科及以上	4-6	基准水平	学历较高,管理能力稳定
本科及以上	7 年及以上	基准水平	学历较高,管理经验丰富

4 结语

本研究提出异构联邦因果森林模型(HF-CF),通过“本地因果树-异构数据融合-全局归因”的分层架构,在保护数据隐私的前提下实现了跨区域异构惠农补贴数据的因果归因分析.实验表明,HFCF 在分类与回归任务中均优于传统因果森林、联邦随机森林等对比模型,有效识别出公示透明度、干部任期等共性关键因素,以及东部地区企业参与审核、中西部地区贫困发生率与交通便利性等区域特有因素.然而,模型仍存在训练成本较高、极端数据稀疏场景下性能衰减及官方数据潜在采集误差等局限.未来可通过引入高效联邦优化策略降低计算开销,结合图神经网络与深度因果推断方法增强复杂关系刻画能力,并融合遥感影像与移动支付等多源数据,进一步提升欺诈风险识别的精准性与鲁棒性.

参考文献:

[1] 俞浩,范菁,孙伊航,等.边缘异构下的联邦分割学习优化方法[J].计算机应用,2026,46(1):33-42.
[2] 李功丽,刘芳芳,雷宏志,等.面向异构数据的安全自适应联邦学习框架[J].计算机应用研究,2025,42

(5):1523-1531.
[3] 张铭泉,贾圆圆,张荣华.数字孪生中混合知识蒸馏辅助的异构联邦类增量学习[J].智能系统学报,2025,20(4):905-915.
[4] 徐茹枝,仝雨蒙,戴理朋.基于异构数据的联邦学习自适应差分隐私方法研究[J].信息安全,2025,25(1):63-77.
[5] 俞浩,范菁,孙伊航.异构联邦学习在无人系统中的研究综述[J].计算机应用研究,2025,42(3):641-649.
[6] Baumann M. Improving a Rule-based Fraud Detection System with Classification Based on Association Rule Mining[C]//Die 51.Jahrestagung der Gesellschaft fur Informatikin,INFORMATIK 2021-51st Annual Conference of the German Informatics Society,INFORMATIK 2021.
[7] Wager S,Athey S.Estimation and inference of heterogeneous treatment effects using random forests[J].Journal of the American Statistical Association,2018,113(523):1228-1242.
[8] Kairouz P,Mcmahan H B,Avent B,et al.Advances and open problems in federated learning[J].Foundations and Trends ® in Machine Learning,2021,14(1):1-210.
[9] Pei J M,Liu W X,Li J H,et al.A review of federated learning methods in heterogeneous scenarios[J].IEEE

- Transactions on Consumer Electronics, 2024, 70(3): 1.
- [10] 刘乐, 武淑红, 于丹, 等. 基于异构设备的自适应分配编码器的联邦学习[J]. 计算机工程与设计, 2024, 45(9): 2569-2576.
- [11] 罗宇哲, 李玲, 侯朋朋, 等. 面向 AIoT 的协同智能综述[J]. 计算机研究与发展, 2025, 62(1): 179-206.
- [12] 洪宝惜. 分布式区块链架构下基于信息授权机制的用户身份认证研究[J]. 兰州文理学院学报(自然科学版), 2025, 39(5): 46-51.
- [13] 史洪玮, 洪道诚, 施连敏, 等. 异构编码联邦学习[J]. 华东师范大学学报(自然科学版), 2023, 2023(5): 110.
- [14] 周天阳, 杨磊. 基于 Edge-TB 的联邦学习中客户端选择策略和数据集划分研究[J]. 计算机科学, 2024, 51(S1): 626-631.
- [15] 余健军, 陆育. 基于图像处理的换热器换热铜管尺寸测量研究[J]. 兰州文理学院学报(自然科学版), 2024, 38(1): 55-58.

[编辑: 陈满丽]

(上接第 45 页)

- [2] 林之钊, 黄惠. 从单幅图像生成人物三维动画[J]. 计算机辅助设计与图形学学报, 2022, 34(9): 1341-1350.
- [3] 沈洁, 张阳. 基于 K-means 算法的动画单帧图像颜色 PS 校正方法[J]. 兰州文理学院学报(自然科学版), 2023, 37(2): 45-48, 66.
- [4] 肖志良, 李中华. 基于 SMPL 可变模型和单幅图像的动画三维重建方法[J]. 计算机应用与软件, 2023, 40(10): 228-234.
- [5] 彭明程, 陈宗仁. 基于增强感知 GAN 模型的破损数字图像重构研究[J]. 兰州文理学院学报(自然科学版), 2025, 39(3): 53-58.
- [6] 葛鹏, 游耀堂. 基于稀疏表示的光场图像超分辨率重建[J]. 激光与光电子学进展, 2022, 59(2): 94-100.
- [7] 周浦城, 张杰, 薛模根, 等. 基于卷积分析稀疏表示和相位一致性的低照度图像增强[J]. 电子学报, 2020, 48(1): 180-188.
- [8] 余晖, 胡凌燕. 基于牛顿迭代算法的分形图像纹理细节增强[J]. 计算机仿真, 2021, 38(2): 263-266.
- [9] 张雅荔, 丁少博, 李昌禄, 等. 基于同态频分聚合的低照度图像增强算法[J]. 激光与光电子学进展, 2023, 60(14): 93-102.
- [10] 杨勇, 李露奕, 黄淑英, 等. 自适应字典学习的卷积稀疏表示遥感图像融合[J]. 信号处理, 2020, 36(1): 125-138.
- [11] 杨雪, 李峰, 鹿明, 等. 混合稀疏表示模型的超分辨率重建[J]. 遥感学报, 2022, 26(8): 1685-1697.
- [12] 刘亮, 蔡泽民, 赖剑煌. 一种基于物理光流与细节增强的湍流图像恢复方法[J]. 郑州大学学报(理学版), 2021, 53(1): 47-53.
- [13] 杨静. 基于二维视图的三维人脸重建设计[J]. 黑龙江工业学院学报(综合版), 2024, 24(4): 66-72.
- [14] 王冠, 来思渊. 改进稀疏表示优化旅游地标图像重建算法[J]. 佳木斯大学学报(自然科学版), 2025, 43(7): 140-143.
- [15] 刘昱, 陈永祺, 王瀚, 等. 基于通道协同与色彩校正的 RAW 数据到 RGB 图像重建方法[J]. 天津大学学报(自然科学与工程技术版), 2025, 58(4): 395-405.

[编辑: 李 岚]