

DOI:10.16644/j.cnki.cn33-1094/tp.2026.04.018

融合因果推断与SHAP的学业成绩影响因素研究

徐恕贞¹, 王延铭²

(1. 郑州科技学院信息工程学院, 河南 郑州 450064; 2. 郑州科技学院机械工程学院)

摘要: 教育大数据背景下, 丰富课堂行为数据为学业成绩研究提供充足数据源, 但传统模型难以揭示二者间因果关联。本文提出融合因果推断与可解释人工智能的分析方法, 该方法基于Bronfenbrenner's生态系统理论指定先验协变量, 通过因果森林估计“高举手频率”对成绩等级的平均处理效应(ATE), 并结合XGBoost与SHAP值识别行为投入度高但成绩未达预期的“高潜力低激活”学生, 进而基于个体处理效应(ITE)生成个性化干预建议。实验结果表明, 将课堂举手频率提升至群体均值以上, 可使成绩等级平均提高0.772, 该方法证实了课堂主动参与的稳健显著因果效应, 为差异化、精准化教育干预提供科学依据。

关键词: 生态系统理论; 处理效应; 教育干预; 因果森林

中图分类号: TP391.9

文献标识码: A

文章编号: 1006-8228(2026)04-96-05

Study on the Influencing Factors of Academic Achievement by Fusing Causal Inference and SHAP

Xu Shuzhen¹, Wang Yanming²

(1. Department of Information Engineering, Zhengzhou University of Science and Technology, Zhengzhou, Henan 450064, China;

2. Department of Mechanical Engineering, Zhengzhou University of Science and Technology)

Abstract: In the context of educational big data, rich classroom behavioral data provide an abundant source for academic performance research; however, traditional models struggle to uncover the causal relationship between classroom behavior and academic achievement. This paper proposes an analytical approach that integrates causal inference with explainable artificial intelligence. Guided by Bronfenbrenner's ecosystem theory, the method specifies prior covariates and estimates the average treatment effect (ATE) of "high hand-raising frequency" on grade levels using causal forests. It further combines XGBoost with SHAP values to identify "high-potential but low-activation" students—those who demonstrate high behavioral engagement yet underperform academically—and generate personalized intervention recommendations based on individual treatment effects (ITE). Experimental results show that classroom hand-raising frequency above the group mean can increase grade levels by an average of 0.772. The approach confirms the significant and robust causal effect of active classroom participation and provides a scientific foundation for differentiated and precision-based educational interventions.

Keywords: Ecosystem Theory; Treatment Effect; Educational Intervention; Causal Forest

0 引言

近年来,随着教育信息化的深入推进,智慧教室与在线学习平台广泛应用,课堂行为数据,如举手次数(Raised Hands)、资源访问(Visited Resources)、公告查看(Announcements View)和论坛参与度(Discussion)等被持续、系统地记录^[1]。这些多维度、细粒度的行为日志为学业表现分析提供了丰富的数据基础,也推动

教育研究从经验判断向数据驱动转型。在此背景下,如何有效利用行为数据实现精准预测与科学干预,已成为智能教育领域的核心议题。

现有研究主要依托机器学习技术开展学业成绩预测。XGBoost、随机森林、LSTM等模型在多项实证研究中展现出良好性能,准确率普遍较高。然而,此类方法聚焦于变量间的统计关联,难以揭示行为干预

收稿日期: 2026-02-05

作者简介: 徐恕贞(1990—), 女, 河南南阳人, 硕士, 助教, 主要研究方向: 数据挖掘、教育信息化。

与学业结果之间的因果机制。尽管部分学者尝试引入倾向得分匹配(P propensity Score Matching, PSM)、工具变量等传统因果推断方法评估教育政策效果,但其对线性关系和低维协变量的依赖,限制了该方法在高维、非线性教育场景中的适用性。同时,可解释人工智能如 SHAP(Shapley Additive exPlanations)虽被用于特征重要性分析,却常被误读为因果效应指标^[2]。

当前研究存在明显局限:一是混淆预测相关性与因果效应,忽视混杂变量对因果识别的干扰;二是缺乏将异质性因果效应估计与个性化干预策略生成相衔接的系统框架^[3]。尤其在多层级教育生态中,如何合理构建满足无混杂性假设的协变量体系,仍是方法论上的薄弱环节。

为此,本文提出融合因果推断与可解释 AI 的三阶段分析框架:首先基于 Bronfenbrenner's 生态系统理论界定个体、家庭、学校等多层次协变量;其次采用因果森林(Causal Forest)^[4]估计“高举手频率”对成绩等级的平均处理效应(Average Treatment Effect, ATE)与个体处理效应(Individual Treatment Effect, ITE);最后结合 XGBoost 与 SHAP 值,识别行为投入高但成绩未达预期的学生群体,并基于 ITE 生成针对性干预建议。

1 相关工作

1.1 学生成绩预测模型

早期研究多采用线性回归、逻辑回归、决策树等可解释模型。随着计算能力提升,集成学习方法因其稳定的效果逐渐成为主流。其中,随机森林在多数教育数据集上表现稳健^[5]。近年来, XGBoost 因其正则化机制与高效训练速度,被广泛用于成绩预测。然而,这些模型本质上是“黑箱”,其内部权重难以映射到教育实践中。

1.2 可解释性方法

为提升模型可信度,研究者开始引入 LIME、SHAP 等局部解释方法。例如, Lundberg S M 等^[6]使用 SHAP 分析在线学习行为对 MOOC(Massive Open Online Courses, 大规模开放在线课程)完成率的影响,发现视频观看时长是最关键特征。但该研究未考虑变量间的因果结构,可能将中介变量(如作业提交)误判为根本原因。更重要的是, SHAP 无法区分可干预变量(如举手次数)与不可干预变量(如性别),限制了其在政策制定中的应用。

1.3 因果推断

因果推断在教育领域的应用主要集中在政策评估。例如,张伟平等^[7]利用工具变量法评估小班教学的效果;国内学者李明^[8]采用 PSM 分析“课后服务”对农村学生成绩的影响。然而,这些方法通常假设线性效应或低维协变量,难以适应现代教育数据的高维非线性特性。

Causal Forest 作为广义随机森林的扩展,能自动学习处理效应的异质性,适用于高维混杂场景。研究者将其应用于美国就业培训项目评估,发现个体收益差异巨大。在教育领域, Kotsiantis S B 等^[9]首次尝试采用 Causal Forest 分析在线学习行为,但未结合可解释性技术,也未生成具体干预建议。

综上,现有研究存在两大缺口:①因果推断与可解释性分析相互割裂;②缺少从效应估计到干预落地的闭环。本文正是针对这些缺口展开工作。

2 研究方法

2.1 协变量选择

为满足无混杂性假设,即 $(Y(1), Y(0)) \perp T | X$, 必须确保所选协变量(X)能够阻断所有从处理变量(T)到结果变量(Y)的后门路径。在教育场景中,这一任务高度依赖领域知识。

本文基于 Bronfenbrenner's 生态系统理论^[10], 将影响学生学业表现的因素划分为四个层次:个体层、家庭层、学校层、社会文化层。据此预先指定了以下 8 个先验协变量:

个体层:性别(Gender)——影响学习风格与课堂参与意愿;

社会文化层:国籍(Nationality)、出生地(Place of Birth)——反映语言背景、文化资本与地域教育资源差异;

课程层:学科主题(Topic)、教育阶段(StageID)——决定认知负荷与兴趣匹配度;

家庭层:家长关系(Relation)——衡量家庭情感支持质量;

学校层:班级编号(SectionID)、学期(Semester)——控制教师效应、同伴氛围与教学进度差异。

所有变量均在课堂行为发生前已确定,满足“先验性”要求。排除家长是否完成调研(ParentAnsweringSurvey)、学生缺勤天数(StudentAbsenceDays)、互

动次数(Discussion)等变量,因其可能位于因果路径上(如成绩好→更愿参与调查),控制它们将导致过度调整偏误。

2.2 因果效应估计模型

本文采用Causal Forest估计平均处理效应(ATE)。该方法属于广义随机森林(Generalized Random Forest)家族,专为处理效应估计设计。其基本思想是:在每棵决策树的叶节点中,通过局部加权回归拟合处理效应,再通过加权平均得到全局估计。模型设定如下:结果变量成绩 Y : ClassM_num($L = 0, M = 1, H = 2$),视为有序连续变量;处理变量举手次数 T : raisedhands_binary(举手次数>样本均值时设置为1,否则为0);协变量 X :上述8个变量;因果模型参数如表1所示。

表1 因果模型参数

参数名	参数物理意义	参数值
n_estimators	决策树数量	100
max_depth	树的最大深度	6
min_samples_leaf	叶子节点至少包含样本数	10
min_var_fraction_leaf	叶节点中,处理变量 T 的方差占总体最大方差比例	0.01

2.3 基于SHAP与ITE的个性化干预生成

为实现从数据洞察到教育行动的转化,本文构建“潜力识别—效益评估—精准干预”的决策流程:首先利用XGBoost与SHAP识别高潜力学生,再基于因果森林估计的ITE量化干预收益,最终生成个性化建议。

XGBoost+SHAP:训练多分类器预测ClassM,计算TreeSHAP值,反映各特征对模型输出的边际贡献(预测重要性);因果森林(Causal Forest)特征重要性如图1所示,提取内置的特征重要性,反映各协变量对个体处理效应异质性的解释力(因果异质性驱动重要性)。

最后,基于ITE排序,对比识别“高潜力低激活”学生群体——即具备良好背景条件(如高年级、理科、积极家庭关系)但当前举手频率低于均值的学生,作为优先干预对象。二者协同的底层数据逻辑在于,尽管目标不同,但共享了变量的特征空间,且通过双重视角互补实现精确定位:SHAP揭示“为什么学生有潜力”;ITE揭示“干预措施对该学生可以提高多少”。

高潜力:SHAP分析具备正向潜力特征,且XGBoost预测结果 ≥ 1 ;低激活:当前举手次数低于样本均值;同时具备以上两个特征的学生,其干预预期收益最大,应作为优先干预对象。




图1 因果森林中的特征重要性

3 实验结果

3.1 数据预处理

本研究的数据集来源于Middle School Student Performance Dataset,包含480名学生样本记录。每一条记录包含17个维度,分别为性别、国籍、出生地、教育阶段、年级、班级、课程主题、学期、与家长关系、举手次数、访问资源次数、查看公告次数、互动次数、家长是否完成调研问卷、家长对学校满意度、学生缺勤天数、成绩。其中性别、国籍、出生地、教育阶段、年级、班级、课程主题、学期为类别特征,采用One-Hot编码进行处理。数据中缺失值与空白值采用删除或填充的方式处理,数值类缺失值采用平均值填充;对于类别型特征的缺失值,首先将其统一编码为一个显式的“缺失”类别(如“MISSING”)。

本文后续的模型在训练过程中,进行两个阶段划分:首先是训练集加上验证集之和与测试集比例为8:2;其次对训练集和验证集之和进行划分,训练集和验证集比例是7:1;最终整体比例为训练集:验证集:测试集=7:1:2。

3.2 平均处理效应估计

本文采用因果森林估计高举手行为对成绩的影响,并给出了全部特征的重要性,具体结果如下:平均处理效应ATE:0.7724 ± 0.0109,95%置信区间:[0.7616, 0.7833],证明该结果具有稳健性,数值均大于指标的随机波动范围。这意味着,若促使一名学生增加举手行为,其成绩等级预期提升近0.772个单位(满分为2分),效果稳健且具有实际教育价值。进一步

地,特征重要性分析显示,性别、学科类型是驱动处理效应异质性的两大关键因素。




图2 不同性别的平均处理效应

图2中X轴代表性别组,M代表男生、F代表女生;Y轴代表平均处理效应ATE。在性别层面,男生的ATE达到0.84,且置信区间明显高于0、不包含0,结果显著;女生ATE为0.65,同样结果显著。两个组的ATE都大于0,说明无论男女,高举手行为均能提升成绩,同时表明不同性别在课堂参与的效益上存在系统性差异。




图3 不同学科的平均处理效应

图3中X轴代表学科,包括阿拉伯语、西班牙语、生物学、数学、古兰经、英语、信息技术、化学、科学、法语、历史、地质学。

语、历史、地质学学科;Y轴代表对应的平均处理效应。语言与科学类课程(如阿拉伯语、数学、生物学)中的ATE大于0.85显著高于全局水平;数学、生物、化学等学科ATE在0.73~0.80之间,略低于语言类,但仍远高于0。而历史与地质学等记忆型科目的ATE则较低,以上指标置信区间不包含0,这表明课堂参与对学业表现的影响存在明显的学科异质性。

上述结果表明,“高举手→成绩”的因果路径并非普适,而是高度依赖个体背景与情境条件。因此,未来的教育干预应超越“全员鼓励发言”的单一模式,转向基于学生画像的精准化支持策略,尤其应关注记忆型学科中课堂参与效应较低的学生及具备高潜力的女生群体,为其创造安全、包容的表达环境。

3.3 SHAP 特征重要性

基于XGBoost模型SHAP值计算的各特征对分类结果的贡献程度,如图4所示,其中横轴X表示特征的重要性分数(即平均绝对SHAP值),纵轴Y为特征名称,条形图按不同成绩类别(低:0、中:1、高:2)划分其影响分布。结果显示,学生出勤天数是最具影响力的特征,其对所有类别的预测均具有显著作用,表明出勤天数是判断学生成绩等级的核心指标。其次,“观看资源次数”和“举手次数”也表现出较高的重要性,反映出学生的学习投入度与课堂参与行为在模型决策中的关键地位。




图4 SHAP特征重要性

此外,公告查看频次和论坛讨论参与度等线上交互式学习行为同样具有较强解释力,说明在线平台上的信息获取与讨论活跃度对成绩预测有正向促进作用。相比之下,性别、学期、班级编号等背景变量的影响较弱,表明该模型主要依赖于学生的行为数据而非人口统计学特征进行分类。

综上所述,本模型不仅实现了高精度的学业成绩预测,更通过 SHAP 解释揭示了其内在逻辑:成绩差异主要由学习行为驱动,而非静态属性。这一发现为教育干预提供了明确方向。这些行为变量不仅主导成绩预测,更可作为识别‘高潜力低激活’学生的关键依据,同时为后续基于 ITE 的精准干预提供候选群体。

3.4 基于 SHAP 与 ITE 的高潜力学生协同识别

为实现从数据洞察到教育行动的有效转化,本文融合可解释人工智能与因果推断,构建“潜力识别—效益评估—精准干预”的决策链条。

首先, XGBoost 模型结合 SHAP 值用于识别行为投入高但学业成绩未达预期的学生群体。如图 4 所示,缺勤天数、访问资源次数等行为变量对成绩预测贡献显著,表明模型能够有效捕捉学习投入与成绩之间的关联模式。基于此,筛选出在关键行为维度(如低缺勤、高资源使用)表现优异,但实际成绩偏低的学生——即具备高学业潜力但尚未充分兑现的个体。

其次,因果森林在控制 Bronfenbrenner's 理论指导下的先验协变量后,估计了“提升举手频率”对每位学生的个体处理效应(ITE)。结果显示,干预效果存在显著异质性:男生(ATE = 0.84)较女生(ATE = 0.65)获益更大;语言类与理科课程中的效应普遍高于历史、地质学等记忆型科目。这表明,举手行为的因果价值高度依赖于学生的背景特征与学科情境。

综合上述分析,本文将“高潜力低激活”学生定义为:行为投入水平高、背景条件有利(如男生、理科生、家庭关系良好),但当前举手频率低于群体均值,且 ITE 显著为正的学生。这类学生并非缺乏能力或努力程度不够,而是因课堂参与不足,导致自身潜力未能转化为成绩。针对这类学生提供鼓励性发言机会,预期可带来最大成绩边际提升。

综上, SHAP 分析用于定位高潜力学生,因果森林用于量化干预收益,二者协同实现了从“谁值得干预”到“干预能带来多大成绩提升”的完整科学决策,为精准化教育支持提供了可操作路径。

4 结束语

本文提出一种融合可解释人工智能与因果推断的分析框架:利用 XGBoost 与 SHAP 识别行为投入高但成绩未达预期的“高潜力低激活”学生,再基于因果森林估计的 ITE 生成个性化干预建议。该方法超越了

传统相关性建模的局限,也避免了单一因果效应估计缺乏个体适配性的不足,从而真正实现了从“因果发现”到“精准行动”的闭环。

本研究证明,在教育数据科学中,领域知识引导的因果建模与可解释 AI 的深度融合,能够生成更具可操作性、可干预性与可推广性的教育策略。未来工作将探索多行为联合干预的因果机制,并将本框架拓展至在线学习、职业教育等更广泛的教育场景。

参考文献(References):

- [1] 邢子昊,刘小英. 计算机专业学习交流平台的设计与实现[J]. 福建电脑,2026,42(1):68-73.
- [2] ZHANG Y, WANG F, SONG S. Interpretable machine learning for academic performance prediction: A SHAP-based analysis of key influencing factors[J]. Innovations in Education and Teaching International, 2025,62(6):1-20.
- [3] WANG Q, DUAN R. LSTM-based early warning system for student performance[J]. Computers & Education, 2020,145:103734.
- [4] 刘智锋,罗鹏程,唐星龙,等. 科学数据开放程度对数据复用的影响研究——基于因果森林的实证[J/OL]. 情报科学,2025: 1-27[2026-01-16]. <https://link.cnki.net/urlid/22.1264.G2.20251223.0822.002>.
- [5] 万美希,蒋墨冰,吕品,等. 生成式人工智能对大学生学业表现的影响——基于广义随机森林模型的异质性处理效应[J]. 浙江理工大学学报(社会科学版),2025,54(6):766-778.
- [6] LUNDBERG S M, LEE S I. A unified approach to interpreting model predictions[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach, CA, USA: Curran Associates Inc.,2017:4765-4774.
- [7] 张伟平,付卫东,李伟,等. 中小学课后服务能促进教育公平吗——基于东中西部6省(自治区)32个县(区)调查数据的分析[J]. 中国电化教育,2021(11):16-23.
- [8] 李明. 基于 PSM 的课后服务政策评估[J]. 教育研究,2022(5): 45-53.
- [9] KOTSIANTIS S B, PIERRAKEAS C. Predicting students' performance in distance learning using machine learning techniques[J]. Expert Systems,2023,20(2):73-82.
- [10] KRÜGER J G C, BRITTO JR A S. An explainable machine learning approach for student dropout prediction[J]. Expert Systems with Applications, 2023, 233:120933. 