



烟草科技
Tobacco Science & Technology
ISSN 1002-0861,CN 41-1137/TS

《烟草科技》网络首发论文

题目：基于零售终端数据治理的卷烟市场状态监测研究
作者：姜思明，刘荣，谭升达，郭航宇，许谨致，谢鸿，蔡颖嘉，黄淇
网络首发日期：2026-04-22
引用格式：姜思明，刘荣，谭升达，郭航宇，许谨致，谢鸿，蔡颖嘉，黄淇. 基于零售终端数据治理的卷烟市场状态监测研究[J/OL]. 烟草科技.
<https://link.cnki.net/urlid/41.1137.ts.20260421.1557.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于零售终端数据治理的卷烟市场状态监测研究

姜思明^{*1}, 刘 荣², 谭升达³, 郭航宇², 许谨致², 谢 鸿², 蔡颖嘉², 黄 淇²

1. 广东烟草茂名市有限责任公司, 茂名市茂南区官山七路 1 号 525000;

2. 中国烟草总公司广东省公司, 广州市天河区林和东路 128 号 510610;

3. 广东烟草阳江市有限责任公司, 阳江市江城区西平北路 363 号 529500

摘要: 针对卷烟零售终端数据普遍存在的质量参差、扫码数据失真及库存虚报等问题, 导致市场状态评估精准度不足的现状, 提出了一套基于零售终端数据治理的卷烟市场状态监测方法, 构建了“数据治理—状态评估”的一体化分析框架。在数据治理阶段, 首先采用聚类分析剔除显著异常终端; 随后基于最大经验似然密度方法对指标得分进行标准化处理; 进而引入潜在因子模型 (Latent Factor Model, LFM) 对零售终端的数据质量进行综合评价, 从而甄选出高质量的零售终端样本。在状态评估阶段, 基于筛选出的高质量终端构建包含订足面、订足率、动销率、毛利率及可销天数等维度的市场状态指标体系; 对品规数据进行预处理并计算综合得分后, 利用高斯混合模型 (Gaussian Mixture Model, GMM) 定量划分市场状态阈值, 将各品规映射至“俏、紧、平、松、软”五级市场状态。实证分析表明, 该方法能够有效提升监测结果的准确性, 与实际市场行情高度契合, 可为卷烟市场精准投放策略的制定提供科学依据。

关键词: 零售终端数据治理; 市场状态监测; 聚类分析; 潜在因子模型; 高斯混合模型

中图分类号: TS43

文献标志码: A

文章编号: 1002-0861 (2026) 10-xxxx-xx

Cigarette market state monitoring based on retail terminal data governance

JIANG Siming^{*1}, LIU Rong², TAN Shengda³, GUO Hangyu², XU Jinzhi², XIE Hong²,
CAI Yingjia², HUANG Qi²

1. Maoming Branch of Guangdong Provincial Tobacco Co., Ltd., Maoming 525000, Guangdong, China

2. Guangdong Provincial Tobacco Company of CNTC, Guangzhou 510610, China

基金项目: 广东省烟草专卖局 (公司) 科技项目“卷烟市场容量与社会库存测算模式的研究” (粤烟科项 202208); 广东烟草阳江市有限责任公司科技项目“卷烟市场现代终端数据采集质量提升研究与应用” (阳烟科项 202301)。

第一作者: 姜思明 (1985—), 女, 硕士研究生, 从事营销大数据、人工智能研究。E-mail: jiangsiming@163.com
引用本文: 姜思明, 刘荣, 谭升达, 等. 基于零售终端数据治理的卷烟市场状态监测研究[J]. 烟草科技. DOI: 10.16135/j.issn1002-0861.2025.0510. (JIANG Siming, LIU Rong, TAN Shengda, et al. Cigarette market state monitoring based on retail terminal data governance [J]. Tobacco Science & Technology. DOI: 10.16135/j.issn1002-0861.2025.0510)

3. Yangjiang Branch of Guangdong Provincial Tobacco Co., Ltd., Yangjiang 529500, Guangdong, China

Abstract: A set of monitoring methods for domestic cigarette market state based on retail terminal data governance was proposed to address the common problems of uneven quality, distorted QR code data and false inventory reporting in cigarette retail terminal data, which led to insufficient accuracy in the market state assessment. Cigarette market state monitoring methods based on retail terminal data governance were proposed and an integrated analysis framework of “data governance-state assessment” was built. At the data governance stage, firstly, cluster analysis was used to remove significantly abnormal terminals. Secondly, the maximum empirical likelihood density method was used to standardize the index scores. Thirdly, a latent factor model (LFM) was introduced to conduct a comprehensive evaluation on the data quality of retail terminals to select high-quality retail terminal samples. At the state evaluation stage, based on the selected high-quality terminals, a market state index system integrating dimensions of order sufficiency coverages, order sufficiency rates, gross profit margins, and salable days was constructed. After preprocessing the product specification data and calculating the composite scores, a Gaussian mixture model (GMM) was used to quantitatively divided the market state thresholds, and each product specification was mapped into five market status levels of “hot, tight, balanced, loose, and weak”. The empirical analysis showed that this method effectively improved the accuracy of monitoring results and was highly consistent with the actual market conditions, providing a scientific basis for the formulation of precise cigarette marketing strategies.

Keywords: Retail terminal data governance; Market state monitoring; Clustering analysis; Latent factor model; Gaussian mixture model

卷烟营销网络是烟草商业企业最重要的经营基础之一，随着行业“互联网+”与信息化工程推进，零售终端在订购、动销、价格、库存等环节产生的过程数据持续汇聚，为市场研判与精准投放提供了数据条件^[1]。卷烟市场状态监测是连接“市场洞察—资源配置—投放策略”的关键环节^[2]，其目标是对一定周期内的市场进行供需量化分析，将不同品规卷烟的销售表现映射为“俏、紧、平、松、软”等市场状态，用于指导投放节奏、扩点扩面与结构优化等下游决策。在实践中，市场状态监测多采用抽样调查路径^[3]，一般包括样本框构建与样本量确定、抽样清单下发与终端数据采集、数据校验与异常识别、加权估计市场状态得分与结果汇总输出等环节。该流程的有效性高度依赖终端数据的真实性与一致性。但受制于采集设备与口径不统一、采集规范执行不到位以及个别零售门店数据造假等因素，终端层面易出现扫码失真、库存虚报、异常跳变与缺失等问题^[4]。这些问题具有“隐蔽性强、分布异质、对结果传导放大”的特点：一旦异常数据进入综合评价与阈值分级环节，便可能造成状态误判，进而影响投放决策的准确性与稳定性。

现有卷烟市场状态监测研究总体形成了“指标体系构建—综合评价得分—阈值映射分级”


的技术路线。在指标体系方面，董秉坤等围绕国产卷烟新品构建市场状态评价体系，强调从供需匹配与市场表现出发设置可量化指标，为新品状态研判提供了较系统的框架^[5]。在综合评价方面，张小玲等以多指标综合评价为核心，采用加权聚合/关联分析等方法将多维指标压缩为综合得分，实现对品规状态的排序与对比^[6]。在应用衔接方面，王雄峰将市场状态评价结果与企业投放策略相衔接，构建产品投放模型并提出策略建议，体现出“状态监测—投放决策”联动的实践导向^[7]。除传统指标体系外，林珍冷从“流动价差—需求指数”等角度引入量化信号，以增强对需求波动、价格传导与异常流动情形的解释能力^[8]；杨蕾结合产品生命周期与四象限分析方法讨论状态识别与阶段特征，提示市场状态识别应与阶段演化相匹配，而非静态一次性判别^[9]。在阈值确定与自动化分级方面，研究从经验分段逐步走向统计规则与智能训练。传统做法多依赖等距、分位数或中位数等经验分组，将综合得分映射为“俏、紧、平、松、软”。为增强阈值的统计依据，许飞提出基于正态分布 3σ 原则的阈值确定优化方法，并强调不同区域、不同指标应采用差异化阈值以避免“一刀切”^[10]。进一步地，黄敏提出“智能集成与阈值训练”思路，通过聚类/训练实现阈值区间自动生成，并可按价位段等分层输出阈值表，从而提升落地效率与可操作性^[11]。

然而，现有工作在终端数据应用于状态监测时仍普遍存在三方面不足：（1）数据真实性常被默认成立，异常处理多停留在箱线图、简单剔除或事后修正，难以抑制扫码失真、库存虚报等引发的系统性偏差，导致综合得分与阈值映射的稳定性不足；（2）权重与阈值对经验或隐含分布假设依赖较强，在数据分布形态复杂、偏态厚尾或样本不足情形下鲁棒性与可迁移性受限；（3）“数据质量控制”与“状态评估”往往割裂，缺少以数据治理为前置、以高质量终端样本为基础的闭环机制，导致“用低质数据做精细研判”的矛盾难以根本缓解。

为此，提出一套基于零售终端数据治理的卷烟市场状态监测方法，构建了“数据治理—状态评估”的两步分析框架。本研究将终端数据治理定义为“对终端层数据的异常、失真与虚报等质量风险进行识别、抑制与筛选，形成可用于统计推断的高质量样本集合”；将市场状态定义为“品规在给定周期内由订购、动销、利润与库存等可观测指标共同反映的供需强弱与销售活跃程度”。在数据治理阶段，首先以治理相关指标刻画终端相似性，采用 K-means++ 聚类分析方法^[12]对终端进行分群，剔除显著异常终端；随后对指标得分采用最大经验似然密度方法进行标准化处理，降低量纲与分布差异影响；进一步引入潜在因子模型（LFM）^[13]对终端数据质量进行综合评价并排序截断，筛选得到高质量终端样本。在状态评估阶段，基于高质量终端构建市场状态指标体系，计算品规综合得分，并利用高斯混合模型对状态阈值进行定量划分，实现对品规“俏、紧、平、松、软”的分级。该框架通过“先治理、后评估”的闭环路径，预期能够提升状态监测的准确性与稳健性，为卷烟精准投放与市场调控提供更可靠的数据支撑与方法依据。

1 问题分析

在卷烟市场状态检测中，当某类客户的终端销售指标在极端值大量聚集，呈现出与其他类客户群体完全偏离的状态时，一般可认定为经营状态异常。在广东阳江的实践中，本研究基于销售终端原始数据对消费笔数、开机天数、品牌宽度和包条比等监测指标进行了预分析，具体结果见图 1 所示。



注：销售笔数指月度总卷烟销售笔数；开机天数指月内有扫码数据的天数；品牌宽度指每天有扫码记录的卷烟品牌数量；包条比指单包销售量与整条销售量的比值。

图 1 销售终端 (a) 销售笔数 (b) 开机天数 (c) 品牌宽度 (d) 包条比核密度图

Fig. 1 Kernel density plots of sales terminal, (a) sales transaction count, (b) operating days, (c) brand breadth and (d) pack-to-carton ratio

分析可知，存在两类经营状况明显异常的客户群体。第一类为“未正常经营客户”，其主

要特征为开机天数少、销售笔数少、包条比极低；第二类客户为具有明显的“虚假扫码”特征，主要表现为品牌宽度极低，包条比为 0 或 1 两个极端。根据实际数据统计，不活跃客户占比约为整体客户的 9%~10%，而虚假交易或刷单交易客户占比约为 20%。两类显著低质量客户占总体比例约为 30%。这些数据质量问题直接影响后续市场状态评估的可靠性，将导致评估结果失真，难以为卷烟投放策略提供科学依据。

2 基于数据治理的卷烟市场状态监测方法构建

2.1 整体设计

本研究提出并实证验证了一种“数据治理—市场状态评估”两步法：首先构建数据治理指标体系，采集数据并采用基于最大经验似然密度方法对指标得分进行标准化处理，结合聚类分析与潜在因子模型（LFM）综合评估并筛选高质量终端；随后基于这些高质量终端，构建市场状态指标体系；最后采用综合评价方法计算状态得分，并利用高斯混合模型（GMM）定量划分卷烟品规市场状态。零售终端数据治理下的市场状态监测双重分析流程图见图 2。




图 2 零售终端数据治理下的市场状态监测双重分析流程图

Fig. 2 Dual analysis flowchart of market state monitoring under retail terminal data governance

2.2 零售终端数据治理

2.2.1 零售终端数据治理指标体系

构建科学、有效的数据治理指标体系是数据质量评估的关键前提在于选取与数据质量高度相关的指标，以保障后续评价的准确性与稳健性^[14]，因此，本研究构建了销售结构、库存管理、扫码时间三维指标体系用以评价数据质量。指标选取基于业务背景知识和实际工作经验，并遵循显著性和稳健性原则。显著性原则要求根据经验构建能够显著反映数据真实性的指标^[15]。例如，构建扫码时间间隔指标时，若每一笔订单与上一笔订单的时间间隔过短，

则有很大可能存在刷单情况，可以反应出数据真实性较低。稳健性原则要求排除零售终端间其他异质性因素带来的影响，使得在不同零售终端间有效样本能够保持在一定范围之内。例如，应排除销售笔数、购进量等受零售终端规模影响较大的指标，保留存销比、销订比等对零售终端规模和经营能力不敏感的指标。基于以上原则，最终确认的指标体系如表 1 所示。

表 1 零售终端数据治理指标体系
Tab. 1 Data quality indexes

指标大类	一级指标	指标解释
销售结构	卷烟销售笔数	月度总卷烟销售笔数
	卷烟销售笔数比例	卷烟销售笔数/整体笔数（包含非烟）
	聚合支付笔数比例	聚合支付笔数/总笔数
	聚合支付金额比例	聚合支付金额/总金额
	聚合支付卷烟销售笔数比例	聚合支付卷烟笔数/总聚合支付笔数
	聚合支付卷烟销售金额比例	聚合支付卷烟金额/总聚合支付金额
	包条比	0~1，1 则全部按包销售，0.9 对应 90 包和 1 条
	销订比	销售量/订购量
	日均扫码品牌宽度	每天有扫码记录的卷烟品牌数量
	单笔量	销量/笔数
库存管理	经营匹配指数	笔数/购入量
	库存变化比	期末库存/期初库存
	异常库存率_规格	异常规格/总规格数
	存销比	期末库存/月度销售量，衡量当前库存还能销售多少个月
时间指标	进销存偏移率	月度（期初 inv-期末 inv+购进-销量）/ 销量
	平均扫码时间间隔	每一笔订单与上一笔订单的时间间隔，不计算每天第一笔
	日扫码稳定性指数	日销量标准差/日均销量
	凌晨时段扫码稳定性指数	0~6 时
	上午时段扫码稳定性指数	6~12 时
	下午时段扫码稳定性指数	12~18 时
	晚上时段扫码稳定性指数	18~24 时
	开机天数	月内有扫码数据的天数

2.2.2 零售终端数据治理流程

收集上述指标数据，按照图 3 的流程进行数据质量综合评价，以期筛选到具有较高数据质量的零售终端。




图 3 分指标计算得分流程示意图

Fig. 3 Schematic diagram of sub-index score calculation process

具体流程如下：

(1) 中心标准化。首先将所有原始数据集中每一个指标所有周期内的数据进行中心标准化，转化为标准化坐标，转化后的每一周期的值代表其在整个周期数据中的位置， $x = 0$ ，表示位于均值， $x = 1$ 表示位于比均值大 1 个标准差处。

(2) 异常终端过滤。利用聚类分析方法对各零售终端数据进行显著异常初步过滤，保留不显著异常数据^[16]。通过聚类分析，对零售终端快速聚类，可视化每个类终端数据质量相关的指标特征的分布形态，结合业务经验可发现存在显著异常的，不符合实际市场逻辑的终端店铺，初步过滤掉这些显著异常的零售终端。

(3) 针对初筛后零售终端数据，分指标进行经验密度计算，将具有最大经验似然密度的样本点设为中心点，计算各样本点距离中心点的距离。此时所有数据基本满足标准正态分布， $\mu = 0$ ， $\sigma = 1$ ，其中 μ 表示正态分布均值， σ 表示正态分布的标准差。则所有数据点出现的概率可通过标准正态分布的概率密度函数计算得到，拟合概率密度函数曲线，令密度值百分化，即可得到 0~100 分范围内的标准化得分。

(4) 利用 LFM 计算分指标得分的权重，基于标准化得分进行加权得到各个终端的数据质量综合评价得分。

(5) 再对综合评价得分由高到低地排序零售终端，筛选出较高质量的零售终端。利用分位数截断方法删除约 10%~20%左右的具有较低数据质量综合评价得分的终端店铺，得到较高质量零售终端。

2.2.3 数据质量综合评价得分计算

本研究利用潜在因子模型(LFM)来计算数据质量综合评价得分，潜在因子模型(LFM)是一类经典的多变量统计建模与降维方法，用于在高维观测变量中提取少量不可观测的共同因子，以解释变量之间的相关结构。其基本假设是：每个观测指标可表示为若干公共潜在因子的线性组合与该指标特有成分（特异因子/误差项）之和^[13]。在心理测量、问卷量表与质量评价中，许多关键属性（如学习能力、满意度、服务质量或数据质量）难以直接观测。可将题项/指标视为外显测量，并假设其相关性由少数潜在因子驱动。LFM 据此估计因子及载荷，得到因子得分或综合评分，用于量化刻画对象在“能力/质量”等维度上的水平。

LFM 假设每一项观测指标可表示为若干线性无关公共因子的线性组合与特殊因子之和, 其中公共因子为同时影响多个观测指标的潜在变量。通过识别并建模这些公共因子, LFM 能够更系统地刻画多指标之间的共变结构及其背后的潜在驱动机制^[13]。在应用潜在因子模型于数据质量综合评价时, 零售终端数据质量可以通过一些可获得的经营数据反映出来。存在开机天数少、销售笔数少、包条比极低特点的这些终端被聚合为一类, 纳入评价指标体系后, 所计算的数据质量得分较低。倒推可发现这些终端存在非正常经营的特点。同理, 将与判别刷单行为相关的扫码时间间隔和日均扫码品牌宽度评分纳入评价指标。若扫码时间间隔和日均扫码品牌宽度均表现异常, 则这两项指标都将得分较低, 可以倒推出大概率存在刷单行为。而这些公共因子指标可以类比假设中影响零售终端数据质量的实际因素, 认为是所有零售终端都共享的因素, 可以反应零售终端的一些公有特征。特殊因子则可以认为反映的是零售终端的一些异质性特征。这些特征一般是零售终端自身所具有的, 与零售终端数据质量无关, 可以将其归结到随机误差中, 不影响零售终端数据质量的评估。统计方法通常均依赖于特定假设, 在数据质量评估场景, LFM 背后蕴含的数学原理符合实际情况, 构造的因子也更能够找到对应的实际意义。

为进一步论证基于 LFM 进行综合评价的合理性。在市场状态评估方法的探索中, 对比了 4 种权重计算方法的效果, 即 (1) 基于经验的方法 (Empirical), 具体权重为: 可销天数: 0.3, 动销率: 0.05, 毛利率 0.3, 订足率: 0.3, 订足面 0.05; (2) 熵权法 (Entropy 方法); (3) 主成分分析 (PCA) 法; (4) 潜在因子分析 (LFM)。在后三种综合评价分析的权重计算方法中, 为客观地融合经验权重信息, 设置组合系数为 1/2, 即对经验权重和综合评价方法计算的权重进行等权算术平均。此处权重的组合系数设置为 1/2, 本质上是假设实际分析者对综合评价分析的权重和经验权重的把握程度一样。在实际中, 该组合系数可以视为一个超参数, 在实际中可以采用网格搜索的方式来确定, 即在 [0,1] 区间中等间隔地取大量的组合系数, 批次计算市场状态得分, 结合实际业务经验判断最佳的组合系数。特别地, 当取该组合系数为 0 时, 则最终的权重退化为经验权重, 反之, 取组合系数为 1, 则最终的权重退化为综合评价方法分析得到的权重。基于 4 种权重的市场状态评估得分的可视化结果见图 4。其中, 横轴为市场状态综合得分 (取值范围 50~100), 得分越高表明卷烟品规的市场状态越佳; 纵轴为对应得分区间内卷烟品规的密度值, 密度越大表示该得分水平的品规数量越多。图中不同颜色的阴影区域表示综合得分映射到的各市场状态分区。




图 4 市场状态得分分布图 (a) Entropy 方法 (b) Empirical 方法 (c) PCA 方法 (d) LFM 方法
Fig. 4 Market state score distribution diagrams by (a) entropy method, (b) empirical method, (c) PCA method and (d) LFM method

从图 4 可以看出，不同权重方法对综合得分的影响不仅体现在均值位置，更体现在分布形态（离散程度、峰态与尾部厚度）。这些形态差异会直接传导到后续“俏、紧、平、松、软”分级：当得分分布被压缩或过度偏斜时，状态区间会被挤压、阈值对噪声更敏感；当分布具有合理的中间覆盖与尾部延展时，状态区间更具可分性，阈值更稳定、解释也更一致。具体而言：熵权法得到的得分高度集中、主峰尖锐且尾部较短，说明多数品规被映射到相近分值区间，导致不同状态的分数跨度偏小，区分度不足；经验权重法的分布更分散，但在高分段偏重，且与经验密度在局部存在偏离，提示该方法对少数高权重指标更敏感，容易随指标整体水平漂移而造成阈值位置波动，从而影响“平稳”区间的覆盖与稳定性；PCA 方法虽然能较好拟合整体密度，但得分更集中于高分段，使中间状态占比偏低，分级结构出现“向高分挤压”的倾向，不利于反映多数品规应处于常态区间的业务规律。相比之下，LFM 在主峰附近与经验密度拟合较为贴合，同时保留了适度的中低分段与高分段尾部，使得各状态区间的样本覆盖更均衡、阈值分割更清晰且对局部噪声更不敏感。综合区分度、稳定性与可解

释性，LFM 更符合市场状态监测对“可分级、可复现、可解释”的要求，因此本文最终采用 LFM 分别用于终端数据治理综合得分与市场状态综合评价得分的计算。

LFM 综合评估的具体步骤如下：

假设对 N_1 个零售终端店铺收集到 m 个与零售终端数据质量相关的指标，例如第 i 个终端店铺的卷烟销售笔数为 $Y_{i,1}$ ，卷烟销售笔数比例为 $Y_{i,2}$ ，聚合支付笔数比例为 $Y_{i,3}$ 等共 m 个。具体收集到的指标个数 m 可结合实际情况调整。

(1) 经过无监督聚类分析过滤后得到 N 个零售终端店铺收集到 m 个与零售终端数据质量相关的数据预处理的数据集 $\{Y_{i,j}\}_{i=1,\dots,N;j=1,\dots,m}$ 以及对 m 个分指标计算标准化得分后的数据 $\{Z_{i,j}\}_{i=1,\dots,N;j=1,\dots,m}$ ，其中 $N < N_1$ ；

(2) 计算 $\{Y_{i,j}\}_{i=1,\dots,N;j=1,\dots,m}$ 的样本协方差矩阵 $\Sigma \in \mathbb{R}^{m \times m}$ ，然后对 Σ 进行实对称矩阵的谱分解：

$$\Sigma = \sum_{j=1}^m \lambda_j v_j v_j^\top \quad (1)$$

令样本协方差矩阵 Σ 的特征值按从大到小排列为： $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m$ ，它们对应的特征向量 $v_j \in \mathbb{R}^m$ 。其中指标的协方差矩阵 Σ 中的元素反映了不同指标之间的相关性程度。例如， $\Sigma(m_1, m_2)$ 表示第 m_1 个数据质量相关特征与第 m_2 个数据质量相关特征之间的相关性，这些信息可通过特征值及其对应的特征向量来提取刻画。

(3) 估计因子载荷矩阵 A ，取前 q 个最大的特征值，及其对应的特征向量，此处的 q 即对应潜在公共因子个数。 q 值的选取一般让它们的特征值占比达到 85% 即可，则 A 中的每一列为： $a_k = v_k \sqrt{\lambda_k} \in \mathbb{R}^{m \times 1}$ ，其中 $v_k \in \mathbb{R}^m, \lambda_k \in \mathbb{R}$ ，则可得

$$A = [a_1, \dots, a_q] \in \mathbb{R}^{m \times q} \quad (2)$$

因子载荷矩阵 A 的第 q 列则反映了 m 个终端数据质量相关指标对第 q 个零售终端数据质量公共因子 f_q 的影响程度。

(4) 计算权重系数：计算矩阵 A 的每行元素平方后的和，这个值反映了第 j 个可观测指标对公共因子 $f_1, \dots, f_q$ 的依赖程度，可以用于解释每个零售终端数据质量相关的可观测指标与终端数据质量潜在因子之间的相关性强弱，对其进行归一化，即可得如下权重公式，

$$w_j = \frac{\sum_{k=1}^q a_{j,k}^2}{\sum_{j=1}^m \sum_{k=1}^q a_{j,k}^2}, j = 1, \dots, m \quad (3)$$

权重 w_j 则表示第 j 个数据质量相关的可观测指标对终端数据质量的影响大小的度量值，该值越大，表示在 m 个指标中的影响越突出。

(5) 计算零售终端数据质量综合评价得分： $S_i = \sum_{j=1}^m w_j Z_{i,j}$ ， $i = 1, \dots, N$ 。

基于 N 个零售终端店铺，通过上述流程，可计算得到 N 个店铺各自的数据质量综合评价得分。对综合评价得分数据集 $\{S_i, i = 1, \dots, N\}$ ，采取分位数截断的方式，剔除数据质量得分较低的约 10%~20%左右的低质量零售终端，最终得到 n 个高质量零售终端，后续将这 n 个零售终端收集市场状态评估相关的数据，进行可靠的市场状态评估。

2.3 市场状态评估

2.3.1 市场状态评估指标体系

卷烟市场状态指不同卷烟品规市场销售景气状态的度量，有时也称为市场状态景气指数。按照不同卷烟品规的畅销程度，通常可划分为 5 个状态，即：“俏、紧、平、松、软”。为准确评估不同卷烟品规的市场状态，基于业务经验和现有研究基础，本文从“量、需、价、存”这 4 个与品规市场状态密切相关的维度筛选建立评价指标，具体的评价指标及其定义见表 2。

表 2 品规市场状态核心指标选取表
Tab. 2 Selection of core indexes for specification market state

指标类别	指标名称	指标定义	取值范围
投放端指标	订足面	$\frac{\text{当周某品规的有订购的零售店铺数}}{\text{当周某品规投放的零售店铺数}} * 100\%$	0~1 之间
	订足率	$\frac{\text{当周某品规的零售店铺订购量}}{\text{当周某品规的零售店铺投放限额}} * 100\%$	0~1 之间
需求满足类指标	动销率	$\frac{\text{当周某品规的零售店铺销售量}}{\text{当周某品规的零售店铺订购量}} * 100\%$	0~1 之间
毛利率类指标	毛利率	$\frac{\text{当周某品规的行情价} - \text{进购价}}{\text{当周某品规的行情价}} * 100\%$	0~1 之间
库存类指标	可销天数	$\frac{\text{当周某品规的期末库存}}{\text{当周某品规的日均零售店销量}}$	> 0

2.3.2 市场状态评估流程

卷烟品规市场状态评估的流程见图 5。




图 5 市场状态评估流程示意图

Fig. 5 Evaluation process diagram of market state evaluation

第一步，基于所建立的卷烟品规市场状态评估的指标体系，对数据集进行中心标准化后，利用潜在因子 LFM 方法，通过融合指标得到各个指标的对应权重向量 w ；

第二步，考虑融合主观经验信息，设 w_0 表示主观经验权重信息，通过修正系数 $\lambda \in$

$(0,1)$, 构建权重向量的凸组合, $w^* = \lambda w + (1 - \lambda)w_0$, 其中 λ 代表对数据或经验的可信度, 可根据实际情况进行调整;

第三步, 根据第二步得到的修正权重对指标状态数据集 Z 进行加权综合 (即线性变换) 得到市场状态综合得分向量, 记为 $S = Zw^*$, 其中 w^* 表示基于数据进行统计分析得到的权重结果;

第四步, 基于第三步得到的市场状态综合得分向量 S , 绘制概率直方图和经验密度图, 采用高斯混合模型进行拟合, 然后使用基于多个波峰、波谷的均值和方差, 确定不同卷烟品规的市场状态阈值。将某一卷烟品规划分为“俏、紧、平、松、软”的五状态之一。

2.3.3 市场状态得分的计算

收集到 I 种卷烟品规, 每个品规有 p 个市场状态相关指标。第 i 种规格的第 j 个市场状态评估相关原始值指标为 x_{ij} , $i=1, \dots, I$; $j=1, \dots, p$ 。

(1) 数据标准化。对数据采取正/负向指标分别采用 Min-Max 归一化处理得到标准化指标 $\tilde{x}_{ij}$ 。然后进行指标线性得分化处理: $z_{ij} = 50 + 100 \times \tilde{x}_{ij}$, 可得各个指标得分化后的数据矩阵 Z , 用于后续权重计算。

(2) 权重融合。在得到每个指标的得分后, 实际上得到的是与零售终端数据质量评估中分指标计算得分后类似结构的数据集, 即一个 I 行 p 维的矩阵 Z , 采用类似 2.2.2 节的 LFM 综合评价方法计算得到一个 p 维的市场状态指标权重 w , 结合业务经验权重 w_0 , 设定组合系数 $\lambda=1/2$, 动态地调整得到融合权重 $w^* = \lambda w + (1 - \lambda)w_0$, 通过 $S = Zw^*$ 计算可得到一个 I 维的卷烟规格市场状态得分向量 S 。

(3) 市场状态划分阈值计算

第三步是计算市场状态阈值, 采用高斯混合模型 (GMM) [17,18] 的阈值定界方法 (具体见下文 2.3.3 节), 给出品规市场状态的合理划分, 基于专卖流动、倒挂、顺价分档等信息对市场状态的分类结果进行分级调节。此即“俏、紧、平、松、软”的五状态四阈值的定界方法。

2.3.4 市场状态划分阈值的确定

市场状态得分的经验分布直方图通常是钟形多峰的 (见图 4d-LFM 方法), 表明可采用高斯混合分布进行拟合市场状态得分数据 S 。利用高斯混合模型对市场状态得分分布聚类可以融入市场状态得分分布的方差、均值等信息进行阈值定界, 最终确定不同规格的市场状态。该方法相较于仅考虑方差信息的 $3-\sigma$ 准则[10]具有更好的分析精度和可解释性。具体步骤如下:

第一步, 由 EM 算法[19]估计得出 K 个高斯分布的参数, 假定按照均值递增顺序表示

每个高斯分布为 $N(\mu_k, \sigma_k), k = 1, \dots, K$;

第二步, 按照各自单位均值波动大小来确定每个正态分布的边界, 计算出波动倍数:

$$c_k = \frac{\mu_{k+1} - \mu_k}{\sigma_{k+1} + \sigma_k}, k = 1, \dots, K; \quad (4)$$

其中 μ_k 为第 k 个高斯分布的均值参数, σ_k 为第 k 个高斯分布的标准差, c_k 表示第 $k+1$ 个高斯分布相对第 k 个高斯分布的均值差异在联合波动尺度上的相对大小 (即“波动倍数”)

第三步, 根据计算得到的波动倍数, 基于传统“ 3σ ”-准则的构造思路^[10], 构造不同市场状态的得分阈值。波动倍数融合了相邻分布均值相对变化信息, 因此, 对第一个高斯分布的左侧阈值与最后一个高斯分布的右侧阈值, 由于不存在相邻分布用于比较, 因此无需引入波动倍数。对于任意两个相邻高斯分布, 其交叉处边界可有两种取法即左边界: $\mu_k + c_k \sigma_k$, 或右边界: $\mu_{k+1} + c_k \sigma_{k+1}$, 所有可以使用的市场状态划分的阈值依次可表示为:

$$\{\mu_1 - \sigma_1, \mu_1 + c_1 \sigma_1, \dots, \mu_{k-1} + c_{k-1} \sigma_{k-1}, \mu_k + c_k \sigma_k\}$$

或者

$$\{\mu_1 - \sigma_1, \mu_2 - c_1 \sigma_2, \dots, \mu_k - c_{k-1} \sigma_k, \mu_k + c_k \sigma_k\}$$

由于所假定市场状态至多只有 5 种, 所以产生数据点的混合高斯分布中的个数 K 应当满足 $2 \leq K \leq 5$, 下面讨论对不同的 K 的选择时阈值的选择。 K 的选择一方面可以基于品规得分的直方图和经验核密度估计图来确定或者可以使用一些自适应的聚类方法来确定, 如 R 语言软件包 NbClust 可以用于确定最佳聚类个数^[19]。当 $K = 2$ 时, 阈值的确定只有一种, 即 $[\mu_1 - \sigma_1, \mu_1 + c_1 \sigma_1, \mu_2 - c_1 \sigma_2, \mu_2 + \sigma_2]$; 当 $K = 3$ 时, 阈值的确定有 4 种结果, 即 $[\mu_1 - \sigma_1, \mu_1 + c_1 \sigma_1, \mu_2 + c_2 \sigma_2, \mu_3 + \sigma_3]$; $[\mu_1 - \sigma_1, \mu_2 - c_1 \sigma_2, \mu_2 + c_2 \sigma_2, \mu_3 + \sigma_3]$; $[\mu_1 - \sigma_1, \mu_1 + c_1 \sigma_1, \mu_3 - c_2 \sigma_3, \mu_3 + \sigma_3]$; $[\mu_1 - \sigma_1, \mu_2 - c_1 \sigma_2, \mu_3 - c_2 \sigma_3, \mu_3 + \sigma_3]$; 当 $K = 4$ 时, 有 16 种阈值的划定, 类似可推; 当 $K = 5$ 时, 出于计算结果的可解释性和方便, 不再考虑最左高斯分布的左边界点和最右侧高斯分布的右边界点, 因此, 此时有 16 种阈值结果。

在实际计算中, 可以由以下三方面来简化计算: 第一, 根据直方图或者密度估计图, 事先确定混合分布中的高斯分布个数; 第二, 在确定两个相邻高斯分布的交叉边界时, 可以均只选择其中靠左或者靠右的分布均值的波动倍数偏倚作为阈值; 第三, 对于高斯混合分布中的混合概率、均值向量、方差分量的先验初值, 可事先采用 K-means 方法事先进行聚类, 可以得到基于数据的先验混合概率、均值和方差, 从而避免较强的主观性^[20]。

3 应用效果

基于广州阳江零售终端数据治理和卷烟品规市场状态评估场景, 验证模型实际的应用效果。所提出的数据质量综合评价方法和市场状态评估方法具有较高的通用性, 基于公开免费的 R 编程语言或 python 语言可轻易实现, 兼容 CPU 多核并行或 GPU 服务器运行。

3.1 零售终端数据质量分析

本次研究中使用某省 3 个地市的零售终端进销存数据进行实验,具体原数据及数据量如下表 3。利用聚类分析进行初步清洗,筛去非“易灵通”客户、无订购客户后,与本研究相关的有效易灵通共 $N=4,202$ 户,共包含 22 个指标,整理得到 4202 行 22 列的数据矩阵。

基于 2.2.3 节的方法,对 4202 行 22 列的数据进行计算相关(或协方差)矩阵,并进行特征值分解/因子提取,得到各潜在因子的特征值(即解释方差)。据此计算各因子的方差贡献并绘制碎石图,如图 6 所示。从第 3 个因子开始因子方差平滑下降,对原有变量的贡献解释性显著减小,因此依据手肘法选择前 2 个因子进行具体分析。




图 6 因子方差碎石图

Fig. 6 Factor variance gravel diagram

选择因子方差最高的前两项潜在因子建模,计算载荷矩阵后,绘制雷达图如图 7 所示。该雷达图反映了因子方差最高的两个潜在因子分别与各指标之间的相关关系大小,可用于考察两个潜在因子对各项指标的贡献度。



图 7 潜在因子对贡献度雷达图

Fig.7 Radar chart of latent factor contribution scores

因子 1 (绿色)在指标包销售比例，经营匹配指数，单笔量这三个观测指标上的占比较大，而这三个指标主要刻画了零售终端的销售和经营能力，故命名这个潜在因子为零售终端经营匹配度因子。

因子 2 (蓝色)在日扫码稳定性指数，扫码间隔时间，销订比这三个观测指标上占比较大，它们主要刻画了零售终端的经营稳定性，和可持续性销售的能力，故命名称这个潜在因子为零售终端销售稳定性因子。

基于确定的 2 个潜在因子，首先由因子分析结果得到各原始指标在两个因子上的载荷（反映该指标与因子的关联强度）。为刻画“贡献度”，将载荷的大小转化为解释贡献（通常用载荷的平方表示，载荷越大说明该指标对该因子的解释作用越强）。随后，引入两个因子的方差贡献率作为因子层面的权重，对各指标在两个因子上的贡献度进行加权汇总，得到每个指标的综合贡献得分。最后，为便于横向比较，将各指标的综合贡献得分进行归一化处理，使其和为 1（或 100%），归一化后的结果即为表 3 所列的指标权重得分。因而，权重得分越高表示该指标对综合评价结果的总体贡献越大。

表 3 指标权重
Tab. 3 Index weights

指标	权重得分
开机天数	0.037
包销售比例	0.161
日扫码稳定性指数	0.071
扫码间隔时间	0.106
日均扫码稳定性指数	0.055
存销比	0.095
销订比	0.143
进销存偏移率	0.009
单笔量	0.165
库存变化比	0.051
经营匹配指数	0.107

基于前文确定的两个数据质量相关的潜在因子可得到指标的权重,再计算终端的数据质量综合评价得分,最终对 4202 个零售终端店铺的数据质量综合评价得分进行 15%分位数截断,最终得到 4172 个具有较高质量的零售终端。分析结果见图 8,左图可视化了终端数据治理的结果,右图可视化了数据质量评价得分的分布。




图 8 零售终端数据质量治理结果与评分分布

Fig. 8 Results of retail terminal data quality governance and score distribution

3.2 市场状态评估分析

采用数据治理完毕的某地市具有较高数据质量的零售终端，收集与卷烟品规市场状态相关指标（表 2）进行评估，数据周期从 2024 年 9 月第 2 周到 2025 年 3 月第 3 周共 29 周。剔除无效数据后，共获得 3896 个零售终端的 1911 条数据，共涉及品规名称、周期、可销天数、动销率、毛利率、订足率、订足面这 7 个指标，涉及卷烟品规 143 个。

采用上文提及的市场状态评估算法进行每个卷烟规格的市场状态评估。首先得到每个卷烟规格的市场状态得分，再利用 2.3.3 节中市场状态划分阈值的方法，可得到“俏、紧、平、松、软”五状态的阈值划分结果，整理得到表 4。在本方法体系下，因市场状态得分的计算和阈值划分是基于全部卷烟品规的数据分析得到的，所以市场状态划分阈值适用于所有卷烟品规，与销量规模大小无关。

表 4 市场状态阈值划分结果
Tab. 4 Threshold classification results of market state

评估方法	状态类型				
	疲软	宽松	平稳	紧俏	俏销
LFM	(50,76.13]	(76.13,90.38]	(90.38,94.77]	(94.77,95.69]	(95.69,100]

选择有代表性的卷烟品规为例呈现评价得分和状态的划分结果，选择这些规格在 2024 年 9 月至 2025 年 3 月的市场状态得分以及 5 个市场状态相关指标，计算其指标得分值（结果保留 3 位小数），利用表 5 的市场状态阈值划分结果，可得到每个规格的市场状态，汇总后如下表 5。

表 5 市场状态得分值-LFM
Tab. 5 Market state scores - LFM

规格	双喜（软经典）	双喜（硬经典）	芙蓉王(硬中支)	白沙（软）	玉溪（软）
市场状态得分	95.435	99.343	88.833	95.439	91.530
可销天数	6.738	7.671	27.619	10.248	19.723
订足率/%	99.393	99.149	68.101	99.706	82.583
订足面/%	99.906	99.839	99.662	100	96.217
动销率/%	42.398	37.380	41.978	48.295	28.932
毛利率/%	11.427	11.361	11.476	11.369	11.415
卷烟市场状态	紧俏	俏销	宽松	紧俏	平稳

由表 5 可见，不同卷烟品规的市场状态得分存在明显差异，对应的市场状态类型也呈现出较强区分性。结合表 4 所给出的阈值划分结果，可以看出：双喜（硬经典）市场状态得分为 99.343，落入“俏销”区间，说明该规格在样本期内市场需求旺盛、供需关系偏紧，具有较强的市场吸引力；双喜（软经典）和白沙（软）的市场状态得分分别为 95.435 和 95.439，均处于“紧俏”区间，表明这两个规格整体销售表现较好，市场需求相对活跃；玉溪（软）得分为 91.530，位于“平稳”区间，说明其市场供需关系总体较为均衡，既未表现出明显滞销，

也未出现显著紧缺；芙蓉王（硬中支）得分为 88.833，处于“宽松”区间，表明该规格市场供给相对充足，而需求拉动相对不足，整体市场状态偏弱。

进一步结合 5 个原始指标分析可发现，各规格之间的毛利率与订足面差异相对较小，说明这两个指标对不同规格状态差异的解释作用相对有限；相比之下，可销天数、订足率和动销率的变化更为明显，对市场状态得分的区分作用更强。具体来看，双喜（硬经典）和双喜（软经典）的订足率均接近 99%，且可销天数较低，表明市场需求较强、货源消化较快，因此其市场状态得分较高；白沙（软）同样具有较高订足率和较低可销天数，因而被识别为“紧俏”状态。相反，芙蓉王（硬中支）的可销天数高达 27.619，订足率仅为 68.101%，虽然其订足面和毛利率并不低，但由于需求释放不足、库存消化较慢，其市场状态得分明显偏低，最终被划分为“宽松”状态。玉溪（软）则处于中间水平，其可销天数、订足率和动销率均未表现出特别突出的高位或低位特征，因此整体状态表现为“平稳”。

综上，基于 LFM 计算得到的市场状态得分能够较好反映不同卷烟品规在市场中的相对冷暖程度，并实现从“宽松”到“紧俏”的层次化区分。其中，订足率、动销率和可销天数是影响市场状态差异的关键因素：订足率越高、动销越快、可销天数越低，通常对应更高的市场状态得分；反之，则更可能表现为平稳或宽松状态。这一结果说明，卷烟市场状态本质上是多指标共同作用的结果，其中需求强弱与库存消化速度对状态识别具有更直接的解释意义。

此外，研究发现这些规格的毛利率、订足面基本相差不大，最终导致市场状态得分有差异的是动销率、订足率与可销天数，尤其是订足率和动销率。这也表明销量和价格因素在市场状态得分中具有重要影响作用，且销量比价格更重要，因为订足率较大的规格其市场状态得分也较大，这一趋势符合预期。

4 结论

针对零售终端数据存在扫码失真、库存虚报与异常波动等问题，本研究提出“数据治理—状态评估”一体化框架：先通过聚类剔除显著异常终端，结合最大经验似然密度标准化与潜在因子模型（LFM）计算数据质量综合得分，并采用分位数截断筛选高质量终端样本；再基于高质量样本构建订足面、订足率、动销率、毛利率、可销天数等市场状态指标体系，利用 LFM 综合评价方法得到品规市场状态得分，并引入高斯混合模型（GMM）定量确定“疲软—宽松—平稳—紧俏—俏销”五级阈值，实现状态分级。实证结果表明，该方法能够更稳定、可解释地刻画品规市场冷暖差异，其中订足率、动销率与可销天数对状态区分作用更为显著，可为卷烟精准投放与市场调控提供量化依据。

参考文献

[1] 李厚天, 郑朋. 基于数据集成分析的卷烟市场新型监测体系构建研究[C]//中国烟草学会 2017 年学术年会优秀论文集. 北京: 中国烟草学会, 2017: 4736-4748.

LI Houtian, ZHENG Peng. Research on the construction of a new monitoring system for cigarette market based on data integration analysis[C]//Proceedings of 2017 Annual Academic Conference of China Tobacco Society. Beijing: China Tobacco Society, 2017: 4736-4748.

[2] 王伟东, 尹海滨, 张宗文, 等. 数字化营销背景下的卷烟零售市场状态优化策略研究[J]. 技术与市场, 2023, 30(12): 132-135.

WANG Weidong, YIN Haibin, ZHANG Zongwen, et al. Research on optimization strategies for cigarette retail market status in the context of digital marketing[J]. Technology and Market, 2023, 30(12): 132-135.

[3] 金勇进, 蒋妍, 李序颖. 抽样技术[M]. 北京: 中国人民大学出版社, 2002.

JIN Yongjin, JIANG Yan, LI Xuying. Sampling techniques[M]. Beijing: China Renmin University Press, 2002.

[4] 苟俊杰. 烟草行业提升卷烟市场监测工作质量的策略研究[J]. 中国管理信息化, 2024, 27(18): 188-190.

GOU Junjie. Strategies for improving the quality of cigarette market monitoring in tobacco industry[J]. China Management Informationization, 2024, 27(18): 188-190.

[5] 董秉坤, 原源, 郭兴堃, 等. 国产卷烟新品市场状态评价体系量化研究[J]. 中国烟草学报, 2023, 29(2): 105-110.

DONG Bingkun, YUAN Yuan, GUO Xingkun, et al. Quantitative study on market state evaluation system of new domestic cigarettes[J]. Acta Tabacaria Sinica, 2023, 29(2): 105-110.

[6] 张小玲, 张小萍, 马宁. 卷烟市场状态综合评价模型的建立与应用[J]. 中国集体经济, 2025(12): 117-120.

ZHANG Xiaoling, ZHANG Xiaoping, MA Ning. Establishment and application of a comprehensive evaluation model for cigarette market state[J]. China Collective Economy, 2025(12): 117-120.

[7] 王雄峰, 蒋丽雯, 朱博, 等. 基于市场状态的企业产品投放模型及其策略研究——以衡阳烟草为例[J]. 企业改革与管理, 2024(20): 115-119.

WANG Xiongfeng, JIANG Liwen, ZHU Bo, et al. An enterprise product launch model and its strategy based on market status: a case study of Hengyang tobacco[J]. Enterprise Reform and Management, 2024(20): 115-119.

[8] 林珍玲. 基于流动价差与需求指数的卷烟市场状态评价模型构建[J]. 海峡科学, 2024(9): 142-148.

LIN Zhenleng. Construction of a cigarette market state evaluation model based on circulating price spread and demand index[J]. Straits Science, 2024(9): 142-148.

[9] 杨蕾, 向其凤, 何雪峰, 等. 基于产品生命周期和四象限法的卷烟产品市场状态评价[J]. 中国市场, 2023(18): 127-132.

YANG Lei, XIANG Qifeng, HE Xuefeng, et al. Market state evaluation of cigarette products based on product life cycle and four-quadrant method[J]. China Market, 2023(18): 127-132.

[10] 许飞, 张一博, 史浪, 等. 烟草商业企业市场状态评价指标阈值确定方法优化——基于正态分布 3σ 原则[J]. 经济师, 2023(5): 278-281.

XU Fei, ZHANG Yibo, SHI Lang, et al. Optimization of threshold determination method for market state evaluation indexes of tobacco commercial enterprises: based on normal distribution 3σ principle [J]. China Economist, 2023(5): 278-281.

[11] 黄敏, 梁艳, 向云海, 等. 基于智能集成与阈值训练的卷烟市场状态评价体系研究——以南充市为例[J]. 中国烟草学报, 2025, 31(5): 155-166.

HUANG Min, LIANG Yan, XIANG Yunhai, et al. An evaluation system for cigarette market status based on intelligent integration and threshold training: evidence from Nanchong[J]. Acta Tabacaria Sinica, 2025, 31(5): 155-166.

[12] 石江南, 彭长根, 谭伟杰. Spark 框架下支持差分隐私保护的 K-means++ 聚类方法[J]. 信息安全研究, 2024, 10(8): 712-718.

SHI Jiangnan, PENG Changgen, TAN Weijie. K-means++ clustering method supporting differential privacy protection in Spark framework[J]. Journal of Information Security Research, 2024, 10(8): 712-718.

[13] 王啸飞, 鲍胜利, 陈炯环. 基于潜在因子模型在子空间上的缺失值注意力聚类算法[J]. 计算机应用, 2023, 43(12): 3772-3778.

WANG Xiaofei, BAO Shengli, CHEN Jionghuan. Missing value attention clustering algorithm based on latent factor model in subspace[J]. Journal of Computer Applications, 2023, 43(12): 3772-3778.

[14] 徐涛, 尤建新. 考虑多场景需求的数据资产质量评价指标体系构建[J]. 上海质量, 2024(12): 37-40.

XU Tao, YOU Jianxin. Construction of a data asset quality evaluation index system considering multi-scenario requirements[J]. Shanghai Quality, 2024(12): 37-40.

[15] 常延斌, 王桂瑶, 牟文君, 等. 基于熵权法和改进 TOPSIS 法的烤烟质量综合评价[J]. 烟草科技, 2023, 56(8): 35-43.

CHANG Yanbin, WANG Guiyao, MU Wenjun, et al. Comprehensive assessment of flue-cured tobacco quality based on entropy weight method and modified TOPSIS method[J]. Tobacco Science & Technology, 2023, 56(8): 35-43.

[16] 严涛, 江开忠, 姜新盈, 等. 基于高斯混合聚类采样的不平衡数据处理方法[J]. 计算机应用与软件, 2023, 40(12): 305-311.

YAN Tao, JIANG Kaizhong, JIANG Xinying, et al. Unbalanced data processing method based on gaussian mixture clustering[J]. Computer Applications and Software, 2023, 40(12): 305-311.

[17] 王清亮, 韩悦萍, 陈轩, 等. 基于加权高斯混合概率模型的系统谐波阻抗估计[J]. 电网与清洁能源, 2024, 40(9): 38-46, 53.

WANG Qingliang, HAN Yueping, CHEN Xuan, et al. System harmonic impedance estimation based on weighted gaussian mixture probability model[J]. Power System and Clean Energy, 2024, 40(9): 38-46, 53.

[18] 杨柳林, 胡贺骏. 基于改进 GMM 算法的综合能源数据清洗研究[J]. 电子测量技术, 2023, 46(4): 78-83.

YANG Liulin, HU Hejun. Research on comprehensive energy data cleaning based on improved GMM algorithm[J]. Electronic Measurement Technology, 2023, 46(4): 78-83.

[19] 姜喆, 王丹璐, 吴刘仓. 带有偏正态误差的众数回归模型最大似然估计的 EM 算法[J]. 高校应用数学学报, 2024, 39(2): 141-151.

JIANG Zhe, WANG Danlu, WU Liucang. Parameter estimates for mean and mode regression models with skew-normal errors[J]. Applied Mathematics A Journal of Chinese Universities, 2024, 39(2): 141-151.

[20] 王卫东, 徐金慧, 张志峰, 等. 基于密度峰值聚类的高斯混合模型算法[J]. 计算机科学, 2021, 48(10): 191-196.

WANG Weidong, XU Jinhui, ZHANG Zhifeng, et al. Gaussian mixture models algorithm based on density peaks clustering[J]. Computer Science, 2021, 48(10): 191-196.