

经济与管理

崔建华, 陈颢, 刘冬荣. 基于 MLP 主导的卷烟销量预测模型构建及应用研究[J]. 中国烟草学报, 2026, 32(3): 133-140. CUI Jianhua, CHEN Hao, LIU Dongrong. Research on the construction and application of an MLP-dominated cigarette sales forecasting model[J]. Acta Tabacaria Sinica, 2026, 32(3):133-140. doi:10.16472/j.chinatobacco. 2025. T0167

基于 MLP 主导的卷烟销量预测模型构建及应用研究

崔建华, 陈颢, 刘冬荣*

中国烟草总公司浙江省公司, 浙江省杭州市上城区将军路 9 号 310000

摘要: 卷烟市场销量具有强烈的“周期性+节令性+策略性”特征, 传统预测模型难以刻画政策指令、供给计划、投放节奏、库存守恒、专卖约束等关键的非市场因素影响。为此, 本文将多层感知机(Multi-Layer Perceptron, MLP)与大语言模型(Large Language Model, LLM)相结合, 提出了“MLP 主导、LLM 辅助”的卷烟销量组合预测模型。MLP 擅长自然数据建模而 LLM 具备多源信息理解与推理能力。在此基础上, 将销量预测模型应用于卷烟移库策略, 提出了基于递阶分布式模型预测控制(Distributed Model Predictive Control, DMPC)的卷烟物流供应链库存动态最优控制方法。采用 Z 省 2022 年 1 月至 2023 年 6 月共 18 个月的真实历史数据进行销量预测和库存控制, 结果表明: 该预测模型对畅销品规的平均相对预测误差为 3.5%, 显著优于 ARIMA (20.0%) 和 RBF 神经网络 (8.3%); 该库存控制方法对某地市前置仓不同时期 3 项卷烟移库指标(平均库存、运输车次、入库量标准差)均低于传统的存销比控制方法, 平均分别下降了 24.21%、36.84%和 9.93%。

关键词: 卷烟物流; 销量预测; 库存控制; 多层感知机; 大语言模型; 模型预测控制

0 引言

卷烟市场的销量预测与一般快消品销量预测有显著不同的特点。卷烟销量并非单纯由市场自然需求、自发生成, 而是在计划管理与投放调控机制下被持续塑形的经营结果: 商业公司通常依据年度、半年度经营目标形成销售计划, 并按品牌、规格、区域与渠道逐级分解到月度乃至周度; 在执行层面, 烟草商业公司在供给能力、可供货量、订货与投放节奏、价格与结构管控要求、库存结构(商业库、共库、前置仓、客户库存)及阶段性计划完成进度等约束下, 对每周投放量、发货节奏和区域倾斜进行动态调配。因此, 历史销量数据同时包含了市场需求信号与专卖策略信号, 既可能来自真实需求变化, 也可能来自控货、缺货、保价、结构优化、冲刺达成等经营动作, 再叠加元旦、春节等节令窗口销量集中释放, 卷烟销量曲线具有强烈的“周期性+节令性+策略性”特征。传统的

卷烟销量预测以数据驱动类方法为主, 大致可分为基于统计回归^[1]、基于时间序列^[2]、基于神经网络^[3]、基于机器学习^[4]、基于深度学习^[5]等模型的方法。上述不同的卷烟销量预测方法各有优劣: 统计回归模型和时间序列模型简单方便, 但难以应对季节性变动、长期趋势以及政策因素; 机器学习类模型能有效处理非平稳、非线性数据, 但容易陷入参数敏感性、局部最优及过度拟合等问题, 模型泛化能力不强; 包括深度学习在内的神经网络类方法需要大量训练数据且收敛慢且模型难以反映动态变化规律。因此, 若仅依赖历史销量数据进行外推, 传统预测模型虽然能拟合部分周期规律, 但难以显示表达政策指令、计划分解、投放节奏、库存守恒与供给约束等关键的非单纯市场机制, 容易在节令窗口、计划调整期、供给紧张期出现结构性偏差。近年来, 出现了很多组合预测方案^[6-8], 即根据不同方法的优势和特点把两种或多种方法相结合进行卷烟销量预测, 克服了单一模型的局限性。本文将

基金项目: 中国烟草总公司重点研发项目“基于智慧物流的工商供应链一体化研究”(110202202043)

作者简介: 崔建华(1965—), 高级经济师(副高级), 主要研究方向为烟草产业链供应链一体化、卷烟商业领域企业管理、销售物流等, Email: cuijh@zjyc.cn

通讯作者: 刘冬荣(1984—), Tel: 0577-88660198, Email: liudr@zjyc.cn

收稿日期: 2025-04-25; 网络出版日期: 2026-04-08

深度学习的MLP^[9]与AI技术的LLM^[10]相结合进行卷烟销量的智能预测,建立了面向卷烟需求预测场景的“数据预测+决策耦合”卷烟销量预测模型。在此基础上,本文将该卷烟销量预测模型应用于卷烟物流供应链的库存控制中,基于模型预测控制^[11]提出了递阶DMPC方法,降低了卷烟库存和提高了卷烟配送运输效率。

2 基于MLP和LLM相结合的卷烟销量预测模型

2.1 “MLP主导、LLM辅助”的卷烟销量预测建模策略

基于烟草行业的业务特点,卷烟销量预测具有明

确的“数据预测+决策耦合”特征:一方面要通过市场数据预测稳定可用的未来定长(例如未来一周)销量基线,作为补货计算与计划对齐的统一参照;另一方面要把年度/半年度计划分解、阶段达成率约束以及品牌投放调配对销量形成的影响显式纳入预测链路;两者共同作用使预测结果能够真实反映烟草经营“市场主导、计划驱动、策略调控、供给约束”的运行方式。为此,本文将MLP与LLM相结合,提出了“MLP主导、LLM辅助”的卷烟销量预测方法,如图1所示。




图1 “MLP主导、LLM辅助”的卷烟销量预测方法

Fig. 1 Framework for cigarette sales forecasting method combining MLP and LLM

“MLP主导、LLM辅助”的卷烟销量预测方法的核心是MLP模型和LLM模型的相互结合。由于卷烟销量预测既要求结果精确、稳定、可直接进入补货计算链路,又要求能够吸收计划分解口径、达成率压力、控量保价与重点规格策略等经营信息,单一模型很难同时满足上述两类要求。MLP模型擅长直接输出固定步长的数值序列,天然具备“精确、稳定、易对接”的优势,但对计划文本、策略口径、跨系统异构信息的融合能力不足;LLM模型具备多源信息理解与推理能力,能够模拟投放调配逻辑并给出可解释的校正依据,但若直接生成未来销量数值序列,容易出现输出长度不一致、格式漂移等风险。因此,采用“MLP模型产出定长基线+LLM模型生成校正方案+确定性执行器落地并做一致性校验”的组合分工,在不牺牲可用性的前提下,将真实销售决策过程显式纳入预测

链路。

2.2 “MLP主导、LLM辅助”的卷烟销量预测模型

图1中,“业务输入层”是全链路的数据与规则入口,作用是把分散在商业经营、仓配物流与计划管理系统中的关键要素按统一口径汇聚、对齐与结构化,形成后续模块可直接调用的“输入包”;“约束融合输出层”是预测指令校正落地与一致性检验的执行模块,用于把“MLP主导、LLM辅助”的卷烟销量预测转化为最终可执行的协同预测结果。而基于MLP的“基线预测层”和基于LLM的“策略校正层”是整个模型的核心。

(1)基线预测层负责产生实际可用的定长数值基线,是整个链路中对接补货计算的“硬输出”来源。在不引入当期策略再分配的前提下,基线预测层基于MLP模型(图2)输出未来固定H天(或H周)的基

线需求/基线销量序列 $\hat{y}_{t+1:t+H}^{base}$ (按品规维度可扩展为 $K \times H$ 的预测矩阵, K 为品规数量)。

a) 网络结构与前向传播: 设在同一地市(或区域)内共有 K 个卷烟品规, 在时刻 t 将销量历史窗口、计划与供给等结构化特征拼接为输入向量 $x_t \in R^d$ 。记第 0 层为输入层 $h^{(0)} = x_t$, 第 l 个隐藏层 ($l = 1, \dots, L-1$) 为 $h^{(l)} = \varphi(W^{(l)}h^{(l-1)} + b^{(l)})$, 其中 $W^{(l)}$ 、 $b^{(l)}$ 分别为权值矩阵与偏置向量, $\varphi(\cdot)$ 为非线性激活函数。输出层采用线性回归形式 $\hat{y}_{t+1:t+H}^{base} = W^{(L)}h^{(L-1)} + b^{(L)}$ 。为保证预测长度严格固定, 采用“多步长向量直接输出”而非逐步递推, 从机制上避免出现输出步长不一致。

b) 损失函数、正则化与输出端投影: 以监督学习方式构造样本对 $(x_t, y_{t+1:t+H})$, 采用均方误差 (MSE) 作为主损失函数: $J(\theta) = (1/N) \sum_{t \in D} \|y_{t+1:t+H} - \hat{y}_{t+1:t+H}^{base}\|_2^2 + \lambda \sum_l \|W^{(l)}\|_F^2$, 其中 $\theta = W^{(l)}, b^{(l)}$ 为模型参数, λ 为 L2 正则系数。针对节令窗口与供给扰动引入的异常点, 可将 MSE 替换为 Huber 损失以提升鲁棒性。为确保基线结果可直接用于补货计算, 输出端引入基础投影, 对预测值执行非负与必要的上下限裁剪: $\hat{y}^{base} \leftarrow clip(\hat{y}^{base}, 0, U^{base})$, 从而保证数值可用与格式稳定。

c) 参数优化与训练-预测流程 (图 3): 为将卷烟经营计划与供给约束以“可计算”形式植入基线预测, 样本构造与特征设计采用场景化扩展: 在时间粒度上以日(或周)为基本单位, 将销售、订发货、在途、库存、计划分解与达成率等数据对齐到同一时间轴; 在特征构造上以滑动窗口方式提取历史销量序列(长度为 L 的滞后窗口), 并拼接计划销售、计划生产、可供销量、库存结构、缺货/控量标记、节令窗口等结构化变量形成输入 x_t ; 标签 $y_{t+1:t+H}$ 为未来 H 步的实际销量, 用于监督训练。




图 2 基线预测层 MLP 模型结构

Fig. 2 MLP model structure for the baseline prediction layer

按上述原理构造的基线预测层实现了“多品规共享参数+定长多步向量输出+输出端投影”的功能组合: MLP 在同一网络内学习多个品规的共性波动模式(如周内周期、节令共振), 提升长尾品规在数据稀疏条件下的稳定性; 同时以向量直接输出保证预测步长严格固定, 并以投影机制保证预测值在有效的范围内, 从而实现可复现、可对接、可审计的基线预测。




图 3 基线预测层 MLP 模型流程

Fig. 3 Operating process of the MLP model for the baseline prediction layer

(2) 策略校正层基于 LLM 模型, 用于生成“如何从基线走向实际可执行结果”的校正方案, 其输出为结构化指令而非最终销量预测(销量预测结果由“约束融合输出层”获得)。该层以基线预测层 MLP 模型的基线预测序列 $\hat{y}_{t+1:t+H}^{base}$ 为输入基准, 同时读取业务输入层的计划分解口径、阶段达成率、供给能力与库存结构约束、节令窗口与重点策略等信息, 模拟围绕计划目标进行投放调配的逻辑, 输出结构化的校正指令包 u 。策略校正层输出指令通过约束融合输出层进行确定性变换得到候选校正序列 $\hat{y}_{t+1:t+H}^{cand} = clip(\alpha \odot \hat{y}_{t+1:t+H}^{base} + \beta, floor, cap)$ 并对 $\hat{y}_{t+1:t+H}^{cand}$ 执行企业规则与物理约束的一致性校验后, 得到带硬约束的可行化过程最小改动优化模型: $\hat{y}^{final} = argmin_y \|y - \hat{y}^{cand}\|_2^2, s.t. y \in F$, 其中 F 为企业规则与物理约束构成的可行域, 最终得到长度

严格为 H 的协同预测序列 $\hat{y}_{t+1:t+H}^{final}$ 。这里引入 LLM 模型的原因在于其具备多源信息理解、文本口径解析与跨维度约束推理能力，能够将“计划-达成率-库存供给-节令策略”等异构信息组织为可解释的决策线索。

较传统的产品销量预测类方法相比，“MLP 主导、LLM 辅助”的卷烟销量预测模型实现 MLP 和 LLM 的优势互补，将卷烟销量预测升级为“基线预测+校正决策+约束执行”的“预测+决策耦合”模式，主要技术优势包括：1) MLP 模型负责“定长与稳定”的数值基线输出，LLM 模型负责“多源信息融合与经营逻辑推理”的校正方案生成，并通过确定性约束执行器负责“可执行与可审计”的落地与一致性校验，从而同时满足烟草供应链系统对计划对齐、协同补货与风险可控的要求；2) 以 MLP 模型定长多步向量输出为硬基线，并通过输出端投影保证预测长度严格固定、格式稳定，通过裁剪机制保证数值合法可用（满足非负与基础上下限），可直接进入补货计算；3) 以“先基线、后指令、再执行”的执行路径完成：基线预测层给出固定周期的销量基线，策略校正层生成结构化校正指令并给出原因标签与优先级，约束执行器将校正指令落地为可行的最终预测与补货建议并生成审计记录，实现“预测结果-经营策略-补货动作”三者同口径联动。

2.3 基于递阶 DMPC 的卷烟物流供应链库存控制

卷烟物流供应链中智能仓储管理策略的核心是库存控制。结合当前卷烟物流供应链实行全面前置的实

际情况，构成了以烟草工业（烟厂）、集散式前置仓、直接式前置仓、各地市配送中心为核心节点的多层级、多节点供应链网络，卷烟移库过程库存控制呈现出强耦合（同一发货地各品规的拼载）、不确定性（卷烟销量与运输时长的不确定）和大迟滞（发起移库到实际入库的延迟）等特点，同时还存在针对输入、输出的众多约束条件（如移库量不能超出烟厂产能或销售计划量、库存量居于安全库存和库容上限间等），这对库存控制提出了极高要求，传统方法不再适用于类似全面前置这样复杂系统的库存控制任务。为此，本文提出基于递阶 DMPC 的卷烟供应链库存控制方法，它将卷烟供应链的全链库存控制问题分解为各集散式前置仓、各直接式前置仓、各地市配送中心的多个最优库存控制子问题，在优化调度层统一协调下由多个局部控制器独立或协同工作，每个控制器负责供应链网络的一部分，共同组成了递阶分布式库存控制的架构。这里，DMPC 构成包含库存输入输出模型、库存预测模型和移库优化控制模型，其中，卷烟销量预测结果被分解后作为移库请求量送入库存输入输出模型作为模型输入。

(1) 库存输入输出模型。库存输入输出模型如图 4 所示。其中，状态量 $DI(t)$ 和 $DB(t)$ 分别为直接式前置品规和集散式前置品规的 t 日库存量，输入量 $DIR(t)$ 、 $DBR(t)$ 为对应品规的 t 日发起的移库请求量，输出量 $DIC(t)$ 、 $DBC(t)$ 则为对应品规的 t 日出库量，下标 i, j 代表着某具体品规的编号。




图 4 库存输入输出模型

Fig. 4 Market inventory input-output model

鉴于移库操作存在时延特性，即从卷烟厂发起移库到实际入库存存在若干天间隔，因此某品规 t 日实际入库量 $DIR_i(t - \tau_i)$ 为 τ_i 天前的移库量，而变量 $DIR_i(t)$ 则为 t 日发起的移库量，最终会在 $t + \tau_i$ 日入库。

(2) 库存预测模型。在当日初始库存量、出库量

和入库量已知的情况下，可进行模型的单步预测，计算下一日的库存量。以某地市为例，假设有 a 个直接式前置品规， b 个集散式前置品规，其各品规下一日库存量的计算方法如式（1）所示。

$$\begin{bmatrix} DI_1(t+1) \\ \vdots \\ DI_a(t+1) \\ DB_1(t+1) \\ \vdots \\ DB_b(t+1) \end{bmatrix} = \begin{bmatrix} DI_1(t) \\ \vdots \\ DI_a(t) \\ DB_1(t) \\ \vdots \\ DB_b(t) \end{bmatrix} + \begin{bmatrix} DIR_1(t-\tau_1) \\ \vdots \\ DIR_a(t-\tau_a) \\ DBR_1(t-\tau) \\ \vdots \\ DBR_b(t-\tau) \end{bmatrix} - \begin{bmatrix} DIC_1(t) \\ \vdots \\ DIC_a(t) \\ DBC_1(t) \\ \vdots \\ DBC_b(t) \end{bmatrix} \quad (1)$$

创建库存状态向量 $\mathbf{x}(t)$ 、入库向量 $\mathbf{u}(t)$ 和出库向

示为式 (5)。

量 $\mathbf{f}(t)$ 如式 (2) - (4) 所示, 则模型的单步预测可表

$$\mathbf{x}(t) = [DI_1(t), \dots, DI_a(t), DB_1(t), \dots, DB_b(t)]^T \quad (2)$$

$$\mathbf{u}(t) = [DIR_1(t-\tau_1), \dots, DIR_a(t-\tau_a), DBR_1(t-\tau), \dots, DBR_b(t-\tau)]^T \quad (3)$$

$$\mathbf{f}(t) = [DIC_1(t), \dots, DIC_a(t), DBC_1(t), \dots, DBC_b(t)]^T \quad (4)$$

$$\mathbf{x}(t+1) = \mathbf{x}(t) + \mathbf{u}(t) - \mathbf{f}(t) \quad (5)$$

式中: $\mathbf{x}(t)$ 为所有品规在 t 日作业前的初始库存 未来 N 天的库存量 $\mathbf{x}(t+k)$, $k=1, 2, \dots, N$ 进行预测, 向量; $\mathbf{x}(t+1)$ 为 $t+1$ 日的初始库存向量, 同时可以理 如式 (6) 所示。解为所有品规在 t 日作业后的库存结算量。进一步对

$$\begin{aligned} \mathbf{x}(t+1) &= \mathbf{x}(t) + \mathbf{u}(t) - \mathbf{f}(t) \\ \mathbf{x}(t+2) &= \mathbf{x}(t) + \mathbf{u}(t) + \mathbf{u}(t+1) - \mathbf{f}(t) - \mathbf{f}(t+1) \\ &\vdots \\ \mathbf{x}(t+k) &= \mathbf{x}(t) + \sum_{i=0}^{k-1} \mathbf{u}(t+i) - \sum_{i=0}^{k-1} \mathbf{f}(t+i) \\ &\vdots \\ \mathbf{x}(t+N) &= \mathbf{x}(t) + \sum_{i=0}^{N-1} \mathbf{u}(t+i) - \sum_{i=0}^{N-1} \mathbf{f}(t+i) \end{aligned} \quad (6)$$

(3) 移库优化控制模型。设某地市配送中心共管理 m_1 个直接式前置品规, m_2 个集散式前置品规, 以各品规的未来入库量 $\mathbf{u}(t+k)$ 为决策变量如式 (7), $k=0, 1, 2, \dots, N-1$, 对所有品规未来 N 天的库存进行

预测和控制。假设各品规的初始库存 $\mathbf{x}_0$ 、历史入库量 $DIR_{i,j}, DBR_{i,j}$ 和未来出库量 $\mathbf{f}_k$ 已知, 可根据式 (6) 预测未来库存情况如式 (8) 所示。

$$\mathbf{u}(t+k) = [DIR_1(t-\tau_1+k), \dots, DIR_{m_1}(t-\tau_{m_1}+k), DBR_1(t-\tau+k), \dots, DBR_{m_2}(t-\tau+k)]^T \quad (7)$$

$$\begin{cases} \mathbf{x}(t) = \mathbf{x}_0, \\ \mathbf{f}(t+k) = \mathbf{f}_k, k=0, 1, \dots, N-1, \\ DIR_i(t+j) = DIR_{i,j}, i=1, 2, \dots, m_1, j=-\tau_i, -\tau_i+1, \dots, -1, \\ DBR_i(t+j) = DBR_{i,j}, i=1, 2, \dots, m_2, j=-\tau, -\tau+1, \dots, -1, \\ \mathbf{x}(t+k) = \mathbf{x}(t) + \sum_{i=0}^{k-1} \mathbf{u}(t+i) - \sum_{i=0}^{k-1} \mathbf{f}(t+i), k=1, 2, \dots, N \end{cases} \quad (8)$$

根据前置仓运行的业务特点, 除式 (8) 的状态转移方程外, 优化命题的其他各项硬约束条件包括:

(1) 各品规库存量上下限约束: 高于安全下限值, 低于库容上限值。

$$ss \leq \mathbf{x}(t+k) \leq cp, k=1, 2, \dots, N \quad (9)$$

(2) 各品规移库量上下限约束: 前置仓申请的移库总量不能超出半年度或年度销售计划。

$$\begin{cases} DIR_i(t+j) \geq 0, i=1,2,\dots,m_1, j=0,1,\dots,N-\tau_i-1, \\ DBR_i(t+j) \geq 0, i=1,2,\dots,m_2, j=0,1,\dots,N-\tau-1, \\ \sum_{j=0}^{N-\tau_i-1} DIR_i(t+j) \leq pl_{DI_i}, i=1,2,\dots,m_1, \\ \sum_{j=0}^{N-\tau-1} DBR_i(t+j) \leq pl_{DB_i}, i=1,2,\dots,m_2 \end{cases} \quad (10)$$

$$\begin{cases} \left(\sum_{k=0}^{n_j-1} \sum_{i \in Z_j} DIR_i(t+k) + d_j^- - d_j^+ \right) - EB_j \times b_j = 0, j=1,2,\dots,a, \\ \left(\sum_{k=0}^{n_j-1} \sum_{i \in DC_j} DBR_i(t+k) + d_j^- - d_j^+ \right) - EB_j \times b_j = 0, j=a+1,a+2,\dots,a+b, \\ d_j^-, d_j^+ \geq 0, j=1,2,\dots,a+b, \\ b_j \in \mathbb{N}, j=1,2,\dots,a+b \end{cases} \quad (11)$$

式中, d_j^- 和 d_j^+ 分别代表所有品规多日总移库量与运输满载量的负偏差和正偏差, 因为总移库量不总是等于满载量, 为保证命题可解, 需要表示此偏差。

最后, 完成优化命题目标函数的构造。库存周转率是衡量库存管理效果的重要指标, 高周转率意味着能快速转化库存为收入。此外, 通过每次移库时尽可能提高运输车辆的满载率、降低运输成本也是一个重要目标。建立优化目标如下:

$$\min \lambda_1 \frac{\sum_{k=1}^N x(t+k)}{N \cdot \sum_{k=0}^{N-1} f(t+k)} + \lambda_2 \sum_{j=1}^{a+b} [d_j^- + d_j^+] \quad (12)$$

(3) 各品规移库量的拼载约束: 前置仓模式的一大优势是对同一发货地各品规卷烟进行以车辆满载为目标的拼载运输, 使得减少总运输批次、降低运输成本。移库拼载约束如式 (11)。

3 测试验证

面向 Z 省 11 个地市和 1 个集散中心, 测试周期为 18 个月 (2022 年 1 月—2023 年 6 月), 测试期间内的验证数据为真实历史数据。以 Z 省 H 市畅销卷烟品规 672 为例, 采用本文卷烟销量预测模型的一步预测结果如图 5 所示, 平均相对预测误差 3.5%。另外, 与典型的时间序列模型 ARIMA 和径向基神经网络模型 RBF 进行比较, 结果如表 1 所示。




图 5 卷烟品规 672 的销量预测结果 (上: 实际数据 vs. 预测数据, 下: 预测相对误差)

Fig. 5 The predicted results for sales of cigarette brand A (upper: True Data vs. Pred. Data, down: Relative Errors)

表 1 不同预测模型比较结果
Tab. 1 Comparison results of different prediction models

模型类型	平均相对预测误差 (预测时长 1 天) /%	平均相对预测误差 (预测时长 10 天) /%
ARIMA	20.00	23.98
RBF	8.30	14.59
本文模型	3.50	5.00

进一步进行 DMPC 应用测试。仍采用第 2.3 节 18 个月数据，并在同一时期内同时运用基于存销比的传统库存控制进行方法对比。首先以 Z 省 N 市单一地市为例，以 6 个月为 1 个周期，将数据分为第 1、2、3 期，对直接式前置仓运行的各项数据进行统计和分析，结果见表 2。可见，本文库存控制方法在各时期内的指标均低于存销比控制方法，分别下降了 24.21%、36.84%和 9.93%。

表 2 测试周期内前置仓各时期的运行数据
Tab. 2 Operating data of the front-loaded warehouse for each period during the test cycle

指标	时期	存销比	本文方法	下降幅度/%
平均库存/件	第 1 期	49 594.02	34 148.74	31.14
	第 2 期	35 569.85	29 636.47	16.68
	第 3 期	37 883.31	29 741.39	21.49
	合计	41 249.86	31 261.52	24.21
运输车次/车	第 1 期	573	361	37.00
	第 2 期	652	408	37.42
	第 3 期	532	366	31.20
	合计	1 797	1 135	36.84
入库量标准差	第 1 期	6 550.53	6 055.53	7.56
	第 2 期	2 973.36	3 245.04	-9.14
	第 3 期	6 946.90	5 788.29	16.68
	合计	5 776.28	5 202.42	9.93

对全省所有地市两类前置仓库存控制测试验证。共涉及来自 Z 中烟、H 中烟和 S 中烟的 27 个直接式前置品规和 10 个集散式前置品规。结果如下：（1）对于同省 Z 中烟的所有直接式前置品规，各地市运输车次总量降幅为 29.97%。其中，Z 中烟各品规在 H 市的销售量最大，使得存销比模式也能从大批量运输中受益，所以 H 市的车次降低幅度为全省最小但也达到 17.39%；而对于销量较小且运输距离较远的 Q 市、L

市和 Z 市，本文方法对于运输经济性的提升非常显著，降幅分别为 45.80%、48.34%和 59.53%；（2）对于跨省 H 中烟的所有直接式前置品规，本文方法带来的运输经济性提升更为显著，即使在销量最大的 N 市，运输车次的降幅也达到 27.46%，全省运输车次总体降幅为 45.20%；（3）对于 S 中烟的所有集散式前置品规，运输车次总量降幅为 46.56%。

4 结论

（1）建立了“MLP 主导、LLM 辅助”的卷烟销量预测模型，通过 MLP 和 LLM 优势互补将卷烟销量预测升级为“基线预测+校正决策+约束执行”的“预测+决策耦合”模式，实现了“先基线、后指令、再执行”的执行路径。测试验证结果表明：对畅销品规的平均相对预测误差为 3.5%，显著优于 ARIMA(20.0%)和 RBF 神经网络(8.3%)。

（2）提出了递阶 DMPC 库存控制方法，将卷烟供应链的全局库存控制问题分解为多个子系统协同求解，尤其适合卷烟供应链多层次、多品规、强耦合、大迟滞应用场景，实现了多重约束下的动态库存决策。测试验证结果表明，该库存控制相较于传统存销比控制，平均库存、运输车次、入库量标准差 3 项指标平均分别下降了 24.21%、36.84%和 9.93%。

（3）本文提出的“MLP 主导、LLM 辅助”卷烟销量预测模型和递阶 DMPC 库存控制，已经在 Z 省得到了实际应用。数据统计表明，2024 年全年 Z 省烟草工商整体库存下降 6.35%，烟草工业运输成本下降 10%，烟草商业日均库存下降 38.1%。

参考文献

[1] MARTINEZ E, MEJIA R, PEREZ-STABLE E J. An empirical analysis of cigarette demand in Argentina[J]. Tobacco Control, 2015, 24(1): 89-93.

[2] 康静, 姚春玲. Prophet-VAR 组合优化模型在高值卷烟销量预测中的应用[J]. 中国烟草学报, 2023, 29(1): 127-134.

KANG Jing, YAO Chunling. Application of Prophet-VAR combined optimization model in predicting sales of high-priced cigarettes[J]. Acta Tabacaria Sinica, 2023, 29(1): 127-134.

[3] 齐志成. 基于 BP 神经网络模型的商洛市卷烟需求预测[J]. 湖南农业科学, 2017, (1): 86-89.

QI Zhicheng. Cigarette demand forecasting based on BP neural network model in Shangluo[J]. Hunan Agricultural Sciences, 2017, (1): 86-89.

[4] 武牧, 林慧苹, 李素科, 等. 一种基于支持向量机的卷烟销量预测方法[J]. 烟草科技, 2016, 49(2): 87-91.

WU Mu, LIN Huiping, LI Suke, et al. An SVM-based method for predicting cigarette sales volume[J]. Tobacco Science & Technology, 2016, 49(2): 87-91.

- [5] 邓超, 刘颂, 王露笛, 等. 基于深度神经网络的卷烟智能投放模型构建方法[J]. 烟草科技, 2021, 54(02): 78-83.
DENG Chao, LIU Song, WANG Ludi, et al. Modeling for intelligent cigarette release based on deep neural network[J]. Tobacco Science & Technology, 2021, 54(02): 78-83.
- [6] 吴明山, 王冰, 起亚宁, 等. 卷烟销量组合预测模型研究[J]. 中国烟草学报, 2019, 25(3): 84-91.
WU Mingshan, WANG Bing, QI Yaning, et al. Research on combined forecasting model for cigarette sales volume[J]. Acta Tabacaria Sinica, 2019, 25(3): 84-91.
- [7] 蒋兴恒. 基于分解集成思想的复杂卷烟销量时间序列预测模型研究[J]. 中国烟草学报, 2025, 31(5): 138-145.
JIANG Xingheng. Research on time series prediction model of complex cigarette sales based on decomposition ensemble idea[J]. Acta Tabacaria Sinica, 2025, 31(5): 138-145.
- [8] 赵旻, 张丹枫, 曾中良, 等. 基于组合模型的云南省卷烟需求预测与结果评价研究[J]. 中国烟草学报, 2019, 25(1): 93-98.
ZHAO Min, ZHANG Danfeng, ZENG Zhongliang, et al. Prediction of cigarette demand in Yunnan province based on combination model and criteria of result evaluation[J]. Acta Tabacaria Sinica, 2019, 25(1): 93-98.
- [9] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Association for the Advancement of Artificial Intelligence (AAAI), 2023, 37(9): 11121-11128.
- [10] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [11] FU D, ZHANG H T, DUTTA A, et al. A cooperative distributed model predictive control approach to supply chain management[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2019, 50(12): 4894-4904.

Research on the construction and application of an MLP-dominated cigarette sales forecasting model

CUI Jianhua, CHEN Hao, LIU Dongrong*

Zhejiang Tobacco Monopoly Administration, Hangzhou 310001, China

Abstract: Cigarette market sales exhibit strong cyclical, seasonal, and strategic characteristics, making it difficult for traditional forecasting models to capture the impact of key non-market factors such as policy directives, supply plans, delivery rhythms, inventory balance, and monopoly regulations. To address this, this paper combines a Multi-Layer Perceptron (MLP) with a Large Language Model (LLM) and proposes a combined forecasting model for cigarette sales characterized by “MLP dominance and LLM assistance”. In this framework, the MLP excels at modeling natural data patterns, while the LLM provides capabilities for multi-source information understanding and reasoning. Based on this forecasting model, the study further applies it to cigarette inventory transfer strategies and proposes a dynamic optimal control method for cigarette logistics supply chain inventory based on hierarchical Distributed Model Predictive Control (DMPC). Using real historical data from Province Z covering the 18-month period from January 2022 to June 2023, the sales forecasting and inventory control are evaluated. Results show that the proposed forecasting model achieves a mean relative prediction error of 3.5% for fast-selling stock-keeping units, significantly outperforming ARIMA (20.0%) and the RBF neural network (8.3%). Furthermore, the proposed inventory control method outperforms the traditional inventory-to-sales ratio approach across three cigarette inventory transfer indicators (average inventory, number of transport trips, and standard deviation of inbound volume) in a front warehouse of a prefecture-level city during different periods, achieving average reductions of 24.21%, 36.84%, and 9.93%, respectively.

Keywords: cigarette logistics; sales forecasting; inventory control; Multi-Layer Perceptron; Large Language Model; model predictive control

*Corresponding author. Email: liudr@zjyc.cn