

经济与管理

蒋兴恒. 基于分解集成思想的复杂卷烟销量时间序列预测模型研究[J]. 中国烟草学报, 2025, 31(5): 138-145. JIANG Xingheng. Research on time series prediction model of complex cigarette sales based on decomposition-ensemble idea[J]. Acta Tabacaria Sinica, 2025, 31(5): 138-145. doi:10.16472/j.chinatobacco.2024.T0324

基于分解集成思想的复杂卷烟销量时间序列预测模型研究

蒋兴恒

安徽中烟工业有限责任公司技术中心, 合肥市高新区永和路 399 号 230601

摘要: 本文提出一种基于集合经验模态分解 (EEMD) 的分解集成预测框架, 通过自适应参数优化将原始销量序列分解为多尺度本征模态函数 (IMF) 分量, 并针对各分量特性匹配 ARIMA、门限回归及 LM-BP 神经网络模型进行预测, 最终集成各分量的预测结果。实证研究表明, 该方法对黄山、中华、云烟等品牌的预测均方根误差 (RMSE) 较传统方法降低 70.73%~80.23%, 通过对比, 对原时间序列分解集成方法的预测精度大于一般整体预测精度, 适用范围更加广泛。并通过对不同时段利群、黄鹤楼和芙蓉王品牌的销量预测, 进一步证明了该方法的适用性。本研究为复杂时间序列预测提供了方法论创新与实践参考。

关键词: 卷烟销售; 分解; 集成; 预测

卷烟销量预测准确性的提升, 不仅能在日常管理中优化资源配置, 提升运营效率, 还能够为预警机制提供精准的数据支撑, 确保面对市场波动时能够迅速反应。目前关于产品销量等时间序列的预测方法大致可以分为 3 类: ①基于时间序列的数据特征, 运用传统的计量经济学方法构建预测模型。这类方法通过对历史数据的深入分析, 挖掘数据间的潜在规律, 并据此建立数学模型预测未来销量。葛娜等^[1]基于传统的计量经济模型对产品销量进行预测, 为制定销售战略和产业布局提供依据。②借助神经网络等机器学习方法构建预测模型。利用计算机模拟人脑神经网络的运作方式, 自动识别数据中的复杂模式, 从而实现准确预测。陈尚林^[2]利用基于 LSTM 神经网络和百度指数对新能源汽车销量进行了预测。③将传统计量方法与神经网络相结合, 以提高预测准确性。这种方法融合了这两种方法的优点, 既能够保留传统计量方法对数据特征的深入挖掘能力, 又能够借助神经网络强大的模式识别能力来捕捉数据中的非线性关系。吴明山等^[3]选择 ARIMA 模型、基于梯度下降算法的 BP 神经网络模型、基于 LM 算法改进的 BP 神经网络模型等方法对卷烟数据进行了预测。

上述不同的预测模型具有各自的优劣势: 传统计量模型的函数形式是固化的, 其对符合条件的时序数

据具有较高的预测精度, 但与实际情况中绝大部分数据的非平稳性、非线性等复杂的数据特征相悖。机器学习在非平稳、非线性数据的研究中, 也容易陷入参数敏感性、局部最优及过度拟合等弊端。同时, 前述预测方法无法实现从更细化的维度对时间序列进行分析。原始时间序列数据受到季节性变动、长期趋势以及随机波动等多种因素的共同作用, 可能会掩盖时间序列中的某些重要信息。如果能够从更精细化的维度去分析时间序列, 就有可能提高预测的精度和效果。鉴于此, 本文将采用分解集成的研究思路, 构建“分解-分项建模-集成”的卷烟销量预测框架, 对原始时间序列数据从更细化的维度分析, 揭示时间序列数据背后的复杂动态, 以提升预测的准确性和有效性。

本文创新点在于: ①提出 EEMD 参数自适应优化方法, 用于卷烟销量分解; ②构建“分解-分项建模-集成”的卷烟销量预测框架, 综合线性与非线性模型优势, 构建分量数据预测模型。

1 分析方法

本研究所构建的分解集成分析框架遵循“分解-分项建模-集成”的方法体系, 其核心流程包含 3 个关键阶段:

第一阶段, 采用自适应集合经验模态分解 (EEMD)

作者简介: 蒋兴恒 (1982—), 硕士研究生, 高级统计师, 主要从事经济数据分析等, Tel: 1386693805, Email: 66903003@qq.com

收稿日期: 2024-08-27; **网络出版日期:** 2025-06-05

将原始时间序列分解为不同的模态分量。EEMD 算法通过引入服从正态分布的随机白噪声,克服传统 EMD 的模态混叠缺陷,获得不同周期的本征模态函数 (IMF) 集合:

$$X(t)=\sum_{j=1}^n C_j+r_n \quad (1)$$

其中分量 C_j 表示第 j 次分解的 IMF 分量, r_n 为趋势项^[4-6]。

第二阶段,针对 IMF 分量特征建立双维度检验机制,构建预测模型。采用 ADF 单位根检验评估分量的平稳性,运用 BDS 检验识别分量的线性特征^[9]。基于检验结果实施差异化建模。

对于平稳线性序列,使用 ARIMA (p,d,q) 等方法建模。

ARIMA (p,d,q) 模型通过差分处理 (d 阶) 实现序列平稳化,其预测方程为:

$$(1-\sum_{i=1}^p \phi_i L)(1-L)^d y_t=(1+\sum_{i=1}^q \theta_i L)\varepsilon_t \quad (2)$$

式中 L 为滞后算子, ϕ_i 、 θ_j 分别为自回归和移动

平均系数, ε_t 为白噪声序列。

对于非平稳非线性序列,使用门限回归、Levenberg-Marquardt 算法改进的 BP 神经网络等方法建模预测。

其中,SETAR 模型基于门限机制建立的分段线性回归^[7],其表达方程为:

$$y_t=a_0+a_1 y_{t-1}+\cdots+a_p y_{t-p}+\varepsilon_t, y_{t-d} \geq \tau \quad (3)$$

$$y_t=\beta_0+\beta_1 y_{t-1}+\cdots+\beta_q y_{t-q}+\theta_t, y_{t-d} < \tau \quad (4)$$

式中 y_{t-d} 是门限,在门限的两边,序列 y_t 呈现出两种不同的自回归过程。

Levenberg-Marquardt 算法改进的 BP 神经网络,其表达式为:

$$x_{k+1}=x_k-\left[J^T J+\mu I\right]^{-1} J^T e \quad (5)$$

式中为雅克比矩阵, μ 为阻尼因子,是网络误差向量。该算法通过动态调整 μ 值实现梯度下降法与高斯-牛顿法的自适应切换,在保证收敛精度的前提下提升训练速度^{[8][10]}。

前述预测方法均有相对优势,同时也有一定的局限性,具体如表 1 所示。

表 1 预测模型优势和局限性对比表

Fig.1 Comparison table of advantages and limitations of prediction models

预测模型	优势	局限性
ARIMA 模型	能够有效地捕捉数据的长期趋势和季节性变化。	对数据要求高,需要时间序列数据是平稳的或者通过差分后变得平稳;对异常值敏感。
门限回归模型	适用于各种类型的数据集,无论是截面数据还是面板数据。同时能够有效捕捉变量之间的非线性关系,提供更准确的预测和分析结果。	门限回归模型以单一变量的变化作为门槛值的划分标准,但是实际经济活动中,门槛值可能涉及多个变量。
BP 神经网络	具有较强的非线性映射能力、高度自学习和自适应能力,也具有一定的容错能力。	学习和预测过程不透明,无法输出明确的方程模型,并且对初始网络权重敏感,往往会收敛于不同的局部极小点,易出现过拟合等现象。

第三阶段,集成各分量预测结果重构最终预测值。该框架通过多尺度分解并有效提取序列特征分别建

模,构建了“分解-检验-适配-集成”的优化路径,显著提升了预测模型的适应性。具体流程如图 1 所示。




图 1 分解、集成预测方法思路图

Fig.1 Decomposition and integration prediction method

2 实证分析

2.1 数据来源与预处理

数据范围：选取 2009 年 6 月—2019 年 5 月，黄山、中华和云烟月度销量数据，以及 2019 年 1 月—2024 年 11 月，利群、黄鹤楼和芙蓉王的月度销量数据。

数据划分：将 2009 年 6 月—2019 年 1 月的黄山、中华和云烟销量数据作为训练集，2019 年 2—5 月的数据为测试集。使用 2019 年 1 月—2024 年 7 月的利群、黄鹤楼和芙蓉王的销量数据为训练集，2024 年 8-11 月数据为测试集。

数据特点：本文重点分析黄山、中华和云烟 3 个品牌。其中黄山品牌销量规模中等，可以反映较多品牌销量的变化规律；中华品牌作为行业销售收入较多的品牌，其销量数据具有单箱结构高的特点；云烟品牌销量规模较大，能够反映大销量品牌的一些特征。这 3 个品牌组合覆盖了烟草市场主要的规模梯度，可反映揭示行业共性规律。为进一步分析不同时段、不同品牌情况下所构建模型的适用性，对利群、黄鹤楼和芙蓉王 3 个品牌的销量也进行了预测。

2.2 对黄山、中华和云烟品牌销量的分解预测

2.2.1 EEMD 参数优化

EEMD 分解的完备性和计算效率依赖于添加的白噪声幅值 (Nstd) 和集合平均次数 (NE)，这两个参数一般都是根据“经验”来选取的，势必会出现因人而异的偏差。所以，参数能够自适应选择显得尤为重要。相关学者在此方面做了研究。Lei^[11]尝试了不同的噪声幅值，根据 Huang^[4]的建议及实验效果挑选合适的噪声幅值。Niazy^[12]使用相对均方根误差(RMSE)评价 EEMD 在不同水平的添加白噪声的性能。香港城市

大学的 Guo^[13]等利用相对均方根误差作为优化白噪声幅值的评价标准，提出了最优集合经验模式分解。赵乾坤等^[14]提出了基于最优参数选择的 EEMD 方法进行电能质量识别，选定最优参数来提取特征值。王晶^[15]在集合经验模式分解算法的基础上，提出了一种经验模式分解参数优化方法。

综合以上研究，本文使用同步确定 EEMD 两个参数最优化的自适应计算方法。对于添加不同噪声幅值的序列，评价 EEMD 的分解性能的优劣关键在于其主要信号成分是否与噪声、其它低相关序列成份分开。本文引入了均方根误差 (RMSE) 指标，用以评价不同噪声水平下的 EEMD 方法的性能。假设卷烟销量时间序列为 $x_0(k)$ ，应用 EEMD 方法处理销量序列，该序列被分解为多个 IMF 分量。选取与原始数据序列相关性最高的 IMF 分量，称为 $c_{\max}(k)$ ，其包含了原始序列的主要成分。其均方根误差为：

$$RMSE = \sqrt{\frac{\sum_{k=1}^N (x_0(k) - c_{\max}(k))^2}{N}}$$

RMSE 越小，说明所选的 $c_{\max}(k)$ 越接近原始序列，分解效果也就越差。然而，一定存在一个噪声值，使 RMSE 最大， $c_{\max}(k)$ 只包含原始序列的主要成分，并于噪声和其他无关的分量分开，这是理想的分解效果，对应的噪声幅值是最优的。

如图 2 所示，以黄山卷烟销量为例，通过遍历取值并绘制 RMSE 随参数变化的三维曲面图可以发现，在 Nstd 取值从 0.1 到 0.5，NE 取值从 100 到 800 时，最优的 Nstd=0.45，最优的 NE=150，此时 RMSE 的最大值。




图 2 Nstd 和 NE 对 RMSE 的影响图
Fig.2 The impacts of Nstd and NE on RMSE

从二维 Nstd 与 RMSE 的关系图也可观察到，当 NE=150 时，Nstd=0.45 时，RMSE 取得最大值 1.66。




图 3 Nstd 与 RMSE 的关系图
Fig.3 The impact of Nstd on RMSE

从二维 NE 与 RMSE 的关系图也可观察到，当 Nstd=0.45，NE=150 时，RMSE 取得最大值 1.66。




图 4 NE 与 RMSE 的关系图
Fig.4 The impact of NE on RMSE

综上，可知黄山品牌销量 EEMD 分解的最优参数值 Nstd=0.45，最优的 NE=150。使用上述方法，可以确定其它品牌的 EEMD 分解的最优参数值。

2.2.2 EEMD 分解结果分析

使用最优 EEMD 分解模型，可以得到所分析品牌

的销量模态分解分量及趋势项。以黄山品牌为例，经 EEMD 分解，黄山品牌的销量序列分解得到 6 个模态分量和 1 个趋势项。每一个模态分量代表不同时间尺度的变化，最下方的曲线是趋势项（详见图 5）。




图 5 黄山品牌本征模态函数分量 1-7

Fig.5 Intrinsic mode function components 1-7 of huangshan brand

图 5 显示，本征模态函数（IMF）各分量揭示了黄山品牌销量变化的多时间尺度特征。IMF1 呈现约 2.5 年的周期性波动，可能与市场需求或宏观经济因素相关；IMF2 显示约 2 年的震荡模式，反映市场中期动态；IMF3 表现出 1 年左右的短期波动，或与促销活动等短期因素有关；IMF4 的 2 年变率与 IMF2 的中期动态相呼应；IMF5 揭示约 5 年的长周期波动，或源于行业技术革新；IMF6 呈现 9 年超长周期，反映宏观经济环境周期性；IMF7 作为趋势项，表明销量保持稳健增长态势。

采用 EEMD 方法将黄山品牌销量序列分解为多个 IMF 分量，各分量累加值与原始序列的最大差值仅

0.0019，验证了分解的精确性。该方法实现了将复杂数据分解为具有独立动态特性的 IMF 分量和趋势项。

2.2.3 模态分量预测

在时间序列分析领域，通常基于一定的数据假设，其中最常见的是数据的平稳性和线性关系。基于前文介绍的分析方法，首先，判断本征模态函数分量数据的平稳性及是否为线性序列。其次，针对数据的不同特征，采取相应的预测方法。平稳且线性的分量采用 ARIMA 预测模型，其它分量经平稳处理后使用门限回归或 LM-BP 神经网络等模型分析预测。

综合上述分析，黄山、中华和云烟品牌销量的数据特征如表 2 所示。

表 2 黄山、中华和云烟品牌销量 EEMD 最优分解参数、IMF 分量及其预测方法

Tab.2 Optimal decomposition parameters, imf components and prediction methods of eemd for huangshan, chunghwa and yunyan brand sales

品牌	Nstd	NE	IMF 分量数	IMF 分量预测模型组合
黄山	0.45	150	7	ARIMA(2,1,1)+ SETAR+ SETAR+ ARMA(3,2)+ ARMA(4,3)+ ARMA(4,1)+ AR(2)
中华	0.50	150	7	SETAR+ SETAR+ SETAR+ AR(4)+ ARMA(4,1)+ ARMA(3,2)+ AR(3)
云烟	0.45	150	7	SETAR+ SETAR+ SETAR+ ARMA(4,1)+ AR(5)+ AR(4)+ AR(2)

2.2.4 结果分析

通过对本征模态函数分量的分析, 针对每个分量

的不同数据特征, 构建了相应的预测模型, 实现对每个分量的精准预测 (详见表 3)。

表 3 黄山、中华和云烟品牌销量分解集成预测值对比表

单位: 万箱

Tab.3 Comparison table of decomposed-ensemble predicted values for huangshan, chunghwa and yunyan brand sales

序号	黄山品牌		中华品牌		云烟品牌	
	预测值	与实际值差值	预测值	与实际值差值	预测值	与实际值差值
117	9.29	-0.72	10.42	1.20	28.15	-0.14
118	9.74	-0.72	9.05	-0.08	28.07	-0.58
119	11.33	0.08	9.55	0.45	29.74	1.36
120	12.28	1.34	8.86	0.35	28.79	2.61

为了进一步验证分解集成方法的预测准确性, 对未分解的原销量数据构建模型进行预测, 并将预测结果与分解集成预测的结果进行对比。

为提高预测准确性并弥补单一模型的不足, 对原销量数据采用组合预测的方法, 即在构建 ARIMA 模

型的基础上, 进一步引入了基于 LM 算法改进的 BP 神经网络模型进行辅助预测。为了进一步提高预测精度, 对 LM-BP 神经网络的预测值进行 50 次模拟, 并将 50 次预测值的均值作为最终预测结果。

表 4 黄山、中华和云烟品牌销量 EEMD 分解及整体预测误差对比表

Tab.4 Comparison table of eemd decomposition and overall prediction errors for huangshan, chunghwa and yunyan brand sales

品牌	分解集成预测的均方根误差 RMSE	整体预测的均方根误差 RMSE	RMSE 降幅/%	p 值 (配对 t 检验)
黄山	0.84	2.87	70.73	0.008
中华	0.67	3.39	80.23	0.000
云烟	1.51	5.17	70.79	0.000

注: 基于中心极限定理, 为满足样本均值分布的正态性等相关假设, 通常需要配对样本量不小于 30 对 ($n \geq 30$)。由于样本量 (预测值) 较小 ($n=4$), 直接进行配对 t 检验的相关假设难以满足。为此, 本研究采用 Bootstrap 重抽样方法, 通过有放回地抽取 4 对原始数据生成 30 组伪样本, 探索差异均值的分布特性^[16]。

由表 4, 黄山、中华和云烟品牌基于分解集成方法预测的销量均方根误差 RMSE 分别为 0.84、0.67 和 1.51, 表明分解集成方法在预测黄山品牌销量方面具有较高的精度。

与分解集成模型的预测值相比, 黄山品牌销量整体预测的均方根误差 (RMSE) 为 2.87, 这意味着在预测未来 4 个月的销售情况时, 平均误差将达到 2.87 万箱。这一误差明显大于使用 EEMD (经验模态分解) 方法的预测误差 0.84。这说明原始销售数据的整体预测误差相对较大, 分解集成方法显著降低预测误差 (RMSE 降幅 70.73%), 分解集成模型在提高预测精度方面具有更好的优势。

中华品牌销量的整体预测均方根误差为 3.39, 这意味着在预测未来 4 个月的销量时, 平均误差将达到 3.39 万箱。对数据进行分解后再进行预测集成的均方根误差降至 0.67, 表明预测未来 4 个月的平均误差为 0.67 万箱, 均方根误差 (RMSE) 降幅 80.23%, 预测精度明显提高。

云烟品牌销量整体预测的均方根误差为 5.17, 对数据先分解再整体预测的均方根误差降至 1.51、降幅 70.79%。进一步验证了数据分解在提升预测精度方面的有效性。

通过对中华品牌、云烟品牌和黄山品牌销量数据的 EEMD 分解预测, 发现分解后的各模态数据更易于捕捉其内在规律, 提高了预测的准确性。相比之下, 对整体的预测往往难以捕捉数据的复杂变化规律, 导致预测误差较大。

3 讨论

通过对中华品牌、云烟品牌和黄山品牌销量数据的 EEMD 分解预测及整体预测结果对比, 验证了先采用 EEMD 分解后预测的方法在提高预测准确性方面的优势。为了进一步说明该方法对于不同时间段、不同品牌的适用性, 使用 2019 年 1 月—2024 年 7 月利群、黄鹤楼和芙蓉王的月度销售数据, 构建分析模型, 预测 2024 年 8—11 月这 3 个品牌的销售情况。

表 5 利群、黄鹤楼和芙蓉王品牌销量 EEMD 分解及整体预测误差对比表

Tab.5 Comparison table of eemd decomposition and overall prediction errors for liqun, yellow crane tower and furongwang brand sales

品牌	分解集成预测的均方根误差 RMSE	未参与分解集成预测的均方根误差 RMSE	RMSE 降幅/%	p 值 (配对 t 检验)
利群	0.77	1.51	49.00	0.032
黄鹤楼	0.83	2.97	72.05	0.000
芙蓉王	0.73	1.03	29.13	0.040

经过计算，经 EEMD 分解后，利群、黄鹤楼和芙蓉王的预测销量均方根误差（RMSE）的平均降幅超过了 50%，且预测精度的提升均具有统计学显著性，进一步验证了数据分解在提升预测精度方面的有效性。

本研究的分解集成预测方法不仅提升了卷烟销量预测精度，其成果也可转化为以下应用：一是供应链动态优化。基于分解模型的高频分量与趋势项预测，实现精准生产计划管理，保证市场需求。二是建立安全库存与动态预警机制。根据预测销量，结合预测误差的分布特性，构建动态安全库存模型。三是将分解得到的不同周期波动序列与宏观经济波动结合分析，可以探索分析主要宏观经济指标与趋势项及低频分量的相关关系。

4 结论

通过对不同时间段、不同卷烟品牌销售数据的分析，说明了采用 EEMD 分解再预测的方法在处理不同类型品牌销量数据时表现出较高的准确性和适用性。相比较其他预测方法，本文的预测方法具有以下主要优势：一是本文方法依据研究的样本数据特征，不限定其他特定条件，具有广泛的适用性；二是通过序列分解，将原本复杂的序列拆解为若干简单的子序列，从而有效降低了预测建模的难度；三是确保了各步骤建模过程的合理性、科学性和有效性，显著提高了模型的分析与预测性能。

总的来看，本文所采用的分解集成的预测思想，具有适用范围广、预测精度高等特点，但是这种方法更加成熟的运用，还需要不断地检验、完善与发展，以争取为卷烟销售预测领域带来更多的创新和突破。

参考文献

[1] 葛娜, 孙连英, 赵平, 等. 基于 ARIMA 时间序列模型的销售量预测分析[J]. 北京联合大学学报, 2018: 27-33.
GE Na, SUN Lianying, ZHAO Ping, et al. Sales volume forecasting analysis based on ARIMA time series model[J]. Journal of Beijing Union University, 2018: 27-33.

[2] 陈尚林. 基于 LSTM 神经网络和百度指数的新能源汽车销量预测——以比亚迪为例[D]. 2024, 03.

CHEN Shanglin. Forecasting sales volume of new energy vehicles based on LSTM neural network and baidu index — a case study of BYD[D]. 2024, 03.

[3] 吴明山, 王冰, 起亚宁, 等. 卷烟销量组合预测模型研究[J]. 中国烟草学报, 2019: 84-91.
WU Mingshan, Wang Bing, Qi Yanning, et al. Research on combined forecasting model for cigarette sales volume[J]. Acta Tabacaria Sinica, 2019: 84-91.

[4] Huang N E, Shen Z, Long S R, 1998. The empirical mode decomposition and the Hilbert spectrum for nonlinear and nonstationary time series analysis[J]. Proceedings of the Royal Society A, 454: 903-995.

[5] Wu Z, Huang N E, 2004. Ensemble empirical mode decomposition: a noise-assisted data analysis method[R], Centre for Ocean-Land-Atmosphere Studies, Technical Report, No. 193.51.

[6] 郑祖光, 刘莉红. 经验模态分析与小波分析及其应用[M]. 北京: 气象出版社, 2010: 1-83.
ZHENG Zuguang, LIU Lihong. Empirical mode decomposition and wavelet analysis and their applications[M]. Beijing: Meteorological Press, 2010: 1-83.

[7] 高铁梅, 王金明, 陈飞, 等. 计量经济分析方法与建模 eviews 应用及实例[M]. 北京: 清华大学出版社, 2016: 1-477.
GAO Tiejie, WANG Jinming, CHEN Fei, et al. Econometric analysis methods and modeling with eviews applications and examples[M]. Beijing: Tsinghua University Press, 2016: 1-477.

[8] 朱凯, 王正林. 精通 MATLAB 神经网络[M]. 北京: 电子工业出版社, 2010: 193-224.
ZHU Kai, WANG Zhenglin. Mastering MATLAB neural networks[M]. Beijing: Publishing House of Electronics Industry, 2010: 193-224.

[9] 杰弗里·M·伍德里奇. 计量经济学导论现代观点[M]. 2015: 511-529.
Jeffrey M. Wooldridge. Introductory econometrics: a modern approach[M]. 2015: 511-529.

[10] 蒋兴恒, 朱素蓉. 基于 Levenberg-Marquardt 算法改进 BP 神经网络的卷烟销量预测模型研究[J]. 中国烟草学报, 2011, 17(05): 81-86.
JIANG Xingheng, ZHU Surong. Research on cigarette sales volume prediction model based on improved BP neural network with levenberg-marquardt algorithm[J]. Acta Tabacaria Sinica, 2011, 17(05): 81-86.

[11] Lei Y, He Z, Zi Y. EEMD method and WNN for fault diagnosis of locomotive roller bearings[J]. Expert Systems With Applications, 2011, 38(6):7334-7341.

[12] Niazy R K, Beckmann C F, Brady J M, et al. Performance evaluation of ensemble empirical mode decomposition[J]. Advances In Adaptive Data Analysis, 2014, 01(02): 0900010.

[13] Guo W, Tse P W. A novel signal compression method based on optimal ensemble empirical mode decomposition for bearing vibration signals[J]. Journal Of Sound And Vibration, 2013, 332(2): 423-441.

- [14] 赵乾坤, 曹灵芝. 基于最优参数选择的 EEMD 方法的暂态电能质量扰动识别分类[J]. 计算机与数字工程, 2019: 1067-1071.
ZHAO Qiankun, CAO Lingzhi. Identification and classification of transient power quality disturbances based on EEMD method with optimal parameter selection[J]. Computer and Digital Engineering, 2019: 1067-1071.
- [15] 王晶. 经验模式分解参数优化算法研究与应用[D]. 广州, 2019.
- WANG Jing. Research and application of parameter optimization algorithm for empirical mode decomposition[D]. Guangzhou, 2019.
- [16] 陈磊. 应用统计学[M]. 北京: 中国纺织出版社, 2018: 112-150.
CHEN Lei. Applied Statistics[M]. Beijing: China Textile & Apparel Press, 2018: 112-150.

Research on time series prediction model of complex cigarette sales based on decomposition-ensemble idea

JIANG Xingheng

Anhui Zhongyan Industrial Co., Ltd., Technology Center, Hefei, 230601, China

Abstract: This study proposes a decomposition-integration forecasting framework based on an improved Ensemble Empirical Mode Decomposition (EEMD) method. By adaptive parameter optimization, the original sales series is decomposed into multi-scale Intrinsic Mode Function (IMF) components. ARIMA, threshold regression, and LM-BP neural network models are matched for prediction according to the characteristics of each component, and the prediction results of each component are finally integrated. Empirical research shows that the root mean square error (RMSE) of this method for the prediction of Huangshan, Chunghwa, and Yunyan brands is reduced by 70.73% to 80.23% compared with traditional methods. Through comparison, the prediction accuracy of the decomposed-ensemble method for the original time series is greater than the general overall prediction accuracy, and the applicable scope is wider. Furthermore, the applicability of this method is demonstrated by the sales forecast of Liqun, Yellow Crane Tower, and Furongwang brands in different periods. This study provides methodological innovation and practical reference for complex time series forecasting.

Keywords: cigarette sales; decomposition; ensemble; forecasting

*Corresponding author. Email: 66903003@qq.com

《烟草科技》2025 年第 9 期目次

· 烟草化学

以分配系数为指标分析卷烟中酯类单体香料的分配转移特征
..... 罗曾源, 付英杰, 张博莹, 等

GC-MS-O-双柱定性分析香紫苏精油的关键香气成分
..... 陈伟华, 刘子轩, 贾晓慧, 等

基于静电捕集的卷烟主流烟气烟碱气、粒相分布
..... 陈锴琦, 余晶晶, 郭吉兆, 等

· 烟草农学与生物学

烤烟氮肥利用率与生物碱组分含量的定量关系
..... 蔡民爵, 曾嘉楠, 黄瑞寅, 等

施用有机肥对重庆植烟土壤碳氮矿化的影响
..... 黄乐煜, 沈 铮, 赵东方, 等

调制过程中光照强度对晒黄烟叶品质的影响
..... 刘 璐, 史小军, 喻 杰, 等

· 烟草工艺

基于关键化学指标相似的上部烟叶模块配方数字化设计
..... 郝贤伟, 田雨农, 李石头, 等
卷烟感官评价指标敏感性的表征方法构建及对比分析
..... 杨佳东, 杨 露, 刘继辉, 等

· 设备与仪器

中高速包装机组多品规包装纸集中自动配送装置的设计
..... 张天奇, 李 辉, 康凯宁, 等
一种棒形制品装盘/盒装置的设计
..... 刘 恺, 汤治国, 孔方亮, 等
ZJ116B 型卷接机组施胶方式对预打孔接装纸细支烟的影响
..... 潘 著, 冯 忆, 裘雨灿, 等

· 信息技术与数据科学

基于多传感器融合 SLAM 的 AGV 自动装车导航系统设计
..... 周永光, 李晓彬, 梅海青, 等