

骆宇峰, 黄斌. 基于微调大语言模型的互联网卷烟消费评价文本分类研究[J]. 中国烟草学报, 2025, 31(5): 146-154. LUO Yufeng, HUANG Bin. Research on internet cigarette consumption evaluation text classification based on fine-tuning large language model[J]. Acta Tabacaria Sinica, 2025, 31(5): 146-154. doi:10.16472/j.chinatobacco.2024.T0387

基于微调大语言模型的互联网卷烟消费评价文本分类研究

骆宇峰, 黄斌

九江市烟草公司柴桑分公司, 江西省九江市柴桑区江州大道 332000

摘要: 本文旨在研究一种基于微调大语言模型的卷烟消费者评价文本分类方法, 以实现卷烟产品评论的精准分类。针对传统深度学习模型在处理互联网中文文本时面临的挑战, 本文设计了一种能够同时兼顾情感分类、主题分类和自然语言推理的人工智能模型。研究方法包括构建包含五类标签的数据集, 并采用监督微调和强化微调对大语言模型进行训练。实验结果表明, 该模型在测试集上 Micro F1 分数相比基础模型最大提升 26.72%, 有效地提高了对卷烟产品评论的分类准确率和灵活性。通过模型的运用可以帮助企业从互联网卷烟消费者评论中快速发现自身不足, 提高产品改进效率、优化市场策略, 在竞争激烈的市场中保持优势。

关键词: 烟草; 文本分类; 情感分析; 主题分类; 大语言模型; 深度学习

深度学习方法作为自动化探索非结构化文本背后观点的重要工具, 已被广泛应用于文本分类任务。准确提取产品评价内容的情感状态对于企业改进和提升具有重要作用。在传统文本分类情感分析研究^[1]中通常会任务分为情感分析、主题分类、自然语言推理等多个具体子任务^[2-5]进行单独研究。然而, 互联网是一个相对开放的环境, 用户评论内容往往是未经严格筛选的, 仅具备单一能力的模型无法使用于复杂的真实场景。

综合以上特点, 本研究尝试设计一种能够同时完成情感分类、主题分类和自然语言推理的人工智能模型, 以实现卷烟产品评论的精准分类。通过构建包含 5 类标签的数据集, 并采用监督微调和强化微调对大语言模型进行训练, 本研究旨在克服传统深度学习模型的不足, 提高对卷烟产品评论的分类准确率和灵活性。

1 数据与方法

1.1 数据来源

使用 requests 库对国内某卷烟产品评论网站中所

有国产卷烟产品评论数据进行采集, 具体涉及 111 个卷烟品牌, 2953 个产品规格, 117105 条评论。结合应用场景和多任务处理的需求, 通过文本描述分析, 将文本结构不完整或不符合任务主题的内容, 划入无产品评价语义分类; 通过自然语言推理分析, 将存在语义特征前后矛盾的内容, 划入讽刺(冲突)分类; 通过文本中情感倾向表现, 按不同程度分别划为正向、中性、负向类别, 任务与分类结果对应关系如图 1。

应用在线版本大语言模型 G 的 API (Application Programming Interface) 进行分类标注。标注后的数据按每个类别 50%: 50% 的概率随机抽样分为本次研究的训练集和验证集, 所有数据均保留其原始状态。其中包含“\xa0、\u3000”等无关语义的不间断空格符号, 也包含“doge、TM、FB”等重要情绪宣泄用语或拼音字母缩写, 同时还存在部分错别字的情况, 数据集中样本分布情况见表 1。




图 1 文本综合分类任务流程图
Fig.1 Flowchart of text comprehensive classification task

表 1 样本数据数量分布
Tab.1 Distribution of sample data quantity

分类	占比	样例
A 正向	35.60%	"可可的香味很迷人，烟气入后还算柔和，性价比高" "一直抽的三年的口粮"
B 负向	23.12%	"朋友给了一根，太 TM 难抽了" "吸完嘴里有一股怪怪的味道\xa0 本地人大多不吸这个都吸红旗渠"
C 中性	35.62%	"中规中矩的西北烟。" "一个信阳的哥们儿给的，包装平平无奇。烟气还算浓，马马虎虎。"
D 讽刺（冲突）	3.67%	"也不看看自己什么牌子就想往 FB 烟里上" "再贵也是 XX，有这钱上绿猫不好吗"
E 无产品评价语义	1.99%	"你是的"，"鞍山"，"000"

数据集中虽然存在较大的样本分布不均衡情况，但在真实的业务场景中，D 讽刺（冲突）与 E 无产品评价语义在总体样本中存在量确实远小于其他分类，因此，使用这样的数据集训练模型更具实际意义。

1.2 基础模型选择

相较于传统的循环神经网络模型，大语言模型（Large Language Models, LLMs）在大量语料库上进行了预训练，积累了丰富的语言知识和模式，在处理多义词和长依赖关系时表现出色。同时，应用注意力机制（Attention Mechanism）的神经网络结构使得模型在处理信息时能够聚焦于当前最为重要的部分。更大容量和更高表达能力，使得它们能够捕捉更复杂的模式和细微差异。在数据效率方面，大模型在少样本学习和零样本分类任务中表现出色，能够在标注数据有限的情况下取得良好的性能。

本研究以大模型 Q 的 7B 版本进行专项任务改进，其作为目前最强大的中文开源大模型之一，已经具备基础的自然语言推理能力^[6]，能够适配本研究需求，

模型架构如图 2。




图 2 模型整体架构图
Fig.2 Overall architecture diagram of the model

Q2_7B 是典型的单独解码器 (decode-only) 模型, 在原始的 transformer 模型^[7]解码器模块的基础上做了部分调整。掩码注意力机制公式为:

$$\text{Mask Attention} = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V \quad (1)$$

其中, Q 、 K 、 V 、 M 均为矩阵形式, 掩码矩阵 M 为严格上三角矩阵, 主对角线 (不含) 上方元素均为负无穷, 其余元素均为零, d_k 为缩放系数, 在多头注意力机制中代表每个头上处理数据的维度, 用于稳定模型梯度传递, 该模型中实际值为 128。

使用 RMSnorm (Root Mean Square Layer Normalization) 替换原有的归一化方式^[8], 去掉计算均值的步骤, 运算速度明显提升, 公式为:

$$\bar{a}_i = \frac{a_i}{\sqrt{\frac{\sum_{j=1}^n a_j^2}{n} + \epsilon}} \quad (2)$$

其中, ϵ 通常为随机数, 用于规避除 0 错误, 本研究中实际值为 $1e-6$ 。

使用分组注意力机制 (Grouped-query attention) 替换原始的多头注意力 (MQA)^[9], 在注意力分数计算中多个 query 使用同一组 key、value 进行计算, 降

$$g(x_m, x_n, m-n) = \begin{pmatrix} q_m^{(1)} & q_m^{(2)} \end{pmatrix} \begin{pmatrix} \cos((m-n)\theta) & -\sin((m-n)\theta) \\ \sin((m-n)\theta) & \cos((m-n)\theta) \end{pmatrix} \begin{pmatrix} k_n^{(1)} \\ k_n^{(2)} \end{pmatrix} \quad (3)$$

其中, m 、 n 分别代表两个 tokens 的绝对位置, q 、 k 为对应输入 x 的注意力分解值。

使用 SwiGLU 激活函数^[11]替换原始的 ReLU 激活函数。SwiGLU 是 Swish 激活函数与 GLU 门控线性单元的组合, 如图 4, 提升模型在不同长度文本环境下的推理精度。公式为:




图 4 SwiGLU 架构图

Fig.4 SwiGLU architecture diagram

低读取时数据加载量, 本研究中实际值为 7, 如图 3。




图 3 分组注意力架构图

Fig.3 Grouped attention architecture diagram

对 query、key 使用旋转位置编码 (RoPE, Rotary Position Embedding)^[10], 融合绝对位置编码和相对位置编码的优点, 更善于处理长文本序列。公式为:

$$\text{SwiGLU}(x, W_1, W_2) = \text{Swish}_\beta(xW_1) \otimes (xW_2) \quad (4)$$

$$\text{Swish}_\beta(x) = \frac{x}{1+e^{-\beta x}} \quad (5)$$

其中, W 为对应线性变换的可学习参数, β 为超参数, 本研究中实际值为 1。

1.3 多分类评估指标

本次研究中采用多分类模型领域常用的评测指标, Micro F1 分数用于评估模型在整体数据集上的性能情况。计算公式为:

$$\text{Precision} = \frac{TP}{TP+FP} \quad (6)$$

$$\text{Recall} = \frac{TP}{TP+FN} \quad (7)$$

$$\text{MicroF1} = \frac{2PR}{P+R} \quad (8)$$

2 实验验证和分析

2.1 提示词工程

提示词工程 (prompt engineering) 是大语言模型区别于其他模型的重要特征之一, 指在不对模型内部参数进行调整的情况下, 让模型仅根据不同的输入文本的内容, 就能完成不同任务需求的专有调试方式。

本研究通过模仿大语言模型在预训练中常用的提示词设计格式，分别从定义交互角色（Role），明确任务目标（Goal），确定任务文本（Context），限定输出

格式（Expectations）4 个方面进行提示词构建，格式如图 5。




图 5 提示词构成示意图
Fig.5 Schematic diagram of prompt composition

图中蓝色框选内容设计为任务复杂度控制项，在仅需简要回答需求时删除。绿色库框选内容为过拟合控制项，为保留模型泛化能力，在模型训练和测试时，会随机替换成近似语义内容，具体替换文件见附录 2。

经过提示词工程后，分别从是否需要说明理由、是否量化模型、模型超参数（hyper parameter）调整 3 个方面对测试集进行能力测试，评估指标使用 Micro F1 分数（average=macro），结果如表 2。可以发现通过使用适当的提示词引导，预训练模型本身已经有一定的识别能力，但整体精度上还有提升空间，其中通过不需要说明理由的简化回答的方式，能够大幅提升模型识别正确或规范答案格式的能力，通过量化模型在简化回答的情况下对模型整体推理结果影响较小，但大幅降低了模型消耗的算力资源，调整温度系数（temporary）对模型结果影响不大。

表 2 基础模型测试能力表	
Tab.2 Baseline model testing capability table	
模型参数	F1 Score/%
基础问答	60.86
简化回答	71.40
4bit 量化模型	71.78
温度系数 0.5	71.86
温度系数 0.3	72.16

如图 6，从各分类细分的角度考虑，图中 A-E 对应前文所述的 5 个分类，F 分类对应输出内容不符合预期，无法正确提取分类结果的情况。表中结果按行进行了归一化处理，主对角线结果与各分类召回率一致。通过观察可以发现，模型在需要说明理由的长文本输出的环境下，难以控制其输出结果格式，但相比其他条件的模型下，讽刺和无产品评价两个类别识别结果更准确。



图 6 基础模型具体分类结果混淆矩阵
Fig.6 Confusion matrix of specific classification results of the baseline model

2.2 模型监督微调

监督微调（Supervised Fine-Tuning）是提升大语言模型在特定领域能力的基础方法之一。通过前文研究可知，量化后的模型并未出现明显的能力劣化情况，故采用 QLoRA（Quant Low-Rank Adaptation）^[12] 的高效微调策略。以 LoRA 模型设计为基础，训练过程中冻结模型原始参数，并新增一条路径，如图 7，A、B 是两个较小的矩阵，用来保证参数更新在低秩的情况下运行，矩阵相乘后维度与原参数维度一致，使模型在保留原始能力的同时提升特定任务能力，其公式为：




图 7 LoRA 模型架构图
Fig.7 LoRA model architecture diagram

$$Y^{BF16} = X^{BF16}W^{BF16} + X^{BF16}AB^T \tag{9}$$

其中， $X^{BF16}W^{BF16}$ 代表左侧原始路径及模型参数，BF16为数值编码类型， $X^{BF16}AB^T$ 为右侧新增路径及模型参数，B矩阵初始参数为全 0，以保证模型初始化时，输出值Y的一致性，本次研究中 W' 矩阵的秩（Rank）设为 16。

在训练过程中将原始模型参数进行 nf4（Normal Float 4bit）的双重量化，第一次量化采用线性量化的方式，快速实现数据压缩，第二次量化采用分位数量化（Quantile Quantization）的非线性量化的方式，用于契合正态分布型的数据，使量化后的数据更为合理和易于区分，如图 8，本研究中量化后的模型可以在几乎不改变模型精度的情况下压缩显存占用至原始的 25%，量化公式为：




图 8 nf4 量化结果映射图
Fig.8 Mapping of NF4 quantization results

$$X^{Int8} = \text{round}\left(\frac{127}{\text{absmax}(X)}X\right) = \text{round}(c \cdot X) \tag{10}$$

$$W^{BF16} = \text{dequant}(\text{dequant}(c^{FP16}, c^{Int8}), W^{NF4}) \tag{11}$$

$$\text{dequant}(c^{FP16} \cdot X^{k\text{-bit}}) = \frac{X^{k\text{-bit}}}{c^{FP16}} \tag{12}$$

其中，absmax(·)是取绝对值后最大数的函数，round(·)是取整函数，8bit 量化阶段为线性缩放，4bit 量化为分位数非线性缩放，为避免边界为无穷的情况，实际置信度取值区间仅覆盖正态分布区间的 96.77%，各区间均值如图，其中零值单独分为 1 个区间，其余区域分为负值区间 7 个、正值区间 8 个，反量化过程是量化过程的逆操作。

表 3 4bit 监督微调超参数
Tab.3 4-bit supervised fine-tuning hyper-parameters

超参数名称	设置值
r(low_rank)	8
lora_alpha	16
lora_dropout	0.1
per_device_train_batch_size	4
gradient_accumulation_steps	4
num_train_epochs	3
learning_rate	2e-4
optim	paged_adamw_8bit
weight_decay	0.001
warmup_ratio	0.3
lr_scheduler_type	"linear"

为提升模型输出格式的规范性，使用简要回答版本的训练集进行微调训练，训练中超参数如表 3，训练后 Micro F1 分数提升至 82.08%。细分类别中，如图 8，在保持正向、负向两个情感分类指标稳定的情况下，大幅提升了其他分类的召回率，并且完全消除了格式不符合要求的情况，如图 9。但具体查看混淆矩阵的情况可知，D 矛盾评价与 B 负面评价、E 无产品相关评价与 C

中性评价两组分类存在易混淆的情况。




图 9 监督微调模型结果混淆矩阵

Fig.9 Confusion matrix of supervised fine-tuning model results

其中， σ 即 sigmoid 函数， β 为超参数控制模型调试，在本次研究中设置为 0.1， y^+ 、 y^- 分别为模型生成支持、拒绝的回答， $\pi_{\theta}(\cdot)$ 、 $\pi_{\text{ref}}(\cdot)$ 分别为改进模型与原始模型生成对应支持、拒绝文本的概率累计，该损失函数实际作用为拉大模型生成支持、拒绝内容间的距离。

2.3 模型强化微调

进一步分析督微调后依然无法正确分类的数据，发现这部分数据均呈现了情绪释放不清晰这一特点，主要特点为内容简短，仅有轻微的情感倾向或文本内容同时存在符合多种分类选项的情况，在确定分类归属时界限模糊。

人类反馈强化学习（Reinforcement Learning from Human Feedback, RLHF）^[13]是一种偏好学习的方式，让模型与人类的价值取向、道德观念、社会常识保持一致，特别适用于难以从客观上判断回答的对错，仅反映主观上喜好的情况。本研究采用基于其改进的直接偏好优化方法(Direct Preference Optimization, DPO)^[14]，通过直接公式推导的方式，消除传统方法中的奖励模型需求，损失函数如式 13，简化模型调优过程。优化后的损失函数公式为：

$$L_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y^+, y^-) \sim D} [\log \sigma(\beta \log \frac{\pi_{\theta}(y^+|x)}{\pi_{\text{ref}}(y^+|x)} - \beta \log \frac{\pi_{\theta}(y^-|x)}{\pi_{\text{ref}}(y^-|x)})] \quad (13)$$

结合前文研究结果，在提示词中要求模型说明理由能够提升模型在识别 D 讽刺、E 无相关产品评价选项的能力。因此从训练集筛选包含解释理由的高质量数据，根据算法设计格式要求形成专用训练集，如表 4，约为原训练集数据量的 10%。

表 4 直接偏好优化数据集格式

Tab.4 Direct preference for optimizing dataset format

评论文本	支持（Chosen）	拒绝（Rejected）
确实不错烟气足也挺顺有劲味道没话说，就是不太好买。	“分类标签”：“A 正面”，“理由”：“评论中提到‘确实不错’，‘烟气足’，‘挺顺有劲’，‘味道没话说’，这些都是对卷烟产品质量的正面评价，说明用户对产品的使用体验是满意的。唯一提到的负面因素是‘不太好买’，但这并不影响对产品质量本身的正面评价。”	“分类标签”：“C 中性”，“理由”：“评论中提到的‘确实不错’、‘烟气足也挺顺有劲’和‘味道没话说’等描述表明了对卷烟产品的正面评价。同时，‘就是不太好买’这一部分则是对购买难度的客观描述，并非对产品质量或体验的直接评价，因此可以归类为中性信息。”
具体价钱不清楚，但是绝对不会这么便宜	“分类标签”：“C 中性”，“理由”：“评论中并未明确表达出对卷烟产品的正面或负面评价，而是仅对产品的价格表达了不确定的态度。评论者没有对产品的质量、性价比或其它具体属性进行直接的正面或负面评价，因此可以归类为中性。”	“分类标签”：“B 负面”，“理由”：“评论中提到‘绝对不会这么便宜’表明评论者认为该商品的价格不合理或超出了他们的预期，因此对产品持负面态度。由于评论没有提供具体的产品信息，所以无法判断价格是否合理，但评论者的态度是明确的负面评价。”
请问你觉得口感怎样？	“分类标签”：“E 无产品评价语意”，“理由”：“该评论是一个询问句，它没有表达出任何关于卷烟产品口感的具体评价，而是在请求对方的看法。因此，它不属于正面、负面、中性或讽刺的任何一种评价，而是一种无评价语意的提问。”	“分类标签”：“C 中性”，“理由”：“这条评论是在询问关于卷烟产品口感的个人意见或体验，并没有直接表达对产品的正面或负面看法。因此，它不属于正面或负面评价，而是中性的询问性质。”
“这烟不错，戒烟首选！”	“分类标签”：“D 讽刺”，“理由”：“评论中称这烟是‘戒烟首选’，通常戒烟意味着停止吸烟，这里使用‘戒烟首选’可能是在讽刺这种烟难抽。因此，这句话带有讽刺意味。”	“分类标签”：“A 正面”，“理由”：“评论者提到‘这烟不错’表明他对这款卷烟有正面的评价。同时，‘戒烟首选’这一表述表明他推荐这款卷烟作为戒烟的选择，进一步强调了其正面的态度和推荐意图。因此，这个评论整体上表达的是对卷烟产品的积极看法和推荐使用。”

经再次训练，训练中超参数如表 5，优化后模型 Micro F1 分数提升至 87.58%，其中 C 中性、D 讽刺、E 无相关产品评价分类的识别能力提升明显，如图 10。

表 5 DPO 优化微调超参数
Tab.5 DPO optimization fine-tuning hyperparameters

超参数名称	设置值
r(low_rank)	16
lora_alpha	16
lora_dropout	0.1
beta	0.1
per_device_train_batch_size	1
gradient_accumulation_steps	8
num_train_epochs	1
learning_rate	5e-5
optim	AdamW
warmup_ratio	0.1
max_prompt_length	128




图 10 直接偏好优化模型结果混淆矩阵
Fig.10 Confusion matrix of direct preference optimization model results

进一步验证模型通用能力是否发生劣化现象，基于 GSM8k^[15]（Grade School Math）进行能力验证，如图 11，可知微调后模型的在该数据集上依然保留与原模型相当的数学推理能力。




图 11 GMS8k 模型通用数学能力验证结果
Fig.11 Validation results of the model's general mathematical abilities on the GMS8k dataset

3 结语

本文研究了基于微调大语言模型的卷烟消费者评价文本分类方法，提出了一种能够同时兼顾情感分类、主题分类和自然语言推理的综合模型思路，并采用提示词设计、QLoRA 和 DPO 方法对大语言模型进行高效微调。实验结果表明，该方法在真实卷烟产品评论数据集上取得了显著的分类效果，Micro F1 分数相比基础模型提升了 26.72%，识别准确率与人类水平相当，识别速率约为 9000 字符/min，为正常人类速率的 20~30 倍。为卷烟行业提供了更精准的用户评价分析工具，有助于企业优化产品改进和市场策略，提升市场竞争力。

未来，我们将进一步探索大语言模型在更多 NLP

任务中的应用，并研究如何将人机交互技术融入文本分类任务，以进一步提高分类效率和准确性。

参考文献

[1] Zhang W, Li X, Deng Y, et al. A survey on aspect-based sentiment analysis: Tasks, methods, and challenges[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 35(11): 11019-11038.

[2] 王昱, 袁毓林. 基于规则的双重否定识别——以“不 V1 不 V2”为例[J]. 中文信息学报, 2022, 36 (04): 12-19.

WANG Yu, YUAN Yulin. Rule-based double negation recognition: taking “不 V1 不 V2” as an example[J]. Journal of Chinese Information Processing, 2022, 36 (04): 12-19.

[3] 杜利明, 郭文艳, 崔蕾, 等. 基于 LDA 的电商平台用户评论挖掘与情感分析研究——以京东商城 App 为例[J]. 江苏科技信息, 2024, 41 (12): 125-129.

DU Liming, GUO Wenyan, CUI Lei, et al. Research on user review mining and sentiment analysis of E-commerce platform based on LDA:taking Jingdong Mall App as an example[J]. Jiangsu Science

- & Technology Information Magazine Agency, 2024, 41(12): 125-129.
- [4] 程灿,赵敬华. 基于 BERT 和 VADER 规则的新能源汽车用户评论情感分析[J/OL]. 智能计算机与应用, 1-12[2024-07-29]. <https://doi.org/10.20169/j.issn.2095-2163.24040907>.
CHENG Can, ZHAO Jinghua. Sentiment analysis of new energy vehicle users comments based on BERT and VADER rules[J/OL]. Intelligent Computer and Applications,1-12[2024-07-29].<https://doi.org/10.20169/j.issn.2095-2163.24040907>.
- [5] 王锐,郑新章,宗国浩,等. 融合 BiLSTM 和注意力机制的卷烟消费者评价情感分类方法[J]. 烟草科技, 2022, 55(11): 106-112.
WANG Rui, ZHENG Xinzhang, ZONG Guohao, et al. An emotion classification method for cigarette consumers'evaluation based on combination of BiLSTM and Attention Mechanism[J]. Tobacco Science & Technology, 2022, 55(11): 106-112.
- [6] Yang A, Yang B, Hui B, et al. Qwen2 technical report[J]. arXiv preprint arXiv: 2407. 10671, 2024.
- [7] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [8] Zhang B, Sennrich R. Root mean square layer normalization[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [9] Ainslie J, Lee-Thorp J, de Jong M, et al. Gqa: Training generalized multi-query transformer models from multi-head checkpoints[J]. arXiv preprint arXiv: 2305. 13245, 2023.
- [10] Su J, Ahmed M, Lu Y, et al. Roformer: Enhanced transformer with rotary position embedding[J]. Neurocomputing, 2024, 568: 127063.
- [11] Shazeer N. Glu variants improve transformer[J]. arXiv preprint arXiv: 2002.05202, 2020.
- [12] Dettmers T, Pagnoni A, Holtzman A, et al. Qlora: Efficient finetuning of quantized llms[J]. Advances in Neural Information Processing Systems, 2024, 36.
- [13] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022, 35: 27730-27744.
- [14] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model[J]. Advances in Neural Information Processing Systems, 2024, 36.
- [15] Cobbe K, Kosaraju V, Bavarian M, et al. Training verifiers to solve math word problems[J]. arXiv preprint arXiv:2110.14168, 2021.

附录 1:

本文中研究过程代码见 https://github.com/py-Rw1nd/llm_text_classify。

附录 2:

提示词多样化设计。

```
prompt_lst = [
    "你是一个语义分类器。",
    "你将扮演一个文本意图识别器。",
    "你的功能是识别用户输入的语义类别。",
    "你的任务是将文本分配到相应的类别中。",
    "请将自己视为一个文本分类专家。",
    "你的目标是理解并分类文本的意图。",
    "你能够识别和归类不同的文本主题。",
    "你在这里是为了将文本信息分门别类。",
    "你的角色是文本意图的分类器。",
    "你是一个专业的语义识别系统。",
    "你专注于文本的语义分析和分类。",
    "你将提供文本意图的分类服务。",
    "你致力于精确地识别和分类文本内容。",
    "你的任务是分析文本并将其归入适当的类别。",
    "你将帮助识别文本的语义范畴。",
    "你能够快速地对文本进行语义分类。",
    "你的任务是将文本意图进行精确分类。",
    "你是文本语义分类助手。",
    "你将确保文本被正确地分类到其语义类别中。",
    "你的角色是确保文本分类的准确性和效率。",
    "你能为文本提供深入的语义分析和分类。"]
```

response_lst = [

"A 正面, B 负面, C 中性, D 讽刺, E 无产品评价语意",
"A 积极评价, B 消极评价, C 中立态度, D 反讽意味, E 无关产品评价的语境",
"A 正面反馈, B 负面反馈, C 中立观点, D 讽刺语气, E 非产品评价内容",
"A 正面情绪, B 负面情绪, C 无明显倾向, D 讽刺性表达, E 非评价性语义",
"A 赞赏性, B 批评性, C 客观性, D 嘲讽性, E 非评价性语义",
"A 正面评价倾向, B 负面评价倾向, C 评价中立, D 讽刺性语气, E 非评价性语境",
"A 积极情绪表达, B 消极情绪表达, C 情绪中性, D 讽刺性语调, E 非产品评价语义",
"A 正面情感色彩, B 负面情感色彩, C 情感中立, D 讽刺性语气, E 非评价性语义",
"A 正面评价, B 负面评价, C 评价中立, D 讽刺性表达, E 非产品评价语义",
"A 积极评价倾向, B 消极评价倾向, C 评价中性, D 讽刺性语气, E 非评价性语境",
"A 正面情感, B 负面情感, C 情感中立, D 讽刺性语调, E 非评价性语义",
"A 正面评价语境, B 负面评价语境, C 中立评价语境, D 讽刺性语境, E 非评价性语境",
"A 积极情绪倾向, B 消极情绪倾向, C 情绪中立, D 讽刺性语气, E 非产品评价语境",
"A 正面评价性质, B 负面评价性质, C 评价性质中立, D 讽刺性质, E 非评价性质",
"A 正面评价特征, B 负面评价特征, C 评价特征中立, D 讽刺特征, E 非评价特征",
"A 积极评价语义, B 消极评价语义, C 评价语义中立, D 讽刺语义, E 非评价语义",
"A 正面情感倾向性, B 负面情感倾向性, C 情感倾向性中立, D 讽刺倾向性, E 非评价倾向性",
"A 正面评价语义特征, B 负面评价语义特征, C 评价语义中立, D 讽刺语义特征, E 非评价语义特征",
"A 正面评价语境特征, B 负面评价语境特征, C 评价语境中立, D 讽刺语境特征, E 非评价语境特征",
"A 积极评价语义倾向, B 消极评价语义倾向, C 评价语义中立, D 讽刺语义倾向, E 非评价语义倾向",
"A 正面情感语义, B 负面情感语义, C 情感语义中立, D 讽刺情感语义, E 非情感评价语义"]

Research on internet cigarette consumption evaluation text classification based on fine-tuning large language model

LUO Yufeng, HUANG Bin

Chaisang Branch, Jiujiang Tobacco Company, Jiujiang 332000, China

Abstract: This paper aims to study a cigarette consumer evaluation text classification method based on fine-tuned large language models to achieve accurate classification of cigarette product reviews. Addressing the challenges faced by traditional deep learning models in processing internet Chinese text, this paper designs an artificial intelligence model that can simultaneously consider sentiment classification, topic classification, and natural language inference. The research method includes constructing a dataset containing five types of labels and using supervised fine-tuning and reinforcement fine-tuning to train the large language model. The experimental results show that the Micro F1 score of this model on the test set is improved by up to 26.72% compared to the baseline model, effectively improving the classification accuracy and flexibility of cigarette product reviews. The application of this model can help enterprises quickly identify their shortcomings from internet cigarette consumer reviews, improve product improvement efficiency, optimize marketing strategies, and maintain an advantage in the fiercely competitive market.

Keywords: tobacco; text classification; sentiment analysis; topic classification; natural language inference; large language mode; deep learning

*Corresponding author. Email: 87378503@qq.com