

基于 YOLOv11 和 YOLOv12 的烟田烟草植株识别与计数

蒋从锋¹, 唐 炜¹, 陈星融², 林远雄³, 黄小武³, 刘俊明¹,
王建武³, 谭 健³, 林曙光³, 陈 俊³

(1.杭州电子科技大学, 杭州 310018; 2.中国烟草总公司广东省公司, 广州 510610; 3.广东烟草清远市有限公司, 广东 清远 511500)

摘 要: 为解决传统烟草种植面积统计中存在的人工统计效率低、空间覆盖有限及数据精度不稳定等问题, 本文提出了一种融合遥感影像与智能算法的大范围烟田烟草植株识别与计数的新方法。首先, 通过引入 Segment Anything Model 2 (SAM2) 进行弱监督田块分割, 精确提取田块区域, 解决了遥感影像中的田块边界模糊和区域冗余问题。然后, 基于 YOLOv11 的阶段识别模块对图像进行生长阶段筛选, 识别并筛选出具备明确烟株形态特征的田块区域, 其准确率达到 99.4%。最后, 在 YOLOv12 烟株识别计数阶段, 采用图像分块策略进行密集目标检测, 并通过区域融合策略及 NMS 去重, 进一步提高了识别精度和效率。试验结果表明, 该方法在大范围烟田场景下的烟株识别计数任务中表现优异, 平均精度均值(mAP@0.5)达 91.5%, 精确率(Precision)达到 97%, 验证了其在提高识别精度和效率方面的有效性。本文提出的融合遥感影像与智能算法的烟株识别计数新方法, 能够有效提升大范围烟田场景下的烟株识别精度与效率, 具有良好的时空可扩展性与技术应用价值, 为烟草种植监管提供了数据与算法支撑。

关键词: 烟株计数; YOLO; SAM 2; 遥感图像; 烟田监管

中图分类号: S572; TP18

文献标识码: A

文章编号: 1007-5119 (2026) 03-0119-10

Identification and Counting of Field Tobacco Plants Based on YOLOv11 and YOLOv12

JIANG Congfeng¹, TANG Wei¹, CHEN Xingrong², LIN Yuanxiong³, HUANG Xiaowu³, LIU Junming¹,
WANG Jianwu³, TAN Jian³, LIN Shuguang³, CHEN Jun³

(1. College of Computer Science, Hangzhou Dianzi University, Hangzhou 310018, China; 2. Guangdong Tobacco Company of CNTC, Guangzhou 510610, China; 3. Guangdong Tobacco Qingyuan Co., Ltd., Qingyuan 511500, Guangdong, China)

Abstract: To address the challenges of low efficiency, limited spatial coverage, and unstable data accuracy in manual tobacco planting area surveys, this paper proposed a novel method for large-scale tobacco plant identification and counting that integrates remote sensing imagery with intelligent algorithms. Firstly, the Segment Anything Model 2 (SAM 2) was introduced for weakly supervised field segmentation and accurate extraction of field parcel boundaries, addressing the issues of blurred field boundaries and regional redundancy in remote sensing imagery. Secondly, A YOLOv11-based module of stage recognition was used to screen images of growth stages, identifying and selecting field parcel regions with distinct tobacco plant morphological features, achieving an accuracy of 99.4%. Finally, in the YOLOv12-based tobacco plant identification and counting stage, an image splitting strategy was employed for dense object detection. Through region fusion and NMS deduplication, the recognition accuracy and efficiency were further improved. The method exhibited excellent performance in large-scale tobacco plant identification and enumeration, achieving a mAP@0.5 of 91.5% and a Precision of 97%, which validated its effectiveness in improving recognition accuracy and efficiency. The proposed method for tobacco plant identification and counting, which integrates remote sensing imagery and intelligent algorithms, can effectively enhance the accuracy and efficiency of tobacco plant identification in large-scale tobacco field scenarios. It features excellent spatiotemporal scalability and technical application value, providing reliable data and algorithmic support for tobacco cultivation supervision.

Keywords: tobacco plant count; YOLO; SAM 2; remote sensing imagery; tobacco field supervision

基金项目: 广东烟草清远市有限公司科技项目(清烟科项 202406)

第一作者: 蒋从锋 (1980—), 男, 博士, 教授, 主要研究领域为云计算与大数据、人工智能、数据中心与分布式计算系统。E-mail: cjiang@hdu.edu.cn

收稿日期: 2025-08-15

修回日期: 2025-12-12

烟叶作为国家严格管控的专卖品,其种植规模需严格契合国家下达的指令性计划。烟叶生产既关系到行业原料供应,又关联着烟农切身利益,还承担助力烟区乡村振兴和经济发展的社会责任。严格管控烟叶种植规模,是行业内部专卖管理监督的重要内容。然而在实际生产中,受多方面因素影响,实际种植面积常常与种植计划合同存在偏差,影响烟草产业链的稳定运行与科学监管决策。随着烟草种植从传统管理模式向智能化模式转变,当前依靠人工巡查与纸质记录进行种植面积统计的传统方法不仅面临时间和空间的局限,还容易受到天气、人员和技术等多方面因素的影响,尤其在地形复杂、作业环境多样的区域,人工核查效率低、精度差的问题尤为突出,无法满足现代烟田监管的需求^[1]。因此,研究一种能够适用多地形、智能化的大范围烟株数量的识别计数方法,以支持对异常情况的准确判断,对烟叶生产种植过程的高效能、精确化监管具有重要意义。

近年来,无人机遥感与深度学习技术在农业领域迅速发展,基于空天地一体化的高分辨率数据获取与智能分析方法成为农业监管的重要研究方向^[2-3]。无人机具备高机动性和厘米级成像能力,能够快速覆盖大面积农田^[4]。同时,以YOLO系列为代表的目标检测算法在作物识别与计数任务中展现出的良好性能,为烟叶种植的高效、自动化农情提取提供了技术支撑^[5-6]。然而,现有方法多集中于局部区域的烟株识别,难以满足在实际应用环境中需要对整田块烟株进行识别计数的需求。例如,耿利川等^[7]提出的基于YOLOv7-Sim和高睿等^[8]提出的基于YOLOv8的烟草植株检测方法,只是局限于烟田某局部区域的识别,未能解决大范围烟田中的空间多样性问题,未能把应用范围扩展至整田块中烟株的识别与计数。

相比之下,本文提出了一种融合遥感影像与智能算法的大范围烟株识别与计数的新方法。首先,通过引入SAM2对原始遥感影像进行田块级预分割,剔除了背景干扰区域,获取结构清晰、目标集中的输入图像;其次,构建基于YOLOv11的生长阶段识别模块,对是否具备可识别植株特征进行前置判别,从源头提升检测对象的适用性和计算效

率;最后,在数株检测阶段结合滑窗切图、结果融合与非极大值抑制等策略,显著提升YOLOv12在密集目标条件下的检测精度与稳定性,以解决前文提到的问题。为验证方法有效性,本文选取广东省清远市典型烟区作为实地测试区域,构建了标准化烟田遥感图像数据集并进行了试验。


1 材料与方法

1.1 数据集构建

本研究使用的数据集来源于广东省清远市连州市典型烟叶种植区(北纬24.78°、东经112.37°),数据集涵盖了烟草起垄、移栽、覆膜及团棵初期等关键生长阶段。采用大疆Matrice 350 RTK多旋翼无人机搭载可见光相机进行低空飞行,飞行高度设定为150 m,地面分辨率(GSD)约为2 cm/像素。航线规划合理设计,确保拍摄图像之间具有约80%的前向重叠率和75%的旁向重叠率。拍摄时间选择在晴天无云的上午9:00至11:00光照稳定时段,采用自动曝光模式以保证图像质量。采集的原始图像通过大疆智图(DJI Terra V4.0.1)成拼接与几何校正处理,生成高分辨率的正射影像。为剔除非目标区域(如:道路、建筑等),本文结合奥维地图中的田块矢量信息,对目标区域进行人工裁图,构建只包含种植区域的原始图像集。根据任务需求构建了两个专用数据集:(1)阶段判别数据集:本数据集用于训练阶段识别模型,其核心任务是在烟株计数前,自动筛选出具备计数条件的图像。由于烟田不同生长阶段在影像上表现差异显著,起垄、移栽、覆膜等阶段中烟株尚未成型或被遮挡严重,难以进行有效识别,仅“团棵初期”阶段具备清晰、分布明确的植株特征,是当前最适合进行烟株计数的生长阶段。基于此,阶段识别模型承担前置判定功能,将“团棵初期”标注为“可计数阶段”,其余阶段统一归为“不可计数阶段”(图1)。该模型能够有效剔除不具备计数条件的图像,避免误检与资源浪费,显著提升整个系统的准确性与处理效率。(2)烟株数量识别数据集:用于训练面向团棵初期生长阶段的烟株目标检测模型,基于团棵初期的高分辨率遥感图像,采用labelImg工具对图像中每一株烟株进行边界框标注^[9],每个标注框都包含了目标类别

和物体的位置，标注文件遵循 YOLO 标准格式，记录了每个边界框的类别编号、中心坐标、宽度与高度等信息，使得检测模型的计数训练更加精准与高效。数据集属性与类别分布详见表 1。两个数据集均按照 7 : 2 : 1 的比例划分训练集、验证集、测试集。其中，验证集用于训练过程中的性能评估与

超参数调整。由于 YOLO 框架内置自动验证机制且训练、验证数据严格独立，其验证结果能充分反映模型在未见数据上的检测能力，因此本研究的试验分析主要基于验证集结果展开。测试集则保留用于后续模型泛化能力及应用效果的独立验证，不参与模型训练与调优过程。



注：A，阶段识别数据集样本的典型阶段图像示例；B，烟株数量检测数据集样本的图像示例。

Note: A, typical stage images of samples from the stage recognition dataset; B, image examples of samples from the tobacco plant count detection dataset.

图 1 数据集样本示意图

Fig. 1 Illustration of dataset samples

表 1 本研究使用的遥感影像数据集基本属性

Table 1 Basic characteristics of the remote sensing image dataset used in this study

数据集 Database	类别 Classification	样本数量 Sample size	图像尺寸 Image size	数据增强 Data strengthen
阶段识别 Stage identification	起垄、移栽、覆膜、团棵初期、杂草/荒地	1670张图像	原始图像不一， 训练时统一为1024×1024	是
烟株检测 Tobacco plant detection	单类(烟株)	128张图像， 约4000标注框	原始图像不一， 训练时统一为1024×1024	是

1.2 烟株识别与计数的技术流程框架

为确保烟株数量识别的精确性和稳定性，本文设计了一个集成化的烟田影像预处理和植株识别计数流程，包括烟田影像分割、阶段识别和植株计数3个核心模块，如图2所示。

首先，针对无人机平台获取的多时相高分辨率遥感影像，采用 SfM (Structure from Motion) 算法进行全自动影像拼接，并结合 RANSAC (Random Sample Consensus) 算法进行几何校正，确保图像在空间分辨率与辐射特性上的一致性。接着，引入基于元学习的 SAM2 语义分割模型，利用其零样本迁移学习能力，实现烟田区域的自动提取，能够有效剔除非目标地物(如道路、建筑等)，为后续的烟株检测提供清晰且精准的输入图像。

其次，考虑到烟株在不同生长阶段的外观特征存在显著差异，设计基于 YOLOv11 的生长阶段识别模块，用于辅助判断图像是否进入适合计数的关键时段。该模块不仅能有效识别“团棵初期”阶段的图像，还能对其他阶段进行分类筛选，确保只将适宜的图像送入后续的识别与计数流程，从源头减少误检和漏检风险，增强系统的整体稳定性与适应性。

最后，在植株计数模块，将符合数株阶段的田块图片经过分块策略后，利用训练好的 YOLOv12 模型进行识别与计数。

1.3 关键算法与模型设计

1.3.1 烟田影像分割模块 为提高烟株识别与计数




图2 烟株识别与计数的全流程架构图

Fig. 2 The full process architecture of tobacco plant recognition and counting

的精度与效率,需在遥感影像中实现田块区域的结构化提取,以避免背景干扰并支持田块级植株目标的空间统计。为此,本文引入 Segment Anything Model 2 (SAM 2) 作为田块级区域切分的预处理工具。SAM 2 基于图像-语言联合嵌入的视觉基础模型,具备 prompt-driven 的目标语义分割能力,能够在零样本设定下对异构图像进行边界感知建模^[10-11]。该模型采用 Vision Transformer-Huge (ViT-H) 作为图像特征编码器,通过多层次特征提取,结合用户提供的提示(如点、框、文本等),在无须针对特定场景进行额外训练的情况下,能够准确分割异构图像中的目标区域。针对遥感影像的超大分辨率与田块边界的不规则分布,本文将原始大尺寸正射影像 (W, H) 预处理为若干尺度适宜的子图 $\{I_i\}_{i=1}^N$, 分别送入 SAM 2 模型执行 prompt-free 分割,生成田块掩膜集合 $\{M_i\}_{i=1}^N$, 并通过拼接重构完整的田块区域信息。

如图 3 所示, SAM 2 在无监督条件下表现出良好的边界解析能力,能够分离具有弱纹理特征的田块边缘与背景区域。该预处理策略为后续基于 YOLOv12 的植株目标检测提供了结构化区域约束,有助于提升检测精度与推理效率。

1.3.2 阶段识别模块 阶段识别需对影像中处于不



注: A, 原始遥感影像; B, SAM 2 分割后各田块有效区域的可视化结果。

Note: A, original remote sensing image; B, visualization results of valid regions in each field after SAM 2.

图3 烟田遥感图像经 SAM 2 分割后的效果示意图

Fig. 3 Illustration of segmentation results on tobacco field remote sensing images using SAM 2 segmentation

同种植阶段的区域进行精准分类,要求目标检测模型具备强大的特征提取、空间感知能力与高效推理效率。YOLOv11 凭借独特的架构设计,在同类算法中脱颖而出,尤其适用于这一任务场景。

YOLOv11 的核心优势源于两大创新模块,其结构如图 4 所示。其一是 C3K2 (Cross Stage Partial k2) 模块,通过双路信息通道与 CBS (Convolution-Batch normalization- SiLU) 结构^[12],在提取特征的同时实现高效训练。以 n 个 C3k, $n=2/\text{Bottleneck}$ 为分支的设计,显著增强跨阶段特征融合能力,在强化中高层语义信息提取的同时,维持网络轻量化,确保检测速度。其二是引入了 C2PSA (Channel-to-Position Self-Attention) 模块,该模块利用 PSA (Position-Sensitive Attention) 机制融合通道与空间注




图4 C3K2 和 C2PSA 结构图

Fig. 4 Structure diagram of C3K2 and C2PSA

意力, 能在大感受野范围内自适应聚焦关键特征区域^[13], 显著提升模型对不同种植阶段特征的判别能力。具体而言, PSA 机制由多头注意力(Multi-head Attention)与前馈网络(Feed-Forward Network, FFN)组成, 结构上类似于 Transformer 编码器模块。具体来说, 给定输入特征图 $X \in R^{B \times C \times H \times W}$, 其中 B 表示批量大小(Batch Size), C 表示通道数(Channels), H 和 W 分别表示特征图的高度(Height)和宽度(Width)。首先通过 1×1 卷积降维为 $X' \in R^{B \times 2C' \times H \times W}$, 拆分 $a, b \in R^{B \times C' \times H \times W}$ 。接着 b 送入多头注意力模块, 计算过程如式(1)所示:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (1)$$

其中 Q, K, V 分别由 b 经不同线性映射获得, 划分为多个 head 以关注不同空间区域的语义响应。接着, 注意力输出通过前馈网络(FFN)处理, 计算过程如式(2)所示:

$$\text{FFN}(x) = W_2 \cdot \text{GELU}(W_1 \cdot x) \quad (2)$$

其中 W_1 和 W_2 是前馈网络中的权重矩阵, GELU 是激活函数。最终与残差连接叠加后与通道 a 拼接, 通过 1×1 卷积融合得到输出 Y , 如式(3)所示:


$$Y = \text{Conv}1 \times 1(\text{Concat}(a, b)) \quad (3)$$

通过该双通道注意力加权机制, YOLOv11 能够精准捕捉不同种植阶段区域的显著特征差异, 有效增强其分类精度与泛化性能, 特别适用于多阶段时序特征显著的烟田图像识别任务。

1.3.3 植株计数模块 尽管 YOLOv11 在烟田图像的种植阶段识别中表现优异, 具备较强的语义建模与空间感知能力, 但在处理密集小目标识别任务时仍存在一定局限性。相比之下, 烟株数量识别对模型的分辨精度、感受野范围及目标区分能力提出更高要求。传统基于卷积神经网络(CNN)的检测方法由于受到局部感受野和特征表达能力的限制, 难以在复杂场景下实现高精度识别。为此, 本研究选用新一代目标检测模型 YOLOv12 作为核心检测框架, 通过结构性革新显著提升了对密集小目标的检测能力。YOLOv12 的优势主要体现在两方面: 一, 其主干网络突破了传统 CNN 结构的局限, 借鉴 Vision Transformer(ViT)的建模思想^[14], 引入改进的区域注意力机制, 以提升模型对微小目标与密集区域的全局感知能力; 该设计融合了 Transformer 的长距离依赖建模优势与 YOLO 系列的层次化特征提取策略, 兼顾感受野与效率。二, 模型中集成了高效的区域注意力模块(A^2 , Area Attention), 通过隐式的特征图分段与稀疏注意力机制, 有效增强了对关键区域的关注能力, 其模块原理如图 5B 所示, 其核心计算如式(4)所示:

$$A^2(x) = \text{Proj}(\text{Attention}(Q_{\text{area}}, K_{\text{area}}, V_{\text{area}}) + \text{PE}(V)) \quad (4)$$

其中 $\text{Attention}(Q_{\text{area}}, K_{\text{area}}, V_{\text{area}})$ 表示在区域划分基础上进行的多头注意力计算, $\text{PE}(V)$ 为作用于值向量 V 的位置编码增强项, $\text{Proj}(\cdot)$ 表示后续的线性投影操作, 用于进一步融合空间结构信息。



注: A, 模型整体架构及 A2C2f 模块架构; B, A^2 模块的原理图。

Note: A, overall model architecture and A2C2f module architecture; B, schematic diagram of the A^2 module.

图 5 YOLOv12 模型结构与注意力机制细化图

Fig. 5 YOLOv12 model architecture and attention mechanism detail diagram

该模块在保证计算效率的同时,加强了对局部关键区域的表征能力。图 5A 展示了 YOLOv12 的整体网络架构。其主干网络融合了改进型区域注意力机制、多尺度检测头和特征融合模块,协同提升不同尺度烟株目标的检测精度。此外, YOLOv12 还引入 R-ELAN(Residual Efficient Layer Aggregation Network)模块构建多路径残差连接^[15],提高特征融合效率并保持梯度稳定性;集成的 FlashAttention 机制进一步优化了注意力计算,降低显存占用、提升推理速度。综上, YOLOv12 在检测精度、计算效率及复杂场景适应性上均超越前代 YOLO 模型,为遥感图像中烟株密集检测任务提供了高效可靠的解决方案。

1.4 模型评价

为全面评估基于 YOLOv11 所训练的阶段识别模型与基于 YOLOv12 的植株计数模型的性能,本文选取了多项具有代表性的评价指标,包括准确率(Accuracy)、精确率(Precision)、召回率(Recall)及平均精度均值(Mean Average Precision, mAP)等^[16]。各项指标定义如下:

(1) 准确率(Accuracy)

适用于分类任务,表示模型预测正确的样本数在全部样本中的占比,定义如公式(5):

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (5)$$

其中, TP(True Positive)为真正例, TN(True Negative)为真反例, FP(False Positive)为假正例, FN(False Negative)为假反例。

(2) 精确率(Precision)

用于衡量模型预测为正样本中实际为正的比列,反映预测结果的可靠性。定义如公式(6):

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (6)$$

(3) 召回率(Recall)

表示实际为正样本中被正确识别为正的比例,反映模型的检测能力。定义如公式(7):

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (7)$$

(4) 平均精度均值(Mean Average Precision, mAP)

mAP 是目标检测领域中常用的评价指标,用于综合衡量模型在不同类别和不同 IoU(Intersection

over Union)阈值下的检测性能。mAP@0.5 表示在 IoU 阈值为 0.5 时计算得到的平均精度,定义为所有类别下 Average Precision(AP)的均值,如公式(8)所示:

$$\text{AP} = \int_0^1 p(r) dr, \text{mAP} = \frac{1}{N} \sum_{i=1}^N \text{AP}_i \quad (8)$$

其中, $p(r)$ 为召回率 r 下的精度, N 为目标类别数量。

综上,本文在用于分类的阶段识别模型评价中,主要采用准确率、召回率等指标;在用于目标检测的植株计数模型评价中,则重点采用精确度、召回率和平均精度均值 mAP@0.5 等指标,以全面反映模型在烟田遥感图像中的识别性能与计数效果。

1.5 试验设置与数据预处理

1.5.1 试验环境 本研究在配备双路 NVIDIA RTX 6000 Ada GPU 的服务器环境下进行,深度学习框架采用 PyTorch 2.2.2。针对烟田遥感影像的特征分辨率与多通道结构,构建了定制化的数据加载与预处理模块,以适配大尺寸图像处理需求。模型训练阶段选用 YOLOv11 分类模型与 YOLOv12 目标检测模型,训练图像分辨率设为 1024×1024,批量大小为 8,启用多尺度训练(multi-scale training)与混合精度加速(AMP),通过两块 GPU 并行处理以提高训练效率。为增强模型在复杂种植场景下的鲁棒性,引入了 Albumentations 库支持的多种数据增强策略,如随机旋转、缩放、亮度调整、随机裁剪、水平翻转等操作,增强过程在数据加载阶段动态执行,不改变原始数据集分布。试验环境配置详见表 2。

1.5.2 图像预处理与推理增强策略 针对无人机遥感影像分辨率高、田块形状不一等特性,直接将整图输入模型易导致信息丢失、显存压力大及检测不稳定等问题。为提升模型部署适应性与识别精

表 2 试验环境配置
Table 2 Experimental environment configuration


项目 Project	配置 Configuration
操作系统	银河麒麟 v10
内存	64 GB
GPU	NVIDIA RTX 6000 Ada
CPU	Core i9-14900K
PyTorch版本	2.2.2

度, 本文在阶段识别与株数检测任务中均设计了相应的图像预处理与推理增强策略, 包括图像切块、无效区域剔除、投票融合及非极大值抑制(NMS)等方法^[7], 构建了适用于大幅遥感图像的高效轻量推理流程。

在阶段识别任务中, 对于宽或高超过 2400 像素的烟田图像, 采用非重叠方式进行固定尺寸(1024×1024 像素)切块处理。由于部分烟田轮廓存在不规则形状或位于图像边缘, 导致某些切块区域无法被真实图像内容完全填充, 从而出现大面积的黑边区域(即零填充区域)。为提升阶段识别模型的有效性, 本文引入图像质量过滤机制, 剔除以下两类低质量子图: (1)零像素区域占比超过 75% 的子图; (2)实际有效区域在切块后长或宽小于标准

尺寸 30%(即小于 307 像素)的子图。随后对剩余有效切块分别使用基于 YOLOv11 训练好的模型进行分类, 并采用投票机制确定整图所属阶段, 以实现大图图像的稳定、高效识别。

在植株计数任务中, 为保证整块烟田图像的检测完整性, 对分辨率超过 2000 像素的图像采用带 200 像素重叠的滑窗分块策略, 将整图切分为多个 1024×1024 子图, 减少边缘目标被截断的影响。模型推理后, 利用非极大值抑制(NMS)融合重叠区域内的重复检测框, 有效提升了密集目标的检测精度与一致性。相关处理流程示意图 6, 其中各子图依次展示了完整烟田图像(图 6A)、非重叠切图与无效区域剔除(图 6B)以及重叠检测窗口及其植株检测效果放大示意图(图 6C)。



注: A, 完整烟田图像; B, 非重叠切图与无效区域剔除; C, 带重叠的滑窗检测窗口及其植株检测效果放大示意图。

Note: A, complete tobacco field image; B, non-overlapping image segmentation and removal of invalid areas; C, enlarged schematic of overlapping sliding-window detection and corresponding plant detection results.

图 6 田块图像切分与检测框融合示意图

Fig. 6 Illustration of plot image tiling and bounding box fusion

2 结果

2.1 阶段识别

在阶段识别任务中, 试验采用分阶段训练策略。首先基于 YOLOv11-cls 模型在原始训练集上进行初步训练, 并保存最优权重 best.pt; 随后在相同数据集上加载该模型权重继续训练。该训练策略在保证收敛速度的同时, 进一步优化了模型的判别能力与稳定性。在验证集上, 模型最高准确率达到 99.4%, 验证损失降至 0.0254; 整个训练过程中, 准确率的平均值为 96.8%, 验证损失的平均值为 0.106, 表明模型对各阶段烟田图像具有较强的判别能力, 分类效果稳定可靠。图 7 展示了模型在训练过程中准确率与验证损失的变化趋势, 如图 7 所示, 模型在早期训练阶段准确率迅速上升, 随后趋于稳定, 且训练与验证损失同步下降, 未出现明

显过拟合现象。

2.2 烟株数量识别

在植株计数任务中, YOLOv12 模型经过训练后表现稳定, 具备较高的检测精度, 在验证集上取得了精确率为 97%, mAP@0.5 达到 91.5% 的检测性能。如图 8 所示的精确率、召回率及 mAP@0.5 的变化曲线表明, 模型训练过程稳定, 收敛良好。相关性能指标如表 3 所示。为进一步评估模型在不




图 7 Accuracy 和 Loss 变化曲线

Fig. 7 Accuracy and Loss variation curves




图8 Precision、Recall、mAP@0.5 变化曲线

Fig. 8 Precision, Recall, and mAP@0.5 variation curves

同检测框架下的性能表现,本文在相同验证集上引入 FasterR-CNN(ResNet50、MobileNetV2 主干)及 YOLOv5s 作为对照模型进行性能比较(表4)。试验结果表明, YOLOv12 在保持较低参数量与计算复杂度的前提下,相较 YOLOv5s 在检测精度上实现显著提升, mAP@0.5 提升约 19.9 个百分点,较 FasterR-CNN(ResNet50)提升超过 55.7%,充分验

表3 分类与检测模型的指标参数

Table 3 Metric parameters of classification and detection models

指标 Indicator	阶段识别模型 Stage recognition model	株数检测模型 Plant count detection model
最高准确率	99.4%	
平均准确率	96.8%	
验证损失(最低)	0.0254	
验证损失(平均)	0.106	
精确率		97%
召回率		88%
平均精度均值 mAP@0.5		91.5%

证了其在密集小目标检测任务中的优势与实用价值。需要说明的是,表3与表4所列的性能指标均来源于验证集结果。验证集与训练集严格独立,且未参与模型参数更新,能够有效反映模型在未见数据上的检测性能与泛化趋势。

表4 烟株目标检测任务中不同模型的检测精度与模型规模对比

Table 4 Detection accuracy and model size comparison of different models for tobacco plant detection

模型 Model	参数量(百万)	计算量(GFLOPs)	mAP@0.5/%	mAP@0.5:0.95/%
Faster R-CNN(ResNet50)	41.5	200	35.8	18.1
Faster R-CNN(MobileNetV2)	14.0	60	21.6	9.4
YOLOv5s	7.2	16.5	71.6	33.5
YOLOv12n	9.3	21.4	91.5	46.9

注:参数量与计算量均为估算值,来源于主流开源实现,仅用于模型规模参考。mAP指标均基于本文数据集评估结果。

Note: The parameter count and FLOPs are estimated values obtained from mainstream open-source implementations and are provided for reference only. The mAP metrics are based on the evaluation results of the dataset used in this study.

2.3 模型泛化能力

为进一步评估模型在真实场景中的泛化能力,本文选取了一批独立于上述数据集之外的清远市烟区无人机采集分割后的 173 张烟株图像,使用训练完成的 YOLOv12 模型进行批量植株检测,并与人工统计的实际株数进行对比分析。图像数据按采集时间与区域分为 4 个批次,分别统计各批次的检测株数、实际株数以及两者之间的绝对误差与相对误差。整体结果显示,模型在各批次中均展现出良好的数量预测一致性与稳定性。4 批图像的平均绝对误差为 74 株,相对误差控制在 0.61% 以内,具体统计见表 5。为进一步验证模型在实际图像上的应用效果,图 9 展示了若干组烟株检测前后的对比图像。其中图 9A 为输入的原始烟株图像,图 9B 为模型输出的检测结果图像,已通过边框标注出识别到的烟株。图中可见模型在不同密度和光照条件下均表现出良好的鲁棒性与精度。


2.4 处理效率与稳定性

为评估模型在实际部署过程中的推理效率,本文进一步统计了烟株图像检测任务中图像尺寸与处理时间之间的关系。对 173 张图像进行检测并记录每张图像的长宽尺寸与实际推理耗时,绘制了图像总像素数(即宽×高)与处理时间的散点图,结果如图 10 所示。从图中可以看出,图像尺寸整体上与处理时间呈正相关关系,符合预期。此外,对相似尺寸图像的处理时间存在一定波动,推测可能受到图像复杂度、目标数量、GPU 负载等因素影响。这说明在图像尺寸可控的前提下,本系统具备良好

表5 基于实测图像的烟株检测结果评估

Table 5 Evaluation of tobacco plant detection results based on measured images

批次 Batch	图像数量 Number of images	实际株数 Actual number of plants	检测株数 Number of strains detected	绝对误差 Absolute error	相对误差 Relative error/%
批次1	44	12926	12996	70	0.54
批次2	43	11551	11599	48	0.42
批次3	43	11843	11963	120	1.01
批次4	43	12663	12721	58	0.46
平均值	173	48983	49279	74	0.61



注：A，原始烟田遥感图像；B，YOLOv12 模型检测结果图像（已加检测框）。

Note: A, original tobacco field remote sensing image; B, YOLOv12 model detection result image (with detection boxes added).

图9 烟株检测任务中检测前后图像对比图

Fig. 9 Comparison of images before and after detection in tobacco plant counting task




图10 图像尺寸与处理时间的关系图

Fig. 10 Relationship between image size and processing time

的处理效率与稳定性，适合部署于大规模烟田图像分析任务中。

3 讨论

由于烟田田间环境复杂、背景干扰因素多，仅依赖可见光影像进行大范围田块烟株识别与计数存在局限。当光照不均或纹理弱时，识别精度容易受影响。相比之下，多/高光谱影像可通过红边、近红外等波段反映植被光谱特征，提升烟株与杂草、土壤的区分度，从而增强作物识别与长势评估精度^[17-18]。例如，陈天才等^[19]系统总结了无人机多光谱影像在烟田智慧管理中的应用，指出其在面积监测、长势诊断、病虫害预警及营养施肥管理等方面表现出显著潜力。但该研究也强调了其在推广中仍面临设备成本高、数据处理复杂、标准化流程缺失等问题。具体而言，如大疆 Phantom 4 Multispectral(P4M)无人机可同时获取红、绿、蓝、红边和近红外等多波段影像，具备较高的光谱分辨

率与空间精度。然而，该类影像需经过辐射校正和波段配准等复杂预处理，在光照不均或地形起伏条件下易产生配准与拼接误差，因此在大面积烟田的常规监测中仍存在较高的计算与操作门槛。

综合来看，多/高光谱方案虽具有较强的光谱区分能力，但受限于成本与复杂度，不利于大面积常规监测。本研究基于可见光航拍数据，提出了一条低成本、高可复制性的整田块烟株识别与计数流程，在保证精度的同时兼顾可行性。多模型分阶段策略(SAM 2 预处理、YOLOv11 阶段筛选、YOLOv12 检测)有效解决了复杂背景干扰与阶段特征差异显著的问题。其中，SAM 2 模型在无监督条件下具备良好的边界解析能力，显著提升了区域聚焦度。YOLOv11 阶段判别模型利用双通道注意力机制，在验证集上实现了 99.4% 的准确率，可有效筛选出适宜烟株计数的生长阶段区域。YOLOv12 检测模型融合区域注意力与 Transformer 的长程依赖建模，在密集小目标识别中表现突出，验证集上达到 91.5% 的 mAP@0.5 和 97% 的精确率，体现了该策略在复杂场景下的稳定性与鲁棒性。相关研究^[20-21]亦表明，基于注意力机制与分阶段检测策略可显著提升农业场景识别的稳健性。

然而，该研究仍存在一定的改进空间。首先，所采集的数据集中团棵初期样本比例较高，虽然模型在验证集上取得了良好性能，但其在复杂场景下的泛化能力仍需进一步验证。例如，在强光照、阴

影及背景纹理复杂的条件下,烟株轮廓易受干扰,可能导致识别精度下降;尤其是在烟叶密集、植株相互遮挡或杂草干扰显著的区域,模型稳定性仍有提升空间。其次,在硬件条件方面,本研究使用的NVIDIA RTX6000Ada GPU主要用于加速模型训练与推理。尽管模型亦可在中端GPU(如RTX3060/4060)或服务CPU环境下运行,但受显存与算力限制,运行速度及批量处理能力会有所降低。未来工作将进一步探索模型压缩与知识蒸馏等轻量化技术^[22],以优化模型在边缘设备及企业级硬件环境下的部署性能,并引入多时相或多模态(RGB+多光谱/热红外)融合以提升复杂环境下的鲁棒性。

4 结 论

为解决大范围烟草植株的识别与计数问题,本研究提出一种融合遥感影像与组合多模型算法的方法,该方法首先通过SAM 2模型进行烟田影像分割,然后通过YOLOv11模型识别筛选处在适合进行烟株计数生长阶段的烟田田块,最后使用YOLOv12模型实现田块级的烟株计数。本研究方法适用于各种地形的田间环境,可应用于烟叶种植监管、合同核查与种植密度分析等实际工作中。

参考文献

- [1] ZHANG Z X, ZHU L X. A review on unmanned aerial vehicle remote sensing: Platforms, sensors, data processing methods, and applications[J]. Drones, 2023, 7(6): 398.
- [2] NATH P C, MISHRA A K, SHARMA R, et al. Recent advances in artificial intelligence towards the sustainable future of agri-food industry[J]. Food Chemistry, 2024, 447: 138945.
- [3] WANG C Y, LIU B H, LIU L P, et al. A review of deep learning used in the hyperspectral image analysis for agriculture[J]. Artificial Intelligence Review, 2021, 54(7): 5205-5253.
- [4] SHAHID R, QURESHI W S, KHAN U S, et al. Aerial imagery-based tobacco plant counting framework for efficient crop emergence estimation[J]. Computers and Electronics in Agriculture, 2024, 217: 108557.
- [5] LIU D X, WANG A G. Multi-period tobacco plant identification based on drone image and improved YOLOv7 model[C]//2023 3rd International Conference on Computer Science, Electronic Information Engineering and Intelligent Control Technology (CEI), Wuhan. IEEE, 2023: 401-406.
- [6] YU X, YIN D M, XU H G, et al. Maize tassel number and tasseling stage monitoring based on near-ground and UAV RGB images by improved YOLOv8[J]. Precision Agriculture, 2024, 25(4): 1800-1838.
- [7] 耿利川, 王忠丰, 秦永志, 等. 基于YOLOv7-Sim和无人机遥感影像的烟株数量检测[J]. 中国烟草科学, 2023, 44(4): 94-102.
- [8] 高睿, 吴会才, 刘春菊, 等. 基于改进YOLOv8的烟草植株检测与计数方法研究[J]. 中国烟草学报, 2025, 31(1): 111-122.
- [9] 肖恒树, 李军营, 梁虹, 等. 基于改进YOLOv8和无人机遥感影像的大田烟株数量检测[J]. 电子测量技术, 2024, 47(9): 163-171.
- [10] MAZUROWSKI M A, DONG H Y, GU H X, et al. Segment anything model for medical image analysis: An experimental study[J]. Medical Image Analysis, 2023, 89: 102918.
- [11] OSCO L P, WU Q S, de LEMOS E L, et al. The Segment Anything Model (SAM) for remote sensing applications: From zero to one shot[J]. International Journal of Applied Earth Observation and Geoinformation, 2023, 124: 103540.
- [12] 赵子杰, 王毅, 唐瑞卿, 等. 基于改进YOLOv11的无人机目标检测算法[J/OL]. 计算机应用, 2025: 1-9. (2025-04-28). <https://kns.cnki.net/kcms/detail/51.1307.tp.20250427.1138.002.html>.
- [13] 刘玉萍, 尚翠娟, 李明明. 改进YOLOv11的无人机小目标检测算法[J/OL]. 计算机工程与应用, 2025: 1-10. (2025-04-22). <https://kns.cnki.net/kcms/detail/11.2127.tp.20250422.0915.004.html>.
- [14] TIAN Y J, YE Q X, DOERMANN D. YOLOv12: Attention-centric real-time object detectors[EB/OL]. 2025: arXiv: 2502.12524. <https://arxiv.org/abs/2502.12524>.
- [15] KHANAM R, HUSSAIN M. A review of YOLOv12: Attention-based enhancements vs. previous versions[EB/OL]. 2025: arXiv: 2504.11995. <https://arxiv.org/abs/2504.11995>.
- [16] 汪睿琪, 张炳辉, 顾钢, 等. 基于YOLOv5的鲜烟叶成熟度识别模型研究[J]. 中国烟草学报, 2023, 29(2): 46-55.
- [17] CAO X F, LIU Y L, YU R, et al. A comparison of UAV RGB and multispectral imaging in phenotyping for stay green of wheat population[J]. Remote Sensing, 2021, 13(24): 5173.
- [18] NGUYEN C, SAGAN V, BHADRA S, et al. UAV multisensory data fusion and multi-task deep learning for high-throughput maize phenotyping[J]. Sensors, 2023, 23(4): 1827.
- [19] 陈天才, 张久权, 蒯雁, 等. 基于无人机多光谱影像的烟田智慧管理应用与挑战[J]. 中国烟草科学, 2025, 46(4): 98-106.
- [20] KIRILLOV A, MINTUN E, RAVI N, et al. Segment anything[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV), Paris. IEEE, 2023: 3992-4003.
- [21] LI Y G, LI Q, PAN J, et al. SOD-YOLO: Small-object-detection algorithm based on improved YOLOv8 for UAV images[J]. Remote Sensing, 2024, 16(16): 3057.
- [22] CHENG Y, WANG D, ZHOU P, et al. A survey of model compression and acceleration for deep neural networks[EB/OL]. 2017: arXiv: 1710.09282. <https://arxiv.org/abs/1710.09282>.