

## 植物保护

宋鑫龙, 张峰, 吴华瑞, 等. 基于半监督学习和改进 YOLOv8n 的轻量级山东烟区主要病虫害检测[J]. 中国烟草学报, 2026, 32(1): 122-134. SONG Xinlong, ZHANG Feng, WU Huarui, et al. Lightweight detection of major tobacco pests and diseases in Shandong based on Semi-supervised learning and an improved YOLOv8n[J]. Acta Tabacaria Sinica, 2026,32(1):122-134. doi:10.16472/j.chinatobacco.2025.T0130

# 基于半监督学习和改进 YOLOv8n 的轻量级 山东烟区主要病虫害检测

宋鑫龙<sup>1,3</sup>, 张峰<sup>1,4</sup>, 吴华瑞<sup>2,3</sup>, 朱华吉<sup>2,3</sup>, 高强三<sup>1,3</sup>,  
闫兆洋<sup>1,3</sup>, 吴秋兰<sup>1,4\*</sup>, 孙想<sup>2,3</sup>

1 山东农业大学信息科学与工程学院, 泰安 271018;

2 北京市农林科学院信息技术研究中心, 北京 100097;

3 农业农村部数字乡村技术重点实验室, 北京 100097;

4 农业农村部黄淮海智慧农业技术重点实验室, 泰安 271018

**摘要:** 【目的】针对复杂场景下烟叶病虫害检测存在的模型精度受限、计算复杂度高、移动端部署难的问题, 本文提出了一种融合半监督学习的轻量级烟叶病虫害检测模型 (PFMS-YOLO)。【方法】首先, 以 Topformer 作为教师模型生成伪标签数据, 并基于此训练改进后的学生模型 Efficient-Topformer, 标注成本降低了约 54.2%。其次, 对 YOLOv8n 网络进行了 3 方面改进: (1) 在主干网络创新性构建了 C2f\_PF 模块, 利用简单的池化操作实现高效特征提取与融合, 提升了模型的检测精度, 降低了运算量和参数量; (2) 将颈部网络中的 C2f 模块替换为 C2f\_EF 模块, 采用部分卷积和 EMA 注意力机制协同优化策略, 在保证精度的同时, 进一步精简了模型的运算量和参数量; (3) 通过引入多参数、低运算量操作的 MultiSEAMHead 轻量化检测头, 增强了边缘病斑感知能力, 并有效提升了遮挡场景检测的鲁棒性。【结果】试验结果表明, PFMS-YOLO 在复杂自然场景烟叶数据集上 mAP@50 达 84.2%, GFLOPs 降至 5.8, 参数量仅为 4.3M, 优于其他主流模型。【结论】本文为资源受限场景下的烟叶病虫害实时检测提供了可行的解决方案。

**关键词:** 病虫害; 目标检测; 烟叶; 轻量化; YOLOv8n

## 0 引言

烟叶是我国重要经济作物, 长期受病虫害威胁, 其中花叶病、白星病、野火病、黑胫病、烟蚜、烟青虫等影响尤为严重。传统烟叶病虫害检测依赖从业人员目测烟叶形态, 易造成误判影响防治效果<sup>[1-6]</sup>。

深度学习发展推动卷积神经网络应用于烟草病虫害智能识别领域<sup>[7-8]</sup>。早期研究多采用图像分类方法: Mohith Kumar B<sup>[9]</sup>基于 CNN 构建了烟草病害识别模

型, 训练精度达 80%, 但测试集表现下降, 模型泛化能力不足。Jianwu Lin<sup>[10]</sup>提出的多特征融合网络精度为 89.71%, 然而复杂度限制了实际应用。Hao Peng 团队<sup>[11]</sup>改进 GoogLeNet 识别准确率高达 97.44%, 但其研究局限于单一病斑, 未解决复杂背景检测问题。张文静等<sup>[12]</sup>基于迁移学习构建的 InceptionV3 在单一背景下烟草病害分类精度为 90.8%, 但无法同时识别多病害。

目标检测算法为复杂场景烟叶病虫害识别提供了新思路<sup>[13]</sup>。Faster R-CNN 等两阶段检测算法精度较高,

基金项目: 国家重点研发计划“特色产业数字化农事全链条服务平台”(No.2024YFD1601304)

作者简介: 宋鑫龙 (2000—), 硕士研究生, 主要从事农业信息化, Tel: 17661293032, Email: 2023121136@sdaa.edu.cn

通讯作者: 吴秋兰 (1976—), 教授, 主要从事农业信息化、智慧村镇关键技术研究, Tel: 13181817575, Email: zxyllsg@sdaa.edu.cn

收稿日期: 2025-04-11; 网络出版日期: 2025-12-02

但计算复杂,难以满足实时检测需求<sup>[14]</sup>。YOLO 系列单阶段检测器因高效性受到关注<sup>[15-17]</sup>,刘延鑫等<sup>[18]</sup>改进的 YOLOv3 检测平均精度达 77%,但仍存在小目标漏检问题。刘春菊等<sup>[19]</sup>改进的 YOLOv5 通过增加检测头提升性能,但模型参数量显著增加,且相似病种区分能力有限。Yuchen Wang<sup>[20]</sup>在 YOLOv8 中引入 GAM 注意力机制和感受野注意力卷积提升了检测精度,但模型较复杂。

尽管目标检测算法在农作物病虫害识别领域取得显著进展,但其大规模标注数据需求仍是实际应用的主要障碍。半监督学习 (Semi-Supervised Learning, SSL) 为降低标注成本提供了可行路径<sup>[21-22]</sup>。Sohn 等<sup>[23]</sup>提出的两阶段 SSL 框架通过伪标记与一致性正则化策略<sup>[24-25]</sup>,有效提升了目标检测性能。但是,暂未查阅到针对烟叶病虫害的半监督标注策略研究。当前烟叶病虫害检测研究主要面临三重挑战:①复杂田间环境

下存在多叶片重叠、杂草地膜干扰等背景噪声,导致传统算法误检率升高;②相似病斑形态特征增加了模型区分难度;③现有高精度模型的计算复杂度与移动端部署需求存在矛盾。

基于上述问题,本文提出了融合半监督学习的烟叶病虫害图像标注策略和轻量化设计的 PFMS-YOLO 模型。通过构建半自动标注体系降低数据标注成本,改进网络结构与特征融合机制提升相似病种识别能力,并采用深度可分离卷积等技术实现模型轻量化。在保证检测精度的前提下,模型参数量为 4.3M,运算量降低 28.4%,为田间复杂场景下的烟叶病虫害实时检测提供了可行解决方案。

1 材料与方法

1.1 研究路线

本文研究路线如图 1 所示。




图 1 研究路线图

Fig. 1 Research roadmap

步骤 1: 构建烟叶病虫害数据集。首先,通过人工采集和网络获取两种方式,采集烟叶病虫害图像,筛选符合实际应用场景的图像进行扩充,并人工标注部分数据。然后,构建半监督图像标注模型,通过教师-学生模型迭代学习,结合真实标签与伪标签训练,不断用学生模型替代教师模型,迭代优化直至结果收

敛,生成高质量烟叶病虫害标注样本。最后,将数据按照 7:2:1 划分数据集。

步骤 2: 病虫害识别模型构建与训练。本文通过三部分改进构建高效轻量的烟叶病虫害检测模型。首先,将主干网络中的 C2f 模块替换为设计的 C2f\_PF 模块,利用简洁的池化结构实现高效的特征提取与融

合；其次，在颈部网络中引入 EMA 注意力机制，设计 C2f\_EF 模块，在保持模型精度的基础上有效减少参数量与计算开销；最后，引入轻量化的 MultiSEAMHead 检测头，增强对病斑区域的关注度，提高遮挡鲁棒性并弱化背景干扰，从而提升整体检测性能。在试验部分，通过消融与对比试验验证模型在烟叶病虫害识别任务中的有效性与优越性。

## 1.2 烟叶常见病虫害图像采集

烟叶常见的病虫害有黄瓜花叶病、白星病、野火病和烟青虫等。本文数据集来自山东农业大学智慧村镇实验室自建数据库，采集于山东省某烟叶种植区域。

使用移动设备在病虫害多发时期的不同天气、不同时间条件下，对患有上述病害的烟叶进行多方位、多角度、多距离拍摄，以保留患病烟叶最真实的状态，共获得 650 张烟叶常见病虫害图像，分辨率为 3024\*4032。包含 228 张黄瓜花叶病、133 张白星病、100 张野火病以及 189 张烟青虫图像。所有图像均为实际农田背景下拍摄，部分图像如图 2 所示。图像存在以下特点：同一病害由于发病时期不同，病斑特征存在差异；部分图像存在特征相似的多种病害；农田环境下拍摄的图像会包含其他烟叶、杂草、地膜、土壤等干扰因素，上述特点增加了病害检测难度。



a. 黄瓜花叶病  
a. Tobacco cucumber mosaic virus



b. 白星病  
b. Phyllosticta leaf spot



c. 野火病  
c. Tobacco wild fire



d. 烟青虫和白星病  
d. Tobacco budworm and phyllosticta leaf spot

图 2 烟叶常见病虫害图像示例

Fig. 2 Example images of common tobacco leaf pests and diseases

## 1.3 数据集构建

数据的充分和全面性对于提高模型的泛化性和鲁棒性至关重要。为了提高目标检测算法对错误标签的记忆并增加样本数量，采用角度旋转、饱和度调整、曝光度调整、添加噪声和高斯模糊等策略，将数据扩

充至 1560 张，按照 7: 2: 1 的比例划分训练集、验证集和测试集。

同时，利用 EISEG 作为图像标注工具，从样本数据中随机抽取 500 张已标注的多类别子图像构成监督训练集 (S)，未标注的剩余样本集 (R) 用于检测以

实现 1.4.2 节的半监督模型训练。

1.4 半监督图像标注策略

1.4.1 模型构建

Topformer 是一种移动端语义分割新架构，融合 CNN 与 ViT 优势构建 Token Pyramid Module 和 Semantics Extractor，平衡了精度与计算成本<sup>[26]</sup>。因此，本文将 Topformer 模型作为烟叶病虫害半监督训练的教师模型，并以此提出了新型的学生模型 Efficient-Topformer。

给定 $X \in R^{H \times W \times 3}$ 的输入图像，其中 3，H，W 代表图像的通道、高度和宽度。Token Pyramid Module

能够生成特征 $F_{\times 8}, F_{\times 16}, F_{\times 32}, F_{\times 64}$ ，将输入图像的分辨率下采样了 8、16、32 和 64 倍。研究发现，与 Token Pyramid Module 五个下采样阶段相比，改进后的四阶段架构具有更小的参数开销，同时仍然保持优异的性能。因此，本文使用四阶段结构的 Token Pyramid Module。同时，为了关注到更多不同尺度的烟叶病虫害特征，本文重构了 Scale-aware Semantics Extractor 位置。在四阶段主干的最后两个阶段中接入了 Scale-aware Semantics Extractor 模块，与在不同尺度获得的 token 一起作为 Semantics Injection Module 的输入构建了 Efficient-Topformer，如图 3 所示。




图 3 Efficient-Topformer 网络结构图

Fig. 3 Network architecture of the Efficient-Topformer model

上述方法在减少网络参数及模型计算量的同时，可以获得更加丰富准确的病斑位置信息及语义信息。

1.4.2 半监督训练流程

训练包括 4 个步骤，如图 4 所示。




图 4 半监督训练流程图

Fig. 4 Workflow of the semi-supervised training process

首先，利用 Topformer 作为教师模型在已标注的增强图像及相应的标签数据 S 上进行训练。其次，从

R 样本数据中随机抽取与 S 数量相同的子数据 R1，利用训练后的教师模型预测 R1 样本数据并生成伪标签。

然后, 将  $S$  样本数据和伪标签数据训练学生模型 Efficient-Topformer。最后, 通过迁移学习替换训练权重, 并同时教师模型替换为学生模型。将训练好的学生模型作为教师迭代第一和第二阶段, 直至训练结果稳定, 生成可靠准确的样本数据。

## 2 模型构建与试验

### 2.1 PFMS-YOLO 模型构建

针对现有烟叶常见病虫害识别模型存在识别背景

单一、模型复杂、运算量大的问题, 设计了一种基于 YOLOv8n 的 PFMS-YOLO 模型, 如图 5 所示。

#### 2.1.1 高效特征融合模块设计

YOLOv8n 中使用了较多的 C2f 结构, 采用跨阶段的分支融合设计保证获取丰富梯度信息, 并使模型轻量化。但烟叶常见病虫害病斑相似性高, 类间差距较小, 类内差距较大, 导致复杂背景下识别不准, 且移动端部署需求下轻量化需进一步提升。因此, 本文使用 PoolFormer 和 FasterBlock 重构 C2f 模块。




图 5 PFMS-YOLO 模型网络结构图

Fig. 5 Network architecture of the PFMS-YOLO model

本文对模型主干网络进行改进, 采用基于 PoolFormer 的 C2f 模块替代原结构以平衡模型精度与计算复杂度, 实现轻量化设计。Yu 等证明了网络性能主要取决于架构设计而非具体算子类型<sup>[27]</sup>。如图 6(a) 所示, 典型 MetaFormer 编辑器由注意力模块 (Token Mixer) 和 Channel MLP 等组件构成, “Token Mixer” 将输入特征映射为输出特征, 且不依赖特定算子实现。

图 6(b) 展示了 PoolFormerBlock 的简化实现结构。其输入的 token 序列经过多个 PoolFormerBlock 处理, 每个 block 包含 2 个子模块。首个子模块通过无

参数空间池化算子实现 token 信息交互, 对位置  $(i,j)$  的特征向量, 计算其  $K \times K$  邻域通道均值并保留残差连接。该操作等效于对局部区域特征进行均值平滑, 从而增强特征表达的一致性, 同时避免引入额外的可训练参数。第二个子模块主要由 2 层 MLP 和非线性激活函数组成。首先, 对池化后的特征进行归一化处理, 随后通过 2 层全连接映射至  $rC$  维, 再映射回  $C$  维, 并施加非线性变换。该模块通过低维投影与非线性变换提升特征表示能力, 同时维持计算效率。




图 6 C2f\_PF 模块结构图

Fig. 6 C2f\_PF module structure diagram

如图 6 (c) 所示, C2f\_PF 结构集成 PoolFormerBlock 与卷积层,通过池化操作实现特征高效映射。该设计融合自注意力机制与池化优势,可同步捕捉烟叶病斑的局部细节与全局上下文特征。其架构优势在于利用简单算子即可获得优越性能表现。

C2f\_PF 采用了无参数的池化操作,不仅实现了高效的特征提取与聚合,还保留了模型架构的通用性。由于池化操作无需引入额外参数,避免了复杂的矩阵乘法和注意力计算,其计算复杂度显著低于其他复杂操作,从而进一步降低了模型的计算负担。这种轻量化设计使得模型对硬件资源的需求大幅降低,更适合部署在计算能力受限的设备上,为实际应用场景提供了更高的灵活性和实用性。

本文针对模型部署移动端的需求,在保持特征融

合能力的前提下优化模型精度与轻量化性能。基于 FasterNet 理论对颈部 C2f 模块实施改进,通过部分卷积 (PConv) 与加速神经网络降低计算成本。该方案通过选择性通道处理、计算路径优化、网络层简化、快速激活函数应用及浮点运算量化等策略,有效平衡模型复杂度与识别准确率。

通过观察中间层的特征图,模型中间层特征存在显著冗余性<sup>[28]</sup>。如图 7 所示, PConv 通过选择性通道卷积实现高效空间特征提取,仅对部分连续通道进行计算,其余通道保持不变,从而将计算量降至常规卷积的 1/16,同时保持输入输出通道数一致并减少信息损失。为充分利用所有通道信息,后续加入  $1 \times 1$  逐点卷积,通过 PConv 与逐点卷积的分解组合进一步降低计算复杂度。




图 7 C2f\_EF 模块结构图

Fig. 7 C2f\_EF module structure diagram

C2f\_EF 模块由 PConv 层、 $1\times 1$  卷积层及 EMA 注意力机制协同构成。其中, PConv 层通过部分通道卷积实现空间特征提取, 后接的  $1\times 1$  卷积层配合 BN-ReLU 结构增强特征多样性。EMA 注意力机制通过建立通道间长程依赖关系, 动态校准特征通道权重, 有效提升模型对关键病斑特征的鉴别能力。模块采用倒置残差结构并设置快捷连接, 在加速梯度传播的同时, 通过特征复用机制优化模型训练效率。该设计兼顾特征表达的丰富性与计算效率, 为移动端部署提供可行性保障。




图 8 MultiSEAMHead 模块结构图

Fig. 8 MultiSEAMHead module structure diagram

模块由带有残差连接的深度可分离卷积和全连接层构成<sup>[29]</sup>。深度可分离卷积通过逐层操作学习不同通道的重要性并减少模型参数量, 但难以捕捉通道之间的信息关系。为了弥补缺失信息, 在每个深度卷积的输出后通过逐点卷积进行组合。通过全连接网络融合每个输出通道的信息, 可以加强通道之间连接, 学习遮挡叶片和未遮挡叶片之间的关系。使用指数归一化函数处理全连接层学习到的输出 logits, 将其值的范围从 $[0, 1]$ 扩展到 $[1, e]$ , 从而提供一种单调的映射关系, 降低结果对位置误差的关注度, 增强模型的鲁棒性。MultiSEAMHead 将输出当作注意力机制, 与原始特征

## 2.1.2 轻量化检测头设计

YOLOv8 检测头采用了主流的 Anchor-Free 解耦头, 其运算量约占整个模型的 36.8%, 能以较小的计算开销实现检测。由于大部分烟叶病虫害图像包含复杂背景、多个烟叶叶片和病斑, 存在类间相互遮挡且病斑大小差距大, 影响了模型的精准度。

针对上述问题, 通过引入自主设计的 MultiSEAMHead 轻量化检测头, 能够在保证模型精度的前提下, 减少模型的计算量, 使其更适应资源受限的移动设备, 其结构如图 8 所示。

相乘, 强化病斑区域, 弱化背景以及其他不重要的区域, 提高模型对病斑区域的关注度和遮挡问题的处理能力。

## 2.2 试验

### 2.2.1 试验环境

本文采用了 YOLOv8 默认超参数配置。输入图像分辨率  $640\times 640$  像素, 批尺寸 24, 4 线程并行数据处理, 训练 500 轮次。优化器选用随机梯度下降法 (SGD), 基础学习率 0.01, 动量系数 0.937。训练过程采用预训练模型初始化网络参数, 以提升模型初始性能。试验环境配置如表 1 所示。

表 1 试验环境配置

Tab. 1 Experimental environment configuration

| 试验环境    | 详情                                    |
|---------|---------------------------------------|
| 程序语言    | Python 3.10.15                        |
| 操作系统    | Windows                               |
| 深度学习框架  | Pytorch 2.2.2                         |
| CUDA 版本 | 11.8                                  |
| GPU     | RTX 4090                              |
| CPU     | Intel(R) Core(TM) i9-14900KF @3.2 GHz |

2.2.2 评价指标

试验采用 Precision、Recall、mAP、F1 Score、GFLOPs 以 Parameters 作为模型的评价指标。

$$Precision_i = \frac{True\ Positives}{True\ Positives + False\ Positives} \times 100\% \quad (1)$$

$$Recall_i = \frac{True\ Positives}{True\ Positives + False\ Negatives} \times 100\% \quad (2)$$

$$mAP = \frac{1}{C} \sum_{i=1}^C AP_i \quad (3)$$

$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (4)$$

公式中*i*表示不同的叶片病虫害；True Positives表

示图片中正确检测叶片病虫害的数量；False Positives 表示图像中检测错误与目标分类错误的数量；False Negatives表示图像中漏检的数量；*C*表示数据集中分类的数量，本文为 4；*AP<sub>i</sub>*表示为某一种病虫害的 P-R 曲线与坐标轴围成的面积，能够反应目标检测在某一种病虫害识别精度的性能；mAP表示模型对不同的病虫害的整体检测精度的性能；F1 Score 表示模型在精确度和召回率方面的平衡情况。

3 结果与分析

为对比分析本文改进方法对模型性能的影响，在模型训练参数以及训练环境一致的情况下设计了 2 组试验：主流模型性能对比试验、模块消融试验。

3.1 对比试验结果分析

为系统评估本模型的性能优势，选取与 SSD、Faster R-CNN、Dino 及 YOLO 系列多个版本对比等主流检测模型进行对比试验，结果如表 2 所示。

表 2 主流模型对比结果

Tab. 2 Comparison results of mainstream models

| 模型           | 模型量化指标   |             |      |      |      |        |              |
|--------------|----------|-------------|------|------|------|--------|--------------|
|              | mAP@50/% | mAP@50:95/% | F1   | P/%  | R/%  | GFLOPs | Parameters/M |
| SSD          | 60.1     | 32.3        | 0.48 | 53.9 | 43.5 | 30.6   | 24.1         |
| Faster R-CNN | 66.5     | 34.1        | 0.54 | 51.4 | 55.9 | 137.2  | 41.4         |
| Dino         | 80.7     | 54.7        | 0.66 | 72.0 | 61.6 | 183.3  | 47.5         |
| YOLOv5n      | 72.0     | 52.3        | 0.71 | 78.8 | 65.3 | 4.1    | 1.8          |
| YOLOv5s      | 72.7     | 56.9        | 0.72 | 75.6 | 69.1 | 15.8   | 7.0          |
| YOLOv7       | 82.5     | 60.4        | 0.83 | 86.6 | 78.9 | 105.2  | 37.2         |
| YOLOv7-tiny  | 83.2     | 57.2        | 0.82 | 86.3 | 77.4 | 13.2   | 6.0          |
| YOLOv8n      | 80.4     | 58.9        | 0.78 | 84.5 | 72.3 | 8.1    | 3.0          |
| YOLOv11n     | 82.5     | 60.5        | 0.77 | 84.7 | 71.1 | 6.3    | 2.6          |
| YOLOv12n     | 82.1     | 60.2        | 0.79 | 85.9 | 73.9 | 5.8    | 2.5          |
| PFMS-YOLO    | 84.2     | 62.2        | 0.82 | 88.9 | 75.5 | 5.8    | 4.3          |

表 2 可见，PFMS-YOLO 在目标检测任务中优势显著，尤其在轻量化和精度平衡方面较为突出。试验结果显示，PFMS-YOLOmAP@50、mAP@50:95、F1 Score、精确率和召回率分别为 84.2%、62.2%、0.82、88.9%、75.5%，各项指标均优于对比模型。同时，PFMS-YOLO 的计算开销较低，计算量仅为 5.8GFLOPs，参数量为 4.3M。综上所述，PFMS-YOLO

在保持较高检测精度的同时具备更优的轻量化特性，适用于资源受限的应用场景。

3.2 消融试验结果分析

为验证每一处的改进模块在烟叶病虫害检测任务上的有效性，以 YOLOv8n 为基础网络，进行消融试验，结果如表 3 所示。

表 3 PFMS-YOLO 消融试验结果

Tab. 3 PFMS-YOLO ablation experiment results

| 改进模块   |        |               | 评价指标     |             |      |      |      |        |              |
|--------|--------|---------------|----------|-------------|------|------|------|--------|--------------|
| C2f_Pf | C2f_EF | MultiSEAMHead | mAP@50/% | mAP@50:95/% | F1   | P/%  | R/%  | GFLOPs | Parameters/M |
| —      | —      | —             | 80.4     | 58.9        | 0.78 | 84.5 | 72.3 | 8.1    | 3.0          |
| ✓      | —      | —             | 83.7     | 60.7        | 0.82 | 89.3 | 75.6 | 7.3    | 2.7          |
| ✓      | ✓      | —             | 84.3     | 62.4        | 0.81 | 89.4 | 73.5 | 6.7    | 2.4          |
| ✓      | ✓      | ✓             | 84.2     | 62.2        | 0.82 | 88.9 | 75.5 | 5.8    | 4.3          |

表 3 可见, PFMS-YOLO 通过逐步引入改进模块, 显著提升了模型准确性, 同时更加轻量化。首先, 主干网络引入 C2f\_PF 模块后, 相比基线模型 YOLOv8nmAP@50、mAP@50:95、精确度、召回率均有明显提升, GFLOPs 和参数量显著降低。这表明 C2f\_PF 模块高效的 Token Mixer 设计增强了对烟叶病斑特征信息的捕获能力并降低了计算复杂度和参数量。其次, 网络颈部引入 C2f\_EF 模块后, mAP@50 和 mAP@50:95 进一步提升, 整体性能仍优于基线模型, 计算效率和参数量进一步优化, 体现其特征融合和计算效率的优势。最后, 通过引入 MultiSEAMHead 轻量化检测头, 在保持高精度与高召回率同时, GFLOPs 减少 28.4%, 参数量略升。该模块低计算量、高参数量设计有效提升了对遮挡病斑的检测能力, 并降低计算开销, 提升了模型检测的效率, 参数量略有

提升, 但在可接受范围内。综上, 逐步引入 C2f\_PF、C2f\_EF 和 MultiSEAMHead 模块, 使 mAP@50 提升 3.8%, mAP@50:95 提升 3.3%, F1 Score 达到 0.82, 计算量减少 28.4%, 兼具轻量化和高精度检测优势, 适用于资源受限的应用场景。

不同类型病害识别结果如表 4 所示。改进模型相较原始模型在各指标均有不同程度的提升。其中, PFMS-YOLO 对白星病的检测性能提升最为显著, mAP@50 提升 11.6%, 表明该模型对识别特征不明显或易混淆病害具备更强的判别能力。对黄瓜花叶病和烟青虫的检测也有一定提升, 野火病上的提升较小, 表明该类病害还有一定的提升空间。F1 Score 的提高反映出模型在精准率和召回率之间取得了较好的平衡能力。总体看, PFMS-YOLO 在轻量化的同时, 提升了多类病虫害的检测性能, 具备较强的实用价值。

表 4 不同类型病害识别对比结果  
Tab. 4 Comparison of identification results for different disease types

| 模型        | 病害类型  | 模型量化指标   |             |      |      |      |
|-----------|-------|----------|-------------|------|------|------|
|           |       | mAP@50/% | mAP@50:95/% | F1   | P/%  | R/%  |
| YOLOv8n   | All   | 80.4     | 58.9        | 0.78 | 84.5 | 72.3 |
|           | 黄瓜花叶病 | 85.3     | 62.5        | 0.78 | 87.0 | 70.2 |
|           | 白星病   | 79.8     | 56.1        | 0.8  | 79.7 | 80.0 |
|           | 野火病   | 72.6     | 53.8        | 0.71 | 88.3 | 58.7 |
|           | 烟青虫   | 83.8     | 63.2        | 0.82 | 83.1 | 80.1 |
|           |       |          |             |      |      |      |
| PFMS-YOLO | All   | 84.2     | 62.2        | 0.82 | 88.9 | 75.5 |
|           | 黄瓜花叶病 | 86.7     | 64.1        | 0.82 | 90.6 | 74.9 |
|           | 白星病   | 91.4     | 66.5        | 0.88 | 92.8 | 84.1 |
|           | 野火病   | 73.5     | 54.4        | 0.73 | 88.7 | 61.5 |
|           | 烟青虫   | 85.3     | 63.9        | 0.83 | 83.9 | 81.7 |
|           |       |          |             |      |      |      |

为了更加直观分析病害间的误检情况, 本文绘制了混淆矩阵, 如图 9 所示, 其中行表示真实标签 (True

Labels), 列表示预测标签 (Predicted Labels)。




图 9 混淆矩阵对比图  
Fig. 9 Confusion matrix comparison chart

图 9 可见，改进后模型在各类病害识别上均有提升。黄瓜花叶病识别准确率由 0.70 提升至 0.74，误判为野火病的比例由 0.08 降至 0，完全消除了该类的误判；野火病的识别准确率由 0.54 升至 0.62，误判为黄瓜花叶病的比例由 0.11 降至 0.03，表明模型对这两类易混淆病害之间的区别能力增强；白星病识别准确率由 0.80 提升至 0.89，表明模型对白星病的识别更加精准；烟青虫识别准确率稳定在高水平，同时对背景的

误判率略有下降，体现了良好的鲁棒性。此外，背景类别误判为病虫害的比例普遍下降，说明模型在病害与背景之间的区分能力也得到了提升。综上，改进模型在减少病害间混淆和降低背景干扰方面表现更优。

3.3 模型热图生成对比分析

为进一步突出改进模型的优势，本文利用 EigenCAM<sup>[29]</sup>展示了 YOLOv8n 和 PFMS-YOLO 在烟叶病虫害检测任务中的关注区域，结果如图 10 所示。





图 10 不同模型输出热力图可视化对比  
Fig. 10 Comparison of heatmap outputs across different models

PFMS-YOLO 相较于 YOLOv8n 在特征表征能力和复杂背景适应性方面显著提升，能更加准确聚焦于病斑主干区域的细粒度纹理特征。尤其在孔洞型病斑中，该模型实现了病灶区域的全域覆盖，在保持边缘特征完整性的同时有效抑制背景干扰。可视化结果表明，PFMS-YOLO 在复杂田间环境下仍能维持稳定的病理特征提取性能，其热力图分布与人工标注具有较

高空间一致性。

3.4 不同模型烟叶病虫害检测可视化分析

使用训练好的 SSD、Faster R-CNN、Dino、YOLOv5n、YOLOv5s、YOLOv7、YOLOv7-tiny、YOLOv8n、YOLOv11n、YOLOv12n 以及 PFMS-YOLO 模型对自然场景下的烟叶常见病虫害进行检测，结果如图 11 所示。



注：红色圆圈代表未检测到的病斑区域，黄色圆圈代表检测错误或重复的病斑区域。  
Note: Red circles represent regions where disease spots were not detected, while yellow circles denote misdected or duplicated disease-spot regions.

图 11 不同模型可视化结果对比  
Fig. 11 Comparison of visualization results among different models

图中红色圆圈标示了漏检病斑区域,黄色圆圈标示了误检或重复检测病斑区域。可视化结果表明,PFMS-YOLO 在多烟叶、多病斑的复杂背景下表现出更高的检测精度,其检测框与目标尺寸的匹配更为准确。特别是在边缘区域病斑检测方面尤为突出,这主要归因于所引入的 MultiSEAMHead 轻量化检测头,该模块通过逐通道分离卷积和通道信息融合,有效提升了复杂场景中病斑的识别能力。

综上所述,本文提出的烟叶常见病虫害检测模型具有较强的泛化能力和鲁棒性,能够高效准确地定位烟叶病斑的关键特征,实现多种类型病虫害的精准检测。

## 4 结论

为解决烟叶病虫害识别标注成本高、背景干扰多、相似病斑难区分以及模型精度与轻量化难平衡等问题,提出了一种融合半监督学习的图像标注策略和基于 YOLOv8n 的轻量化烟叶病虫害识别模型(PFMS-YOLO),不仅降低了数据标注工作的复杂度,而且在保证对病虫害高精度识别的同时,显著降低了计算开销,适合部署于计算资源受限的边缘设备。主要结论如下:

(1) 融合半监督学习的图像标注策略以 Topformer 作为教师模型生成伪标签数据,并基于此训练改进后的学生模型 Efficient-Topformer,减少了 54.2%标注工作量。

(2) PFMS-YOLO 通过三方面改进实现性能突破:首先,主干网络设计了 C2f\_PF 模块,通过特征压缩与跨层融合策略,mAP@50、mAP@50:95 分别提升 3.4%、3.3%,计算量、参数量分别降低了 9.9%、10.0%;其次,颈部网络构建了 C2f\_EF 模块,采用部分卷积与 EMA 注意力协同优化策略,在保持 84.1%检测精度的基础上,将计算量压缩至 6.7GFLOPs,参数量精简至 2.4M;最后,设计 MultiSEAMHead 轻量化检测头,通过多参数、低运算架构增强边缘病斑特征感知能力与遮挡场景下的检测鲁棒性。

(3) 在复杂自然场景烟叶数据集上,PFMS-YOLO 以 5.8GFLOPs 计算量与 4.3M 参数量实现 84.2%的 mAP@50,计算量较 YOLOv8n 降低 28.4%。试验结果表明,PFMS-YOLO 有效解决了农田自然环境下背景干扰、叶片遮挡以及病斑形态相似等导致的烟叶病虫害难识别难题。在精度和轻量化方面均优于主流目标检测模型(SSD、Faster R-CNN、Dino 及 YOLO 系列多个版本),为资源受限的实际应用场景提供了可靠的技术方案。

未来研究中,将依据《GBT 23222—2008 烟草病虫害分级及调查方法》,结合烟草病虫害图像特征,利用深度学习技术,构建烟草病虫害自动分级模型,实现烟草病虫害发生程度的精细化评估,为智能化监测与防治提供可靠的数据支撑与决策依据。

## 参考文献

- [1] 郭兆奎. 暂时放下冠状病毒,说说烟草病毒[J]. 中国烟草学报, 2020, 26(02): 2.  
GUO Zhaokui. Let's temporarily put aside the COVID-19 and talk about the tobacco virus[J]. Acta Tabacaria Sinica, 2020, 26(2): 2.
- [2] 郑倩萍, 缪应舜, 周津弘, 等. 烟草害虫绿色防控技术研究进展[J]. 植物保护学报, 2025, 52(01): 31-39.  
ZHENG Qianping, MIAO Yingshun, ZHOU Jinhong, et al. Research progress on green control technology of tobacco pests[J]. Journal of Plant Protection, 2025, 52(1): 31-39.
- [3] 赵宇婷, 谢晏芬, 曾朝懿, 等. 基于文献计量学的烟草病毒研究知识图谱分析[J]. 中国烟草学报, 2024, 30(01): 83-97.  
ZHAO Yuting, XIE Yanfen, ZENG Chaoyi, et al. Knowledge mapping analysis of tobacco virus research based on bibliometrics[J]. Acta Tabacaria Sinica, 2024, 30(1): 83-97.
- [4] 李佳欣, 李梦瑶, 赵欢, 等. 我国烟草常见病虫害及防治措施研究进展[J]. 现代农业科技, 2024, (19): 68-72+80.  
LI Jiaxin, LI Mengyao, ZHAO Huan, et al. Research progress on common tobacco diseases and pests and their control measures in China[J]. Modern Agricultural Science and Technology, 2024, (19): 68-72+80.
- [5] 曹振亮, 贾博轩, 吴甜, 等. 云南省烟田常见病虫害及绿色防治技术[J]. 现代农业科技, 2024, (16): 211-213+217.  
CAO Zhenliang, JIA Boxuan, WU Tian, et al. Common diseases and pests in tobacco fields in Yunnan province and its green control techniques[J]. Modern Agricultural Science and Technology, 2024, (16): 211-213+217.
- [6] 许天富, 赵海燕, 刘健锋, 等. 植保无人机烟草大田施药作业参数优选[J]. 中国烟草科学, 2024, 45(02): 108-115.  
XU Tianfu, ZHAO Haiyan, LIU Jianfeng, et al. Optimization of pesticide application parameters for plant protection Unmanned Aerial Vehicle (UAV) in tobacco fields[J]. Chinese Tobacco Science, 2024, 45(2): 108-115.
- [7] XU W, LI W. Deep residual neural networks with feature recalibration for crop image disease recognition[J]. Crop Protection, 2024, 176: 106488.
- [8] LU Y, YU X, HU Z, et al. Convolutional neural network combined with reinforcement learning-based dual-mode grey wolf optimizer to identify crop diseases and pests[J]. Swarm and Evolutionary Computation, 2025, 94: 101874.
- [9] KUMAR B M, RAO K R K, NAGARAJ P, et al. Tobacco plant disease detection and classification using deep convolutional neural networks [C]//2022 International Conference on Sustainable Computing and Data Communication Systems (ICSCDS). IEEE, 2022: 490-495.
- [10] LIN J, CHEN Y, PAN R, et al. CAMFFNet: A novel convolutional neural network model for tobacco disease image recognition[J]. Computers and Electronics in Agriculture, 2022, 202: 107390.
- [11] PENG H, YUANG J, HAN G, et al. TDR-Net: Tobacco disease recognition using improved GoogLeNet Network[C]//2022 3rd International Conference on Computer Vision, Image and Deep Learning & International Conference on Computer Engineering and Applications (CVIDL & ICCEA). IEEE, 2022: 726-731.
- [12] 张文静, 孙秀朋, 乔永亮, 等. 基于 InceptionV3 的烟草病害识

- 别[J]. 中国烟草学报, 2021, 27(05): 61-70.
- ZHANG Wenjing, SUN Xiupeng, QIAO Yongliang, et al. Tobacco disease identification based on InceptionV3[J]. Acta Tabacaria Sinica, 2021, 27(5): 61-70.
- [13] KALEZHI J, SHUMBA L. Cassava crop disease prediction and localization using object detection[J]. Crop Protection, 2025, 187: 107001.
- [14] HU H, TANG C, SHI C, et al. Detection of residual feed in aquaculture using YOLO and Mask RCNN[J]. Aquacultural Engineering, 2023, 100: 102304.
- [15] MA C, CHI G, JU X, et al. YOLO-CWD: A novel model for crop and weed detection based on improved YOLOv8[J]. Crop Protection, 2025: 107169.
- [16] WANG N, FU S, RAO Q, et al. Insect-YOLO: A new method of crop insect detection[J]. Computers and Electronics in Agriculture, 2025, 232: 110085.
- [17] ZHOU P, ZHU Y, JIN C, et al. A new training strategy: Coordinating distillation techniques for training lightweight weed detection model[J]. Crop Protection, 2025: 107124.
- [18] 刘延鑫, 王俊峰, 杜传印, 等. 基于 YOLOv3 的多类烟草叶部病害检测研究[J]. 中国烟草科学, 2022, 43(02): 94-100.
- LIU Yanxin, WANG Junfeng, DU Chuanyin, et al. Detection of various tobacco leaf diseases based on YOLOv3[J]. China Tobacco Science, 2022, 43(2): 94-100.
- [19] 刘春菊, 刘延鑫, 李斐, 等. 基于 YOLOv5 的烟草叶部病害智能识别[J]. 中国烟草科学, 2024, 45(03): 93-101.
- LIU Chunju, LIU Yanxin, LI Fei, et al. Intelligent recognition of tobacco leaf diseases based on YOLOv5[J]. China Tobacco Science, 2024, 45(3): 93-101.
- [20] WANG Y, YI C, HUANG T, et al. Research on intelligent recognition for plant pests and diseases based on improved YOLOv8 model[J]. Applied Sciences, 2024, 14(12): 5353-5353.
- [21] PRAKASH V J, NITHYA D L M. A survey on semi-supervised learning techniques[J]. arXiv preprint arXiv: 1402.4645, 2014.
- [22] OUALI Y, HUDELOT C, TAMI M, 2020. An Overview of deep semi-supervised learning. arXiv preprint arXiv: 2006.05278.
- [23] SOHN K, ZHANG Z Z, LI C L, et al. 2020. A simple semi-supervised learning framework for object detection. arXiv preprint arXiv: 2005.04757.
- [24] LI G, LI X, WANG Y, et al. Pseco: Pseudo labeling and consistency training for semi-supervised object detection[C]// European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 457-472.
- [25] LIU Y C, MA C Y, DAI X, et al. Open-set semi-supervised object detection[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 143-159.
- [26] ZHANG W, HUANG Z, LUO G, et al. Topformer: Token pyramid transformer for mobile semantic segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 12083-12093.
- [27] YU W, LUO M, ZHOU P, et al. Metaformer is actually what you need for vision[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10819-10829.
- [28] CHEN J, KAO S, HE H, et al. Run, don't walk: chasing higher FLOPS for faster neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 12021-12031.
- [29] YU Z, HUANG H, CHEN W, et al. Yolo-facev2: A scale and occlusion aware face detector[J]. Pattern Recognition, 2024, 155: 110714.

## Lightweight detection of major tobacco pests and diseases in Shandong based on Semi-supervised learning and an improved YOLOv8n

SONG Xinlong<sup>1,3</sup>, ZHANG Feng<sup>1,4</sup>, WU Huarui<sup>2,3</sup>, ZHU Huaji<sup>2,3</sup>, GAO Qiangsan<sup>1,3</sup>,  
YAN Zhaoyang<sup>1,3</sup>, WU Qiulan<sup>1,4\*</sup>, SUN Xiang<sup>2,3</sup>

1 College of Information Science and Engineering, Shandong Agricultural University, Taian 271018, China;

2 Information Technology Research Center, Beijing Academy of Agriculture and Forestry Sciences, Beijing 100097, China;

3 Key Laboratory of Digital Village Technology, Ministry of Agriculture and Rural Affairs, Beijing 100097, China;

4 Key Laboratory of Huang-Huai-Hai Smart Agricultural Technology, Ministry of Agriculture and Rural Affairs, Taian 271018, China

**Abstract:** [Objective] Tobacco leaf disease and pest detection in complex natural environments faces challenges such as limited detection accuracy, high computational cost, and difficulty in deploying models on mobile or edge devices. To address these issues, this study proposes PFMS-YOLO, a lightweight detection model that integrates semi-supervised learning with an enhanced YOLOv8n architecture. [Methods] Firstly, Topformer was employed as the teacher model to generate pseudo-labels, and an improved student model, Efficient-Topformer, was trained accordingly, reducing annotation cost by approximately 54.2%. Next, three major structural improvements were introduced to the YOLOv8n framework: (1) A C2f\_PF module was designed for the backbone network, leveraging simple pooling operations to achieve efficient feature extraction and fusion, thereby improving detection accuracy while reducing computational burden and parameter count. (2) In the neck network, the original C2f module was replaced with a C2f\_EF module, which integrates partial convolution with an EMA attention mechanism to collaboratively optimize performance and further reduce computation and parameters without sacrificing accuracy. (3) A lightweight detection head, MultiSEAMHead, featuring multiple low-complexity parameter operations, was introduced to strengthen edge-lesion perception and enhance robustness under occlusion. [Result] Experimental results show that PFMS-YOLO achieves an mAP@50 of 84.2% on a complex natural-scene tobacco leaf dataset, while reducing GFLOPs to 5.8 and parameters to only 4.3M—outperforming other mainstream lightweight models. [Conclusion] The proposed PFMS-YOLO model offers a practical and effective solution for real-time tobacco disease and pest detection in resource-constrained environments, supporting deployment on mobile and edge devices.

**Keywords:** tobacco disease and pest; object detection; tobacco leaf; lightweight model; YOLOv8n

\*Corresponding author. Email: zxy1sg@sdaa.edu.cn