

徐天然, 王瑞, 韩清林, 等. 基于改进 Densenet 的烟草叶片病害识别方法[J]. 中国烟草学报, 2026, 32 (2): 135-145. XU Tianran, WANG Rui, HAN Qinglin, et al. Tobacco leaf disease recognition method based on improved DenseNet[J]. Acta Tabacaria Sinica, 2026, 32(2):135-145. doi:10.16472/j.chinatobacco. 2025. T0334

基于改进 Densenet 的烟草叶片病害识别方法

徐天然¹, 王瑞¹, 韩清林¹, 张斌¹, 赵乾², 韩宜彤^{3*}, 许向阳³

1 山东中烟工业有限责任公司滕州卷烟厂, 山东省滕州市鲁班大道 3001 号 277599;

2 枣庄科技职业学院, 山东省滕州市学院东路 888 号 277599;

3 北京理工大学自动化学院, 北京市海淀区中关村南大街 5 号 100081

摘要:【背景和目的】基于改进的 DenseNet 实现对烟草叶片病害的实时准确识别, 保障烟叶的品质和产量。【方法】使用基于多尺度特征融合和注意力机制改进的 DenseNet 模型, 建立一个烟草叶片病害的高精度分类方法。由 SEBlock 和多尺度特征融合组成 SE-MSFF-Deep Block, 以提取多尺度特征。分类层前加入 ViT 风格的 Attention 结构, 整合分散的病害特征区域。引入 Focal Loss 函数作为损失函数, 提高难分样本的识别准确率。使用迁移学习, 解决小数据集的过拟合问题。【结果】SMVF-DenseNet 模型的烟草叶片病害准确率达到 94.44%, FPS 为 23.69, 相较于其他主流模型, 显著降低了难分样本和少数类别样本的类间混淆。同时, SMVF-DenseNet 模型在跨作物病害数据集上能保持有竞争力的、甚至领先的分类准确率, 显示出良好的泛化能力。【结论】基于多尺度特征融合和注意力机制的烟草叶片病害识别方法有效捕获病害斑块细节与整体的特征与关联, 提高模型在易混淆类别上的分类准确率。在其他植物病害数据集上的验证结果表明, 该方法不仅在烟草病害识别中表现优异, 也具备良好的跨作物泛化性能, 为植物病害识别模型的普适化应用提供了可行方案。

关键词: 烟草病害识别; DenseNet; 多尺度特征融合; 注意力机制

0 引言

烟草是我国重要的农业经济作物, 烟叶的质量与产量直接关系到烟草的经济效益与发展^[1]。然而, 在烟草的整个生长周期中, 叶片极易受到诸如角斑病、褐斑病、花叶病、气候斑病等多种病害的侵袭^[2]。因此, 为了最大限度减少产量损失, 保障烟叶品质, 对烟草病害进行及时、准确的检测与识别, 已成为现代烟草农业生产中不可或缺的关键环节。

长期以来, 国内外学者围绕烟草病害的快速、准确检测技术开展了广泛研究。早期研究主要依赖于支持向量机 (SVM)、随机森林等传统分类器^[3,4]。潘兆杰等^[5]基于 SVM 提出了 FNG-NMFW 波段选择算法, 对烟草高光谱数据特征进行提取与降维, 实现了 TMV 与 PVY 两种病害的高精度识别, 总体精度达 94.46%。张红涛等^[6]通过蚁群算法选择最优特征组合, 并优化

SVM 参数, 实现了对烟草蛙眼病与赤星病 96% 的高精度识别。然而, 这些传统方法在很大程度上依赖于特征工程的设计质量, 存在环境适应性较差以及对早期病害识别精度不足的挑战。

近年来, 卷积神经网络 (convolutional neural networks, CNN) 因其强大的泛化能力和快速的收敛速度, 逐渐成为烟草病害检测的主流方法^[7-9]。谢裕睿等^[10]通过对比 SVM 与 ResNet 模型在五种烟草病害图像上的识别效果, 证实了基于深度残差网络的方法识别准确率显著更高。张文静等^[11]基于 InceptionV3 网络, 采用迁移学习与图像融合技术对五种常见烟草病害进行识别, 准确率较原始数据集提升 29.71%, 有效实现了高效准确的病害智能诊断。刘春菊等^[12]通过为 YOLOv5 网络引入多尺度增强模块与小目标检测层, 显著增强了小目标病斑的检测能力。这些方法缺乏对

作者简介: 徐天然 (1980—), 本科, 工程师, 主要从事烟草设备、技术改造和烟草加工工艺, Tel: 13869492333, Email: 88193630@qq.com

通讯作者: 韩宜彤 (2002—), 硕士研究生在读, 主要从事农业图像处理和大语言模型研究, Tel: 15231555556, Email: hyt15231555556@163.com

收稿日期: 2025-09-14; **网络出版日期:** 2026-02-25

病斑区域的动态注意力引导, 导致模型对早期症状和类间相似病害的判别精度有限^[13]。

DenseNet 通过密集连接实现所有层级特征的直接复用, 每一层都可直接访问浅层细节特征和深层语义特征, 可以有效捕捉细微和全局的烟草叶片病害特征^[14,15]。本文提出了一种基于多尺度特征融合与注意力机制增强的 DenseNet 模型 (SMVF-DenseNet), 用于实现烟草叶片病害的高精度分类。针对病害斑块多尺度分布及语义信息分散的特点, 本文设计了 SE-MSFF-Dense 模块, 通过在每个密集块末端嵌入 SEBlock 实现通道层面的自适应特征校准, 并结合跨层级的多尺度特征融合机制, 增强模型对不同尺度病害特征的捕捉能力。为进一步整合分散的病害语义信息, 在主干网络末端引入 ViT 风格的自注意力模块, 对卷积阶段提取的局部特征进行全局上下文建模, 从而强化关键区域之间的长程依赖。针对训练中存在的类别不平衡与难分样本问题, 采用 Focal Loss 作为损失函数, 以降低易分类样本权重, 聚焦难例判别。此外, 本研究借助在 Plant Village 公开数据集上预训练的模型参数进行迁移学

习, 有效缓解小样本条件下的过拟合风险, 进一步提升模型在实际场景中的泛化能力。

1 烟草叶片病害识别方法

1.1 SMVF-DenseNet 整体模型结构

本文基于 DenseNet121 框架, 提出了一种融合多尺度特征与注意力机制的烟草叶片病害分类模型 (SMVF-DenseNet), 其整体结构如图 1 所示。

该模型在保留原有稠密连接结构的基础上, 进行了 3 方面关键改进: (1) 在 Bottleneck 结构中引入多尺度卷积核, 在同一网络层级捕获不同感受野下的病害特征, 增强模型对多尺度病变模式的表征能力。(2) 在每个密集块内部的 Bottleneck 末端嵌入 SEBlock 模块, 通过显式建模通道依赖关系, 使模型能够自适应地校准不同层级中的特征响应, 强化与病害相关的判别性特征。(3) 在最后一个 DenseBlock 之后, 引入一种基于卷积投影的 ViT 风格自注意力模块, 聚合前部卷积网络所提取的局部特征, 以建立分散的病害区域间的全局关联。




图 1 网络模型整体结构图

Fig. 1 Overall structure of the network model

此外,模型沿用 Transition 层实现块间特征压缩与降维,以控制计算复杂度,在保持 DenseNet 特征复用优势的同时,进一步增强了对多尺度局部特征与全局语义关系的协同建模能力。




图 2 多尺度特征融合模块结构图

Fig. 2 Structure of multi-scale feature fusion module

因此本文引入多尺度特征融合机制,在每个 Bottleneck 中并行采用 1×1 、 3×3 和 5×5 不同尺寸的卷积核进行特征提取,并将输出特征进行拼接,结构如图 2 所示。该设计有效增强了网络对多尺度烟草病害表征的感知能力,改善模型对不同形态和尺度病斑特征的响应性能。

具体而言,将原模型中输出通道数为 $4k$ 的 1×1 卷积替换为 3 路并行卷积结构:包括 1×1 卷积、 3×3 卷积和 5×5 卷积,其输出通道比例为 $2:1:1$ 。该比例设置使较小卷积核占据更多通道容量,引导模型更关注叶片局部细微的纹理变化与颜色差异,有助于提升模型对早期烟草病害症状的特征提取能力。

1.3 SEBlock

DenseNet 虽聚合了多尺度特征,但未显式区分其重要性,无法动态聚焦关键病害特征。另外,对于形态相似的病害,如褐斑病与靶斑病、蛙眼病和气候斑病,普通卷积特征缺乏对细微通道差异的放大能力,易导致分类混淆。为解决上述问题,本文在每个密集块内部的 Bottleneck 末端嵌入 SEBlock 模块,引入通道注意力机制,从而在网络的不同层级动态强化与病斑颜色、纹理相关的判别性特征通道,同时有效抑制由背景、光照等因素引起的无关特征干扰。

SEBlock 模块通过压缩-激励操作,显式地建模通道间的依赖关系,如图 3 所示。通过全局平均池化将每个通道的空间维度 ($H\times W$) 压缩为 1 个标量,从而聚合全局空间信息。激励操作通过由 2 个线性层构

1.2 多尺度特征融合模块

DenseNet 网络虽然通过密集连接增加了信息的流动,但由于不同烟草病害表征尺度和空间分布差异大,且随生长阶段动态变化,单一尺度特征提取可能导致信息损失问题,无法充分地捕捉到细微及多样性病斑特征。

成的小型全连接网络实现,通过第一个线性层及 ReLU 激活函数对通道向量进行降维,再经第二个线性层及 Sigmoid 激活函数恢复原始通道数,并生成介于 0 到 1 之间的各通道重要性权重。最终,该权重向量与原始输入特征图进行逐通道相乘,实现特征重标定,从而提升模型在复杂背景和类间差异细微任务上的识别精度。




图 3 SEBlock 模块结构图

Fig. 3 Structure of SEBlock module

SEBlock 模块通过逐层嵌入的设计,使模型能够自底向上地优化特征质量,显著提升了对细微病斑、

早期症状以及类间相似病害的视觉区分能力。

1.4 ViT 风格的 Attention 模块

DenseNet 感受野受卷积核尺寸限制,难以有效捕捉分散在图像不同区域的病斑特征之间的语义关联。尤其是在复杂背景的烟草叶片图像中,病害区域往往分布不规则且彼此孤立,导致局部卷积特征无法形成有效的全局表征。本文在最后一个 DenseBlock 之后嵌入 ViT 风格的 Attention 模块^[16],直接处理经过多个密集块优化后的高层特征,并在语义层面建立全局依赖关系,为最终分类提供结构化的特征表示。

图 4 展示了自注意力模块的架构。该模块首先通过层归一化对输入特征进行标准化,提升训练稳定性。然后利用 1×1 卷积生成 Query、Key 与 Value 向量,并将其拆分为多注意力头,以并行学习不同的特征表示模式。通过缩放点积计算注意力权重,获取全局空间上的相关性分布。最终将加权的值向量投影回原始特征空间,并通过残差连接与原特征融合,在稳定训练的同时保留原始局部特征。




图 4 自注意力模块结构图

Fig. 4 Structure of ViT style attention module

该模块通过聚合前部卷积网络所提取的局部特

征,建立分散的病害区域间的全局关联。这种改进能够显著增强模型对分散小病斑的感知能力,并有效识别跨区域出现的复杂病征模。既保留了 DenseNet 在局部特征提取上的优势,又弥补了其在全局上下文建模上的不足。

1.5 Focal Loss 损失函数

在烟草叶片病害识别任务中,由于早期病害特征(如花叶病、气候斑病等)在视觉表现上往往不明显,病斑颜色淡、纹理变化细微,且多分布于叶缘或叶脉附近,不同病害类型在发病初期表征相似,难以通过肉眼或普通模型准确区分。同时,健康烟草叶片图像数量通常远多于病害样本,导致数据集存在显著类别不平衡,模型易偏向于将多数类(健康叶片)正确分类,而忽略对相似病害样本的判别。因此,本文采用 Focal Loss 作为损失函数,通过动态调节样本权重,增强模型对细微病斑特征的敏感性。

Focal Loss 函数,如式 1,通过引入 1 个动态缩放因子,使得对易分类的样本的损失贡献减小,从而使模型更加关注难以分类的样本,有助于提升模型在类别不平衡情况下的性能^[17]。

$$FL(p_t) = -(1 - p_t)^\gamma \log(p_t) \quad (1)$$

其中, p_t 是预测的概率值, γ 是调节因子,用于调节易分类样本的权重。 p_t 的计算通常如式 2 所示。

$$p_t = \begin{cases} p, & \text{if } y = 1 \\ 1 - p, & \text{otherwise} \end{cases} \quad (2)$$

其中, y 的取值为 1 和 -1, 分别代表前景和背景。 p 是模型预测属于前景的概率,取值范围为 0~1。

Focal Loss 通过调制因子动态降低易分类样本(如明显健康叶片)的损失贡献,使训练过程更聚焦于难分类的病害样本及早期症状,增强模型对细微病斑特征的敏感性和鲁棒性。

2 结果与分析

2.1 数据集介绍

本研究使用公开的烟草病害图像数据集 TPDD (Tobacco Plant Disease Dataset) 作为实验数据集。TPDD 开源部分共包含 1453 张在实地环境中拍摄的烟草叶片图像,这些图像按两种焦距模式拍摄,涵盖 12 个不同的类别^[18]。其中部分难分症状如图 5 所示。




图 5 TPDD 数据集部分样本示例
Fig. 5 Sample images from the TPDD dataset

本研究从近焦距图像中选取了 520 张图片进行实验，实验按照 8:1:1 比例划分为训练集、验证集和测试集。通过对训练集图像进行缩放、旋转、镜像等数据增强处理，最终将其扩充至 1248 张烟草病害图像^[19]，详细的类别分布情况如表 1 所示。

表 1 训练数据集类别分布情况
Tab. 1 Class distribution of the training dataset

类别名称 (Category name)	数量 (Number of samples)	类别名称 (Category name)	数量 (Number of samples)
角叶斑病	54	马铃薯 Y 病毒病	222
炭疽病	66	破烂叶斑病	24
褐斑病	153	靶斑病	114
蛙眼病	129	气候斑病	129
花叶病	150	野火病	63
白粉病	21	健康	123

2.2 迁移学习

由于缺少烟草叶片病害的大型数据集，本研究使用公开数据集 Plant Village 作为源数据集进行迁移学

习，缓解小样本产生的过拟合问题。Plant Village 数据集是一个非常庞大的植物病虫害数据集，涵盖了多种作物如玉米、番茄、马铃薯等 14 个种植物的不同病害和健康状态的图像，数据集按种类和疾病分为 39 类，共包含 54306 张植物叶片图像^[20]。

将 Plant Village 在改进后的模型中训练好的模型权重参数作为初始化权重，迁移至基于改进 DenseNet 的烟草病害识别网络中，冻结位置仅对模型中关键的功能性层启用梯度更新，包括最后一层稠密连接层、自注意力模块和分类层。其余层均保持冻结状态，以保留预训练阶段所学习到的通用特征表示，避免因过度调整而导致的过拟合现象。

2.3 模型训练与评价指标

本研究基于搭载 Intel Xeon Platinum 8352V CPU 和 NVIDIA RTX 4090 GPU 的计算平台完成，操作系统是 Ubuntu 20.04，使用 Pytorch 1.11.0 实现深度神经网络，检测环境包括 CUDA 11.3、Python 3.8。输入图像调整为 84×84 像素，采用 Adam 优化算法（初始学习率 0.0001，权重衰减 1e-5），batch size 为 16，训练轮数为 30，结合控制变量原则，在后续实验中均保持上述超参数设置。

评估指标包括精确率 P 、召回率 R 、准确率 Accuracy、F1 分数，计算公式如下^[21]：

$$P = \frac{TP}{TP+FP} \tag{3}$$

$$R = \frac{TP}{TP+FN} \tag{4}$$

$$Accuracy = \frac{TP+TN}{TP+FP+TN+FN} \tag{5}$$

$$F1 = \frac{2PR}{P+R} \tag{6}$$

其中， TP 为真正例， TN 为真反例， FP 为假正例， FN 为假反例。 P 是模型预测的正样本中真正例的数量。 R 是所有正例中被模型正确检测出来的样本数量， $F1$ 用于中和精确率和召回率的指标。

为综合评估中模型在多分类任务上的性能，后续

实验均采用加权平均法计算精确率、召回率与 F1 分数。针对每个类别单独计算其精确率与召回率，然后依据各类别在测试集中的真实样本数量（即支持度）作为权重，进行加权平均求和。加权平均 F1 分数则由加权后的精确率与召回率计算得出。

2.4 消融实验

为了验证基于注意力机制和多尺度特征融合改进的 DenseNet 模型的优越性，以及 Focal Loss 函数在样本不平衡场景下对模型性能的提升，本研究基于 DenseNet121 网络，使用 TPDD 数据集对 SEBlock、MSFF、ViT style Attention 模块和 Focal Loss 的组合，基于迁移学习进行消融试验。

表 2 消融实验结果对比
Tab. 2 Results of the ablation study

模型名称 (Method)	精确率 (P)	召回率 (R)	准确率 (Acc)	F1 分数 (F1-Score)
DenseNet	85.46%	72.76%	81.48%	78.60%
MSFF+DenseNet	79.06%	82.70%	83.33%	80.84%
SE+DenseNet	86.85%	85.62%	87.04%	86.23%
ViTSA+DenseNet	84.93%	82.18%	84.62%	83.53%
SE+MSFF+DenseNet	88.51%	80.49%	88.20%	84.31%
SE+MSFF+ViTSA+DenseNet	93.17%	91.90%	92.59%	92.87%
SE+MSFF+ViTSA+DenseNet+FL	94.44%	93.23%	94.44%	93.83%

实验结果如表 2 所示，可以看到添加 MSFF 模块的模型相较于原模型，F1 分数提升了 2.24%，准确率提高了 1.85%，增强了模型对不同粒度层次特征信息的捕获能力。引入 SE 模块后，重新校准特征通道权重，各项指标均有所提升，准确率和 F1 分数相较于 baseline 分别上升 5.56%、7.63%。ViT Style Attention 模块弥补了卷积网络在全局建模上的短板，其独立应用时使模型准确率提高了 3.14%，F1 分数提升了 4.93%。在与 SE 及 MSFF 结构联合作用时，ViT Style Attention 模块通过全局自注意力机制对深度特征进行重构，模型性能实现大幅提升，相比与 SE+MSFF 模型，精确率、召回率、准确率和 F1 分数分别上升 4.66%、11.41%、4.39%和 8.22%。最终，采用 FocalLoss 损失函数进一步优化模型，在各类别不平衡的病害数据集

上取得最佳性能，准确率提升至 94.44%，F1 分数提升至 93.83%，验证了 FocalLoss 在处理类别不平衡问题方面的有效性。消融实验结果说明各模块改进都有利于模型整体性能的提升，且各模块间展现出良好的协同效应。

图 6 展示了训练过程中损失值与准确率的变化曲线，可以看到，模型在验证集上的表现与训练集高度同步，泛化误差极小，且验证集损失曲线在保持下降的同时未出现任何反弹迹象。说明了本文提出的 SMVF-DenseNet 模型并非仅通过参数堆叠提升拟合能力，而是通过引入有效的感官归纳偏置，在小数据集条件下成功抑制了过拟合，显著增强了模型对复杂特征的泛化与判别能力。




图 6 SMVF-DenseNet 模型在训练集与验证集上的损失函数 (a) 与准确率变化曲线 (b)

Fig. 6 Training and validation loss and accuracy curves of SMVF-DenseNet

为全面评估本文提出的 SMVF-DenseNet 模型在烟草叶片病害识别任务中的性能表现, 图 7 分别展示了 DenseNet 基准模型与改进后 SMVF-DenseNet 模型对测试集的混淆矩阵。改进前的 DenseNet121 网络存在多个类别的误判情况, 例如炭疽病和蛙眼病, 褐斑病和靶斑病等相似病症病害容易发生混淆, 另外由于

类别数量差异, 角叶斑病识别准确率较差。而改进后的 SMVF-DenseNet 模型的分类精度得到了显著提升, 有效减少了难分样本和少数类别样本的类间混淆, 使得模型能够更精确地区分相似病害, 从而大幅提升了模型的整体识别性能。说明了所提出的方法在复杂病害识别任务中的有效性和优越性。




图 7 基准模型 (a) 与改进后 SMVF-DenseNet 模型 (b) 的混淆矩阵

Fig. 7 Confusion matrices of the baseline model and SMVF-DenseNet

2.5 与主流方法的对比实验

为了全面评估本研究提出的 SMVF-DenseNet 模型的性能, 我们将其与当前几种主流的深度学习分类模型进行了对比, 包括 ResNet34、ResNet152、VGG16、

InceptionV3、MobileNetV3 large、MobileNetV3 small、DenseNet169、DenseNet20ViT。所有模型均在相同的实验环境下进行训练和测试, 以确保结果的公平性。

对比结果如表 3 所示。SMVF-DenseNet 模型在各

项性能指标上均表现出显著的优越性。尤其是在准确率和 F1 分数方面,SMVF-DenseNet 分别达到了 94.44% 和 93.83%,相较于 ResNet34、ResNet152、VGG16、InceptionV3 等传统卷积模型均有显著提升。特别是与 ResNet34 和 ShuffleNetV2 相比,SMVF-DenseNet 在 F1 分数上分别提高了约 33.97%和 38.59%,说明所提出的多尺度特征融合与注意力机制能够有效增强模型对细粒度病斑差异的捕获能力。与原始的 DenseNet 系列模型相比,SMVF-DenseNet 在准确率和 F1 分数上的提升也超过了 14%。

值得注意的是,MobileNetV3 large 和 MobileNetV3 small 这两个轻量级模型分别取得了 88.91%和 89.13%的 F1 分数,推理速度最高可达到 497.49 FPS,具备明显的部署效率优势。然而,根据下一章节的泛化性能实验结果可以看到,这些轻量化模型在复杂病斑形态、

颜色变化以及易混淆类别的识别上存在一定局限。考虑到未来在处理高复杂度或细粒度的植物病害分类任务上的泛化能力,本实验仍选择 DenseNet 作为基础架构,改进后 SMVF-DenseNet 模型在准确率上相较于 MobileNetV3 提升约 5%。

ViT 模型的运行速度远超所有 CNN 模型,但其分类准确率却最低 (51.85%),相比于 SMVF-DenseNet 的准确率低了 42.38 个百分点,差异显著。Transformer 模型虽然在大规模数据集上表现优异,但其对训练样本规模、标签质量及数据多样性要求较高。由于植物叶片病斑具有区域小、结构细碎、颜色差异弱等特点,且实验数据集规模相对有限,ViT 在特征建模过程中难以充分捕捉局部细节,导致识别性能大幅下降。这进一步证实了 SMVF-DenseNet 在烟草叶片病虫害识别任务上的鲁棒性和实用性。

表 3 SMVF-DenseNet 与其他主流分类模型结果对比
Tab. 3 Comparison between SMVF-DenseNet and other mainstream classification models

模型名称 (Method)	精确率 (P)	召回率 (R)	准确率 (Acc)	F1 分数 (F1-Score)	每秒帧数 (FPS)
ResNet34	62.82%	60.77%	60.77%	59.86%	42.52
ResNet152	71.06%	71.06%	71.70%	69.56%	21.13
VGG16	68.81%	70.11%	69.77%	68.92%	21.36
InceptionV3	72.38%	71.38%	71.06%	71.39%	43.20
MobileNetV3 large	90.20%	88.08%	88.48%	89.13%	497.49
MobileNetV3 small	89.76%	88.08%	89.09%	88.91%	414.58
EfficientNet-B0	69.80%	63.61%	70.37%	66.56%	116.42
ShuffleNetV2	57.76%	52.93%	59.26%	55.24%	201.22
DenseNet169	69.82%	71.62%	75.93%	70.71%	41.91
DenseNet201	77.93%	75.33%	79.63%	76.61%	32.65
ViT	53.22%	49.79%	51.85%	51.45%	830.85
SMVF-DenseNet	94.44%	93.23%	94.44%	93.83%	23.69

2.6 泛化性能实验

为全面验证 SMVF-DenseNet 模型在不同作物与病害类型上的鲁棒性与迁移能力,本研究选取了 PlantVillage (PV)、Cassava Leaf Disease Classification (CLDC) [22]、Dataset of Tomato Leaves (DTL) [23]以及 Lettuce Plant Leaf Datasets (LPLD) [24]4 个公开植物病害数据集开展泛化性能测试。这些数据集涵盖了番茄、木薯、生菜等多类作物,病害类型丰富,叶片形态差异显著,且采集条件、种植背景、图像噪声水平

与数据集规模均存在明显差异,能够较好地模拟真实农业场景中跨区域、跨品种、跨成像环境的复杂性。

本实验通过在上述 4 个数据集上分别对本研究提出的 SMVF-DenseNet 模型以及其他农业病害图像识别的主流模型进行测试,以评估模型的泛化能力与跨场景适用性,从而为农业病害识别算法在真实应用中的稳定性提供依据。所有模型均在相同的实验环境下进行训练和测试 (见 2.3 节)。根据不同数据集的规模与模型复杂度调整训练轮次。

表 4 SMVF-DenseNet 与主流分类模型在多数数据集上的泛化性能比较结果

Tab. 4 Comparison of generalization performance between SMVF-DenseNet and mainstream classification models across multiple datasets

模型名称 (Method)	准确率/F1 分数 (Acc) / (F1-Score)			
	PV	CLDC	DTL	LPLD
ResNet34	96.66%/96.67%	74.09%/73.07%	96.62%/96.60%	97.50%/97.38%
ResNet50	95.07%/95.30%	77.03%/75.78%	95.86%/94.46%	97.50%/97.38%
InceptionV3	91.12%/91.02%	69.01%/63.60%	89.57%/85.95%	87.52%/87.70%
MobileNetV3 large	97.88%/97.95%	76.10%/74.54%	97.92%/97.79%	97.67%/97.50%
EfficientNet-B0	97.00%/97.16%	73.39%/71.37%	97.03%/96.70%	85.00%/83.08%
ShuffleNetV2	95.57%/95.54%	66.72%/64.90%	96.68%/96.59%	79.92%/78.08%
ViT	94.65%/94.75%	68.64%/64.13%	95.10%/95.34%	92.57%/92.48%
DenseNet121	97.94%/98.01%	78.01%/77.80%	98.48%/98.00%	87.54%/87.32%
SMVF-DenseNet	97.96%/97.97%	77.82%/77.53%	98.75%/98.15%	97.62%/97.10%

泛化性能评估结果如表 4 所示，SMVF-DenseNet 在多数数据环境下均取得了最优或近最优的表现，展现出较强的跨数据集迁移能力。具体而言，SMVF-DenseNet 在 PV、DTL 和 LPLD 数据集上分别取得 97.96%、98.75%与 97.62%的准确率，均明显优于其他主流卷积网络；在更具挑战性的 CLDC 数据集上，尽管 DenseNet121 在该数据集上取得了最佳表现，但 SMVF-DenseNet 仍以 77.82%/77.53%的准确率和 F1 分数位列第二，且整体性能显著优于大多数其他主流模型。

总体来看，SMVF-DenseNet 不仅在烟草叶片病害识别任务上表现突出，而且在跨不同类型和规模数据集上也有良好的泛化能力和鲁棒性，为复杂农业场景下的实际病害识别任务提供了可靠的模型基础。

3 结论

为有效解决烟草叶片病害识别中存在的类间相似性高、病害尺度多样、难分样本多等导致的识别准确率不足问题，本文提出了基于多尺度特征融合与注意力机制增强的 DenseNet 改进模型 SMVF-DenseNet，用于实现烟草叶片病害的高精度识别。针对病斑呈现多尺度分布、语义特征易分散的特点，构建了 SE-MSFF-Dense 模块：结合跨层级的多尺度特征融合策略，有效强化模型对不同尺度病害斑块的表征能力；并通过对在各密集块末端嵌入 SEBlock，实现通道维度的自适应特征重标定。为整合卷积阶段产生的局部信

息并建立关键区域之间的长程依赖关系，在主干网络末端引入了 ViT 风格自注意力模块，显著提升了全局语义建模能力。针对训练过程中的类别不平衡与难分样本问题，引入 Focal Loss 以抑制易分类样本影响、增强模型对难例的判别能力。同时，利用在 PlantVillage 数据集上预训练的模型参数进行迁移学习，有效缓解小样本条件下的过拟合风险，进一步提升模型在实际应用场景中的泛化性能。

实验结果表明，SMVF-DenseNet 通过多尺度特征融合（MSFF）、通道注意力（SEBlock）及 ViT 风格自注意力模块的协同优化显著提升了烟草叶片病害识别性能，消融实验显示各模块均能有效增强模型对不同尺度病斑特征和关键语义信息的捕获能力，使准确率和 F1 分数相较于 baseline 分别增长 12.96%和 15.23%，达到 94.44%和 93.83%，并有效减少了易混类别和少数样本的误判，鲁棒性明显提升。与其他主流模型对比，改进后的 SMVF-DenseNet 在烟草叶片病害数据集，以及番茄、苹果、葡萄等其他植物病害数据集上，都能保持竞争力甚至领先的识别性能，验证了其在跨作物场景下的良好泛化能力和实际应用价值。

未来工作将从模型轻量化、跨作物泛化、多模态信息融合与智能农田应用四个方面展开。首先，将探索模型剪枝、知识蒸馏和量化等技术，实现高精度与低计算成本的平衡，以便在移动端或无人机上部署。其次，可结合多源数据增强与领域自适应方法，进一

步提升模型在不同作物和复杂环境下的稳健性。第三,利用光谱、近红外等多模态数据融合,提高病害早期检测和精细分类能力。最终,结合自动化监测和智能农田管理系统,实现植物病害识别模型在实际生产环境中的落地应用。

参考文献

- [1] 韩非, 梁金昌, 汪汉成, 等. 我国烟草病害绿色防控科技创新与实践[J]. 中国烟草科学, 2025, 46(3): 109-117.
HAN Fei, LIANG Jinchang, WANG Hancheng, et al. Innovation and Practices of Green Control for Tobacco Diseases in China[J]. Chinese Tobacco Science, 2025, 46(3): 109-117.
- [2] 赵宇婷, 谢晏芬, 曾朝懿, 等. 基于文献计量学的烟草病毒研究知识图谱分析[J]. 中国烟草学报, 2024, 30(1): 83-97.
ZHAO Yuting, XIE Yanfen, ZENG Chaoyi, et al. Knowledge mapping analysis of tobacco virus research based on bibliometrics[J]. Acta Tabacaria Sinica, 2024, 30(1): 83-97.
- [3] 濮永仙. 实数编码遗传算法与支持向量机在烟草病害识别中的应用[J]. 江苏农业科学, 2015, (9): 435-438.
PU Yongxian. Application of real coded genetic algorithm and support vector machine in tobacco disease recognition[J]. Jiangsu Agricultural Sciences, 2015, (9): 435-438.
- [4] 姜雪妍, 辛星龙, 薛文鑫, 等. 基于烟株冠层高光谱的烟草病毒病分类模型构建[J]. 生物灾害科学, 2024, 47(4): 561-573.
JIANG Xueyan, XIN Xinglong, XUE Wenxin, et al. Construction of a tobacco virus disease classification model based on canopy hyperspectra of tobacco plants[J]. Biological Disaster Science, 2024, 47(4): 561-573.
- [5] 潘兆杰, 孙根云, 张爱竹, 等. 基于波段选择的烟草病害检测模型[J]. 光谱学与光谱分析, 2023, 43(4): 1023-1029.
PAN Zhaojie, SUN Genyun, ZHANG Aizhu, et al. Tobacco disease detection model based on band selection[J]. Spectroscopy and Spectral Analysis, 2023, 43(4): 1023-1029.
- [6] 张红涛, 朱洋, 谭联, 等. 基于 FA-SVM 技术的烟草早期病害识别[J]. 河南农业科学, 2020, 49(8): 156-161.
ZHANG Hongtao, ZHU Yang, TAN Lian, et al. The recognition of early tobacco disease based on FA-SVM technology[J]. Journal of Henan Agricultural Sciences, 2020, 49(8): 156-161.
- [7] 马俊红, 刘冬梅, 李永亮, 等. 烟草病虫害智能识别基准数据集构建及三维注意力模型设计[J]. 中国烟草学报, 2021, 27(5): 52-60.
MA Junhong, LIU Dongmei, LI Yongliang, et al. Construction of benchmark data set for intelligent identification of tobacco pests, diseases, phytotoxicity and design of three dimensional attention model[J]. Acta Tabacaria Sinica, 2021, 27(5): 52-60.
- [8] 刘延鑫, 王俊峰, 杜传印, 等. 基于 YOLOv3 的多类烟草叶部病害检测研究[J]. 中国烟草科学, 2022, 43(2): 94-100.
LIU Yanxin, WANG Junfeng, DU Chuanyin, et al. Detection of various tobacco leaf diseases based on YOLOv3[J]. Chinese Tobacco Science, 2022, 43(2): 94-100.
- [9] 邢卓冉, 丁松爽, 张凯, 等. 计算机视觉与深度学习技术在烟叶生产上的研究进展[J]. 中国农业科技导报, 2025, 27(1): 96-106.
XING Zhuoran, DING Songshuang, ZHANG Kai, et al. Research progress of deep learning and computer vision in tobacco leaf production[J]. Journal of Agricultural Science and Technology, 2025, 27(1): 96-106.
- [10] 谢裕睿, 苗晟, 张钰, 等. 基于残差神经网络的烟草病害识别研究[J]. 现代计算机, 2020, (30): 27-31.
XIE Yurui, MIAO Sheng, ZHANG Shuo, et al. Research on tobacco disease recognition based on residual neural network[J]. Modern Computer, 2020, (30): 27-31.
- [11] 张文静, 孙秀朋, 乔永亮, 等. 基于 InceptionV3 的烟草病害识别[J]. 中国烟草学报, 2021, 27(05):61-70.
ZHANG Wenjing, SUN Xiupeng, QIAO Yongliang, et al. Tobacco disease identification based on InceptionV3[J]. Acta Tabacaria Sinica, 2021, 27(05):61-70.
- [12] 刘春菊, 刘延鑫, 李斐, 等. 基于 YOLOv5 的烟草叶部病害智能识别[J]. 中国烟草科学, 2024, 45(03):93-101.
LIU Chunju, LIU Yanxin, LI Fei, et al. Intelligent recognition of tobacco leaf diseases based on YOLOv5[J]. Chinese Tobacco Science, 2024, 45(03):93-101.
- [13] 朱均燕, 黄嘉星. 计算机图像技术在烟草病害诊断中的应用研究进展[J]. 武夷科学, 2022, 38(2): 99-107.
ZHU Junyan, HUANG Jiaxing. Advances in the application of computer imaging technology in tobacco disease diagnosis[J]. Wuyi Science Journal, 2022, 38(2): 99-107.
- [14] HUANG G, LIU Z, VAN DER M L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [15] SHAH F, KASHIF J, SARA A, et al. Deep transfer learning based detection and classification of citrus plant diseases[J]. Computers, Materials & Continua, 2023, (7):895-914.
- [16] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [17] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, PP(99):2999-3007.
- [18] LIN Hong, TSE R, TANG S K, et al. Tobacco plant disease dataset[J]. Proceedings of SPIE - The International Society for Optical Engineering, 2022, 12342.
- [19] 鲁梦瑶, 陈栋, 周强, 等. 基于深度学习的烟叶等级分类及特征可视化[J]. 烟草科技, 2023, 56(6): 92-100.
LU Mengyao, CHEN Dong, ZHOU Qiang, et al. Tobacco leaf grading and feature visualization based on deep learning[J]. Tobacco Science & Technology, 2023, 56(6): 92-100.
- [20] ESPEJO-GARCIA B, MALOUNAS I, MYLONAS N, et al. Using EfficientNet and transfer learning for image-based diagnosis of nutrient deficiencies[J]. Computers & Electronics in Agriculture, 2022, 196: 106868.
- [21] POWERS D M W. Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation[J]. 2020. DOI:10.48550/arXiv.2010.16061.
- [22] DIVYANTH L G, PEEYUSH S, RAJENDRA M. Cassava Leaf Disease Dataset[J]. Mendeley Data, 2021. doi:10.17632/3832tx2cb2.1.
- [23] HUANG M L, CHANG Y H. Dataset of tomato leaves[J]. Mendeley Data, 2020. doi:10.17632/ngdgg79rzb.1.
- [24] <https://github.com/k1chandrasekhar/Lettuce-plant-leaf-Datasets/tree/master>.

Tobacco leaf disease recognition method based on improved DenseNet

XU Tianran¹, WANG Rui¹, HAN Qinglin¹, ZHANG Bin¹, ZHAO Qian², HAN Yitong^{3*}, XU Xiangyang³

1 Tengzhou Cigarette Factory, Shandong China Tobacco Industry Co., Ltd., Shandong 277599, China;

2 Zaozhuang Vocational College of Science and Technology, Shandong 277599, China;

3 Department of Automation, Beijing Institute of Technology, Beijing 100081, China

Abstract: [Background] This study aims to achieve real-time and accurate identification of tobacco leaf diseases using an improved DenseNet model, thereby ensuring the quality and yield of tobacco leaves. [Methods] A high-precision classification method for tobacco leaf diseases was developed using an improved DenseNet model based on multi-scale feature fusion and an attention mechanism. The SE-MSFF-Deep Block, consisting of SEBlock and multi-scale feature fusion, was employed to extract multi-scale features. A Vision Transformer (ViT)-style attention structure was added before the classification layer to integrate scattered disease feature regions. The Focal Loss function was introduced to enhance the recognition accuracy of hard-to-classify and minority samples. Transfer learning was applied to mitigate overfitting on small datasets. [Results] The SMVF-DenseNet model achieved an accuracy of 97.58% for tobacco leaf diseases with an FPS of 23.69. Compared to other mainstream models, it significantly reduced inter-class confusion for difficult-to-class and minority samples. Moreover, the SMVF-DenseNet model maintained competitive classification accuracy on cross-crop plant disease datasets, demonstrating strong generalization capabilities. [Conclusion] The tobacco leaf disease recognition method based on multi-scale feature fusion and the attention mechanism effectively captures both detailed and overall features of disease patches, improving classification accuracy for difficult categories. Validation on additional plant disease datasets shows that the method excels in tobacco disease recognition and demonstrates strong cross-crop generalization, providing a feasible solution for broadly applicable plant disease identification models.

Keywords: tobacco disease recognition; DenseNet; multi-scale feature fusion; attention mechanism

*Corresponding author. Email: hyt15231555556@163.com

《中国烟草科学》2026 年第 1 期目次

· 遗传育种	· 植物保护
中抗青枯病新品种云烟 125 的选育及特征特性 刘 勇, 曾建敏, 黄昌军, 等	烟草赤星病拮抗菌 WN1 的鉴定与生防效果研究 张 权, 潘首慧, 代 飞, 等
烤烟新品种中烟 106 的选育及特征特性 常爱霞, 胡青珠, 刘 旦, 等	贝莱斯芽孢杆菌 DY-6-6 的筛选及对烟草黑胫病的生防潜力 应羽丰, 徐丹阳, 闵琪茹, 等
普通烟草短叶柄突变基因精细定位与候选基因分析 沈 忱, 汪季涛, 王新峰, 等	疫霉菌株 XC-26-5 的分离及其生防制剂对烟草黑胫病的防效 王 典, 薛超群, 高 飞, 等
· 栽培营养与生理生态	· 调制加工
山东烟区中川 208 中棵烟株型特征研究 王树键, 杨秀军, 张本强, 等	不同香型区烟叶烘烤工艺特征及工艺指标的关联分析 师永刚, 金保锋, 徐 端, 等
不同生物刺激素对烤烟碳氮代谢的影响 裘 垚, 付建邦, 毛 娟, 等	· 品质化学
生草栽培对烟田土壤理化性质及真菌群落的影响 黄家腾, 张子怡, 刘 敏, 等	近红外光谱技术快速检测烟草花中主要活性成分含量的研究 付秋娟, 许明磊, 张忠锋, 等
烤烟-粮经作物间作对土壤微生物群落及烟叶品质的影响 王丽丽, 高鹏程, 卢溪文, 等	· 综述与专论
衡阳典型烟田耕层及剖面养分特征与肥力评价 肖志鹏, 侯永浩, 相雨晴, 等	植物生物碱研究现状及其生物合成技术发展前景 史素娟, 方 宁, 王 寒, 等
假单胞菌生物有机肥促进烤烟生长的土壤微生物学机制 徐文正, 郭芳阳, 王孟孟, 等	