

高睿, 吴会才, 刘春菊, 等. 基于改进 YOLOv8 的烟草植株检测与计数方法研究[J]. 中国烟草学报, 2025, 31(1): 111-122. GAO Rui, WU Huicai, LIU Chunju, et al. Research on tobacco plant detection and counting method based on improved YOLOv8[J]. Acta Tabacaria Sinica, 2025, 31(1): 111-122. doi:10.16472/j.chinatobacco.2024.T0153

基于改进 YOLOv8 的烟草植株检测与计数方法研究

高睿¹, 吴会才², 刘春菊³, 刘中庆³, 管恩森³, 高强⁴, 姜红花^{1*}

1 山东农业大学信息科学与工程学院, 泰安 27101;

2 山东省烟草公司莱芜分公司, 莱芜 271199;

3 山东省烟草公司潍坊分公司, 潍坊 261205;

4 山东省烟草公司临沂分公司, 临沂 276003

摘要: 【目的】实现不同生长期烟草植株的快速检测与精准计数, 针对烟草生长过程中存在的叶片交叉以及植株之间不同程度的重叠遮挡等情况, 提出一种基于改进 YOLOv8 的不同生长期烟草植株检测与计数方法。【方法】以 YOLOv8 网络框架为基础, 将特征融合模块改进为渐近特征金字塔网络 (Asymptotic Feature Pyramid Network, AFPN), 避免跨层融合时非相邻层之间的较大语义差异, 提高了烟叶交叉情况下的检测精度; 采用空间金字塔池化快速跨阶段部分通道模块 (Spatial Pyramid Pooling Fast Cross-Stage Partial Channel, SPPFCSPC) 替换原空间金字塔池化结构, 极大程度地解决重复特征提取的问题, 降低模型复杂度; 将损失函数优化为边界框回归损失函数 MPDIoU (Minimum Point Distance Intersection over Union), 有效减少遮挡导致的烟叶漏检情况; 通过搭载 DeepSORT (Deep Simple Online and Realtime Tracking) 目标跟踪算法实现植株计数功能。【结果】本研究建立的模型在目标检测中的平均精确率达到了 95.9%, 相比于原模型提高 3.6%, 与 Faster R-CNN、SSD、CenterNet、YOLOv5n、YOLOv7 等模型相比分别提高 22.6%、4.8%、18.8%、7.1%、4.2%; 在计数任务中, MOTA 最高达到 93.41%。【结论】本研究建立的模型能够实现对不同生长期烟草植株的快速检测与精准计数, 为烟草种植业的智能化管理提供了新的思路和方法, 有助于推动烟草产业的现代化进程。

关键词: YOLOv8; 深度学习; 烟草植株; 计数; 目标检测

当前烟草种植正面临着从传统管理模式向高效、智能模式转变的趋势^[1-3]。烟草植株的精准检测与计数是实现高效种植管理和科学决策的关键环节^[4]。然而, 传统的烟草植株计数主要依赖于人工目测和手工记录, 不仅效率低下, 且容易受到人为因素的干扰, 导致数据测量不准确^[5]。因此, 研究一种基于深度学习的烟草植株自动检测计数方法, 对于提高种植效率、优化资源配置以及促进烟草产业的可持续发展具有重要意义。

目标检测作为计算机视觉领域的一个核心任务, 为烟草植株的精准检测提供了可能^[6]。目前, 目标检

测领域常用的深度学习算法主要有区域卷积神经网络 (Region-based Convolutional Neural Networks, R-CNN) 系列算法^[7-8]、YOLO (You Only Look Once) 系列算法^[9-11]、单阶多层检测器 (Single Shot MultiBox Detector, SSD) 算法^[12]等。Pan 等^[13]提出了一种基于改进 Faster R-CNN 的甘蔗幼苗检测方法, 利用 ResNet50 进行特征提取以生成高分辨率特征表达式, 并采用 SN-block 注意力机制将网络集中在学习幼苗特征通道上, 平均检测准确率达到 93.67%。KONG 等^[14]为了解决复杂田间环境下作物幼苗的检测问题, 提出了一种基于 YOLOv5 和 transformer 机制的幼苗检测网

基金项目: 潍坊烟草公司科技项目 (2023-45); 山东省现代农业技术体系 (SDAIT-25-06)

作者简介: 高睿 (2000—), 硕士, 主要从事计算机视觉与人工智能研究, Tel: 17686263776, Email: 2023121088@sda.edu.cn

通讯作者: 姜红花 (1971—), 教授, 主要从事物联网与人工智能研究, Email: j_honghua@sda.edu.cn

收稿日期: 2024-05-07; 网络出版日期: 2024-09-14

络,使模型的 mAP 值提高了 1 倍。郭辉等^[15]提出了一种改进的 YOLOv5m 网络模型,对红花花冠的检测精度提高到了 93.79%。Shen 等^[16]基于通道修剪算法对 YOLOv5s 聚类检测模型进行改进,对葡萄的检测精度达到了 82.3%。YOLOv8 作为一种先进的实时目标检测算法,继承了前代算法的优点,并在性能和速度上进行了进一步的优化,以其高效的检测速度和较高的准确率在多个领域得到广泛应用。然而,烟草植株在生长过程中会经历形态和颜色的变化,同时烟田环境复杂多变,烟草生长过程中存在的叶片交叉以及植株之间不同程度的重叠遮挡也增加了目标检测的难度。

目前的研究中,目标检测为实时追踪奠定基础,目标检测精度决定追踪器的追踪效果^[17]。DeepSORT 作为一种先进的目标跟踪算法,结合了深度学习和排序算法,能够在复杂环境下实现对目标的实时跟踪,具有出色的性能和稳定性。在农业领域,DeepSORT 算法已被广泛应用于种子出苗率检测^[18]、作物生长监测^[19-20]、果园产量评估^[21-23]以及畜牧养殖^[24-26]等方面,展现出了其在农业智能化管理方面的巨大潜力。

针对复杂烟田环境下烟草植株检测准确率低、计数难的问题,本研究提出了一种基于改进 YOLOv8 的

烟草植株检测计数方法,通过改进特征融合模块、优化空间金字塔池化结构以及替换损失函数构建 YOLOv8-ASi 检测模型,并结合 DeepSORT 算法进行目标跟踪,实现对无人机航拍视频中烟草植株的实时准确检测与计数。通过试验验证,该模型在烟草植株计数任务中展现出了优异的性能,为烟草种植业的智能化发展提供新的思路和方法,进一步提高了烟草植株检测计数的准确率,有助于推动烟田的智能化管理。

1 数据采集与处理

1.1 数据采集

本研究的数据采集自 2023 年 4—9 月,跨越了烟草生长的团棵期、旺长期以及成熟期。主要采集地点包括山东农业大学烟草试验田、山东省诸城市烟草试验站、山东省莱芜烟草试验站等,涵盖了不同地理环境和种植条件下的烟草植株。数据采集过程中,采用无人机(大疆精灵 Phantom 4 Pro V2.0)以 5~10 m 的高度对烟田进行垂直拍摄,获取 10:00—14:00 时间段的视频图像。同时,为确保数据的准确性和可靠性,分别在不同生产阶段对同一区域进行了多次拍摄和记录,不同时期烟草植株数据集如图 1 所示。




图 1 数据集示意图

Fig.1 Schematic diagram of the data set

1.2 数据处理

通过对无人机拍摄视频抽帧,得到用于模型训练的烟草植株图像数据集,共计 930 张,其中团棵期图像 300 张、旺长期图像 300 张、成熟期图像 330 张,使用 labelimg 进行标注,生成对应 txt 文件。

为扩大训练样本数量,采用传统数据增强技术,包括镜像翻转、尺度变换、上下平移、水平平移、亮

度增强、错切变化等方式扩充数据集,扩充时采用高斯噪音和椒盐噪音随机对部分图像进行噪音处理,以提高数据集多样性和复杂度,数据增强效果如图 2 所示。最终,共获得数据集 2500 张,其中团棵期图像 800 张、旺长期图像 800 张、成熟期图像 900 张,按照 7:2:1 的比例划分训练集、测试集、验证集,构建不同生长期的烟草植株数据集。




图 2 数据增强示意图
Fig.2 Data enhancement schematic

2 基于无人机的烟草植株检测及追踪算法模型

为实现烟草植株的检测与计数，本研究构建了基于无人机的烟草检测及追踪算法模型，其流程如图 3 所示，在完成数据集构建后，将其输入到本研究改进

检测模型中，生成最优训练模型，采用 DeepSORT 作为追踪器，实现视频追踪计数功能。构成该算法模型的各个阶段，将在以下小节中具体描述。




图 3 基于无人机的烟草检测及追踪算法模型流程图
Fig.3 Model flowchart of UAV-based tobacco detection and tracking algorithm

2.1 YOLOv8 模型架构

YOLOv8 算法是 ultralytics 公司提出的端到端无锚框通用目标检测网络，继承 YOLO 系列的优势，与其他模型相比，其采用基于 Anchor-Free 的检测方式，

直接预测目标的中心点和宽高比例，减少 Anchor 框的数量，提高了检测速度和精度。由输入端（Input）、主干网络（Backbone）、颈部网络（Neck）、头部网络（Head）4 部分组成，YOLOv8 网络结构如图 4 所示。




图4 YOLOv8 网络结构图

Fig.4 YOLOv8 network structure diagram

主干网络是 YOLOv8 网络的核心部分,用于提取图像的特征。主要采用一系列卷积和反卷积层来进行特征提取,同时使用残差连接和瓶颈结构减小网络的大小,以提升网络性能。与 YOLOv5 相比, YOLOv8 采用 C2f 模块代替 C3 模块,具有更少的参数量和更优秀的特征提取能力; Neck 层采用多尺度特征融合技术,将来自主干网络不同阶段的特征图进行融合,进一步增强特征表示能力; Head 负责目标检测与分类任务,使用解耦头结构,将分类头和检测头分离,有效地提升检测精度。检测头用于生成检测结果,分类头则采用全局平均池化来对每个特征图进行分类。

2.2 基于改进 YOLOv8 的检测模型

本研究改进后的 YOLOv8-ASi 烟草植株检测模型通过引入 AFPN 到主干网络,优化空间金字塔特征池化结构 (SPPFCSPC) 及改进损失函数 (MPDIoU),有效提升了模型的特征提取和融合能力,提高了模型的检测精度和速度,增强了模型的泛化能力。

2.2.1 改进特征融合模块

为提高烟叶交叉情况下的检测精度,本研究对特征融合模块进行改进。特征金字塔是神经网络的重要组成部分,通过提取多尺度特征信息进行融合以聚合不同分辨率的特征,来提高目标检测的精度。YOLOv8 中的 Neck 采用 PAN-FPN 结构^[27-28] (Path Aggregation Network - Feature Pyramid Network),通过上采样或下采样实现相邻特征图大小的一致性,直接将特征图中的通道进行连接,实现特征间的初步融合。然而,这种结构使得不相邻的特征层之间不能直接进行特征融合,忽略了不同尺度特征之间的冲突信息,导致非相邻层之间的信息丢失^[29]。

因此,本研究采用渐近特征金字塔网络 (Asymptotic Feature Pyramid Network, AFPN) 来实现 Neck 中的特征融合,该方法结合了金字塔模式和自适应空间特征融合^[30] (Adaptively Spatial Feature Fusion, ASFF) 的思想,其结构如图 5 所示, C2f 模块结构如图 6 所示。




图5 AFPN 结构图

Fig.5 Structure of AFPN




图 6 C2f 模块结构图

Fig.6 Structure of C2f module

通过两个相邻层之间的上采样或下采样进行融合，统一当前层中特征图的大小，采用更关注关键层的自适应特征空间融合，如式（1）所示。

$$y_{ij}^l = \alpha_{ij}^l \cdot x_{ij}^{1 \rightarrow l} + \beta_{ij}^l \cdot x_{ij}^{2 \rightarrow l} \quad (1)$$

其中， α_{ij}^l 、 β_{ij}^l 分别表示线性组合时的输入权重，满足 $\alpha_{ij}^l + \beta_{ij}^l = 1$ ， $x_{ij}^{n \rightarrow l}$ 表示位于 (i, j) 处的特征向量从第 n 层到第 l 层的转换值。

此外，当跨层特征融合时，由于特征融合已经包含了相邻的特征信息，因此在跨层融合时，可以最大程度避免非相邻层之间的语义差距，从而提高烟草植株目标检测的精度。

2.2.2 优化空间金字塔池化结构

为适应烟田植株计数的应用场景，降低模型复杂

度，极大程度地解决重复特征提取的问题，本研究对空间金字塔池化（Spatial Pyramid Pooling, SPP）结构进行优化。SPP 结构最早是由 He 等^[31]提出，通过将不同尺寸的感受野划分成不同等级，并对每个层级内的特征进行池化操作，将任意大小的输入图像进行固定长度的特征表示，解决了重复特征提取的问题，SPP 结构图如图 7 所示；SPPF 结构是在 SPP 结构的基础上，对 Maxpool 以及卷积核的大小、步长进行了调整，其结构如图 8 所示；SPPCSPC 是 YOLOv7 算法中使用的 SPP 模块，引入跨阶段部分结构（CSP）对输入图像进行辅助优化，但导致模型参数量增加，影响模型的运行速度。




图 7 SPP 结构图

Fig.7 SPP structure




图 8 SPPF 结构图

Fig.8 SPPF structure

因此，本研究提出使用 SPPFCSPC 替换 YOLOv8 池化层中的空间金字塔池化结构，其结构图如图 9 所示。基于 SPPF 的思想进行优化，将 SPPCSPC 中池化核为 5，9，13 的 Maxpool 更改为 3 个池化核为 5 的 Maxpool，并依次连接，得到不同尺度的感受野，来

提取尽可能多的特征信息。该模块在节省计算成本的同时，极大程度地解决了重复特征提取的问题。因此，综合 SPPF 模块与 CSP 模块，使模型在保持感受野不变的情况下获得速度与精度的提升，同时提高了模型在烟田复杂背景下检测的鲁棒性。




图9 SPPFCSPC 结构图
Fig.9 SPPFCSPC structure

2.2.3 优化损失函数

为有效减少遮挡导致的烟叶漏检情况,本研究对YOLOv8 原模型中的损失函数进行改进。原模型中采用CIoU 函数来预测边框坐标损失,其计算如式(2)所示。

$$CIoU = \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \quad (2)$$

$$\alpha = \frac{v}{(1 - IoU) + v} \quad (3)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right)^2 \quad (4)$$

式中, $\rho^2(b, b^{gt})$ 表示预测框与真实框中心的欧氏距离; c 表示预测框与真实框最小闭包区域对角线的距离; α 为权重系数,定义如式(3)所示; v 为预测框与真实框的长宽比,定义如式(4)所示; w 和 h 分别为标注框的宽和高; w^{gt} 和 h^{gt} 分别为真实框的宽和高。

在预测过程中,当预测框与边界框具有相同的纵横比,但宽度和高度值完全不同时,可能会出现CIoU的惩罚项退化为0,不利于模型对相似性边界框的有效优化^[32]。针对该问题,本研究采用MPDIoU 损失函数代替原损失函数,基于最小点距离的新型边界框相似度比较度量标准,直接最小化预测边界框与实际标注边界框之间的左上角和右下角点距离,有效提高遮挡情况下的检测精度。包含了现有损失函数中考虑的所有相关因素,即重叠或非重叠区域、中心点距离、宽高偏差,同时简化计算过程,进一步提高模型的检测精度和速度。

具体计算公式如下:

$$d_1^2 = (x_1^B - x_1^A)^2 + (y_1^B - y_1^A)^2 \quad (5)$$

$$d_2^2 = (x_2^B - x_2^A)^2 + (y_2^B - y_2^A)^2 \quad (6)$$

$$MPDIoU = \frac{A \cap B}{A \cup B} - \frac{d_1^2}{\omega^2 + h^2} - \frac{d_2^2}{\omega^2 + h^2} \quad (7)$$

式中 A 、 B 分别表示两个任意凸形, ω 、 h 分别表示输入图像的宽度、高度, (x_1^A, y_1^A) 、 (x_2^A, y_2^A) 分别代表 A 的左上和右下点坐标, (x_1^B, y_1^B) 、 (x_2^B, y_2^B) 分别代表 B 的左上和右下点坐标, d_1 、 d_2 分别代表 A 、 B 的左上角之间的欧氏距离和右下角之间的欧氏距离。

2.3 DeepSORT 算法

DeepSORT 算法是一种基于深度学习的多目标跟踪算法,它在传统SORT (Simple Online and Realtime Tracking) 算法的基础上进行了改进,通过引入深度特征来提高目标跟踪的稳定性和准确性^[33]。其核心思想在于利用深度学习模型进行目标检测,并结合卡尔曼滤波器进行目标状态预测和数据关联。

为实现植株计数,本研究首先利用改进后的YOLOv8-ASi 模型对视频序列中的每一帧进行目标检测,获取烟草植株的边界框和特征信息;然后通过卡尔曼滤波器对目标的状态(如位置、速度等)进行预测,并采用匈牙利算法根据预测结果与实际检测结果之间的关联度进行目标匹配;此外,设计了基于轨迹管理的策略,通过为每个目标分配一个唯一ID,并使用轨迹列表来记录目标的运动历史。当目标出现遮挡或消失的情况时,算法会暂时保留其轨迹,并在后续帧中尝试重新关联该目标。该策略能够有效地提升算法对烟田复杂场景的适应能力,DeepSORT 目标追踪示意图如图10所示。




图 10 DeepSORT 目标追踪
Fig.10 DeepSORT target tracking

2.4 模型环境与评价指标

2.4.1 训练环境

本研究模型训练环境硬件配置为 Intel i7-11700 2.5GHz CPU, 16GB 内存; NVIDIA GeForce GTX 1080 Ti GPU, 11GB 显存。软件环境为 Windows 10 系统, 64 位, PyTorch 框架版本 1.13.1, CUDA 版本 11.7, 编程语言 python 3.8.2。具体训练环境配置软硬件参数如表 1 所示。

表 1 试验环境参数表

Tab.1 Experimental environment parameter table

试验环境	参数
PyTorch	1.13.1
CUDA	11.7
Python	3.8.2
操作系统	Windows 10
GPU	GeForce GTX 1080 Ti
显存	11GB
CPU	Intel i7-11700 2.5GHz
内存	16GB

为了验证模型改进的有效性, 本研究涉及的所有目标检测网络均使用统一数据集, 数据集划分为训练集: 验证集: 测试集, 比例为 7:2:1; Batch_size 设置为 4; Epoch 设置为 200; Momentum 设置为 0.937; lr0 设置为 0.01; lrf 设置为 0.01; weight_decay 设置为 0.0005; warmup_epochs 设置为 3.0; warmup_momentum 设置为 0.8; warmup_bias_lr 设置为 0.1。

2.4.2 评价指标

为评估模型的目标检测性能, 本研究采用 Recall (召回率)、Precision (精确率)、F₁ 分数、mAP (平均精确率)、MOTA (多目标跟踪准确度) 作为评价指标。

1) Recall (召回率): 表示模型检测出的烟草植株

数目占实际上烟草植株数目的比例;

$$Recall = \frac{TP}{TP + FN} \quad (8)$$

其中, TP (True Positive) 表示模型正确检测到的烟草植株数目, FN (False Negative) 表示模型未能检测到的烟草植株数目;

2) Precision (精确率): 表示模型检测出的烟草植株数目中正确的数目的占比;

$$Precision = \frac{TP}{TP + FP} \quad (9)$$

其中, TP (True Positive) 表示模型正确检测到的烟草植株数目, FP (False Positive) 表示模型错误地检测到的烟草植株数目;

3) mAP (平均精确率): 表示模型在置信度阈值为 0.5 下的平均精确率;

$$AP = \int_0^1 P(R) dR \quad (10)$$

$$mAP = \frac{AP_1 + AP_2 + \dots + AP_n}{n} \quad (11)$$

其中, AP_i (Average Precision) 表示第 i 个类别的平均精确率, n 表示类别的总数目。

4) F₁ 分数 (F1 Score): 精确率和召回率的调和平均值, 用于综合考虑模型的准确性和完整性。

$$F_1 = \frac{2(Precision \cdot Recall)}{Precision + Recall} \quad (12)$$

5) 多目标跟踪准确度 (Multiple Object Tracking Accuracy, MOTA): 用来评价目标跟踪的准确率, 本研究中用于评估烟草植株的计数效果。

$$MOTA = 1 - \frac{FN_t + FP_t + IDSW}{GT} \quad (13)$$

其中, FN_t 为视频检测中烟草植株漏检个数之和, FP_t 为视频检测中误识别的植株个数之和, IDSW 为

ID 跳变的总次数，*GT* 为视频中实际烟草植株个数。

3 结果与分析

3.1 检测模型对比试验

为全面评估不同目标检测模型在烟草植株检测任

务中的性能，本研究选择 Faster R-CNN、SSD、CenterNet、YOLOv5n、YOLOv7、YOLOv8n 等 6 种主流检测模型与改进后的 YOLOv8-ASi 模型在同一环境下，采用验证集进行多次对比试验，结果如表 2 所示。

表 2 不同模型检测结果对比
Tab.2 Comparison of detection results of different models

模型	精度/%	召回率/%	平均精确率/% mAP(IoU=0.5)	权重/MB	F1 分数/%
Faster R-CNN	79.2	75.1	73.3	108	77.1
SSD	87.7	81.6	91.1	90.6	84.5
CenterNet	79.5	74.0	77.1	124	76.7
YOLOv5n	83.6	82.7	88.8	3.62	83.1
YOLOv7	84.1	94.1	91.7	74.8	88.8
YOLOv8n	85.9	94.7	92.3	6.2	90.1
YOLOv8-ASi	88.1	96.1	95.9	9.9	91.9

由表 2 可知，YOLOv8-ASi 模型的精度、召回率、mAP 以及 F1 分数均高于其他模型。相比于 Two-stage 算法模型 Faster R-CNN，本研究改进后的 YOLOv8-ASi 模型在精度上提高 8.9%，召回率提高 21%，mAP 提高 22.6%，同时模型权重减小 90.8%，极大地提高了模型的实用性和部署效率；相较于 One-stage 算法模型 SSD、CenterNet 以及 YOLO 系列的 YOLOv5n、YOLOv7、YOLOv8n 模型，改进后模型的 mAP 分别提高 4.8%、18.8%、7.1%、4.2%、3.6%，尽管模型权重相较于 YOLOv5n、YOLOv8n 有所增大，

但本研究模型在查全率（召回率）和查准率（精度）上均表现出显著的优势，能够更好地适应复杂的检测任务，更有利于在烟草植株检测任务中的实际应用。

3.2 消融实验

为了系统地评估渐近特征金字塔网络（AFPN）、SPPFCSPC 空间金字塔池化结构、MPDIoU 损失函数对模型性能的改进，验证各组件的有效性，本研究选用 YOLOv8 模型为基线网络，在同一环境下采用自建数据集进行了一系列消融实验，结果如表 3 所示。

表 3 消融实验
Tab.3 Ablation test

序号	AFPN	SPPFCSPC	MPDIoU	精度/%	召回率/%	平均精确率 mAP(IoU=0.5) /%	权重/MB
1	×	×	×	85.9	94.7	92.3	6.2
2	√	×	×	87.1	95.8	94.7	6.6
3	×	√	×	87.4	97.6	94.3	10.4
4	×	×	√	88.4	95.9	94.0	6.2
5	√	√	×	87.8	97.3	95.1	9.5
6	√	×	√	87.4	95.0	94.6	6.6
7	√	√	√	88.1	96.1	95.9	9.9

注：√ 为使用该算法；× 为不使用该算法。
Note: √ means to use the algorithm; × means not to use the algorithm.

由表 3 可知，实验 2 在 YOLOv8n 模型中将原特征融合模块 PAN 改进为 AFPN 后，模型的召回率、精度以及平均精确率均有提高，mAP 相比原模型提高了 2.4%，表明其能够更好地融合不同尺度的特征信息；实验 3 启用 SPPFCSPC 结构后，模型权重增加了 4.2 MB，

但精度得到了提高，其原因在于获取了更多的空间上下文信息，通过增加模型的参数量来换取精度的提升；实验 4 替换 MPDIoU 函数，优化了模型预测框和真实框之间的匹配度，模型 mAP 提高了 2.3%；实验 5 同时改进 AFPN 和 SPPFCSPC 模块，相比于实验 2，检

测时间不变,模型的各项指标得到了进一步的提升;实验7同时采用 AFPN、SPPFCSPC 和 MPDIoU 时,模型在精度、召回率和平均精确率上均达到了最高值。与原模型相比,改进后的模型精度提高了 2.2%,召回率提高了 1.4%,平均精度提高了 3.6%,证明本研究提出的改进方法能够提高烟草植株检测的准确性。

3.3 损失函数对比

在目标检测任务中,损失函数的选择对于模型的性能至关重要。不同的损失函数在优化目标、计算复杂度和收敛速度等方面存在差异,因此在烟草植株检测中的表现也各不相同。本研究进行试验对比 YOLOv8-ASi 模型分别采用 CIoU、MPDIoU、EIoU、GIoU 和 SIoU 5 种不同损失函数时的损失值变化,试验结果如图 11 所示。

由图 11 可知,原模型中所使用的 CIoU 在计算过程中考虑了边界框的长宽比,导致计算复杂度相对较高,收敛速度最慢,且收敛后的损失值最高;EIoU 的收敛速度相较于 CIoU 得到一定的提升,但收敛后的损失值仍高于另外 3 种损失函数;SIoU 在前 25 轮的收敛速度高于 GIoU,但收敛后的损失值相差不大,略高于 MPDIoU;相比之下,MPDIoU 则表现出了更快的收敛速度和更好的稳定性,这得益于其结合了多尺度信息和精确距离度量,使得模型在训练过程中能够更快速地找到最优解。




图 11 损失函数对比
Fig.11 Comparison of loss functions

3.4 可视化结果分析

3.4.1 目标检测结果分析

为分析对比模型的检测效果,本研究选取不同时期的烟草植株数据集,分别使用 YOLOv8 原模型与改进后的 YOLOv8-ASi 模型进行检测,结果如图 12 所示,其中黄色框表示漏检,蓝色框表示误检。由图 12 可以看出,原模型在叶片交叉的情况下,出现了误检、漏检情况;在复杂背景下,原模型还出现了对背景的错误识别。如图 13 所示,本研究改进模型能够更好地适应烟田环境,在不同时期的数据集上均取得了良好效果。




图 12 模型检测对比
Fig.12 Model detection comparison



图 13 YOLOv8-ASi 模型不同时期检测结果
Fig.13 Detection results of the YOLOv8-ASi model at different stages

3.4.2 植株计数结果分析

为验证 YOLOv8-ASi 检测模型在烟草植株计数任务中的效果，本研究从实际烟田采集的视频数据中随机挑选了 9 段视频进行测试，涵盖了烟草植株的 3 种不同生长时期，测试视频中烟草棵数共计约 3000 棵。

分别使用 YOLOv8 与本研究模型进行对比试验，并采用人工计数方法的结果为基准，对测试视频中的 ID 跳变情况和 MOTA 进行对比，不同检测网络的跟踪结果如表 4 所示。

表 4 不同检测网络跟踪结果对比
Tab.4 Comparison of tracking results of different detection networks

生长时期	序号	ID 跳变/次		多目标跟踪准确率/%	
		YOLOv8	YOLOv8-ASi	YOLOv8	YOLOv8-ASi
团棵期	1	13	7	91.12	93.41
	2	11	6	89.76	93.37
	3	15	9	90.23	93.12
旺长期	4	17	13	85.61	89.45
	5	19	11	86.37	90.11
	6	20	12	84.25	88.97
成熟期	7	23	15	80.34	85.31
	8	27	18	79.23	83.59
	9	32	21	81.19	83.27

从表 4 中可以看出，本研究模型在烟草植株计数任务中的表现优于原模型。无论是在团棵期、旺长期还是成熟期，本研究模型在 ID 跳变次数和多目标跟踪准确率（MOTA）两个关键指标上都展现出了更好的性能。其中，本研究模型在团棵期测试视频上的 MOTA

最高达到了 93.41%，计数效果如图 14 所示。相比原始 YOLOv8 模型，YOLOv8-ASi 通过更精确的特征提取、更优化的网络结构以及更有效的训练策略，能够更好地检测烟草植株，从而实现了更精准的植株计数效果。



图 14 模型计数效果图
Fig.14 Model counting effect diagram

4 讨论

本研究针对烟草植株在复杂烟田环境中的检测与计数问题,提出了一种基于改进 YOLOv8 的 YOLOv8-Asi 检测模型与 DeepSORT 算法相结合的烟草植株计数方法。通过优化特征融合模块、替换空间金字塔池化结构以及改进损失函数,显著提高了模型的检测精度和速度。相较于耿利川等^[34]提出的基于 YOLOv7-Sim 和无人机遥感影像的烟株数量检测方法,本研究模型不易受烟草长势情况的影响,能够对不同阶段的烟草植株进行检测与计数;此外,本研究不仅局限于无人机静态图像的计数,还可对无人机航拍视频进行动态跟踪检测,实现动态视频下的烟草植株检测与计数,在实际应用中具有更高的灵活性和实用性。

然而,本研究仍存在一些待改进之处。由于 DeepSORT 跟踪算法在动态变化场景中的局限性,成熟期烟株的计数中仍存在部分漏检和 ID 跳变的问题。针对这些问题,后续将进一步优化 DeepSORT 模型结构和算法策略,以提高烟草植株检测计数的准确性和稳定性。其次,烟株密度是烟草生产和科研实验中的一个重要指标,直接关系到烟草的产量和品质。在未来的研究中,本研究团队将研究探索如何结合本研究的烟株检测与计数方法,实现对烟株密度的准确估计,为烟草生产中的智慧管理提供科学依据。同时,随着计算机视觉技术的飞速发展,未来将探索更多基于视觉的烟草植株管理方法,如生长状态监测、病虫害检测等,为烟草产业的智能化管理提供更全面的技术支持。

5 结论

(1) 提出 YOLOv8-ASi 烟草植株检测模型,针对跨层融合时的语义差异问题,将特征融合模块改进为渐近特征金字塔网络;针对重复特征提取问题,采用 SPPFCSPC 替换原空间金字塔池化结构;针对植株漏检情况,将损失函数优化为 MPDIoU。改进后目标检测的平均精确率达到了 95.9%,相比原模型提高了 3.6%。

(2) 将 YOLOv8-ASi 目标检测模型与 DeepSORT 目标跟踪算法相结合,通过卡尔曼滤波器、匈牙利算法及轨迹管理策略,实现了对烟草植株的实时跟踪与计数功能,试验结果显示,该方法的 MOTA 最高达到了 93.41%,验证了其在烟草植株计数任务中的准确性。

(3) 本研究提出的方法能够对不同阶段的烟草植株进行检测与计数,不仅适用于静态图像的烟草植株计数,还能应用于动态视频的实时跟踪检测,具有较高的灵活性和实用性,为烟草种植的智能化管理提供

了新的思路和方法。

参考文献

- [1] 农英雄,陆瑛,陈智斌,等.基于物联网监控的烟叶精准种植管理系统设计与实践[J].中国烟草学报,2021,27(3):114-121. NONG Yingxiong, LU Ying, CHEN Zhibin, et al. Design and practice of tobacco precision planting management system based on internet of things[J]. Acta Tabacaria Sinica, 2021, 27(3): 114-121.
- [2] 张阳,屠乃美,陈舜尧,等.基于 Sentinel-2A 数据的县域烤烟种植面积提取分析[J].烟草科技,2020,53(11):15-22. ZHANG Yang, TU Naimei, CHEN Sunyao, et al. Extraction and analysis of the area of roasted tobacco planted in counties based on Sentinel-2A data[J]. Tobacco Science & Technology, 2020, 53(11): 15-22.
- [3] QIAO Yongliang; VALENTE João, SU Daobilige, et al. Editorial: AI, sensors and robotics in plant phenotyping and precision agriculture[J]. Frontiers in Plant Science, 2022, 13: 1064219-1064219.
- [4] 饶雄飞,周龙宇,杨春雷,等.基于无人机多光谱影像和关键点检测的雪茄烟株数提取[J].农业机械学报,2023,54(3):266-273. RAO Xiongfei, ZHOU Longyu, YANG Chunlei, et al. Cigar tobacco plant number extraction based on UAV multispectral imagery and key point detection[J]. Journal of Agricultural Machinery, 2023, 54(3): 266-273.
- [5] 薛宇飞,张军,张萍,等.基于 Sentinel-2 遥感影像的烟草种植信息精准提取[J].中国烟草科学,2022,43(1):96-106. XUE Yufei, ZHANG Jun, ZHANG Ping, et al. Accurate extraction of tobacco planting information based on Sentinel-2 remote sensing images[J]. China Tobacco Science, 2022, 43(1): 96-106.
- [6] Firozeh Solimani, Angelo Cardellicchio, Giovanni Dimauro, et al. Optimizing tomato plant phenotyping detection: boosting YOLOv8 architecture to tackle data complexity[J]. Computers and Electronics in Agriculture, 2024, 218108728.
- [7] ZHANG W, WANG Y, SHEN G, et al. Tobacco leaf segmentation based on improved MASK RCNN algorithm and SAM model[J]. IEEE Access, 2023, 11: 103102-103114.
- [8] 王梁,侯义锋,贺杰.基于 Mask-RCNN 的自然场景下油茶果目标识别与检测[J].中国农机化学报,2022,43(12):148-154+189. WANG Liang, HOU Yifeng, HE Jie. Mask-RCNN-based target recognition and detection of oil tea fruit in natural scenes[J]. Chinese Journal of Agricultural Chemistry, 2022, 43(12): 148-154+189.
- [9] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 779-788.
- [10] WANG C Y, Bochkovskiy A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2023: 7464-7475.
- [11] WANG C Y, YE H I H, LIAO H Y M. YOLOv9: Learning what you want to learn using programmable gradient information. arXiv 2024[J]. arXiv preprint arXiv: 2402.13616.
- [12] LIU W, Anguelov D, Erhan D, et al. SSD: Single shot multibox detector[C]//Computer Vision-ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [13] PAN Y, ZHU N, DING L, et al. Identification and counting of sugarcane seedlings in the field using improved faster R-CNN[J]. Remote Sensing, 2022, 14(22): 5846.
- [14] KONG S, LI J, ZHAI Y, et al. Real-time detection of crops with dense planting using deep learning at seedling stage[J]. Agronomy, 2023, 13(6): 1503.
- [15] 郭辉,陈海洋,高国民,等.基于深度学习的红花花冠目标检

- 测与空间定位方法[J]. 农业机械学报: 1-10.
- GUO Hui, CHEN Haiyang, GAO Guomin, et al. Deep learning-based target detection and spatial localization method for safflower corolla[J]. Journal of Agricultural Machinery: 1-10.
- [16] SHEN L, SU J, HE R, et al. Real-time tracking and counting of grape clusters in the field based on channel pruning with YOLOv5s[J]. Computers and Electronics in Agriculture, 2023, 206: 107662.
- [17] 王金鹏, 何萌, 甄乾广, 等. 基于 COF-YOLOv 8n 的油茶果静、动态检测计数[J]. 农业机械学报: 1-15.
- WANG Jinpeng, HE Meng, ZHEN Qiang, et al. Static and dynamic detection and counting of oil tea fruits based on COF-YOLOv 8n[J]. Journal of Agricultural Machinery: 1-15.
- [18] LIN Y, CHEN T, LIU S, et al. Quick and accurate monitoring peanut seedlings emergence rate through UAV video and deep learning[J]. Computers and Electronics in Agriculture, 2022, 197: 106938.
- [19] ZHOU Q, GUO W, CHEN N, et al. Analyzing nitrogen effects on rice panicle development by panicle detection and time-series tracking[J]. Plant Phenomics, 5: 0048.
- [20] GE Y, LIN S, ZHANG Y, et al. Tracking and counting of tomato at different growth period using an improving YOLO-DeepSORT network for inspection robot[J]. Machines, 2022, 10(6): 489.
- [21] VILLACRÉS J, VISCAINO M, DELPIANO J, et al. Apple orchard production estimation using deep learning strategies: A comparison of tracking-by-detection algorithms[J]. Computers and Electronics in Agriculture, 2023, 204: 107513.
- [22] ZHENG Z, XIONG J, WANG X, et al. An efficient online citrus counting system for large-scale unstructured orchards based on the unmanned aerial vehicle[J]. Journal of Field Robotics, 2023, 40(3): 552-573.
- [23] 刘雅晨. 基于 YOLOv7 与 Deepsort 算法的猕猴桃产量估计[D]. 华中农业大学, 2023.
- LIU Yachen. Kiwifruit yield estimation based on YOLOv7 and Deepsort algorithm[D]. Huazhong Agricultural University, 2023.
- [24] 孔令昀. 基于深度学习的动物目标识别与跟踪方法研究[D]. 电子科技大学, 2023.
- KONG Lingyun. Research on animal target recognition and tracking method based on deep learning[D]. University of Electronic Science and Technology, 2023.
- [25] TU S, ZENG Q, LIANG Y, et al. Automated behavior recognition and tracking of group-housed pigs with an improved DeepSORT method[J]. Agriculture, 2022, 12(11): 1907.
- [26] GUO Y, HONG W, WU J, et al. Vision-based cow tracking and feeding monitoring for autonomous livestock farming: the YOLOv5s-CA+DeepSORT-Vision transformer[J]. IEEE Robotics & Automation Magazine, 2023, 30(4): 68-76.
- [27] LIN T Y, Dollar P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 2117-2125.
- [28] LIU S, QI L, QIN H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 8759-8768.
- [29] YANG G, LEI J, ZHU Z, et al. AFPN: Asymptotic Feature Pyramid Network for Object Detection[C]//2023 IEEE International Conference on Systems, Man, and Cybernetics (SMC), Honolulu, Oahu, HI, USA, 2023: 2184-2189.
- [30] LIU S, HUANG D, WANG Y. Learning spatial fusion for single-shot object detection[J]. arXiv preprint arXiv: 1911.09516, 2019.
- [31] HE K, ZHANG X, REN S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.
- [32] SILIANG M, YONG X. MPDIoU: A loss for efficient and accurate bounding box regression. arXiv 2023[J]. arXiv preprint arXiv: 2307.07662.
- [33] Wojke N, Bewley A, Paulus D. Simple online and realtime tracking with a deep association metric[C]//2017 IEEE international conference on image processing (ICIP). IEEE, 2017: 3645-3649.
- [34] 耿利川, 王忠丰, 秦永志, 等. 基于 YOLOv7-Sim 和无人机遥感影像的烟株数量检测[J]. 中国烟草科学, 2023, 44(4): 94-102.
- GENG Lichuan, WANG Zhongfeng, QIN Yongzhi, et al. Tobacco plant population detection based on YOLOv7-Sim and UAV remote sensing images[J]. China Tobacco Science, 2023, 44(4): 94-102.

Research on tobacco plant detection and counting method based on improved YOLOv8

GAO Rui¹, WU Huicai², LIU Chunju³, LIU Zhongqing³, GUAN Ensen³, GAO Qiang⁴, JIANG Honghua^{1*}

1 College of Information Science And Engineering, Shandong Agricultural University, Taian 271018, China;

2 Laiwu Branch of Shandong Tobacco Company, Tobacco Co., Ltd., Laiwu 271199, China;

3 Weifang Branch of Shandong Tobacco Company, Weifang 261205, China;

4 Linyi Branch of Shandong Tobacco Company, Linyi 276003, China

Abstract: [Objective] To realize rapid detection and accurate counting of tobacco plants in different growth periods, a method based on an improved YOLOv8 for detecting and counting tobacco plants during different growth periods is proposed. This method addresses issues such as leaf overlap and varying degrees of occlusion between plants during the growth process. [Methods] Based on the YOLOv8 network framework, the feature fusion module was improved to an asymptotic feature pyramid network (AFPN) to avoid large semantic differences between non-adjacent layers during cross-layer fusion, thereby improving detection accuracy in the case of leaf overlap. The original spatial pyramid pooling structure was replaced with a spatial pyramid pooling fast cross-stage partial channel module (SPPFCSPC), effectively addressing the problem of redundant feature extraction and reducing model complexity. The loss function was optimized to the bounding box regression loss function MPDIoU (Minimum Point Distance Intersection over Union) to effectively reduce missed detections of leaves caused by occlusion. Plant counting functionality was achieved by integrating the DeepSORT (Deep Learning Based SORT) target tracking algorithm. [Results] The experimental results show that the method established in this study achieved an average accuracy of 95.9% in target detection, and an increase of 22.6%, 4.8%, 18.8%, 7.1%, and 4.2% compared to Faster R-CNN, SSD, CenterNet, YOLOv5n, and YOLOv7, respectively. In the counting task, the MOTA reached a maximum of 93.41%. [Conclusion] The model in this paper can realize rapid detection and accurate counting of tobacco plants in different growth periods, providing new ideas and methods for intelligent management in the tobacco plantation industry, and contributing to the modernization of the tobacco industry.

Keywords: YOLOv8; deep learning; tobacco plants; counting; target detection

*Corresponding author. Email: j_honghua@sda.edu.cn