

DOI: 10.15913/j.cnki.kjyex.2024.20.002

基于K近邻搜索的卷烟品牌区域偏好研究

刘晓迪, 罗燕雄, 何振峰

(广东烟草惠州市有限责任公司, 广东 惠州 516000)

摘要: 烟草数字营销领域的研究正围绕数据、内容和触点全面展开。烟草营销是产业数字化应用的重点领域。目前烟草行业卷烟品牌培育与卷烟营销等数字化产品已经得到了一定的应用,但是对于数据的分析、再加工等深入分析却略显不足。首先,了解卷烟消费情况,并使用回归模型进行分析,统计商户的各项指标,分析不同区域卷烟的销售、培育情况,进行特征工程提取,获得品牌的地理位置信息,利用K近邻算法进行聚类,形成具有营销特征的客户分类;其次,构建卷烟品牌区域偏好地图,利用GIS技术形成卷烟销售数据的热力图、云地图和知识地图,用以进行品牌偏好分析和培育管理。研究对企业的生产实践有较强的指导意义。

关键词: 卷烟品牌营销; 区域偏好分析; 特征工程; K近邻搜索

中图分类号: TP311.13

文献标志码: A

文章编号: 2095-6835(2024)20-0007-06

烟草营销是产业数字化应用的重点领域,根据两化融合服务联盟和国家工业信息安全发展研究中心发布的《中国两化融合发展数据地图(2018)》可知,烟草行业量化融合发展水平指数为64.4,成果较为突出。烟草行业的管理信息系统搭建、用户适销性分析、销量预测及品牌培育等方面都已经存在相关的研究。与此同时,纸质资料电子化和基础的数据仓库、管理信息系统已经得到了一定的应用,从产生、获取到存储的数据流已初步建立。

随着行业的快速发展,传统信息系统使用频度与日俱增,系统所产生的重要数据并未得到有效利用,缺少量化的数据分析工具。这些工具的功能包括在品牌培育的定性分析中引入量化手段,建立可对营销数据进行智能分析的数据模型等。

在品牌培育,特别是卷烟品牌培育方面,国内外学者已经进行了大量的研究。在此过程中机器学习技术发挥了特别重要的作用,其中K-近邻算法在各个领域都有出色的表现,算法采用向量空间模型来分类,将高维数据进行分类,同一类中数据的相似度高。利用与已知标签数据之间的相似度,预测未知数据的可能分类。

通过前期的实践和调研,初步总结出导致惠州市卷烟品牌培育效果不理想的主要原因之一是对客户周边消费情况的适销性分析不足,此次研究以惠州烟草客户订购历史信息为数据基础,结合K-近邻算法对历史数据进行分析,实现自动推销适销品牌的功能,并生成热销品牌热力图。

将研究模型应用于实际,成功验证了模型对于适销性分析的有效性。为便于使用者便捷高效使用模

型,利用Python、Java、Vue、JQuery等计算机语言基于MVC架构机型进行软件开发,最终以Web网页方式进行操作交互及结果输出,提升理论研究成果在实际生产中的易用性。

1 文献综述

面对竞争日益激烈的烟草市场环境及消费者不断提高的品牌意识,烟草行业逐渐意识到品牌培育对于行业发展的重要性,并积极探索提升品牌培育质效的方法和策略。其中,利用数据和AI技术成为了一个重要方向。

曾嘉(2021)^[1]提出提升烟草行业品牌培育质效的意义,并结合目前烟草行业品牌培育存在的问题,探索提升培育质效的具体策略,以期促进中国烟草行业健康、长久发展;张宇(2016)^[2]分类了“互联网+烟草品牌”的4种主要形式,进行了SWOT(优势、劣势、机遇、威胁)分析,提出了两者融合的3个发展阶段,最后总结了互联网环境下现代烟草企业进行品牌培育创新的关键点,力求为“互联网+烟草品牌”提供一定的参考。

品牌培育正成为行业所关注的重点,而数字驱动是此阶段战略转型的助燃剂。数据驱动指通过对可量化信息的深入分析获得洞见或对未来趋势的评价。具体到营销学领域,是通过分析与消费者的互动结果形成对未来产品适销性、品牌培育较为客观的见解。

在理论研究方面,国内学者也做了大量的工作,不少学者选择K-近邻分类算法助力数据分析预测与品牌培育。

温志芳(2021)^[3]利用各类高文档频率的特征选择方法,结合数据挖掘技术中的K-NN分类算法,分析并

建立匹配模型,在保证数据来源质量基础上可发挥大数据处理和分析的作用,助力科技成果转化体系建设;王璐和姜远(2021)^[4]提出使用随机平滑法对K近邻分类器进行鲁棒性验证,并证明了随机平滑的K近邻分类器展现出了更好的验证鲁棒性;刘鹏等(2019)^[5]改进了基于核的差重建的加权K近邻分类器,通过引入修正因子对含样本数较多的类别进行权值抑制,加大含样本数较少的类别的权值,实验证明,此类办法对于不平衡的心律失常数据集的分类有更好的效果;赵琳和行致源(2019)^[6]着眼于香农熵理论,提出了一种通过计算信息增益寻找对分类结果影响最大的特征,该方法保持了传统K近邻分类算法的精度,引入了最重要特征对分类结果的影响,有效降低了传统K近邻分类算法的时间复杂度;任丽芳(2015)^[7]提出一种基于聚类的加速K-NN分类方法CKNN,用于优化大规模数据的分类问题,实验结果表明,CKNN分类方法在保持较高分类精度的同时可大幅度提高模型的分类效率;职为梅等(2015)^[8]设计了3种影响函数,提出基于影响函数的K近邻分类方法,用于优化大规模数据分类问题,并证明基于影响函数的K近邻分类方法的分类性能好于传统的K近邻分类方法,且对非平衡数据集分类有效;陈伟杰等(2022)^[9]提出一种基于K最近邻及多分类器协同的训练样本扩增分类框架,在多个基准测试数据库中的对比实验结果表明,在少标记样本条件下,所提算法能显著提升分类器的分类精度;张婷暄等(2022)^[10]采用主成分分析法(PCA)对高维度特征数据进行降维,基于之前研究得到的预测模型,采用K近邻分类算法对分类模型进行改进,构造了一个PVC含水量预测模型,并证明了模型有良好的预测准确率;CHATCHAI & WORASAIT(2019)^[11]提出了一种基于几何中值(GM)的扩展原型选择技术,并将提出的方法与7种最先进的原型选择方法进行了比较,实验证明,该方法以略微降低精度为代价,运行速度比基线模型快3.5倍。

此外,陈文龙和时宏伟(2022)^[12]通过KD树对数据集进行划分,构造邻域对象集,提前区分出噪声点和核心点,避免聚类过程中对噪声的邻域集计算,加快了核心点对象的邻域集查询速度,实验结果表明,KD-DBSCAN算法的聚类效果和传统的DBSCAN算法基本一致,但时间性能有很大的提升。

李建锋等(2018)^[13]提出一种用于光线跟踪的SAH-KD树构建方法,解决当前KD树并行算法并行度不高且效率低的问题,并证明算法在生成同等质量KD树的情况下,能在线程数成倍增加时达到相近倍数的加速比。

综合以上分析可以发现,K近邻搜索已经在诸多场景下获得了比较好的应用效果,本文将K近邻搜索技术引入烟草品牌培育问题中,力图取得较好的应用效果。

2 问题与模型描述

2.1 问题描述

本文研究了卷烟品牌在惠州市各区域的偏好情况,其主要内容是利用机器学习方法特别是K近邻算法对已有的卷烟营销数据进行分析与处理。通过K近邻算法,根据客户经纬度信息、客户卷烟订购信息、品牌客户订购量信息、品牌基础信息、客户基础信息相关数据,查询客户相关数据,进行对标分析,以便推荐适销品牌。

已有数据主要是惠州近一年销售数据,其中包含组织名称、零售户编码、商品编码、商品名称、价类、需求量、实际订购量、合理定量、金额、商户经纬等主要信息。每天每个商户被派发的各个品规为一条单独完整的数据。

需求量由商户提供,是商户对品规自我规划的反映;实际订购量为真实销售数量;此次研究以实际订购量为参考数据,需将数据清洗选出实际订购量不为0的品规作为数据集。

基于商户经纬度将商户切分成多个区域商圈。根据模型,预测在不同的自变量情况下每种品规在各自区域的销量比率,并进行类似品规商品的推荐。

2.2 算法过程和步骤

2.2.1 符号说明

现有数据集定义为序列 $D=\{x_1, x_2, \dots, x_i, \dots, x_n\}$, n 为序列的个数, $x_i=y(x_1^i, x_2^i, \dots, x_{l_i}^i)$,其中 l_i 为序列 x_i 包含的属性个数。

序列 D 中分类数值大于阈值的序列定义为特征序列 $D'=\{x_1', x_2', \dots, x_i', \dots, x_m'\}$,其中 m 为特征序列的个数。

序列 D 中分类数值小于等于阈值的序列定义为验证集序列 $D''=\{x_1'', x_2'', \dots, x_i'', \dots, x_{n-m}''\}$ 。

相似的特征序列构成类簇中心定义为特征集合 $p=\{p_1, p_2, \dots, p_i, \dots, p_u\}$,其中 u 为聚类后类簇的个数。

K近邻任意2个序列被距离定义为 $kd_k(x_i)$,与 x_i 距离小于 $kd_k(x_i)$ 的序列被定义为邻近域 $N_{KNN_k(x_i)}^\circ$ 。

2.2.2 基于K近邻算法的特征序列识别

本文应用K近邻识别算法对数据集进行数据清洗,整体工作流程如图1所示。



图1 基于K近邻算法的特征序列识别总体流程

为了确定特征序列,首先利用序列 D 中任意2个序列 x_i, x_j ,抽取经纬度属性后采用DTW算法计算 x_i 与 x_j 之间的距离 $d_{\text{dtw}}(x_i, x_j)$,记为 $kd_k(x_i)$:

$$d_{\text{dtw}}(x_i, x_j) = d(x'_i, x'_j) + \min \begin{cases} d_{\text{dtw}}(x_i, x_{j-1}) \\ d_{\text{dtw}}(x_{i-1}, x_j) \\ d_{\text{dtw}}(x_{i-1}, x_{j-1}) \end{cases} \quad (1)$$

去除首尾元素干扰,采用欧式距离计算:

$$d(x'_i, x'_j) = \sqrt{(x'_i - x'_j)^2} \quad (2)$$

确定距离后算法后,选定 K 值求 x_i 第 K 邻近距离 $kd_k(x_i)$ 构成 x_i 的邻近域,即:

$$N_{\text{KNN}_k(x_i)} = \{x_j \in D, x_j \neq x_i | d_{\text{dtw}}(x_i, x_j) \leq kd_k(x_i)\} \quad (3)$$

为了精确确定特征序列,需要设置阈值 T ,考虑到烟草数据特性,选取最小方差阈值,即:

$$T = \mu + \sigma \quad (4)$$

$$\mu = \frac{1}{N} \sum_{i=1}^N X(x_i) \quad (5)$$

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N [X(x_i) - \mu]^2} \quad (6)$$

$$X = \frac{X(x_i) - \min(X)}{\max(X) - \min(X)} \quad (7)$$

$$X(x_i) = 1 - M(x_i) \quad (8)$$

$$M(x_i) = \frac{N_{|\text{KNN}_{\text{thr}}(x_i)|}}{\sum_{x'_i \in N_{\text{KNN}_{\text{thr}}(x_i)}} \text{adr}(x_i, x'_i)} \quad (9)$$

$$\text{adr}(x_i, x'_i) = \frac{d_{\text{dtw}}(x_i, x'_i)}{kd_{k_i}(x'_i)} \quad (10)$$

最后,根据算法计算分数与阈值对比,大于阈值范围抽选为特征序列 D' 。

2.2.3 模型评价方法

为了综合评价KNN回归模型的预测效果,对特征序列 $D' = \{x'_1, x'_2, \dots, x'_i, \dots, x'_m\}$ 进行聚类,将每个聚类中心定义为一个特征集合,对不同的特征集合进行识别,寻找聚类中心遵循2个原则,即聚类中心的密度要高于邻近的密度和任意2个类中心距离保持足够

远。首先利用所选取的 K 值 $K_i(i=1,2,3,\dots,n)$,选中值作为特征序列的密度。 K 值最大的特征序列为第一个聚类中心 O_1 ,依此类推,在距离范围内继续搜寻聚类中心,最终识别出特征集合。

为了验证聚类效果的好坏,引入轮廓系数 i_{sil} 对此进行综合评价。当聚类个数为 q 时,轮廓系数的计算公式为:

$$i_{\text{sil}} = \frac{1}{N} \sum_{i=1}^q \sum_{w \in C_i} \frac{\text{dif}(w, C_i) - \text{sam}(w, C_i)}{\max[\text{sam}(w, C_i), \text{dif}(w, C_i)]} \quad (11)$$

$$\text{sam}(w, C_i) = \frac{1}{n_{C_i}-1} \sum_{\mu \in C_i} d_{\text{dtw}}(w, \mu) \quad (12)$$

$$\text{dif}(w, C_i) = \min_{C_l, l \neq i} \left[\frac{1}{n_{C_l}} \sum_{\mu \in C_l} d_{\text{dtw}}(w, \mu) \right] \quad (13)$$

式中: N 为特征序列个数; w 为类簇内的序列; C_i 为第 i 个类簇; $\text{sam}(w, C_i)$ 为自定义函数,用来衡量序列簇内属性的相似度,根据入参计算2个序列的dtw距离(依次计算),以平均距离数值大小评价相似性; n_{C_i} 为 C_i 中包含的序列的个数; $\text{dif}(w, C_i)$ 为自定义函数,主要衡量簇间的相似度,根据入参计算2个序列间dtw距离(依次计算); n_{C_l} 为 C_l 中包含的序列的个数。

轮廓系数的数值直接反映出聚类效果的好坏, i_{sil} 值越大,证明序列中属性相同的距离更近,属性不同的距离较远,最终将所有有效性指标最大的聚类中心集合找出,算法结束求得聚类中心。

2.3 数值实验与结果

2.3.1 实验环境

为了对算法结果进行验证,进行了基于真实数据的算例实验。实验环境为Win 10 64 bit操作系统,Python 3.7.6软件、JAVA 1.8软件等, Tomcat中间件、Nginx中间件, 8 GB内存, Intel(R) Core(TM), i5-4200H CPU@2.80 GHz处理器。

2.3.2 实验数据集

本文所用数据来自2021年惠州部分地区销售历史数据、商户数据集、惠州数据字典集等。为满足模型使用要求,对近1 500万条销售原始数据主要进行了以下处理。

2.3.2.1 数据合并

如前所述,获取到的销售数据和商户数据等分别来自不同的数据库,为便于导入样本数据,首先需要对2份数据表进行合并。通过销售数据中商户编码主键与商户数据表外键关联,以销售数据表为主,将商户基本信息包括经纬度信息等插入销售数据表。

在数据合并过程中,将销售数据表中实际订购量为0的数据删除,确保合并后表格每条数据都为实际订购的数据,无其他干扰数据,合并后得到含有450万条

数据的销售样本数据集。

2.3.3.2 数据清洗

数据清洗工作主要步骤如下:①删除样本数据集中存在商户经纬度数据项缺失的样本;②根据经验修改或删除存在明显错误的数 据,如实际订购数据与金额不对等的数 据;③同一商圈订购单品价类数据具有极高相似性,为减少样本间距离的计算量,提升模型效率,删除重复的样本数据。经数据清洗后,销售数据集共有 156 235 条样本数据。

2.3.3.3 数据确定

数据预处理后得到的销售数据样本数据集共有 44 个字段和 156 235 条样本数据,在进行 KNN 回归模型设计前,首先需要明确模型样本的特征值和目标值;其次,为了验证 KNN 回归模型预测品规推荐结果的准确率,需要将样本数据集划分为测试样本集和训练样本集。

2.3.3.4 特征值与目标值

根据对品规推荐预测结果影响因素的分析,选取零售户编码、价类、商品编码、实际订购数量、经度、纬度等 22 个因素作为 KNN 回归模型的特征值;根据本文的研究目标,选取待预测的商品编码和合理定量作为回归模型的目标值,具体如表 1 所示。

表 1 KNN 回归模型特征值与目标值选取

数据类别	数据项
特征值	组织名称、零售户编码、零售户名称、客户分档、经营业态、商品编码、商品名称、价类、卷烟批发价、需求数量、实际订购数量、合理定量、金额、经度、纬度、条支比、盒支比、件支比、箱支比、万支比、货源属性、投放方式
目标值	商品编码、合理定量

2.3.3.5 确定训练样本与测试样本

为满足 KNN 回归模型对于训练数据和测试数据的要求及保证数据实验的灵活性,随机选取数据预处理后的销售数据集总量的 1%(1 562 条)作为测试样本,其余 99% 作为训练样本。

在实际销售数据中,按照品规价类划分为超千类、高价类、高一类、中一类、普一类、低一类、二类、高三类、低三类、四类、五类这 11 类。

其中超千类、高价类占比较低且品牌固定,不作为此次分析样本;主要选取剩余 9 类数据作为此次分析样本。

为保证随机抽取的测试样本分布的均衡性,避免测试样本集中于某一类价类,计划在 9 个价类中各随机抽取 1% 样本共同构成测试样本集,测试样本集在各价类中的随机取样安排如表 2 所示。

表 2 样本分布表

价类	样本数据集样本数量	随机抽取测试样本数量
高一类	1 250	12
中一类	3 625	36
普一类	20 415	204
低一类	19 254	192
二类	36 521	365
高三类	33 564	335
低三类	25 416	254
四类	15 012	150
五类	23 694	235

2.3.3 KNN 回归模型准确率判断步骤

输入训练样本集、测试样本集、最近邻数 K 。

输出测试样本集中样本对象目标值的预测结果及模型对测试样本集的预测准确率。

KNN 回归模型准确率判断步骤如下:①为 KNN 回归模型设置初始 K 值;②为 KNN 回归模型选择初始距离度量公式,利用设置的距离公式计算测试样本集中所有样本对象与训练样本集中的所有样本对象间的距离;③按照测试样本与训练样本间的距离将全部训练样本对象按升序排列,选择升序序列中的前 k 个训练样本对测试样本进行预测;④将距离最近的 k 个训练样本目标值的算术平均值记为测试样本目标值的预测值,并记录全部测试样本的预测结果;⑤按照设定的精确度计算方法计算 KNN 回归模型对测试样本集的预测准确率;⑥按照规定的评价标准判断 KNN 回归模型的准确率是否已达到要求,若未达到则更新最近邻数 K 值或更换距离度量公式,重复步骤②—⑤;若已达到要求,则可以确定该 KNN 回归模型的最佳 K 值和最优距离度量公式。

2.3.4 结果分析

利用测试样本随机抽取方法从抽油机井样本数据集中随机选取 1 562 条作为测试样本集,对其进行预测并分析评价模型预测效果。为了便于使用人员通过图形界面便捷应用上述基于 KNN 回归模型的研究结果,基于 Python 3.7.6、JAVA 1.8 设计了 KNN 回归模型应用的 WEB 界面,简洁美观,避免使用人员直接操作代码造成的工作不便。

在图 2、图 3 所示的 WEB 界面中,共包含 6 列区域,其主要内容和功能如下:分类指标、本店销量、同位置范围值标杆、同位置范围均值、同位置排名百分比、推荐订购规格,实现算法结果数据的展示以及自动推荐适销品牌。同位置范围值标杆是惠阳区内相同档位,如十三档客户中相应的最大值;同位置范围均值是惠阳区内相同档位平均值;同位置排名百分比是客户在

该档位排名与该档位总客户数的比值;推荐订购规格是当前客户规定范围内,根据KNN算法检索同品类卷烟,根据销量排序择优推荐。KNN回归模型根据商户

经纬度检索区域范围内卷烟销量,标点颜色代表卷烟销量的多少,颜色越深表示销售量越高。烟品销量热力图如图4所示。

分类指标	本店销量（条）	同位置范围标杆值（条）	同位置范围均值（条）	同位置排名百分比	推荐订购规格
		范围可达（500米、1公里、2公里一、10公里、15公里）默认1公里			推荐同位置前6名烟品类规格，按销量排序分别标注推荐指数（1-5星）
细支烟	6	27	10	0.19	黄鹤楼（硬平安），真龙（凌云），黄鹤楼（天下名楼），黄金叶（爱尚），贵烟（跨越），
中支烟	0	20	3	0.03	芙蓉王（硬中支），天子（中支），黄山（小红方印），七匹狼（纯境），中华（双中支），
短支烟	2	4	2.3	0.08	双喜（金01），黄山（记忆），利群（夜西湖），大前门（短支），
爆珠烟	2	7	2.2	0.25	贵烟（跨越），黄鹤楼（硬奇景），黄鹤楼（硬峡谷情细支），娇子（五粮浓香中支），爱喜（幻爱），
超千类	0	1	0.1	0.03	黄鹤楼（1916中支），
高价类	1	9	1.5	0.14	黄鹤楼（硬平安），白沙（硬细支和天下），南京（细支九五），白沙（和天下），黄鹤楼（硬1916），
高一类	1	15	2.9	0.06	中华（硬），中华（软），冬虫夏草（和润），南京（雨花石），中华（双中支），
中一类	0	16	3.2	0.03	芙蓉王（硬中支），芙蓉王（硬内带细支），芙蓉王（蓝），娇子（宽窄好运），贵烟（硬峡谷情细支），
普一类	6	22	8.4	0.25	芙蓉王（硬），双喜（硬世纪经典），双喜（硬金梅好日子），贵烟（跨越），玉溪（软），
低一类	2	21	7.7	0.11	双喜（硬红五叶神），黄鹤楼（软蓝），天子（金），玉溪（硬），黄山（红方印细支），
二类	15	29	18	0.22	双喜（硬经典1906），双喜（硬金五叶神），双喜（软珍品好日子），利群（新版），双喜（金01），

图2 WEB界面数据展示区(上)

细支烟	6	27	10	0.19	黄鹤楼(硬平安),真龙(凌云),黄鹤楼(天下名楼),黄金叶(爱尚),贵烟(跨越),芙蓉王(硬中支),天子(中支),黄山(小红方印),七匹狼(纯境),中华(双中支),双喜(金01),黄山(记忆),利群(夜西湖),大前门(短支),贵烟(跨越),黄鹤楼(硬奇景),黄鹤楼(硬峡谷情细支),娇子(五粮浓香中支),爱喜(幻爱),黄鹤楼(1916中支),黄鹤楼(硬平安),白沙(硬细支和天下),南京(细支九五),白沙(和天下),黄鹤楼(硬1916),中华(硬),中华(软),冬虫夏草(和润),南京(雨花石),中华(双中支),芙蓉王(硬中支),芙蓉王(硬内带细支),芙蓉王(蓝),娇子(宽窄好运),黄鹤楼(硬峡谷情细支),芙蓉王(硬),双喜(硬世纪经典),双喜(硬金梅好日子),贵烟(跨越),主喜(软),双喜(硬红五叶神),黄鹤楼(软蓝),天子(金),玉溪(硬),黄山(红方印细支),双喜(硬经典1906),双喜(硬金五叶神),双喜(软珍品好日子),利群(新版),双喜(金01),
中支烟	0	20	3	0.03	
短支烟	2	4	2.3	0.08	
爆珠烟	2	7	2.2	0.25	
超千类	0	1	0.1	0.03	
高价类	1	9	1.5	0.14	
高一类	1	15	2.9	0.06	
中一类	0	16	3.2	0.03	
普一类	6	22	8.4	0.25	
低一类	2	21	7.7	0.11	
二类	15	29	18	0.22	
高三类	10	15	10.8	0.22	双喜(硬),双喜(硬经典),双喜(软经典),白沙(精品二代),双喜(硬精品好日子),双喜(软),黄山(新一品),白沙(硬),钻石(国运),七匹狼(蓝),红旗渠(新版银河),红树(硬),红梅(软黄),
低三类	5	12	7.1	0.14	
四类	0	3	1	0.03	

图3 WEB界面数据展示区(下)




图4 烟品销量热力图

3 结束语

本文关注于卷烟营销数据的采集和分析工作,基于人工智能算法,开发了卷烟营销数据管理信息系统和卷烟营销数据地图。该系统可以横向推广到行业内的其他烟草企业,促进企业间的有效信息交流,加强营销方面的指导,形成有效的卷烟品牌竞争态势,从而对惠州市乃至广东省的卷烟销售工作提供数据和工具上的支持,做出更加数字化、智能化、精确化的决策。同时,本文的研究和应用成果能够促进卷烟品牌的管理和培育能力的提高,提升卷烟品牌管理与培育当中的信息化水平,使得卷烟营销更加精细化,基本实现精准投放。

此外,为进一步提高惠州市重点品牌的销量及上架率、提升品牌形象和影响力,需要建立需求量不确定的随机优化模型对推荐的卷烟销量进行预测,根据预测的置信度确定卷烟需求量的上界和下界,并收集需求分布信息,提升销量的同时优化库存管理水平。

参考文献:

[1] 曾嘉.关于提升烟草行业品牌培育质效的思考[J].中国市场,2021(35):126-127.

[2] 张宇.基于“互联网+”视角下的烟草品牌培育路径创新初探[J].老字号品牌营销,2016(12):8-13.

[3] 温志芳.基于K-近邻分类算法的供需数据智能匹配研究[J].工程机械与自动化,2021(2):29-30,33.

[4] 王璐,姜远.K-近邻分类器鲁棒性验证:从约束放松法到随机平滑法[J].中国科学:信息科学,2021,51(1):27-39.

[5] 刘鹏,杜佳芝,吕伟刚,等.面向不平衡数据集的一种改进的K-近邻分类器[J].东北大学学报(自然科学版),2019,40(7):932-936.

[6] 赵琳,行致源.基于最重要特征的裁剪K-近邻分类算法设计[J].电子设计工程,2019,27(14):135-138.

[7] 任丽芳.基于聚类的加速K-近邻分类方法[J].计算机应用与软件,2015,32(10):298-301.

[8] 职为梅,张婷,范明.基于影响函数的K-近邻分类[J].电子与信息学报,2015,37(7):1626-1632.

[9] 陈伟杰,郑成勇,蔡圣杰,等.少样本条件下基于K-最近邻及多分类器协同的样本扩增分类[J].现代电子技术,2022,45(15):123-127.

[10] 张婷喧,邓久宁,汪洁,等.基于主成分分析与K近邻分类算法的化工干燥分类模型[J].辽宁化工,2022,51(5):696-699.

[11] CHATCHAI K, WORASAIT S.Adaptive geometric median prototype selection method for K-nearest neighbors classification[J].Intelligent data analysis volume , 2019 , 23 (4) : 855-876.

[12] 陈文龙,时宏伟.基于KD树改进的DBSCAN聚类算法[J].Computer systems & applications,2022,31(2):305-310.

[13] 李建锋,谭耀华,廖胜辉.用于光线跟踪的高并行度表面积启发式(SAH)KD树构建[J].湖南大学学报(自然科学版),2018,45(10):148-154.

作者简介:刘晓迪(1983—),男,江西南昌人,硕士,政工师,研究方向为质量管理、卷烟营销、数据分析与应用。罗燕雄(1983—),男,广东增城人,本科,研究方向为信息化技术、网络安全、数据分析与应用。何振峰(1985—),男,广东兴宁人,硕士,工程师,研究方向为机械自动化。

(编辑:严丽琴)

(上接第6页)

[19] 荣命哲,吴翊.开关电器计算学[M].北京:科学出版社,2018.

[20] YOSHIHIRO K, HIROYUKI M, SHOKICHI I.3-D finite element analysis of electrodynamic repulsion forces instationary electric contacts taking into account asymmetric shape[J]. IEEE transon magnetics, 1997, 3(2):1994-1999.

[21] 王蒙,张文朝,高享想,等.基于积分法和差分法的电力系统短路电流直流分量特征参数计算[J].高压电器,2018,54(12):

268-273.

[22] 朱元武,杨俊,沈建梅.高压断路器触头烧蚀情况分析与研究[J].机械研究与应用,2022,35(2):149-153.

作者简介:豆龙江(1988—),男,河北衡水人,博士,讲师,研究方向为电站设备在线监测与故障诊断。

(编辑:李晓娟)