

基于 LightGBM 模型的中国成人吸烟行为研究

刘忠华¹, 卢鑫¹, 梅文强⁴, 赵旻¹, 胡彬彬², 张轲³, 殷红慧⁴

(1. 中国烟草总公司云南省公司, 云南 昆明 650011; 2. 云南省烟草农业科学研究院, 云南 昆明 650031;

3. 云南省烟草质量监督检测站, 云南 昆明 650032; 4. 云南省烟草公司文山州公司, 云南 文山 663099)

摘要: 采用 2018 年世界卫生组织在中国开展的成人烟草调查数据, 对成人吸烟行为影响因素进行探究。首先对原始数据做数据清洗, 包括剔除无关变量、组合新变量等步骤。其次结合卡方检验、方差分析以及最大互信息数对处理后的数据集进行特征选择。再次基于 XGBoost、LightGBM 算法进行建模, 对影响成人吸烟行为的因素进行排序和分析。最后基于表现较好的 LightGBM 模型进行变量组合建模, 进一步挖掘吸烟者特征。经建模分析, 识别得出成人性别、烟草环境、增税态度、低焦油烟认知、学历、年龄重要性由强至弱对吸烟行为产生影响。

关键词: LightGBM; XGBoost; 吸烟行为

中图分类号: TP399

文献标识码: A

文章编号: 2096-4706 (2024) 07-0128-09

Study of Adult Smoking Behavior in China Based on the LightGBM Model

LIU Zhonghua¹, LU Xin¹, MEI Wenqiang⁴, ZHAO Min¹, HU Binbin², ZHANG Ke³, YIN Honghui⁴

(1.China National Tobacco Corporation Yunnan Company, Kunming 650011, China; 2.Yunnan Academy of Tobacco Agricultural Sciences, Kunming 650031, China; 3.Yunnan Tobacco Quality Inspection & Supervision Station, Kunming 650032, China;

4. Yunnan Tobacco Company Wenshan Prefecture Company, Wenshan 663099, China)

Abstract: Using the adult tobacco survey data conducted by the World Health Organization in China in 2018, this study explores the influencing factors of adult smoking behavior. Firstly, perform data cleaning on the original data, including removing irrelevant variables, combining new variables, and other steps. Secondly, feature selection is performed on the processed dataset by combining Chi-square test, analysis of variance, and Maximal Information Coefficient (MIC). Then, it conducts modeling based on XGBoost and LightGBM algorithms, sorting and analyzing the factors affecting adult smoking behavior. Finally, based on the well performing LightGBM model, variable combination modeling is performed to further explore the characteristics of smokers. Through modeling and analysis, it is identified that adult gender, tobacco environment, attitude towards value-added tax, low tar smoke awareness, educational background, and age importance have a varying impact from strong to weak on smoking behavior.

Keywords: LightGBM; XGBoost; smoking behavior

0 引言

烟草作为一种嗜好品, 长期吸食会对人体健康产生一定影响。烟草烟雾中含有数百种有毒有害物质, 其中包括至少 69 种致癌物质。吸烟不仅对吸烟者自身健康有害, 而且对周围不吸烟者也产生危害。在过去的 50 年里, 越来越多无可争辩的科学证据表明, 使用烟草制品或接触二手烟会导致死亡、疾病和残疾。根据《世界卫生报告》, 在全球 8 个主要死因中, 有 6 个与吸烟有关, 而吸烟每年导致多达 700 万人死亡。为了遏制烟草流行, 减少烟草对健康和经济的破坏性影响, 世卫组织制定了烟草控制框架公约 (FCTC), 这是第一个国际公共卫生条约, 也是最广泛接受和最

迅速实施的条约之一。到目前为止, 已有 181 个国家签署了《烟草控制框架公约》, 中国是早期签署国之一。该公约要求签署国应建立烟草监测系统, 提供准确的国家和全球烟草使用数据, 以估算烟草使用对公共卫生和经济的影响, 并进一步评估烟草控制政策的有效性。

根据国家卫生委员会的工作计划, 在世界卫生组织的支持下, 中国疾病预防控制中心在 2018 年 7 月至 12 月期间, 按照全球成人烟草调查标准, 在中国开展了 2018 年成人烟草调查。该调查是一项针对 15 岁及以上非集体中国居民的家庭调查, 调查内容包括背景资料、烟草使用、电子烟使用、戒烟、二手烟、烟草价格、烟草控制运动、烟草广告、宣传和赞助、烟草使用知识、态度和看法等。本次调查采用分层多阶段整群随机抽样的方法, 最终得到 19 376 份有效问卷。对于收集到的问卷, WHO 研究人员进行统

收稿日期: 2023-07-13

基金项目: 云南省烟草公司文山州公司
科技计划一般项目 (20235326002)

计分析后，用于了解该国总体烟草流行情况，以及城市和农村地区、性别的烟草流行情况等问题。近年来，基于梯度提升决策树（Light Gradient Boosting Machine, LightGBM）的算法快速发展^[1, 2]，已被广泛用于交通^[3, 4]、医学^[5, 6]、金融^[7-9]、防灾^[10]、警务^[11]等领域。本文基于 WHO 组织调查数据，借助集成机器学习模型 XGBoost、LightGBM 进行数据挖掘，探究影响中国成人吸烟行为的主要因素，并通过对部分因素进行组合，进一步刻画出吸烟者和非吸烟者画像。最终，借助研究结果，针对不同特征的人群，提出更为准确的控烟建议。同时，也可根据建立得出的最优模型对中国成人吸烟行为进行预测。

1 数据预处理

1.1 处理目的

在进行建模分析之前，为得到表现较好的模型，需要对数据进行预处理^[12]。收集数据采用的抽样方法为 WHO 制定的多阶段随机整群抽样方法，得到的样本代表性良好。数据清洗的目的是让数据更加规整，主要包括剔除无关变量、组合新变量等步骤。特征选择则是帮助保留对模型结果有显著性影响的特征，化繁为简，增强模型的可解释性。

1.2 抽样方法

调查采用分层多阶段随机整群抽样方法^[13]。在设计过程中，充分考虑了与以往调查数据进行纵向可比性的需要，以客观反映烟草使用和烟草控制政策的现状。抽样过程如下：首先，全国按地理区域（中北部、东北部、中东部、中南部、西南部和西北部）和城乡（区县）划分为 12 个地层。

第一阶段抽样：在 2010 年保留的 100 个监测点的基础上，再选择 100 个监测点。在 12 个地层中，主要采样级别为县 / 区级别。每个阶层的原始样本规模与该地区的总户数成正比。根据每个县 / 区的户籍数量，采用概率比例抽样法（PPS）选择每个阶层的县 / 区。在 2018 年的调查中，新选出了 50 个县和 50 个区；因此，最终选定的主要样本单元总数为 200 个。

第二阶段抽样：首先，在第一阶段选择的县 / 区中，采用 PPS 法选择了 2 个村或居委会。因此，全国共选出 400 个村或居委会。如果选定的村或居委会的户籍人口在 1 000 户至 2 000 户之间，则该村或居委会被视为第二阶段的最终样本单元；如果选定的村或居委会的户籍人口超过 2 000 人，则将村或居委会分成若干部分，每个部分约有 1 000 户。采用简单随机抽样法选择一个断面作为第二阶段的最终样本单元。

第三阶段抽样：采用简单随机抽样方法，从每个

选定部门 / 村 / 居委会的住户名单中选择 55 户，全国共有 22 000 户。由于部分路段的空置住户相对较多，抽样时样本量有所扩大，全国共选择 24 370 户。

第四阶段抽样：根据选定的住户名单进行住户调查，根据调查问卷记录住户成员的信息，并从每户中随机选择一名成员作为受访者，最终，总共有 19 376 人完成了个人调查。

1.3 数据清洗

使用数据中的样本权重变量（gatsweight），经过计算调整样本数量，最终得到 60 350 条样本数据，代表中国 15 岁及以上的男性及女性的整体情况。数据中一共包含 339 个变量，包含个人背景资料、烟草使用、电子烟使用、戒烟、二手烟、烟草价格、烟草控制运动、烟草广告、宣传和赞助、烟草使用知识、态度和看法等方面内容。针对研究问题对数据做如下清洗：一是剔除无关变量。剔除与研究问题——是否抽烟无关的变量，以及只针对部分人群（如吸烟者）提问而产生的变量，保留 82 个变量做后续研究。二是组合部分变量，得到新变量。结合问卷信息，对类型一致或相似的变量进行组合，经过组合，得到 6 个新变量，如表 1 所示。

表 1 新变量表

变量名	解释	变量值	使用原始变量
isEle	是否抽电子烟	0: 不抽, 1: 抽	EC2、EC3
isPub	是否在公共场所接触过二手烟	0: 否, 1: 是	E10、E12、E14、E26、 EE16、E16、E22、 E20、E28、EE32
isSupPub	是否支持公共场所禁烟	0: 不支持, 1: 支持	E29A-E29H (8)
isBanM	媒体是否宣传禁烟	0: 否, 1: 是	G01A、G01B、G01C、 G01D、G01D2、 G01D3、G01D1、G01E
isProM	媒体是否宣传吸烟	0: 否, 1: 是	G04A-G04K (11)
isProC	是否有烟草推销活动	0: 否, 1: 是	G06A-G06G (7)

1.4 变量值的处理

问卷中变量值 7、77 含义为：Don't know，9、99 含义为：Refuse to answer，将其用缺失值替换，由于集成机器学习模型对缺失值兼容，不需要进行缺失值填充；涉及是非问题的变量值 1 含义为：Yes，2 含义为：No，将 2 替换为 0，后续建模时即可将该类型变量作为 0 ~ 1 变量来处理；对于部分有序离散型变量，根据变量值含义调整数值大小；对于多分类的无序离散型变量（假设含有 n 个类别），结合其变量值分布，进行独热编码，最终处理为 n 个 0 ~ 1 变量。表 2 为多分类无序离散型变量处理表。

表 2 多分类无序离散型变量处理表

变量名	解释	变量值	独热编码处理后的 0 ~ 1 变量
REGION3	地区	1:East, 2:Central, 3:West	East, Central, West
HHH6	家庭收入	1、2、3:Below 50 000; 4、5、6、7:50 000 ~ 300 000	Below 50 000, 50 000 ~ 300 000
A04	学历	1、2、3:elementary school and below; 4、5:Middle school; 6、7、8:High school and above	elementary school and below, Middle school, High school and above
A05	职业	1、3:farmer and industry workers; 2:gov/public institute employees; 4:teacher; 5:healthcare worker; 8:unemployed; 6、7、9、10:other	farmer and industry workersgov/public institute employees, teacher, healthcare worker, unemployed, other

1.5 剔除类别分布不平衡变量

对于无序离散型变量，部分变量的类别分布过于极端，某类别样本达到总样本的 90% 以上，此变量很难对模型拟合效果的提升产生贡献，考虑将其进行

剔除处理。经过上述清洗过程后得到 29 个变量，其中因变量为是否吸烟（isSmoke），自变量 28 个，包含连续型变量、有序离散型变量及无序离散型变量。相关变量说明如表 3 所示。

表 3 变量说明表

变量种类	变量类型	变量名	解释	变量值
因变量		isSmoke	是否抽烟	0: 否, 1: 是
自变量	连续型	PersonNum	家庭 15 岁以上人数	1 ~ 10
	离散型	Age	年龄	15 ~ 110
		TobaccoEnv	烟草环境	0 ~ 4
		LowtarAware	低焦油烟认知	1 ~ 3
		Residence	居住地	0: 农村, 1: 城市
		Male	男性	0: 否, 1: 是
		Flush toilet	家里是否有抽水马桶	
		Car	家里是否有汽车	
		Motorcycle	家里是否有摩托车	
		isKnowEle	是否听说过电子烟	
		Cigarette warnings	是否看过烟草警告	
		isSupPic	是否烟盒支持印刷烟草危害图片	
		Actor smoke in media	是否在媒体中见到吸烟场景	
		Stroke	是否了解吸烟会引起中风	
		Heart disease	是否了解吸烟会引起心脏病	
		Erectile dysfunction	是否了解吸烟会引起勃起障碍	
		isIncreTax	是否支持增税	
		isPub	是否在公共场所接触到二手烟	
		isBanM	媒体是否支持禁烟	
		Central	中部	
		East	东部	
		West	西部	
		50 000 ~ 300 000	家庭年收入 50 000 ~ 300 000	
		Below 50 000	家庭年收入 50 000 以下	
		High school and above	学历高中及以上	
		Middle school	学历初中	
		elementary school and below	学历小学及以下	
		farmer and industry workers	农民工	

2 特征选择

2.1 离散型变量特征选择

对于本文研究的问题来说,如果一个离散型特征取值在吸烟组和不吸烟组占比是相同的,就认为这个变量对成人吸烟与否是没有影响的;如果该离散型特征取值在吸烟组和不吸烟组占比相差非常大,就认为该变量对成人吸烟与否影响非常大,即通过分析对比离散型变量不同取值在不同组之间分布有无显著差异,进行离散型变量的特征选择。由于考虑的是两个属性变量之间是否有联系,采用列联表分析的方法,列联表分析使用的是卡方统计量^[14]。下面先介绍列联表分析的统计量卡方检验,以变量 Male 说明列联表筛选变量的原理与步骤。卡方检验方式如下:

若用 f_0 表示观测值频数,用 f_e 表示期望值频数, χ^2 统计量可写为:

$$\chi^2 = \sum \frac{(f_0 - f_e)^2}{f_e}$$

如果在一定显著性水平下, χ^2 统计量大于所对应的 $\chi^2(n)$, 那么我们认为拒绝原假设,我们就认为检测的两属性之间是不独立的,反之。下面以变量 Male 这一变量举例说明。表 4 是性别在不同组内的实际人数分布和期望人数分布,对应的卡方统计量计算为:

$$\chi^2 = \frac{(29\ 171 - 21\ 784)^2}{21\ 784} + \frac{(613 - 7\ 910)^2}{7\ 910} + \frac{(15\ 151 - 22\ 448)^2}{22\ 448} + \frac{(15\ 145 - 8\ 118)^2}{8\ 118} \approx 18\ 095$$

在 $\alpha=0.05$ 的显著性水平下, $\chi^2_{0.05}(1) \approx 3.84$, 可见 $18\ 095 \gg 3.84$, 作出拒绝原假设的判断,即认为性别与是否吸烟是显著相关的。

表 4 变量 Male 分布示例表

性别	实际人数分布			期望人数分布		
	不吸烟	吸烟	合计	不吸烟	吸烟	合计
女性	29 171	613	29 784	21 874	7 910	29 784
男性	15 151	15 415	30 566	22 448	8 118	30 566
合计	44 322	16 028	60 350	44 322	16 028	60 350

同样的,对其他的离散型变量依次进行卡方检验,进行变量筛选。

2.2 连续型变量特征选择

在这一节中,采用单因素方差分析方法进行变量选择。需要说明,将有序离散型变量烟草环境 (TobaccoEnv)、低焦油烟认知 (LowtarAware) 当作连续型变量进行处理。方差分析的一般步骤如下:

1) 提出原假设与备择假设。此问题原假设为是否吸烟对受访者特征没有影响。

2) 构造检验统计量。计算组间平方和 SSA、组内平方和 SSE,构造 F 统计量:

$$F = \frac{SSA/(k-1)}{SSE/(n-k)} \sim F(k-1, n-k)$$

其中, k 为因素水平个数, n 为样本总数。SSA 与 SSE 定义为:

$$SSE = \sum_i^k \sum_j^{n_i} (x_{ij} - \bar{x})^2$$
$$SSA = \sum_i^k n_i (\bar{x}_i - \bar{x})^2$$

3) 统计决策。根据计算出来的 F 统计量在一定显著性水平下判断是否拒绝原假设。下面以年龄这一变量举例说明方差分析的步骤,如表 5 所示。即这里分别计算不同组的组内、组间平方和。由于这里数据量过大,不展示详细的计算步骤。由上述计算得出拒绝原假设,保留年龄变量。同样的,对剩余的连续型变量依次进行方差分析,进行变量筛选。

表 5 变量年龄分布示例表

类别	年龄					
不吸烟	34	34	...	36	70	...
吸烟	60	60	...	40	63	...

2.3 依据变量相关性进行特征选择

在最后建模之前,我们考虑变量间可能会存在一定程度相关性,这会影响建模结果。用衡量两变量间相关关系的最大互信息数 (MIC) 作为判断标准,最大互信息数不局限于线性关系,也可以衡量变量间的非线性关系。MIC 的计算公式为:

$$MIC(x; y) = \max \frac{I(x; y)}{\log_2(\min(a, b))} \quad a \times b < B$$

MIC 计算的时候会 $a \times b$ 的网格划分数据空间。经计算得到两变量间 MIC 值结果,如表 6 所示。

表 6 变量 MIC 值

变量一	变量二	MIC 值
Heart disease	Erectile dysfunction	0.793 54
Erectile dysfunction	East	0.768 89
Stroke	Heart disease	0.754 57
Erectile dysfunction	Central	0.746 34
Residence	Erectile dysfunction	0.745 75
Erectile dysfunction	West	0.744 74
Heart disease	East	0.729 11
Heart disease	West	0.715 68
Stroke	Erectile dysfunction	0.703 51

本文对存在相关性的变量处理如下:若两变量之间 MIC 值大于 0.7,结合卡方检验以方差分析结果进行判断,只将其中一个变量纳入建模的数据集中。经过上述特征选择,最终选取的 16 个变量用

于后续建模，具体说明如表 7 所示。文中使用的模型 XGBoost、LightGBM 均是在梯度提升决策树模型（GBDT）的基础上改进而来，由于运算速度快、效果好的优点，在目前各个研究领域内被广泛使用。

表 7 特征选择结果

变量种类	变量类型	变量名	解释	变量值
因变量		isSmoke	是否抽烟	0: 否, 1: 是
自变量	连续型	PersonNum	家庭 15 岁以上人数	1 ~ 10
	离散型	Age	年龄	15 ~ 110
		TobaccoEnv	烟草环境	0 ~ 4
		LowtarAware	低焦油烟认知	1 ~ 3
		Male	男性	0: 否, 1: 是
		isKnowEle	是否听说过电子烟	
		Actor smoke in media	是否在媒体中见到吸烟场景	
		Heart disease	是否了解吸烟会引起心脏病	
		isIncreTax	是否支持增税	
		isPub	是否在公共场所接触到二手烟	
		Below 50 000	家庭年收入 50 000 以下	
		High school and above	学历高中及以上	
		Middle school	学历初中	
		elementary school and below	学历小学及以下	
		farmer and industry workers	农民工	

3 模型方法

3.1 XGBoost 模型

XGBoost（eXtreme Gradient Boosting）相较于传统 GBDT 在效率与准确率上有较大提升。它本质上是一种通过组合弱学习器来产生强学习的 Boosting 算法，相比于较早的 Adaboost 通过调整每一轮训练样本的权重，XGBoost 是通过拟合上一轮学习器的残差来训练模型。

$$\text{Obj}(\Theta) = \sum_i^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

上式是 XGBoost 的目标函数，第一部分是训练误差，第二部分是每棵树的复杂度的和。主要有以下优点：一是高度灵活性。支持线性分类器，对代价函数进行二阶泰勒展开。二是正则化。在代价函数加入了正则项，用于控制模型复杂度，防止过拟合。三是自动缺失值处理。对于存在缺失值的特征，可以自动学习出它的分裂方向。四是列抽样。借鉴了

Randomforest 对列随机抽样的做法，不仅能降低过拟合，还能减少计算量。

3.2 LightGBM 模型

LightGBM 算法是 2017 年由微软团队提出的 GBDT 算法的改进版，是基于梯度的单面采样算法（GOSS）和特征捆绑算法（EFB）的结合。GOSS 采样认为梯度大的样本点会贡献更多的信息增益，因此 GOSS 进行下采样的时候保留大梯度的数据，按比例随机采样梯度小的样本点。EFB 算法通过绑定互斥的特征来减少互斥特征的数量从而实现降维的目的。LighGBM 采用了 Histogram 算法，将连续特征离散化固定到固定数量的 bins 上。主要有以下优点：一是时间复杂度低。采用直方图算法将遍历样本转变为遍历直方图；二是计算量小。采用了基于 Leaf-wise 算法的增长策略构建树；三是内存占用少。采用互斥特征捆绑算法减少了特征数量；四是支持并行学习。采用优化后的特征并行、数据并行方法加速计算，当数据量特别大的时候还可以采用投票并行的策略。

4 模型构建与评估

数据预处理完成后，分别建立 XGBoost、LightGBM 模型，用 AUC 值作为模型主要评价指标。依据模型绘制出决策树，并进行特征重要性排序，从而得出结论。

4.1 模型评价指标

对于二分类模型，其阈值可能设定的高或低，通过设定不同的阈值得到不同的假正类率（FPR）和真正类率（TPR），ROC 曲线就是将同一模型每个阈值的 FPR 作为横坐标，TPR 作为纵坐标所形成的曲线。

由于 ROC 曲线的形状不好量化比较，因此需要结合 ROC 曲线与坐标系所围成的面积（AUC）来评价模型的预测性能。AUC 评价指标相对于其他指标而言，更能衡量模型对于不平衡数据的预测能力，不关注具体得分，只关注排序结果，不需要设定阈值，评估效果更好。因此，本文选用 AUC 值作为模型评价指标。

4.2 模型建立——XGBoost

建模过程分为以下步骤：

- 1) 训练集与测试集划分。按照 8:2 的比例划分训练集与测试集，在训练集进行模型训练，在测试集上用 AUC 值进行模型评价。
- 2) 网格搜索调参。网格搜索算法是一种最简单也是最常用的超参数搜索算法，给定参数搜索范围，输出最优化的参数，如表 8 所示。

表 8 网格调参结果

参数名	参数值
colsample_bytree	0.8
learning_rate	0.6
max_depth	8
subsample	0.9

3) 最优模型训练。给定最优化的参数, 在训练集上进行训练, 在测试集上的 AUC 值为 0.872, 模型泛化能力强, 图 1 为 ROC 曲线。

4) 获得模型结果。依据建立出的模型, 可以绘制出决策树, 如图 2 所示。

由图 2 可得出以下结论:

- 1) 吸烟者画像: 年龄为 18.5 岁以上、不支持增税的男性; 年龄 63.5 岁以上、不支持增税的女性。
- 2) 不吸烟者画像: 年龄 21.5 岁以下、支持增税的男性; 支持增税、对电子烟不了解的女性。




图 1 ROC 曲线

用特征分裂后带来的平均增益作为特征重要性评估标准, 得到如图 3 所示的排序, 其中, 性别、烟草环境、是否支持增税为判断吸烟者的主要特征。可见, 改善烟草环境能够有效降低成人的吸烟率, 国家可出台相关政策进行管控。

重要性排前 5 的特征对 AUC 值的提升如表 9 所示。




图 2 XGBoost 决策树




图 3 XGBoost 特征排序

表 9 AUC 提升值

特征	提升值	特征	提升值	特征	提升值
Male	0.110	isIncrTax	0.020	High school and above	0.001
TobaccoEnv	0.060	LowtarAware	0.007		

4.3 模型建立——LightGBM

建模过程分为以下步骤：

- 1) 训练集与测试集划分。按照 8:2 的比例划分训练集与测试集，在训练集进行模型训练，在测试集上用 AUC 值进行模型评价。
- 2) 贝叶斯全局优化调参。贝叶斯优化是一个很有效的全局优化算法，目标是为了找到全局最优解。模型主要参数的选择如表 10 所示。

表 10 贝叶斯调参结果

参数名	参数值
feature_fraction	0.23
lambda_l1	1.06
lambda_l2	3.90
learning_rate	0.26
max_depth	9
min_data_in_leaf	3
min_gain_to_split	0.08
min_sum_hessian_in_leaf	0.01
num_leaves	10

- 3) 最优模型训练。给定最优化的参数，在训练集上进行训练，在测试集上的 AUC 值为 0.874，模型泛化能力强，图 4 为 ROC 曲线。




图 4 ROC 曲线

- 4) 获得模型结果。用全部变量进行建模，绘制出决策树，如图 5 所示。

依据该图的不同分支，可得出结论：

- 1) 吸烟者画像：高中以下学历、在媒体上见过吸烟场景的男性。
- 2) 不吸烟者画像：高中以上学历、未在媒体上见过吸烟场景的男性。

用特征分裂后带来的平均增益作为特征重要性评估标准，得到如图 6 所示的排序。

由图 6 可知，与 XGBoost 模型相同，性别、烟草环境、是否支持增税为判断吸烟者的主要特征。重要性排前 5 的特征对 AUC 值的提升如表 11 所示。




图 5 LightGBM 决策树




图 6 LightGBM 特征排序

表 11 AUC 提升值

特征	提升值
Male	0.090
TobaccoEnv	0.030
isIncreTax	0.020
Age	0.010
LowtarAware	0.009

为进一步刻画出吸烟者画像, 详细了解其特征,

对部分变量进行组合建模, 对绘制出的决策树图像进行分析, 得出结论。

依据图 7, 可得出吸烟者画像为: 支持增税、不认同低焦油烟危害以及吸烟引起心脏病; 不支持增税、认同低焦油烟危害、18.5 岁以上; 在公共场所接触过二手烟、初中学历以下、18.5 岁以上; 未在公共场所接触过二手烟、年龄 37.5 岁以下; 家里 7 口人以上、高中以下学历、农民工; 家里 6 口人以下、小学以下学历、非农民工。




图 7 组合变量决策树

5 结 论

本文基于 WHO 组织 2018 年在中国开展的成人烟草调查数据, 采用多阶段随机整群抽样方法, 对其进行数据清洗、特征选择后, 将 XGBoost、LightGBM 算法运用到成人吸烟行为预测模型中。研究表明, 在算法上, LightGBM 运行速度和模型分类

能力均优于 XGBoost; 影响因素分析上, XGBoost 和 LightGBM 算法均给出了影响因素重要性排序图, 主要因素有: 性别、烟草环境、增税态度、低焦油烟认知、学历、年龄等。通过对组合变量进行建模, 由绘制出的决策树可以进一步刻画出吸烟者画, 便于相关管理部门和控烟组织针对不同特征人群 (下转 140 页)

等功能,减少用户在多个平台获取商品信息时所花费的时间和精力,从而为用户购物提供更加便捷的服务,为商业应用创造可观的价值。

未来,随着人工智能技术的不断发展,RPA 优惠商品比价平台有望在更多领域得到应用。例如,结合自然语言处理和机器学习技术,为用户提供更精准的商品推荐;引入区块链技术,确保数据的安全性和可信度;拓展平台的合作伙伴,增加更多购物平台的支持等。这些发展将为用户提供更便利、高效的商品信息搜索服务,同时为商业应用带来更广阔的市场前景。




图7 平台商品比价页面

参考文献:

- [1] 中国互联网络信息中心 .CNNIC 发布第 51 次《中国互联网络发展状况统计报告》[J]. 互联网天地, 2023 (3): 3.
- [2] GUPTA S, RANI S, DIXIT A. Recent Trends in

Automation-A Study of RPA Development Tools [C]//2019 3rd International Conference on Recent Developments in Control, Automation & Power Engineering(RDCAPE).Noida: IEEE, 2019: 159-163.

[3] 程平, 邓湘煜 .RPA 财务数据分析机器人: 理论框架与研发策略 [J]. 会计之友, 2022 (13): 148-155.

[4] 陈虎, 孙彦丛, 郭奕, 等 . 财务机器人——RPA 的财务应用 [J]. 财务与会计, 2019 (16): 57-62.

[5] 司玉涛 . 基于 RPA 的 HB 公司财务共享服务中心业务流程优化研究 [D]. 邯郸: 河北工程大学, 2022.

[6] 王学平, 李长春, 毛玲燕 . 基于 RPA 的应用交付能力研究与实践 [J]. 冶金自动化, 2023, 47 (S1): 592-595.

[7] ZHAO C H, QIAN Q, XUE J R, et al. Design and Implementation of Enterprise Sensitive Information Monitoring System Based on RPA [C]//2023 5th International Conference on Communications, Information System and Computer Engineering (CISCE).Guangzhou: IEEE, 2023: 263-267.

[8] 田高良, 陈虎, 郭奕, 等 . 基于 RPA 技术的财务机器人应用研究 [J]. 财会月刊, 2019 (18): 10-14.

[9] LUBIS L S, SEMBIRING D E. Driving Digital Transformation: Leveraging Robotic Process Automation(RPA)to Enhance Business Process Efficiency and Reducing Manual Errors [C]//2023 IEEE International Conference on Data and Software Engineering(ICoDSE).Toba: IEEE, 2023: 91-95.

[10] 秦海波, 曹莉, 叶宜修, 等 .RPA 流程自动化技术分析 [J]. 自动化技术与应用, 2022, 41 (5): 1-3+25.

作者简介:

黄英迪 (2002—), 女, 汉族, 山东临沂人, 本科在读, 主要研究方向: 件项目开发与管理; 陈立涛 (2002—), 男, 汉族, 广东汕头人, 本科在读, 主要研究方向: 大数据与区块链技术; 梁通达 (2000—), 男, 汉族, 广西南宁人, 本科在读, 主要研究方向: Web 前端开发。

(上接 135 页)制定个性化控烟政策提供决策依据。

参考文献:

- [1] 尹超英, 邵春福, 黄兆国, 等 . 基于梯度提升决策树的多尺度建成环境对小汽车拥有的影响 [J]. 吉林大学学报: 工学版, 2022, 52 (3): 572-577.
- [2] 生红莹, 赵伟国, 陈扬, 等 . 基于深度数据挖掘的电力系统短期负荷预测 [J]. 吉林大学学报: 信息科学版, 2023, 41 (1): 131-137.
- [3] 常硕, 张彦春 . 基于袋外预测和扩展空间的随机森林改进算法 [J]. 计算机工程, 2022, 48 (3): 1-9.
- [4] 甘红楠, 张凯 . 参数自适应下基于近邻图的近似最近邻搜索 [J]. 计算机工程, 2022, 48 (9): 28-36.
- [5] 彭俊, 项薇, 谢勇, 等 . 基于 LightGBM 多阶段医疗服务等待时间的预测研究 [J]. 计算机应用与软件, 2022, 39 (12): 119-124.
- [6] 闫瑞平, 王习亮, 姚粉霞, 等 . 决策树模型与 Logistic 回归分析模型识别高血压危险因素的效果比较 [J]. 中华疾病控制杂志, 2022, 26 (2): 218-222.
- [7] 胡嘉麟 . 基于 LightGBM 模型的车辆保险购买兴趣预测研究 [D]. 大连: 大连理工大学, 2021.

[8] 张汉平 . 基于 LightGBM 模型的个人贷款违约预测的研究 [D]. 武汉: 华中师范大学, 2021.

[9] 郭长东 . 基于 XGBoost 模型的股票预测研究 [D]. 延吉: 延边大学, 2021.

[10] 范桂英, 汤军, 高贤君, 等 . 基于 LightGBM 的南阳市西部地区山洪灾害风险评价 [J]. 中国农村水利水电, 2023 (8): 135-141+156.

[11] 钱芳慧, 蔡竞 . 基于 LightGBM 的犯罪类型预测模型研究 [J]. 计算机仿真, 2023, 40 (1): 25-30.

[12] 吴照明, 胡西川 . 基于 LightGBM 信贷风控模型的算法优化 [J]. 计算机应用与软件, 2022, 39 (6): 342-349.

[13] 郭长帅, 卓建伟 . 基于数据挖掘算法的流动人口定居意愿研究 [J]. 管理现代化, 2019, 39 (3): 81-86.

[14] 冯斌, 张又文, 唐昕, 等 . 基于 BiLSTM-Attention 神经网络的电力设备缺陷文本挖掘 [J]. 中国电机工程学报, 2020, 40 (S1): 1-10.

作者简介:

刘忠华 (1982—), 男, 汉族, 云南楚雄人, 统计师, 农艺师, 硕士研究生, 主要研究方向: 应用统计和数字农业; 通讯作者: 殷红慧 (1977—), 女, 汉族, 云南玉溪人, 高级农艺师, 硕士, 主要研究方向: 烟草农业研究。