

分类号：

密级：

U D C：

学号：417117816024

南 昌 大 学 专 业 学 位 硕 士 研 究 生

学 位 论 文

基于 Hadoop 的江西卷烟零售户画像系统的 设计与实现

The Design and Implementation of Jiangxi Tobacco retailers'

Persona System Based on Hadoop

吴漪涛

培养单位（院、系）：管理学院

指导教师姓名、职称：刘春年 教授

指导教师姓名、职称：刘志军 教授

专业学位种类：工程管理硕士

论文答辩日期：2018 年 5 月 27 日

答辩委员会主席：陆伟锋 教授

评阅人：_____

2018 年 5 月 27 日

摘 要

在吸烟人口减少和全面政策控烟的情况下，常规的卷烟营销方式已经不能满足江西烟草企业发展的需求。随着企业的发展，江西烟草积累了大量的零售户数据，希望通过对用户数据的分析发现新的商业模式。通过运用大数据技术手段重塑业态结构与生态圈的零售新模式，将是江西烟草企业发展的一条途径，而其中对于零售户的全方位识别就是重中之重。传统的用户分析过于依赖于个人经验，因此需要一个简单的具有智能分析的平台来进行自动分析。本课题以江西烟草卷烟零售户的相关数据作为数据分析集，研究零售户画像的相关理论，建立画像模型，并在此基础上开发出基于 Hadoop 大数据平台的零售户画像信息系统。主要研究的内容：

1、建立适宜江西省烟草公司的 Hadoop 大数据平台，将全省烟草系统内的业务数据，将零售户相关的数据纳入大数据管理平台管理。

2、建立零售户画像模型及分类评价理论模型，设计并实现江西烟草零售户画像的信息系统。

3、依托零售户的画像信息，实现江西烟草的精准营销、精准服务、精准管控的目标。

关键词：画像；零售户；大数据；烟草

ABSTRACT

With the decrease of smoking population and the overall policy of tobacco control, the conventional cigarette marketing mode can no longer meet the needs of Jiangxi tobacco enterprises. With the development of enterprises, Jiangxi tobacco has accumulated a large number of retail data, hoping to find new business models through analyzing user data. It will be a way for the development of Jiangxi tobacco enterprises to reshape the new model of retail structure and ecosphere by using large data technology, and the overall identification of retail households is the most important. Traditional user analysis is too dependent on personal experience, so a simple intelligent analysis platform is needed for automatic analysis. This subject takes the related data of Jiangxi tobacco cigarette retailer as the data analysis set, studies the related theories of retail portrait and builds the picture model, and develops a retail customer picture information system based on the Hadoop large data platform. The main research content:

1. Set up a Hadoop large data platform suitable for the tobacco companies of Jiangxi Province, the business data of the tobacco system in the whole province, and bring the data of retail customers into the management of the large data management platform.
2. Establish the retail portrait model and the classified evaluation theory model, and design and implement the information system of Jiangxi tobacco retail households portrait.
3. Relying on the portrait information of retail households, we will achieve the goal of precise marketing, precise service and precise control of Jiangxi tobacco.

Key Words: Portrait; Retailer; Big Data; Tobacco

目 录

摘 要.....	II
ABSTRACT.....	III
第 1 章 引言.....	1
1.1 研究背景及意义.....	1
1.2 现状研究.....	1
1.3 研究内容.....	2
1.4 论文组织结构.....	3
第 2 章 卷烟零售户画像的相关理论.....	4
2.1 客户细分理论.....	4
2.2 客户画像理论.....	4
2.3 层次分析法.....	5
2.4 数据挖掘技术.....	6
2.5 客户关系管理.....	7
第 3 章 卷烟零售户画像的分析.....	8
3.1 卷烟零售业务概况.....	8
3.2 卷烟零售户画像分析.....	10
3.2.1 零售户画像概述.....	10
3.2.2 数据标签映射法.....	11
3.3 卷烟零售户画像建模.....	12
3.3.1 用户标签树概述.....	12
3.3.2 客户画像建模.....	13
3.4 零售户分类综合评价建模.....	15
3.5 系统功能需求分析.....	20
3.5.1 零售户管理.....	21
3.5.2 标签库管理.....	22
3.5.3 零售户分类管理.....	23
3.5.4 数据管理.....	25
3.5.5 系统管理.....	27
第 4 章 卷烟零售户画像系统设计.....	28
4.1 设计原则.....	28
4.2 总体设计.....	28
4.3 功能模块设计.....	29
4.3.1 零售户管理.....	30
4.3.2 标签库管理.....	30
4.3.3 零售户分类管理.....	31

4.3.4 数据管理.....	32
4.3.5 系统管理.....	33
4.4 主要数据表设计.....	34
第5章 卷烟零售户画像系统实现.....	40
5.1 开发运行环境.....	40
5.2 Hadoop 平台实现.....	40
5.2.1 数据源分析.....	40
5.2.2 数据 ETL 实现.....	41
5.2.3 数据挖掘算法实现.....	42
5.3 主要功能模块实现.....	45
5.3.1 零售户信息查询.....	45
5.3.2 零售户标签信息查看.....	47
5.3.3 零售户综合评价画像信息查看.....	48
5.4 系统测试.....	49
5.4.1 测试内容.....	49
5.4.2 测试用例.....	50
5.4.3 测试结论.....	50
5.5 系统应用及效果分析.....	51
5.5.1 样本数据.....	51
5.5.2 客户画像结果分析.....	52
5.5.3 营销策略.....	54
5.5.4 应用效果分析.....	55
第6章 结论与展望.....	57
6.1 结论.....	57
6.2 进一步工作的方向.....	57
致 谢.....	58
参考文献.....	59

第1章 引言

1.1 研究背景及意义

近年来，数据爆发式增长，引起了“大数据”概念在科学领域、学术界和工业界的激烈讨论。传统的 IT 行业对基础设施和基本技术有很高的要求。而大数据平台对硬件基础设施的需求相对较低，大数据平台可以使用价格低廉的硬件资源来部署。另外，相对于数据库运用的高起点，大数据平台的研究运用国内外差距较小。Hadoop 是作为大数据平台的代表，实现对海量数据进行管理。Hadoop 框架中最核心设计就是 HDFS 和 MapReduce。HDFS 解决大数据的存储，MapReduce 解决大数据的计算。Hadoop 是目前主流的大数据处理平台，其生态圈还包括数据抽取 Sqoop，数据仓库 Hive，数据分析 Mahout 等技术，能全面支持大数据的抽取、清洗、存储、分析的需要。

2016年烟草行业提出要主动顺应时代潮流，积极应用现代技术和管理手段，努力提高行业信息化水平。同时提出零售端的提升关键是客户素质的提升，帮助客户提升素质，首先要对客户有全面认知。2017年江西省烟草公司在客户净化方面，要求对全省卷烟零售客户进行统一摸底、梳理、识别、判定、归类、建档，实行“大户统管服计划、中户培养计划、小户覆盖计划”，精准识别零售客户的经营商圈、经营特点、经营能力及其对行业和特定品牌忠诚度等，并建立客户动态管理机制。

因此，设计和开发在大数据环境下可以精准识别卷烟零售客户，并对卷烟零售客户进行动态管理的信息系统是非常有必要的。将大数据平台 Hadoop 应用于江西卷烟零售户画像，可以为解决零售户画像涉及的大数据处理提供帮助，具有重要的研究意义和实际应用价值。

1.2 现状研究

交互设计领域是最开始使用用户画像的，交互设计大师 Alan Cooper 认为用户画像是根据用户内在属性、外在属性、日常习性等信息，提炼出的一个用

户特征集。用户画像就是将现实对象用数据抽象出来，通过数据进行特征描述的一种行为。目前国内外对用户画像的研究都是从画像构建过程和画像的应用场景两方面进行。

国内外研究者一般认为构建用户画像过程的核心工作是给用户贴“标签”。标签是一种经过高度总结的特征标识。当今的信息数据呈 ZB 级增长，信息越多，使用越难。不能与业务含义发生联系的数据只是数字，没有实际意义，也难以被有效使用。用一句话来概述这些数据的含义，就是标签赋予了数据活力。

国内外对用户画像应用研究主要集中在产品设计、运营、分析，智能推荐，精准营销，风险控制等场景中。在产品设计过程中，根据用户画像设计产品，可以避免产品设计和生产的盲目性，降低设计失误和投入风险。在产品分析领域，对自有产品和竞争产品的客户群进行特征分析，做到心中有数。应用在智能推荐上，通过对用户特征画像，实行用户分类，给分类用户精准推荐产品。在精准营销领域，通过用户画像制定营销策略来降低成本，提高效率。在风险控制领域，通过用户画像对人进行全面描述、精准分析、有效预测，提高风险控制能力。其中，精准营销是用户画像在营销领域最重要的应用。

用户画像在互联网行业广为应用，以国内的腾讯、京东两家企业以及国外的亚马逊、eBay 两家企业的用户画像实践为例，四家企业均十分重视用户画像在产品运营和用户运营领域的应用，从典型应用场景看，产品运营方面以产品精准营销为主线，包括产品推广、个性化推介以及营销渠道分析等细分环节。用户运营方面以用户群的精准识别和特征分类为重点。

1.3 研究内容

本文主要以江西烟草零售户画像管理为研究对象，根据零售户的相关数据，分析并建立零售户的画像模型和综合评价模型，对零售户进行客户画像。设计并开发一套江西卷烟零售户画像信息系统，可以在大数据环境下对零售户进行特征画像，用于精准识别卷烟零售客户，进行零售户的动态分类管理。根据零售户的画像信息，制定不同的营销策略，来提升江西烟草公司的精准营销能力。包括以下研究内容：

- 1) 卷烟零售户画像的理论模型和主要技术分析。
- 2) 基于数据挖掘和综合评价的卷烟零售户画像建模和分析。

- 3) 基于 Hadoop 的江西卷烟零售户画像系统的设计与现实。
- 4) 零售户画像系统的应用和效果分析。

1.4 论文组织结构

本文共有六个章节，各章节组织结构如下：

第1章：引言。阐述本课题的研究背景、意义、现状及内容，编制本课题的组织结构。

第2章：卷烟零售户画像的相关理论。概述性的介绍零售户画像的相关理论和方法技术。

第3章：卷烟零售户画像的分析。阐述零售户画像的业务背景，分析并建立画像模型，对画像系统的功能需求进行分析。

第4章：卷烟零售户画像系统设计。从总体设计、详细设计方面描绘画像系统的设计内容。

第5章：卷烟零售户画像系统实现。介绍画像系统开发的技术及过程，对系统进行测试，并对系统的应用情况及效果进行分析。

第6章：结论与展望。总结全文所做的主要研究工作，提出零售户画像的未来研究方向。

第2章 卷烟零售户画像的相关理论

2.1 客户细分理论

美国学者 Wendell.Smith 最早提出基于客户差别需求的客户细分理论。具体来说,不同类型的客户其需求的有所不同,以客户决策的影响因素为研究对象,将客户划分成不同类别,企业为不同类别的客户,提供不同类型的服务。

不同企业,会根据其企业特性,选择适合企业本身的客户细分方法。一般会采用定性、定量的分析方法来进行客户细分。定性分析主要依赖于分析人的水平,水平不足容易出现偏差。定量分析是以客户数据为依据,运用分析技术进行客户分类的方法。客户细分的分类方法主要有基于客户特征的细分、基于客户价值的细分和基于客户行为的细分。

(1) 基于客户特征的细分

客户特征的选取,经常从客户的内在特征和外在特征两个方面进行,内在特征如性别、年龄段、收入高低等。外在特征如所属地域,社会关系,人文环境等。其优点在于数据易于收集,分类含义易于理解,其缺点是难以判断客户的好坏,预测客户的行为。

(2) 基于客户价值的细分

需要建立一套客户价值指标体系,通过指标来计算客户的价值,根据客户的价值高低进行客户细分。客户价值的计算可以从当前价值和未来价值两个方面来考虑。当前价值有直接的和间接的,而未来价值往往考虑客户的未来成长性和对企业的忠诚度。

(3) 基于客户行为的细分

是一种基于动态数据分析的分类方法,是依据客户的历史行为数据来预测将来的行为,这种客户分类往往更加准确、更有价值。

2.2 客户画像理论

在交互设计领域,通常将用户画像定义为针对产品服务目标群真实特征的

勾画，是一种将目标客户、客户需求与产品设计进行有效连接的工具，借助用户画像，设计师将头脑中的主观想象转化为目标用户的特征，从而设计出产品原型。这些年，互联网行业的发展一日千里，但在产品运营中存在用户定位不精准、个性化服务不到位的问题，为解决这些问题，互联网企业引入用户画像作为用户行为的一种分析，通过对用户打标签、建立数据模型来解读所有用户的特征。在互联网用户行为分析领域，通过收集与分析用户的相关提炼出一个用户群的特征全貌。这不仅能帮助企业全方位、多角度地了解用户特征，还可以帮助企业对不同的用户群分别开展有针对性的设计、营销、服务等。从交互设计转向用户行为分析，用户画像的定义与应用一直在变化。在互联网应用领域，用户画像主要指以真实用户为研究对象，以用户的静态属性数据和动态行为数据为基础，通过定性或定量方法提炼抽象出的具有显著特征的用户模型。

鉴于用户画像的领域不同，画像的思路和方法有所差别，典型的用户画像思路可以归结为四类画像视角，分别是基于虚构的视角，基于目标导向的视角，基于角色的视角，基于参与的视角。而其中基于参与视角的用户画像中常用的方法是数据—用户标签映射法，这也是目前互联网业界较为流行的用户画像方法之一。数据—用户标签映射法是典型的数据驱动用户画像，首先采集用户的静态属性，诸如自身特征、社会特征、位置特征等数据和动态属性，诸如行为特征、偏好特征、社交特征等数据，然后通过一定数据挖掘算法或者人工分析将其转化为用户的标签信息，并进一步应用数据可视化技术，发挥画像人员一定的想象力，最终完成用户画像。对于用户标签树的定义，常常采用层次分析法来定义。另外，数据—用户标签映射法的优点是以海量的用户真实数据为基础，以大数据分析和可视化技术为手段来实现的，因此画像效率更高，特征内容更加准确。

2.3 层次分析法

层次分析（Analytic Hierarchy Process，简记 AHP）法是一种定性和定量分析相结合，研究复杂决策问题的方法之一。它将决策者的经验判断量化成数字，将思考问题的过程层次化，逐层比较，逐层验真，由此产生的结果较有说服力的，易于理解和接受。因此，它广泛应用于决策领域。层次分析法的基本步骤如图所示。




图 2.1 层次分析法过程图

2.4 数据挖掘技术

数据挖掘要处理的数据量往往非常大，要从这些低密度的、有噪声的信息里挖掘出有价值的信息，必须运用一定的挖掘算法和工具，对源数据进行相应的筛选，清洗成统一的格式，之后进行数据挖掘与分析，然后根据挖掘的数据特征做出判断，分析解释其中有价值信息的含义，为用户的决策和管理提供数据支撑。数据挖掘的工具和算法很多，处理方式也不相同。其中，贝叶斯分类算法和 K-means 聚类算法是两种常用的数据挖掘算法。数据挖掘主要过程如图所示。




图 2.2 数据挖掘过程图

2.5 客户关系管理

客户关系管理（简称 CRM），是一种用来管理企业与客户关系的管理方式。企业要以客户为关注焦点，按照客户类型的不同，分配不同的企业资源，来提高企业收入，提升客户满意度。Gartner 公司阐述了客户关系管理理论和客户关系管理系统的组成，逐渐形成了 CRM 系统，并在之后应用到电子商务领域，客户关系管理的理念是实现对客户最大价值的开发及挖掘，对忠诚客户投放更多资源，积极发展新客户的同时兼顾老客户的想法，建立完整的客户档案。

客户细分是客户关系管理的一种手段，是企业制定不同的客户营销策略的依据。而客户画像是在客户细分的基础上进行发展而来的，通过客户特征的全面刻画，完整的认识客户，再结合大数据的客户分类，为管理决策和销售策略的制定提供的强有力数据支撑。

所以，依据客户的相关数据信息，建立有效的客户画像，对客户进行全面的识别，从而实现高效的零售户管理与服务，是企业高效创新发展的管理新思路。

第3章 卷烟零售户画像的分析

3.1 卷烟零售业务概况

我国实行烟草专卖管理制度，有相应的法律进行了约束。烟草公司的卷烟销售既有市场经济性质又有计划经济性质，卷烟销售量并不是越多越好，而是按照国家宏观调控，确定一个销售任务，完成该任务即可。卷烟的购进价和销售价由国家烟草局规定，省局是不能改变的。中烟工业不会因为烟草公司购进的卷烟多，就给它打折。烟草公司也不会因为零售户购进的多，就给它打折，这是计划经济的方面。另外，市场经济方面，烟草公司需要根据零售户订购卷烟的情况，感知消费市场上卷烟销售的情况。烟草公司需要根据市场情况挑选并购进合适品规的卷烟，制定合适的卷烟投放计划，指导并帮助零售户购进合适的卷烟品规和数量，实现销售的快速周转，减少货物积压，帮助零售户实现盈利。烟草公司在整个卷烟销售过程中，完成卷烟销量目标，实现卷烟税利目标，保证了国家的财政收入。

零售户开展卷烟经营销售，首先需要办理零售许可证，由烟草专卖部门进行审查批准发送。零售户申请到零售许可证后，进入卷烟购进环节。一般，零售户需要签订银行代扣协议，可由烟草公司从指定银行卡中划拨卷烟结算资金。接着，烟草公司销售部门为零售户分配片区、线路，指定订货日，开通新商盟订烟系统的账号。这些手续完成后，客户就可以在订货日查看可订购的卷烟信息，然后决定买入那些卷烟品牌规格，可以通过系统自助下单，也可以委托给烟草电访员下单，烟草公司营销部门对订单进行确认后，订单不可修改。订单传递给烟草公司物流部门进行卷烟配送、货款结算。零售户收到订购的卷烟后进行零售销售。卷烟零售业务流程如图所示。




图 3.1 卷烟零售业务流程图

除了提供卷烟订购服务外，烟草公司还为零售户提供客户拜访服务，了解零售户的需求，为零售户订烟提供建议，为零售户送烟到户。通过分析烟草公司的卷烟销售业务流程和经营目标，发现同一种品规卷烟的价差是固定的，那么烟草公司购进合适卷烟品规及数量就是完成经营目标的关键。而烟草公司的目标需要零售户来完成，如果烟草公司能满足零售户的需求，那么目标容易完成；如果烟草公司不能满足零售户的需求，就可能造成零售户从其他非正规渠道购进卷烟，甚至购进销售假烟，损害消费者的权益，搅乱卷烟市场，影响卷烟市场健康持续发展。那么零售户的覆盖面，零售户的忠诚度，零售户的购进量和购进结构，零售户的订烟频率，零售户的结算方式都是影响烟草公司经营目标达成的关键因素。

（1）零售户的覆盖面

零售户是烟草公司最主要的外部资源，只有保证合理数量的零售户才能让零售户的经营辐射范围覆盖到全省。一旦某些区域的零售户不够，可能造成部分市场的丢失，影响经营目标的达成。同时还可能让这些区域成为假、私、非烟的集中地。同时，某些区域的零售户过多，可能会造成过度竞争，库存积压，卷烟降价销售的情况，从而减少订购，或者乱渠道销售卷烟，也会影响经营目

标的达成。因此零售户的合理分布，既使零售户的经营辐射范围覆盖到全省，又使零售户辐射区域的交叉最小，才是对烟草公司最有利的。

（2）零售户的忠诚度

零售户的忠诚主要体现在从指定的渠道购入正规的卷烟进行销售，不销售“假、私、非”的卷烟，长期经营卷烟零售业务，持续为烟草企业带来贡献。

（3）零售户的购进量和购进结构

零售户的购进量越大，单条均价越高，其购进的总金额就会越大，一般来说这种情况对烟草公司的贡献就越大。但是这并不是绝对的，过快的提高卷烟价格，若不能与当前社会消费水平相适应，会造成吸烟人数的急剧下降，损害的是卷烟销售的长期市场。零售户的购进量应以稳定为主，购进结构组成应合理，高、中、低档烟都有合适的配比，使单条均价在一个合理的区间。

（4）零售户的订烟频率和结算方式

零售户的订烟频率，一般都是每周可以订一次烟。如果零售户每周按期订烟，订烟数量和结构就会相对稳定，这对于烟草公司的消费者市场预测是有利，同时卷烟送货的压力相对稳定，不会出现大的波动。零售户选择合适的结算方式，比如电子结算，对烟草公司也是有利的。大量的现金结算，如何保障结算资金的安全，会是烟草公司的一种困扰。在电子结算如此发达的今天，是否使用电子结算，体现的是零售户对烟草公司工作的配合度和支持度。

3.2 卷烟零售户画像分析

3.2.1 零售户画像概述

目前，零售户的相关信息分布在营销、专卖、物流、资金结算、信息采集等系统中，零售户信息的展现也只存在于不同的信息系统，没有对零售户属性信息、行为信息的统一展现，更缺少对零售户信息的提炼。零售户画像，是一个综合领域，全方位、立体刻画客户形象，不仅要考虑客户基本属性、经营行为，还要考虑零售户的内在特点、外在环境等影响要素。零售户在各业务系统存在的静态属性信息，去除重复属性，有 156 项，动态行为属性有 376 项，而且动态行为属性信息根据分析的要求不同，还在不断产生新的维度分析项。零售户信息项的重要程度不一样，客户画像就是要在这些信息项中提炼出关键的

特征信息，通过这些特征信息就对零售户有一个全面的了解，并且可以将具有相同或相似特征信息的零售户划为一类，执行相同的货源供应策略，客户服务策略，市场监管策略等。通过零售户画像，来提升烟草公司客户关系管理的能力，从而提升烟草公司整体的管理水平。

3.2.2 数据标签映射法

数据标签映射法是典型的数据驱动用户画像，客户画像可以看成是关于客户的知识生成、分享过程，便于各层次员工提高特定客户的认知能力。从这个角度看，可以将客户已有基础数据、经营行为等结构化数据进行加工生成特定信息，还可以记录、整理包括全体员工、消费者对客户感性认知方面的数据。

（1）数据标签映射法的客户画像目的

直观、快速、立体地反映客户全貌。与数据查询分析功能根本区别是，用户不需要通过各个命令操作，分别查询需要了解的客户不同情况，而是通过图文方式进行直观结果呈现，屏蔽掉大数据加工分析过程。

（2）数据标签映射法的客户画像方法

给零售户贴标签，就要分析出零售户标签化应用的不同场景，本文主要从考核评价、货源投放、客户服务、精准查案等场景来提炼数据指标，应用大数据技术对指标数据进行分类、聚类算法操作，根据分类、聚类算法的结果，应用通俗易懂的文字给该零售户贴标签，进行客户画像。

（3）数据标签映射法的客户画像流程

首先进行零售户相关数据的采集，包括静态属性和动态属性。第二、对零售户的采集数据进行清洗，经过分类、聚类算法计算，形成用户标签信息。第三、根据应用场景，建立相应的用户画像模型。第四、将用户画像结果数据呈现给用户。流程如图所示：




图 3.2 数据标签映射法构建用户画像过程图

3.3 卷烟零售户画像建模

3.3.1 用户标签树概述

标签树是通过建立不同类别、类别的客户标签，并通过标签组合给出关于客户认知的信息。按照看问题角度不同，客户标签体系可以看作是一个森林系统，每个问题可以看作一棵树。为此，客户画像要结合特定应用场景，组合不同的标签“树”或标签“叶”。

零售户标签按层级关系可分为根标签、枝标签、叶标签。

（1）叶标签：叶标签主要是指某种客户属性，用来表述客户某一方面特征的指标，是客户基础数据中最小粒度且无法分解的、彼此没有交叉和重复的数据。

（2）枝标签：由零售户的一个或者多个叶标签组成的上级标签，用来表述客户某一汇总方面特征的指标。

（3）根标签：是一个标签库的根节点，用来表述零售户在某一场景下的综合评述。

零售户标签按标签类别可分为静态标签、动态标签、组合标签。

(1) 静态标签：静态标签由客户一个或多个属性描述而成，是对客户某种相对稳定的特征的描述。

(2) 动态标签：动态标签根据记录的客户订货、客户经营等行为数据加工分析形成，是对一定时期内客户经营动态的特征描述，是变化的客户行为知识。

(3) 组合标签：组合标签是某些属性标签、行为标签的组合，通过某方面的标签体系的定义，数据来源定义，计算模型定义，计算评价得出的一种综合性标签。

3.3.2 客户画像建模

本文采取德尔菲法进行定性分析，构造特定场景下的客户画像模型。首先挑选优秀一线员工，业务骨干，公司管理层，第三方专家共计 20 人组成专家小组。就客户服务，品规营销、市场监管三个业务应用场景，发送 3 份电子调查问卷给专家小组成员，进行开放式的首轮调研，由专家小组成员分别针对 3 个业务应用场景下，需关注哪些零售户标签进行回答。对每个业务场景下，专家在首轮调研中回答的关注零售户标签进行整理，开始第二轮调研，由专家对每个业务场景下关注的零售户标签列表进行选择。将超过 2/3 专家选择的零售户标签列表进行整理，开始第三轮调研，由专家进行标签选择。经过 3 轮调研，最终每个业务场景保留超过 2/3 专家选择的零售户标签作为该业务场景下零售户的画像信息。具体如下表：

表 3.1 零售户画像标签表

	一级标签	二级标签	三级标签
客户服务场景下的零售户画像	基础信息标签	许可证号，企业(字号)名称，负责人(经营者)姓名，经营场所，负责人联系电话	
	贡献度	贡献特征	总量，次均价，省产烟占比
		增长特征	总量同比，次均价同比，省产烟占比同比
	配合度	终端店铺特征	终端性质，硬件设施，日常维护，卷烟上柜率，终端扫码销售率
		品牌培育特征	新品订购率，重点品牌订购

第3章 卷烟零售户画像的分析

			率, 各价类订购率
		订货特征	网上订购率, 订货周期
		结算特征	电子结算率
		信息采集特征	价格采集率, 库存采集率
品规营销场景下零售户画像	基础信息标签	许可证号, 企业(字号)名称, 负责人(经营者)姓名, 经营场所, 负责人联系电话	
	成长度	经营者特征	性别、学历、经营卷烟时间、吸烟情况、信息化技能
		市场特征	市场类型, 商圈类型, 商圈成熟度, 周边消费能力, 辐射人口数
		管理特征	客户经理、市管员、送货员
		增长特征	总量同比, 次均价同比, 省产烟占比同比
		盈利特征	市场毛利率, 存销比, 年度回报率
		经营偏好特征	品类偏好, 品规宽度, 订货面, 需求满足率, 订足率
	配合度	终端店铺特征	终端性质, 硬件设施, 日常维护, 卷烟上柜率, 终端扫码销售率
		品牌培育特征	新品订购率, 重点品牌订购率, 各价类订购率
		订货特征	网上订购率, 订货周期
		结算特征	电子结算率
		信息采集特征	价格采集率, 库存采集率
市场监管场景下零售户画像	基础信息标签	许可证号, 企业(字号)名称, 负责人(经营者)姓名, 经营场所, 负责人联系电话	
	规范度	违法特征	案件数量, 案件金额
		违规特征	违规次数, 违规扣分
		盈利特征	市场毛利率, 存销比, 年度回报率
		增长特征	总量同比, 次均价同比, 省产烟占比同比

3.4 零售户分类综合评价建模

为便于对零售户进行分类管理，有必要设计一套规则用于计算每户零售户的综合得分，本次研究采用德尔菲法进行定性分析后，应用层次分析法来对零售户综合评价进行定量分析。首先邀请江西省烟草公司，江西省中烟工业公司，市级烟草公司等单位 13 位专家组成专家小组，采用调查问卷的方式由专家小组成员对我们系统标签库中的指标进行选定。按照既全面评价卷烟零售户，又要利于评价工作开展，确定了以市场净化为目的的零售户综合评价为目标层，以贡献度、成长度、配合度、规范度四个指标作为准则层，以订购总量、订购条均价、省产烟占比、网上订购率、电子结算率、扫码销售率、需求满足率、品规宽度、违法风险度、违规风险度十个指标作为方案层的综合评价体系。

(1) 层次结构的建立

根据确定的 10 个指标划分层次结构，如图所示。



图 3.3 零售户综合评价指标分解图

(2) 构造判断矩阵

设目标层 A 为“零售户综合评价”，准则层 B 为 $u = \{u_1, u_2, u_3, u_4\}$ 的集合，本次调查二级评价指标有 4 个，即 u_1 为“贡献度”， u_2 为“配合度”， u_3 为“成长度”， u_4 为“规范度”。

本研究向全省烟草系统内 7 名业务专家发出了意见征询表,对指标的相对重要程度进行评价,根据每位专家的打分,各项取平均值,形成总表,构造判断矩阵。专家打分依据下表所示。

表 3.2 专家打分依据表

标度值	打分依据
1	若因素 A 与因素 B 比较,同等重要,得 1 分。
2	表示因素 A 与因素 B 比较,因素 A 的重要程度位于上下之间,得 2 分
3	若因素 A 与因素 B 比较,因素 A 稍微的重要,得 3 分。
4	表示因素 A 与因素 B 比较,因素 A 的重要程度位于上下之间,得 4 分
5	若因素 A 与因素 B 比较,因素 A 较明显的重要,得 5 分。
6	表示因素 A 与因素 B 比较,因素 A 的重要程度位于上下之间,得 6 分
7	若因素 A 与因素 B 比较,因素 A 明显的重要,得 7 分。
8	表示因素 A 与因素 B 比较,因素 A 的重要程度位于上下之间,得 8 分
9	若因素 A 与因素 B 比较,因素 A 极端的重要,得 9 分。

若因素 A 与因素 B 比较的得分 C,则因素 B 与因素 A 比较的得分是 $1/C$ 。

零售户综合评价(A)专家打分表如表所示。

表 3.3 零售户综合评价(A)专家打分表

	贡献度(B1)	配合度(B2)	成长度(B3)	配合度(B4)
贡献度(B1)	1	2	3	5
配合度(B2)	1/2	1	2	3
成长度(B3)	1/3	1/2	1	2
配合度(B4)	1/5	1/3	1/2	1

贡献度(B1)专家打分表如表所示。

表 3.4 配合度(B1)专家打分表

标度值	订购总量(C1)	订购条均价(C2)	省产烟占比(C3)
订购总量(C1)	1	2	6
订购条均价(C2)	1/2	1	4
省产烟占比(C3)	1/6	1/4	1

配合度(B2)专家打分表如表所示。

表 3.5 配合度(B2)专家打分表

	网上订购率(C4)	电子结算率(C5)	扫码销售率(C6)
网上订购率(C4)	1	2	6
电子结算率(C5)	1/2	1	4
扫码销售率(C6)	1/6	1/4	1

成长度(B3)专家打分表如表所示。

表 3.6 成长度(B3)专家打分表

	需求满足率(C7)	品规宽度(C8)
需求满足率(C7)	1	4
品规宽度(C8)	1/4	1

规范度(B4)专家打分表如表所示。

表 3.7 规范度(B4)专家打分表

	违法风险度(C9)	违规风险度(C10)
违法风险度(C9)	1	2
违规风险度(C10)	1/2	1

(3) 层次单排序和一致性检验

层次单排序的目的就是求出同一层次的每个指标的权重，然后排序。本文采用其中的和积法，以零售户综合评价(A)专家打分表形成的判断矩阵A为例进行计算，具体步骤如下：

$$A = \begin{bmatrix} 1 & 2 & 3 & 5 \\ 1/2 & 1 & 2 & 3 \\ 1/3 & 1/2 & 1 & 2 \\ 1/5 & 1/3 & 1/2 & 1 \end{bmatrix} \quad (3.1)$$

第一步:矩阵归一化处理，得新矩阵 Q：

$$Q = \begin{bmatrix} 0.491803279 & 0.52173913 & 0.461538462 & 0.454545455 \\ 0.245901639 & 0.245901639 & 0.307692308 & 0.272727273 \\ 0.163934426 & 0.130434783 & 0.153846154 & 0.181818182 \\ 0.098360656 & 0.086956522 & 0.076923077 & 0.090909091 \end{bmatrix} \quad (3.2)$$

第二步：求向量。

将 Q 的每一列元素按行相加，其计算结果为向量 β ：

$$\beta = (1.93 \ 1.09 \ 0.63 \ 0.35)^T$$

第三步：求特征向量。

将 β 作正规化处理，得到特征向量 a 即为同一层次各评价指标的权重。

$$a = (0.48 \ 0.27 \ 0.16 \ 0.09)^T$$

第四步：求判断矩阵的最大特征根：

$$\lambda_{\max}=4.015$$

第五步：一致性检验。

判断矩阵是由专家对评价指标两两比较打分产生的，专家也是人，也可能对评价指标的重要程度判断产生偏差。对判断矩阵进行一致性检验，这就是检验专家的判断是否合理。检验公式为：

$$CI = (\lambda_{\max} - m) / (m - 1) \quad (3.3)$$

$$CR = CI / RI \quad (3.4)$$

式 3.3 中， CI 为判断矩阵一致性指标， $\lambda_{\max}=4.015$ ， $m=4$ ，即可计算出 $CI=0.005$ 。

式 3.4 中： CR 为判断矩阵的随机一致性比率， RI 为判断矩阵的平均随机一致性指标，查表可知 4 阶的 $RI=0.9$ 。即可计算出 $CR=0.006$ 。查表可知 4 阶矩阵的 $CR < 0.1$ 时，即认为判断矩阵具有满意的一致性，说明专家打的分是合理的，否则就需要重新打分，再次计算。

同样方法可求出其余判断矩阵是否具有满意的一致性，计算过程略。其中表 3.4 判断矩阵： $\lambda_{\max}=3.009$ ；表 3.5 判断矩阵： $\lambda_{\max}=3.009$ ；表 3.6 判断矩阵： $\lambda_{\max}=2$ ；表 3.7 判断矩阵： $\lambda_{\max}=2$ 。

(4) 层次总排序

层次总排序的目的就是求出任意一个指标对总目标的相对权重，然后排序。层次总排序需要从上到下逐层分解，得到每个指标针对总目标的权重。各指标最终权重如表所示。

表 3.8 各指标最终权重表

	贡献度 (B1)	配合度 (B2)	成长度 (B3)	规范度 (B4)	最终权重
C 层总计	0.48	0.27	0.16	0.09	
C1	0.59				0.2832
C2	0.32				0.1536
C3	0.09				0.0432
C4		0.59			0.1593
C5		0.32			0.0864
C6		0.09			0.0243
C7			0.8		0.128
C8			0.2		0.032
C9				0.67	0.0603
C10				0.33	0.0297

(5) 各指标定义及评价规则

方案层的指标,按指标定义计算出一定周期内的指标值,周期设计为月度、年度。以地市为计算单元,将全市的零售户指标值进行 k-means 聚类分析,分为 5 类。根据聚类中心点的大小,从小到大或者从大到小将类别分成 5 类。每类得分=20*类别数。准则层和目标层的得分由下层指标得分*权重汇集而成。准则层和目标层可通过 k-means 聚类分析上层指标得分,将其再分为 5 类,作为零售户该指标的画像标签值。方案层指标定义及评价规则如表所示。

表 3.9 指标定义及评价规则表

指标代号	指标名称	指标定义	分类规则	评价规则
C1	订购总量	订购的卷烟总量	K-means 聚类分析,分成 5 类	按聚类中心点的大小从小到大分为 5 类:1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分
C2	订购条均价	订购的卷烟总额/订购总量	K-means 聚类分析,分成 5 类	按聚类中心点的大小从小到大分为 5 类:1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分
C3	省产烟占比	一个时间周期内零售户订购省产烟总量/订购总量	K-means 聚类分析,分成 5 类	按聚类中心点的大小从小到大分为 5 类:1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分
C4	网上订购率	网上订购次数/应订购次数	K-means 聚类分析,分成 5 类	按聚类中心点的大小从小到大分为 5 类:1 类 20 分;

			类	2类 40分; 3类 60分; 4类 80分; 5类 100分
C5	电子结算率	电子结算次数/ 订货次数	K-means 聚类 分析, 分成 5 类	按聚类中心点的大小从小 到大分为 5 类: 1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分
C6	扫码销售率	扫码销售的卷 烟量/订购总 量	K-means 聚类 分析, 分成 5 类	按聚类中心点的大小从小 到大分为 5 类: 1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分
C7	需求满足率	实际订单量/ 需求量	K-means 聚类 分析, 分成 5 类	按聚类中心点的大小从小 到大分为 5 类: 1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分
C8	品规宽度	订购的品规/ 全市在销品规	K-means 聚类 分析, 分成 5 类	按聚类中心点的大小从小 到大分为 5 类: 1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分
C9	违法风险度	朴素贝叶斯算 法预测出现违 法的概率	K-means 聚类 分析, 分成 5 类	按聚类中心点的大小从大 到小分为 5 类: 1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分
C10	违规风险度	朴素贝叶斯算 法预测出现违 规的概率	K-means 聚类 分析, 分成 5 类	按聚类中心点的大小从大 到小分为 5 类: 1 类 20 分; 2 类 40 分; 3 类 60 分; 4 类 80 分; 5 类 100 分

3.5 系统功能需求分析

基于 Hadoop 的零售户画像系统利用 Hadoop 大数据平台及其生态圈的数据挖掘技术, 对烟草公司内部各业务系统中的零售户相关信息进行大数据挖掘, 分析各种数据之间的关联性, 从零售户对公司的贡献度、潜力度、配合度、忠诚度等方面, 将零售户划分为不同的群体, 并给这些群体的零售户定义相应的标签, 作为该零售户的画像。针对不同画像标签的零售户, 提供精准的货源供应和客户服务, 为烟草公司的决策提供量化的信息和标签数据。基于 Hadoop 的江西烟草零售户画像系统的总体需求描述如下:

- (1) 系统支持基于 RBAC 模型的用户权限管理。
- (2) 建立统一的大数据平台，将江西烟草各业务系统中的相关数据抽取出来，经过数据清洗、格式转换等操作，为大数据挖掘和分析提供数据支持。
- (3) 建立零售户相关指标库，运用大数据技术按对零售户进行特征细分，并对分类结果进行判定并标签化，形成零售户的完整画像。
- (4) 具备业务数据信息的查询功能。能对画像过程中产生的指标数据提供查询功能，能对单个指标提供历史数据查询功能。
- (5) 提供零售户画像特征分类信息的查询统计功能。

3.5.1 零售户管理

零售户管理实现对零售户信息的全面登记和管理，包括零售户信息的增删改查统、明细查询、按条件过滤查询、按指定方式统计等功能。零售户信息主要来源于烟草专卖和营销系统，从专销系统抽取零售户的基本信息到本系统，基本信息不可修改，而对于零售户的终端、负责人、商圈、管理者信息等扩展信息，由客户经理进行维护。零售户管理模块的用例如图所示。




图 3.3 零售户管理用例图

零售户管理模块的需求描述如表所示。

表 3.10 零售户管理需求

模块名称	需求描述
零售户管理	每日从专卖系统读取零售客户基础信息,包括企业类型(组成形式),许可证号,企业(字号)名称,负责人(经营者)姓名,经营场所,地理坐标,供货单位,发证单位,有效期限等信息。该信息仅能查询,不能修改。
终端信息管理	终端信息为零售户基本信息的扩展信息,包括该零售店是否连锁店,是否困难户,是否夜店,经营业态,经营规模等信息。终端信息管理功能包括增删改查统等操作。
负责人信息管理	负责人信息为零售户基本信息的扩展信息,包括该零售店负责人的出生日期,性别,身份证号,文化程度,经营卷烟销售开始年月,电脑技能,智能手机技能,智能手机类型,吸烟情况,联系方式等信息。管理功能包括负责人信息的增删改查统等操作。
商圈信息管理	商圈信息为零售户基本信息的扩展信息,包括该零售户店所处的市场类型,商圈类型,商圈成熟度,商圈消费能力等信息。管理功能包括增删改查统等操作。
管理人信息管理	管理人信息为零售户基本信息的扩展信息,包括烟草公司安排管理、服务该零售户的客户经理的姓名、电话、手机运营商,市管员的姓名、电话、手机运营商,送货员的姓名、电话、手机运营商等信息。管理功能包括增删改查统等操作。
零售户查询	系统提供多种查询方式,包括关键字查询、模糊查询、组合查询等查询零售户的相关信息。

3.5.2 标签库管理

标签库管理实现对客户画像标签的全面定义和管理,由系统管理员进行管理。包括标签类型管理、标签定义管理、指标计算、标签查询,其中,标签类型定义,比如静态标签、动态标签、综合评价标签等。标签定义一般包含定义,名称,内容,评价标准,特征值五个方面的内容。指标计算是对零售户相关的

指标进行计算，根据指标值与评价标准，确定该零售户的特征值。标签库管理模块的用例如图所示。




图 3.4 标签库管理用例图

标签库管理模块的需求描述如表所示。

表 3.11 标签库管理需求

模块名称	需求描述
标签类型管理	标签类型一般包括类型编码、类型名称，上级节点，是否有效等。管理功能包括增删改查统等操作。
标签定义管理	标签信息包含定义、名称、内容、评价标准、特征值等信息。标签值是预定义好的枚举值。管理功能包括增删改查统等操作。
指标计算	根据每项标签中标签评价标准，计算出指标值，将指标值与评价标准对比，确定每户零售户该项标签上的标签值。
标签查询	系统提供多种查询方式查询标签的相关信息。

3.5.3 零售户分类管理

零售户分类管理是实现基于业务场景的零售户分类。以客户服务、精准营销、精准查案等业务场景为目标，将零售户进行分类。江西烟草全面开展客户

净化工作，提出从客户的贡献度、配合度、成长度和规范度等方面进行综合评价，将全省统一将现有有效零售客户划分为“核心忠诚客户、忠诚客户、一般客户和风险客户”4个类别。零售户分类管理包括系统管理员构建综合评价树、定义分类算法，大数据平台根据分类算法定义自动计算出各级指标的分类及零售户综合评价分类。用户可通过该系统查询零售户分类数据，按零售户分类进行数据统计。零售户分类管理模块的用例如图所示。




图 3.5 零售户分类管理用例图

零售户分类管理模块的需求描述如表所示。

表 3.12 零售户分类管理需求

模块名称	需求描述
构建综合评价树	选择指标构建评价树，管理功能包括增删改查等操作
定义分类算法	为每个指标定义分类算法，对分类算法的参数进行维护
计算零售户分类	大数据平台根据定义的分类算法自动计算出各级指标的分类
零售户分类查询	系统提供多种查询方式查询零售户分类情况的相关信息。
零售户分类统计	系统提供按时间、空间的基于分类类型的零售户统计功能。

3.5.4 数据管理

系统顶层数据走向是从江西烟草各业务系统中抽取零售户相关数据，经过清洗整理后统一存储到大数据平台，然后对零售户数据进行挖掘和画像分析，最后将零售户画像数据集存储到MySQL中，再从MySQL中查找零售户画像数据以文字、图表等形式呈现给用户，并提供零售户画像数据接口给第三方系统。系统顶层数据流如图所示。




图 3.6 系统顶层数据流图

数据管理模块的用例如图所示。




图 3.7 数据管理用例图

数据管理需求描述如表所示。

表 3.13 数据管理需求

模块名称	需求描述
数据抽取	数据抽取管理包括数据抽取内容管理，数据抽取源管理，自动数据抽取任务管理，数据抽取日志管理。数据抽取内容管理主要是管理被抽取的数据结构说明。数据抽取源管理主要是管理被抽取的数据集所在的位置，如 IP 地址，端口，用户名和密码等验证信息。自动数据抽取任务管理主要是定义抽取程序段代码，代码标识，抽取时间，间隔频次等信息。数据抽取日志管理主要用来管理抽取日志信息
数据清洗	数据清洗主要通过 Hadoop 中的 MapReduce 来实现清洗逻辑。通过 Linux Shell 脚本实现清洗任务管理，通过 MySQL 数据库库保存清洗日志数据。
数据挖掘	数据挖掘管理包括挖掘算法、挖掘执行，挖

	掘日志管理。数据挖掘主要通过 Hadoop 中的 Mahout 来实现 K-means 聚类算法、朴素贝叶斯算法。通过 Linux Shell 脚本实现挖掘任务管理，通过 MySQL 数据库库保存挖掘日志数据。
数据入库	目标数据源管理包括数据源的增删改查等功能，数据入库规则管理用来定义 HDFS 中的数据格式。数据入库任务管理主要通过 Linux Shell 脚本实现数据从 HDFS 中保存到 Hive、HBASE、MySQL 中。通过 MySQL 数据库库保存入库日志数据。
零售户画像数据	以数据视图的方式提供零售户画像数据接口

3.5.5 系统管理

系统管理功能主要提供对参数、用户、角色、资源权限、机构管理和日志管理功能，该模块主要由信息系统管理员使用。其用例如图所示。




图 3.8 系统管理用例图

第 4 章 卷烟零售户画像系统设计

4.1 设计原则

本文设计的系统主要满足江西烟草公司的零售户画像的业务需求，并考虑零售户相关的数据持续快速增长，系统如何做到稳健。在设计时遵循以下原则：




图 4.1 设计原则

4.2 总体设计

本系统采用分层的架构，共分为三层，分别是展示层、应用层、数据层。层与层的调用采用面向接口的开发，实现高内聚，低耦合的架构思路。其中数据层还包括源数据层，即零售户相关数据来源系统。软件架构如图所示。




图 4.2 系统软件体系架构图

展现层：即系统与用户的交互层。

应用层：即系统的核心处理层。Hadoop 的 MapReduce 和 Mahout 也属于应用层的内容。

数据层：即系统数据的存取层。数据层主要提供基于 Hadoop 平台生态和关系型 MySQL 数据库的数据服务。

4.3 功能模块设计

系统的功能分为五个模块，分别是零售户管理、标签库管理、零售户分类管理、数据管理和系统管理。如图所示。




图 4.3 系统功能模块图

4.3.1 零售户管理

零售户管理包括基本信息管理，终端、负责人、商圈、管理人等管理，查询统计等功能。基本信息管理实现对零售户基本信息的查看。由于基本信息是零售许可证件信息，证件已经发放给零售户，此信息不可修改，需要换证。模块的功能类如图所示。




图 4.4 零售户管理功能类图

零售户管理模块功能类图主要包括基本信息管理类 CustBaseManage，终端信息管理类 CustZdManage，商圈信息管理类 CustSqManage，负责人信息管理类 CustMpManage 和管理人信息管理类 CustGpManage。其中，基本信息管理类是基类，其他类继续该类，主要包括零售户信息的增删改查统等操作功能。

4.3.2 标签库管理

标签库管理包括类型管理、定义管理、指标计算、查询等功能。标签库管

理模块的功能类如图所示。




图 4.5 标签库管理功能类图

标签库管理模块功能类图主要包括标签类型管理类 LabelTypeManage，标签信息管理类 LabelManage，标签库管理类 LabelLabManage，简单标签评价计算管理类 SingleCalculate 和复杂标签评价计算管理类 ComplexCalculate。主要包括标签信息的增删改查统及评价计算等操作功能。

4.3.3 零售户分类管理

零售户分类管理包括挖掘算法管理、指标管理、大数据分析、零售户分类查询和统计等功能。目前分类算法主要以实现综合评价排名分段分类，指标级以 K-means 聚类，朴素贝叶斯分类为主。零售户分类管理模块的功能类如图所示。




图 4.6 零售户分类管理功能类图

零售户分类管理模块功能类图主要包括分类指标管理类 SortLabelManage，算法定义管理类 AlgorithmManage，零售户分类管理类基类 SortManage，综合评价分类管理类 ZhSortManage，贡献度指标分类管理类 GxSortManage，配合度指标分类管理类 PhSortManage，成长度指标分类管理类 CzSortManage，规范度指标分类管理类 GfSortManage。

4.3.4 数据管理

在进行零售户画像分析时，需要大量的数据支持，这些数据包括客户的基本特征、订单、结算、采集、案件等，这些零售户数据存放在不同的业务系统中。因此，需将这些数据收集出来，统一存储，经过预处理后形成数据挖掘所需要的分析数据集。数据管理模块功能类如图所示。




图 4.7 数据管理功能类图

数据管理模块功能类图主要包括数据管理类基础类 **DataManage**，数据抽取管理类 **DataExtractManage**，数据清洗管理类 **DataCleanManage**，数据挖掘管理类 **DataMiningManage**，数据载入管理类 **DataLoadManage**，数据输出管理类 **DataOutputManage**。其中，数据管理基础类负责数据处理的管理，包括数据处理的定义、运行、日志等功能的逻辑处理。数据抽取管理类负责数据抽取过程调度的定义、执行、日志记录等业务的逻辑处理。数据清洗管理类负责数据清洗过程调度的定义、执行、日志记录等业务的逻辑处理。数据挖掘管理类负责数据挖掘过程调度的定义、执行、日志记录等业务的逻辑处理。数据载入管理类负责将数据挖掘结果载入到 HBASE、Hive、MySQL 过程调度的定义、执行、日志记录等业务的逻辑处理。数据数据管理类负责将零售户画像数据以接口的方式输出给第三方系统过程中的定义、执行、日志记录等业务的逻辑处理。

4.3.5 系统管理

系统管理包括系统参数管理、用户管理、角色管理、资源权限管理、组织

机构管理和日志管理等功能。系统管理模块的功能类如图所示。




图 4.8 系统管理功能类图

系统管理模块功能类图主要包括参数管理类 ParaManage，用户管理类 UserManage，角色管理类 RoleManage，权限资源管理类 ResourceManage，组织机构管理类 OrgManage，日志管理类 LogManage。

4.4 主要数据表设计

(1) 零售户基本信息表如表所示。

表 4.1 零售户基本信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
CUST_CODE	零售户许可证号	VARCHAR(60)	主键
CUST_NAME	企业(字号)名称	VARCHAR(60)	
CUST_MANAGER	负责人(经营者)名字	VARCHAR(60)	

CUST_TYPE	企业类型(组成形式)	VARCHAR(60)	
CUST_ADDR	经营场所	VARCHAR(100)	
SALE_SCOPE	许可范围	VARCHAR(30)	
SALE_COM	供货单位	VARCHAR(60)	
LICENCE_START_DATE	许可证有效开始时间	VARCHAR(60)	
LICENCE_END_DATE	许可证到期时间	VARCHAR(60)	
LICENCE_COM	发证机关	VARCHAR(60)	
LICENCE_START_DATE	制证时间	VARCHAR(60)	

零售户基本信息为零售户许可证上的信息。从专卖系统抽取而来,不能改变。

(2) 零售户终端信息表如表所示。

表 4.2 零售户终端信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
CUST_CODE	零售户许可证号	VARCHAR(60)	主键
STATUS	客户经营状态	VARCHAR(30)	
IS_SALE_FM	是否罚没烟专柜	VARCHAR(30)	
SITE_OWNTYPE	经营场所权属	VARCHAR(30)	
BUSI_TYPE	零售户经营业态	VARCHAR(30)	
BUSI_SIZE	经营规模	VARCHAR(30)	
IS_SEFL_CUST	是否直营店	VARCHAR(30)	
TERMINAL_TYPE	终端类型	VARCHAR(30)	
IS_FUNC_CUST	是否功能店	VARCHAR(30)	
P_DIFFICULTY_TYPE	困难户类型	VARCHAR(30)	
P_SPECIAL_GROUP	特殊客户	VARCHAR(30)	
GROUP_TYPE	集团属性	VARCHAR(30)	
ECONOMY_TYPE	经济性质	VARCHAR(30)	
OPENING_TIME	营业时间	VARCHAR(30)	
BUSI_AGE	经营年限	VARCHAR(30)	
BUSI_AREA	卷烟经营面积	DECIMAL(16, 4)	
DISPLAY_AREA	卷烟陈列面积	DECIMAL(16, 4)	
AD_AREA	卷烟品牌宣传面积	DECIMAL(16, 4)	
STAFF_NUM	店员数量	VARCHAR(30)	
CRM_LONGITUDE	百度经度	DECIMAL(18, 8)	
CRM_LATITUDE	百度纬度	DECIMAL(18, 8)	
ORG_LONGTITUDE	GPS 经度	DECIMAL(18, 8)	
ORG_LANTITUDE	GPS 纬度	DECIMAL(18, 8)	

零售户经营业态有7种：■食杂店 ■便利店 ■超市 ■商场 ■烟酒商店 ■娱乐服务类 ■其他；终端类型有2种：■现代终端 ■普通终端

(3) 零售户负责人(经营者)信息表如表所示。

表4.3 零售户负责人(经营者)信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
CUST_CODE	零售户许可证号	VARCHAR(60)	主键
CUST_MANAGER	负责人(经营者)名字	VARCHAR(60)	
P_SALE_YEAR	负责人经营卷烟年份	VARCHAR(30)	
P_CARDID	负责人身份证号	VARCHAR(60)	
P_PHONE	负责人电话	VARCHAR(60)	
P_PHONE_RESERVE	备用电话	VARCHAR(60)	
P_QQ	QQ号	VARCHAR(60)	
P_WEIXIN	微信号	VARCHAR(60)	
P_SEX	负责人性别	VARCHAR(30)	
P_BIRTHDAY	负责人出生年月	VARCHAR(60)	
P_EDU	负责人文化程度	VARCHAR(30)	
P_SMOKE_HABIT	负责人吸烟情况	VARCHAR(30)	
P_COMPUTER_SKILL	负责人电脑技能	VARCHAR(30)	
P_PHONE_SKILL	负责人智能手机技能	VARCHAR(30)	
P_PHONE_TYPE	负责人智能手机类型	VARCHAR(30)	

(4) 零售户商圈信息表如表所示。

表4.4 零售户商圈信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
CUST_CODE	零售户许可证号	VARCHAR(60)	主键
BUSI_BSTYPE	市场类型	VARCHAR(30)	
SHOPDISTRICT_TYPE	商圈类型	VARCHAR(30)	
SHOPDISTRICT_RIPE	商圈成熟度	VARCHAR(30)	
SHOPDISTRICT_CONSUME	商圈消费能力	VARCHAR(30)	
CONSUMER_FIX_FLOW	消费主要群体	VARCHAR(30)	

市场类型有2种：■城镇 ■乡村；商圈类型有6种：■商业区 ■住宅区 ■文教区 ■办公区 ■工业区 ■混合区；商圈成熟度有3种：■高 ■中 ■低；商圈消费能力有3种：■高 ■中 ■低；消费主要群体：性别：■男 ■女，年龄段：■老年 ■中年 ■青年，职业：■公务员 ■工人 ■农民 ■商人 ■学生 ■军人 ■无业，烟龄：■5年以下 ■5-10年 ■10年以上。

(5) 零售户烟草管理服务人员信息表如表所示。

表 4.5 零售户烟草管理服务人员信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
CUST_CODE	零售户许可证号	VARCHAR(60)	主键
COM_NAME	市公司名称	VARCHAR(60)	
XIA_NAME	县名称	VARCHAR(60)	
SALEDEPT_NAME	部门名称	VARCHAR(60)	
SLSMAN_NAME	客户经理姓名	VARCHAR(60)	
SLSMAN_PHONE	客户经理电话	VARCHAR(60)	
CUST_MANAGER_NAME	市管员姓名	VARCHAR(60)	
CUST_MANAGER_PHONE	市管员电话		
ROUTE_NAME	送货线路	VARCHAR(60)	
ROUTE_ORDER	送货序号	INTEGER	
DELIVERY_MAN_NAME	送货员名称	VARCHAR(60)	
DELIVERY_MAN_PHONE	送货员电话	VARCHAR(60)	
CONCUR_GROUP_NAME	自律互助小组名称	VARCHAR(60)	
DIV_TOWN_NAME	乡镇(街办)名称	VARCHAR(60)	
DIV_VILL_NAME	村庄(社区)名称	VARCHAR(60)	

有名称的字段都有相应的 ID 字段,限于篇幅不在此列举。

(6) 零售户经营服务信息表如表所示。

表 4.6 零售户经营服务信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
CUST_CODE	零售户许可证号	VARCHAR(60)	主键
BL_SENCAN	省产烟占比	DECIMAL(16, 4)	
BL_JINSEN	金圣烟占比	DECIMAL(16, 4)	
BL_ORDFULFIL_ALL	需求满足率	DECIMAL(16, 4)	
BL_ORDRATE_ALL	订购率	DECIMAL(16, 4)	
BL_ORDRATE_SENCAN	省产烟订购率	DECIMAL(16, 4)	
AVGPRICE_ALL	卷烟购进单条均价	DECIMAL(16, 4)	
AVGPRICE_SENCAN	省产烟购进单条均价	DECIMAL(16, 4)	
AVGPRICE_JINSEN	金圣烟购进单条均价	DECIMAL(16, 4)	
AVGQUANTITY_ALL	次均购进量	DECIMAL(16, 4)	
BS_WIDTH_ALL	总品规经营宽度	DECIMAL(16, 4)	
BS_WIDTH_SENCAN	省产烟品规经营宽度	DECIMAL(16, 4)	
PRICE_LEVEL	卷烟销售价格档级	VARCHAR(30)	
PRICE_MODE	卷烟零售方式	VARCHAR(30)	

BRAND_SOLD_PRICE1	一类烟主销品牌	VARCHAR(500)	
BRAND_SOLD_PRICE2	二类烟主销品牌	VARCHAR(500)	
BRAND_SOLD_PRICE3	三类烟主销品牌	VARCHAR(500)	
BRAND_SOLD_PRICE4	四类烟主销品牌	VARCHAR(500)	
INV_TYPE	发票类型	VARCHAR(30)	
TAX_TYPE	纳税性质	VARCHAR(30)	
ORDER_WAY	订货方式	VARCHAR(30)	
ORDER_FREQUENT	订货频度	VARCHAR(30)	
ORDER_WEEKDAY	每周订货日	VARCHAR(30)	
DELIVERY_PERIOD	送货周期	VARCHAR(30)	
DELIVERY_MODE	送货方式	VARCHAR(30)	
PAY_TYPE	支付类型	VARCHAR(30)	
VISIT_FREQUENT	拜访频次	VARCHAR(30)	

卷烟销售价格档级: ■条包一价 ■包零售价 ■条零售价 ■条市场价 ■倒挂价; 卷烟零售方式: ■包销售占比 30%以下(批发性质) ■包销售占比 30-50% ■包销售占比 50-70% ■包销售占比 70%以上; 发票类型: ■不要 ■普通 ■增值税 ■每日普通 ■每月普通 ■每日增值税 ■每月增值税; 纳税性质: ■一般纳税人 ■小规模纳税人; 订货方式: ■电话 ■PC ■手机 ■其他; 订货频度: ■1周2次 ■1周1次 ■2周1次 ■其他; 支付类型: ■现金 ■电子结算 ■网银 ■支票 ■终端付款 ■POS机刷卡 ■手机 ■转账 ■微信 ■支付宝; 拜访频次: ■每周1次 ■半月1次 ■每月1次 ■其它。

(7) 零售户标签信息表如表所示。

表 4.7 零售户标签信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
LABEL_ID	标签编码	VARCHAR(60)	主键
LABEL_NAME	标签名称	VARCHAR(60)	
LABEL_DEF	标签定义	VARCHAR(60)	
LABEL_CONTENT	标签内容	VARCHAR(60)	指标原始值
LABEL_EVA_CRIT	标签评价标准	VARCHAR(60)	评价算法
LABEL_VALUE	标签值	VARCHAR(60)	分类标签值
LABEL_TYPE	标签类型		

(8) 零售户综合评价标签库信息表如表所示。

表 4.8 零售户综合评价标签库信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
LABEL_UUID	唯一编码	VARCHAR(60)	主键
LABEL_ID	标签编码	VARCHAR(60)	
LABEL_NAME	标签名称	VARCHAR(60)	
WEIGHT	标签权重	VARCHAR(60)	
PARENT_LABEL_ID	上级标签编码	VARCHAR(60)	
LABEL_ALG	标签评价算法	VARCHAR(60)	评价算法
LABEL_LAB_ID	所属标签库	VARCHAR(60)	

(9) 零售户综合评价标签结果信息表如表所示。

表 4.9 零售户综合评价标签结果信息表

COL_NAME	CHINESE_NAME	COL_TYPE	NOTE
LABEL_UUID	唯一编码	VARCHAR(60)	主键
LABEL_ID	标签编码	VARCHAR(60)	
LABEL_LAB_ID	所属标签库	VARCHAR(60)	
CUST_CODE	零售户许可证号	VARCHAR(60)	
CUST_NAME	负责人(经营者)名称	VARCHAR(60)	
LABEL_CONTENT	零售户标签内容	VARCHAR(60)	
LABEL_CONTENT	零售户标签值	VARCHAR(60)	
LABEL_SCORE	标签得分	VARCHAR(60)	
LABEL_ORDER	标签得分排名	VARCHAR(60)	
LABEL_SORT	标签分类	VARCHAR(60)	

第 5 章 卷烟零售户画像系统实现

5.1 开发运行环境

零售户画像系统需要对大量的零售户数据进行处理，并要求能进行大数据挖掘分析。传统的关系型数据仓库，并不能很好的支持大数据下的数据挖掘，而且还需要一大笔资金用于购买数据仓库软件。综合考虑，决定采用基于 Hadoop 平台生态技术来搭建整个开发和运行环境。详细信息如表所示。

表 5.1 开发及运行配置表

	项目	配置及版本详情
开发环境	硬件资源	2.4GHz CPU*4, 8G 内存, 硬盘 1T
	开发工具	eclipse-jee-oxygen-3-win32-x86_64
	大数据平台	Hadoop 2.6 for Win7
	操作系统	64 位 Win7
	数据库软件	Mysql 5.6
	Web 服务器	Tomcat 8.0
运行环境	硬件资源	2 台 NameNode (2.4GHzCPU*8, 32G 内存, 硬盘 1T) *2 5 台 DataNode (2.4GHzCPU*4, 16G 内存, 硬盘 2T) *5 1 台 DB 服务器 (2.4GHzCPU*8, 32G 内存, 硬盘 1T) *1 2 台 web 服务器 (2.4GHzCPU*8, 32G 内存, 硬盘 300G) *2
	操作系统	CentOS6.5
	大数据平台	Hadoop 2.6 for Linux
	Web 服务器	Tomcat 8.0
	数据库软件	Mysql 5.6

5.2 Hadoop 平台实现

5.2.1 数据源分析

零售户画像所用的指标和数据分散存储在烟草公司各业务系统中，因此就

需要从各业务系统中提取零售户的相关数据,并对数据进行预处理后统一存储。建立大数据平台,可以实现数据抽取、清洗、分析、入库、出库等一系列数据管理要求。其数据源结构如图所示。




图 5.1 数据源结构图

专卖系统储存了零售户的许可证办理相关数据,是零售户的基本属性信息,其中一些属性数据可作为零售户的静态标签,而案件信息可以作为零售户风险度分析的数据来源。营销系统用于烟草公司购进卷烟,制定货源投放策略,管理零售户扩展信息,管理卷烟规格信息等,是零售户的补充属性信息和主要的行为信息。订货系统用于零售户的卷烟订货,即烟草新商盟系统,是零售户订单数据的提供者。营销系统和订货系统当中的零售户相关数据是分析零售户贡献度、成长度的主要数据来源。结算系统有订单结算数据,采集系统有库存价格数据,可用来分析零售户配合度。由于这些源数据,为了提高系统的处理和分析能力,必须先将这些抽取出来,清洗后在大数据中心统一存储。

5.2.2 数据 ETL 实现

ETL 数据处理包括数据抽取、清洗、加载三个主要过程,如图所示。




图 5.2 数据处理阶段流程图

在这个 ETL 数据过程中，还有一个重要的参数管理功能，主要用来维护 ETL 过程中所需要的参数信息。包括业务参数表、指标参数表、服务器描述表、系统描述表、定时器描述等。其中服务器描述表用于保存服务器的相关参数信息。定时器描述表用来定义自动调用的时间、频率等信息。评价指标配置表包括各指标的对应关系和可执行程序定义，为了以后维护和升级方便，建立了零售户画像系统中的标签和可执行程序定义的对对应关系。将来如果标签的定义和算法发生变化，只要修改可执行程序定义即可，降低了未来的维护工作量。

本文采用 Sqoop 实现从数据源抽取数据到大数据平台 Hadoop 的 HDFS 中，使用 MapReduce 编程方式对数据进行清洗后继续保存到 HDFS 中。通过 Linux Shell 脚本编程将清洗后 HDFS 中的数据根据需要分别载入到 HBASE 和 Hive 中。采用 Sqoop 将 Hive 中的统计数据载入到关系型数据库 MySQL 中。运用 Mahout 对清洗后 HDFS 中的数据进行挖掘，形成零售户的分类数据，采用 Sqoop 将零售户的画像结果数据载入到关系型数据库 MySQL 中。当用户需要查看零售户画像数据时，仅需要通过调用 MySQL 中的画像数据即可，由于零售户画像系统中形成的画像数据是有周期的，每个画像周期内每个零售户有一条画像数据记录，这样 MySQL 数据库中每次存储的数据量不超过 18 万条记录，数据量不大，可大大提高实时响应速度。其中，Sqoop 是 Hadoop 生态下的一款开源软件，主要用于 Hadoop 与传统数据库间进行数据的交换。Mahout 也是一个开源项目，提供了大量的可在大数据环境下运行的挖掘算法，可简单快速的开发出数据挖掘系统。

5.2.3 数据挖掘算法实现

K-means 是一种基于距离思想的聚类算法，其优点是算法原理容易理解、聚类效果较好，运算速度较快。聚类算法的基本步骤如图所示。




图 5.3 K-means 算法执行流程图

在 Mahout 中使用 k-means 算法进行数据聚类核心代码如下：

```
mahout kmeans
-i input/data_vectors
-c output/kmeans-clusters
-o output/data_kmeans
-k 100
-dm org.apache.mahout.common.distance.EuclideanDistanceMeasure
-x 100
-cd 0.01
-ow
-xm mapreduce
```

- i: 表示输入, 需分析数据集在 input/data_vectors。
- o: 表示输出, 每一轮迭代的结果将输出在 output/data_kmeans。
- k: 表示分类的数量, 此处说明需将输入数据分为 5 类。
- c: 表示初始化中心点的数据位置, 若设置了 K 值, 使用随机数。
- dm: 表示计算距离的公式算法, 此处表示欧几里得算法。
- x : 表示最大迭代次数, 此处为 100。
- cd: 表示迭代收敛阈值, 默认 0.5, 此处为 0.01。
- xm: 表示采用 MapReduce 模式执行。
- ow: 表示覆盖输出文件夹

而朴素贝叶斯算法主要用于预测零售户发生违规违法行为的概率, 再按照发生违规违法行为概率进行 $K=5$ 的聚类分析, 其中概率最小的一类零售户认为就是规范度最高的零售户。算法执行如图所示。




图 5.4 朴素贝叶斯算法执行流程图

核心代码如下：

```
--训练贝叶斯模型
mahout trainnb
-i /user/risk/result-train-vectors -el
-o /user/risk/model
-li /user/risk/labelindex
-ow -c
--测试贝叶斯模型
mahout testnb
-i /user/risk/result-train-vectors
-m /user/risk/model
-l /user/risk/labelindex
-ow -o /user/risk/result-testing -c
--应用贝叶斯模型对待分类数据分类
mahout testnb
-i /user/risk/result-test-vectors
-m /user/risk/model
-l /user/risk/labelindex
-ow -o /user/risk/result-testing -c
```

5.3 主要功能模块实现

5.3.1 零售户信息查询

系统实现了零售户查询功能，可以按关键字查询，也可以按所属区域、业态、市场、商圈等多条件联合查询。零售户的查询程序的实现流程如图所示。




图 5.5 零售户查询流程图

零售户查询的页面效果如图所示。




图 5.6 零售户查询效果图

从上图可知，系统实现了按关键字查询，同时还实现了按常用的客户分类查询，比如按所属区域，卷烟销售总量、结构，经营业态，市场类型，结算方式，商圈等信息来进行分类查询。

5.3.2 零售户标签信息查看

通过零售户查询条件，查询出符合条件的零售户列表后，“点击”任意一户零售户信息表格中的“零售户画像”进入零售户画像页面。首先显现零售户的标识标签信息，主要包括许可证号，店铺名称，所属区域，客户经理等信息，属于零售户画像的静态标签信息。零售户标识标签信息查看的页面效果如图所示。



图 5.7 零售户标识标签查询效果图

在零售户画像页面，选择经营水平显现零售户的经营水平指标信息，主要包括省产烟占比，需求满足率，订购率，品规宽度等信息，属于零售户画像的

动态行为标签指标信息。零售户经营标签指标查询的页面效果如图所示。



经营水平	
省产烟占比	40.0000
金圣烟占比	34.5400
需求满足率	98.4117
订购率	100.0000
省产烟订购率	100.0000
卷烟购进单条均价	173.1087
省产烟购进单条均价	164.2886
金圣烟购进单条均价	180.6581
次均购进量	86.8000
总品规经营宽度	13.1313
省产烟品规经营宽度	42.8571
经营规模	中

图 5.8 零售户经营标签指标查询效果图

5.3.3 零售户综合评价画像信息查看

零售户综合评价信息是零售户画像特征数据的完整展现。每个月按照综合评价指标体系进行一次零售户的综合评价，根据综合评价得分在各地市的排名情况，将现有有效零售客户划分为“核心忠诚客户、忠诚客户、一般客户和风险客户”4 个分类标签。将每个二级指标的得分进行 K=5 的 kmeans 聚类，使零售户按照二级指标进行分类，并最终形成 5 档标签。零售户综合评价画像标签查询的页面效果如图所示。



图 5.9 零售户综合评价画像查询效果图

5.4 系统测试

5.4.1 测试内容

系统测试用于验证系统是不是按设计来实现的，对软件工程质量负责，工作阶段主要 5 个，如图所示。




图 5.10 系统测试阶段工作图

5.4.2 测试用例

测试用例编写的优劣，对测试的执行效果有明显作用。测试用例一般包含的内容如下表。

表 5.2 零售户查询测试用例

项目名称	零售户画像系统	程序版本	0.9.0
功能模块	功能测试	编制人	xxx
用例编号	Test-010	编制时间	2017-12-4
系统功能	零售户查询	测试目的	通过查询条件能否查询到对应的零售户
测试数据		脱敏后的全省零售户基本信息数据	
操作步骤	操作描述	输入	期望输出
1	进入零售户查询页面	点击“零售户查询”菜单	显示零售户查询主页面
2	输入关键字，查询零售户	输入“洪城”二字，点击“查询”按钮	显示带“洪城”二字的零售户列表
3	任意选择两个查询条件，查询零售户	经营业态选择“烟酒店”，市场类型选择“乡村”，点击“查询”按钮	显示经营业态是烟酒店并且市场类型是乡村的零售户列表
4	出入关键字，并任意选择两个查询条件，查询零售户	输入“洪城”二字，经营业态选择“烟酒店”，市场类型选择“乡村”，点击“查询”按钮	显示带“洪城”二字，经营业态是烟酒店并且市场类型是乡村的零售户列表
5	退出零售户查询页面	点击“返回”按钮	退出当前零售户查询页面，进入系统主页面

5.4.3 测试结论

通过第一轮的依据测试用例的完整功能测试，对测试数据进行分析认为：系统功能达到了设计的要求，没有严重缺陷，但程序存在一定数量的一般缺陷和轻微缺陷，需要进行完善解决。经过程序修正，第二轮测试通过，各功能模块运行正常，数据准确。

5.5 系统应用及效果分析

江西烟草零售户画像系统已开发完，目前在南昌市烟草公司试运行，系统稳定运行，为烟草一线员工和管理层进行客户识别、客户评价、客户分类提供了数据支撑。本文抽取南昌市局 2017 年度零售户所有相关数据，对其进行评价和分析，将客户进行分类管理，分别制定具体的客户服务策略，并对系统的应用效果进行分析。

5.5.1 样本数据

抽取南昌市烟草公司 2016 年之前入网的，2017 年有销售行为的零售户相关数据，并对数据进行预处理，形成与零售户综合评价密切相关的 11 个指标属性。各属性数据定义与类型见下表：

表 5.3 各属性数据详细说明表

ID	COL_NAME	CHINESE_NAME	COL_TYPE
1	客户编码	零售户许可证号	String
2	订购总量	零售户卷烟订购总量	Int
3	订购条均价	零售户卷烟订购额/ 订购总量	Float
4	省产烟占比	零售户订购江西本土 品牌卷烟数量/订购 总量	Float
5	网上订购率	网上订购次数/应订 货次数	Float
6	电子结算率	电子结算次数/应订 货次数	Float
7	扫码销售率	扫码销售条数/订购 总量	Float
8	需求满足率	订购总量/需求总量	Float
9	品规宽度	订购的卷烟品规类型 数量/可订购卷烟品 规总数	Float
10	违法风险度	违法发生的概率	Float
11	违规风险度	违规发生的概率	Float

我们抽取南昌市烟草公司所有有效零售户 15880 户的相关数据，约有 2000 万条记录作为源数据，对其进行预处理，得到初步的模型数据，包括 12986 户零售户的 11 个指标数据，数据正规化处理后导入系统进行挖掘工作。

5.5.2 客户画像结果分析

对于客户画像我们主要采用一维指标画像，多维指标画像，综合评价画像三种方式。

(1) 一维指标画像

按照 K-Means 方法建立挖掘模型，任意选择一个指标项作做一维聚类，此处以“订购总量”为例，拟产生 5 个客户群（K=5）。经过数据挖掘，得到了客户群的初始化划分。见下表：

表 5.4 基于“订购总量”的初次客户群划分

客户群	聚类中心	客户数	客户占比
1	82689	2	0.02%
2	6914	2482	19.11%
3	426725	1	0.01%
4	44664	7	0.05%
5	1337	10494	80.81%

从上表所限的初步聚类结果发现，客户群 1、客户群 3 和客户群 4 的聚类中心远大于其他 2 类客户群，这 3 个客户群的总客户数占比不到 0.1%，但销量占比达到了 2.8%。因此，将客户群 1、客户群 3 和客户群 4 归为一类。由于客户群 2 和客户群 5 占比过大，不符合分类原则，剔除新一类的零售户，将剩余的零售户再次进行 K=5 的聚类。客户群分布见下表：

表 5.5 基于“订购总量”的二次客户群划分

客户群	订购总量上限	订购总量下限	订购总量均值	客户数	客户数占比	订购总量占比
1	22471	9639	11828	346	2.66%	12.75%
2	5911	3296	4416	1898	14.62%	26.12%
3	9615	5916	7409	1028	7.92%	23.73%
4	3294	1403	2173	3229	24.87%	21.87%
5	1401	5	630	6475	49.86%	12.71%

基于 2 次聚类，可以把基于“订购总量”的零售户群分为 6 类。零售户分类画像结果如下表。

表 5.6 按“订购总量”分类画像结果

类别	客户群	分级依据
微型客户	客户群 5	订购总量≤1401 条
小型客户	客户群 4	1401 条<订购总量≤3294 条
中型客户	客户群 2	3294 条<订购总量≤5911 条
大型客户	客户群 3	5911 条<订购总量≤9639 条
特大客户	客户群 1	9639 条<订购总量≤22471 条
超大客户	客户群 6	22471 条<订购总量

(2) 多维指标画像

多维指标画像主要指采用二维以上指标进行聚类分析，此处采用零售户贡献度中的两个主要指标“订购总量”和“订购条均价”进行 K-Means 聚类。将特殊极值提取出来形成一个客户群 10，其他零售户进行 K=9 的聚类，形成客户群 1-9。如下表所示。

表 5.7 基于“贡献度”的二维指标客户群划分

客户群	订购总量上限	订购总量下限	订购总量均值	订购条均价上限	订购条均价下限	订购条均价均值	客户数	客户占比
1	2102	10	842	147	121	134	3845	29.61%
2	5871	2383	3935	194	146	162	1239	9.54%
3	2482	5	973	189	147	160	2200	16.94%
4	5538	1845	3064	152	104	136	1679	12.93%
5	5587	5	861	120	41	107	1902	14.65%
6	7685	10	1712	309	188	216	419	3.23%
7	20595	9130	11602	237	92	151	358	2.76%
8	9556	4895	6831	162	97	144	930	7.16%
9	14125	4438	7216	258	160	180	399	3.07%
10	426725	21	63671	616	62	279	15	0.1%

根据上表可以看出：客户群 10 表现为量大、价高、客户少的特征，为特殊超大型客户，如监狱、铁路、超大商超等。客户群 7、8、9 是大型客户，表现

为量大、价格稍高、客户稍少，为普通大型客户，其中客户群 7 为特大型客户，主要是大型商超、大型批发部、大型食杂店、烟酒专卖店等。客户群 3、6 表现为价高、量少，主要是连锁超市、加油站等，结构不合理，应重点关注此类客户。客户群 5 表现为量小、价低，客户不少，主要是周边消费能力低的普通食杂店，一般为农村，属于价值较小的客户。客户群 1 表现为量小、价稳，客户多，主要是周边消费能力还可以的普通食杂店，一般为城镇，属于有潜力可挖的客户。客户群 2、4 表现为量价配合，客户群中等，属于稳定性客户。

(3) 综合评价画像

根据 3.4 章的零售户分类综合评价模型，计算出每个零售户的综合得分。根据综合得分进行客户群的划分。

表 5.8 基于“综合评价”的客户群划分

客户群	聚类中心	综合得分上限	综合得分下限	客户数	客户占比
1	81.00	91.47	75.45	4811	30.44%
2	56.20	63.04	49.63	3204	20.27%
3	69.89	75.44	63.05	4723	29.88%
4	43.06	49.63	19.05	3069	19.42%

零售户综合评价分类画像结果如下表。

表 3.2 按“综合评分”分类画像结果

类别	客户群	分级依据
核心忠诚客户	客户群 1	综合得分>75.45
忠诚客户	客户群 2	63.05<综合得分<=75.45
一般客户	客户群 3	49.63<综合得分<=63.05
风险客户	客户群 4	综合得分<=49.63

5.5.3 营销策略

针对不同特征、不同分类的零售户，烟草公司要实施精准的营销策略，对于存在风险的客户，要制定相应的策略，以防客户的风险真正发生。以市场净化为目标的零售户综合评价分类，就执行了不同的营销策略。

(1) 核心忠诚零售户

营销服务方面：每月实地拜访4次，新品全面投放、终端建设优先考虑、物料优先满足；市场监管方面：专卖人员在未接到举报、客户和消费者反映的情况下，可以不进行检查；货源供应方面：完全满足；学习培训方面：在店内挂牌或在许可证上贴标，提升“核心忠诚客户”的荣誉感。

（2）忠诚零售户

营销服务方面：每月实地拜访2次，新品优先投放、终端建设选点安排、物料逐步满足；市场监管方面：不定期进行监管，每季度至少例行检查1次；货源供应方面：基本满足；学习培训方面：每年培训学习至少一次。

（3）一般零售户

营销服务方面：每月实地拜访最少1次，新品选择性投放、终端建设暂不考虑、物料少量满足；市场监管方面：要定期进行监管，每月例行检查至少1次；货源供应方面：部分满足；学习培训方面：每年选择性的培训学习一次。

（4）风险零售户

营销服务方面：每月必须拜访4次，新品不投放、终端建设不考虑、物料不提供；市场监管方面：进行实时监控，每月例行检查不少于4次；货源供应方面：停供或减供；学习培训方面：每月至少接受一次法律知识的学习和违法风险的教育，不参加营销组织的培训学习。

5.5.4 应用效果分析

基于大数据平台的零售户画像已经在江西烟草试运行，其主要围绕江西烟草在大数据处理与挖掘方面的不足进行，根据画像结果有针对性的进行客户分类，取得效果如下：

（1）对海量零售户的相关数据处理进行完善，从以报表统计为主的数据分析逐步转变为以数据挖掘为主的数据分析方式，使得江西烟草的管理走向数据驱动管理。

（2）根据聚类分析，对零售户进行分类，系统提供了多种零售户分类的方式，为江西烟草在多种应用场景下制定相应的销售策略提供了数据的支撑。

（3）合理利用江西烟草的有限资源，随时随地查阅零售户的画像信息，提高了客户服务的效率，降低了企业成本。

(4) 制定因类而异的销售策略，提升了江西烟草的影响力和服务口碑，最终圆满完成了年度利税目标。

第6章 结论与展望

6.1 结论

零售户的画像信息来源于零售户本身属性信息和相关的实际业务数据，能够真实的反映出零售户的静态特征和动态特征。基于大数据的分析算法，其准确性比人为经验判断更高，其分析判断速度也更快。基于层次分析法的综合评价零售户分类方法，其理论原理容易理解，烟草公司管理层更容易认可。基于Hadoop的江西烟草零售户画像系统的建立，对于不同的画像信息的零售户可以分别制定相应的客户服务策略，客户营销策略，客户监管策略，实现江西烟草精准服务、精准营销、精准监管的目标，从而增强了江西烟草的市场竞争力。本文取得的主要研究成果如下：

- (1) 基于层次分析法，设计了烟草行业客户画像模型和分类模型。
- (2) 构建了具有先进性，科学性和合理性的适合大数据环境的烟草行业客户画像分类评估与预测系统。

6.2 进一步工作的方向

课题研究工作已经初步完成，零售户画像系统也部署上线试运行，但系统设计上还是有考虑不周的地方，需要不断完善。在课题研究结束之时，也在思考以后的工作方向，产生以下几点想法：

- (1) 新的业务场景下的零售户画像建模。
- (2) 零售户综合评价分类的指标优化。
- (3) 新的数据挖掘算法的应用；
- (4) Hadoop 大数据平台数据管理的稳定性；
- (5) 零售户画像的实时分析。

致 谢

两年时间转眼而过，在工作十一年后能再回到校园学习是一件不容易的事，付出总要比常人多一点。值得庆幸的是，在这里，结识了许多良师益友，正是有了你们的教导和陪伴，我才能顺利完成课程的学习直至本论文顺利完成。谢谢你们！

首先，感谢刘春年教授，我的硕导，给予的方向性建议。通过这两年学习，让我这么一个有十多年工作经验的应用型人才，现在也会做那么一点点的理论研究了，并在大数据理论和数据挖掘工具应用上，得到了刘老师建设性的指导。今天能够顺利的完成论文的写作，刘老师也给予我悉心的指导。谢谢老师！

我还要感谢我们的班长林孝宽，由于我们专业的特殊性，很多学校的日常事务都是班长在给我们打理，节省了我们大量的精力。谢谢孝宽同学！此外，我还要感谢刘志军教授、徐明发主任、袁泉科长在业务方面的指导，感谢锦峰软件李伟总经理提供系统测试所需的硬件资源。谢谢领导！

最后，感谢我的家人，这两年由于工作学习的原因，陪伴你们的时间少了，同时二宝也在这个时候降临，辛苦并快乐着，感谢夫人的理解与支持！

吴漪涛

2018 年 4 月

参考文献

- [1] 潘文.我国大数据发展现状与趋势[J].领导科学论坛,2017 (4) :28-44
- [2] 亓丛 , 吴俊.用户画像概念溯源与应用场景研究[J].重庆交通大学学报:社会科学版,2017,17 (5) :82-87
- [3] 张丽娟.基于大数据分析的用户画像助力精准营销研究[J].电信技术 , 2017 , 8 (1) :61-62-87
- [4] 刘海, 卢慧, 阮金花, 田丙强, 胡守忠.基于"用户画像"挖掘的精准营销细分模型研究[J].丝绸,2015 ,52 (12) :37-42
- [5] 崔琳.基于客户画像的数据挖掘技术在 CRM 中的应用[D].东华大学 ,2015
- [6] 廖晶贵.基于 Hadoop 的大数据关联规则挖掘算法的研究与实现[D].华南理工学 ,2015
- [7] 张宏安.基于 Hadoop 的多数据源数据挖掘技术应用研究[D].北方工业大学 , 2015
- [8] 蒋佳军.基于 Hadoop 平台的电力大客户用电时序数据分类研究[D].华南理工学 ,2015
- [9] 李冰, 王悦, 刘永祥.大数据环境下基于 K-means 的用户画像与智能推荐的应用[J].现代计算机 , 2016 (24) :11-15
- [10] 庞夫星.基于聚类分析的烟草行业客户细分研究[D].山东财经大学,2014
- [11] 徐娟.基于贝叶斯网的社交网络用户相似性发现[D].云南大学,2015
- [12] 梁雯斌.基于层次分析和聚类分析法的客户细分研究[D].湖北工业大学,2015
- [13] 孙琳.大数据技术在客户细分中的应用[J].信息系统工程, 2017 (4) :18-18
- [14] 李玉华.基于 Hadoop 的 CDMA 分组域海量数据处理模型的研究[D].武汉邮电科学研究院, 2013
- [15] 陈韶男.基于 NoSQL 的综合信息汇聚平台的设计与实现[D].北京邮电大学 , 2015
- [16] 佟林.基于 Hadoop 平台的网络舆情分析系统的研究与实现[D].吉林大学, 2015
- [17] 金凤.基于 hadoop 的 web 管理系统[D].北京邮电大学,2015
- [18] 朱海东.证券公司客户价值分析系统的设计与实现[D].大连理工大学 , 2014
- [19] 裘华东, 涂莹 , 丁麒.基于标签库系统的电力企业客户画像构建与信用评估及电费风险防控应用[J].电信科学,2017 (S1)
- [20] 刘光榕, 任建涛.基于客户画像的精准推荐[J].科技经济导刊 ,2016 (35)
- [21] 张哲.基于微博数据的用户画像系统的设计与实现[D].华中科技大学 , 2015
- [22] 王海飞.基于 Hadoop 云的数据库营销海量数据处理与挖掘的研究[D].浙江理工学,2013.
- [23] 王劲.大数据时代的管理变革[J]. 中国商贸,2013,02:189-190.
- [24] 关雷. 神经网络在卷烟销量预测及营销策划中的应用[D].内蒙古大学,2012.
- [25] 李伟萁,李光明.库马尔零售户终身价值模型及其参数的简化[J].科技视界,2012(28).
- [26] 孙福权.基于 Hadoop 大数据平台存储平台的构建[J].辽宁工程技术大学学报 2011(30).
- [27] 张小可,沈文明,杜翠凤.贝叶斯网络在用户画像构建中的研究[J].移动通信,2016,40(22)
- [28] 陈禹安.大数据污染与用户画像[J].销售与市场:管理版,2016(13)
- [29] 林汉川,张万军,杨柳.基于大数据的个人信用风险评估关键技术研究[J]

- [30] 易晓辉.人工智能如何改变营销决策方式[J].新营销,2017(4)
- [31] 孙新伟.电商企业网购用户的客户分类识别研究[J].吉林大学,2017
- [32] 马亮,陶利涛,谢骏凯.基于客户画像的客户诉求管理[J].电力需求侧管理,2016,18(a01)
- [33] 朱卫东,孙宜博,吴勇,李矿,杜承勇.基于神经网络的烟草零售户销售假烟行为的预警模型研究[J].中国烟草学会优秀, 2015
- [34] 许泓,刘文倩.基于卷烟零售户销售潜力分值(G 值)的新产品投放策略研究[J].中国烟草学报,2016,22(1)
- [35] 王新良,刘旭东,朱乐泉.关于镇区户卷烟库存分类管理与库存预警机制的研究与实践[J].山东社会科学,2016(s1)
- [36] 祖强.基于卡诺模型面向消费者的客户分类评价体系建设研究[J].中国烟草学报,2017,23(1)
- [37] 高金标.基于 Hadoop 的全国零售户数据处理与市场感知[D].浙江理工大学,2016
- [38] 蔡军.论烟草市场营销渠道中零售商的管理问题与对策.商场现代化[J],2016(8)
- [39] 李晓军.烟草商业企业精准营销探析[J].中国管理信息化,2015,18(20)
- [40] 徐云.大数据时代烟草精准营销方法研究[J].企业研究,2014(16)
- [41] 张莉艳,齐永智.大数据背景下零售经营要素变革研究[J].技术经济与管理研究,2015(7)
- [42] 王彦明.近年来 Hadoop 国内研究进展[J].现代情报,2014,34(8)
- [43] 郑晓平.基于层次分析法的烟草专卖零售经营者动态信用评价模型研究.重庆与世界,2016,11
- [44] 冯登国,张敏,李昊.大数据安全与隐私保护[J]. 计算机学报,2014,01:246-258.
- [45] 马梅若. 大数据预言[J].中国经济和信息化,2013,08:42-45.
- [46] 李文莲,夏健明. 基于“大数据”的商业模式创新[J]. 中国工业经济,2013,05:83-95.
- [47] 刘煜.浅述云计算对烟草行业信息化的影响[J].现代商业,2011(11).
- [48] Aisling O'Driscoll,Jurate Daugelaite,Roy D. Sleator. 'Big data', Hadoop and cloud computing in genomics[J]. Journal of Biomedical Informatics,2013,;.
- [49] Apache.Apache Hadoop[EB/OL].<http://hadoop.apache.org/>.
- [50] Carstoiu, Dorin,Lepadatu, Elena,Gaspar, Mihai. Hbase - non SQL Database, Performances Evaluation[J]. International Journal of Advancements in Computing Technology,2010,25;.
- [51] Henschen, Doug. HBase: Hadoop's Next Big Data Act[J]. EN,2012,1334;.
- [52] Henschen, Doug. HBase: Hadoop's Next Big Data Chapter[J]. EN,2012;.
- [53] Henschen, Doug. MapR Promises A Better HBase[J]. EN,2012;.
- [54] Anja Gruenheid.Query optimization using column statistics[J].IDEAS,2011(11),97~105
- [55] 王永洲. 基于 HDFS 的存储技术的研究[D].南京邮电大学,2013.
- [56] 曹风兵.基于 Hadoop 的云计算模型研究与应用[D].重庆:重庆大学,2011.
- [57] 李宽.基于 HDFS 的分布式 Namenode 节点模型的研究[D].华南理工大学,2011.
- [58] 徐叶.基于 HDFS 的海量小文件存储系统设计与实现[D].国防科学技术大学,2012.
- [59] 江三锋,王元亮. 基于 Hive 的海量 web 日志分析系统设计研究[J]. 软件,2015,04:93-96.
- [60] 刘云飞.基于 Hadoop 的数据迁移与存储的研究[D].北京邮电大学,2015.
- [61] 王正也.基于 Hadoop 平台的海量数据查询分析系统的性能优化研究[D].北京邮电大

- 学,2015.
- [62] 陆嘉恒.Hadoop 实战[M].北京:机械工业出版社,2011,7~10.
- [63] 刘涛.云环境下的烟草互联应用与研究[D].浙江理工大学,2012.
- [64] 杜海宁.基于云计算的图书馆海量数据存储研究[J].图书与情报,2010(3).
- [65] 戴婉荣.基于分布式数据库的数据同步机制的研究与应用[D].武汉理工大学,2010.
- [66] 孙胜利.大型分布式信息系统数据同步技术研究[D].石家庄铁道大学,2014.
- [67] 刘永增,张晓景,李先毅. 基于 Hadoop/Hive 的 web 日志分析系统的设计[J].广西大学学报(自然科学版),2011,S1:314-317.
- [68] 王有为,王伟平,孟丹. 基于统计方法的 Hive 数据仓库查询优化实现[J].计算机研究与发展,2015,06:1452-1462.
- [69] 张华强.关系型数据库与 NoSQL 数据库[J].电脑知识与技术,2011(20).