

莫玉华, 谭茜, 古越, 等. 基于合成控制法与机器学习的新品卷烟投放策略研究[J]. 中国烟草学报, 2024, 30 (5). MO Yuhua, TAN Qian, GU Yue, et al. Research on new cigarette launch strategy based on synthetic control method and machine learning[J]. Acta Tabacaria Sinica, 2024,30(5). doi:10.16472/j.chinatobacco.2023.024

基于合成控制法与机器学习的新品卷烟投放策略研究

莫玉华, 谭茜*, 古越, 邓超, 黄飞杰, 许良本

广西中烟工业有限责任公司, 互联网研究中心, 南宁市北湖南路 28 号 530001

摘要: 目前, 新品卷烟投放预测存在数据区间较短、数据波动较大等问题, 制约了传统基于时间序列的卷烟投放模型在新品卷烟上的应用。为解决这一问题, 创新性地将合成控制法与机器学习模型结合, 采用稳定的成熟卷烟产品销量趋势对新品卷烟的销量趋势进行模拟和校准。以广西玉林市 18 个月卷烟销售数据为研究样本, 将真龙(海韵中支)作为研究对象, 基于随机森林算法对数据中缺失值进行相应处理后, 通过合成控制法计算成熟卷烟产品对新品卷烟的拟合权重。应用效果检验发现, 基于长短期记忆模型(LSTM)对新品卷烟预测的准确率仅为 33.31%, 在加入模型标签体系的多种机器学习模型后, 集成学习模型(Weighted Ensemble)算法准确率可达到 88.56%。最终, 在将合成控制法和多种机器学习模型融合后, 算法准确率达到 94.17%。该算法解决了当前新品卷烟销量预测局限性, 并填补了新品卷烟投放模型的研究空白。

关键词: 卷烟投放模型; 合成控制法; 机器学习; 模型融合

烟草行业以数字化技术为依托, 加速推进数字技术和烟草产业的深度融合, 为未来的行业高质量发展注入新动能^[1]。学者开始使用机器学习方法对卷烟投放相关问题进行实证分析与研究, 但现有方法和文献集中于采用时间序列对成熟卷烟产品的销售量进行预测^[2-5], 少有文献探索新品卷烟的投放模型和销量预测问题。

根据市场调查机构统计, 2021 年全年烟草行业各工业公司新上市的规格就多达 33 种。但是大量上市的新品卷烟应该如何投放、向何处投放、又该投放多少, 这些都是烟草企业高度关注的问题。成熟卷烟产品的销售预测模型不能简单套用到新品卷烟的销量预测, 主要原因有二: 一是成熟卷烟产品预测模型需要具有较长的卷烟销售历史数据, 比如邓超等^[2]运用连续 4 年日度层面 1.18 亿条数据进行预测。但新品卷烟往往并不具有长时间序列数据, 样本数据时间跨度较短会导致时间序列模型的估计偏差; 二是成熟卷烟产品销售的整体趋势较为稳定。而由于前期的宣传因素和顾客的尝新心理, 新品卷烟数据往往在销售初期存在剧烈波动。采用时间序列数据预测容易放大新品卷烟数

据的销量波动, 进而增加估计误差, 影响新品卷烟的投放策略决策。因此, 如何在数据区间限制下, 预测新品卷烟的投放模型, 是当前企业乃至行业发展亟需解决的重要问题。

本文以 2020 年真龙(海韵中支)为例, 将广西玉林市零售户层面 18 个月卷烟销售数据作为研究样本。本文的核心思想为基于机器学习和合成控制法, 利用成熟卷烟产品数据区间长、销量较为稳定的特点对新品卷烟的销量走势进行拟合。具体来看, 本文首先借助合成控制法, 从卷烟品规数据中选取成熟卷烟产品模拟新品卷烟, 通过计算得到各个成熟卷烟产品的权重, 并比较合成控制法的拟合程度。第二, 使用机器学习算法, 利用零售户销售数据、商圈人群画像数据以及卷烟品规数据, 计算得到各种成熟卷烟产品的销量预测数据。第三, 根据机器学习得到的成熟卷烟产品预测数据和合成控制法所得到的权重, 计算得到新品卷烟的销量预测数据。本文的算法准确率达到 94.17%, 研究解决了当前新品卷烟销量预测局限性问题, 填补了新品卷烟投放模型的研究空白。

基金项目: 广西中烟工业有限责任公司项目“数据挖掘对真龙新品在广西市场培育的应用研究”(GXZYCX2021E019)

作者简介: 莫玉华(1995—), 硕士, 工程师, 主要研究方向为大数据、人工智能、软件工程, Email: 18482173509@163.com

通讯作者: 谭茜(1986—), Email: 371462268@qq.com

收稿日期: 2023-02-24; **网络出版日期:** 2024-02-08

1 数据与方法

1.1 数据来源

本文所使用的 4 类数据来源于广西玉林市烟草专卖局，其中包括：零售户的品规-月度销量维度数据、零售户的标签维度数据、商圈人群的画像标签维度数据、品规的标签维度数据。考虑到真龙（海韵中支）于 2020 年上市，因此，本文选择的样本时间跨度为 2021 年 1 月—2022 年 6 月。

核心数据是零售户-卷烟品规-月度销量维度数据，其中包括各个零售户 90 种卷烟的月度追踪数据，标签“销量（条）”即为本文所预测的目标。零售户特征标签维度数据刻画了零售户的销售能力、商业区位、业态形式、经营模式等变量。商圈人群画像包括本地商圈人口数量、人口结构、人群消费偏好等变量。品规的标签维度数据包括本文所涵盖的 90 种卷烟类型、品类、价格区间等变量。商圈人群画像、卷烟品规标签、零售户特征标签均为横切面数据。相比单纯通过时间序列进行预测，本文额外引入了商圈人群画像、卷烟品规和零售户销售能力数据组成模型标签体系，模型标签体系可以更多利用商圈人群、卷烟品规和零售户特征这些影响卷烟销量的外部因素，从而更好满足数据估计的无偏性与一致性。

1.2 模型构建

1.2.1 数据清洗

为了保证模型具有代表性，同时消除数据内极端值和不同量纲之间差异所带来的影响，本文对数据的缺失值和异常值进行了清洗。

首先，对包括商圈数据匹配以及不同叫法的品规名称进行模糊匹配，并进行人工校准，将上述 4 种数据合并为 1 个大小约为 10GB 的数据集，组成训练数据集 A。

第二，对数据集 A 的数据集缺失值进行比例统计，如下图表 1 所示，可以看出针对“通勤方式自驾 tgi”

和“到访 4s 店品牌五菱 tgi”的缺失比例最大，同时共计 211 个特征需要填补缺失值。

表 1 数据集 A 中特征缺失情况

Tab.1 Missing labels in dataset A

数据集 A 中特征	缺失值数量	缺失值百分比/%
通勤自驾方式 tgi	23000	9.5
到访 4s 店品牌五菱 tgi	22359	8.9
...	...	...
节假日客流 day_avg	2077	0.8
居住人口	2077	0.8

此处的缺失值考虑使用随机森林填补缺失值，具体步骤如下：①初始化：首先将数据集中的缺失值用平均值（对于连续变量）或众数（对于分类变量）填充，以便构建初始的随机森林模型。②迭代填充：对于每个包含缺失值的变量，依次执行以下操作：a. 以当前变量作为目标变量（需要预测的变量），其他变量作为特征变量。使用完整的数据（没有缺失值的观测）构建一个随机森林模型。b. 利用该随机森林模型预测缺失值。将预测结果填充回数据集中相应的缺失位置。c. 当所有包含缺失值的变量都进行了一次填充后，返回第 2 步，再次迭代填充。反复进行这一过程，直到达到预定的迭代次数或填充结果收敛（即连续两次迭代的填充结果变化很小）。③完成插补：迭代过程结束后，得到填充后的完整数据集。具体的，本文对缺失值按照缺失比例从小到大：“居住人口”“节假日客流 day_avg”“流动人口客流 day_avg”等的顺序进行随机森林缺失值填补，得到经过清洗的完整数据集 A。

第三，针对数据集 A，选择基于箱体图的异常值监测算法进行监测。箱体图是一种比较常见的异常值检测方法，一般情况下，取所有样本的 25%分位点 Q1 和 75%分位点 Q3 两者之间的距离为箱体的长度 IQR，可认为小于 $Q1-1.5IQR$ 或者大于 $Q3+1.5IQR$ 的样本值为异常样本。具体效果如下图 1 所示：




图 1 异常值监测示意图

Fig.1 Schematic diagram of outlier monitoring

第四,针对监测到的异常数据,使用盖帽法进行异常值处理。具体做法:整行替换数据框里 99%以上和 1%以下的点,将 99%以上的点赋值为 99%的点值;小于 1%的点赋值为 1%的点值。即默认凡小于百分之 1 分位数和大于百分之 99 分位数的值将会被百分之 1 分位数和百分之 99 分位数替代。

1.2.2 模型构建思路

本文将通过合成控制法和机器学习方法得到新品卷烟的预测模型,进而解决由于新品卷烟销售量波动大和历史数据不足在预测中所导致的问题。模型构建思路包含以下 3 点:①借助合成控制法,从卷烟品规数据中选取成熟卷烟产品模拟生成新品卷烟,通过计算得到各个成熟卷烟产品的权重,进而通过历史数据比较合成控制法的拟合程度。②使用机器学习算法,利用零售户销售数据、商圈人群画像数据以及卷烟品规数据,计算得到各种成熟卷烟产品的销量预测数据。③根据机器学习得到的成熟卷烟产品预测数据和合成控制法所得到的权重,计算得到新品卷烟的销量预测数据。

在卷烟投放中,相似品规的卷烟销量保持强正相关性,这主要是因为 2 种卷烟拥有相似的受众,影响其销量走势的共同因素较多。因此,本文可以通过合成控制法寻找最优权重,并利用相似品规的成熟卷烟产品销量对新品卷烟销量进行预测和拟合。在机器学习方法的运用上,卷烟投放预测是传统的回归问题,本文将使用 Catboost、NeuralNetTorch、LightGBM、RandomForest 及集成模型等多种机器学习算法及它们的融合模型来进行学习。

1.2.3 模型建立

为了展现本文采用合成控制法与机器学习结合算法的结果,本文的模型结果展示将采用消融实验思路,逐步对各个方法进行模拟和验证。①参照现有文献的思路^[2],利用原有文献的 LSTM 模型对广西中烟新品卷烟真龙(海韵中支)的销量进行预测。②在 LSTM 模型基础上,引入零售户特征、商圈人群画像和卷烟品规数据等横截面数据,只用各种机器学习方法对广西中烟新品卷烟真龙(海韵中支)销量进行预测。③利用 Stata 软件运行合成控制法,得到各个成熟卷烟产品对广西中烟新品卷烟真龙(海韵中支)的权重,并将合成控制得到的权重与各种机器学习结果融合,再次利用机器学习确定融合比例。以下将主要介绍合成控制法与机器学习结合模型建立与训练过程。

合成控制法是由 Abadie and Gardeazabal^[6]以及 Abadie et al^[7]提出,在本文研究中,将使用广西中烟新品卷烟真龙(海韵中支)作为实验组(目标预测新品卷烟产品),使用其他成熟卷烟产品作为控制组(参考成熟卷烟产品)。本文采用合成控制法确定每个成熟卷烟产品对应拟合权重的思想为:假设共有 $J+1$ 种卷烟品牌,假设第一种卷烟品牌($j=1$)为本文想要预测销量的目标新品卷烟产品,其余($j=2, 3, \dots, J+1$)为成熟卷烟产品,数据的时间为 t ,对于成熟卷烟产品 j 和时间 t ,定义 X_{jt} 表示成熟卷烟产品匹配变量向量。对于目标新品卷烟产品 $j=1$, x_{1t} 表示其在 t 时的匹配变量向量。本文中的匹配变量向量包含变量有:卷烟销量、卷烟品牌、卷烟品类、卷烟品规、价格区间、条包零售价格。

为了得到成熟卷烟产品对目标新品卷烟产品的拟合权重,合成控制法得到的权重可以由 $J \times 1$ 的权重向量表示,即 $\omega_i = (w_1, \dots, w_j)$,其中各权重非负,权重之和为 1,权重的选取是为合成控制法中最为重要的一环,只有参考卷烟品牌能够较好的拟合新品卷烟品牌时,该研究方法的结果才具有意义,该方程采用最优化方法对 $x_{1t} - X_{it} \omega_i$ 求最小值。具体为需要选择权重 ω_i 使得包括卷烟销量、卷烟品牌、卷烟品类、卷烟品规、价格区间、条包零售价格等匹配变量的 X_{it} 尽可能接近 x_{1t} ,经过加权后的成熟卷烟产品各项匹配特征将尽量接近目标卷烟。

具体最优化方程如下式(1)和式(2)所示,在确定使得基于合成控制法得到的预测误差最小的拟合权重过程中。将目标卷烟产品匹配变量向量为 x_{1t} ,成熟卷烟品牌匹配向量为 X_{it} ,对角矩阵 V 以及约束条件权重 $\omega_i \geq 0$,且所有权重 ω_i 和为 1,解得最优条件下各成熟卷烟产品对新品卷烟产品权重向量 ω_i 。

$$\min_{\omega} (x_{1t} - X_{it} \omega_i)^T V (x_{1t} - X_{it} \omega_i) \quad (1)$$

$$\text{s.t. } \omega_i \geq 0, i = 1, \dots, A; \sum_{i=1}^A \omega_i = 1 \quad (2)$$

其中,公式(2)中 s.t. 为 subject to 缩写,表示公式(2)为公式(1)的约束条件, $(x_{1t} - X_{it} \omega_i)^T$ 表示 $(x_{1t} - X_{it} \omega_i)$ 的转置矩阵。

合成控制法作为经济学领域内政策或事实评估的重要手段,可以根据数据之间的相似度来选择最优的线性组合权重,目前已被广泛应用于社会经济与企业管理等多个方面。连玉君、李鑫^[8]通过标准化转换来

惩罚安慰剂校验过程中的噪音部分,利用合成控制法推动安慰剂检验改进研究。近年来,国外文献也有使用合成控制法与机器学习算法进行融合,对碳市场定价、污染排放、经济增长等问题进行了研究^[9,10]。

在合成控制法确定了各个成熟产品卷烟对新品卷烟的权重后,本文分别采用 Catboost^[11]、NeuralNetTorch、LightGBM、RandomForest^[12,13]、集成模型、LSTM^[14-15]机器学习模型对成熟卷烟产品的需求量进行预测,并合成得到新品卷烟的需求量。在机器学习模型的建立方面,鉴于本文使用的是零售户层面的长时间序列数据,因此,本文将2021年12个月数据观测样本作为训练集,将2022年1—6月的数据观测样本作为测试集。

1.3 模型评估

为了将各模型之间的预测效果进行比对,本文需要提出一种比对模型预测准确率的标准对不同模型的预测效果进行比对。针对本文的最终目标,即精准预测广西中烟新品卷烟真龙(海韵中支)每个零售户的销量。本文首先构建了最终评估模型整体效果的指标为准确率^[3],具体含义为实际销量和预测销量的差占预测销量的比值与1的差距。该指标越大,模型效果越好,其具体表达式为:

$$\text{准确率} = \left(1 - \frac{|\text{实际销量} - \text{预测销量}|}{\text{预测销量}}\right) \times 100\% \quad (3)$$

1.4 模型运行环境

合成控制方法采用 Stata17 进行处理,计算得到各

个成熟卷烟产品对新品卷烟的权重。图像处理、模型建立、数值计算代码均采用 Python 语言,神经网络构建采用开源的 Pytorch 1.10.0,图像处理单元(Graphic Processing Unit, GPU)采用 NVIDIA GeForce RTX 3090。

2 结果与分析

本文的模型结果展示将采用消融实验思路,逐步对各个方法进行模拟和验证。①利用既往文献所使用的 LSTM 模型对广西中烟新品卷烟真龙(海韵中支)的销量进行预测。②在 LSTM 模型基础上,引入零售户特征、商圈人群画像和卷烟品规数据等横截面数据,用机器学习方法对广西中烟新品卷烟真龙(海韵中支)销量进行预测。③利用 Stata 软件运行合成控制法,得到各个成熟卷烟产品对广西中烟新品卷烟真龙(海韵中支)的权重,并将合成控制得到的权重与机器学习结果融合,再次利用机器学习确定融合比例。本部分将根据各模型准确率选择最优模型。

2.1 仅加入 LSTM 模型的结果分析

基于 LSTM 模型对每个零售户的新品卷烟销量进行建模,通过 LSTM 模型学习 2021 年 12 个月的数据,并预测 2022 年 1—6 月数据。如图 2 所示,其中蓝色折线表示真实数据,黄色折线表示仅仅使用 LSTM 预测结果。通过计算,本文发现基于 LSTM 模型对新品卷烟预测的准确率仅为 33.31%。由于新品卷烟的时间跨度过短,数据量并不充足,因此 LSTM 无法在文中具有良好的表现。




图2 只基于 LSTM 模型下的预测效果

Fig.2 Prediction results based on LSTM model only

2.2 引入标签体系的机器学习

在本节中，机器学习主要调用 Weighted Ensemble, NeuralNetTorch, LightGBMLarge, RandomForestMSE, CatBoost 模型方法及其变体进行特征的提取和学习，接下来将具体介绍每个模型的具体参数和运行状态及其最终的结果。

下表 2 展示了各机器学习方法在该数据集上经过

调参后获得的最优效果。可以发现 Weighted Ensemble 模型的效果最好，其准确率可以达到 88.5%。其次分别为 RandomForest，NeuralNet，CatBoost 以及 LightGBM，这说明引入了零售户特征、商圈人群画像和卷烟品规数据后，对本文的机器学习结果有了明显增益，机器学习训练准确率有了较大幅度的提高。

表 2 各模型运行结果列表
Tab.2 List of results of each model run

模型名称	RMSE	预测花费时间/s	训练时间/s	内存使用量/MB	准确率
WeightedEnsemble	1.940	32.277	990.833	4243.000	0.885
NeuralNet	2.019	0.092	432.388	1144.000	0.758
RandomForest	2.769	0.061	1461.305	57607.000	0.838
LightGBM	2.778	0.028	58.328	27929.000	0.650
CatBoost	3.055	0.004	9.905	11223.000	0.705

2.3 合成控制方法与机器学习的融合算法

首先，本文利用合成控制法计算各成熟卷烟产品对新品卷烟的拟合权重。具体为在数据集中将真龙(海韵中支)标记为实验组，并且选择其他 89 种成熟卷烟产品作为控制组，分别选择卷烟品牌、卷烟品类、卷烟品规、价格区间、条包零售价格等卷烟品规数据作为合成控制变量，最终经过公式（1）和公式（2）计算，可得到表 3 的成熟卷烟产品对新品卷烟的权重系数。观察后可以发现，合成控制法所选取权重最大的控制组卷烟为“冬虫夏草（双中支）”，其次是“黄山（小红方印中支）”。

表 3 成熟卷烟产品合成新品卷烟的权重系数
Tab.3 Weight coefficients for synthesizing new cigarette products from mature cigarette products

卷烟品规	关联系数
娇子（宽窄好运）	0.002
娇子（软阳光）	0.024
真龙（软娇子）	0.009
真龙（巴马天成）	0.053
真龙（海韵）	0.022
真龙（软海韵）	0.136
真龙（鸿韵）	0.101
黄山（大红方印）	0.075
黄山（小红方印中支）	0.188
冬虫夏草（双中支）	0.389

鉴于上部分已经得到基于标签体系的机器学习结果，本部分将进一步将机器学习预测结果和合成控制法结果进行融合。具体地，首先根据机器学习模型得到以上 10 种成熟品种卷烟销量数据；按照表 3 中合成控制法计算得到的权重加权得到卷烟新品的预测销量；将合成控制法得到的卷烟新品预测销量与上节得到的机器学习卷烟新品预测销量进行加权融合。对于加权融合的权重，选择以 0.05 作为步长进行 Vote 融合（Stacking 融合的一种）。即将合成控制法获得的预测量分别和机器学习模型得到的预测量进行拼接做 Vote 融合，从而使机器学习模型借助合成控制法在性能上得到提升。具体表达式如下：

result = ∑Xi * Wi

(4)

对权重进行搜索，由于存在两个模态的结果，所以只需要搜出一对权重即可，故从 0 到 1 步长为 0.05 进行搜寻，从而获得不同模型在和合成控制法 Vote 融合时最好的参数。表 4 为融合后 Top5 模型的模型表现，可以发现 WeightedEnsemble 算法与合成控制法融合的效果最好，融合后模型准确率可达 94.17%，融合权重中 WeightedEnsemble 预测量占比 65%，合成控制法预测量占比 35%。RandomForestMSE 和合成控制融合模型准确也可达到 90.10%，其融合权重为机器学习预测量占到 50%，合成控制法占到 50%。

表 4 融合后 Top5 模型的表现
Tab.4 Performance of Top5 models after fusion

算法名称	融合后效果	融合权重 (机器：合成)
WeightedEnsemble和合成控制	0.942	0.650: 0.350
RandomForestMSE和合成控制	0.901	0.500: 0.500
NeuralNetTorch和合成控制	0.891	0.400: 0.600
XGBoost和合成控制	0.706	0.250: 0.750
LightGBM和合成控制	0.691	0.850: 0.150

为了量化合成控制法对新品卷烟预测量准确率带来的贡献，进一步计算了合成控制法增益效果。具体为采用各机器学习模型与合成控制法融合模型的准确率减去各机器学习模型的准确率。图 3 为加上合成控制法增益图。可以看出合成控制法对 5 个机器学习模型存在着不同程度的增益，其中对 NeuralNetTorch 算法增益最大，其次是 RandomForestMSE 以及 Weighted Ensemble 算法，对 XGBoost 算法的增益最小。




图 3 加上合成控制法增益图
Fig.3 Gain diagram with added synthetic control method




图 4 玉林市新品卷烟预测和实际比较图
Fig.4 Comparison of predicted and actual new cigarette products in Yulin City

最后用 WeightedEnsemble 和合成控制法融合方法对全样本区间新品卷烟销售量进行了预测，并加总得到该模型算法下新品卷烟预测量和实际卷烟销售量之间的比较图。图 4 展示了新品卷烟预测和实际比较图，其中橙色线条为基于机器学习和合成控制融合算法得到的预测销售量，而蓝色线条为新品卷烟的实际销售量。从图 4 来看，本模型良好地拟合了新品卷烟的趋势和走向。

3 结论

针对新品卷烟精准投放问题，本文提出了一种适用于烟草商业公司的卷烟智能投放模型构建方法。该方法融合了机器学习模型和合成控制法，以广西中烟新品卷烟真龙（海韵中支）及其他成熟卷烟产品的历史销售数据为对象，对投放模型进行测试，结果显示销售预测准确率为 94.17%。该智能投放模型的基本原

理是基于成熟卷烟产品走势较为稳定且数据区间较长的特点,利用成熟卷烟产品销量走势对新品卷烟销量走势进行了预测,最终生成新品投放策略。

本智能投放算法通过将机器学习与合成控制法结合,可以针对特定品类的新品卷烟,填补了新品卷烟的模型空白。本文模型做到了单个新品的定制化预测,可以为卷烟企业的新品卷烟投放提供更加有效的指导策略,帮助企业科学投放新品卷烟。

参考文献

- [1] 付秋璇. 浅析广西烟草行业数字化转型的主要问题与解决方法[J]. 中国管理信息化, 2022,25(20):134-137.
FU Qiuxuan. Analysis of the main problems and solutions in the digital transformation of the tobacco industry in province A[J]. China Management Informationization, 2022,25(20):134-137.
- [2] 邓超, 刘颂, 王露笛, 等. 基于深度神经网络的卷烟智能投放模型构建方法[J]. 烟草科技, 2021,54(02):78-83.
DENG Chao, LIU Song, WANG Ludi, et al. A method for building an intelligent cigarette delivery model based on a deep neural network[J]. Tobacco Science and Technology, 2021,54(02):78-83.
- [3] 武牧, 林慧苹, 李素科, 等. 一种基于支持向量机的卷烟销量预测方法[J]. 烟草科技, 2016,49(02):87-91.
WU Mu, LIN Huiping, LI Suke, et al. A cigarette sales prediction method based on support vector machine[J]. Tobacco Science and Technology, 2016,49(02):87-91.
- [4] 韩伟民, 杨应广. 卷烟创新产品工商交易预测研究[J]. 中国烟草学报, 2022,28(01):115-122.
HAN Weimin, YANG Yingguang. Research on forecasting industrial and commercial transactions of cigarette innovative products[J]. China Tobacco Journal, 2022,28(01):115-122.
- [5] 吴明山, 王冰, 起亚宁, 等. 卷烟销量组合预测模型研究[J]. 中国烟草学报, 2019,25(03):84-91.
WU Mingshan, WANG Bing, QI Yaning, et al. Research on cigarette sales volume combination prediction model[J]. Acta Tabacaria Sinica, 2019,25(03):84-91.
- [6] Abadie A, Gardeazabal J. The economic costs of conflict: A case study of the Basque Country[J]. American economic review, 2003, 93(1): 113-132.
- [7] Abadie A, Diamond A, Hainmueller J. Synthetic control methods for comparative case studies: Estimating the effect of California's tobacco control program[J]. Journal of the American statistical Association, 2010, 105(490): 493-505.
- [8] 连玉君, 李鑫. 合成控制法中的安慰剂检验改进研究——基于准标准化转换的统计推断[J]. 统计研究, 2022, 39(8):14.
LIAN Yujun, LI Xin. Improvement of Placebo Test in Synthetic Control Method — Statistical Inference Based on Quasi-standardized Transformation[J]. Statistical Research, 2022, 39(8):14.
- [9] Abrell J, Kosch M, Rausch S. How effective is carbon pricing?—A machine learning approach to policy evaluation[J]. Journal of Environmental Economics and Management, 2022, 112:102589-.
- [10] GUO J, ZHANG Z. Does renaming promote economic development? New evidence from a city-renaming reform experiment in China[J]. China Economic Review, 2019, 57.
- [11] Prokhorenkova L, Gusev G, Vorobev A, et al. CatBoost: unbiased boosting with categorical features[J]. Advances in neural information processing systems, 2018, 31.
- [12] Liaw A, Wiener M. Classification and Regression by Random Forest[J]. R News, 2002, 23(23).
- [13] Ke G, Meng Q, Finley T, et al. Lightgbm: A highly efficient gradient boosting decision tree[J]. Advances in neural information processing systems, 2017, 30.
- [14] Graves A, Schmidhuber J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. Neural networks, 2005, 18(5-6): 602-610.
- [15] Gers F A, Schmidhuber J, Cummins F. Learning to forget: Continual prediction with LSTM[J]. Neural computation, 2000, 12(10): 2451-2471.

Research on new cigarette launch strategy based on synthetic control method and machine learning

MO Yuhua, TAN Qian*, GU Yue, DENG Chao, HUANG Feijie, XU Liangben

Internet Research Center, China Tobacco Guangxi Industrial Co., LTD., Nanning 530001, China

Abstract: At present, new product cigarette launch forecasts are hindered by short data intervals and significant fluctuations, limiting the use of traditional time-series models for new varieties. This paper innovatively combines the synthetic control method with machine learning to simulate and calibrate new cigarette varieties' sales trends using data from mature products. This paper takes 18 months of cigarette sales microdata in Yulin City, Guangxi as the research sample, and takes the new product Zhenlong (Haiyun Medium) as the research object. After processing the missing values in the data accordingly based on the random forest algorithm, the fitted weights of mature product cigarettes to new product cigarettes were calculated by the synthetic control method. The application effect test revealed that the LSTM model's prediction accuracy for new varieties was only 33.31%. In contrast, the Weighted Ensemble algorithm, enhanced with multiple machine learning models, achieved an accuracy of 88.56%. By fusing the synthetic control method with multiple machine learning models, we achieved an algorithm accuracy of 94.17%. This research overcomes limitations in predicting new variety cigarette sales and bridges the gap in new product launch models.

Keywords: cigarette delivery model; synthetic control method; machine learning; model fusion

*Corresponding author. Email: 371462268@qq.com