

浙江理工大学

Zhejiang Sci-Tech University

硕士学位论文

Master's Thesis



中文论文题目: 基于零售信息挖掘下面向消费市场的精准推送模型
设计与研究

英文论文题目: Design and research of precision push model based
on retail information mining to consumer market

学科专业: 信号与信息处理

作者姓名: 姚龙飞

指导老师: 何利力

完成日期: 2017 年 12 月 20 日

浙江理工大学学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得浙江理工大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名: 

签字日期: 2018 年 1 月 20 日

摘要

从海量的零售信息中提取有意义的数据为企业营销创造价值是众多企业共同需要解决的问题，然而面对海量数据如果仅仅采用传统的统计方法来分析不仅无法满足大数据环境下高效处理的要求，而且往往很难得到想要的结果，同时由于海量数据中存在的模糊性与不确定的表达将使得数据建模变得更加困难，也就无从开展精准推送营销，基于此本文从海量的零售数据中提取衡量客户价值的 RFM 模型指标，通过 RFM 模型指标提取客户特征属性构建用户画像标签，对用户画像标签的模糊性与不确定性通过云模型和本体思想来构建用户画像模型，从而实现面向消费市场的精准推送。具体研究内容如下：

（1）数据预处理：如何从海量的零售信息中提取用户的共同特征，本文从海量的零售信息数据库中按照分层抽样的思想随机抽取具有代表性的样本数据，在保证抽样数据符合标准格式要求的前提下，重点研究了在海量数据环境下如何实现最优分配以及如何对抽样性能评估，保证样本数据在一定条件下能够反映全量数据的整体全貌。

（2）用户画像标签处理：从抽样数据中提取 RFM 模型指标，针对抽样数据中该类指标的不确定性与模糊性的特点，本文引入云模型理论和本体技术，通过高斯云发生器将 RFM 指标转换为基于云模型的 RFM 指标（时间间隔云模型、消费频率云模型、消费金额云模型）来构建群体价值画像标签体系，通过本体思想对用户属性进行表示、解释和推理来构建用户个体画像标签体系。

（3）用户画像建模：用户画像力求借助用户个性化的标签来反映用户信息全貌，标签的选取直接影响用户画像的建模的成功与否，本文基于云模型的 RFM 指标构建用户价值画像模型，同时通过用户个体属性来构建个体用户画像模型。为了对云模型领域的用户画像聚类分析，本文对传统的 K-Means 聚类算法进行改进，设计了基于云模型的聚类算法。在该算法的基础上可以根据具体的业务场景得到不同的用户画像模型。

（4）精准推送阶段：通过云模型画像聚类对客户群体进行价值分类，建立群体与服务之间的关联，通过本体推理对零售户建立个体与产品之间的关联，实现由服务（群体）到产品（个体）的二级推荐。

关键词：云模型；用户画像；RFM 模型；K-Means 聚类；大数据抽样；本体

Abstract

It is a common problem for many enterprises to extract meaningful data from the massive retail information to create value for enterprise marketing. However, if we only use traditional statistical methods to analyze massive data, it can not meet the requirements of efficient processing in large data environment. and it is often difficult to get the desired results, at the same time, because of the fuzziness and uncertainty expression in mass data, it makes data modeling more difficult, so it is impossible to carry out the accurate push marketing. This paper extraction index RFM model to measure customer value from the retail data based on the extraction of customer attributes through the RFM model index to construct user portrait labels on user portrait label ambiguity and uncertainty by the cloud model and the ontology to construct the user portrait model, so as to achieve precise push for the consumer market. The specific research contents are as follows:

(1) Data sampling: how to extract the common features of users from massive retail information in the sample data, This paper randomly selects representative sample data from a mass retail information database according to the idea of stratified sampling. under the premise that the sampling data meet the requirements of the standard format, we focus on how to achieve the optimal allocation and how to evaluate the sampling performance in the mass data environment, and ensure that the sample data can reflect the whole panorama of the total data under certain conditions.

(2) User portrait label processing: In view of the uncertainty and fuzziness of the class index in the sampling data, this paper extract RFM model index from sampled data and introduces the theory of cloud model and the ontology technology. The cloud of Gauss generator is used to transform RFM index to RFM index based on cloud model (the cloud model of time interval, the cloud model of consumption frequency and the cloud model of consumption amount) to build group value portrait labeling system. The user attributes are expressed, explained and reasoning through the ontology idea to construct the user's personal portrait label system.

(3) User portrait modeling: User portrait seeks to reflect the full information of the user by the user's personalized label, the selection of the label directly affects the success of the modeling of the user's portrait. Based on the RFM index of cloud model, this paper constructs customer's portrait model of customer value, and constructs personal user portrait model by user's personal

attribute. In order to cluster analysis of user portrait in cloud model field, this paper improves the traditional K-Means clustering algorithm and designs a clustering algorithm based on cloud model. On the basis of this algorithm, different user portrait models can be obtained according to the specific business scene.

(4)Precise push stage: Using the image of cloud model clustering to classify customer groups and establish the association between group and service, Through ontological reasoning, it establishes the association between the individual and the product, and realizes the two level recommendation from the service (Group) to the product (individual).

Keywords: Cloud model;User portrait;RFM model; K-Means clustering; Large data sampling; Ontology

目 录

摘要	I
Abstract	II
第一章 绪论	1
1.1 研究背景及研究意义	1
1.1.1 研究背景	1
1.1.2 研究目的及意义	1
1.2 国内外研究及发展现状	2
1.3 主要研究内容	4
1.4 论文框架	5
第二章 理论基础和相关概念	6
2.1 云模型理论基础和相关概念	6
2.1.1 云模型的定义	6
2.1.2 云模型相关概念	6
2.2 RFM 模型理论基础和相关概念	9
2.2.1 RFM 模型相关概念	9
2.2.2 基于 RFM 客户细分应用概述	11
2.3 本章小结	12
第三章 基于海量数据的抽样研究	13
3.1 海量数据抽样研究概述	13
3.2 海量数据背景下的抽样方法比较	14
3.3 基于海量数据背景下的分层抽样设计	16
3.3.1 确定分层标志和界限	16
3.3.2 如何确定分层的层数	20
3.3.3 选择什么样的样本分配方法	21
3.4 本章小结	23
第四章 基于云模型与本体的用户画像分析与研究	24
4.1 用户画像研究概述	24
4.1.1 用户画像定义	24
4.1.2 用户画像标签体系	24
4.2 用户画像建模分析与研究	25
4.2.1 用户定量画像	25
4.2.2 基于本体的用户定性画像	26
4.2.3 基于云模型的用户定性画像	28
4.3 群体用户画像分析与研究	30
4.3.1 基于 RFM 模型的用户价值画像创建流程	30
4.3.2 用户画像标签存储分析	32
4.3.3 云模型聚类分析	36
4.4 本章总结	38

第五章 零售信息挖掘下的推送模型设计与案例分析.....	39
5.1 推送模型架构分析.....	39
5.2 海量零售信息处理案例分析.....	40
5.2.1 数据说明.....	42
5.2.2 抽样过程.....	42
5.3 用户画像建模案例分析.....	45
5.3.1 云模型用户价值画像模型构建过程.....	45
5.3.2 用户个体画像模型构建过程.....	48
5.4 云模型画像聚类与本体推理案例分析.....	51
5.4.1 基于云模型的用户价值画像聚类案例分析.....	51
5.4.2 基于本体推理的用户个体画像案例分析.....	55
5.5 精准推送模型应用分析.....	57
5.6 本章小结.....	59
第六章 总结与展望.....	60
6.1 本文工作总结.....	60
6.2 不足与展望.....	61
参考文献.....	62
致谢.....	65
攻读学位期间的研究成果.....	66

第一章 绪论

1.1 研究背景及研究意义

1.1.1 研究背景

现代营销模式的重心已经逐渐从传统的线下模式转型到线上模式，也即网络营销。网络营销的优势在于能够给企业提供直接面向消费者的平台，通过该平台企业不仅降低了运营成本，而且企业也可以从平台获得大量的零售信息^[1]。随着大数据时代的到来以及计算机技术和网络技术的飞速发展，各企业积累了用户大量消费数据，很多领域和行业开始意识到数据是贯穿整个营销过程的始末，其对营销的效果起着至关重要的作用，因此如何利用用户的行为数据以及如何利用大数据思维对用户开展精细化营销成为了企业在激烈的市场竞争环境下立于不败之地的最强有力的后盾。企业之间已经突破了传统商业模式的竞争，越来越重视数据的潜在价值，纷纷朝着智慧性方向转型发展，但由于网络空间开放与信息自由的特点，信息超载伴随互联网时代而降临。2017年8月4日中国互联网络信息中心（CNNIC）在京发布第40次《中国互联网络发展状况统计报告》，该报告显示，截止到2017年6月，中国网民规模达到7.51亿，半年共计新增网民1992万，半年增长率为2.7%，占全球网民总数的五分之一。同时我国互联网普及率为54.3%，超过全球平均水平4.6个百分点^[2]。在互联网技术应用大面积普及和现代移动终端快速发展的背景下，网络在给网民带来了便利的同时，也传播了大量无意义与繁杂的信息。Google、百度等搜索引擎的出现为网民检索互联网上的信息提供了便利的方式，极大的提高了网络信息的利用价值。对企业而言，尤其是随着亚马逊、阿里巴巴等电子商务巨头数据营销体系的成熟，基于大数据营销战略的关注度越来越高，并且被大多数企业应用。

在此背景下，本文将从海量的零售信息中挖掘用户的价值模型作为出发点，来探讨消费市场环境下如何从海量零售信息中抽样数据，并利用这些样本数据建立用户画像模型来指导企业针对不同用户群体开展精准推送的个性化营销。

1.1.2 研究目的及意义

目前，众多领域已经进入互联网和大数据普及的时代，网络营销应运而生，网络营销不仅为企业搭建了直接面对消费者的平台，同时也为企业提供了获取消费数据最直接的途径。企业手中拥有大量的数据，这些数据无论在规模、复杂程度以及技术支持上都对大数据营销的企业提出了新的要求，企业如何利用历史沉淀的数据来为企业的营销做出决策是众多企业转型大数据营销模式的关键，因此本文希望通过针对当前时代背景，对大数据营

销展开分析,将主要围绕如何破解企业转型大数据营销开展相应的研究。

其次本文将人工智能领域的定性定量转换的认知模型——云模型与用户画像结合构建适用于大数据营销模式下客户价值的用户画像模型,通过具体的模型进行案例分析,使得本文的研究更加具体和生动。同时,大数据营销作为新型的营销模式,不仅为众多互联网企业提供了客户价值分析的参考模型,也为那些即将转型大数据营销的企业提供发展之道。

此外,本文的研究内容不仅从理论上对传统的精准营销策略展开论述和验证,而且对大数据营销的企业具有实践指导意义。本文选取客户关系管理分析模式中的 RFM 模型,提取客户关系管理数据库中最普遍的三个指标(最近一次消费,消费频率,消费金额)作为建模分析的起点,由于该指标具有普遍性,因而各企业可以针对指标的内涵和特点结合具体的业务场景展开具体的分析和建模。

1.2 国内外研究及发展现状

纵观国内外关于面向消费市场的精准推送模型主要从以下几个方面展开研究。

- (1) 基于情感分析的信息推荐
- (2) 电子商务个性化推荐
- (3) 基于用户画像的个性化推荐
- (4) 基于机器学习的个性化推荐

在基于情感分析的信息推荐的相关研究中,Rao 等^[3]通过词极性检测问题的研究,提出了基于图的半监督学习方法对词极性进行转换,实现了根据词语义倾向的模糊推荐。王莉^[4]提出了一种基于情感标签的改进的协同过滤算法,从用户评论数据中自动抽取情感标签,结合情感标签和评分数据共同产生推荐结果,来缓解传统协同过滤算法的稀疏和冷启动问题。夏明星^[5]提出一种融合情感词频和主题维数拓展的方法,利用主题维度拓展和情感词频进行特征提取,用 LIBSVM 进行分类,得到自动判别评论的情感极性,使用户通过评论极性分类直观的发现其他用户的反馈。刘莉平^[6]针对在浏览微博过程中无法判断问题的客观性时,提出了一种描述公众反馈信息的属性——争议度,给出了争议度的概念并构建了争议度计算模型。何炎祥^[7]针对微博表情符号语义提出用于微博情感分析的一种情感语义增强的学习模型,有效增强了 MCNN 捕捉情感语义的能力。

在电子商务个性化推荐的相关研究中,Huang Z 等^[8]对协同过滤算法在电子商务领域个体隐私容易泄露的问题提出了 three algo-rithms 来解决如何从稀疏性的推荐数据库中筛选敏感词汇,实现对用户隐私的保护。曹俊^[9]针对基于 LBS 个性化推荐研究均使用地理位置情境的问题提出抵达时间、用户状态概念以具体化用户位置情景(分解为用户抵达时间、天

气和用户状态三种情境信息并纳入个性化推荐),分别分析用户抵达时间、天气和用户状态三种情境下用户信息需求并制定相应个性化推荐算法。郭燕萍^[10]提出一种基于 LBS 的 O2O 电子商务个性化推荐系统架构,并在此基础上提出了一种基于 LBS 的 O2O 电子商务个性化推荐的方法和思路,来提高 O2O 电子商务中个性化推荐的效率。

在用户画像的相关研究中, Jiang L 等^[11]研究了在线健康社交网站用户相似性的测量方法,通过向消费者推荐类似的用户,来帮助他们以更有效的方式寻求信息和情感上的支持。Chen G 等^[12]建立个体指纹与基因之间的关联,使用基于 spark 框架的图形处理单元尝试从基因的角度精确的建立人体健康信息档案来反映用户信息全貌。陈志明等^[13]构建了基于用户基本属性、社交属性、兴趣属性和能力属性四个维度的动态用户画像模型,并对“知乎”网站 PM2.5 话题下 1303 位用户进行了实证分析;姜建武等人^[14]在大数据理论上提出构建行为-主题、主题-词汇及行为-词汇三位一体的数学模型,来研究基于用户画像的信息本体提取方法.采用包含对象、时间、地点、内容、行为和重返次数六方面内容的事件描述法计算本体权重,以此构建用户画像。MYH Al-Shamri^[15]在研究众多人口推荐系统方法(DRS)的基础上根据用户属性类型、属性表示和分析方式对用户进行分析,并对每种方法的布局、描述和适当的相似性计算方法进行了相关研究,为用户画像中难以提取的用户隐私的指标找到了一种可替代方案。

在基于机器学习推荐的相关研究中,麻省理工学院的 Lieberman^[16]根据用户的兴趣模型实现了 Letizia 算法来为用户搜索提供辅助的智能推荐,从而为用户提供个性化的页面资源,提高了用户个性化搜索体验度。Kunal Thakkar 等^[17]使用数据集的支持向量机(SVM)和随机森林(RF)来进行深度学习,通过机器学习来根据客户的属性制定有效和精准的葡萄酒推荐决策。吕伟民等^[18]构建加权作者合作网,以不同的链路预测指标作为特征输入,运用极端随机树(Extremely Randomized Trees,ET)机器学习算法训练分类,并利用遍历算法求取分类结果的最优权重组合,选取 TOP 准确度的预测作为合作推荐结果,来提高单独基于链路预测方法的推荐精确度。Brbić 等^[19]针对用户特征属性的多值与连续的问题分别提出了贝叶斯分类器和决策树分类器的算法来解决该类问题,最后,结合基于内容的贝叶斯分类算法与协同过滤的 k-均值聚类算法的推荐算法分别对电影推荐任务的性能作出评估。实验结果清楚地表明,与协同过滤相比,混合方法显著提高了推荐精度,同时降低了过度规范的风险。

目前,随着人工智能,智能信息处理技术的不断发展,以机器学习和用户画像技术为代表的个性化推荐系统逐渐走进了人们的视野,现在国内较大的公司如 A 和今日头条等,

都在广泛使用机器学习来构建推荐系统。传统的协同过滤、tag、和各种你能看懂的基于规则或者群体智能甚至物理学的传统推荐方法在逐渐被淘汰^[20]。这点在内容推荐上尤其明显，因为这些传统推荐策略都无法解决对长尾内容的精细化个性化推荐和热度穿透等问题，而且效果上也远远不如机器学习方法。

在用户画像领域，尤其是在视频推荐领域得到了广泛的应用，其中一个主要原因是，用户画像是一种能够将定性方法与定量方法完美结合在一起的载体，定性化的方法，通过对用户的生活情景、使用情景、用户心智进行分析来对用户的性质和特征做出抽象与概括；定量化可以对特征做精细的统计分析与计算，获得对于用户较为精准的认识，便于在数值排序的基础上实现核心用户的挖掘与突出。在不确定性人工智能研究领域，以李德毅院士为代表的云模型理论围绕不确定性人工智能的数学基础、特征、表示、模型、推理机制、不确定性思维活动中的确定性，以及语言文字中不确定性的形式化表示问题等进行了研究^[21]。用户画像领域与人工智能的云模型领域的融合交汇将会是面向消费市场精准推送的又一个突破点。

1.3 主要研究内容

本文主要是对基于零售信息挖掘下面向消费市场的精准推送模型展开研究，通过阅读大量的国内外参考文献，分析了面向消费市场的精准推送模型的国内外研究与发展现状，针对零售信息所体现的数据量大的特点，本文在数据处理部分重点研究了在海量数据环境下抽样的相关理论和方法，最终得出传统统计学的抽样方法在大数据处理领域存在的必要性和实践价值。针对零售数据定性和非语义化特点，本文引入云模型理论和本体技术，构建基于 RFM 的用户价值画像模型和用户个体画像模型。建立从面向群体的服务到面向个体的产品的二级精准推荐体系，基于此，本文将从以下几个方面展开研究。

（1）海量数据环境下的抽样研究：该部分对传统统计学中的分层抽样做了重点分析和研究，分别从如何确定分层界限、如何确定分层层数和如何选择样本分配方法来研究如何在海量数据环境下对数据进行抽样。

（2）构建用户价值画像标签体系：样本以结构化的数据形式存储在关系型数据库中，从抽样数据中提取 RFM 模型指标，针对抽样数据中该类指标的不确定性与模糊性的特点，本文引入云模型理论，通过高斯云发生器将 RFM 指标转换为基于云模型的 RFM 指标（时间间隔云模型、消费频率云模型、消费金额云模型），同时根据云模型标签数据结构设计基于云模型的存储结构模型。

(3) 构建用户个体画像标签体系：个体画像旨在构建个体与产品之间的关联，通过对零售户的消费行为标签进行本体构建，来实现标签语义化的转变，让计算机具有语义识别功能。通过本体推理机制来实现个体（类）与产品（类）之间的关联，来实现具体产品（实例）到个体（类）精准推荐。

(4) 用户画像建模：用户画像分定量画像和定性画像，仅仅依靠定量或者定性画像无法全面精准的刻画用户，而云模型是定性与定量转换的认知模型，将云模型与用户画像结合将会对为精准客户用户画像提供理论支持，本文采用基于云模型的 RFM 指标构建客户价值的用户画像模型。对传统的 K-Means 聚类算法进行改进，设计了基于云模型的聚类算法，通过该算法对用户画像模型聚类分析。根据具体的业务场景得到不同的用户画像模型。

1.4 论文框架

本文共分为 6 个章节，个章节的主要研究内容如下所示：

第一章 绪论，介绍了本文选题背景以及研究目的及意义，并对国内外发展现状进行了分析。

第二章 本章分别介绍了云模型理论和 RFM 模型，为后文的研究打下基础。

第三章 本章首先对海量数据环境下抽样研究的必要性做了系统分析，然后通过对比不同的抽样方法来选择最适合海量数据环境下的抽样方法，最后重点分析和研究了分层抽样理论在海量数据环境下如何来确定分层标志和界限、分层层数和样本分配方法的三个问题。

第四章 本章首先利用云模型理论与 RFM 模型来构建用户价值画像模型，通过知识工程与本体来构建用户个体画像模型。然后分别根据以上两种模型的数据结构来设计存储模型及存储方案。最后通过改进的 K-Means 算法来对云模型用户画像进行聚类分析。

第五章 本章首先分析了精准推送模型的系统架构，然后按照系统架构的模块分层，结合具体案例进行实验验证和分析。

第六章 本章总结了本文所做的工作，以及针对本文不足之处，展望了未来需要改进和研究的方向。

第二章 理论基础和相关概念

2.1 云模型理论基础和相关概念

云模型是描述不确定问题的一种方法,该理论受启发于模糊集理论中的隶属函数思想,但该理论不能简单的看作随机加模糊、模糊加随机、二次模糊或二次随机等,该理论最早是由李德毅院士提出,是定性与定量转换模型,这种方法分析的结果很直观,能够实现定性概念与其数值表示之间的不确定性转换,清晰的分析出所需求的目标.其中正态云是云模型中最重要的模型,具有普适性^[22],已经在许多领域有很多成熟的应用^[23,24].

2.1.1 云模型的定义

设 U 是用数值精确表示的一个定量论域, C 是 U 上的一个定性概念,若定量值 $\chi \in U$, χ 是定性概念 C 的一次随机实现, χ 对 C 的确定度 $\mu(\chi) \in [0,1]$ 是有稳定倾向的随机数满足

$$\mu: U \rightarrow [0,1] \quad \forall \chi \in U \quad \chi \rightarrow \mu(\chi)$$

则 χ 在论域 U 上的分布称为云,每一个 χ 称为一个云滴^[25]。

2.1.2 云模型相关概念

(1) 云模型的数字特征

云模型用期望 Ex , 熵 En , 和超熵 He 三个数字特征来整体表示一个定性概念。

期望 Ex : 定性概念的基本确定性度量,是云滴在论域空间分布的均值(数学期望).通俗的说,就是最能够代表定性概念的点或者是该定性概念的重心。

熵 En : 表示定性概念的不确定性度量,在云图上反映的是云的厚度,它是由概念的模糊性和随机性共同决定.一方面,熵是定性概念随机性的度量,反映了能够代表这个定性概念的云滴离散程度;另一方面,又是隶属于这个定性概念的度量,决定了论域空间中可被概念接受的云滴确定度。

超熵 He : 表示熵的熵,指熵不确定的度量,在云图上反映云滴的凝聚度.对于一个定性概念,被普遍接受的程度越高,超熵越小,在云图上云滴比较聚集;对于难以形成共识的概念,超熵则比较大,在云图上云滴比较离散。

(2) 云发生器的概念

本文研究云模型中最重要的模型——高斯云模型,其中高斯云发生器分为正向正态高斯云发生器和逆向正态高斯云发生器。

其正向高斯云定义如下:

设 U 是一个用精确数值表示的定量论域, $C(Ex, En, He)$ 是 U 上的定性概念, 若定量值 $X(X \in U)$ 是定性概念 C 上的一次随机实现, 服从以 Ex 为期望, En'^2 为方差的高斯分布 $X \sim N(Ex, En'^2)$, 其中 En' 是服从以 Ex 为期望, He^2 为方差的高斯分布 $En' \sim N(En, He^2)$ 的一次随机实现, X 对 C 的确定度满足

$$\mu = e^{-\frac{(X - Ex)^2}{2(En')^2}}$$

则 X 在论域 U 上的分布称为高斯云^[26]。

根据正向高斯云的定义以下给出正向高斯云算法描述和步骤^[27]。

输入: 表示定性概念 C 的三个数字特征 (Ex, En, He) , 生成云滴的个数 N 。

输出: N 个云滴的定量值, 及其确定度 μ 。

算法步骤:

- 1) 生成以 En 为期望值, He^2 为方差的一个高斯随机数 $En_i = \text{NORE}(En, He^2)$;
- 2) 生成以 Ex 为期望值, $(En_i)^2$ 为方差的一个高斯随机数 $x_i = \text{NORE}(Ex, (En_i)^2)$;
- 3) 计算 $\mu_i = e^{-\frac{(x_i - Ex)^2}{2(En_i)^2}}$;
- 4) 具有确定度 μ_i 的 x_i 成为数域中的一个云滴;
- 5) 重复步骤 1) 到 4), 直至产生 N 个云滴。

正向高斯云发生器的运行机理如图 2.1 所示




图 2.1 正向高斯云发生器

逆向高斯云则完全相反, 逆向高斯云算法实现从样本数据集合到表示定性概念的数字特征 (Ex, En, He) 的转换, 是正向高斯云的逆向算法。逆向高斯云算法是基于统计的矩估计来实现的, 利用矩估计的一阶原点来估计期望, 利用二阶样本中心矩来估计方差。根据逆向高斯云的实现原理以下给出逆向高斯云算法描述和步骤。

输入：样本点 x_i ，其中 $i=1, 2, \dots, n$

输出：反映定性概念的数字特征 (Ex, En, He)

算法步骤

1) 计算 x_i 的平均值

$$Ex = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{公式 2-(1)}$$

2) 计算样本一阶绝对中心矩

$$\frac{1}{n} \sum_{i=1}^n |x_i - Ex| \quad \text{公式 2-(2)}$$

3) 计算样本二阶中心矩

$$S = \frac{1}{n-1} \sum_{i=1}^n (x_i - Ex)^2 \quad \text{公式 2-(3)}$$

4) 计算

$$En = \sqrt{\frac{\pi}{2}} * \frac{1}{n} \sum_{i=1}^n |x_i - Ex| \quad 0 < He < \frac{En}{3} \quad \text{公式 2-(4)}$$

5) 求

$$He = \sqrt{S - En^2} \quad \text{公式 2-(5)}$$

逆向高斯云发生器的运行机理如图 2.2 所示




图 2.2 逆向高斯云发生器

(3) 综合云

定义：将两个及以上具有相同属性特征的云模型进行综合，得到一个高层次的云模型，叫做综合云^[28]。

公式：设在论域 U 中有 b 个同类型子云，分别为

$$C_1(Ex_1, En_1, He_1), C_2(Ex_2, En_2, He_2), \dots, C_b(Ex_b, En_b, He_b)$$

则综合云表示为

$$Ex = \frac{\sum_{k=1}^b Ex_k * En_k}{\sum_{k=1}^b En_k} \quad \text{公式 2-(6)}$$

$$En = \sum_{k=1}^b En_k \quad \text{公式 2-(7)}$$

$$He = \frac{\sum_{k=1}^b He_k * En_k}{\sum_{k=1}^b En_k} \quad \text{公式 2-(8)}$$

其中 Ex_k En_k He_k 分别为各子云的数字特征。

(4) 云模型相似度

定义: 任意具有相同属性特征的云模型的相似程度叫云模型相似度^[29], 采用余弦相似度来定量表示

公式: 设在论域 U 中任意 2 个同类属性云为 $U_{ik}(Ex_{ik}, En_{ik}, He_{ik})$, $V_{jk}(Ex_{jk}, En_{jk}, He_{jk})$ 则有

$$Sim(U_{ik}, V_{jk}) = \cos(U_{ik}(Ex_{ik}, En_{ik}, He_{ik}), V_{jk}(Ex_{jk}, En_{jk}, He_{jk})) = \frac{U_{ik}(Ex_{ik}, En_{ik}, He_{ik}) \cdot V_{jk}(Ex_{jk}, En_{jk}, He_{jk})}{\|U_{ik}(Ex_{ik}, En_{ik}, He_{ik})\| * \|V_{jk}(Ex_{jk}, En_{jk}, He_{jk})\|} \quad \text{公式 2-(9)}$$

2.2 RFM 模型理论基础和相关概念

RFM 模型是由美国数据库营销研究所 Arthur Hugched(1994) 提出, 是用于衡量客户价值和客户创利能力的重要工具和手段, RFM 模型由客户数据库中的三个指标组成, 分别是最近一次消费(Recency)、消费频率(Frequency)、消费金额(Monetary). 围绕 RFM 指标, 企业可以从客户群体中工具客户的价值重新分类客户, 针对不同价值的客户群体精准推送相应的服务, 使其推送的服务符合科学营销应用的需要^[30]。

2.2.1 RFM 模型相关概念

最近一次消费(Recency)

最近一次消费时间表示顾客最近一次购买时间和分析时间点间隔的天数。当顾客最近一次购买时间离下一次购买时间间隔比较近, 就可以认为该顾客重复购买的可能性比较大, 该顾客最近一次消费的指标项分数便较高, 对应该顾客的价值也就越高, 所以企业应该关注此类顾客群。及时准确度把企业相关商品和活动的消息推送给该群体, 通过该指标对顾客分析能够做到以最小的投入换来更大的回报, 提高企业的经营业绩^[31]。

消费频率(Frequency)

购买频率表示计算期内顾客购买产品或者服务的次数, 一般来说, 统计期内购买次数高的顾客, 企业就有理由相信该顾客忠诚度高, 顾客价值大, 反之顾客忠诚度低, 顾客价值小。

消费金额(Monetary)

消费金额表示计算期内顾客的购买总额，一般来说，统计期内顾客在企业的消费金额越高，该顾客对企业来说更具有价值。

RFM 模型不仅能够对客户价值分析，还对客户进行分类，对客户分类主要有三种建模方法：

1) Hughes 构建的 RFM 模型：Hughes 在研究 RFM 模型时，对 R、F、M 指标进行一定的处理，其认为这三个指标对客户价值评价的重要性是一致的，因此，当时并没有对这些指标赋予相应的权重。基于这样的假设，Hughes 从顾客消费记录中提取最近一次消费、消费频率、消费金额，然后按照由大到小，由多到少的顺序进行排列，按顺序分成五份，对于每项指标的前百分之二十的顾客赋予 5 分，百分之二十到百分之四十的顾客 4 分，百分之四十到百分之六十的顾客 3 分，百分之六十到百分之八十 2 分，最后一部分 1 分，如表 2.1 所示。分值越高，代表该顾客价值越高。

表 2.1 Hughes 构建的 RFM 模型指标处理

RFM 模型 指标排名	(最近一次消费)R	(消费频率)F	(消费金额)M
前 20%	5	5	5
前 20%-40%	4	4	4
前 40%-60%	3	3	3
前 60%-80%	2	2	2
前 80%-	1	1	1

2) Stone 构建的 RFM 模型：stone 在研究 RFM 模型时，对 RFM 模型的三个指标分别处理如下：对 R 值处理是将一年的时间段按照每三个月划分为四个阶段，并给每阶段赋予相应的分值，同时为了避免 F 偏小和 M 偏大，将 F 值扩大四倍，M 值为原值的 1/10 处理，最后将三个变量总和作为 RFM 值，如表 2.2 所示。同时根据具体的场景和业务需求设置相应的 RFM 阈值来划分客户，得到不同价值的客户群。

表 2.2 Stone 构建的 RFM 模型指标处理

RFM 指标	指标分数	指标权重
最近一次消费时间	最近三个月 24 分 最近 3-6 个月 12 分 最近 6-9 个月 6 分 最近 9-12 个月 3 分 12 个月以上 0 分	中
购买次数	购买次数*4	高
购买金额	购买金额*10% (最高 9 分)	低

3)Sung 构建的 RFM 模型:Sung 提出利用 SOM 自组织特征映射网络对客户的 RFM 变量分类,然后比价各类别的 RFM 平均值以及所有客户的 RFM 总平均值,单个指标对比有大于或者小于均值两种可能的结果,共分为八类,根据指标的变化观察顾客的变化规律,判断客户类型。刘朝华等同样根据 SOM 客户分类方法采用 RFM 指标分类,在 Sung 基础上计算每类客户的价值排序模型,该模型能够提供更加准确的客户信息,具有广泛的应用。对 Sung 构建的 RFM 模型可以在三维象限图中清晰直观的描述,其中,X 轴表示 Recency,Y 轴表示 Frequency,Z 轴表示 Monetary,坐标系的 8 个象限分别表示 8 类客户。如图 2.3 所示




图 2.3 客户分类三维图

2.2.2 基于 RFM 客户细分应用概述

翻阅众多关于 RFM 文献,改进的 RFM 最终实现的是对客户价值更精准的分析 and 评价,主要从以下几个方面开展研究:

1) 建立基于 R、F、M 指标的转换模型

2) 建立 RFM 模型的评估算法

张继燕^[32]在构建网络消费者价值识别模型时,考虑到传统的 RFM 模型仅仅是站在企业的角度来评价客户的价值度,而仅仅通过企业评价的方式不足以满足高速发展的互联网企业客户关系管理需求。针对此问题,该文在 RFM 模型的基础上引入能够用来衡量网络消费者的感知价值指标,既客户价值满意度指标 S,构建新的客户价值评价模型 RFMS,也就是利用新的 RFMS 模型来代替 RFM 模型。

明勇等^[33]针对通过零售数据进行客户分群是传统的 RFM 模型未考虑商品价值问题,提出用 RFM 表达交易数据的方法(RFMPT)。该方法的实现是在传统的 RFM 模型基础上将购买的商品和商品类别组成一颗 RFM 树结构,借助树的结构和特点提出了基于 RFM 树的快速聚类算法。

Peiman Alipour Sarvari 等^[34]针对人口因素与 RFM 模型对客户价值评价方式遭到质疑时提出在不考虑人口因素的前提下可以利用加权 RFM(WRFM)和 RFM 值/成绩对客户群体价值进行分类,通过 Apriori 算法提取关联规则,对场景进行性能分析。通过分析得到借助于权重的 RFM(WRFM)可以获得更加精确的客户价值分类。

以上的对 RFM 模型改进的方案都体现出一个共同特点,即 RFM 模型的建立是基于具体的业务场景,任何基于传统的 RFM 的优化和改进都是在具体的业务场景下开展的。基于此本文将在 RFM 模型基础上提出一种新型的通用客户价值评价模型,实现客户价值模型的建立不依赖与具体的业务场景。即本文提出的基于云模型理论的 RFM 模型,将在本文第四章介绍。

2.3 本章小结

本章详细介绍了云模型的概念、理论和相关算法,为后文云模型用户画像建模提供理论基础,同时本节对 RFM 模型的概念做了详细阐述,并对基于 RFM 模型的客户分类展开了论述,为后文客户价值分类提供模型基础。

第三章 基于海量数据的抽样研究

3.1 海量数据抽样研究概述

在《大数据时代：生活、工作与思维的大变革》一书中提出：在大数据分析和应用中，不应关注如何使用抽样技术，而应通过大样本数据来分析总体。以往采取抽样的方法是因为无法对总体直接分析和预计，当拥有足够的数据时，是不是就可以抛弃抽样了呢？进入大数据时代，学术界对抽样方法的用武之地开始产生了质疑。

本文认为在大数据时代大数据分析和传统的抽样是共生共存的。

首先抽样数据能够克服计算资源和数据可获得性的障碍。虽然我们已经进入了大数据时代，但现有的计算资源和技术仅仅被部分企业所掌握，对于大多数企业来说并没有足够的计算资源来处理和分析大规模的数据。

其次，是否需要抽样应该取决于我们需要解决的问题，抽样的目的是通过对抽样样品的分析和研究来估计和推断总体的特征。如果是以概括总体为目标，那么可以采用抽样的方式来分析样本。如果是以分析群体用户中的每一个个体特征为目标，那么可以采用大数据样本的方式分析群体用户中的个体特征。

最后，在计算资源和技术能达到处理大规模数据的情况下，使用抽样来代替大数据分析可以节约成本。大数据分析主要围绕如何处理海量数据的计算和海量数据降维而展开，在大数据应用的过程中如果能采用小样本分析会节省一大笔成本开销，从效率和成本角度考虑，适当的抽样是非常有必要的，同时，抽样也是矫正杂乱的、非标准数据源的重要方法。因此，在做大数据分析时，可以先对总体数据抽样处理，然后再利用大数据的相关算法对样本数据分析和建模等。

总而言之，在传统的数据统计分析中，通常是通过抽样调查的方法从总体中获取统计分析的样本数据，而其中的抽样设计方法是整个调查中最核心和关键的步骤，其抽样的样本数据质量直接影响对整体的认知和把握。随着信息化技术水平的进步，虽然我们有更多的渠道和途径去获取和处理海量数据的能力，但这些数据本质上依然是总体数据的一个映射，通过传统的统计来获取总体的信息是一种有效的方法，也是进入大数据时代对数据分析的一个补充。因此，我们有理由认为，进入大数据时代传统的抽样调查是不可或缺的一种分析方法。

3.2 海量数据背景下的抽样方法比较

抽样调查是一种选择全量数据对象的样本进行分析的常用方法。在数据挖掘中，使用抽样的算法可以降低分析的数据样本，提高样本数据的质量，节省数据挖掘算法的开销。常用的抽样调查方法如图 3.1 所示，下面对几种常见的抽样策略简单介绍一下。




图 3.1 常用的抽样调查方法

1) 简单随机抽样：将所有调查总体编号（1-M），直接从总体 M 中抽取包含 m 个个体组成的样本. 通常是指不放回简单随机抽样。

优点：操作简单易行。缺点：如果分析的总体是海量数据，工作量太大。

2) 分层随机抽样：将一个包含有 M 个单位的总体分成 K 个子集，且这些子集之间不会相互重叠，保证每一个单元必属于且仅属于其中的一个子集，每一个子集内的单元具有相同的性质。根据一定的比例从每一个子集中分别独立的进行简单的随机抽样，将抽样得到的个体综合在一起，组成一个完整的样本即为分层抽样。分层抽样适用于总体情况比较复杂，单位数量较多以及内部差异较大的情况，并且可以确保每一个子集中都有单元入选随机抽样的样本。

优点：充分保证样本结构与总体的一致，提高了样本的代表性;提高了参数估计精度

缺点：整体差异不明显是不适用，在使用时需要与其它抽样方法综合使用。

3) 系统抽样：将总体按某一顺序分成均衡的 n 个部分，然后按照预定的规则从每部分随机抽取一个或者一组观察单位，直到抽满 n 个为止。

优点：易于理解、简单便行。

缺点：总体有周期或增减趋势时，易产生偏差。

4) 便利抽样：又称方便抽样，是指调查者在抽取样本时依据方便的原则，以最大限度降低调查成本的目的。

优点：操作简单，可及时获取调查者所需要的信息，降低调查成本。

缺点：样本的信息无法说明总体的状况，无法通过获取的样本信息对总体进行数量特征的推断，因而便利抽样获得的样本不适合描述性研究和因果关系研究。

通过对以上各抽样方法优缺点分析和比较，抽样调查在大数据环境下的不足主要体现在三个方面，第一点是存在不可避免的误差，第二点是抽样样本中子集中的数据单元过少，第三点是获取数据的周期比较长。同时，在面向大数据分析统计时，我们也需要弄清楚大数据分析所面临的挑战和困难，通过探研和分析这些困难和挑战，来从传统统计学抽样中找出解决方法。首先，数据是大数据分析的源泉，在进行大数据分析时必须要有一定量的数据做基础，也就是说大数据分析过程是从单纯的数据出发，而分析的结果往往是缺乏先验信息做参考的，这种分析过程是称作“冷启动”。通常，在大数据分析的数据收集与整理阶段往往是无状态的，因此这个阶段无法获取显著的先验分布信息。而基于传统的统计学在采集数据时是根据实验设计的理念而针对性的搜集具有明确倾向的数据，也就是有状态的搜集过程^[35]。其次，大数据分析传统的统计分析的目的是不同的，大数据分析的目的在于从数据中发现一些有趣的特征或者模式，实现数据的深度挖掘，辅助决策者做出更加科学、精确、合理的决策。第三，大数据之所以为“大”，在于数据量大，但数据量大并不等同于有用的信息量就大，相反随着信息的爆炸式增长，数据量也呈现出爆炸式增长，数据的形式也多样化，这就导致数据中所含的信息量相对较少。也就是大数据所面临的“稀疏性”问题。此外在大数据建模阶段还面临数据存储、高维、时间序列特性等亟待解决的问题，而对于所处理数据集规模较小时，这些问题将得到极大的缓解甚至不再是困扰数据建模的问题。正因如此，在大数据分析面临挑战和瓶颈时，传统的统计学抽样领域将大有可为。

另一方面，在海量数据的前提下，大数据分析提倡数据为先，这些数据可能是毫无意义的垃圾数据，如果大数据分析是以垃圾数据为主导的，那么分析的结果必然是没有价值的，因而对数据分析过程以前的预处理缺乏科学的指导^[36]。而统计学中的统计抽样提倡的是科学为先，从这个角度来说，随机抽样为大数据分析的预处理阶段提供了最直接的理论分析基础。同时由于抽样在大数据环境下所存在的弊端，使得传统统计学中的抽样方法的功能发生了改变，其并不能直接的从海量数据中抽取有用的信息，而是加速大数据分析建模的过程，使大数据分析能够更快更准确的发现一些有趣的特征或者模式。基于此本章的定位是在大数据分析环境下，为了节约计算资源，通过统计学的统计抽样方法来减少样本的数据量，同时又能够得到良好的响应结果来反映总体的特征。

综合分析和比较各抽样方法的优缺点,在海量数据环境下,总体规模比较大,简单的随机抽样可能存在样本单元对总体代表性不高的情况,从而对估计精度产生影响,同时对大规模总体进行简单的抽样,样本也可能存在调查难度较大等问题。而非概率抽样因无法通过获取的样本去反映总体的信息,因此并不适合在大规模数据环境下使用。为了克服上述抽样不足之处,本文将以概率抽样中的分层随机抽样为原型,在海量数据环境下改进分层随机抽样技术,并对其性能进行研究。

3.3 基于海量数据背景下的分层抽样设计

要实施一项完整的分层抽样需要解决以下几个问题:

- (1) 选择什么样的样本分配方法
- (2) 如何确定分层标志和分层界限
- (3) 如何确定分层的层数

不管是传统统计学上的小规模总体还是基于海量数据背景下的大规模总体,分层抽样都要面临上述三个问题,只有很好的解决以上三个问题,才是一项完整有效的分层抽样,由此得出的效率才会更高。接下来将分别针对以上三个问题在海量数据背景下如何分层抽样做具体分析和研究。

3.3.1 确定分层标志和界限

分层标志的确定,一般可以从各种类型的辅助信息中选择选择分层标志位,辅助信息可以是定性的也可以是定量的。

- (1) 通过定性辅助信息来确定分层界限

通过定性辅助信息来确定分层界限是最简单和通用的一种方式,这种方法本着层内差异小,层间差异大的原则。如分层指标的属性变量是民族、性别等,通常可以直接按照类别进行分类。如果辅助信息是行政区划分等具有层级关系的变量,在分层时需要根据研究的目的来对层进行细粒度划分。

在海量数据环境下,这种方法还存在一定的缺陷,比如在人口调查过程中,按照性别划分层次之后,每一层的数据容量还是非常大,为了进一步提高估计精度,需要在原有分层的基础上再次通过定性辅助信息来确定分层的界限,直到达到合适的细粒度划分标准。但是在抽样调查的过程中,可能找不到合适的定性辅助信息来确定分层界限。为了解决这类问题可以通过研究辅助变量的信息来确定分层界限。

对于某个调查总体,假设需要划分为 H 层,令 $y_0 < y_1 < \cdots < y_H$ 为各层的界限,其

中 y_0 , y_H 分别为辅助变量的最小值和最大值, 在抽样之前假设是已知的, 接下来需要确定 $y_1 \cdots y_{H-1}$ 。扎库拉·戈文达拉玉卢 (2005) [37] 就行了研究, 并做如下假设:

令辅助变量 y 的密度函数为 $f(u)$, 且是已知的; $\bar{y}_{u_h}$ 和 $S_{y_{uk}}^2$ 分别表示第 N 层的均值和方差。那么有如下表达式

$$W_h = \int_{x_{h-1}}^{x_h} f(u) du \quad \text{公式 3-(1)}$$

$$W_h S_{x_{uk}}^2 = \int_{y_{h-1}}^{y_h} u^2 f(u) du - W_h \bar{y}_{u_h}^2 \quad \text{公式 3-(2)}$$

$$W_h \bar{y}_{u_h} = \int_{x_{h-1}}^{x_h} u f(u) du \quad \text{公式 3-(3)}$$

其中 W_h 是层权。在分层随机抽样下, 总体均值的简单估计为

$$\bar{y}_{st} = \sum_{h=1}^H W_h \bar{y}_{s_h} \quad \text{公式 3-(4)}$$

分层随机抽样中, 样本层的均值是总体层均值的无偏估计, 故 $\bar{y}_{st}$ 是总体均值的无偏估计。

$\bar{y}_{st}$ 方差为

$$V(\bar{y}_{st}) = V\left(\sum_{h=1}^H W_h \bar{y}_{s_h}\right) = \sum_{h=1}^H W_h^2 \frac{(1 - f_h) S_{x_{uk}}^2}{n_h} \quad \text{公式 3-(5)}$$

其中 f_h 是层抽样比, 在海量数据背景下可以看作 $f_h \rightarrow 0$, 即

$$V(\bar{y}_{st}) = \sum_{h=1}^H W_h^2 \frac{S_{x_{uk}}^2}{n_h} \quad \text{公式 3-(6)}$$

至此, 分层抽样中最优分层界限的设计问题转化为使 $\bar{y}_{st}$ 估计量方差 $V(\bar{y}_{st})$ 最小的问题。

在奈曼分配情况下最优分层界限满足如下推导关系式[38]:

$$[(y_h - \bar{y}_{u_{k+1}})^2 + S_{y_{U_{k+1}}}^2] / 2S_{y_{U_k}} = [(y_h - \bar{y}_{u_{k+1}})^2 + S_{y_{U_{k+1}}}^2] / 2S_{y_{U_{k+1}}} \quad \text{公式 3-(7)}$$

其中 $h = 1, \dots, H-1$ 。由于上式是非线性方程, 无法计算结果, 在实际调查中通常使用 Dalenius 和 Hodges(1959)提出的累积平方根法来确定分层界限。该方法适用于研究变量未知的情况, 可以利用研究变量与辅助变量之间相关关系求出分层界限。

假设研究变量 y 与辅助变量 x 满足如下关系:

$$y_k = \alpha + \beta x_k + \varepsilon_k \quad k = 1, \dots, N \quad \text{公式 3-(8)}$$

其中 ε_k 为误差项, 满足 $E(\varepsilon_k) = 0$, 且 $Cov(\varepsilon_k, x_k) = 0$, 如果在第 h 层内, 辅助变量 x 的方差为 S_{xh}^2 , ε_k 的方差为 $S_{\varepsilon h}^2$, 将研究变量 y 与辅助变量 x 的关系式带入公式 3-(1), 得到使 $V(\bar{y}_{st})$ 达到最小值 x 的界限所满足的等式, 如下所示:

$$\frac{\beta^2[(x_h - \bar{x}_{U_k})^2 + S_{\varepsilon h}^2]}{\beta S_{xh} \sqrt{1 + S_{\varepsilon h}^2 / \beta^2 S_{xh}^2}} = \frac{\beta^2[(x_h - \bar{x}_{U_{k+1}})^2 + S_{x,h+1}^2 + 2S_{\varepsilon,h+1}^2]}{\beta S_{x,h+1} \sqrt{1 + S_{\varepsilon,h+1}^2 / \beta^2 S_{x,h+1}^2}} \quad \text{公式 3-(9)}$$

其中 $h = 1, \dots, H-1$, 对于所有层, 如果 $S_{\varepsilon h}^2 / \beta^2 S_{xh}^2 \rightarrow 0$ 时, 那么上式可化简成公式 3-(7) 的形式, 从而能够得出辅助变量 x 的最优界限。同时 $S_{\varepsilon h}^2 / \beta^2 S_{xh}^2 = (1 - \rho_h^2) \rho_h^2$, 其中 ρ_h^2 是第 h 层内变量 y 与 x 的相关系数, 所以当变量 y 与 x 相关程度越高, 利用辅助变量确定最优边界越准确。

(2) 通过定量辅助信息来确定分层界限

确定分层标志另外一种方法是通过定量辅助信息来确定边界。在海量数据环境下, 当需要从总体中抽取的样本数据巨大时, 由于大数据的稀疏性特点, 抽取的样本特征很难精确的反映总体的特征。例如通过对全国烟草零售户的订单数据分析得出客户价值的特征, 按照区域分层抽样后, 各层样本的数量任有 2-5 万条记录, 并且样本层的方差偏大, 层内数据相对分散, 从这些样本数据中找出特征数据的工作量依然巨大。针对现有问题, 对分层抽样中确定界限的方法结合数据挖掘相关知识做如下改进。改进的原则是使数据分布集中的区域少抽, 数据分布分散的区域多抽, 以保证抽取的样本能够反映整体的基本特征。

1) 设抽样业务数据为 $x_i (i = 0, 1, \dots, n)$, 划分为 k 层, 为了描述一定区域内抽样数据的集中趋势, 这里定义一定区域内的平均数为该层的数据中心, 即

$$\bar{x} = \frac{\sum_{i=0}^n x_i}{n} \quad \text{公式 3-(10)}$$

以 $\bar{x}$ 为中心, 将业务数据按序均等划分为 K 个区域, 区域被划分的次数为 n , 如图 3.2 所示, 其划分区域过程如下所示:

- A. $K=1$ 时, 业务数据总体, 一等份
- B. $K=2$ 时, 对总体数据均分第一次, 二等份
- C. $2 < K \leq 4$ 时, 对总体数据均分第二次, 四等份

- D. $4 < K \leq 8$ 时, 对总体数据均分第三次, 八等份
- E. $2^{n-1} < K \leq 2^n$ 时, 对总体数据均分第 n 次, 2^n 等份




图 3.2 区域划分示意图

- 2) 统计所有被均分区域内的数据量, 并编号从 $Z_1 \sim Z_k$;
- 3) 依次计算区域 $Z_1 \sim Z_k$ 的标准差, 并设定标准差阈值, 当标准差大于指定阈值时, 说明该区域有扰动数据, 删除该区域第一个数据和最后一个数据重新计算标准差, 直到小于标准差阈值, 最后取该组数据为该区域有效数据。
- 4) 初始化 Z_1 为第一个聚类中心 C_1 ;
- 5) 依次计算其他区域的中心点与 Z_1 的距离 $d(\bar{x}_k, c_1)$, 其中 $\bar{x}_k$ 为第 k 层区域的的数据中心, 取 $\max \{d(\bar{x}_k, c_1)\}$ 对应的 $\bar{x}_k$ 为第二个聚类中心 C_2 , 依次计算出第 k 个聚类中心
- 聚类中心满足如下关系式:

$$C_k = \max \left\{ \sum_{i=1}^{k-1} d(\bar{x}_k, c_i) \right\}$$

公式 3-(11)

- 6) 将 $(C_1, \dots, C_k)$ 作为聚类中心, 分别代表 k 个聚类, 应用聚类算法得到聚类结果。相比对于 K-means 算法, 不需要重新反复计算聚类中心, 大大提高了聚类的效率。
- 7) 根据聚类的结果, 确定每一层的界限与层内的数据。结果如表 3.2 所示

表 3.2 分层聚类结果

层次	聚类数	分层标志
Z_1	N_1	$\bar{x}_1$
Z_2	N_2	$\max \{d(\bar{x}_1, c_1)\}$
Z_3	N_3	$\max \{d(\bar{x}_2, c_1) + d(\bar{x}_2, c_2)\}$
.....		
Z_k	N_k	$\max \{\sum_{i=1}^{k-1} d(\bar{x}_k, c_i)\}$
扰动数据	N_e	——
总数	n	——

3.3.2 如何确定分层的层数

层数确定通常分两种情况，

其一，层的界限是自然的，不需要认为设置层数。如统计 2017 年每个季度的 GDP，此时就以季度为属性，可分为四层。同理，如统计某个区域人属性生肖的人数，此时按照生肖来分层，可分为 12 层。

其二，当层的界限属性不是自然的，而是基于辅助信息来确定的，就存在层数确定的问题。

在确定分层界限的部分本文讨论了通过定性辅助信息来确定分层界限，该方法在实际应用中通常是通过累积平方根来确定层的界限。由累积平方根的特点可知，层内需要通过估计量方差的无偏估计来分析抽样的效率，因此每层至少有两个样本单元，所以实际层数不大于样本量的一半。

为了使分层抽样达到最高的精度，这里考虑以目标量作为分层标识，假设样本单元数为 n ，将总体分成 L 层，且样本层 y_i 是区间[0,x]上的均匀分布。则

总体量方差为

$$V(Y) = \frac{X^2}{12}$$

公式 3-(12)

样本层简单随机抽样的方差为

$$V(\bar{y}) = \frac{X^2}{12n} \quad \text{公式 3-(13)}$$

选择比例分配的样本分配方法即

$$\text{层权: } W_h = \frac{1}{L} \quad \text{各层样本单元数: } n_h = \frac{n}{L} \quad \text{总体层方差为 } S_h^2 = \frac{X^2}{12L^2}$$

则总体均值无偏估计方差为

$$V(\bar{y}_{st}) = \sum_{h=1}^L W_h^2 \frac{1}{n_h} S_h^2 = \frac{X^2}{12nL^2} = \frac{V(\bar{y})}{L^2} \quad \text{公式 3-(14)}$$

当 $L \uparrow$ 时, $V(\bar{y}_{st}) \downarrow$, 由此可得出层数的增加在一定程度上能够提高总体均值的估计精度。

但由于研究变量 Y_i 未知, 在实际中通常利用研究变量 Y_i 与辅助变量 X_i 之间相关关系求出分层界限, 此时, 估计量方差由两部分组成, 一部分与层数有关, 一部分与层数无关。用公式表示这种关系即为 $\frac{P^2}{L^2} + (1 - P^2)$, 其中 P^2 表示与层数有关部分, $(1 - P^2)$ 是方差中与层数无关的部分, 因此, 当层数增加到一定程度, 层数对精度的影响很小, 在此不做深入研究, 根据相关研究得出, 除非 $\gamma(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var[X]Var[Y]}} > 0.95$, 否则分层抽样的层数不宜超过 6 层。

3.3.3 选择什么样的样本分配方法

当层数确定后, 接下来就需要将样本量按照某种原则分配到各个层中, 也就是通过特定的分配方法从各个层中抽取的相应数量的样本。

样本量在各层的分配主要有两种方法, 分别是比例分配和奈曼分配。

(1) 比例分配

比例分配指的是按各层单元数的比例分配。此时总体中任何一层的任何一个单元都能以相同的概率被抽取。每一层的样本叫做子加权样本, 在分层抽样中采用比例抽样可以提高样本的代表性, 避免出现简单随机抽样过程中出现某种特性的样本被遗漏的问题。其样本容量 n 计算表达式为

$$n = \sum_{h=1}^L W_h S_h^2 / (V + \sum_{h=1}^L W_h S_h^2 / N) \quad \text{公式 3-(15)}$$

(2) 奈曼分配

奈曼分配是指在假设每层抽样费用相同的情况下, 考虑一种分配样本量的方式, 使得在总费用给定的条件下, 估计量方差达到最小, 或在估计量方差给定的条件下, 是费用最小。

设总体容量为 M , 划分层数为 R , 各组的容量为 $M_i (i = 1, 2, \dots, R, \sum M_i = M)$ 。

现在需要从各层中抽取子样本, 组成容量为 $m_i (i = 1, 2, \dots, R, \sum m_i = m)$ 的样本. 按照比例分配的原则抽样即

$$m_i / m = M_i / M$$

从上式可以看出各组的抽样比等于总体抽样比相等, 也即

$$m_i / M_i = m / M$$

该分配方式的特点是样本总容量在各组的分配只取决于该组本身容量的大小, 但是在海量数据环境下, 数据存在稀疏性问题, 这将导致层与层之间的波动范围比较大, 也就是标准差比较大, 如果采用这种方法抽样会导致抽样的精度降低。样本的分配方法首先要解决的一个问题就是如何在层间标准差差异比较大的环境下提高分配的精度。

另外一种分配方法是奈曼分配, 它的精确公式如下所示:

$$\frac{m_i}{m} = \frac{M_i \theta_i \sqrt{M_i / (M_i - 1)}}{\sum M_i \theta_i \sqrt{M_i / (M_i - 1)}}, \text{ 其中 } \theta_i \text{ 为每一层的标准差。}$$

在海量数据背景下, M_i 非常大, 可以认为 $M_i \rightarrow \infty$

$$\text{所以 } \sqrt{M_i / (M_i - 1)} = 1,$$

$$\text{上式变为 } \frac{m_i}{m} = \frac{M_i \theta_i}{\sum M_i \theta_i}$$

$$\text{即 } m_i = m \frac{M_i \theta_i}{\sum M_i \theta_i}$$

其样本容量 n 计算表达式为

$$n = (\sum_{h=1}^L W_h S_h)^2 / (V + \sum_{h=1}^L W_h S_h^2 / N) \quad \text{公式 3-(16)}$$

由上式可以得出样本容量在各组分配的容量跟每一层的标准差 θ_i 和该层的容量 M_i 有

关，其目的在于使抽取的每个样本能最充分合理的代表该层数据的特点。上式还表明，当层内数据差异大时（ $\theta_i \uparrow$ ），增加抽样的样本数，当层内数据差异小时（ $\theta_i \downarrow$ ），减少抽样的样本数。这恰恰解决了比例分配在海量数据背景下各层间标准差差异较大时导致样本量在各层分配精度低的问题。

3.4 本章小结

本章主要对海量数据环境下如何抽样展开研究，首先对海量数据环境下抽样理论的可靠性进行了分析，然后对海量数据环境下各抽样方法的优缺点做了比较，最后着重从如何确定分层标志和界限、如何确定分层层数以及如何选择样本分配方法来研究如何将分层抽样方法应用到海量数据的数据处理中。

第四章 基于云模型与本体的用户画像分析与研究

4.1 用户画像研究概述

4.1.1 用户画像定义

用户画像又称用户角色 (User Portrait), 是根据用户的静态属性 (社会属性, 生活属性) 和动态属性 (消费行为、使用行为) 等信息勾画用户和联系用户诉求与产品设计的工具。用户画像的概念经常与数据挖掘中的聚类联系在一起, 聚类实现的功能通俗的说就是“物以类聚, 人以群分”, 用户画像从某种程度上来说正体现了聚类的这种特征, 用户画像是真实用户的虚拟代表, 每一个用户画像都映射着一类具有相同特征的特定群体。例如, 有这样一个体: 男性, 50 岁, 手机号码, 戴眼镜, 教授, 承担政治课程的教学, 在某大学任职, 喜欢看报纸等。通过这些信息我们可以很直观的了解这个体, 如果信息足够充分的话, 我们就可以根据这个体的静态属性和动态属性对这个体的行为习惯做出预测。例如, 根据这个体是政治学科的教授, 以及爱看报纸, 我们可以预测这个体可能会比较喜欢看时政类的新闻, 根据我们对这个体行为的预测, 然后针对他的喜好给他提供个性化的推荐服务, 我们通过获取他的手机号 (静态属性) 来给他定点发送时政要闻的链接, 同时为了做到人性化推荐, 我们可以推荐他下载相关的 App, 以便他能更及时更便利的获取时政相关的信息。如果还有其他人或者其他群体同样具备喜欢看时政新闻的特征, 我们可以构建该类群体的用户画像模型, 同时为该类群体提供相同的个性化服务。

4.1.2 用户画像标签体系

标签是根据用户的某类特征人工定义的高度凝练的特征符号。其具有三个最重要的特征, 语义化特征、短文本特征和种群性特征。其中语义化特征赋予标签一定的含义, 目的是使人很容易的理解这些标签的含义, 短文本特征表现形式可以是文字也可以数字, 是为了方便计算机对标签处理和分析, 种群性特征是从用户的属性中抽样和归纳事物的特征。所以, 用户画像的标签化是用户画像的核心工作, 标签化的用户画像即方便人们的理解, 也方便了计算机对标签的分析和处理。

用户画像建模也就是通过对用户画像标签的描述与刻画来发现人们感兴趣的模型, 所以, 科学准确的构建用户画像标签体系是用户画像建模的重要组成部分^[39]。从最初的样本数据到最终的高度凝练标签, 从海量数据中抽样处理再到数据挖掘与机器学习, 让用画画像模型能够被人理解, 并能通过模型来发现用户潜在的特征和行为。本文参考许多的文献和企业文档, 认为标签体系应当具有以下层级结构, 如图 4.1 所示:




图 4.1 标签体系结构

如上图所示，标签体系的逻辑结构分别包括原始数据层、事实层、模型预测层、营销模型预测层和业务层。

原始数据层：这一层指在数据库服务器中追踪和服务于用户的原始数据，如会员信息，消费行为。通过对这些原始的信息进行清洗和机构化加工处理得到用户信息的事实层。

事实层：这一层是在原始数据的粗加工基础上统计分析得出的数据，该层主要实现的功能是对原始数据进行校验，同时将准确无误的数据传输到模型预测层统计建模。

模型预测层：这一层基于事实层的数据，通过机器学习建模，对事实层的数据分析和利用，从中发现用户的特征和兴趣模型。

营销模型预测：这一层是对模型预测层通过语义化和短文本的方法对用户特征和用户行为标签化，通过用户的标签化，建立营销预测模型，从而根据用户的用户画像标签来识别和预测群体用户中的客户价值度、忠诚度、流失度等人们感兴趣的模型，用以来挖掘用户的潜在需求。

业务层：这一层主要是对营销模型预测的结果以直观的可视化方式展示。

4.2 用户画像建模分析与研究

4.2.1 用户定量画像

通过用户的定量属性来构建用户画像是最简单的用户画像建模方法，这种建模方法关键是如何把握用户画像的颗粒度，通常而言，颗粒度越小，用户画像越细腻，对用户的刻画就越精细。但并非颗粒度越小用户画像建模就越可靠，一方面，更细化的颗粒度将会导

致更高的建模成本，另一方面更细化的颗粒度将导致用户画像映射的群体越来越狭隘，适用性降低。因此，在建模时需要根据具体的业务场景来调优颗粒度的大小，既要保证用户画像的不失真，同时也要保证用户画像在一定范围内的适用性。

定量用户画像的数据主要来自于存储在数据库中的表单数据和用户行为日志中，而收集的表单数据，大多是基于用户的真实信息，所以推荐系统可以直接利用，但收集用户的行为日志，需要进一步通过数据统计和预测分析将行为属性显示化。很明显通过用户行为日志分析的用户信息相比于直接通过表单获取的信息准确性要差，但是在一个群体画像中，用户的日志行为往往就代表了他们的一种偏好和习惯，而偏好和习惯在一定程度上可以反映出用户群体的特征，从这一点来说，在群体用户画像中，通过日志分析用户的行为是有意义的。

但定量数据只是用户信息最表象的描述，仅仅通过用户的定量数据来构建用户画像往往无法全面精准的刻画用户。所以需要寻求另外一种更有效的用户画像建模方法——用户定性画像。

4.2.2 基于本体的用户定性画像

用户定性画像与用户定量画像不同，用户定性画像是基于用户标签，所以标签化是用户画像的核心，标签化的用户画像即方便人们的理解，又方便计算机分析和程序处理。如何表示、解释、推理、验证标签是用户定性画像建模的关键。其中用户画像的标签表示一般阐述的是什么人、在什么时间、什么地点，做了什么事。标签的语义化解释和推理主要基于知识工程的分析。

知识工程的概念是 1977 年美国斯坦福大学计算机科学家费根鲍姆教授在第五届国际人工智能会议上提出的^[40]，他认为“知识工程是以人工智能的原理和方法对那些需要专家知识才能解决的应用难题提供求解手段，恰当的运用专家知识的获取、表达和推理过程的构成与解释，是设计基于知识的系统的重要技术问题。”从知识工程的角度出发，用户定性画像就是利用本体的思想对用户标签表示、解释、推理和验证。其基于知识表示的标签主要包括用户特征、用户行为以及用户兴趣偏好。其结构如图 4.2 所示




图 4.2 基于知识表示的标签结构

用户定性画像的核心就是对用户画像标签的提取，最终将标签经计算机处理得到人们感兴趣的模型。标签是对用户特征以短文本的形式高度精炼的语义化标识，对于人来说这些标识自然能做到见名知义，但对于计算机来说这些标签仅仅是一串存储在计算机内层中的二进制符号，没有实际的语义。如何让计算机具有语义识别的功能，就需要借助本体为标签赋予对应的语义。

本体 (Ontology)^[41]是近年来人工智能领域快速发展的一项技术，它在知识获取、分析、表示和处理等方面具有优势。本体研究的主要目标是实现某种程度的知识共享和重用。本体的结构一般包括类、属性、实例、公理和推理规则。其中类是具有相似性质的所有个体的抽象，Thing 是所有类的父类，每个父类包含相应的子类，类与类之间构成平行关系或者层级关系。属性是对类概念的刻画，其包含对象和数据两种属性。实例则是描述本体类中的具体对象。公理是本体中的永真式，用来描述概念的约束性。

本体构建的过程如下所述：

- 1) 需求分析，根据需要建模的领域确定用户画像的适用范围和应用的具体目标，具体而言就是通过构建的用户画像设置一系列相关的问题来检验本体的知识是否完全覆盖了用户画像分析和建模的领域，然后一步步的修正和调整来确定本体的范围。
- 2) 信息搜集和处理，在本体的范围内搜集数据，经整体、读取、分析和提取分类之后，添加相应的公理和约束。在以上的基础上通过数据分析得出用户画像本体所涉及的范围数据和本体的结构信息以及约束条件。最后将这些信息以文件的形式存储在计算机中，待计算机处理。
- 3) 本体构建，基于整理的信息利用本体描述语言 OWL DL 和本体构建工具 protégé 进行用户画像本体的构建。在构建的过程中，需要遵循四点原则，首先使用标准术语，其次要支持与其定义相一致的推理。第三，提供一个共享的词汇表。最后，本体构建时应当使用多种层次，同层次之间应当保持较近的语义差别。

本体为标签赋予语义的过程中非常重要的一步是定性画像知识的推理，对本体使用者来说，推理就是将用户画像的特征标签信息聚类的过程，然后借助本体的知识来训练标签，使其具有类、属性等概念，从而有助于将标签转化为计算机能识别的语义标识。目前而言，实现本体推理主要有四种方法，分别是基于传统描述逻辑推理方法、基于规则方法、利用逻辑编程方法、基于一阶谓词证明器的方法^[42]。基于以上四种方法，接下来有必要了解一下本体推理机。

本体推理机一般五个模块组成，分别是本体解析器、查询分析器、推理引擎、结果输出模块和 API 组成，如图 4.3 所示。其中本体解析器负责读取和解析本体文件，解析性能的好坏决定本体推理机对大文件的处理效率。查询分析器负责解析用户的查询命令。结果输出模块是对推理引擎输出的结果进行包装，它直接决定了推理机支持的文件输出格式。API 主要面向开发用户，为他们提供编程语言的开发接口。




图 4.3 本体推理机


4.2.3 基于云模型的用户定性画像

上一节从知识工程和本体思想的角度对用户定性画像，相比定量画像，定性画像在建模时将用户标签化，可以实现对用户精炼的概括，同时借助知识工程与本体的思想将标签转换为计算机可识别的具有语义的短文本，不仅方便人们的理解也方便了计算机的快速处理。定性画像克服了定量画像中无法直接描述的数值型属性以及很难通过算数法则表示的模型问题。使得用户画像在一定程度上能够精准、全面的刻画用户。极大的推动了用户画像建模在各领域被广泛的成功应用。


再次来总结一下其优点，用户定性画像可以借助知识工程与本体的思想将刻画的用户特征通过语义化和短文本化的方式交给计算机处理，方便计算机对标签的运算和聚类分析，极大的提高了用户画像建模的效率和精准度。其中本体思想和知识工程是实现标签语义化

的关键，也是将人所能理解的语言转换为机器所能表示的重要一步。顺着这条思路，本文将引入云模型来解决用户画像中遇到的语言文字不确定性的形式化表示问题。

在第二章中本文已经对云模型进行了简单的介绍，简单的说云模型是定性定量转换的认知模型，能够实现定性概念与定量数值之间的双向转换。在用户画像的过程中，需要处理大量的标签，这些标签根据属性的不同分为定量属性和定性属性，定量属性是表单中明确的用户真实信息，在计算机中的语义化的表示是离散的不连续的，无法形成一个具体的、达到普遍共识的和可描述的概念，借助云模型理论的转换模型，将定量的概念通过 Ex （期望）、 En （熵）、 He （超熵）在云图上直观的进行表示定量概念的边界和聚集度,如图 4.4 所示。而对于定性属性，经语义化处理后已经形成了一个可描述的概念，将定性概念经云模型转换模型得到定性概念的量化表达，如图 4.5 所示。基于云模型的这种特点，把云模型理论用于用户画像的建模将为标签语义化与机器识别等问题提供了一条解决途径。本文将在下一节对云模型理论与用户价值画像之间的关系展开分析和研究。



4.4 定量-定性转换模型



4.5 定性-定量转换模型

4.3 群体用户画像分析与研究

在第二章中本文介绍了 RFM 模型, RFM 模型是客户关系管理领域的一种定量分析模型, 也即通过一个客户最近一次消费时间间隔 $R(\text{Recency})$ 、最近一段时间内的消费频次 $F(\text{Frequency})$ 和最近一段时间消费的总金额 $M(\text{Monetary})$ 三个指标来动态的刻画一个客户价值的整体轮廓, 也就是用户价值画像。

在群体用户价值画像建模过程中, 需要解决三个问题, 首先从用户的信息中提取用户 RFM 模型的三个指标标签, 其次将 RFM 模型的三个指标标签语义化为机器所能识别的语言, 最后为每一个用户打上唯一性的标识。其中, 用户唯一性标识的作用是为了精准定位到指定的用户, 从而可以为该用户推送相应的服务和产品。本文将从用户价值画像创建流程、用户画像标签存储和云模型推理分析三个部分来分析。

4.3.1 基于 RFM 模型的用户价值画像创建流程

本文从客户的交易信息中提取 RFM 模型的三个指标进行分析, 综合运用云模型的理论来得出客户类型聚类的结果, 其主要过程如下:

1) 从订单信息库中采集用户画像数据并进行数据预处理

订单信息库包含行业全口径用户数据和订单数据, 该部分数据量巨大, 需要通过大量的建模对数据清洗、降维和指标计算, 并在海量数据环境下对数据抽样处理。

2) 用户价值画像数据标签化

按照用户价值画像数据的属性把数据划分为客观属性和行为属性两大类, 其中客观属性数据代表的是用户固有属性, 例如身份证、订单号等, 因其在全局中具有唯一性的特点, 在用户价值画像中可以把这类数据作为用户的唯一标识, 在数据库中作为 token (ID) 来存储, 实现在群体用户中精准推送的目的。行为属性是用户价值画像建模的主要数据来源, 行为属性包含用户的定性数据和定量数据, 定量数据无法直接被机器识别, 必须要经过语义化处理转化为可被定性描述的概念。这个过程首先消除数据带来的影响, 对数据进行标准化处理, 然后借助云模型理论中的逆向高斯云发生器来实现定量数据语义化的转化, 最后将行为属性中的定性数据与语义化的定性数据共同作为用户价值画像的定性标签。

3) 定性标签云模型转换

本文对用户价值的判别是基于 RFM 模型来建模分析的, 首选从定性标签中提取表示用户价值属性的标签模型, 构建时间间隔云模型、消费频率云模型和消费金额云模型三种模型, 然后通过这三种模型对用户价值画像和分析, 如表 4.1 所示;

表 4.1 用户价值画像云模型指标

序号	指标名称	指标说明
1	消费时间间隔云模型	统计节点与最近一次消费的时间差
2	消费频率云模型	一段时间区间内消费的次数
3	消费金额云模型	一段时间区间内每次消费的总金额

4) 用户价值画像的云模型聚类

用户群体价值画像聚类是为了找出群体中不同用户价值的特征模型，然后针对不同价值的客户推送相应的服务或者产品。在数据挖掘领域，聚类算法主要有如下几种，第一种是以 K-MEANS 和 K-MEDOIDS 为代表的基于划分的聚类算法、第二种是以 BIRCH 和 CURE 为代表的基于层次的聚类算法、第三种是以 DBSCAN 和 OPTICS 为代表的基于密度的聚类算法和第四种以 STING 为代表的基于网格算法以及图论聚类算法和模型算法等^[43]。但这些聚类算法均无法适用于云模型领域。为此，本文设计了一种算法来适应云模型领域的需求，该算法将在 4.2.3 节展开论述。

5) 用户价值画像定量分析

根据云模型理论的”3En”原则，将定性的用户价值画像转化为定量的区间用户价值画像，建立定量价值画像的分析模型。

其大致流程如图 4.6 所示：




图 4.6 用户价值画像分析流程

4.3.2 用户画像标签存储分析

在 4.2.2 节介绍了基于知识工程与本体思想构建定性画像的一般过程，通过本体构建工具 **protégé** 来构建本体库，并以本体描述语言 **OWL DL** 来描述本体库中以后缀名为 **owl** 的文件。当需要对这种格式的文件处理时，传统的关系型数据库已经无法胜任。随着关系型数据库的发展和本体存储技术得到越来越多的关注，本体数据管理工具通过基于关系-关系或者对象-关系数据库管理系统来实现，代表的数据库管理系统有 **Jena** 和 **KAON** 等。

Jena 是有由英国惠普实验室开发的用于语义网的综合系统，它为开发中提供了丰富的 **Java** 库，用于处理 **RDF**、**QWL** 等语言编写的代码，它的系统架构如图 4.7 所示，分别由 **RDF** 应用接口、**RDF/XML** 解析器与写入器、推理机应用接口、存储应用接口等四个部分组成^[44]。

- （1）**RDF 应用接口**：通过本体 **API** 直接调用 **Java** 代码来处理 **OWL** 模型以及通过 **SPARQL API** 直接调用 **Java** 代码来查询和更新 **RDF** 模型。
- （2）**RDF/XML 解析器与写入器**：主要是对 **RDF/XML**、**N_triples**、**N3** 和 **OWL** 等文件解析和读取操作。
- （3）**推理机应用接口**：主要是基于推理机内置规则和自定义规则进行推理。
- （4）**存储应用接口**：为本体数据存储提供多个接口，可以是暂时性存储的内存、持久化存储的关系型数据库、快速持久化存储三元组形式到磁盘的 **TDB** 数据库以及其他自定义的数据库。





图 4.7 jena 架构图

以上介绍的 Jena 的语义网系统是用用户定性画像领域有待研究和需要进一步改进的存储方案，从 jena 组成部分的描述来看，要实现本体数据在关系数据库中存储需要做以下几件事，首先，用户画像信息的搜集和整理，人工处理为主，缺乏自动化的处理方式；其次创建本体数据，并以 RDF/XML 或者 OWL 形式存储；第三需要根据实际需求定制推理规则，同时不同规则之间需要排除冗余和矛盾项，这些工作任以手工为主，工作量及其复杂。由于其工作量的复杂性和自动化机制的不完善导致其在用户定性画像领域难以推广使用。本文对此部分只从客户和商品两个维度对用户进行个体画像的研究，将在分别在 5.3 节和 5.4 节根据具体案例进行分析。

在 4.2.3 节介绍了云模型用户画像的一般过程，为了实现对云模型的存储，首先来分析一下云模型画像的数据结构。

根据正向高斯云发生器的原理可知，云模型用 Ex （期望）、 En （熵）和 He （超熵）三个数字特征来整体表征一个概念，也即每一个概念由许许多多的具有 Ex （期望）、 En （熵）和 He （超熵）三个数字特征的云滴组成，通过设定云滴数，利用高斯云算法就可以在云图上反映该概念的整体隶属度分布情况。其过程如图 4.8 所示。



4.8 某 userId 用户价值画像形成过程

由以上分析可以得出，任一个 userId 的用户价值画像云图都可以通过若干个云滴来实现，其云模型数据结构如图 4.9 所示。




图 4.9 某 userId 用户价值画像数据结构

用户价值画像的云模型数据结构具有如下特点

- （1）用户价值画像的云模型数据结构首部必须有一个唯一标识（userId），用这个标识作为元素的关键字。
- （2）各云滴之间互不影响，也没有先后顺序，不同云滴之间通过唯一标识来区分。
- （3）每一个云滴由 Ex （期望）、 En （熵）和 He （超熵）组成
- （4）映射的元素包含关键字和值，且关键字不能重复
- （5）提供关键字到值的映射功能，即根据关键字查找值

根据用户价值画像的云模型数据结构的以上特点，传统的关系型数据库已经无法对该类型的数据进行存储、检索和运算等操作。随着 NoSQL 等非关系型数据库的出现，极大的弥补了传统关系型数据支持存储类型的缺陷，NoSQL 数据库通过集成分布式系统、集群、分区等技术实现分布式存储，能有效的伸缩存储规模、实现海量数据存储和检索。其中的 Mongo DB 就是一种介于关系型数据库和非关系型数据库之间的一种高性能、无源、模式自由且面向文本类型的文档存储的数据库，其查询功能强大、支持复制和数据恢复^[45]。

Mongo DB 是一个基于文档的数据库，它使用二进制 JSON 来存储数据（BSON），其中文档可以具有一种灵活的模式，也就是说集合中的文档可以有相同或者不同的字段集^[46]。Mongo DB 部署可以使用多种数据库，每个数据库就是一组集合，如图 4.10 描述了 Mongo DB 数据库模型。




图 4.10 MongoDB 数据库模型

通过 BSON 可以来构建用户价值画像的云模型存储格式文档，如下是用户价值画像的云模型 BSON 文档内容，通过 MongoDB 可实现对 BSON 文档的增删改查操作，对其简单操作如表 4.2 所示

```
userId1={
  "userId":[
    "userId_1":{
      "Ex":Ex1,
      "En":En1,
      "He":He1
    },
    "userId_2":{
      "Ex":Ex2,
      "En":En2,
      "He":He2
    },
    .....,
    "userId_N":{
      "Ex":Exn,
      "En":Enn,
      "He":Hen
    }
  ]
}
```

表 4.2 Mongo DB 对 user1 文档的增删改查操作

操作描述	范例
把 user1 文档插入到数据库 col 中	db.col.insert(userId1)
查询 user1 文档	db.col.find()
删除 userId=userId_1 的文档	db.col.remove({'userId': 'userId_1'})
把 userId=userId_1 更改为 userId=userId_x	db.col.update({'userId':userId_1},{ \$set: {'userId': 'userId_x'}})

4.3.3 云模型聚类分析

在本文中，需要实现市场环境下帮助市场分析人员从客户订单记录中发现不同的客户群，以此来指导市场人员针对不同群体精准推送相应的服务和产品等。针对客户群体价值分类，本文首先基于 RFM 模型来构建用户价值云模型标签体系，然后通过云模型标签体系来刻画用户价值画像模型。其中第一步已经在上文做了论述，接下来需要完成第二步。

用户价值画像也就是在群体用户中抽象出所有用户价值的共同特征，然后根据特征之间的相似性来划分不同的数据集，最终得到不同的簇，其过程类似与数据挖掘中基于划分方法的 K-means 算法，但这种算法划分的依据是基于距离的，在云模型领域没有距离这一概念，为了实现在云模型领域的聚类运算，本文用云模型的相似度量方法来取代 K-means 算法中基于距离的划分依据。而对于云模型中的聚类中心，将用综合云相似度来取代 K-means 算法中质心。其云模型聚类流程图如图 4.11 所示




图 4.11 云模型聚类流程图

以 K-means 算法思想为原型,按照以云模型相似度取代距离作为相似度度量,以综合云相似度取代质心作为聚类中心的原则对其改进,其算法描述如下:

算法: 基于云模型聚类算法

算法描述:

输入: 聚类的个数 K , K 个云模型聚类中心

输出: K 个聚类中心簇

1) 从用户画像云模型集合 $V=\{V_1,\cdots,V_m\}$ 中任意检索出 K 个初始化云模型聚类中心,记作初始化聚类云模型集合 $U=\{U_1,\cdots,U_k\}$; 云模型指标集合记为 $C=\{C_1,\cdots,C_j\}$; 云模型相似度集合记为 S .

2) 计算云模型集合中元素与云模型聚类中心元素的定性相似度(先遍历 U , 然后遍历 V)

for each U_i in U do

for each V_j in V do

//计算集合 U 中每一个元素 U_{ik} 与集合 V 中每一个元素 V_{jk} 的云模型相似度, γ_k 为权重因子.

$$Sim(U_i, V_j) = \sum_{k=1}^n Sim(U_{ik}, V_{jk}) \quad \gamma_1 + \gamma_2 + \dots + \gamma_k = 1;$$

$S = Sim(U_i, V_j) \cup S$ //将云模型相似度的结果装入 S 集合中.

3) 根据相似度的最大值取出云模型聚类元素,放入到对应的 G_i 集合中(先遍历 V , 然后遍历 U)

for each V_j in V do

for each U_i in U do

for each $Sim(U_i, V_j)$ in S do

$$G_i = \max\{Sim(U_i, V_j)\} \cup G_i$$

4) 设定阈值 F

if $F > \min\{G_i\}$ // F 大于聚类云模型集合 G_i 中最小值

then 公式 2-(6), 2-(7), 2-(8)式 //重新计算聚类中心

$C = \{C_1(Ex_1, En_1, He_1), C_2(Ex_2, En_2, He_2), \dots, C_n(Ex_n, En_n, He_n)\}$ // 新的聚类中心

重复 2), 3) 步骤 //直到聚类云模型集合 G_i 中最小值大于阈值 F

end

4.4 本章总结

本章首先对用户画像进行了概述，然后分别从定量画像、定性画像和云模型用户画像三种建模方式展开研究和分析。通过以知识工程与本体的思想为理论基础来构建用户个体画像模型，通过以云模型理论为基础构建云模型用户价值画像模型，并就云模型的数据结构来设计云模型的存储结构模型，实现非结构化云模型标签的存储。最后改进传统 K-means 聚类算法，使得该算法能够适用于云模型等相关领域。

第五章 零售信息挖掘下的推送模型设计与案例分析

5.1 推送模型架构分析

推送模型架构分别由数据处理模块、云模型用户画像建模模块、云模型用户画像聚类模块和用户画像应用体系模块四部分组成，如图 5.1 所示。

数据处理：通过数据库查询语言 SQL 提取目标数据，并对目标数据进行脱敏和缺失值过滤的操作。将清洗好的数据存入数据库中准备下一阶段的数据抽样处理。在海量数据环境下的抽样主要是围绕样本分层界限、样本分层层数和样本分配方法的选定来操作的。

云模型用户画像聚类：该模块要建立基于 RFM 模型的用户画像标签体系，围绕用户特征、用户行为和用户偏好建立个体用户画像标签和经过云模型转换得到的云模型画像标签，并将用户画像的标签信息及表征信息通过 BSON 文档的形式存储在 Mongo DB 数据库中。

云模型画像聚类：该部分通过应用程序直接调用数据库中的数据，通过云模型聚类算法，将云模型标签数据分成若干个簇，实现云模型的聚类。对于单数据（非样本数据）通过综合相似度来确定所属的类别。

用户价值画像应用体系：该部分通过对以上数据分析的结果，分析得出用户的价值画像，对价值画像建立服务推荐库和产品推荐库，其中服务推荐库是基于云模型用户价值画像的面向群体的推荐，产品推荐库是基于个体用户画像的面向个体的推荐。建立面向群体推荐的是服务，面向个体推荐的是产品的二级推荐梯度。




图 5.1 推送模型架构

5.2 海量零售信息处理案例分析

本文实验分析数据来自于企业 CRM 系统中零售订单数据，该数量级平均每年达到 50 亿条，通过企业数据处理平台对数据进行数据建模、清洗、降维等数据加工处理操作，其过程如图 5.2 所示




图 5.2 订单数据处理图

原始数据：通过读取校验文件对原始订单数据进行校验处理，保证与下行数据（订单和订单明细）的一致性，同时对相应的数据做好备份。如上图灰色表所示

中间过程表数据：对原始的数据集实施批量的数据清洗操作，接着对数据实施降维操

作，形成大而全的体系结构，以支持结果数据计算，同时支持单区域或者更细粒度数据的查询^[47]。

结果数据：通过中间过程表数据结合所需指标体系计算所得结果。达到海量数据的计算分析能力。如上图淡蓝色表所示

本文将在企业数据处理平台处理好数据的基础上，通过中间过程表数据结合 RFM 模型指标对数据进行提取并在海量数据环境下对数据抽样数来建立数据处理模型。如上图深蓝色表所示

5.2.1 数据说明

本文所采集的用户画像数据主要包括三个方面，一是用户特征属性数据——用户姓名、区域等；二是用户行为属性数据——消费行为、消费频率和消费金额等；三是用户兴趣偏好数据——品牌偏好、价格偏好等。

在原始数据集中，根据区域指标来确定所要分析的源数据范围，这里选取区域湖南省（地级市）范围内从 2016 年 7 月到 2017 年 6 月的用户订单数据作为分析模型，剔除在此期间流失和新进客户，以及用户画像指标数据不全的客户。经过数据脱敏和缺失值处理之后大约剩下 19.8 万零售户，用户画像数据的各指标变量和分类如表 5.1 所示。

表 5.1 用户画像数据指标分类

变量	类别
用户 ID (UserId)	个体用户画像唯一标识
一级区域 (Area_first)	13 个类别：代表湖南省 13 个地级市
二级区域 (Area_second)	各地级市区县
商品名称 (Goods)	用户购买的商品列表
消费时间间隔 (Interval)	浮点数
消费频率 (Frequency)	浮点数
消费金额 (Monetary)	浮点数
品牌偏好 (Brand)	浮点数
价格偏好 (Price)	浮点数

5.2.2 抽样过程

在第三章中本文对海量数据环境下抽样所需要解决的三个问题展开了分析，从理论上解释了分层抽样在海量数据环境下的适用性，接下来通过具体的案例来分析这个过程。

在本案例中需要通过湖南省一年内的零售户订单记录来了解该区域内用户价值的分布情况。对 2016 年 7 月到 2017 年 6 月的零售户订单进行分层随机抽样，组成一个样本容量为 N 的样本。本例分别采用比例分配和假设每层抽样费用一致的尼曼分配进行抽样，最后用 Kullback-Laible 信息量来衡量样本数据集的质量，从而选择最优分配分配方案。

1、总体分层

利用 2016 年 7 月到 2017 年 6 月企业数据处理平台记录湖南省范围内的历史零售户订单数据作为先验信息，根据数据分布的形态，确定总体分层按照湖南省地级市划分，如果直接利用地级市的数据进行预测，则可能存在数据抽样的不稳定性，尤其是在海量数据环境下噪音数据带来的误差更大。

根据抽样理论，设总体为 X ，分为 K 层，其中假设每一层的样本数为 n ,均值分别为 $\bar{X}_1, \bar{X}_2, \bar{X}_3, \dots, \bar{X}_k$ ，则每一层的方差均为 $\frac{\delta^2}{n}$ ，显然 $\frac{\delta^2}{n} < \delta^2$ ，也即通过多重分层能够降低预测结果的方差。于是本文决定采用二级分层， 其分层结构如图 5.3 所示




图 5.3 零售信息分层结构

2、样本容量 n 的确定

对数据进行分层后，计算二级分层各层的层权和方差，按照公式 3-(15)和 3-(16)要求在 95%的置信水平下，相对误差不超过 10%，再在二级分层基础上计算一级分层的层权和方差，根据以上计算过程得到按比例分配的样本容量至少为 2261，按照奈曼分配的样本容量至少为 1915。

3、各层样本量的计算

样本量确定以后，根据层内标准差 S_h 和层权 W_h 来确定样本在各层的分配，其在奈曼分配和比例分配情况如表 5.2 所示。

表 5.2 比例分配与样本分配地市样本量

分配方法 \ 分层	比例分配	奈曼分配
长沙市	259	73
株洲市	271	69
湘潭市	230	97
衡阳市	119	185
邵阳市	103	201
岳阳市	182	128
常德市	231	87
张家界市	98	243
益阳市	203	107
娄底市	165	142
郴州市	159	168
永州市	162	156
怀化市	79	259
总数	2261	1915

4、样本质量评估

样本质量是样本与整体数据结构相似性的衡量指标，这里用 Kullback-Laible 信息量来衡量样本集 S 与整体数据集 D 之间的差异性，其公式如下所示：

$$I(S, D) = \sum_{i=1}^K (f_{Si} - f_{Di}) \log \frac{f_{Si}}{f_{Di}}$$

公式 5-(1)

其中 f_{Si} 为样本集第 i 个分层区间的样本抽样频率， f_{Di} 为整体数据集第 i 个分层区间的频率，即层权，本文通过公式 5-(1) 的幂指数来衡量样本数据的质量，即

$$Q(S, D) = e^{-I(S, D)}$$

公式 5-(2)

其中，当样本集 S 与整体数据集 D 频率分布越接近， $I(S, D)$ 的值越小， $Q(S, D)$ 的值就越大，代表样本数据的对整体数据的代表性就越好，样本数据的质量就越高。
根据公式 5-(1)和 5-(2)得到样本质量评估结果

(1) 比例分配 $Q(S, D)=0.864$

(2) 奈曼分配 $Q(S, D)=0.952$

通过分析, 综合比较得出在海量数据环境下通过奈曼分配能够得到更好的样本数据质量。所以本文将采集奈曼分配抽样的数据作为分析建模的数据。

5.3 用户画像建模案例分析

在上一节, 本文对湖南地区 13 个地级市进行了分层抽样, 得到样本容量为 1915 的抽样样本, 本文将在 5.3.1 节通过该样本对湖南省地区用户建立用户价值画像模型。同时对未采集到的数据, 也即非样本数据(单数据), 通过建立个体用户画像标签体系来分析个体与商品的相似性分析, 其过程将在 5.3.2 中详细阐述。

5.3.1 云模型用户价值画像模型构建过程

本节将从 1915 位零售户近一年(2016-7~2017-6)的订单记录中挖掘出用户价值的分析模型。首先通过 RFM 模型构建用户价值标签体系, 然后将基于 RFM 模型的价值指标经逆向高斯云发生器转换为云模型画像标签, 最后将云模型画像标签转换为 BSON 文档格式存储在 MongoDB 中。

在 5.2 节数据说明部分, 本文从修正信息库中提取了用户的三个指标数据, 这三个指标分别是消费时间间隔(Interval)、消费频率(Frequency)和消费金额(Monetary)。其中消费频率(Frequency)和消费金额(Monetary)与 RFM 模型所表达的含义完全一致, 由于 RFM 模型另外一个要素——最近一次消费(Recency)是通过用户上一次订购行为来预测下一次订购行为, 但仅仅把最近的一次订购行为作为先验条件来预测下次的订购行为往往具有很大的随机性, 无法对用户的长期价值取向做出准确的分析, 所以在本文中将该要素替换为消费时间间隔(Interval), 其中时间间隔的每一个区间取 2016.7-2017.6 期间的每一个自然月(从上个月最后一个非完整周的周一到本月最后一个完整周的周日)。如表 5.3 所示为某郭姓零售户 2016.7-2017.6 用户价值画像指标。

表 5.3 某郭姓零售户 2016.7-2017.6 用户价值画像指标

姓名	时间区间	消费频率/次	消费金额/千元	消费时间间隔/天
郭*	2016. 07. 04-2016. 07. 31	2	3. 23	10
郭*	2016. 08. 01-2016. 08. 28	5	4. 52	7
郭*	2016. 08. 29-2016. 09. 25	5	4. 73	6
郭*	2016. 09. 26-2016. 10. 30	6	5. 51	5
郭*	2016. 10. 31-2016. 11. 27	5	4. 52	6
郭*	2016. 11. 28-2016. 12. 25	5	5. 33	5
郭*	2016. 12. 26-2017. 01. 29	7	5. 57	6
郭*	2017. 01. 30-2017. 02. 26	6	4. 71	6
郭*	2017. 02. 27-2017. 03. 26	6	4. 25	7
郭*	2017. 03. 27-2017. 04. 30	6	4. 5	5
郭*	2017. 05. 01-2017. 05. 28	6	4. 63	5
郭*	2017. 05. 29-2017. 06. 25	2	3. 92	18

用户价值画像指标提取后，对每个用户画像指标数据的分布情况进行分析，其指标数据取值范围如表 5.4 所示，从表中数据可以看出用户价值画像指标的取值范围差异比较大，为了消除指标之间的差异，需要通过标准化处理。

表 5.4 用户价值画像指标取值范围

指标名称	消费时间间隔	消费频率	消费金额
最大值	29	13	23
最小值	1	0	0

通过 MATLAB 内置函数 `zscore` 可以实现对指定数据集文件进行标准化处理，其代码如下所示

```
%%初始化输入参数
file='../datafile.xls';%需要标准化文件的路径
zfile='../zfile.xls';%标准化后文件的存储路径文件

%% 标准差标准化处理
[data,txt]=xlsread(file);
zdata=zscore(data);

%%数据输出到zfile文件中
xlswriter(zfile,[txt;num2cell(zdata)]);
```

由于逆向高斯云算法是实现从样本数据集合到表示定性概念的数字特征 (Ex, En, He) 的转换工具，因此可以通过逆向高斯云算法来实现将标准化的数据集转换为具有云模型数字特征的指标，其基于 RFM 模型的指标也即云模型画像标签，分别是消费频率云模型 (FC)、消费金额云模型 (MC) 和时间间隔云模型 (IC)。其结构形式如表 5.5 所示

表 5.5 云模型画像标签（样本）

姓名	消费频率云模型	消费金额云模型	时间间隔云模型
郭*	(0.196, 0.052, 0.035)	(0.181, 0.020, 0.010)	(0.276, 0.110, 0.100)
陈*月	(0.173, 0.061, 0.034)	(0.312, 0.031, 0.027)	(0.462, 0.021, 0.015)
张*琳	(0.153, 0.056, 0.042)	(0.437, 0.036, 0.091)	(0.536, 0.039, 0.027)
熊*	(0.216, 0.052, 0.038)	(0.865, 0.071, 0.032)	(0.257, 0.072, 0.032)
李*龙	(0.193, 0.072, 0.040)	(0.225, 0.064, 0.023)	(0.228, 0.049, 0.024)
夏*	(0.146, 0.062, 0.021)	(0.288, 0.074, 0.057)	(0.576, 0.043, 0.022)
刘*棋	(0.076, 0.022, 0.015)	(0.527, 0.031, 0.021)	(0.539, 0.028, 0.013)
陈*方	(0.641, 0.102, 0.034)	(0.678, 0.035, 0.032)	(0.426, 0.051, 0.036)
王*明	(0.131, 0.042, 0.027)	(0.231, 0.095, 0.013)	(0.373, 0.085, 0.033)
杨*凯	(0.146, 0.062, 0.022)	(0.563, 0.047, 0.026)	(0.324, 0.113, 0.042)

云模型画像标签通过云模型的三个数字特征 (Ex, En, He) 定性的代表了零售户基于 RFM 的价值模型，云模型画像标签将通过二进制 json 格式 (BSON) 文件存储在 MongoDB 数据库中，其文档内容形式如下所示

```
{
  "郭*":[
    "FC":{
      "Ex":0.196,
      "En":0.052,
      "He":0.035
    },
    "MC":{
      "Ex":0.181,
      "En":0.020,
      "He":0.010
    },
    "IC":{
      "Ex":0.276,
      "En":0.110,
      "He":0.100
    }
  ],.....,
  "陈*月":[
    "FC":{
      "Ex":0.173,
      "En":0.061,
      "He":0.034
    },
    "MC":{
      "Ex":0.312,
      "En":0.031,
      "He":0.027
    },
    "IC":{
      "Ex":0.462,
      "En":0.021,
      "He":0.015
    }
  ]
}
```

5.3.2 用户个体画像模型构建过程

上一节通过样本数据对总体数据的价值特征进行提取，并进行了建模分析，本节将通过 protégé 工具构建用户个体画像本体。

1. 确定用户个体画像的本体的目的和范围

构建用户个体画像本体是为了根据零售户的订单记录来发现该零售户可能需要或者偏好的产品，因此在建立本体库时应使得系统推荐的产品能更适合该零售户的画像特征。

2. 定义类及层次关系

类是相同属性的集合，在构建类的结构时，通过领域概念的分类层次将概念进行分类组织，用于描述领域概念间的类属关系，并将本体中的概念模块化。

在本文中，通过对零售订单的分析，建立零售户与卷烟产品之间的关联关系，将零售户和卷烟作为一级概念。然后分别建立零售户与卷烟的子类作为二级概念，依次类推，最后定义最低级的概念。图 5.4 显示了部分基于 protégé 工具构建的用户画像本体分类的层次关系。




图 5.4 用户画像本体分类的层次关系（部分）

3. 定义类的属性

类只是表示本体的基本知识的框架，并不能描述类之间的关系，其关系的描述需要通

过语义化的方法来实现，在类中我们可以通过类的属性来描述。类的属性包括对象属性（Object Properties）和数据属性（Data Properties），其中对象属性描述的是两个类的实例关系，其定义域为类，值域为某个类的实例。数据属性描述的是实例，定义域为某个类的实例，值域为字符串、整型等类型的值。下表列出了部分属性名称，如表 5.6 所示

表 5.6 类的属性

对象属性	定义域	值域	语义描述	所属类别
卷烟名	卷烟	名称	卷烟有特定的名称	对象属性
好评率	零售户	浮点型	零售户对卷烟的评价	数据属性
重购率	零售户	浮点型	零售户对卷烟的重复购买率	数据属性
上柜率	零售户	浮点型	零售户对卷烟的上柜率	数据属性
订购量	零售户	浮点型	零售户对卷烟的单次购买量	数据属性
订购金额	零售户	浮点型	零售户对卷烟的单次消费金额	数据属性
订购时间	零售户	时间	零售户订购卷烟的时间	对象属性
订购卷烟	零售户	卷烟	零售户对卷烟的系列和品牌	对象属性

根据上面确定的属性在 protégé 中添加编辑如图 5.5 所示




图 5.5 类的属性

4. 创建实例

实例是类的具体表现形式，类的实例通常包括类的名称、所属类别、实例等信息。在本文中，白沙（硬和气生财）是白沙一类的实例，郭某是重要保持客户的具体实例，其属性重购率为 90%，则有该零售户建立了与白沙一类之间的联系，在该零售户采购卷烟时，我们可以给他推荐白沙一类的其他系列，例如白沙（珍品）等，用户画像本体相关实例的示例如表 5.7 所示

表 5.7 用户画像本体相关实例的示例

实例名称	所属类别	说明
白沙（硬和气生财）	卷烟（白沙一类）	白沙一类烟的一种卷烟
郭某	重要保持客户	郭某具有重要保持客户的特征

在构建本体时，不仅可以用构建工具，还可以通过 owl 语言来构建本体，protégé 编辑器可以自动生成完整的 OWL 代码，本文中用户画像本体的部分代码如下：

```
<?xml version="1.0"?>
<rdf:RDF xml:base="http://www.semanticweb.org/ontologies/2017/11/Ontology1512442049370.owl">
  <!-- Object Properties -->
  <owl:ObjectProperty rdf:about="#topObjectProperty"/>
  <owl:ObjectProperty rdf:about=" 卷烟名">
    <rdfs:subPropertyOf rdf:resource="#topObjectProperty"/>
  </owl:ObjectProperty>
  <owl:ObjectProperty rdf:about="区域">
    <rdfs:subPropertyOf rdf:resource="#topObjectProperty"/>
  </owl:ObjectProperty>
  <!-- Data properties -->
  <owl:DatatypeProperty rdf:about="#topDataProperty"/>
  <owl:DatatypeProperty rdf:about="订购金额">
    <rdfs:subPropertyOf rdf:resource="#topDataProperty"/>
  </owl:DatatypeProperty>
  <!-- Classes -->
  <owl:Class rdf:about="低价值客户">
    <rdfs:subClassOf rdf:resource="零售户"/>
  </owl:Class>
  <owl:Class rdf:about="白沙">
    <rdfs:subClassOf rdf:resource="卷烟"/>
  </owl:Class>
  <owl:Class rdf:about="白沙一类">
    <rdfs:subClassOf rdf:resource="白沙"/>
  </owl:Class>
  <owl:Class rdf:about="白沙二类">
    <rdfs:subClassOf rdf:resource="白沙"/>
  </owl:Class>
  <owl:Class rdf:about="白沙三类">
    <rdfs:subClassOf rdf:resource="白沙"/>
  </owl:Class>
  <owl:Class rdf:about="白沙四类">
    <rdfs:subClassOf rdf:resource="白沙"/>
  </owl:Class>
</rdf:RDF>
```

5. 用户画像本体的存储

在本文中利用 protégé 创建本体，其数据是以 OWL 格式的文件进行存储，在 4.3.2 节中，本文对 owl 格式的存储进行了分析，鉴于传统关系型数据库不能直接来存储 owl 格式的文件，本文引入了数据库管理系统 jena，由于 jena 可以通过接口把数据存储到关系型数据库中，因此基于 owl 格式的文件存储得以解决，下面介绍通过 MySQL 存储 owl 格式文件的过程。

首先连接 MySQL 数据库,在命令行界面输入正确的用户名和密码后进入如下界面，如图 5.6 所示




图 5.6 成功连接 mysql 数据库界面

然后创建数据库，在命令行界面输入 create database ontodb，当 protégé 通过 API 第一次加载模型时，这时可以从文件读取本体到模型，第一次将模型存入数据库时会自动生成几张表，如图 5.7 所示




图 5.7 用户画像本体生成的表格

5.4 云模型画像聚类与本体推理案例分析

5.4.1 基于云模型的用户价值画像聚类案例分析

在上一节中,通过逆向高斯云算法将基于 RFM 模型的标签转换为云模型价值画像标签，最后以 BSON 格式的文件存储在 MongoDB 数据库中，这样外部应用程序就可以直接通过 JDBC 从 MongoDB 数据库中调取数据，在 4.3.3 节，本文对传统的 K-means 聚类算法进行了改进，使得改进后的聚类算法能够适应于云模型领域。对样本数据进行用户价值画像聚类分析，如表 5.8 所示

表 5.8 云模型用户价值画像聚类结果

用户画像类型	聚类数	云模型聚类中心		
		消费频率云模型	消费金额云模型	时间间隔云模型
用户价值画像一	529	(0.521, 0.026, 0.012)	(0.453, 0.041, 0.017)	(0.119, 0.023, 0.011)
用户价值画像二	203	(0.131, 0.042, 0.013)	(0.473, 0.133, 0.032)	(0.331, 0.063, 0.022)
用户价值画像三	826	(0.156, 0.041, 0.013)	(0.438, 0.130, 0.063)	(0.731, 0.081, 0.025)
用户价值画像四	357	(0.216, 0.059, 0.017)	(0.163, 0.043, 0.011)	(0.685, 0.102, 0.020)

通过云模型聚类算法，将样本划分为四类不同的用户价值画像，用户价值画像由消费频率云模型、消费金额云模型和时间间隔云模型三个指标共同决定，根据这三个指标可以将其通过正向高斯云发生器得到的云模型的云滴图，这里这里取云滴数为 2000，其结果如图 5.8-5.11 所示。通过云滴的分布图可以比较清晰的看到每一类用户价值画像的三个指标分布情况，其中云滴图上越密集的地方代表该概念在该处更容易形成普遍认识，也即该价值画像指标隶属于该概念的程度越高，是该概念最具代表性的点。




图 5.8 用户价值画像一云滴图




图 5.9 用户价值画像二云滴图




图 5.10 用户价值画像三云滴图




图 5.11 用户价值画像四云滴图

云模型的三个数字特征参数中，期望（ E_x ）代表用户画像某种行为特征的最可能取值，熵（ En ）反映了用户画像某种行为特征所有的取值相对于期望（ E_x ）的离散度，熵越大代表该用户画像所代表的某种行为属性的稳定性低.通过期望（ E_x ）和熵（ En ）可以近似的将云图转换为一个区间的取值.超熵（ He ）反映了熵的离散程度，超熵越小云滴越聚集在云图的轮廓线附近。

一个云图是由许许多多的具有三个数字特征的云滴组成，所有的云滴对某种定性概念的形都有贡献，不同的云滴群对概念的贡献是不同的^[48]，根据李德毅院士证明的高斯云“ $3En$ 规则”（如图 5.12 所示），即可以忽略 $[E_x - 3En, E_x + 3En]$ 区间外的云滴对定性概念的贡献。




图 5.12 论域中的元素对定性概念的贡献

根据高斯云“3En规则”，由期望（ E_x ）和熵（ En ）可以近似的将云图转换为一个量化的区间范围，得到如表 5.9 结果，该区间取值的范围大致描述了对应的用户画像模型。

表 5.9 用户价值画像定量值区间范围

用户画像类型	消费频率云模型	消费金额云模型	时间间隔云模型
用户价值画像一	[0.440, 0.602]	[0.330, 0.576]	[0.050, 0.188]
用户价值画像二	[0.005, 0.257]	[0.074, 0.872]	[0.142, 0.520]
用户价值画像三	[0.033, 0.279]	[0.048, 0.828]	[0.488, 0.976]
用户价值画像四	[0.099, 0.333]	[0.034, 0.292]	[0.379, 0.991]

为了从用户画像中分析得出各种类型画像的映射群体及群体代表的用户特征，取高斯云“3En规则”的区间中点代表该行为属性的聚集点，得到客户群特征图，如图 5.13 所示




图 5.13 用户价值画像聚类指标特征

如上图所示，通过纵向比较，消费频率在用户价值画像三所代表的群体中该特征比较明显；消费金额在用户价值画像一、用户价值画像三和用户价值画像四所代表的群体中该特征均表现明显，在用户价值画像二所代表的群体中该特征比较弱；时间间隔在用户价值画像三和用户价值画像四所代表的群体中特征比较明显，在用户价值画像一和用户价值画像二所代表的群体中该特征比较弱. 从图中可以看出，每一类型的用户价值画像都具有显著不同的特征，通过对不同类型的用户价值画像和用户行为特征的分析，将这四种用户价值画像映射为四类群体：重要保持客户、重要挽留客户、重要发展客户、低价值客户^[49]，其价值特征分布如图 5.14 所示




图 5.14 客户群体指标特征

5.4.2 基于本体推理的用户个体画像案例分析

本文通过构建用户个体画像本体来建立零售户与产品之间的关联,在对该零售户客户分类已知的情况下,通过零售户的历史信息来推理出该零售户可能感兴趣的产品。

Jean API 提供了对本体数据的处理能力,实现了 RDFS 推理机和 OWL 推理机,可以通过本体中已有的知识和公理。结合自定义的规则,推理出新的知识,并可以通过 SparQL 对本体进行查询。

要进行用户个体画像领域内的规则推理就需要结合用户个体画像本体知识对 RDF 规则进行自定义,本文在用户个体画像本体的基础上主要从以下几个方面来考虑。

- (1) 根据客户价值来推荐产品
- (2) 根据品牌效应来推荐给客户
- (3) 提升客户价值等级

本文通过对用户个体画像本体的研究,针对以上几个方面的情况,利用 Jena Rules 来表示相关的推理规则。

(1) 零售户对某产品的高重购率,可以作为备选产品推荐给与其等价值群的零售户,对此编写规则如下:

[Rule1:(?A owl:instanceOf ?X),(?B owl:instanceOf ?X),(?A 重购率 ?Y)

→(?B 推荐购买 ?Y)];

规则 1 表示: X 是零售户子类,表示某价值客户群体, A 和 B 是零售户子类 X 的实例,表示具体某零售户, Y 是卷烟子类,表示某卷烟品牌。则可以向 B 推荐购买 Y。例如零售户 A 和零售户 B 均是重要保持客户, A 购买白沙一类烟的重购率较高,那么 B 在购买卷烟时可以推荐白沙一类烟。

(2) 零售户对某种品牌的卷烟有很高的评价,可以根据品牌效应给该零售户推荐同品牌其他系类的卷烟,对此编写规则如下:

[Rule2:(?A owl:instanceOf ?X),(?B owl:instanceOf ?X),(?Y 好评率 ?B) →(?Y 推荐购买 ?A)];

规则 2 表示: X 是卷烟子类,表示某卷烟品牌, A 和 B 是 X 的实例, Y 是零售户子类的实例,表示具体零售户, Y 对 B 的有较好的好评率,则可以向 Y 推荐 X 的其他实例 A。例如零售户 Y 对白沙一类烟品牌下的白沙(硬和气生财)有较好的好评率,在 Y 在此购买时系统可以推荐 Y 选购白沙一类烟品牌下的白沙(珍品)。

- (3) 根据零售户价值分类按价值重要程度从高到低依次是重要保留客户、重要发展客户、

重要挽留客户和低价值客户，实现客户价值重要程度的提升，需要做到客户体验满意度的提升，对此编写规则如下：

[Rule3:(?A owl:instanceOf ?X), (?B owl:instanceOf ?C) ,(?Y 好评率 ?B),(?Z 好评率 ?B)→
(?A 推荐购买 ?C)];

规则 3 表示：X,Y 和 Z 分别是零售户子类，且其客户价值依次递增，C 是卷烟的子类，代表某品牌的卷烟，B 是 C 的实例，代表某种卷烟，A 是 X 的实例，表示具体某零售户，Y 和 Z 对 C 具有较高的好评率，则可以向 A 推荐购买 C。例如重要保持客户 B 和重要发展客户 C 对白沙一类烟品牌下的白沙（珍品）好评率高，重要挽留客户 A 在选购卷烟是可以把比其客户价值高的客户好评率高的卷烟白沙（珍品）推荐给 A。以获得 A 较高的满意率，达到提升客户价值的目的。

在 Jena 中进行推理时，首先需要获取一个推理接口，主要代码如下所示：

```
1. List<Rule> rules=Rule.rulesFormURL(path);//path是推理规则路径
2. GenericRuleReasoner reasoner=new GenericRuleReasoner(rules);//基于规则的推理对象
3. reasoner.setOWLTranslation(true);
4. reasoner.setDerivationLongging(true);
5. reasoner.setTransitionveClosureCaching(true);
```

获取接口后，然后接下来需要获取推理的本体，其主要代码如下所示：

```
1. Model model=ModelFactory.createDefalutModel();//创建缺失模型对象
2. model.read(path);//读取本体文件
3. OntModel ont=ModelFactory.createOntologyModel(
    OntModelSpec.OWL_DL_MEM_RDFS_INF,model);//创建本体模型对象
4. Resource configuration=ont.createResource();//创建资源对象
5. configuration.addProperty(ReasonerVocabulary.PROPruleModel," hybrid");//给资源添加属性
```

最后，创建查询对象 QueryExecution，通过查询对象来创建查询执行对象，通过该对象得到查询的结果集，其主要代码如下所示：

```
1. Query query=QueryFactory.create(queryString);//创建查询对象
2. QueryExcution qe=QueryExcutionFactory.create(query,this.inf);//创建执行对象
3. ResultSet results=qe.execSelect();//结果集对象
4. ResultSetFormatter.out(System.out,results,query);//执行结果集，输出结果
5. qe.close();//关闭执行对象
```

通过以上代码就可以根据自定义的规则进行推理，利用 SparQL 来构造查询语句。其中 SparQL 格式如下所示：

```
PREFIX namespace:<http://www.owl-ontologies.com/saleman.owl#> //定义命名空间
SELECT ?V1 ?V2 ?V3 //查询字段 V1,V2,V3
WHERE //查询的条件，由三元模式组成
{
    ?类 namespace:属性 ?类
    ?实例 namespace:属性 ?类
    ?子类 namespace:属性 ?类
}
```

例如，本文通过本体推理要给重要保留客户何某推荐可能感兴趣的产品。其主要代码如下所示：

```
1.String rule="[[Rule1:(?A owl:instanceOf ?X),( ?B owl:instanceOf ?X),( ?A 重购率 ?Y)
→(?B 推荐购买 ?Y)]]";
2.GenericRuleReasoner reasoner=new GenericRuleReasoner(Rule.parseRules(rule));
3.Model model=ModelFactory.createDefalutModel();
4.model. read("d://paper/data/profile.owl");
5.String qString=" PREFIX P:<http://www.owl-ontologies.com/ profile.owl#>"
+" SELECT ?B ?Y WHERE {"" ?张** owl:instanceOf ?重要保留客户 ""
+" ?何** owl:instanceOf ?重要保留客户 ?张** ?P:重购率 ? Y "" } ";
6.Query query=QueryFactory.create(qString); //推理
7.ResultSet results=QueryExecutionFactory.create(query,model).execSelect();
```

其查询推荐结果如表 5.10 所示

表 5.10 查询推荐结果

姓名	推荐产品
何**	芙蓉王硬（天源）
	芙蓉王硬（君信）
	白沙一类（和气生财）

5.5 精准推送模型应用分析

根据本章的实验分析结果，得到基于云模型的 RFM 指标聚类的用户价值画像群体可以被映射为重要保留客户、重要发展客户、重要挽留客户和低价值客户四种类型的客户群，针对这四类群体的特征来指导企业开展相应的商业营销活动，企业可以根据不同群体的特征来建立相应的服务推荐库，建立群体与服务之间的关联；同时企业可以根据不同个体消费行为的特征来建立产品推荐库，建立个体与产品之间的关联。接下来本文针对这四类客

户的价值特征来分析如何建立服务推荐库来精准推荐给特定价值的群体以及如何根据客户个体画像来精准推荐产品。

（1）重要保留客户

该类客户的特征是消费频率高、消费的金额高和最近一次消费的时间离统计的节点比较近。这类客户具有很高的消费能力，同时他们对该企业的产品具有很高的忠诚度，是企业综合服务价值最高的客户，对他们应该建立互动的和高接触的渠道来进行差异化管理和一对一精细化营销，例如给他们推出 VIP 会员服务的专属通道，他们可以通过这个通道享受更加便捷的个性化服务以及企业提供的忠诚福利等，通过这些高质量的服务不断提高该用户的忠诚度与满意度，尽可能延长其高消费的水平。

（2）重要发展客户

该类客户的特征是消费频率低、消费的金额高和最近一次消费的时间离统计的节点比较近。他们是企业潜在客户，既是容易流失的客户类型也是容易发展为企业忠臣客户的类型，企业需要针对该类型的客户制定更具互动性和个性化的创新渠道来了解他们的需求和挖掘他们的兴趣，以便实现服务升级。例如建立产品积分等级制使客户的每一次消费都能为下次消费带来经济效益来促进该群体消费能力和忠诚度，同时为他们提供更具性价比的产品来提高该类客户的满意度，使他们逐渐成为企业的忠诚客户。

（3）重要挽留客户

该类客户的特征是消费频率低、消费金额高和最近一次消费的时间离统计的节点很久远。该类客户价值变化的模糊性和随机性比较大，针对该类客户企业需要通过更大力度的品牌维系和服务补救措施来实现该类型客户的价值升级和挽留客户的目的。例如给该类客户推出优惠的包月套餐或者年度套餐，同时给他们推荐本企业高价值客户（重要保留客户或者重要发展客户）重购率和好评率高的产品，让他们体验到企业更有竞争力的产品。对这类客户需要企业多方面掌握该客户的信息，重点联系，采取一定的营销策略来延长该类客户的生命周期。

（4）低价值客户

该类的客户的特征是消费频率低、消费金额低和最近一次消费的时间离统计的节点很久远。该类客户可能只在企业做活动时才会消费或者是出于便利的原则。这类客户是企业的边缘客户，在营销上的成本比较大，但这类客户在某种程度上是企业产品的宣传大军，能够带来销量的大幅提升，在营销服务策略上应该纳入企业可留意的客户群体，一旦企业开展相应的促销活动可以推荐给这类群体。

5.6 本章小结

本章首先对推送模型整体架构进行简单的概述，然后结合真实数据依对海量数据抽样处理、用户画像构建过程和云模型画像聚类与本体推理三个部分开展详细的实验论证与分析，最后，在本章最后一节对该模型的在实际中的应用进行了简单的分析。

第六章 总结与展望

6.1 本文工作总结

当下大数据技术发展变化日新月异,大数据应用已经遍及工业和社会生活的方方面面,原有的数据管理理论体系与大数据产业应用之间的差距越来越大,各企业之间的竞争已经到了寸土必争的时代,如何留住老客户、吸引新的客户以及读懂客户的消费心理和需求,这些都是企业发展至关重要的问题。本文也就是在这一背景下提出了基于零售信息挖掘下面向消费市场的精准推送模型设计研究的论题。本文主要从以下几个方面展开研究。

本文研究了海量数据环境下的抽样,首先从大数据时代统计抽样存在的必要性发表了自己的观点,也即海量数据环境下的抽样并不是直接从海量数据中提取有用的信息,而是通过传统统计学的抽样方法来减少样本分析的数据量,同时又能够使得样本取得良好的响应效果来反映总体的特征,从而加速大数据分析建模的过程,使大数据分析能够更快更准确的发现一些有趣的特征或者模式。然后从三个方面来研究如何在海量数据环境下确定分层界限、分层层数以及样本分配方法。

本文研究了群体用户画像的建模,首先以知识工程为基础,通过知识工程和本体思想将用户标签转化为语义化的标识,构建基于本体推理的用户个体画像标签体系,并通过 jena 来实现本体推理数据在关系型数据库中的存储。然后以云模型理论为基础,提取 RFM 模型价值标签,构建定性-定量转换的云模型用户价值画像标签体系,对云模型用户价值画像标签的数据结构进行分析,并设计云模型用户价值画像标签的存储结构。为实现群体用户价值画像聚类分析,本文设计了云模型聚类算法,其基本原理是用云模型的相似度度量方法来取代 K-means 算法中基于距离的划分依据,将用综合云相似度作为云模型的聚类中心来取代 K-means 算法中的质心。

本文还重点分析了零售信息挖掘下的推送模型的具体实现过程,首先设计并分析了推送模型整体架构,然后以湖南省一年的零售订单数据作为总体对其进行抽样分析,并通过 Kullback-Laibei 信息量来衡量抽样数据的质量。在用户画像建模模块,分别建立了基于云模型用户价值画像标签体系来实现群体与服务之间的关联关系以及基于本体的用户个体画像体系来实现个体与产品之间的关联关系,形成了由服务到群体和由个体到服务的二级精准推送模型。

6.2 不足与展望

由于本人研究时间和水平有限，论文还曾在诸多不完善之处，有待后期做进一步的研究加以改进。

首先，本文在构建用户价值标签体系时，仅仅考虑到的是基于 RFM 模型的客户价值评价指标，但实际中的网络营销需要考虑的因素是多方面的，例如企业的服务质量和品牌效应也会对客户价值产生一定的影响，后续研究可以考虑将这些相关因素通过建立模型的方式植入到客户价值评价体系，使客户价值分类更加明晰和细化。

其次，本文通过知识工程与本体的思想将用户画像标签语义化为计算机所能识别的语言来构建用户个体画像模型，并通过 jena 来实现本体数据在关系型数据库中的存储，但并未对当前本体数据的整理、存储和推理的复杂性做深入的优化和研究，而其复杂性的问题也正是当前本体能否普遍应用在人工智能领域的一个关键性的屏障。

最后，本文深入研究了海量数据环境下抽样方法的相关理论，为当前大数据处理提供了一点思路，但随着计算机存储能力和数据处理能力的显著提高，海量数据抽样将面临诸多挑战，如何从数据抽样的微观角度来分析数据的潜在规律和如何从大数据处理的宏观角度来发现数据价值将有待于数据抽样理论和大数据处理技术的进一步发展。

参考文献

- [1]高芳. REIDY 园艺用品有限公司创业方案[D].沈阳大学,2014.
- [2]记者 苏德悦. 我国互联网普及率超全球平均水平 4.6%[N]. 人民邮电,2017-08-07(001).
- [3] Rao D, Ravichandran D. Semi-Supervised Polarity Lexicon Induction.[C]// Eacl 2009, Conference of the European Chapter of the Association for Computational Linguistics, Proceedings of the Conference, March 30 - April3, 2009, Athens, Greece. DBLP, 2009:675-682.
- [4]王莉. 基于标签的个性化推荐系统的研究与实现[D].北京工业大学,2015.
- [5]夏明星. 基于情感分析的评论极性分类和电影推荐系统的设计与实现[D].安徽大学,2016.
- [6]刘莉平,刘梦,李绍鹏. 基于情感分析的新浪微博争议度分析[J]. 计算机工程与科学,2016,38(10):2158-2164.
- [7]何炎祥,孙松涛,牛菲菲,李飞. 用于微博情感分析的一种情感语义增强的深度学习模型[J]. 计算机学报,2017,40(04):773-790.
- [8] Huang Z, Zeng D, Chen H. A Comparison of Collaborative-Filtering Recommendation Algorithms for E-commerce[J]. IEEE Intelligent Systems, 2007, 22(5):68-78.
- [9]曾俊. 基于 LBS 的电子商务个性化推荐研究[D].湖北工业大学,2016.
- [10]郭燕萍. 基于 LBS 的 O2O 电子商务个性化推荐方法研究[J]. 农业网络信息, 2016,(12):52-54.
- [11] Jiang L, Yang C C. User recommendation in healthcare social media by assessing user similarity in heterogeneous network[J]. Artificial Intelligence in Medicine, 2017.
- [12] Chen G, Zhao J, Cohen T, et al. Using Ontology Fingerprints to disambiguate gene name entities in the biomedical literature. Database the Journal of Biological Databases & Curation, 2015, 2015(13):bav034.
- [13]陈志明,胡震云. UGC 网站用户画像研究[J]. 计算机系统应用, 2017,26(01):24-30.
- [14]姜建武,李景文,陆妍玲,叶良松. 基于用户画像的信息智能推送方法[J]. 微型机与应用,2016,35(23):86-89+92.
- [15] Al-Shamri M Y H. User profiling approaches for demographic recommender systems[J]. Knowledge-Based Systems, 2016, 100:175-187.

- [16] Lieberman H. Letizia: an agent that assists web browsing[C]// International Joint Conference on Artificial Intelligence. Morgan Kaufmann Publishers Inc. 1995:924-929.
- [17] Kunal Thakkar, Jay Shah, Raghav Prabhakar, Anant Narayan, Anurag Joshi. AHP and MACHINE LEARNING TECHNIQUES for Wine Recommendation[J]. International Journal of Computer Science and Information Technologies, 2016, Vol.7(5), 2349-2352
- [18] 吕伟民, 王小梅, 韩涛. 结合链路预测和 ET 机器学习的科研合作推荐方法研究[J]. 数据分析与知识发现, 2017, 1(04):38-45.
- [19] Brbić M, Zarko I P. Tuning Machine Learning Algorithms for Content-Based Movie Recommendation[J]. Intelligent Decision Technologies An International Journal, 2015, 9(3).
- [20] 黄伟. 基于位置的馆藏图书推荐系统[D]. 西南科技大学, 2017.
- [21] 高洪波, 张新钰, 张天雷, 刘玉超, 李德毅. 基于云模型的智能驾驶车辆变粒度测评研究[J]. 电子学报, 2016, 44(02):365-373.
- [22] 李德毅, 刘常昱. 论正态云模型的普适性. 中国工程科学, 2004, (08):28-34.
- [23] WU Aiyun, MA Zhonggui, ZENG Guangping. Set Pair Fuzzy Decision Method Based on Cloud Model. Chinese Journal of Electronics, 2016, 25(02):215-219.
- [24] Rui-xiang DU. A Measurement Method of Threat for Co-Residency Detection Based On Cloud Model[A]. Science and Engineering Research Center. Proceedings of 2016 International Conference on Computer, Mechatronics and Electronic Engineering (CM EE 2016)[C]. Science and Engineering Research Center, 2016:8.
- [25] 崔天宝. 基于云模型的短期电价预测的研究[D]. 保定: 华北电力大学, 2008.
- [26] 张光卫, 李德毅, 李鹏, 康建初, 陈桂生. 基于云模型的协同过滤推荐算法[J]. 软件学报, 2007, (10):2403-2411.
- [27] 许昌林. 基于云模型的双向认知计算方法研究[D]. 西南交通大学, 2014.
- [28] 李克潮, 凌霄娥. 云模型与用户聚类的个性化推荐. 计算机应用, 2013, 33(10): 2804-2806+2826.
- [29] 陈平华, 陈传瑜. 基于云模型的用户双重聚类推荐算法. 计算机工程与科学, 2015, 37(07):1245-1251.
- [30] 计海斌. 基于改进 RFM 模型的应用研究[D]. 吉林大学, 2010.
- [31] Ramón A. Carrasco, María Francisca Blasco, Enrique Herrera-Viedma. A 2-tuple Fuzzy Linguistic RFM Model and Its Implementation[J]. Procedia Computer Science, 2015, 55:.

- [32]张继艳.基于改进 RFM 模型的网络消费者价值识别研究[D].南华大学,2015.
- [33]明勇,张文斌,黄哲学,陈小军.基于 RFM 购买树的客户分群[J].深圳大学学报(理工版),2017,34(03):306-312.
- [34] Peiman Alipour Sarvari,Alp Ustundag,Hidayet Takci. Performance evaluation of different customer segmentation approaches based on RFM and demographics analysis[J]. Kybernetes,2016,45(7):.
- [35]李毅,米子川.大数据挖掘的均匀抽样设计及数值分析[J]. 统计与信息论坛,2015,30(04):3-6.
- [36] C. Soto Valero. Predicting Win-Loss outcomes in MLB regular season games – A comparative study using data mining methods[J]. International Journal of Computer Science in Sport,2016,15(2):.
- [37]扎库拉·戈文达拉玉卢.抽样理论与方法(英文版)[M].北京:机械工业出版社,2005.
- [38]刘建平,陈光慧. 分层抽样中分层界限的优化设计[J]. 统计与决策,2008,(11):4-6.
- [39]刘速.浅议数字图书馆知识发现系统中的用户画像——以天津图书馆为例[J]. 图书馆理论与实践,2017,(06):103-106.
- [40]任天华,张涛.制造型企业知识工程建设[J].技术与市场,2013,20(02):97+99.
- [41]高小龙,朱信忠,赵建民,曹存根,徐慧英,吴德.电影本体的构建与一致性分析[J]. 计算机应用,2014,34(08):2192-2196+2201.
- [42] Sunitha Abburu,Nitant Dube. Ontology Concept-Based Management and Semantic Retrieval of Satellite Data[J]. Journal of Intelligent Systems,2017,26(2):.
- [43]闫明月. 基于 kernel K-means 算法的城市交通客流量分析[J]. 物流技术,2013,32(17):158-160+213.
- [44] http://jena.apache.org/getting_started/index.html.
- [45]刘玉海.基于 MongoDB 的煤矿大数据管理研究[J].信息系统工程,2017,(09):119-120.
- [46]陈超,王亮,闫浩文,仇阿根,李玉祥,朱芳菲. 一种基于 NoSQL 的地图瓦片数据存储技术[J]. 测绘科学,2013,38(01):142-143+159.
- [47]安鲜儿.基于海量数据的企业营销资源优化研究与分析[D].浙江理工大学,2017.
- [48]李德毅.知识表示中的不确定性[J].中国工程科学,2000,(10):73-79.
- [49]丁欣.东方航空公司机票营销渠道优化策略研究[D].上海:复旦大学,2013.

致谢

不知不觉已经走过了研究生两年半的生涯，此刻将意味着我顺利的通过了浙江理工大学的硕士学位论文答辩，即将开启我人生的下一个篇章。回首过往，奋斗和辛劳成为了丝丝记忆，研究生期间的甜美和欢笑也成为了我永远的记忆，在浙江理工大学的求学生涯让我学到了很多，也让我成长了很多。值此硕士学位论文答辩完成之际，我谨向所有关心、爱护、帮助我的人们表示最诚挚的感谢与最美好的祝愿。

首先，我要感谢我的导师何利力教授，何老师在我研究生期间给了我很多帮助，从开题到最后的顺利完成硕士学位论文答辩直接或间接的都得到了何老师对我论文的指导和支持。从小论文的退稿到小论文的最终被期刊录用何老师功不可没。何老师给我们提供了一个良好的实践平台，让我们在研究生期间有机会零距离接触企业的业务并在熟悉业务的过程中锻炼了自己的技术，为我们毕业后的就业作了很好的铺垫。在此我衷心的感谢我的恩师何利力教授。

其次，我要感谢在研二实习期间给我帮助的各位师兄师姐，在实习期间我深入接触了湖南中烟的客户营销的业务，结实了一批技术达人，通过与甲方之间的业务交流和同事之间的技术沟通极大的拓展了我对软件开发行业的知识面，开启了我对软件开发行业的职业生涯规划。最怀念的是实验室齐聚在湖南中烟实习的那段短暂而又快乐的时光。

最后，衷心的感谢各位专家在百忙之中抽出时间对本文提出的宝贵意见。

攻读学位期间的研究成果

1. 参加的科研项目：

[1]湖南省“湖南中烟工业公司全国零售户订单数据分析系统”项目.2016.7-2017.5

[2]杭州“绿城（中国）业务融合平台”项目.2017.7-2017.10

2. 发表的论文：

[1]姚龙飞,何利力.基于云模型理论的群体用户画像模型[J].计算机系统应用（已录用）.