

经济与管理

谭琛, 周欣然, 栾晓宇, 等. 基于高维精准画像与深度学习的卷烟零售户动态分档研究[J]. 中国烟草学报, 2024, 30(3). TAN Chen, ZHOU Xinran, LUAN Xiaoyu, et al. Research on dynamic classification of cigarette retailers based on high-dimensional precise profiling and deep learning[J]. Acta Tabacaria Sinica, 2024, 30(3). doi:10.16472/j.chinatobacco.2022.073

基于高维精准画像与深度学习的卷烟零售户动态分档研究

谭琛¹, 周欣然¹, 栾晓宇¹, 李敏刚², 杨云丽^{3*}, 顾敏洁⁴, 金雅昭⁴

1 上海烟草集团有限责任公司信息中心, 上海市长阳路 717 号 200082;

2 上海烟草集团有限责任公司营销中心, 上海市长阳路 733 号 200082;

3 上海品见智能科技有限公司, 上海市合川路 2679 号 201101;

4 北京大数据研究院企业数智化转型研究中心, 北京市海淀区颐和园路 5 号 100080

摘要:【目的】丰富卷烟零售户考核评价的维度, 建立档位动态认定的科学标准, 辅助档位调整、分类管理及投放策略制定等营销工作。【方法】提出基于高维精准画像体系和深度学习模型进行档位识别的解决方案, 介绍档位标签推演、画像特征指标设计、识别模型搭建、新零售户样本预测及评价、档位动态调整等环节的可行策略, 并通过分析特征重要性挖掘到零售户档位的潜在影响因素。【结果】在数值实验部分, 基于 A、B 市场多个投放周期内的营销数据, 对比非线性深度学习 DXGBOOST 模型与线性回归 LR 模型、梯度提升 XGBOOST 模型的分类识别效果: 相比线性的 LR, DXGBOOST 算法可将 A、B 两市零售户档位识别准确率分别提升 9.09% 和 15.43%; 相比非线性的 XGBOOST, 可进一步提升精准档位及档位区间的准确率, 降低误判的偏差程度。【结论】实践证明, 在保证稳定性的前提下, 基于 DXGBOOST 模型的档位识别方法可以很大程度提升卷烟零售户档位的划分精度, 为及时开展科学、精准、智能地营销分析与商业决策提供数据和理论支撑。

关键词: 精准画像; 档位识别; 深度学习; DXGBOOST 模型; 卷烟零售户

烟草行业内常规投放策略包括按“档位”、按“档位+价位”、按“档位+商圈位置”、按“档位+星级”投放等^[1], 按档投放是卷烟商业投放策略制定中一种常见且重要的方式, 零售户档位的精准判定为投放精准的基础^[2]。档位判定方法的科学性、公正性、合理性, 不仅利于零售商户在激烈竞争中获得健康稳定的发展, 也利于维护卷烟市场的经营秩序、营造公平竞争的市场环境。随着大数据+人工智能时代的到来, 对卷烟零售户的研究需要逐步由“经验式分析”向“数据化分析”转变^[3]。本文从一个新的角度对人工智能学习算法在零售户档位识别环节的应用进行前瞻性研究, 辅助精细化终端零售户画像^[4]及定档分级, 为智能营销与管理提供支撑。

目前国内外针对卷烟零售户档位判定的研究相对较少, 更多关注于卷烟投放策略的制定^[5]与分析^[6]。卷烟零售户分类的相关研究^[7]主要集中在依据商圈、经

营业态、经营能力、销售潜力等维度进行分类。文献[8]提到了利用数据挖掘方法计算产品属性重要程度, 挖掘产品属性与客户行为之间的本质联系, 再结合模糊综合评价法对零售户的销售能力进行评分, 进而给出一种评估区域市场客户对卷烟产品销售潜力 G 值的新方法, 但是尚未对不同客户群的 G 值差异关系进行深入分析。文献[9]依据经营能力对客户进行分类, 将零售客户上一季度的月均购进量和月均购进条均价分别划分为 11 和 12 个区间, 即理论类别数量为 132。每个季度直接根据 2 个指标的数据对零售客户进行自然归属分类, 该方法因对零售户分类较细而不易管理, 在区间阈值的确定时缺乏客观分析, 客户分类虽然是动态调整的, 但调整速度较慢, 其合理性、通用性及适用性需要更多的实践验证。文献[10]在维持“购进数量”、“购进金额”、“购进品规数量”三个维度分值区间不变的基础上, 基于营销数据使用 CRITIC

作者简介: 谭琛 (1980—), 本科, 工程师, 信息化与大数据分析, Tel: 021-61669711, Email: tanchen@sh.tobacco.com.cn

通讯作者: 杨云丽 (1991—), Tel: 15618063536, Email: yunli252@mail.ustc.edu.cn

收稿日期: 2022-04-18; 网络出版日期: 2023-09-28

方法来优化三个维度的权重指标，形成综合评分后再利用 K-MEANS 算法实现对零售户的划分。该研究在评价零售户时参考的维度也相对较少，评分是采用三个维度的线性加权，缺乏对大数据的挖掘，在应对波动性较大的指标时，鲁棒性不佳。朱卫东等^[1]选择零售户经营业态、市场类型、销售行为、卷烟品种数等指标，采用自组织特征映射神经网络 SOM 方法对零售客户进行聚类，并依据聚类结果将零售户划分成 5~7 类，此种方法不太适宜作为行业提出按 30 档进行客户分档管理的参考依据。

纵观上述，已有研究多基于多维指标，使用主观评分、线性加权或者聚类分析的方法进行卷烟零售户的分类，缺乏对零售户进行更精准的画像，仅采用简单的评价模型尚不能完全刻画出卷烟零售户的真实归属类别。本文提出了基于卷烟订单详情、卷烟基本属性及部分中高端卷烟商业投放计划等业务数据，对零售户进行实时地精准画像，建立梯度提升决策树 XGBOOST 与深度神经网络 DNN 组合的模型（简称 DXGBOOST），改进了基于简单线性模型的分类效果。该方法达到对零售户档位进行更高精准的识别效果，为卷烟零售户档位的动态调整、“一品一地一策”精准投放策略的定制等奠定基础并提供数据支撑。

1 零售户分档方案的核心原理

1.1 部分零售户档位标签的推演

基于成对矫正的投放标量映射法对零售户进行档位标签推演，为后续建模提供必要的样本标签。即：在任意投放周期内，基于所有卷烟商业投放计划中的投放标量以及对应的投放档位范围，并结合所有卷烟实际订购量，经过多轮成对矫正完成对零售户档位的

推演。其中，成对矫正体现在每轮次零售户的档位推演由两种卷烟共同决定。具体推演模型如下：

假设在某周期内，已知卷烟 a 对档位范围为 $[K_i^{a,min}, K_i^{a,max}]$ 的零售户的计 划 投 放 标 量 为 n_i^a ， 卷 烟 b 对 档 位 范 围 为 $[K_j^{b,min}, K_j^{b,max}]$ 的零售户的计 划 投 放 标 量 为 n_j^b ，其中 $i = 1, 2, \dots, n_a, j = 1, 2, \dots, n_b$ ；再对比实际订单可确定卷烟 a 订购量为 n_i^a 且卷烟 b 订购量为 n_j^b 的零售户档位区间最可能为 $[\max(K_i^{a,min}, K_j^{b,min}), \min(K_i^{a,max}, K_j^{b,max})]$ ，简记第 t 轮成对矫正后零售户档位范围为 $[K_t^{min}, K_t^{max}]_{K_t^{min} \leq K_t^{max}}$ ，其中 $K_t^{min} = \max(K_i^{a,min}, K_j^{b,min})$ ， $K_t^{max} = \min(K_i^{a,max}, K_j^{b,max})$ ，则基于 M 次成对矫正的可能档位区间集合为 $\{[K_t^{min}, K_t^{max}] | K_t^{min} \leq K_t^{max}, 1 \leq t \leq M\}$ 。进而推演出零售户档位标签的下界为 $\max_{1 \leq t \leq M} K_t^{min}$ ，上界为 $\min_{1 \leq t \leq M} K_t^{max}$ 。

特别地，若档位标签下界值与上界值相等时，可确定出零售户的精确档位；若档位标签下界值大于上界值时，该零售户实际订购行为与商业计划不匹配，暂时不作为后续建模样本；若档位区间跨度较大时，该零售户也不参与建模。实际数据的建模处理详情，可参见 2.1 小节。

1.2 任意零售户精准画像特征指标的定义

考虑到不同投放周期内档位与其计划投放标量之间的对应关系存在一定差异性，仅仅使用零售户订购总量、订购金额等来预测零售户的档位还不够充分。为了更精准的判别零售户的档位，本研究中基于真实订单详情数据，从基本属性、订购属性、订购倾向、贡献分位、相对排名等维度构建高维精准画像体系，形成档位判别的候选特征集，详见表 1。

表 1 卷烟零售户画像的指标体系
Tab.1 Index system of cigarette retailer portraits

画像维度	字段名称	数量
订购属性类	订购数量、订购金额、订购卷烟种类数、订购卷烟最高单价、订足卷烟种类数、定足卷烟占比、需求总量、订购条均价	8
贡献分位类	订购数量贡献分位、订购数量矫正下界贡献分位、订购数量矫正上界贡献分位、订购金额贡献分位、订购金额矫正下界贡献分位、订购金额矫正上界贡献分位、订购卷烟种类贡献分位、订购卷烟种类矫正下界贡献分位、订购卷烟种类矫正上界贡献分位、订购卷烟最高单价贡献分位、订购卷烟最高单价矫正下界贡献分位、订购卷烟最高单价矫正上界贡献分位、需求量贡献分位、需求量矫正下界贡献分位、需求量矫正上界贡献分位、条均价贡献分位、条均价矫正下界贡献分位、条均价矫正上界贡献分位	18
相对排名类	订购数量相对排名、订购金额相对排名、订购卷烟种类相对排名、订足卷烟种类相对排名、需求量相对排名、条均价相对排名	6
基本属性类	城乡分类、经营规模、经营业态	3
订购倾向类	N 类卷烟(一类、二类、三类、四类、...)的订购量; 省外卷烟订购品种数、省内卷烟订购品种数、省外卷烟订购量、省内卷烟订购量	10+

表 1 中某些指标计算逻辑定义如下, 假设在某投放周期 T 内, n 个零售户的某观测值(如: 订购金额、订足卷烟种类等)按照增序排列为 $\{s_1, s_2, s_3, s_4, \dots, s_n\}$, 则:

$$\text{第 } i \text{ 个零售户的贡献分位} = \frac{\sum_{j=1}^i s_j}{\sum_{j=1}^n s_j}$$

$$\text{第 } i \text{ 个零售户的矫正下界贡献分位} = \frac{\sum_{j=1}^{j=\arg\min_k \{S_k=S_i\}} s_j}{\sum_{j=1}^{j=n} s_j}$$

$$\text{第 } i \text{ 个零售户的矫正上界贡献分位} = \frac{\sum_{j=1}^{j=\arg\max_k \{S_k=S_i\}} s_j}{\sum_{j=1}^{j=n} s_j}$$

$$\text{第 } i \text{ 个零售户的相对排名} = \frac{\arg\min_k \{S_k=S_i\} + \arg\max_k \{S_k=S_i\}}{2 * n}$$

1.3 零售户档位识别算法的设计

1.3.1 模型搭建

LR 算法作为一种典型的线性分类器, 其核心过程等价于直接对特征进行权重求和, 决策边界是线性方程, 存在可解释性强的优势, 但不易捕捉到非线性信息, 需要预先进行大量特征工程找到特征组合。XGBOOST 算法基于决策树模型自身的特点, 将多个子模型 $f_i(x)$ 进行堆叠, 后一个子模型在前一个子模型的基础上学习其剩余的残差, 训练完成得到 m 个子模型。在样本预测时, 直接将每个子模型进行线性加和, 即:

$$\hat{y} = \varphi(x) = \sum_{i=1}^m f_i(x)$$

其中 $\{f_i(x) = w_{q(x)} \mid q: R^n \rightarrow T, w \in R^T\}$ 是由多个子模型构成的决策树模型集合, $w_{q(x)}$ 为叶子节点 q 的

分数。

特别地, 每棵决策树得到的叶子结点信息可以视为一种高阶的交叉特征, 利用这份预训练学习到的交叉特征结合原始特征, 借助深度神经网络 DNN 较强的非线性拟合和学习能力, 进一步挖掘线性加和所无法关注到的特征信息, 更好地捕捉到卷烟零售户画像指标数据与档位之间的非线性映射关系。为此, 本文建立了基于 XGBOOST 改进的深度组合模型(简称 DXGBOOST)作为一种卷烟零售户档位分类器, 其模型结构如图 1。

在 DXGBOOST 模型中, 通过将 XGBOOST 模块获取到的叶子节点信息用作 DNN 模块的输入信息实现模型融合, 其大致思想为: 首先, 用原始高维画像特征训练 XGBOOST 模块获取交叉特征, 即每个样本落在 XGBOOST 中各棵子树上的叶子结点信息构成的高阶交叉特征向量, 其长度等于 XGBOOST 模块中所有子树包含的叶子节点数之和。例如: 假设模型共有 4 棵子树且叶子节点数量分别为 4、3、3、2, 则交叉特征向量为 $[x_{11}, x_{12}, x_{13}, x_{14}, x_{21}, \dots, x_{42}]$, 其中前 4 位表示第 1 棵树的叶子节点信息, 以此类推。其次, DNN 模块采用了多层感知机结构, 激活函数为收敛速度较快的 ReLU, 每层神经元个数遵循塔式变化原则, 默认使用两个隐藏层, 各层神经元间采用全连接的形式。将 XGBOOST 模块获得的交叉特征与原始高维画像特征联合作为 DNN 模块的输入层, 最后保证输出层神经元个数与零售户档位数保持一致。




图 1 DXGBOOST 模型结构示意图

Fig.1 Schematic diagram of DXGBOOST model structure

1.3.2 特征选择及模型训练

为从高维画像特征指标中挖掘到对档位判别核心有效的入模变量,采用相关性分析剔除原始变量之间相关性较高的特征,并采用卡方检验和最大信息系数法来评估零售户画像特征与其档位的相关性,最后通过设置阈值来获取到对模型训练起重要作用的入模特征。

基于筛选后的入模特征和推演的档位标签进行建模样本的构造及模型参数的训练,即:对于任意投放周期 T ,使用零售户的入模变量 $\mathbf{X}^T$ 和档位 $\mathbf{Y}^T$ 构造样本集 $\{(\mathbf{X}^T, \mathbf{Y}^T)\}$,随机划分出训练集进行档位识别模型参数的拟合,在模型训练的第一阶段采用 Grid Search CV 进行 XGBOOST 模块的参数调优,并对训练集中各样本进行预测以获取到叶子节点对应的交叉特征;在第二阶段将交叉特征与入模变量 $\mathbf{X}^T$ 拼接成 DNN 模块的输入特征,通过控制变量法逐步对 DNN 网络结构进行参数调优,从而得到档位识别模型 $\mathbf{y} = \text{Model}(\mathbf{x})$ 。实际建模中的部分核心超参数详情参见 2.1 小节。

1.3.3 模型评价指标

假设分类模型的混淆矩阵 $\mathbf{N} = \{n_{ij}\}_{i,j=1,2,\dots,K}$, n_{ij} 表示第 i 类的样本被预测成第 j 类的数目, K 为总类别数。准确率 ACC 、浮动正确率 R_ACC 、平均绝对误差 MAE 的定义如下:

$$ACC = \frac{1}{n} \sum_{i=1}^K n_{ii}$$

$$R_ACC = \frac{1}{n} \sum_{i,j=1, |i-j| \leq 1}^K n_{ij}$$

$$MAE = \frac{1}{n} \sum_{i,j=1}^K |i-j| \cdot n_{ij}$$

其中 n 为样本的总数目,即混淆矩阵各元素相加,

ACC 、 R_ACC 的取值范围分别为 $[0,1]$,其取值越大分类效果越好, MAE 的取值范围为 $[0, K-1]$,其取值越小分类效果越好。

1.4 任意零售户档位的判别

基于已训练的档位识别模型 $\mathbf{y} = \text{Model}(\mathbf{x})$ 对任意零售户 i 进行档位判别,预测档位概率向量为 $\mathbf{y}_i = (p_1, p_2, p_3, \dots, p_K)$ 时,则该零售户最可能的档位为 $\tilde{k} = \text{argmax}_{1 \leq j \leq K} \{p_j\}$,零售户档位浮动区间为 $[\max(1, \tilde{k}-1), \min(\tilde{k}+1, K)]$ 。

2 实验结果分析与应用

本文基于 A、B 两市在 2021 元春市场的商业订单详情、卷烟基本属性及部分中高端卷烟商业投放数据开展研究,数据来源于烟草营销公司数据库。通过对比实验探究深度提升树 DXGBOOST、梯度提升树 XGBOOST 及线性 LR 等不同模型在卷烟零售户档位识别上的分类效果,并通过特征重要性分析挖掘出卷烟零售户档位的潜在影响因素。最后,对基于自动学习的零售户档位识别模型如何服务于各类卷烟零售户档位的动态调整进行介绍,为零售户管理及投放策略的制定等奠定基础。

2.1 数据情况及实验设计

A、B 两市上零售户的总档位数均是按 30 档来进行划分的,基于中华软、中华硬、中华双中支等中高端卷烟在各投放周期内的商业投放计划与订单详情对零售户进行档位标签推演,可得到部分零售户的精确档位或档位区间。特别地,将低档位非精确档零售户和高档位精确档零售户进行重分组映射成 23 类,即:1~5 档内为第一类,6~9 档位为第二类,第 10 及以上档位分别为第三、四、.....、二十三类,并采用随机抽样的方式进行档位识别模型训练集与测试集的划分,卷烟零售户数的分布情况见表 2。

表 2 2021 元春市场 A、B 市上不同投放周期内各类零售户的分布情况

Tab.2 Distribution of retailers in different delivery period on the market A and B during the New Year's Day and Spring Festival in 2021

投放周期	零售户数		实际有订购零售户数		精确档位零售户数		低档位非精确档零售户数		训练集零售户数		测试集零售户数	
	A 市	B 市	A 市	B 市	A 市	B 市	A 市	B 市	A 市	B 市	A 市	B 市
20201228—20210105	21927	48720	21673	46303	12823	25175	8147	9217	15724	25800	5246	8592
20210106—20210111	21941	48751	21669	46517	12854	25201	8205	9509	15794	26033	5265	8677
20210112—20210117	21977	48799	21711	46583	12844	25185	8178	9436	15763	25964	5259	8657

续表 2

投放周期	零售户数		实际有订购零售户数		精确档位零售户数		低档位非精确档零售户数		训练集零售户数		测试集零售户数	
	A 市	B 市	A 市	B 市	A 市	B 市	A 市	B 市	A 市	B 市	A 市	B 市
20210118—20210123	21991	48808	21722	46559	12831	25203	8157	9342	15737	25921	5251	8624
20210124—20210129	22013	48803	21675	46265	12810	25090	8133	9217	15709	25726	5234	8581
20210130—20210203	22036	48852	21631	46028	12779	25012	8056	9164	15621	25656	5214	8520
20210204—20210208	22058	48849	21657	45941	12759	24928	8065	9054	15619	25498	5205	8484
20210223—20210228	22050	48805	21603	45901	12718	24806	8003	9079	15526	25434	5195	8451
20210301—20210307	22031	48788	21660	46054	12736	24821	8022	9071	15565	25428	5193	8464
20210308—20210314	22033	48799	21711	46023	12741	24768	8030	9103	15573	25399	5198	8472
20210315—20210321	22039	48799	21724	45968	12738	24706	8010	9054	15558	25328	5190	8432
20210322—20210328	22039	48774	21725	45942	12717	24731	7994	8973	15535	25277	5176	8427

对于同一市，各投放周期内不同类别的零售户数量分布基本保持一致，图 2 仅展示了 A、B 两市上某个投放周期（20210106—20210111）内各类零售户的数量分布。




图 2 20210106-20210111 投放周期内 A、B 市上各类别内零售户数量分布

Fig.2 Distribution of the number of retailers by different categories on the market A and B during the 20210106-20210111 delivery period

为了得到精确且稳定的识别模型，建模过程中采用 SMOTE 算法处理样本不均衡现象，采用 Grid Search CV 和控制变量法进行模型参数优化，并在每个投放周期内，使用 k-折交叉验证（k 默认为 5）策略进行多次模型训练与测试，再综合 k 次模型的预测结果来评价分类的效果。其中，较优识别模型的核心参数配置情况如下：

在 XGBOOST 模块中，学习速率为 0.1，决策子树棵数为 20，决策子树最大深度为 4，子节点中最小的样本权重和为 1；在 DNN 模块中，采用 4 层全连接网络，中间两个隐藏层神经元个数分别为 256、64，

输出层采用 SoftMax 激活，其他层激活函数为 ReLU，学习率为 1e-4，同时采用 RMSprop 加快梯度下降，保证网络收敛速度。

2.2 零售户档位识别效果对比

基于上述实验设置，训练卷烟零售户档位识别模型，再对测试集中的零售户进行档位判别，并采用 ACC、R_ACC、MAE 等指标对各投放周期内档位识别模型的效果进行评估，表 3 至表 5 分别给出了 A、B 市各投放周期内 3 种不同识别模型上各评价指标的平均值x和标准差s。

表 3 测试集上零售户分类准确率 ACC
Tab.3 The ACC of retailers on the testing set

投放周期	准确率 ACC（平均值 _{标准差} ）					
	A 市			B 市		
	LR	XGBOOST	DXGBOOST	LR	XGBOOST	DXGBOOST
20201228—20210105	86.61% _{0.0325}	93.64% _{0.0035}	93.90% _{0.0005}	84.32% _{0.0404}	92.80% _{0.0059}	94.45% _{0.0014}
20210106—20210111	89.02% _{0.0364}	97.25% _{0.0023}	97.55% _{0.0022}	82.75% _{0.0470}	90.43% _{0.0058}	91.49% _{0.0018}
20210112—20210117	84.12% _{0.0409}	96.58% _{0.0041}	97.36% _{0.0019}	69.60% _{0.0286}	86.83% _{0.0121}	90.70% _{0.0048}
20210118—20210123	86.06% _{0.0280}	95.90% _{0.0033}	96.59% _{0.0017}	56.11% _{0.0361}	78.49% _{0.0105}	86.16% _{0.0032}
20210124—20210129	87.42% _{0.0258}	97.10% _{0.0027}	97.47% _{0.0035}	73.41% _{0.0274}	85.78% _{0.0059}	87.89% _{0.0017}
20210130—20210203	86.69% _{0.0266}	95.31% _{0.0043}	96.37% _{0.0025}	76.49% _{0.0283}	88.57% _{0.0096}	91.73% _{0.0021}
20210204—20210208	86.72% _{0.0428}	96.67% _{0.0038}	97.58% _{0.0012}	69.96% _{0.0326}	82.82% _{0.0071}	87.92% _{0.0049}
20210223—20210228	88.72% _{0.0101}	92.99% _{0.0025}	93.06% _{0.0037}	72.64% _{0.0224}	81.20% _{0.0069}	81.78% _{0.0078}
20210301—20210307	79.62% _{0.0385}	91.12% _{0.0036}	92.12% _{0.0023}	59.58% _{0.0389}	77.25% _{0.0083}	81.46% _{0.0037}
20210308—20210314	78.19% _{0.0200}	87.38% _{0.0047}	87.85% _{0.0045}	72.09% _{0.0313}	82.83% _{0.0051}	86.03% _{0.0026}
20210315—20210321	83.82% _{0.0156}	89.70% _{0.0015}	90.00% _{0.0015}	74.41% _{0.0367}	82.31% _{0.0074}	86.42% _{0.0054}
20210322—20210328	90.20% _{0.0225}	96.31% _{0.0010}	96.48% _{0.0017}	82.72% _{0.0363}	92.34% _{0.0038}	93.23% _{0.0015}
汇总	85.60% _{0.0283}	94.16% _{0.0031}	94.69% _{0.0023}	72.84% _{0.0338}	85.14% _{0.0074}	88.27% _{0.0034}

从表 3 可以看出，非线性档位识别模型在 A、B 市上的整体正确率可分别达到 94%和 85%以上，相对于线性模型 LR 提高 10 个百分点左右；且 DXGBOOST

模型比 XGBOOST 模型准确率更高、档位识别效果相对更稳定。

表 4 测试集上零售户分类浮动准确率 R_ACC
Tab.4 The R_ACC of retailers on the testing set

投放周期	浮动准确率 R_ACC（平均值 _{标准差} ）					
	A 市			B 市		
	LR	XGBOOST	DXGBOOST	LR	XGBOOST	DXGBOOST
20201228—20210105	97.97% _{0.0054}	99.02% _{0.0005}	99.24% _{0.0007}	97.27% _{0.0119}	99.34% _{0.0016}	99.59% _{0.0003}
20210106—20210111	98.83% _{0.0039}	99.67% _{0.0003}	99.72% _{0.0003}	97.60% _{0.0114}	99.50% _{0.0006}	99.64% _{0.0003}
20210112—20210117	96.43% _{0.0129}	99.36% _{0.0008}	99.56% _{0.0008}	89.43% _{0.0147}	97.25% _{0.0046}	98.82% _{0.0010}
20210118—20210123	97.34% _{0.0085}	99.34% _{0.0006}	99.50% _{0.0006}	84.49% _{0.0250}	97.07% _{0.0044}	99.21% _{0.0010}
20210124—20210129	96.52% _{0.0096}	99.29% _{0.0005}	99.39% _{0.0006}	93.63% _{0.0153}	98.97% _{0.0013}	99.44% _{0.0010}
20210130—20210203	97.11% _{0.0065}	98.95% _{0.0020}	99.20% _{0.0005}	93.78% _{0.0177}	98.55% _{0.0017}	99.22% _{0.0007}
20210204—20210208	96.79% _{0.0068}	99.04% _{0.0019}	99.26% _{0.0007}	92.18% _{0.0173}	97.14% _{0.0030}	98.48% _{0.0006}
20210223—20210228	97.19% _{0.0045}	98.42% _{0.0019}	98.57% _{0.0026}	96.36% _{0.0103}	98.86% _{0.0008}	99.11% _{0.0006}
20210301—20210307	92.44% _{0.0196}	97.57% _{0.0023}	98.41% _{0.0007}	84.29% _{0.0307}	94.29% _{0.0066}	96.55% _{0.0029}
20210308—20210314	93.93% _{0.0118}	97.51% _{0.0028}	97.66% _{0.0032}	92.18% _{0.0136}	96.81% _{0.0018}	97.54% _{0.0015}
20210315—20210321	96.74% _{0.0034}	98.53% _{0.0013}	98.81% _{0.0008}	92.44% _{0.0190}	96.04% _{0.0040}	97.32% _{0.0021}
20210322—20210328	97.98% _{0.0040}	99.27% _{0.0011}	99.28% _{0.0005}	96.75% _{0.0090}	98.91% _{0.0008}	99.18% _{0.0009}
汇总	96.61 _{0.0081}	98.83% _{0.0013}	99.05% _{0.0010}	92.53% _{0.0163}	97.73% _{0.0026}	98.68% _{0.0011}

从表 4 可以看出，非线性档位识别模型 DXGBOOST 在 A、B 市上的整体浮动正确率相对于线性模型 LR 分别由 96.61%提升到 99.05%、92.53%

提升到 98.68%，更进一步提升零售户档位区间判别准确性。从各投放周期上看，均有 DXGBOOST 模型优于 XGBOOST 模型优于 LR 模型的识别效果。

表 5 测试集上零售户分类平均绝对误差 MAE
Tab.5 The MAE of retailers on the testing set

投放周期	平均绝对误差 MAE（平均值 _{标准差} ）					
	A 市			B 市		
	LR	XGBOOST	DXGBOOST	LR	XGBOOST	DXGBOOST
20201228—20210105	0.1700 _{0.0438}	0.0796 _{0.0032}	0.0752 _{0.0014}	0.1913 _{0.0536}	0.0813 _{0.0073}	0.0637 _{0.0022}
20210106—20210111	0.1284 _{0.0426}	0.0336 _{0.0030}	0.0304 _{0.0033}	0.2051 _{0.0614}	0.1019 _{0.0064}	0.0899 _{0.0022}
20210112—20210117	0.2197 _{0.0654}	0.0469 _{0.0064}	0.0382 _{0.0029}	0.4498 _{0.0442}	0.1677 _{0.0177}	0.1080 _{0.0053}
20210118—20210123	0.1898 _{0.0458}	0.0568 _{0.0061}	0.0487 _{0.0057}	0.6879 _{0.0819}	0.2542 _{0.0158}	0.1517 _{0.0039}
20210124—20210129	0.1950 _{0.0426}	0.0429 _{0.0018}	0.0388 _{0.0026}	0.3459 _{0.0496}	0.1550 _{0.0074}	0.1299 _{0.0031}
20210130—20210203	0.1788 _{0.0346}	0.0670 _{0.0074}	0.0521 _{0.0014}	0.3200 _{0.0566}	0.1332 _{0.0118}	0.0939 _{0.0033}
20210204—20210208	0.2091 _{0.0464}	0.0597 _{0.0093}	0.0439 _{0.0051}	0.4156 _{0.0528}	0.2150 _{0.0106}	0.1466 _{0.0043}
20210223—20210228	0.1791 _{0.0254}	0.1005 _{0.0105}	0.0986 _{0.0134}	0.3214 _{0.0361}	0.2021 _{0.0075}	0.1956 _{0.0063}
20210301—20210307	0.3552 _{0.0624}	0.1387 _{0.0075}	0.1165 _{0.0035}	0.6676 _{0.0977}	0.3088 _{0.0185}	0.2320 _{0.0075}
20210308—20210314	0.3188 _{0.0297}	0.1678 _{0.0049}	0.1608 _{0.0053}	0.3783 _{0.0471}	0.2100 _{0.0061}	0.1712 _{0.0040}
20210315—20210321	0.2346 _{0.0189}	0.1339 _{0.0033}	0.1304 _{0.0044}	0.3612 _{0.0647}	0.2303 _{0.0117}	0.1707 _{0.0062}
20210322—20210328	0.1580 _{0.0122}	0.0604 _{0.0072}	0.0612 _{0.0055}	0.2144 _{0.0476}	0.0911 _{0.0042}	0.0806 _{0.0027}
汇总	0.2114 _{0.0392}	0.0823 _{0.0059}	0.0746 _{0.0045}	0.3799 _{0.0578}	0.1792 _{0.0104}	0.1362 _{0.0042}

从表 5 可以看出，DXGBOOST 模型的 MAE 指标数值更小些。在一定程度上说明，虽然该识别模型存在对少量样本分类错误的推断，但分类误识别的偏差程度更轻。

综上所述，基于高维精准画像对零售户档位进行分类识别时，非线性模型能够充分利用数据潜在有效信息，挖掘到影响档位的客观规律；通过深度网络组

合 XGBOOST 模型的设计，可以在保证稳定性的同时进一步提高卷烟零售户档位识别效果。

2.3 零售户档位的潜在影响因素分析

通过对 XGBOOST 模型使用直接输出模型的重要特征，对 DNN 网络结构采用蒙克卡罗模拟的方式进行敏感性分析的方式，挖掘到影响卷烟零售户档位的相关因素。




图 3 2021 年元春市场 A、B 市上影响卷烟零售户档位的 TOP10 因素
Fig.3 The top ten factors affecting the grade of cigarette retailers on the market A and B during the New Year's Day and Spring Festival in 2021

图3给出影响A、B市上零售户档位识别效果的前10种因素及其重要性。可以看出:订购卷烟最高单价矫正下界贡献分位和订购卷烟最高单价矫正上界贡献分位分别是A、B市上最重要的影响因素,其次A市更注重基于订购卷烟最高单价、订购数量、订购卷烟种类数量、订购卷烟条均价等相关的衍生特征区分不同档位的零售户,而B市更易通过订购卷烟条均价衍生的贡献分位、均价值、排名等指实现对零售户的分档识别,为A、B市零售户如何提升档位提供一定的指导建议。

2.4 卷烟零售户动态分档策略

为做好零售户分档管理,本研究中基于高维精准画像体系和档位识别模型实现对每个投放周期内卷烟零售户进行立体画像与档位排名,为建立一个全新的基于自动学习的动态分类调整标准奠定基础。

对于正常经营的卷烟零售户,假设在近 N 个投放周期内的档位分别为 $K_1, K_2, K_3, \dots, K_N$,各投放周期内的档位权重为 $\omega_1, \omega_2, \omega_3, \dots, \omega_N$,其中 $0 \leq \omega_i \leq 1$,且越近投放周期内配置的档位权重越高,即 $\omega_1 \geq \omega_2 \geq \omega_3 \geq \dots \geq \omega_N$,则可以估计该零售户的当前档位为 $K = \left\lfloor \frac{\sum_{i=1}^N \omega_i \cdot K_i}{\sum_{i=1}^N \omega_i} \right\rfloor$ 。一般地,当按照月度动态调整档位时,取 $N = 4$,按照季度调整档位时,取 $N = 12$,视各地市情况确定权重 ω_i 的具体取值。

对于新入网零售户,初始申报档位设置上界值,同时基于相似零售户档位及内部经营条件,如:门店类型、经营面积、卷烟陈列背柜地柜数量、是否数字化经营等完成零售户档位初始化。 N 个投放周期后,同正常经营零售户一样参与档位识别模型的测算,若首次测算档位低于初始档位,考虑仍保持原初始档位以给予一次“保档”机会,后续按照正常经营零售户进行动态分档。

特别地,对于停歇业复供零售户,可在提供相关证明材料后申请维持原档;对于违法违规零售户,制定降档管理办法且自执行周期开始维持一定期限内存在升档上界的限制。

3 结论与展望

在人工智能技术赋能各行业进入新“智能化”阶段,本文结合卷烟订单与商业投放数据提出了一套将卷烟零售户高维画像与卷烟投放档位动态调整相结合

的智能化卷烟销售管理解决方案,并详细讲述了基于深度学习算法实现卷烟零售户档位识别的过程。特别地,考虑到梯度提升树XGBOOST虽然可有效挖掘多特征交叉信息,但存在仅利用叶子结点信息线性加和来进行分类的劣势,本文提出融合深度网络模型DNN对XGBOOST进行优化的DXGBOOST模型,进一步提升了模型的非线性化以及档位识别模型的预测效果和精度,同时通过特征重要性分析得到影响零售户档位的潜在因素,并介绍各类零售户档位动态调整的可行策略,为卷烟零售户档位提升、科学管理、精准营销等工作奠定了坚实的基础。

从数值实验的结果看来,可得出以下主要结论:

(1)基于本文提出的高维画像体系,零售户档位的识别准确率可以达到90%以上,浮动准确率接近100%,说明该指标体系对刻画档位是较精准的。

(2)卷烟零售户档位识别模型的预测精度对比为:DXGBOOST > XGBOOST > LR,其中非线性模型相比线性模型准确率可提升10%。

(3)本文提出的DXGBOOST模型对比具有较高识别能力的XGBOOST模型,ACC从85.14%提升到88.27%, R_ACC 从97.73%提升到98.68%,MAE从0.1792降低到0.1362,在一定程度上证明了大数据指标下基于高维画像进行识别时,基于非线性、深度的复杂模型的有效性和必要性。

(4)在不同地市上,影响零售户档位划分的因素存在一定的差异性,需要因地制宜地对零售户进行管理与服务。

(5)在任意投放周期内,基于档位识别模型可快速地评判有订购行为的零售户,可以满足对零售户实行动态分档调整的需求。

最后,总结经验与思考,尝试展望零售户分类未来的几个研究方向点:

(1)结合数字孪生或视觉分析技术,采集并挖掘更高维度的多源异构数据,丰富零售户画像指标体系,为卷烟零售户的聚类及分类提供参考依据。

(2)将不同档位的零售户分类识别转换成一个有序分类问题,从设计有序分类算法的角度出发,对档位识别模型进行调整与优化。

(3)引入更多实际销售例证,基于零售户档位分析营销策略,及时掌握卷烟营商环境状况,进一步拓宽零售户档位智能化应用与服务的场景。

参考文献

- [1] 马宗泽, 孙永寿, 薛寅. 基于商圈与动态规划理论的卷烟精准投放模型的研究[J]. 现代商业, 2021(15): 32-34.
MA Zongze, SUN Yongshou, XUE Yin. Research on the accurate delivery model of cigarettes based on business circle and dynamic programming theory[J]. Modern Business, 2021(15): 32-34.
- [2] 付秋璇. 卷烟货源精准投放的探索与应用[J]. 计算机时代, 2020(12): 47-52.
FU Qiuxuan. The exploration and application of precise supply strategy of cigarette[J]. Computer Era, 2020(12): 47-52.
- [3] 周宏. 基于大数据的烟草营销创新应用[J]. 信息技术与标准化, 2020(5): 66-70.
ZHOU Hong. Tobacco marketing innovation application based on big data[J]. Information Technology & Standardization, 2020(5): 66-70.
- [4] 吴涛涛. 基于 Hadoop 的江西卷烟零售户画像系统的设计与实现[D]. 南昌大学, 2018.
WU Yitao. The design and implementation of Jiangxi tobacco retailers' persona system based on Hadoop[D]. Nanchang University, 2018.
- [5] 邓超, 刘颂, 王露笛, 等. 基于深度神经网络的卷烟智能投放模型构建方法[J]. 烟草科技, 2021, 54 (2): 78-83.
DENG Chao, LIU Song, WANG Ludi, et al. Modeling for intelligent cigarette release based on deep neural network[J]. Tobacco Science & Technology, 2021, 54 (2) : 78-83.
- [6] Wei T, Huang F, Zhang X, et al. Research and application of data mining based on artificial intelligence in cigarette delivery[C]// 2020 International Conference on Big Data, Artificial Intelligence and Internet of Things Engineering (ICBAIE). IEEE, 2020: 184-189.
- [7] 王怡. 卷烟零售户分类及应用探索[J]. 科技广场, 2016(8): 172-177.
WANG Yi. Study on the classification and application of cigarette retailers[J]. Science Mosaic, 2016(8): 172-177.
- [8] 许泓, 刘文倩. 基于卷烟零售户销售潜力分值 (G 值) 的新产品投放策略研究[J]. 中国烟草学报, 2016, 22(1): 114-121.
XU Hong, LIU Wenqian. Study on strategy for new cigarette products launch based on retailers' sales potential (G value)[J]. Acta Tabacaria Sinica, 2016, 22(1): 114-121.
- [9] 雷恩杰, 李伟群. 卷烟投放策略研究[J]. 管理观察, 2014(27): 87-89.
LEI Enjie, LI Weiqun. Research on cigarette delivery strategy [J]. Management Observer, 2014 (27): 87-89.
- [10] 魏雨宸, 朱逸雯, 杜珏, 等. 荆州卷烟零售户精准划分及货源投放策略[J]. 合作经济与科技, 2020(2): 61-65.
WEI Yuchen, ZHU Yiwen, DU Jue, et al. Accurate division of cigarette retailers in Jingzhou and strategy for supplying goods[J]. Co-Operative Economy & Science, 2020(2): 61-65.
- [11] 朱卫东, 汪国珍, 李矿. SOM 聚类方法在卷烟零售户分类中的应用[J]. 烟草科技, 2014(6): 29-32.
ZHU Weidong, WANG Guozhen, LI Kuang. Application of SOM clustering method to classification of cigarette retailers[J]. Tobacco Science & Technology, 2014(6): 29-32.

Research on dynamic classification of cigarette retailers based on high-dimensional precise profiling and deep learning

TAN Chen¹, ZHOU Xinran¹, LUAN Xiaoyu¹, LI Mingang², YANG Yunli^{3*}, GU Minjie⁴, JIN Yazhao⁴

1 Information Center, Shanghai Tobacco Group Co., Ltd, Shanghai 200082, China;

2 Marketing Center, Shanghai Tobacco Group Co., Ltd, Shanghai 200082, China;

3 Shanghai Pintechs Technology Co., Ltd, Shanghai 201101, China;

4 Research Center of Digital Transformation for Enterprises, Beijing Institute of Big Data Research, Beijing 100080, China

Abstract: [Objective] This study aims to enrich the evaluation dimensions of cigarette retailers, establish the scientific standards for dynamic identification, and assist the marketing works such as grade adjustment, classification management, and delivery strategy formulation. [Methods] this paper introduces the overall solution for cigarette retailers identification, which is based on a high-dimensional precise profiling system and the deep learning model. Some effective strategies have been put forward, such as deducting the grade for retailers, designing the indicators of portrait, building the identification models, predicting and evaluating new samples, adjusting grade dynamically. In addition, by analyzing the importance of features, the potential influencing factors of retailers are excavated. [Results] In the numerical experiments, based on marketing data from multiple launch cycles in Markets A and B, a comparison of the classification recognition effects of the nonlinear deep learning DXGBOOST model with the linear regression LR model and gradient boosting XGBOOST model is presented. Compared with the linear LR, the DXGBOOST algorithm can increase the grade identification accuracy of retailers in Markets A and B by 9.09% and 15.43% respectively. Compared to the nonlinear XGBOOST, it further enhances the accuracy of precise grades and grade intervals, reducing the degree of misjudgment bias. [Conclusion] Practice has proven that, while ensuring stability, the grade identification method based on the DXGBOOST model can greatly improve the grading accuracy of cigarette retailers, providing data and theoretical support for timely conducting scientific, precise, and intelligent marketing analysis and business decision-making.

Keywords: precise profiling; grade identification; deep learning; DXGBOOST model; cigarette retailer

*Corresponding author. Email: yunli252@mail.ustc.edu.cn