

大数据环境下基于 K-means 的用户画像与智能推荐的应用

李冰¹, 王悦¹, 刘永祥²

1.中国烟草总公司北京市公司, 北京, 100122;

2.浪潮软件股份有限公司, 山东 济南, 250000

摘要: 随着中国烟草行业市场化取向改革日益深入以及计算机技术的快速发展, 如何利用新技术更准确的洞察市场、了解卷烟零售客户销售特征、针对性的为零售户提供适销对路的卷烟商品成为了行业内所共同关注的问题。本文探索了一种基于大数据技术及 K-means 算法的卷烟零售户特征画像, 并在此基础上实现了对零售户订货的智能推荐。

关键词: 大数据 ; 智能推荐 ; 聚类

The Application of User portrait and Intelligent Recommendation Based on Big Data Technology and K-means

1.Li Bing

2. Wang Yue

3. Liu Yong-xiang

(1. China National Tobacco Corp. Beijing Corp., Beijing 100122)

(2. China National Tobacco Corp. Beijing Corp., Beijing 100122)

(3. Inspur.inc, Jinan Shandong 250000)

Abstract: With the proceeding of China tobacco industry market oriented reform and the development of computing technology, departments of tobacco sales and marketing pay more and more attention to how to use new techniques to obtain accurate information of the market, understanding the sales characteristics of tobacco retailer and provide marketable tobacco goods for the retailer. In this paper, we explore a kind of tobacco retailer user portrait based on Big Data technology and K-means clustering algorithm, and provide the application of intelligent recommendation for tobacco ordering.

Keywords: Big Data; intelligent recommendation; clustering

1. 背景

2015 年以来,中国烟草行业逐步开始进行市场化取向改革。卷烟营销市场化取向改革是以满足消费者需求为核心,以改革卷烟订单采集方式为抓手,以营销流程再造为重点,保障零售客户自主经营权,层层传导市场力量,优化营销资源配置,促进品牌优胜劣汰,充分发挥改革乘数效应,全面增强行业整体竞争实力。

截至 2015 年 12 月 31 日,烟草行业市场化已经初见成效,基本实现了订单采集集中化、业务流程标准化、营销过程可视化,完成市场化改革的单位覆盖卷烟市场容量 1764 万箱,占全国卷烟销量的 35.4%,实现批发销售收入 5010 亿元,占全国卷烟销售收入的 35.2%,涉及零售客户 165 万户,占全国正常经营零售客户总数的 34%。

随着市场化改革范围的扩大和深入,原来计划体制下的卷烟营销方式逐渐难以满足快速变化的市场需求。与此同时,随着中国经济进入“新常态”以及北京市人口疏解工作的不断推进,北京市场的卷烟销售压力日益增加。因此北京烟草对如何准确洞悉市场信息、把握卷烟消费者和零售户的需求从而实现精准营销提出了更高的要求。

北京烟草经过十数年信息化建设,系统中存储着接近十年的海量交易数据。如何充分利用这些海量数据资源、把大数据技术及互联网企业的成功实践经验引入到北京烟草的信息化建设当中并成为市场化取向改革的强大助力,已成为北京烟草当前亟待解决的课题。本文实现了一种大数据技术的应用,即通过采集历史数据样本,建立聚类模型对卷烟零售户的特征进行画像,测算出零售户属性和卷烟属性中的相关性,并基于这些结果在卷烟零售客户订货时根据其特征推荐相关的卷烟产品。该方式一方面可以把市场中成熟的销售经验传递给新入网的零售户,另一方面可以促进北京烟草合理组织货源,主动为零售户提供了适销对路的商品,提高市场营销的准确度。

2. 大数据技术与聚类算法

2.1 大数据技术简介

学界与工业界对于所谓的“大数据”并没有一个统一的定义。如 2011 年 McKinsey 的研究报告[1]中将大数据定义为“超过了典型数据库软件工具捕获、

存储、管理和分析数据能力的数据集”，而美国国家标准和技术研究院 NIST 认为“大数据是指数据的容量、数据的获取速度或者数据的表示限制了使用传统关系方法对数据的分析处理能力，需要使用水平扩展的机制以提高处理效率”[2]。随着大数据技术的持续演进，其内涵与外延也不断得到发展，现在通常认为“大数据”包含海量结构化、半结构化以及无结构化数据，因此大数据相关技术与传统关系型数据库相比在处理非结构化数据和无结构化数据方面无论是在处理速度还是存储容量上均有较大优势。

大数据价值链可以分为四个阶段：数据生成、数据获取、数据存储和数据分析[3]。其中“数据生成”的工作主要是由相关业务系统或设备来完成，因此目前主流大数据技术主要负责后三个阶段的工作。其中 Apache Software Foundation 于 2005 年启动的 Hadoop 项目最为引人关注[4]。Hadoop 源自于对 Google Map/Reduce 和 Google File System 的开源模拟，也正是由于其开源特性，吸引了各国优秀计算机专家与工程师投身其中，不断对其丰富完善，现已发展为包含 spark 和 storm 等多个模块在内的既能实现离线大数据分析也能完成流式计算的主流大数据解决方案[5]，并在各行业中均有落地。

2.2 聚类算法

聚类分析是数据挖掘中的一种重要算法。聚类的目标是在没有任何先验知识的前提下，根据数据的相似性将数据聚合成不同的类（或簇），使得相同类中的元素尽可能相似，而不同类中的元素差别尽可能的大，因此又称为非监督分类（unsupervised classification）[6]。早在 20 世纪 70 年代，学界就对聚类算法有了比较深入的研究[7][8]，聚类的方法包括统计学方法和机器学习方法。

目前存在着多种聚类算法，其可以分为如下几类：基于划分的方法（Partitioning Method）、基于层次的方法（Hierarchical Method）、基于密度的方法（Density-Based）、基于网格的方法（Grid-Based）和基于模型的方法（Model-Based）等[9]。

K-means 算法由 Mac Queen 于 1967 年首先提出，该算法是目前为止在工业界和科学应用中一种极有影响的聚类算法[10]。K-means 是基于划分的方法中的一种，是典型的基于原型的目标函数聚类方法的代表[11]。K-means 聚类的目标就是在给定分类组数 k ($k \leq n$) 值的条件下，通过聚类把样本点按聚

集程度分成若干个簇，在同一个簇内具有较高的相似度，而在簇间的相似度较低。即对簇集合 $S = \{S_1, S_2, \dots, S_k\}$ ，在数值模型上，对以下表达式求最小值，其中 μ_i 表示分类 S_i 的平均值：

$$\arg \min \sum_{i=1}^k \sum_{x_j \in S_i} \|x_j - \mu_i\|^2$$

具体算法流程如下：

- (1) 从 n 个数据对象任意选择 k 个对象作为初始聚类中心；
- (2) 根据每个聚类对象的均值(中心对象)，计算每个对象与这些中心对象的相异度,将这些元素分别划归到相异度最低的簇；
- (3) 重新计算每个(有变化)聚类的均值(中心对象)；
- (4) 循环(2)到(3)直到每个聚类不再发生变化为止；
- (5) 输出结果。

通过每天的销售记录中的客户编码和卷烟编码把客户属性和卷烟属性关联在一起组成一条记录，获取到拥有 n 条数据记录的集合 $(x_1, x_2, \dots, x_n)$ ，并且每个 x_i 为 d 维的向量，即 $x_i (x_{i1}, x_{i2}, \dots, x_{id})$ ，其中 $x_{i1} \sim x_{id}$ 为客户属性和卷烟属性。

3. 大数据环境下基于 K-means 的用户画像与商品智能推荐模型

3.1 大数据平台技术架构

由于北京烟草现有信息系统中存储了大量历史交易数据，因此使用传统关系型数据库难以在可接受时间内完成对海量数据的分析与处理。北京烟草与浪潮软件股份有限公司共同搭建了基于 Hadoop 的大数据处理平台，将原有数据中心的历史数据保存到 HDFS 之中，并通过 MapReduce/SPARK 实现海量数据计算。




图 1 北京烟草大数据平台技术架构

3.2 数据挖掘工具的选取

本文中所采用的数据挖掘工具为 WEKA。WEKA 的全名是怀卡托智能分析环境（Waikato Environment for Knowledge Analysis），WEKA 作为一个公开的数据挖掘工作平台，集成了大量能承担数据挖掘任务的机器学习算法，包括对数据进行预处理，分类，回归、聚类、关联规则以及在新的交互式界面上的可视化。WEKA 可以与基于 Hadoop 的大数据平台相结合，实现较为完整的大数据分析解决方案。

3.3 基于 K-means 的用户画像

整个画像过程分为六个步骤，包括：

（1）确定业务场景

确定三个业务场景进行试验，三个业务场景分别为：场景 1.挖掘特征客户群对于卷烟品类的倾向性；场景 2.挖掘特征客户群对于产品类型的倾向性；场景 3. 挖掘特征客户群对于产地类型的倾向性。

（2）数据样本获取

从数据中心系统数据库中关联客户商品日销售表、客户表（通过客户编码关联）和卷烟表（通过卷烟编码关联），选取一个销售周期的数据，共获得样本数据 690177 条，把数据存为 weka 挖掘工具可用的 csv 格式，每条样本数据的字段列如下：

序号	类别	属性	描述
1	客户	CUST_CODE	客户编码
2		BASE_TYPE_CODE	业态编码
3		MARKET_TYPE_CODE	市场类型编码
4		AREA_TYPE_CODE	区域类型编码
5		SALE_SCALE_CODE	经营规模编码
6		BAL_MODE_CODE	结算方式编码
7		SALE_SCALE_KIND_NAME	订货档次名称
8		ORDER_WAY_CODE	订货方式编码
9		IS_R3	是否终端
10	卷烟	PRICE_KIND_CODE	价类编码
11		MFR_TYPE_CODE	产地类别编码
12		ITEM_TYPE_CODE	产品类型编码
13		CATEGORY_CODE	品类编码
14		PACK_KIND_CODE	包装类型编码

表 1 销售数据字段列表

(3) 数据预处理

数据预处理分为两步，第一步把样本中数字编码处理成字符编码，因为挖掘工具会把这些数字分类编码当成数值来处理，从而影响挖掘结果。需要处理的字段列包括：区域类型、经营规模、结算方式、订货方式、是否终端、价类、产地类别、品类、包装类型。第二步需要在 weka 预处理界面中打开样本数据集，剔除掉 CUST_CODE 列。

(4) 算法选择

选择聚类算法 K-means, 依据 Within cluster sum of squared errors 值的大小（越小越好）经过多次调试, 把算法参数 seed（随机种子数）设为 100。

(5) 调试

依次进行业务场景调试，初始时选择所有客户属性和与场景对应的卷烟属

性进行挖掘，依据 Within cluster sum of squared errors 值的大小以及生成的簇间关系进行调整，调整内容包括忽略掉某个客户属性（去掉无效列）、调整预生成簇的个数和调整 seed。

（6）结果分析

经过调试，最终确认的各个场景的结果如下：

场景 1：挖掘特征客户群对于卷烟品类的倾向性。

零售客户特征选择：业态（对应 BASE_TYPE_CODE）、经营规模（对应 SALE_SCALE_CODE）、月均订货量档次（对应 SALE_SCALE_KIND_CODE）；

卷烟属性设定为卷烟品类（对应 CATEGORY_CODE）。

聚类后，生成特征客户群，簇 0 和簇 1。其中簇 0 的特征为：业态为食杂店（标识为：‘Z’）的、经营规模为中的（标识为：‘2’）、月均订货量在 251—500 条的（标识为：‘A3’）零售客户倾向于订购卷烟零售价在 65（含）-105 之间的（标识为：‘C08’）卷烟；簇 1 的特征为：业态为便利店（标识为：‘B’）的、经营规模为中的（标识为：‘2’）月均订货量在 101—250 条的（标识为：‘A2’）零售客户倾向于订购卷烟零售价在 200（含）-260 元的（标识为：‘C05’）卷烟。

场景 2：挖掘特征客户群对于产品类型的倾向性。

零售客户特征选择：业态（对应 BASE_TYPE_CODE）、市场类型（对应 MARKET_TYPE_CODE）、区域类型（对应 AREA_TYPE_CODE）、经营规模（对应 SALE_SCALE_CODE）；

卷烟属性设定为产品类型（对应 ITEM_TYPE_CODE）。

聚类后，生成特征客户群，簇 0、簇 1 和簇 2。其中簇 0 的特征为：业态为食杂店（标识为：‘Z’）的、市场类型为城市的（标识为：‘C’）、区域类型为学区的（标识为：‘A03’）、经营规模为中的（标识为：‘S2’）零售客户倾向于订购烤烟型（标识为：‘IT1’）卷烟；簇 1 的特征为：业态为便利店（标识为：‘B’）的、市场类型为城市的（标识为：‘C’）、区域类型为工业区的（标识为：‘A02’）、经营规模为中的（标识为：‘S2’）零售客户倾向于订购混合型（标识为：‘IT2’）卷烟；簇 2 的特征为：业态为食杂店（标识为：‘Z’）的、

市场类型为乡村的（标识为：‘X’）、区域类型为学区的（标识为：‘A03’）\ 经营规模为大的（标识为：‘S1’）零售客户倾向于订购烤烟型（标识为：‘IT1’）卷烟。

场景 3: 挖掘特征客户群对于产地类型的倾向性。

零售客户特征选择：业态（对应 BASE_TYPE_CODE）、市场类型（对应 MARKET_TYPE_CODE）、月均订货量档次（对应 SALE_SCALE_KIND_CODE）；

卷烟属性设定为产地类别（对应 MFR_TYPE）。

聚类后，生成特征客户群，簇 0、簇 1 和簇 2。其中簇 0 的特征为：业态为食杂店（标识为：‘Z’）的、市场类型为城市的（标识为：‘C’）、月均订货量在 251—500 条的（标识为：‘A3’）零售客户倾向于订购省外（标识为：‘M1’）卷烟；簇 1 的特征为：业态为食杂店（标识为：‘Z’）的、市场类型为城市的（标识为：‘X’）、月均订货量在 101—250 条的（标识为：‘A2’）零售客户倾向于订购省外（标识为：‘M1’）卷烟；簇 2 的特征为：业态为便利店（标识为：‘B’）的、市场类型为城市的（标识为：‘C’）、月均订货量在 101—250 条的（标识为：‘A2’）零售客户倾向于订购省内（标识为：‘M0’）卷烟。

3.4 商品智能推荐模型

在完成零售户画像的基础之上，在零售客户网上订烟平台新商盟网站应用数据挖掘的结果，对符合特征的客户推荐对应特征的卷烟商品。比如向业态为食杂店的、市场类型为城市的、区域类型为学区的、经营规模为中的零售客户推荐烤烟型卷烟。

5. 结束语

本文基于大数据技术采用 K-means 实现了用户画像与智能推荐，为北京烟草市场化取向改革的进一步推进提供了新的思路和方法。但由于本方案是基于零售客户的历史订货数据而不是从周边区域消费者角度分析各类特征，如区域人口分布、性别比、消费能力等，因此零售户画像以及在此基础上实现的智能推荐在准确度上尚有不足，需要进一步改进。

参考文献：

[1] Manyika J, Chui M, Brown B, et al. Big data: the next frontier for

innovation, competition, and productivity. McKinsey Global Institute, 2011

[2]Cooper M, Mell P. Tackling Big Data. NIST, 2012

[3]李学龙, 龚海刚. 大数据系统综述[J]. 中国科学: 信息科学, 2015, 第 45 卷 第一期: 1-44

[4] <http://hadoop.apache.org/>

[5]赵晟, 姜进磊. 典型大数据计算框架分析[J]. 中兴通讯技术. 2016. 4

[6]陈丽. 数据挖掘中聚类算法研究[D]. 2007

[7]Bijne ET. Cluster analysis [M]. Netherlands: Tiberg University Press, 1973

[8]Everitt B. Cluster analysis [M]. London: Heinemann Educational Books Ltd., 1974

[9]Jiawei Han, Micheline Kamber. 数据挖掘概念与技术[M]. 范明, 孟小峰等译. 北京: 机械工业出版社, 2001

[10] J. B. MacQueen. Some Methods for classification and Analysis of Multivariate Observations. Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability . Berkeley, University of California Press, 1:281-297

作者简介: 李 冰 (1984~), 男 (汉族), 北京市人, 中国烟草总公司北京市公司经济信息中心工程师, 博士, 研究方向: 云计算与大数据。

联系地址: 北京市朝阳区南新园西路 2 号

邮编: 100122

电子邮箱: vincent_lisiyi@163.com

联系电话: 010-67009039 18611847362